

论文信息

MoH: MULTI-HEAD ATTENTION AS MIXTURE-OF-HEAD ATTENTION

Peng Jin^{1,2*}, Bo Zhu⁴, Li Yuan^{1,2,3} ✉, Shuicheng Yan⁴ ✉

¹School of Electronic and Computer Engineering, Peking University, Shenzhen, China

²Peng Cheng Laboratory, Shenzhen, China

³Rabbitpre Intelligence, Shenzhen, China

⁴Kunlun 2050 Research & Skywork AI, Singapore

jp21@stu.pku.edu.cn, yuanli-ece@pku.edu.cn

Code: <https://github.com/SkyworkAI/MoH>

论文题目: MoH: Multi-Head Attention as Mixture-of-Head Attention

中文题目: MoH: 多头注意力作为混合头注意力

论文链接: <https://arxiv.org/pdf/2410.11842?>

官方 github: <https://github.com/SkyworkAI/MoH>

所属机构: 北京大学深圳电子与计算机工程学院, 深圳鹏城实验室, 深圳兔智科技, 新加坡昆仑2050 研究与 Skywork AI

关键词: 多头注意力机制、混合注意力机制、图像分类、图像生成、大语言模型

核心速览: 本文提出了一种新的多头注意力机制, 称为混合头注意力 (MoH), 它将注意力头视为混合专家 (MoE) 机制中的专家。MoH 通过选择最相关的注意力头来增强推理效率, 同时保持或超越之前的准确度水平。