

论文信息

Agent Attention: On the Integration of Softmax and Linear Attention

Dongchen Han^{1*}, Tianzhu Ye^{1*}, Yizeng Han¹, Zhuofan Xia¹, Siyuan Pan², Pengfei Wan², Shiji Song¹ and Gao Huang^{1**}

¹ Department of Automation, Tsinghua University

² Kuaishou Technology

论文题目: Agent Attention: On the Integration of Softmax and Linear Attention

中文题目: 代理注意力: 关于 Softmax 和线性注意力的整合

论文链接: <https://arxiv.org/pdf/2312.08874>

官方 github: <https://github.com/LeapLabTHU/Agent-Attention>

所属机构: 清华大学自动化系, 快手科技

核心速览: 本文提出了一种名为 Agent Attention 的新型注意力机制, 旨在平衡计算效率和表达能力, 通过引入一组代理令牌 (agent tokens) 来提高 Transformer 模型在视觉任务中的性能。