


论文信息



论文题目: SLAB: Efficient Transformers with Simplified Linear Attention and Progressive Re-parameterized Batch Normalization

中文题目: SLAB: 具有简化线性注意力和渐进式重参数化批量归一化的高效变换器

论文链接: <https://arxiv.org/pdf/2405.11582>

官方 github: <https://github.com/xinghaochen/SLAB>

所属机构: 华为诺亚方舟实验室

核心速览: 本文提出了一种名为 SLAB 的高效 Transformer 模型, 通过简化线性注意力模块 (SLA) 和渐进式重参数化批量归一化 (PRepBN) 来解决 Transformer 在资源受限设备上部署的高计算成本问题。

```
RepBN(  
  (bn): BatchNorm1d(32, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
)  
微信公众号:AI缝合术, nb!  
Input shape: torch.Size([1, 256, 32])  
Output shape: torch.Size([1, 256, 32])
```

公众号 · AI缝合术

```
RepBN2d(  
  (bn): BatchNorm2d(32, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
)  
微信公众号:AI缝合术, nb!  
Input shape: torch.Size([1, 32, 256, 256])  
Output shape: torch.Size([1, 32, 256, 256])
```

公众号 · AI缝合术