


论文信息



论文题目: Token Statistics Transformer: Linear-Time Attention via Variational Rate Reduction

中文题目: Token 统计 Transformer: 基于变化率降低的线性时间注意力

论文链接: <https://arxiv.org/pdf/2412.17810>

官方 github: <https://github.com/RobinWu218/ToST>

所属机构: 加州大学伯克利分校, 宾夕法尼亚大学, 密歇根大学, 清华大学, 香港大学, 约翰霍普金斯大学

核心速览: 本文提出了一种新的变分形式的 MCR2 目标函数, 并通过梯度下降法推导出一种新的注意力模块, 称为 Token Statistics Self-Attention (TSSA)。TSSA 通过计算输入令牌特征的基于经验的二阶矩统计量, 避免了计算输入令牌之间的成对相似性, 从而实现了线性复杂度的注意力计算。