


论文信息



论文题目: Transformers without Normalization

中文题目: 无归一化的 Transformer

论文链接: <https://arxiv.org/pdf/2503.10622>

官方 github: <https://github.com/jiachenzhu/DyT>

所属机构: Meta FAIR (原属 Facebook 公司), 纽约大学, 麻省理工学院, 普林斯顿大学

核心速览: 本文提出了一种名为 Dynamic Tanh (DyT) 的简单技术, 用以替代 Transformer 中的归一化层, 展示了不使用归一化层的 Transformer 同样可以达到甚至超越使用归一化层的性能。

Dynamic Tanh (DyT) 技术: 提出了一种名为 Dynamic Tanh (DyT) 的技术, 作为 Transformer 中传统

归一化层的替代品。DyT 通过一个可学习的参数 α 来调整输入激活范围，并通过 $\tanh$ 函数压缩极端值，从而无需计算激活统计数据即可实现归一化层的效果。

Algorithm 1 Pseudocode of DyT layer.

```
# input x has the shape of [B, T, C]
# B: batch size, T: tokens, C: dimension
```

```
class DyT(Module):
    def __init__(self, C, init_α):
        super().__init__()
        self.α = Parameter(ones(1) * init_α)
        self.γ = Parameter(ones(C))
        self.β = Parameter(zeros(C))

    def forward(self, x):
        x = tanh(self.alpha * x)
        return self.γ * x + self.β
```

DynamicTanh()

微信公众号: AI缝合术!

输入张量的形状: torch.Size([1, 32, 256, 256])

输出张量的形状: torch.Size([1, 32, 256, 256])