

核心速览

Algorithm 1 PnP-Nystra in (7): Self-Attention Approximation

Require: Queries $\mathbf{Q} \in \mathbb{R}^{N \times d}$, Keys $\mathbf{K} \in \mathbb{R}^{N \times d}$, Values $\mathbf{V} \in \mathbb{R}^{N \times d_v}$, number of landmarks m

(Step 1) Select m landmark query and key vectors to form landmark matrices $\tilde{\mathbf{Q}} \in \mathbb{R}^{m \times d}$, $\tilde{\mathbf{K}} \in \mathbb{R}^{m \times d}$

(Step 2) Compute core matrix $\mathbf{G}_A \in \mathbb{R}^{m \times m}$ in (4)

(Step 3) Compute cross-similarity matrices $\mathbf{G}_L \in \mathbb{R}^{N \times m}$ and $\mathbf{G}_U \in \mathbb{R}^{m \times N}$ in (5)

(Step 4) Compute pseudoinverse $\mathbf{G}_A^\dagger \in \mathbb{R}^{m \times m}$

(Step 5) Compute premultiplier $\mathbf{P} \in \mathbb{R}^{N \times m}$ as $\mathbf{G}_L \mathbf{G}_A^\dagger$

(Step 6) Compute numerator $\mathbf{O}_N = \mathbf{P} (\mathbf{G}_U \mathbf{V}) \in \mathbb{R}^{N \times d_v}$ and compute denominator $\mathbf{O}_D = \mathbf{P} (\mathbf{G}_U \mathbf{1}_N) \in \mathbb{R}^{N \times 1}$

(Step 7) Normalize $\hat{\mathbf{O}} = \mathbf{O}_N \oslash \mathbf{O}_D$ (row-wise division)

return Output $\hat{\mathbf{O}} \in \mathbb{R}^{N \times d_v}$

公众号 · AI缝合术

论文题目: Plug-and-Play Linear Attention for Pre-trained Image and Video Restoration Models

中文题目: 即插即用线性注意力机制在预训练图像与视频修复模型中的应用

论文链接: <https://arxiv.org/pdf/2506.08520>

所属单位: 印度理工学院马德拉斯分校电气工程系

核心速览: 本文提出了一种名为 PnP-Nystra 的新型线性注意力, 作为预训练图像和视频恢复模型中多头自注意力 (MHSA) 的即插即用替代方案, 能够在不重新训练的情况下实现显著加速并保持较高恢复质量。

论文内容详细解读:

<https://mp.weixin.qq.com/s/Tut6JZpuBDRkvNAcXOtUBA>