

部分通道网络：计算更少，性能更优

黄海朵、田霞、赵文哲、任鹏菊西安交通大学·人工智能与机器人

研究所

huanghd@stu.xjtu.edu.cn, stian xia@xjtu.edu.cn, wenzhe@xjtu.edu.cn, pengjuren@xjtu.edu.cn

摘要

设计一种能够在不牺牲精度和吞吐量的情况下使网络保持低参数和低FLOPs的模块或机制仍是一个挑战。为解决这一挑战并利用特征图通道内的冗余性，我们提出了一种新方案：**部分通道机制（PCM）**。具体而言，通过分割操作，特征图通道被划分为不同部分，每个部分对应不同的操作，如卷积、注意力、池化和恒等映射。基于这一假设，我们引入了一种新颖的**部分注意力卷积（PATConv）**，能够高效地将卷积与视觉注意力结合。我们的探索表明，PATConv可以在减少模型参数和FLOPs的同时完全替代常规卷积和常规视觉注意力。此外，PATConv可衍生出三种新型模块：部分通道-注意力模块（PAT_ch）、部分空间注意力模块（PAT_sp）和部分自注意力模块（PAT_sf）。此外，我们提出了一种新颖的**动态部分卷积（DPConv）**，该方法能够自适应学习不同层中分割通道的比例，从而实现更优的性能平衡。基于PATConv和DPConv，我们提出了一种名为**PartialNet**的新型混合网络家族，该网络在ImageNet-1K分类任务上相比部分SOTA模型展现出更优的top-1准确率和推理速度，并在COCO数据集上同时表现出色的检测和分割能力。我们的代码可在<https://github.com/haiduo/PartialNet>获取。

1. 介绍

设计高效且有效的神经网络一直是计算机视觉研究中的重要课题。为了设计高效的网络，许多先前的研究采用深度可分离卷积（DWConv）[13]作为常规密集卷积的替代方案。例如，一些基于CNN的模型[27, 30]利用DWConv来降低模型的FLOPs和参数量，而基于混合模型的模型[11, 26, 37]则采用DWConv来模拟自注意力机制。

降低计算复杂度的操作。然而，一些研究[5, 20]表明，DWConv在推理过程中可能因频繁内存访问和低并行性[3]而导致吞吐量低下。




图1. 不同手术类型的比较

考虑到特征图之间存在显著冗余[3, 8]，为在降低计算成本和参数数量的同时提升模型推理速度与精度，我们引入了部分通道机制（PCM）以充分挖掘特征图通道的价值。PCM通过分割操作将特征图划分为不同部分，每个部分经过差异化处理后，再通过拼接操作进行整合。我们的核心洞见在于：通过合理分配不同操作并采用成本更低、效率更高的运算符部分替代高成本密集型运算符，可以在提升模型推理速度的同时进一步增强其准确性。具体而言，我们的方法通过用计算成本较低的视觉注意力机制替代计算密集型卷积，从而增强模型表征能力并加快推理速度。基于这一理念，我们提出了一种新型部分注意力卷积（PATConv），该机制既能替代常规卷积和常规视觉注意力，又能有效减少模型参数量和浮点运算量（FLOPs）。该方法主要将部分卷积与部分视觉注意力相结合。

如图1所示。

近期部分研究虽然尝试对特征图进行分割，但采用的仍是简单粗暴的处理方式——对部分特征图进行操作，而另一部分则保持原样。例如，ShuffleNet V2[20]引入的“通道分割”操作，将输入特征通道划分为两部分：一部分直接保留，另一部分则经过多层卷积处理。类似地，FasterNet[3]提出的局部卷积（PConv）技术，通过选择性地对部分输入通道应用卷积运算，而对其他通道保持原样。这种设计使得PConv在推理速度上比常规卷积和深度卷积（DWConv）更快。但这些研究仅从减少特征通道数量的角度考虑模型性能提升，却忽视了其他通道部分的潜在价值。

因此，我们认为从全局视角出发，通过利用全部特征通道来综合考量整体浮点运算量、推理速度和准确率更为合理。具体而言，我们提出将卷积层与注意力机制相结合，分别应用于部分通道。由于目前缺乏针对部分通道的有效注意力算法，我们创新性地设计了三种高效的局部视觉注意力模块：(1) PAT_ch整合了增强型高斯通道注意力机制[14]，促进通道间更丰富的全局信息交互；(2) PAT_sp在MLP层引入空间注意力机制，进一步提升模型精度；(3) PAT_sf借鉴MetaFormer架构[38]，将全局自注意力机制融入模型末级，从而扩展其全局感受野。

尽管上述改进能提供更强大的视觉模型，但考虑到延迟和参数的限制，部分卷积与部分视觉注意力之间的通道分割比例仍需进一步优化。为解决这一问题，我们借鉴动态分组卷积[39]的思想，提出了一种新型动态部分卷积方法。该方法能够根据参数和延迟等约束条件，自适应地学习不同层的分割比例，从而在模型推理速度与准确度之间实现最佳平衡。

综上所述，我们提出的改进模型被命名为PartialNet，如图2所示，该模型在保持相似吞吐量的同时，显著提升了ImageNet1K分类任务的整体性能。我们的主要贡献可概括为：

- 我们提出一种部分通道机制，并引入部分注意力卷积（PATConv），该机制以并行方式将视觉注意力整合到部分卷积中，这与先前研究的串行方式不同，可在提高推理速度的同时提升模型性能。
- 基于PATConv，我们开发了三种部分视觉




图2. 我们的PartialNet在ImageNet-1K数据集上实现了更高的准确率与吞吐量折衷。

注意力块：PAT_ch展现出作为常规卷积和DWConv替代方案的高潜力，PAT_sp能以最小成本有效增强MLP层，而PAT_sf则整合局部与全局特征，从而提升准确率。

- 为在模型推理速度与准确度之间实现更优的平衡，我们提出了一种新型动态部分卷积（DPConv），该方法可根据约束条件（例如模型参数）自适应地学习不同层的分割比例。
- 基于上述方法，我们设计了一种名为PartialNet的新型混合模型家族，该模型在标准视觉基准测试中表现优于大多数高效SOTA模型。

2. 相关工作

高效的CNN与ViT。 DWConv被广泛应用于高效神经网络的设计中，例如MobileNets[12, 27]、EfficientNets[30, 31]、MobileViT[21]以及EdgeViT[23]。由于其在现代并行设备上的效率限制，大量研究致力于改进该架构。例如，RepLKNet[5]采用大核DWConv以缓解计算利用率不足的问题。PoolFormer[38]仅通过池化操作实现空间交互即可获得强劲性能。近期，FasterNet[3]通过引入部分卷积同时减少浮点运算和内存访问。然而，FasterNet在准确率上并未超越其他视觉模型。相比之下，我们提出的PartialNet通过将视觉注意力整合到卷积中来提升模型准确率，从而解决了这一局限。

视觉注意力。 视觉变换器（ViTs）的有效性主要归因于注意力机制的作用[24, 25]。在视觉任务中，注意力机制通常分为三类：

通道注意力、空间注意力与自注意力。部分研究[2, 22, 26, 29]采用多种技术高效实现自注意力机制，例如线性注意力[2, 32]。此外，通道注意力与空间注意力的有效性已在 SRM [17]、SE-Net[14]和 CBAM [34]中得到验证。类似地，我们对同一特征采用并行方式结合注意力机制，并通过部分注意力来缓解元素级乘法对整体推理速度的影响。

3. 方法学

在本节中，我们首先阐述了通过视觉注意力增强部分卷积的动机，并提出创新的“部分注意力卷积”（PATConv）机制。该机制通过在特征通道子集上应用注意力机制，在计算效率与准确度之间取得平衡。随后详细说明PATConv中的三个创新模块：部分通道注意力模块（PAT_ch），将Conv3×3与通道注意力相结合以实现全局空间交互；部分空间注意力模块（PAT_sp），通过Conv1×1与空间注意力的结合，高效整合通道级信息；以及部分自注意力模块（PAT_sf），选择性应用自注意力以扩展模型的感受野。我们进一步引入具有自适应通道分割比例的可学习动态部分卷积（DPConv），以提升模型灵活性。最后，我们描述了整体架构——部分网络（PartialNet）采用四层分层结构，通过集成PATConv模块，旨在实现不同模型变体间的稳健速度-准确度平衡。

3.1. 部分通道机制

通常来说，设计高效的神经网络需要从多个角度进行全面考量和优化，包括减少浮点运算次数、缩小模型体积、降低内存访问量以及提升精度。近期，部分研究（如MobileViTv2[22]和EfficientViT[2]）尝试将深度可分离卷积与自注意力机制结合，以减少模型参数和延迟。其他研究（如ShuffleNetv2[20]和FasterNet[3]）则通过仅使用特征图部分通道进行特征提取，试图降低浮点运算次数并提升推理速度。然而，与参数或浮点运算量相近的模型相比，这些方法并未展现出显著的精度优势。其中，FasterNet仅使用部分卷积操作，在各类设备上实现了卓越的运行速度。但我们发现，FasterNet仅对部分通道执行卷积运算，虽然能降低浮点运算次数和延迟，但会导致特征交互有限且缺乏全局信息交换。

相比之下，我们全面挖掘了其潜力

在特征图的各个通道中进行价值评估。针对不同的特征通道，我们采用不同的操作策略，在提升模型精度的同时进一步降低浮点运算量，这种机制被称为部分通道机制。基于此，我们提出了一种新型卷积运算——部分注意力卷积（PATConv），它用成本效益更高的视觉注意力机制替代了计算密集型的全卷积操作。已有研究[3, 8]表明，特征通道之间存在冗余性，因此对部分通道应用注意力机制本质上是一种全局信息交互形式。

与常规视觉注意力方法不同，我们的PATConv由于仅使用部分通道进行计算密集的逐元素乘法运算而更高效。事实上，通过在独立分支上并行执行两个操作可实现同步计算，从而优化GPU资源利用率[16]。假设PATConv的输入和输出分别表示为 $F \in \mathbb{R}^{h \times w \times c_{in}}$ 和 $O \in \mathbb{R}^{h \times w \times c_{out}}$ ，其中 c_{in} 和 c_{out} 分别代表输入和输出通道数， h 、 w 分别为通道的高度和宽度。假设 $c_{in} = c_{out}$ ，PATConv可定义为

$$O = \text{PATConv}(F) = \text{Conv}(F^{c_{in} \times r_p}) \cup \text{Atten}(F^{c_{in} \times (1-r_p)}) \quad (1)$$

其中符号 $\cup$ 和Atten分别表示拼接操作和视觉注意力操作。 r_p 是表征通道分割比例的超参数，可进行自适应学习。

此外，PATConv可应用通道级与空间级混合以增强全局信息，并整合自注意力机制以扩展模型的感受野，从而推导出三个模块，经证实具有高度有效性。

PAT_ch：我们首先提出整合卷积3×3与包含全局空间信息交互的通道注意力机制，并采用增强型高斯统计-熵模块计算通道均值与方差以压缩全局空间信息。与SENet[14]不同，该方法仅考虑通道的均值信息而忽略标准差的统计信息。考虑到特征图在训练过程中服从近似正态分布[15]，我们充分利用高斯统计特性来表达通道级表征信息，如图3(b)所示。

PAT_sp：其次，我们将空间注意力与Conv1×1结合，因为这两种操作都混合了通道信息。我们的空间注意力采用逐点卷积将全局通道信息压缩为仅含单个通道的张量。经过Hard-Sigmoid激活后，该张量作为空间注意力图来加权特征。我们将PAT_sp置于MLP层之后，使得PAT_sp的Conv1×1组件在推理时能与MLP层的第二个Conv1×1融合，如图3(c)所示。这种设置进一步最小化了注意力对推理速度的影响，其融合细节




图3. 我们的PartialNet整体架构由四个层级阶段组成，每个阶段包含一系列PartialNet模块，随后是嵌入或融合层。最后三个层专门用于特征分类。其中 $\odot$ 和 $\cdot$ 分别表示元素乘法和矩阵乘法。

操作步骤参见附图1(d)。

PAT sf: 最后，自注意力机制不仅参与空间信息交互，还能扩展模型的有效感受野，从而替代传统通道注意力机制。但由于自注意力运算的计算复杂度会随特征图尺寸呈平方增长，我们将其应用限制在模型的最后阶段，以实现更优的运算效率与精度平衡。此外，我们在注意力图中引入了相对位置编码（RPE）[35]，如图3(e)所示，该技术能进一步提升模型精度。

值得注意的是，与传统卷积神经网络（CNN）结合注意力机制逐级处理不同，我们的方法能在同一输入上同步处理多个步骤，从而优化速度与精度的平衡。此外，PATConv不仅限于上述三种组合方式，还可高效整合更多视觉注意力模块。

3.2. 可学习的动态部分卷积

对于PATConv而言，分割比例 r_p 是一个关键超参数，它会显著影响模型的参数设置和响应时延。若 r_p 设置过大，PATConv就会退化为普通卷积层，导致视觉注意力组件无法有效捕捉全局信息；反之，若 r_p 过小，则PATConv会缺失必要的局部归纳偏置信息。

在相似条件下实现更高的准确性和通量

复杂性通常需要大量实验来确定最优 r_p 。在FasterNet中，所有变体的默认分割比例为1/4。相比之下，我们提出了一种动态部分卷积（DPConv），其中 r_p 是可学习的。该方法允许模型在训练过程中自适应地确定不同层的最优 r_p 。这些策略可通过二元关系矩阵 $U \in \{0, 1\}^{c_{in} \times c_{out}}$ [39]建模。整个矩阵 U 可分解为一组 K 个小矩阵 $U_k \in \{0, 1\}^{2 \times 2}$ ，其中 U_k 要么等于一个 2×2 的常数矩阵 $\mathbf{1} \mathbf{1}$ ，要么等于 2×2 的单位矩阵 I ，即。

$$U = U_1 \otimes U_2 \otimes \dots \otimes U_K \quad (2)$$

$$U_k = g_k \mathbf{1} \mathbf{1} + (1 - g_k) I, \quad g_k \in \{0, 1\}^K, \quad g = \text{Sign}(\tilde{g}) \quad (3)$$

其中 $\otimes$ 表示克罗内克积[1]， $\tilde{g} \in \mathbb{R}^K$ 是一个可学习的连续值门向量，而 $g \in \{0, 1\}^K$ 是一个二进制门向量，其导出自 $\tilde{g}$ 。由于Sign函数不可微，门参数采用直通估计器[4]进行优化，类似于二进制网络量化方法，以确保收敛。假设 $c_{in} = c_{out}$ ，则 $K = \log_2 c_{in}$ 。DPConv可定义为

$$O = \text{DPConv}(F) = U \odot \mathbf{m} \odot W \quad (4)$$

其中 $\odot$ 表示元素乘积， $\mathbf{m} \in \mathbb{R}^c$ 是用于屏蔽 U 中无用部分的向量。由于克罗内克积的结果是一个 2^K 的幂次矩阵，模型每一层的通道数也需要为 2^K 。

因此，不难推断

$$r_p = \frac{2^{\sum_{k=1}^L c_l}}{c} = \frac{1}{c} \cdot \frac{1}{(\ln 2)^{\sum_{k=1}^L c_l}} \cdot \mathbf{m} = \begin{cases} 10 & \text{if } i \geq \frac{1}{r_p} \\ 1 & \text{otherwise} \end{cases} \quad (5)$$

其中 g_k 表示 g 的第 k 个分量。DPConv的具体生成过程如图4所示。




图4. DPConv的生成过程，其中 $\odot$ 表示逐元素乘积， $\otimes$ 表示克罗内克积。

考虑到模型部署的限制条件（例如参数和浮点运算次数），有必要限制学习得到的 r_p 以避免其过大。为此，我们为DPConv设计了一种资源受限的训练方案。为简化计算，假设仅考虑部分卷积的情况。我们提出一个正则化项 ζ 来约束计算复杂度。

$$\zeta = \sum_{l=1}^L \zeta_l, \quad \zeta_l = \sum_{i=1}^{c_{in}} \sum_{j=1}^{c_{out}} u_{ij}, \quad \forall u_{ij} \in U \quad (6)$$

其中 L 表示DPConv层的数量， u_{ij} 表示 U 的元素。 ζ_l 项代表 U 中非零元素的数量，用于衡量第 l 个DPConv层激活的卷积权重数量。因此， ζ 可视为模型计算复杂度的度量指标。实际上，可以推导出 U 每一行或每一列的总和 can be calculated as $\prod_{k=1}^K (1+g_k)$ 。将其代入等式(6)可得

$$\zeta = \sum_{l=1}^L \left(\prod_{k=1}^{K^l} (1+g_k^l) \cdot \prod_{k=1}^{K^l} (1+g_k^l) \right) = \sum_{l=1}^L 2^{2 \cdot \sum_{k=1}^{K^l} g_k^l} \quad (7)$$

其中 g_k^l 和 K^l 分别表示第 l 层中的 g_k 和 K 。此处假设 $c_{in} = c_{out}$ 。令 $\varphi = \frac{1}{c} \sum_{l=1}^L \sum_{k=1}^{K^l} g_k^l$ 表示整个网络的期望计算复杂度。通过设置 φ ，我们可以控制PartialNet的整体复杂度。例如，当 $\varphi=4$ 时，其复杂度等于FasterNet中 $r_p=1/4$ 的复杂度。因此，一个加权乘积 $[\frac{\zeta}{c}]^\alpha$ 用于近似帕累托最优问题， ζ

是一个通过经验设定的常数值。当 $\varphi \leq \varphi$ 时，我们有 $\zeta = 0$ ，这意味着复杂度约束得到满足。否则， $\zeta = -0.01$ 用于在 $\varphi > \varphi$ 时对模型复杂度进行惩罚。

此外，分裂比例掩码与门向量 g 密切相关。只有当 g 中的元素按顺序排列，使得DPConv中 l 的所有元素都位于1之前时，才能生成合理的克罗内克积。因此，需要通过引入正则化损失项 f 来约束 g ，该损失项可通过

$$\psi = \sum_{l=1}^L f_l, \quad f_l = \begin{cases} 0 & \text{if } g_i^l = 1 \text{ and } g_{i+1}^l = 0 \\ 1 & \text{otherwise} \end{cases} \quad (8)$$

最后，我们的目标是寻找一个PartialNet模型

$$\begin{cases} \mathcal{L}(\{w_l\}_{l=1}^L, \{\tilde{g}_l\}_{l=1}^L) \cdot [\frac{\zeta}{c}]^\alpha + \psi\beta, \\ \zeta \leq \kappa. \end{cases} \quad (9)$$

其中 $\zeta \in (0, 1]$ 是 f 的惩罚因子，默认值为0.9。

3.3. 部分网结构

PartialNet的整体架构如图3所示，由四个层级阶段组成，每个阶段前均有一个嵌入层（常规Conv 4×4 ，步长4）或一个合并层（常规Conv 2×2 ，步长2）。这些层用于空间下采样和通道数扩展。每个阶段包含一组PartialNet模块。在PartialNet的前三个阶段中，我们采用包含PAT_ch模块和PAT_sp模块的“PartialNet Block v1”，如图3(a)所示。类似地，在最后一个阶段中，我们将PAT_ch替换为PAT_s，并修改快捷连接方式以实现稳定训练，采用“PartialNet Block v2”，如图3(d)所示。

此外，我们仅在每个中间Conv 1×1 层后保留归一化或激活层，以保持特征多样性并实现更高吞吐量。同时，我们在相邻的Conv层中引入批量归一化，以在不牺牲性能的前提下加速推理。对于激活层，较小的PartialNet变体采用GELU，而较大的PartialNet变体则使用ReLU。最后三个层由全局平均池化、Conv 1×1 和全连接层组成，这些层共同负责特征转换和分类。我们提供微型、小型、中型和大型四种PartialNet变体，分别标记为PartialNet-T0/1/2、PartialNet-S、PartialNet-M和PartialNet-L。这些变体具有相似的架构，但深度和宽度存在差异。具体规格请参阅附录中的表3。

4. 实验

4.1. 基于ImageNet-1k分类的PartialNet

设置。 ImageNet-1K是计算机视觉领域应用最广泛的数据集之一，包含1000个常见

网络	类型	参数 (M)↓	浮点运算次数(G)↓	TP V100 (FPS)↑	TP MI250 (FPS)↑	CPU延迟 (毫秒) ↓	前1% (%) ↑
ShuffleNetV2 x1.5[20]	中心体	3.5	0.30	5315	6642	13.7	72.6
MobileNetV2[27]	中心体	3.5	0.31	3924	7359	13.7	72.0
FasterNet-T0[3]	中心体	3.9	0.34	8546	10612	10.5	71.9
MobileViTv2-0.5[22]	杂种	1.4	0.46	3094	3135	15.8	70.2
部分净T0 (本组)	杂种	4.3	0.25	7777	11744	12.2	73.9
EfficientNet-B0[30]	中心体	5.3	0.39	2934	3344	22.7	77.1
ShuffleNetV2 x2[20]	中心体	7.4	0.59	4290	5371	22.6	74.9
MobileNetV2 x1.4[27]	中心体	6.1	0.60	2615	4142	21.7	74.7
FasterNet-T1[3]	中心体	7.6	0.85	4648	7198	22.2	76.2
部分净T1 (本组)	杂种	7.8	0.55	4403	7379	21.5	78.1
EfficientNet-B1[30]	中心体	7.8	0.70	1730	1583	35.5	79.1
ResNet50[9]	中心体	25.6	4.11	1258	3135	94.8	78.8
FasterNet-T2[3]	中心体	15.0	1.91	2455	4189	43.7	78.9
PoolFormer-S12[38]	杂种	11.9	1.82	1927	3558	56.1	77.2
MobileViTv2-1.0[22]	杂种	4.9	1.85	1391	1543	41.5	78.1
EfficientViT-B1[2]	杂种	9.1	0.52	3072	3387	25.7	79.4
部分T2加权像 (本组)	杂种	12.6	1.03	3074	4761	35.2	80.2
EfficientNet-B3[30]	中心体	12.0	1.80	768	926	73.5	81.6
FasterNet-S[3]	中心体	31.1	4.56	1261	2243	96.0	81.3
PoolFormer-S36[38]	杂种	30.9	5.00	675	1092	152.4	81.4
MobileViTv2-2.0[22]	杂种	18.5	7.50	551	684	103.7	81.2
Swin-T[18]	杂种	28.3	4.51	808	1192	107.1	81.3
部分净额 (我方)	杂种	29.0	2.71	1559	2422	72.5	82.1
EfficientNet-B4[30]	中心体	19.0	4.20	356	442	156.9	82.9
FasterNet-M[3]	中心体	53.5	8.74	621	1098	181.6	83.0
PoolFormer-M36[38]	杂种	56.2	8.80	444	721	244.3	82.1
Swin-S[18]	杂种	49.6	8.77	477	732	199.1	83.0
部分净M (本研究)	杂种	61.3	6.69	799	1280	155.3	83.1
EfficientNet-B5[30]	中心体	30.0	9.90	246	313	333.3	83.6
ConvNeXt-B[19]	中心体	88.6	15.38	322	430	317.1	83.8
FasterNet-L[3]	中心体	93.5	15.52	384	709	312.5	83.5
PoolFormer-M48[38]	杂种	73.5	11.59	335	556	322.3	82.5
Swin-B[18]	杂种	87.8	15.47	315	520	333.8	83.5
部分净L (本研究)	杂种	104.3	11.91	426	765	272.5	83.9

表1. ImageNet-1K基准测试对比：具有相似前1%准确率的模型被归为一组。TP表示吞吐量。

数据集包含约130万张训练图像和5万张验证图像。我们使用ImageNet-1k数据集进行模型训练，采用AdamW优化器训练300个周期，并设置20个周期的线性预热。在正则化、数据增强技术及多尺度训练方面，我们沿用了FasterNet的相同方案。具体实验参数详见附录表2。为评估推理速度，我们在Nvidia-V100和AMDInstinct-MI250 GPU上测试了模型的吞吐量（批量大小为256），并在AMD EPYC™ 73F3单核处理器上测试了延迟性能。

结果。表1对比了我们的PartialNet模型（T0、T1、T2、S、M和L）与先前基于SOTA卷积神经网络（CNN）及混合模型成果。实验结果表明，PartialNet在所有模型变体中均持续超越FasterNet[3]等近期模型。例如，PartialNet-T2的准确率比FasterNet-T2高出1.3%，同时在V100（或MI250）吞吐量上提升约25.2%（或13.7%），CPU延迟降低24.1%。这些结果证明该模型的...

通过结合局部视觉注意力与局部卷积技术，模型性能得到显著提升，同时吞吐量也有所增加。V100与MI250在硬件架构上存在差异：V100更适合计算密集型任务，而MI250则在带宽密集型任务中表现更优[7]。这或许可以解释为何在V100的T0和T1版本测试中，我们的PartialNet模型吞吐量略低于FasterNet。更多对比数据请参阅附录中的表4。

此外，从图5可以看出，随着我们的PartialNet变体从T0到L逐渐增加，Top-1准确率和FLOPs均有所提升，但Top-1准确率相对于FLOPs的提升更为显著。这进一步证明，我们的PartialNet在较低计算成本下实现了更高的准确率。

4.2. 部分网络在下游任务中的应用

设置。我们在Mask-RCNN[10]检测器中采用预训练的PartialNet作为骨干网络进行目标检测

脊梁骨	参数 (M) ↓	浮点运算次数 (G) ↓	吞吐量 (FPS) ↑	AP^b ↑	AP_{50}^b ↑	AP_{75}^b ↑	AP^m ↑	$APm50$ 升高	$APm75$ 升高
ResNet50[9]	44.2	253	121	38.0	58.6	41.4	34.4	55.1	36.7
PoolFormer-S24[38]	41.0	233	68	40.1	62.2	43.4	37.0	59.1	39.6
PVT-Small x1.5[33]	44.1	238	98	40.4	62.9	43.8	37.8	60.1	40.3
FasterNet-S[3]	49.0	258	121	39.9	61.2	43.6	36.9	58.1	39.7
部分净额 (我方)	46.9	216	122	42.7	64.9	46.5	39.3	61.8	42.2
ResNet101[21]	63.2	329	62	40.4	61.1	44.2	36.4	57.7	38.8
ResNeXt101-32×4d[36]	62.8	333	51	41.9	62.5	45.9	37.5	59.4	40.2
PoolFormer-S36[38]	50.5	266	44	41.0	63.1	44.8	37.7	60.1	40.0
PVT培养基[33]	63.9	295	52	42.0	64.4	45.6	39.0	61.6	42.1
FasterNet-M[3]	71.2	344	62	43.0	64.4	47.4	39.1	61.5	42.3
部分净M (本研究)	78.2	295	65	44.3	65.8	48.5	40.6	63.3	43.7
ResNeXt101-64×4d[36]	101.9	487	29	42.8	63.8	47.3	38.4	60.6	41.3
PVT-大×4d[33]	81.0	358	26	42.9	65.0	46.6	39.5	61.9	42.5
FasterNet-L[3]	110.9	484	35	44.0	65.6	48.2	39.9	62.3	43.0
部分净L (本研究)	122.0	397	39	44.7	66.3	49.0	41.0	63.7	44.2

表2. 使用PartialNet-S/M/L在COCO数据集目标检测与实例分割基准上的结果。




图5. 不同PartialNet模型变体中浮点运算次数 (FLOPs) 与Top-1准确率的关系。

并在包含11.8万张训练图像和5000张验证图像的MS-COCO 2017数据集上进行实例分割。为突出主干网络本身的效能，我们采用FasterNet方法并使用AdamW优化器，进行12个周期的训练，采用16的批量大小、 1333×800 的图像尺寸，并保持其他训练设置不变，无需进一步调整超参数。

结果。表2展示了PartialNet与代表性模型的对比，报告了在检测和实例分割方面的平均精度 (mAP) 表现。结果显示PartialNet持续优于主流 SOTA 模型，在保持相似推理速度的同时实现了更高的平均精度 (AP)。例如，PartialNet-S在检测指标中 AP^b 较FasterNet-S高出7%以上，在分割指标中 AP^m 较FasterNet-S高出6.5%，且参数和FLOPs更少，同时保持相似吞吐量。这些结果进一步证实了我们提出的PartialNet在各种任务中的泛化能力。

4.3. 消融研究

部分注意力与全注意力对比。为验证PATConv优于全注意力机制的优势，我们在PartialNet-T2数据集上进行了对比实验 (如表3所示)。具体而言，我们用常规全注意力机制替换PATConv进行对比。全注意力机制需要对输入特征图的所有通道进行视觉注意力计算，这是传统视觉注意力机制的通用方式。实验结果表明，相较于全注意力机制，我们的PATConv在推理速度与性能之间实现了更优的平衡。此外，我们采用GradCAM[28]对注意力机制进行可视化分析。图6的结果显示，部分视觉注意力机制能够聚焦目标对象。这种对部分通道进行注意力操作的可行性验证，证实了我们改进的部分通道注意力机制的有效性。

ch-sp-sf	参数 (M)	浮点运算次数 (G)	吞吐量 (FPS) ↑	潜伏期 (ms) ↓	第1名 (%) ↑
P-P-P	12.6	1.03	4761	35.2	80.2
F-P-P	13.0	1.04	4662	36.5	80.1
P-F-P	12.6	1.04	4688	35.6	79.9
P-P-F	14.5	1.12	4600	38.6	80.2

表3. ImageNet-1K数据集上部分注意力(P)与全注意力(F)在PartialNet-T2上的对比。其中“ch”、“sp”和“sf”分别表示通道注意力、空间注意力和自注意力。

三个PATConv模块的效果。为验证我们提出的三个PATConv模块的独立效果，我们按照表4所示逐步添加每个模块进行消融研究。结果表明，这三个PATConv模块持续提升模型性能。此外，表5也显示




图6. 可视化结果显示使用Grad-CAM对ImageNet-1K验证集的不同类别进行分析的结果。

本文提供了PATConv应用于其他模型的复现对比结果。这些结果进一步验证了我们提出的PATConv模块的有效性。ConvNext-tiny的训练过程如附录图2所示。

奇	斯普	斯菲	参数 (M)	浮点运算次数 (G)	吞吐量 (FPS)↑	潜伏期 (ms)↓	第1名 (%)↑
w/o	w/o	w/o	11.1	0.92	6405	25.7	76.0
w.	w/o	w/o	11.1	0.92	5440	30.9	77.4
w.	w.	w/o	11.5	0.92	5157	31.7	78.9
w.	w.	w.	12.6	1.03	4761	35.2	80.2

表4. PartialNet-T2在ImageNet-1K数据集上采用不同PAT模块配置的消融实验

模型	吞吐量 (FPS) ↑		前1% ↑	
	最初的	PAT卷积	最初的	PAT卷积
ResNet50	1258	2832	76.13	77.64
MobileNetV2	3924	4560	71.14	73.85
凸阵微波手术	902	1123	76.00	78.57

表5. PATConv应用于其他模型的结果。

PATConv与常规卷积及深度卷积的对比。为深入验证我们提出的部分注意力卷积（PAT conv）相较于常规卷积（Conv）和深度卷积（DWConv）的优势，我们在PartialNet-T2模型上进行了消融实验（如表6所示）。为确保公平比较，我们通过扩展DWConv来使三种卷积类型的吞吐量保持在同一量级。实验结果表明，我们的PAT conv在参数量、浮点运算量、吞吐量、延迟及Top-1准确率等所有指标上均优于Conv和DWConv，这充分验证了PATConv的高效性与有效性。

卷积 3×3	参数 (M)	浮点运算次数 (G)	吞吐量 (FPS)↑	潜伏期 (ms)↓	前1% (%) ↑
PAT通道	12.6	1.03	4761	35.2	80.2
凸	15.8	2.12	4190	49.9	79.9
双卷积	15.8	1.28	4017	35.4	79.6

表6. ImageNet-1K数据集上采用不同卷积类型对PartialNet-T2进行消融实验

不同约束设置。在固定不同约束 θ 及其他参数的情况下，我们在PartialNet-T0上进行了不同实验，如图7所示。我们发现不同层间学习到的分割比例 r_p 呈现一致规律：随着 θ 增加，首层与末层相较于中间层表现出的稀疏性更低，这与模型量化结论[6]一致，即模型首层与末层更为重要。关于不同层间分割比例 r_p 的详细说明，请参阅附录表3。




图7. PartialNet-T0不同复杂度约束条件 θ 下各层学习到的分割比例 r_p 。

5. 结论

特征选择理论表明，特征之间可能存在一定程度的冗余与关联。虽然这种冗余不会带来额外的信息增益，但会增加计算复杂度并加剧过拟合风险。我们的研究从实现角度出发，基于该理论在性能与计算效率之间取得平衡。具体而言，我们提出部分通道机制并创新性地引入部分注意力卷积，通过将视觉注意力策略性地融入卷积过程来提升特征效用。此外，我们开发了动态部分卷积技术，这种自适应方法能学习模型各层通道的最佳分割比例。基于这些创新，我们构建了PartialNet架构，在ImageNet-1K分类任务以及COCO检测与分割任务中均超越了近期高效网络。这充分证明了部分通道机制在实现性能与效率最优平衡方面的有效性。