

# 基于结构化感知的解码：整合方向性、频域-空间及结构注意力进行医学图像分割

张凡<sup>1</sup>、顾志伟<sup>1</sup>、王华<sup>2\*</sup>

<sup>1</sup>山东理工大学计算机科学与技术学院，烟台 264005，中国

<sup>2</sup>中国山东省烟台市鲁东大学计算机与人工智能学院，邮编：264025

zhangfan@sdtbu.edu.cn, guzhiwei409@gmail.com, hwa229@163.com

## 摘要

为解决Transformer解码器在捕捉边缘细节、识别局部纹理及建模空间连续性方面的局限性，本文提出了一种专为医学图像分割设计的新型解码器框架，包含三个核心模块。首先，自适应交叉融合注意力（ACFA）模块将通道特征增强与空间注意力机制相结合，并引入平面、水平和垂直三个方向的可学习引导，以增强对关键区域和结构方向的响应能力。其次，三重特征融合注意力（TFFA）模块融合空间域、傅里叶域和小波域的特征，实现联合频域-空间表征，既强化全局依赖关系和结构建模，又保留边缘、纹理等局部信息，尤其适用于复杂模糊边界场景。最后，结构感知多尺度掩码模块（SMMM）通过利用多尺度上下文和结构显著性过滤优化编码器与解码器之间的跳跃连接，有效减少特征冗余并提升语义交互质量。这些模块协同工作时，不仅能弥补传统解码器的不足，还能显著提升肿瘤分割和器官边界提取等高精度任务的性能，同时提高分割精度和模型泛化能力。实验结果表明，该框架为医学图像分割提供了高效实用的解决方案。

## 介绍

医学图像分割在智能医疗和临床应用中发挥着关键作用，其核心目标是从复杂医学影像中精准识别器官、肿瘤或病变，为临床医生提供结构化且直观的参考信息。这不仅显著提升了诊断和病变评估的准确性，还为手术规划、放射治疗剂量设计及治疗监测提供了重要支持。随着医学影像数据的快速增长，自动化分割方法已成为降低临床决策成本不可或缺的工具。医师工作量，提高诊断效率，并\*通讯作者。版权归2026年人工智能促进协会所有（www.aaai.org）。保留所有权利。

确保结果的一致性。作为人工智能的驱动力，深度学习极大地推动了卷积神经网络（CNN）在图像分割中的应用。早期模型如LeNet（LeCun等人，2002年）和AlexNet（Krizhevsky、Sutskever和Hinton，2012年）展示了深度卷积架构在特征提取方面的优势。后续模型如VGG（Simonyan和Zisserman，2014年）和ResNet（He等人，2016年）通过残差机制和多路径设计提升了特征表示和训练稳定性。在此基础上，UNet（Ronneberger、Fischer和Brox，2015年）提出了一种编码器-解码器架构，通过下采样捕获全局语义信息，并通过融合多层级特征的跳跃连接恢复空间细节。然而，传统跳跃连接通常依赖简单的加法运算，可能导致空间细节丢失和冗余信息的引入，难以平衡全局与局部特征。近年来，视觉Transformer因其通过自注意力机制捕捉长距离依赖关系的能力，在医学图像分割领域展现出巨大潜力。诸如Swin-UNet（曹等人，2022）、PVT（王等人，2021）、MaxViT（屠等人，2022）、Merit（拉赫曼与马库莱斯库，2024）以及ConvFormer（林等人，2023）等代表性方法虽显著提升了整体分割性能，但在建模精细纹理和边缘细节方面仍存在不足。大型模型的发展也为我们的研究提供了新思路（马等人，2024）。此外，近期在组合图像检索领域的进展——包括编码器（李等人，2025a）、FineCIR（李等人，2025b）、Offset（陈等人，2025a）、HUD（陈等人，2025b）、PAIR（傅等人，2025）以及Median（黄等人，2025）——表明将结构化推理与不确定性建模及分层特征聚合相结合，可显著提升表征鲁棒性和语义可解释性，这为医学图像分割领域的发展注入了新动力。因此，受上述进展的启发，我们提出一种新型解码器框架，旨在通过保留全局感知的同时增强边缘和结构细节的表征来应对这些挑战。该解码器由三个关键模块组成：

- ACFA：一种增强结构定向性和空间一致性的方向感知模块。

- TFFA：一种融合空间、傅里叶和小波表示的三分支融合模块，用于平衡全局与局部特征。
- SMMM：一种多尺度跳跃融合模块，可抑制冗余、细化边界并优化特征对齐，从而实现精准细致的分割。

#### 相关作品

### 视觉编码器

卷积神经网络（CNN）因其在局部卷积、权重共享和成熟架构中高效提取多层次空间与语义特征的能力，被广泛应用于医学图像分割的编码器。VGGNet（Simonyan和Zisserman, 2014）通过堆叠深度递增的小核结构提升性能，而GoogLeNet（Szegedy等人, 2015）则采用Inception模块和全局平均池化技术，在参数更少的情况下实现高效特征提取。ResNet（He等人, 2016）通过引入残差连接克服深度网络的性能衰减，使模型在保持高效的同时实现更深的结构。然而，CNN的固定感受野限制了其捕捉长距离依赖关系和全局上下文的能力，这对复杂形状或模糊边界识别至关重要。视觉Transformer（ViTs）通过自注意力机制解决这一问题，其变体如Swin Transformer（Liu等人, 2021）和PVT（Wang等人, 2021）进一步增强了全局建模能力。PVTv2（Wang等人, 2022）则将局部特征卷积、重叠补丁嵌入以及线性注意力与均值池化相结合，实现了更优的全局建模。尽管全球表征有所改进，这些方法在有效建模短程依赖性方面仍存在困难。

### 医学图像分割

医学图像分割作为医学图像分析的核心任务，得益于深度学习强大的特征提取能力和端到端建模能力而显著受益。基于经典卷积神经网络（CNN）的框架如U-Net（Ronneberger、Fischer和Brox, 2015）、V-Net（Milletari、Navab和Ahmadi, 2016）、SegNet（Badrinarayan、Kendall和Cipolla, 2017）以及FCN（Long、Shelhamer和Darrell, 2015）为器官和病灶的自动化勾画奠定了基础。U-Net采用带有跳跃连接的编码器-解码器架构实现了多尺度融合，V-Net将这一理念扩展至三维数据，而SegNet和FCN则分别提升了空间保真度和端到端预测能力。近期进展进一步增强了表征能力：AD-LA Former（Wang、Wang和Zhang, 2025）结合动态卷积和位置注意力处理复杂结构，而EMCAD（Rahman、Munir和Marculescu, 2024）引入多尺度注意力解码器，通过通道、空间和分组门控注意力强化显著区域建模。基于Transformer的模型如TransUNet（Chen等人, 2021）、Swin-UNet（Cao等人, 2022）和CSWin-UNet（Liu等人, 2025年研究通过自注意力机制扩展了长距离上下文建模，而MISSFormer（Huang等人, 2022b）和LeViTUNet（Xu等人, 2023）则通过多尺度和轻量级设计提升了效率。混合架构结合了

诸如HiFormer（海达里等人, 2023）和TBCovL-Net（伊克巴尔等人, 2025）等结合卷积神经网络与Transformer的模型，巧妙融合了两种范式的优点，实现了局部特征、全局关联与计算成本的平衡。在传统分割模型之外，高效学习（姚、李、肖, 2024）、联邦协调（肖等人, 2024）、跨模态对比学习（王等人, 2025）以及基于扩散的自监督（肖等人, 2025）等领域的突破，为鲁棒特征表示开辟了新方向。此外，标准化三维场景建模（姚等人, 2023）和多模态推理（张等人, 2025）的进展，为医学图像分割提供了更高效的信息融合与推理方法，有望带来更显著的改进。

#### 方法

我们的目标是开发一种新型医学图像分割解码器，该解码器能够在更强调关键区域特征的同时，有效保持局部和全局信息的完整性。以下章节将详细描述如图1所示的解码器结构设计，该解码器由三个核心模块组成：

### 自适应交叉融合注意力

为增强模型对关键区域的响应能力及其建模结构方向的能力，我们设计了一个具有方向感知的ACFA模块。该模块整合了通道增强与空间建模机制，同时沿三个方向（平面、垂直和水平）引入可学习的引导，从而实现不同尺度和方向上的精细特征增强。具体而言，对于输入特征图 $X \in \mathbb{R}^{B \times C \times H \times W}$ ，首先应用通道与空间门控来提取特征：

$$\hat{X}_{l-1}^{CG} = X \odot \delta(CG_{avg}(X) + CG_{max}(X)) \quad (1)$$

$$\hat{X}_{l-1}^{SG} = X \odot \delta(f_{7 \times 7}^{Conv}(SG(X))) \quad (2)$$

此处， $CG_{avg}()$ 和 $CG_{max}()$ 分别代表平均通道门控和最大通道门控。 $SG()$ 表示空间特征门控， $f_{7 \times 7}^{Conv}()$ 指代一个 $7 \times 7$ 核的卷积操作， $\delta()$ 是Sigmoid激活函数， $\odot$ 表示矩阵乘法。随后，为获取更深层特征，将特征图沿通道维度划分为四个子集 $X_l^{S-G_1^1}$ 、 $X_l^{S-G_1^2}$ 、 $X_l^{S-G_1^3}$ 、 $X_l^{S-G_1^4}$ ，每个子集均与对应特定方向的可学习参数结合以实现细粒度调制。随后应用深度可分离卷积来提取关键响应每个方向。具体来说，三个分支引入了具有方向引导的可学习权重参数：

$$Tensor^{HW} = f_{[1]}^{U0, ni form}(Param[1, \frac{C}{4}, H, W]) \quad (3)$$

$$张量H = f_{[1]}^{U0, ni形式}(参数[1, \frac{C}{4}, H, 1]) \quad (4)$$




图1: 模型的建议网络架构。

$$\text{张量} W = f[U0, \text{参数}_{1'}^{\text{形式}}(\frac{C}{4}, 1, W)] \quad (5)$$

此处,  $f_{[U0, \text{参数}_{1'}^{\text{形式}}]}$  表示使用均匀函数进行初始化, 该函数将张量值设置为[0,1]范围内的随机数。随后这些张量通过深度可分离卷积进行处理, 以进一步建模不同方向上的结构分布模式。参数以端到端方式优化, 使模型在训练过程中能够自动学习最适合数据分布的方向注意力模式。具体而言:

$$\hat{X}_{l-1}^{HW} = f_{3 \times 3}^{DW} \text{转换} (\vartheta (f_{1 \times 1}^{Conv} (Tensor^{HW}))) \quad (6)$$

$$\hat{X}_{l-1}^H = f_3^{DWConv1d} (\vartheta (f_1^{Conv1d} (Tensor^H))) \quad (7)$$

$$\hat{X}_{l-1}^W = f_3^{DWConv1d} (\vartheta (f_1^{Conv1d} (Tensor^W))) \quad (8)$$

此处,  $f_{DWConv3}^{1d}()$  和  $f_{Conv1}^{1d}()$  分别表示核尺寸为3的一维深度可分离卷积和核尺寸为1的一维卷积, 而  $\vartheta()$  表示 GELU 激活函数。为补充其他方向可能遗漏的细节信息, 第四分支采用一组标准卷积操作来捕获更广义的上下文信息, 具体包括:

$$\hat{X}_{l-1}^4 = f_{1 \times 1}^{Conv} \text{无血管性毛细血管扩张症} (\vartheta (f_{3 \times 3}^{DWConv} (\hat{X}_{l-1}^{SG4}))) \quad (9)$$

最终, 将三个方向分支与第四个分支的特征进行拼接, 随后通过LayerNorm和卷积融合获得最终的方向感知增强输出。

### 三重特征融合注意力

传统空间卷积结构依赖于具有固定感受野的局部卷积核, 虽然能够捕捉局部纹理信息, 但在建模长程依赖关系、全局结构关联及跨尺度语义交互方面存在局限。特别是在特征融合阶段, 简单的空间堆叠或平均操作虽能保留空间分布信息, 却容易导致语义平滑和冗余, 可能掩盖关键边缘或细微区域, 削弱模型对细节和边界的敏感度。为解决这些局限, 我们提出 TFFA 模块, 该模块包含三个分支: 小波分支、傅里叶分支和空间特征分支。在小波分支中, 模块采用DoG和墨西哥帽小波函数进行局部时空分析。这两种小波函数作为经典滤波或边缘检测算子, 具有强大的空间定位和频率分析能力。相较于Haar或Daubechies等传统小波, 它们能提供更优的边缘和纹理表征。对于输入张量  $X \in \mathbb{R}^{B \times C \times H \times W}$ ,

| 方法          | 平均           |              | 斯普           | RKID         | LK键          | 半球           | 磅            | 经常订单         | Aor          | 平底锅          |
|-------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
|             | DSC 升高       | HD95 ↓       |              |              |              |              |              |              |              |              |
| 跨网          | 77.49        | 31.69        | 85.08        | 77.02        | 81.87        | 63.16        | 94.08        | 75.62        | 87.23        | 55.86        |
| 猪-网         | 79.13        | 21.55        | 90.66        | 79.61        | 83.28        | 66.53        | 94.29        | 76.60        | 85.47        | 56.58        |
| LeViT-UNet  | 78.53        | 78.53        | 88.86        | 80.25        | 84.61        | 62.23        | 93.11        | 72.76        | 87.33        | 59.07        |
| MISS前体      | 81.96        | 18.20        | 91.92        | 82.00        | 85.21        | 68.65        | 94.41        | 80.81        | 86.99        | 65.67        |
| 缩尺          | 82.86        | 16.81        | 89.40        | 83.31        | 86.36        | 74.97        | 95.12        | 80.14        | 88.73        | 64.85        |
| HiFormer-B  | 80.39        | <b>14.70</b> | 90.99        | 79.77        | 85.23        | 65.23        | 94.61        | 81.08        | 86.21        | 59.52        |
| DAE前        | 82.63        | 16.39        | 91.82        | 82.39        | 87.66        | 71.65        | 95.08        | 80.77        | 87.84        | 63.93        |
| PVT-CASCADE | 81.06        | 20.23        | 90.10        | 80.37        | 82.23        | 70.59        | 94.08        | 83.69        | 83.01        | 64.43        |
| 两栖货船        | 82.77        | 17.42        | 91.45        | 81.93        | 84.93        | 71.05        | 94.87        | 83.71        | 87.48        | 66.76        |
| EMCAD       | 83.63        | 15.68        | 92.17        | 84.10        | 88.08        | 68.87        | <b>95.26</b> | <b>83.92</b> | 88.14        | 68.51        |
| AD-LA 前     | 83.48        | 21.31        | 88.72        | 70.82        | 86.50        | <b>83.30</b> | 95.17        | 67.28        | <b>91.34</b> | <b>84.69</b> |
| CSWin-UNet  | 81.12        | 18.86        | 89.05        | 78.53        | 83.51        | 67.85        | 95.23        | 81.74        | 87.13        | 65.94        |
| 我们的         | <b>83.92</b> | 18.91        | <b>92.46</b> | <b>86.47</b> | <b>89.26</b> | 67.51        | 94.72        | 83.33        | 87.63        | 69.95        |

表1: 该模型与既往方法在Synapse数据集上的比较结果。加粗部分表示最佳结果，dsc值分别对应腹部器官脾脏（Spl）、右肾（Rkid）、左肾（Lkid）、胆囊（Gal）、肝脏（Liv）、胃（Sto）、主动脉（Aor）及胰腺（Pan），下文同理。

| 方法         | 差示扫描量热法      | SE           | SP           | 应收账款         |
|------------|--------------|--------------|--------------|--------------|
| 跨网         | 81.23        | 82.63        | 95.77        | 92.07        |
| 猪-网状内皮细胞   | 88.15        | 83.64        | <b>98.69</b> | 95.82        |
| 两栖货船       | <b>90.99</b> | 90.55        | 98.49        | 96.98        |
| Hiformer-B | <b>90.93</b> | 88.67        | 98.57        | 96.69        |
| EGE-联合核素   | 89.28        | 88.39        | 98.11        | 96.48        |
| 超轻量虚拟机     | 90.91        | 90.53        | 97.90        | 96.46        |
| EMCAD      | 90.06        | <b>93.70</b> | 96.81        | 96.55        |
| AD-LA 前    | 87.68        | 93.18        | 98.65        | 97.03        |
| 结核病卷积神经网络  | 90.89        | 91.19        | 97.61        | 96.07        |
| 我们的        | <b>91.40</b> | 92.75        | 97.78        | <b>97.26</b> |

表2: 基于 ISIC 2017数据集的对比实验。

小波变换的实现如下:

$$W(a, b) = \int_{-\infty}^{\infty} x(t) \psi_a, b(t) dt \quad (10)$$

其中  $\psi_{a, b}()$  表示母小波函数, 通过不同小波类型实例化。DoG (高斯差分) 定义为不同尺度的高斯模糊图像之间的差值:

$$\psi(x, y) = G_{\sigma_1}(x, y) - G_{\sigma_2}(x, y), \quad \sigma_1 < \sigma_2 \quad (11)$$

该方法通过在特定频段内突出图像细节, 作为近似LoG的带通滤波器。通过调整高斯核参数  $\sigma$ , 可增强特定纹理尺度。医学图像通常对比度低且纹理模糊; DoG能突出灰度变化显著的区域, 从而增强边缘和轮廓感知。其公式为:

$$\psi_{a, b}^{Dog}(x) = -\frac{1}{\sqrt{a}} \left( \frac{x-b}{a} \right) e^{-\left( \frac{x-b}{a} \right)^2} \quad (12)$$

此处,  $a$  为尺度参数,  $b$  为平移参数, 二者均可学习, 从而实现动态融合

| 方法         | 差示扫描量热法      | SE           | SP           | 应收账款         |
|------------|--------------|--------------|--------------|--------------|
| 跨网         | 84.99        | 85.78        | 96.53        | 94.52        |
| 猪-网状内皮细胞   | 86.03        | 79.98        | 98.53        | 94.45        |
| 两栖货船       | 88.88        | 84.75        | 98.34        | 95.34        |
| Hiformer-B | 88.10        | 84.61        | 97.74        | 94.85        |
| EGE-联合核素   | 89.04        | 90.44        | 95.91        | 94.58        |
| VM-UNetV2  | 89.73        | 88.64        | 97.13        | 95.06        |
| 超轻量虚拟机     | 89.40        | 86.80        | 97.81        | 95.58        |
| EMCAD      | 89.73        | 92.43        | 96.75        | 96.17        |
| DMSA-联合    | 90.63        | <b>97.14</b> | 97.14        | 96.16        |
| AD-LA 前    | 85.91        | 91.24        | <b>99.04</b> | 96.46        |
| 我们的        | <b>90.71</b> | 93.34        | 96.18        | <b>96.62</b> |

表3: 基于 ISIC 2018数据集的对比实验。

多小波特征。相比之下, 墨西哥帽 (Mexican Hat) 通过平滑后的二阶导数检测边缘零交叉点, 同时有效抑制噪声干扰:

$$\psi_{a, b}^{MH}(x) = \frac{2}{\sqrt{3a\pi^{\frac{1}{4}}}} \left( 1 - \left( \frac{x-b}{a} \right)^2 \right) e^{-\left( \frac{x-b}{a} \right)^2} \quad (13)$$

小波变换提供局部多尺度信息, 而傅里叶变换本质上是全局性的, 能够捕捉整体结构并建模长程依赖关系, 从而弥补卷积模型对大尺度结构感知能力的局限。该变换将图像从空间域转换到频率域, 用正弦和余弦波表示周期性结构。频率域特征通过可学习的权重矩阵进行调制, 其中高频分量对应边缘和纹理, 低频分量则代表轮廓和背景。其公式为:

$$F(u, v) = \iint f(x, y) e^{-j2\pi(ux+vy)} dx dy \quad (14)$$

在空间分支中, 逐点卷积被应用于提取空间特征。与简单的通道堆叠或

在平均化处理后，TFFA 在三个分支后引入注意力门控机制，为空间、频率和小波输出分配动态权重以实现自适应融合。该机制避免了传统融合策略导致的过度平滑现象，并增强了模型对复杂场景中显著区域的响应能力。最终融合结果经过批量归一化和激活函数处理，以提升特征稳定性和非线性建模能力，从而在涉及复杂边界和精细分割的任务中实现卓越性能。

结构感知多尺度掩模模块

在医学图像分割中，跳跃连接对于在编码器和解码器之间连接多尺度特征以及缓解上采样过程中的空间细节损失至关重要。然而，传统的跳跃连接通常仅使用简单的特征相加，缺乏选择性融合，导致冗余或无关信息。为克服这一局限，我们提出 SMMM —— 一种结构感知的多尺度融合策略，可增强特征表示与区分能力。具体而言，对于形状相同的编码器特征  $X \in \mathbb{R}^{B \times C \times H \times W}$  和解码器特征  $Y \in \mathbb{R}^{B \times C \times H \times W}$ ，首先通过并行逐点卷积处理以激活空间线索，随后通过多尺度感知模块。每个模块整合了深度可分离卷积（核尺寸为  $3 \times 3$ 、 $5 \times 5$ ），结合两阶段通道分裂和 ReLU 激活，有效扩大感受野并提升捕捉复杂结构边界的能力。具体公式如下：

$$\hat{X}_M = f_{1 \times 1}^{Conv}(X) \tag{15}$$

$$\hat{X}_{M-1}^{S_1} = \gamma \left( f_{3 \times 3}^{DWConv}(\hat{X}_M) \right) \tag{16}$$

$$\hat{X}_{M-1}^{S_2} = \gamma \left( f_{5 \times 5}^{DWConv}(\hat{X}_M) \right) \tag{17}$$

$$\hat{X}_M^{S_1} = \gamma \left( f_{3 \times 3}^{DWConv}(Cat(\hat{X}_{M-1}^{S_1}, \hat{X}_{M-1}^{S_2})) \right) \tag{18}$$

$$\hat{X}_M^{S_2} = \gamma \left( f_{5 \times 5}^{DWConv}(Cat(\hat{X}_{M-1}^{S_1}, \hat{X}_{M-1}^{S_2})) \right) \tag{19}$$

$$X^- = f_{1 \times 1}^{Conv}(\hat{X}_M^{S_1}, \hat{X}_M^{S_2}) \tag{20}$$

其中  $\gamma()$  表示 ReLU 激活函数。经过多尺度特征融合模块后，编码器和解码器的特征被输入掩模模块进行空间显著性建模。该模块通过应用三种不同通道门控滤波器来识别空间域中最具区分度的区域，并采用 Softmax 激活函数实现加权策略，重点突出高响应区域。这种显著性设计能有效应对医学图像中病灶模糊、轮廓不清等挑战。随后，经过滤波的特征被叠加，并通过 2 倍膨胀率的扩张卷积进行进一步融合。该操作不仅扩展了感受野范围，提升了病灶形态和结构边界的捕捉精度，还引入了更丰富的上下文信息，且未压缩特征图分辨率。最终，融合后的特征

| 方法          | 左心室掩模 | 残气量   | 肌     | 左心室   |
|-------------|-------|-------|-------|-------|
| 猪-网         | 88.07 | 85.77 | 84.42 | 94.03 |
| 跨网联         | 89.71 | 86.67 | 87.27 | 95.18 |
| 级联功绩        | 91.85 | 90.23 | 89.53 | 95.80 |
| PVT-GCASCAD | 91.95 | 90.31 | 89.63 | 95.91 |
| DMSA-UNet   | 92.28 | 90.32 | 90.49 | 96.02 |
| EMCAD       | 92.12 | 90.65 | 89.68 | 96.02 |
| AD-LA 前     | 90.09 | 88.68 | 88.94 | 95.30 |
| CSWin-UNet  | 91.46 | 89.68 | 88.94 | 95.76 |
| 我们的         | 92.75 | 91.18 | 90.40 | 96.67 |

表4： ACDC 数据集的对比实验。

通过归一化层和逐点卷积进行处理，以实现通道对齐和特征分布的稳定化，防止梯度消失并提高训练稳定性。

实验

实验设置

我们使用 PyTorch 1.11.0 实现模型，并在配备 40GB 显存的单 NVIDIA A100 GPU 上完成所有实验。实验设置参照 EMCAD，采用 ImageNet 预训练的 PVTv2-b2 作为编码器，学习率和权重衰减设为  $1e-4$ ，训练时使用 AdamW 优化器，采用归一化掩码 [0,1] 且不进行数据增强。批量大小固定为 12。在 ISIC 2017 和 ISIC 2018 数据集上训练 200 个周期，在 Synapse 和 ACDC 数据集上分别训练 300 和 400 个周期。

数据集

皮肤病变分割我们使用了国际皮肤成像协作组织发布的 ISIC 2017 和 ISIC 2018 数据集。ISIC 2017 包含约 2000 张高分辨率皮肤镜图像，配有精确的病变标注，主要用于边界分割评估。ISIC 2018 扩展至 2594 张图像，涵盖更多病变类型，为多类分割和泛化评估提供了基准。

突触多器官分割突触数据集源自 2015 年 MICCAI 多图谱标注颅盖骨后挑战赛，包含 30 幅腹部 CT 扫描图像，附有肝脏、胰腺、肾脏和脾脏等八个器官的像素级标注。其标准化影像和高质量掩膜使其成为多器官分割、跨结构识别及泛化研究的广泛使用的基准。

ACDC 数据集该 ACDC 数据集是 2017 年 MICCAI 心脏分割挑战赛的一部分，包含 100 名受试者的心脏 MRI 电影序列，涵盖健康与病理病例（如扩张型和肥厚型心肌病）。数据集提供左心室、右心室及心肌的精确标注，作为心脏结构分割与功能分析的基准。






图2：本模型性能与其他模型在Synapse数据集上可视化结果的比较。




图3：ISIC 2017数据集分割结果与其他先前方法的对比。




图4：2018年 ISIC 上所提模型的注意力热图可视化。

## 定量与定性结果

在Synapse数据集（表1）上，我们的模型平均DSC值达到83.92%，超越了 EMCAD（83.63%）和AD-LA Former（83.48%）等前沿方法，展现出在多器官分割领域的显著优势。在脾脏（92.46%）、右肾（86.47%）和左肾（89.26%）等关键器官上表现最佳，凸显了其捕捉复杂器官边界和精细结构的能力。尽管AD-LA Former在胆囊分割上获得最高分（83.30%），但其整体平均值仍低于我们的模型。我们还将其与近期其他方法进行对比，包括ScaleFormer（黄等人2022a）、DAEFormer（阿扎德等人2023）、PVT-cascade（拉赫曼和马库莱斯库2023a）、LKA（郭等人2023）、EGE-Unet（阮等人2023）、UltraLightVM-UNet（吴等人2024）、Cascaded merit（拉赫曼和马库莱斯库2023b）、VMUNetV2（张等人2024）以及 DMSA -UNet（李等人2024）。

2024年）在Synapse、ISIC 2017、ISIC 2018和 ACDC 数据集上的表现。在 ISIC 2017数据集（表2）中，我们的模型实现了最高的DSC（91.40%）和ACC（97.26%），优于 EMCAD（90.06%）和 LKA（90.99%），同时保持了平衡的敏感性和特异性。在 ACDC 数据集（表4）中，其平均 DSC 达到 92.75%，RV、Myo 和 LV 评分分别为 91.18%、90.40% 和 96.67%，超越 DMSAUNet（92.28%）和 Cascaded merit（91.85%）。在 ISIC 2018 数据集（表3）中，其达到最佳DSC（90.71%）和ACC（96.62%），以及具有竞争力的SE（93.34%），仅次于 DMSA -UNet（97.14%）。这些全面的结果，进一步通过详细的可视化比较（图2和图3）得到支持，证实了我们的模型在多器官、心脏和皮肤病变分割任务中的鲁棒性、结构感知能力和强大的跨任务泛化能力，凸显了其在处理多样化和具有挑战性的医学影像场景中的有效性。

| 方法                      | 平均     |        | Aor   | 半球    | LK键   | RKID  | 磅     | 平底锅   | 斯普    | 经常订单  |
|-------------------------|--------|--------|-------|-------|-------|-------|-------|-------|-------|-------|
|                         | DSC 升高 | HD95 ↓ |       |       |       |       |       |       |       |       |
| 基线                      | 81.35  | 20.42  | 86.78 | 64.11 | 87.48 | 83.96 | 93.82 | 62.00 | 89.88 | 82.77 |
| 基线+ ACFA                | 82.04  | 21.46  | 86.54 | 65.73 | 87.69 | 84.27 | 93.38 | 65.17 | 90.12 | 83.42 |
| 基线值+ ACFA + TFFA        | 83.23  | 16.72  | 86.05 | 64.43 | 87.89 | 86.86 | 94.58 | 70.99 | 91.07 | 83.97 |
| 基线值+ ACFA + TFFA + SMMM | 83.92  | 18.91  | 87.63 | 67.51 | 89.26 | 86.47 | 94.72 | 69.95 | 92.46 | 83.33 |

表5：不同模块对Synapse数据集模型影响的消融研究

| 方法                      | 显示扫描量热法 | SE    | SP    | 应收账款  |
|-------------------------|---------|-------|-------|-------|
| 基线                      | 85.95   | 83.68 | 98.96 | 96.05 |
| 基线+ ACFA                | 87.82   | 85.12 | 98.16 | 95.92 |
| 基线值+ ACFA + TFFA        | 89.15   | 89.83 | 97.29 | 96.85 |
| 基线值+ ACFA + TFFA + SMMM | 91.40   | 92.75 | 97.78 | 97.26 |

表6：不同模块对 ISIC 2017数据集影响的消融研究

|   | TFFA | TFFA | 参数(M) | 复杂性 (GMac) |
|---|------|------|-------|------------|
| 不 | 不    | 不    | 25.07 | 11.85      |
| 是 | 不    | 不    | 30.67 | 13.35      |
| 是 | 是    | 不    | 32.01 | 13.75      |
| 是 | 是    | 是    | 42.52 | 18.29      |

表8：突触数据集模块的计算成本与复杂度

| 热欧姆 | 小波    |        |         | SE    | SP    | 应收账款  |
|-----|-------|--------|---------|-------|-------|-------|
|     | 梅西肯哈特 | 多巴胺神经元 | 显示扫描量热法 |       |       |       |
| 不   | 不     | 不      | 90.32   | 89.31 | 97.73 | 95.37 |
| 是   | 不     | 不      | 90.48   | 91.43 | 97.27 | 95.74 |
| 是   | 是     | 不      | 90.57   | 92.63 | 96.41 | 96.15 |
| 是   | 是     | 是      | 90.71   | 93.34 | 96.18 | 96.62 |

表7：TFFA 模块内不同组件影响的消融研究。

消融研究

为验证所提解码器的有效性，我们在Synapse和 ISIC 2017数据集上进行了消融实验，如表5、6、7和8所示。

不同组分对突触的影响

在Synapse数据集上的实验结果表明，各组件均能提升性能。引入 ACFA 仅使参数量增加560万，计算量增加1.5GMac，同时将DSC提升至82.04%。这证明方向感知与通道-空间融合能增强结构感知能力。进一步整合TFFA 使DSC提升至83.2%，并将HD95降至16.72，表明联合空间-频率建模能补充全局语义与局部边界学习。当所有模块整合时，解码器在参数量4252万、计算量1829GMac的情况下，DSC达到83.92%，在保持效率的同时实现了对肝脏、肾脏等复杂器官的最佳分割。

不同组分对 ISIC 的影响2017

我们还在 ISIC 2017数据集上进行了消融实验。基线模型达到85.95%的DSC值。加入 ACFA 后，DSC提升至87.82%，凸显了方向性和区域区分能力的增强。当引入 TFFA 时，DSC达到89.15%，SE提升至89.83%，验证了空间-频率融合能优化边缘和纹理表征。整合SMMM 后，模型性能达到最佳。

(DSC 91.4%，SE 92.75%，ACC 97.26%)，表明联合多模块学习可增强病灶勾画及边界准确性。

ISIC 2018数据集注意力热图分析

ISIC 2018数据集上的注意力热图（图4）表明，所提出的解码器能有效捕捉病灶边界、纹理及内部结构。ACFA 增强了方向性边缘感知能力，TFFA 通过傅里叶-小波融合技术平衡全局与局部特征，SMMM 在特征聚合过程中减少空间细节损失。这些技术的协同作用实现了对病灶区域的精准聚焦、边界预测的平滑化以及泛化能力的提升。

TFFA 模块的内部烧蚀研究

我们对 TFFA 模块进行了内部分析，并验证了各频率分量的贡献。傅里叶建模增强了全局结构表征，而添加墨西哥帽小波则提升了局部边缘敏感度。结合DoG和墨西哥帽小波实现了最佳效果（DSC 90.71%，SE 93.34%），证实多尺度空间-频率融合能有效优化边界感知。

结论

我们提出一种新型医学图像分割解码器，针对边缘细节建模、长程依赖捕捉及多尺度特征融合等挑战。该框架整合了方向与结构感知 ACFA、联合小波-傅里叶-空间特征建模 TFFA，以及采用显著性掩码的多尺度跳跃融合 SMMM。总体而言，该解码器通过联合方向-频率-结构建模显著提升了分割精度，为高精度医学图像分割提供了高效实用的解决方案。