

GROUPKAN:基于分组样条的KAN模型对非线性进行重新思考以实现高效的医学图像分割

李国杰

西安交通大学利物浦大学机器人学院
中国江苏省苏州市215000, 英国利物浦大学计算机科学系, 利物浦L69 3BX

安瓦尔·P·P·阿卜杜勒·马吉德

西安交通大学利物浦大学机器人学院, 中国江苏省苏州市215000; 森伟大学工程技术学院, 马来西亚雪兰莪州
达鲁埃山47500

穆罕默德·阿提克

西安交通大学苏州分校物联网学院, 中国江苏省苏州市215000

阮先生

利物浦大学计算机科学系
利物浦L69 3BX, 英国

范张*

西安交通大学利物浦大学机器人学院
中国江苏省苏州市 215000

摘要

医学图像分割需要具备精准度高、体积轻量且可解释性强的模型。传统卷积架构缺乏自适应非线性特征和透明决策机制, 而Transformer架构则因二次复杂度和不透明的注意力机制受限。U-KAN通过采用柯尔莫哥洛夫-阿诺德网络 (Kolmogorov-Arnold Networks) 解决了这些难题, 其准确率超越卷积和注意力机制方法, 参数量少于Transformer变体, 且可解释性优于传统方案。然而, 由于全通道变换导致的 $O(C^2)$ 复杂度限制了其扩展性——随着通道数量增加, 模型性能会逐渐受限。为解决这一问题, 我们提出GroupKAN——一种轻量级分割网络, 其整合了两个新颖的结构化功能模块: (1) 分组KAN变换, 将通道划分为G组进行多元样条映射, 将复杂度降低至 $O(C^2/G)$; (2) 分组KAN激活, 在每个通道组内应用共享的样条映射, 实现高效的标记级非线性。在三个医学基准集 (Busi、GlaS和CVC) 上评估时, GroupKAN平均IoU达到79.80%, 较U-KAN提升+1.11%, 同时仅需47.6%的参数量 (3.02M对比6.35M), 并展现出更强的可解释性。代码可在以下地址获取: <https://github.com/liguojie09/GroupKAN>

关键词 计算机视觉 · 医学图像分割 · 科尔莫戈罗夫-阿诺德网络 ·

*通讯作者: Fan.Zhang@xjtlu.edu.cn

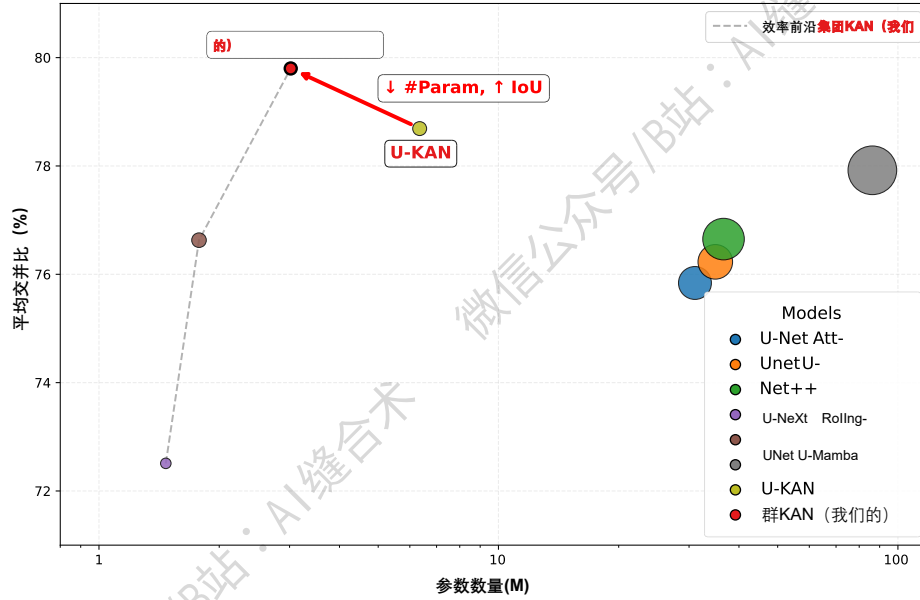


图1: 医学分割中的精度-复杂度权衡: 常见骨干模型的交并比 (IoU) (%) 与参数数量(M)关系。标记大小反映各模型的计算成本, 面积与GFLOPs成正比。虚线表示效率前沿。我们的GroupKAN (红色圆圈) 在参数量仅为U-KAN的47.6%时, 将IoU提升了1.11%。

1 引言

医学图像分割对临床诊断和治疗方案制定至关重要[1, 2], 但现有深度学习模型在现实临床场景中难以平衡准确率、模型紧凑性和可解释性[3, 4, 5]。尽管现有方法能获得精准的分割结果, 但其高昂的计算成本和不透明的决策流程, 阻碍了这些技术在资源有限的临床环境中的实际应用。

卷积神经网络 (如U-Net[6]) 凭借其强大的归纳偏置特性, 长期以来一直是医学图像分割系统的基石, 这种特性有助于在数据有限的情况下实现泛化。然而, 其表达能力有限且缺乏自适应非线性特征, 导致难以建模复杂结构, 这促使人们寻求更灵活且可解释的替代方案[7, 8]。相比之下, 基于Transformer的方法摒弃了局部归纳偏置, 转而采用全局自注意力机制, 虽然能够实现长距离上下文建模, 但存在二次复杂度和数据效率低下的缺陷[9, 10, 11]。近年来的Mamba模型[12]通过状态空间公式实现了线性时间复杂度的长距离依赖建模, 但其架构复杂度高且难以应用于密集预测任务, 限制了其在分割场景中的实际效果。

为增强可解释性, U-KAN[13]通过全通道样条变换在特征维度上整合了Kolmogorov-Arnold网络 (KANs) [14]。虽然该设计提升了分割精度和可解释性, 但其参数复杂度达到 $O(C^2)$, 导致模型规模随通道维度增加呈二次增长, 这给资源受限场景下的可扩展性和部署带来了挑战。

为解决这些局限性, 我们提出**GroupKAN**, 一种由两项关键创新构成的轻量级架构: (1) **分组KAN变换 (GKT)**, 将通道划分为 G 个独立组, 并在每组内应用组特异性样条算子来建模通道间交互。这种结构化设计将变换的参数复杂度从 $O(C^2)$ 降低至 $O(C^2/G)$, 在保持表征能力的同时显著减小模型规模; (2) **分组KAN激活 (GKA)**, 一种基于样条的新型逐点非线性函数, 使同一组内所有通道共享相同样条函数。该机制通过实现结构化逐标记激活来提升可解释性, 同时保持组间功能多样性。

GroupKAN通过将群体感知样条操作整合至轻量级架构中, 重新审视了功能建模方法, 从而在医学图像分割领域实现了可解释性、轻量级设计与准确性的同步提升 (参见图1)。具体而言, 我们的贡献包括:

- 我们提出**GroupKAN**，一种集成群感知样条建模的轻量级医学图像分割骨干网络。GroupKAN采用Kolmogorov–Arnold网络联合建模标记级激活与通道级变换，将这些过程统一在一个可解释且紧凑的框架中。
- 我们提出**分组KAN变换（GKT）**，这是一种计算效率高的算子，可在通道组内执行多元样条映射。这将参数复杂度从 $O(C^2)$ 降低至 $O(C^2/G)$ ，同时保持建模丰富通道间依赖关系的能力。
- 我们提出**分组KAN激活（GKA）**，这是一种基于样条的非线性函数，可在补丁嵌入后对通道组应用共享的单变量函数。该设计实现了参数高效的标记级激活。
- 我们在三个医学分割基准集（Busi、GlaS和CVC）上验证了GroupKAN的性能，结果显示：仅需302万参数，其平均IoU值较U-KAN提升1.11%，不仅在定量和定性指标上均取得显著进步，还生成了更具可解释性的预测结果。

2 相关工作

2.1 医学分割的体系结构

以U-Net[6]为代表的U型架构，凭借其对称的编码器-解码器结构和支持多尺度特征融合的跳跃连接，被广泛用作医学图像分割的骨干网络。此后，众多改进方案通过增强跳跃路径[15, 16]、引入注意力机制[17, 18, 19]以及更新卷积组件[20]，对这一设计进行了优化。

近年来，诸如Rolling U-Net[21]这类轻量级架构通过将卷积编码器与MLP启发式模块相结合，在保持计算效率的同时提升了长距离依赖建模能力。与此同时，U-Mamba[22]等模型则采用Mamba风格的序列建模技术，进一步优化了全局表征学习效果。然而，现有研究大多聚焦于架构优化，对非线性变换设计的探索仍相对不足。

2.2 柯尔莫哥洛夫-阿诺德网络与功能建模

KANs[14]通过可学习的样条组合来近似函数，以更少的参数实现强大的可解释性和表达能力。U-KAN[13]通过在U型网络中插入基于样条的KAN模块引入函数激活，从而在分割和生成任务中均取得显著成果。然而，其全局通道映射会带来高昂的参数和计算成本，尤其当通道维度增大时更为明显。这凸显了对更高效函数建模的迫切需求。

近期研究探索了卷积KANs[23, 24]，通过用基于样条的非线性滤波器替代线性卷积核来提升表征能力和精度。然而这些方法往往引入显著的参数和计算开销，且缺乏结构化的分组设计。因此，基于分组感知样条变换在参数高效分割中的潜力仍有待深入挖掘。

2.3 非线性激活

标准激活函数如ReLU[25]和 GELU[26]计算效率高但固定，这可能限制深度网络的非线性建模能力。为提升灵活性，近期研究引入了可学习的替代方案。截断集成线性单元（TeLU）[27]将激活函数表述为可训练的截断ReLU组合，实现有界且平滑的过渡。Gompertz线性单元（GoLU）[28]基于Gompertz函数定义的非对称激活函数 $f(x)=x\text{Gompertz}(x)$ ，能增强正输入的梯度流动同时平滑抑制负输入。GoLU利用这种固有不对称性来改善深度网络的学习动态和收敛稳定性。与此同时，架构研究表明在补丁嵌入后立即插入非线性激活可增强早期表征能力。值得注意的是，CvT[29]和PVTv2[30]实证表明后投影激活（如 GELU）对密集预测任务有益。然而，这些激活是按神经元独立施加的，且缺乏对空间或通道水平结构的感知。

3 方法

图2展示了专为医学图像分割设计的轻量级网络GroupKAN的整体架构。该设计采用对称的编码器-解码器结构，其中编码器包含三个卷积阶段。

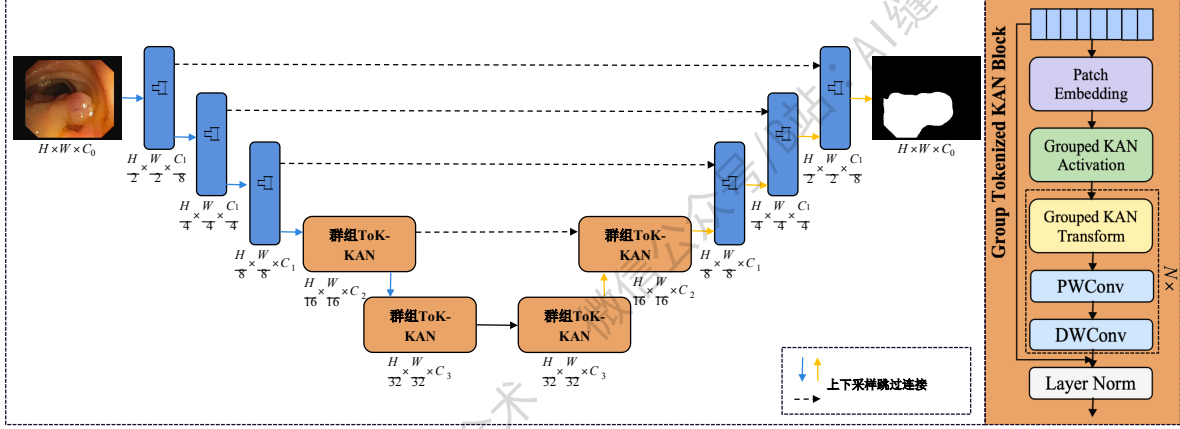


图2: GroupKAN流水线架构示意图。编码器通过卷积模块提取特征。在瓶颈层中, 每个Group ToK-KAN模块依次执行补丁嵌入和分组KAN激活, 随后进行 N 次分组KAN变换, 包含逐点和深度卷积操作。解码器通过上采样和跳跃连接对编码器进行镜像处理, 最终生成分割图。

输出通道尺寸分别为 $C_1/8$ 、 $C_1/4$ 和 C_1 。每个阶段逐步将空间分辨率减半, 同时捕捉越来越抽象的特征。

在卷积编码器之后, 特征图通过一系列**分组标记化KAN** (Group ToK-KAN) 模块进行处理。每个模块以补丁嵌入开始, 将空间特征图重塑为 $B \times N \times C$ 的标记, 其中 C 表示通道维度。随后应用**分组KAN激活**, 将 C 个通道分割为 G 组, 并在每组内应用基于样条的共享单变量激活函数, 从而实现可学习且高效的标记级非线性。接着进行**分组KAN变换**, 迭代 N 步, 每次迭代使用组内全连接KAN层转换组内通道特征, 并结合逐点和逐深度卷积以支持跨组通信与空间交互。在瓶颈阶段使用两个ToK-KAN模块, 分别在中间通道维度 C_2 和 C_3 上运行。

解码器采用与编码器相同的结构, 通过卷积块逐步上采样并细化特征。编码器中的跳跃连接实现了多尺度信息融合。解码阶段在通道维度 C_3 , C_2 , C_1 , $C_1/4$ 和 $C_1/8$ 上进行操作, 最终输出通过 1×1 卷积层投影到分割图上。

3.1 可解释功能模块的KAN

Kolmogorov-Arnold网络 (KANs) [14]通过用可学习的单变量样条函数替代固定权重投影和静态激活函数, 重新定义了神经计算模型。这一设计灵感源自Kolmogorov-Arnold表示定理[31], 该定理指出任何多元函数都可以分解为有限个单变量函数的叠加。通过解耦变换与非线性特征, KANs构建了兼具更强表达力和可解释性的统一函数建模范式。

每个KAN层将一个可训练的基于样条的算子矩阵 Φ_k 应用于输入:

$$\mathbf{Z}_{k+1} = \Phi_k \mathbf{Z}_k, \quad (1)$$

其中每个 $\phi_{q,p}: \mathbb{R} \rightarrow \mathbb{R}$ 都是可学习的单变量样条。该公式能够生成紧凑且可解释的表示, 同时保持强函数保真度, 为传统MLP提供了极具吸引力的替代方案, 尤其适用于医学图像分割等密集预测任务。

在我们的框架中, KAN承担着两个互补功能: (1)**分组KAN变换 (GKT)**, 通过在通道组内应用结构化样条映射来建模通道间依赖关系; (2)**分组KAN激活 (GKA)**, 通过分组单变量样条函数调节补丁嵌入以增强标记级表征。这些功能体现了我们的架构策略, 使GroupKAN能够有效替代分割网络中的MLP和注意力模块, 既保证了可解释性, 又实现了轻量级设计。

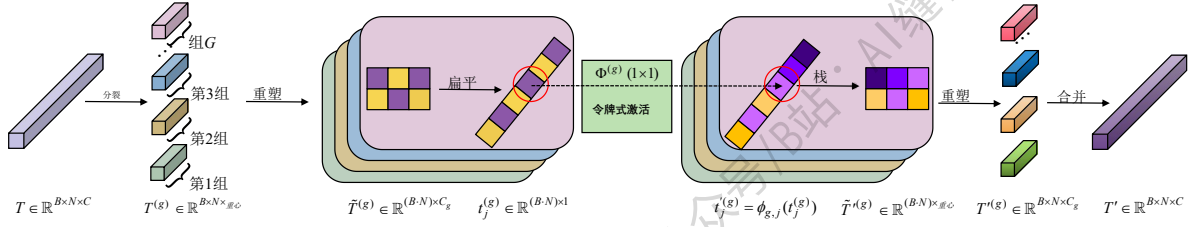


图3: 分组KAN激活示意图。给定标记嵌入 $T \in \mathbb{R}^{B \times N \times C}$, 我们将通道维度划分为 G 个组, 每个组重塑为 $(B \cdot N) \times C_g$ 。随后对每个组中的每个标量维度独立应用一维KAN函数 $\Phi^{(g)}$ 。输出经过重塑和拼接后, 生成激活表示 $T' \in \mathbb{R}^{B \times N \times C}$ 。

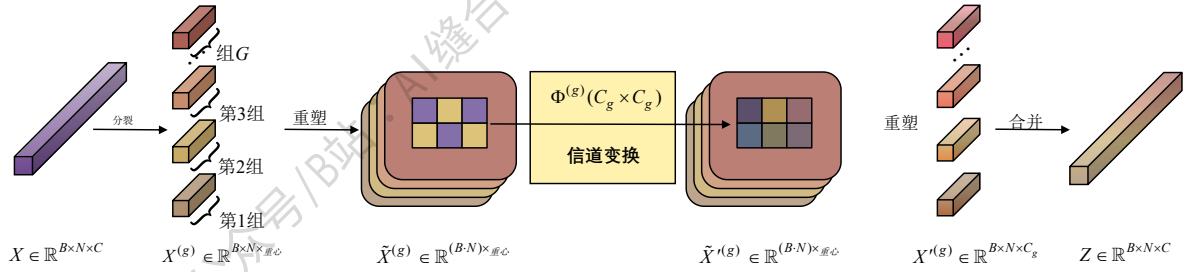


图4: 分组KAN变换示意图。输入特征 $X \in \mathbb{R}^{B \times N \times C}$ 沿通道维度被划分为 G 个组。每个组被重塑为 $(B \cdot N) \times C_g$, 并通过一个具有可学习映射的非线性变换 $\Phi^{(g)}$ (大小为 $C_g \times C_g$) 进行处理。变换后的输出被重塑并拼接, 形成输出 $Z \in \mathbb{R}^{B \times N \times C}$ 。

3.2 群组标记KAN

为启动组分标记KAN阶段, 我们首先将二维特征图转换为一系列补丁标记。对输入 $X \in \mathbb{R}^{B \times C_0 \times H \times W}$ 应用步长为2的 3×3 卷积, 生成中间特征 $F \in \mathbb{R}^{B \times C \times H' \times W'}$ 。这些特征被重塑为标记序列 $T \in \mathbb{R}^{B \times N \times C}$, 其中 $N = H' \cdot W'$ 。我们保留了U-KAN[13]中基于卷积的嵌入策略, 该策略通过感受野编码局部和位置先验, 并且与展平-投影替代方案相比, 对输入分辨率变化表现出更强的鲁棒性。

3.2.1 分组KAN激活 (GKA)

为增强标记级别的表达能力, 我们在补丁嵌入后引入了一个GKA模块 (见图3)。给定输入序列 $T \in \mathbb{R}^{B \times N \times C}$, 我们将通道维度划分为 G 组, 每组大小为 $C_g = C/G$, 从而得到分组特征 $T^{(g)} \in \mathbb{R}^{B \times N \times C_g}$ 。

每个组被重塑为二维矩阵 $\tilde{T}^{(g)} \in \mathbb{R}^{(B \cdot N) \times C_g}$ 。然后, 如展平步骤所示, 我们将每个标量特征提取为列向量 $t_j^{(g)} \in \mathbb{R}^{(B \cdot N) \times 1}$, 并应用逐标记一维样条函数 $\phi_{g,j}(\cdot)$ 以获得 $t_j'^{(g)} = \phi_{g,j}(t_j^{(g)})$ 。

该操作对应于等式1的对角变换, 其中每个 $\Phi^{(g)}$ 包含 C_g 个独立的 (1×1) 算子。Stack操作随后将群重构成 $\tilde{T}'^{(g)} \in \mathbb{R}^{(B \cdot N) \times C_g}$, 并将其重塑为 $T'^{(g)} \in \mathbb{R}^{B \times N \times C_g}$ 。所有群输出最终被拼接以生成激活序列 $T' \in \mathbb{R}^{B \times N \times C}$ 。

与传统激活函数 (如ReLU或GELU) 在早期卷积后应用不同, 我们的分词样条非线性函数可在嵌入层实现结构化、分词感知的转换, 从而提升分词层面的灵活性与表达能力。

方法	布西[32]		GlaS [33]		CVC [34]	
	Iu↑	F1↑	Iu↑	F1↑	IoU↑	F1↑
U-Net (Ronneberger等, 2015)	57.36±4.61	72.41±3.37	86.51±1.13	92.68±0.82	83.66±1.03	91.02±0.87
Att-Unet [17]	57.62±3.93	72.77±3.14	86.67±1.25	92.77±0.77	84.39±0.68	91.52±0.34
U-Net++ [15]	58.25±3.58	73.23±2.76	87.13±0.82	93.02±0.47	84.57±1.33	91.66±0.97
U-NeXt [20]	58.27±1.56	73.38±1.77	83.64±1.02	90.98±0.52	75.62±1.08	86.21±0.87
Rolling-UNet [21]	60.23±1.23	75.05±1.65	86.53±0.87	92.50±0.74	83.12±1.38	90.79±1.12
U-Mamba [22]	61.79±3.54	76.13±3.27	87.08±0.52	93.11±0.37	84.88±0.63	91.74±0.44
U-KAN [13]	63.41±2.67	76.51±2.88	87.51±0.39	93.29±0.18	85.14±0.67	91.99±0.36
群KAN (我们的)	65.18±2.73	78.22±2.72	87.91±0.36	93.66±0.19	86.31±0.73	92.35±0.64

表1: Busi、GlaS和CVC-ClinicDB数据集的定量分割结果。GroupKAN始终取得最佳交并比 (IoU) 和F1分数, 优于基于卷积、注意力机制及函数的基线方法。

3.2.2 分组KAN变换 (GKT)

GKT将分组KAN激活 (GKA) 的设计从 1×1 的标记级激活扩展为结构化 $C_g \rightarrow C_g$ 通道变换。虽然两个模块都采用分组样条框架 (见图3和图4), 但 **GKT** 通过在每个组内应用完整样条矩阵, 实现了更丰富的组内建模。

给定输入 $X \in \mathbb{R}^{B \times N \times C}$, 我们将信道维度划分为 G 个组, 每组大小为 $C_g = C/G$, 得到 $X^{(g)} \in \mathbb{R}^{B \times N \times C_g}$ 。每个组被重塑为 $\tilde{X}^{(g)} \in \mathbb{R}^{(B \cdot N) \times C_g}$, 并通过一个可学习的非线性映射:

$$\tilde{X}'^{(g)} = \Phi^{(g)}(\tilde{X}^{(g)}), \quad \Phi^{(g)} = [\phi_1^{(g)}, \dots, \phi_{C_g}^{(g)}], \quad (2)$$

其中每个 $\phi_j^{(g)}: \mathbb{R} \rightarrow \mathbb{R}$ 是基于样条的函数, 每组形成一个 $C_g \rightarrow C_g$ 变换。输出被重塑为 $X'(g) \in \mathbb{R}^{B \times N \times C_g}$ 并拼接为 $Z = \text{Concat}_{g=1}^G X'(g) \in \mathbb{R}^{B \times N \times C}$ 。

为促进跨组间交流与空间交互, 我们采用逐点卷积后接非线性处理及深度卷积的处理流程:

$$Y = \text{DWConv}(\sigma(\text{PWConv}(Z))). \quad (3)$$

该过程在每个Group ToK-KAN块内重复 N 次, 以逐步丰富通道特征。与标准全通道KAN相比, 后者复杂度为 $O(C^2)$, 而分组变体将复杂度降低至 $O(C^2/G)$, 同时保持组内表达能力。

为稳定优化过程并保持恒等映射, 我们采用残差连接层和归一化层 (LayerNorm):

$$Y = Y + X, \text{ 输出} = \text{LayerNorm}(Y). \quad (4)$$

生成的输出被转发至下一转化阶段。

4 实验

4.1 数据集

为确保与先前研究的公平比较, 我们在U-KAN[13]使用的相同数据集 (包括Busi、GlaS和CVC-ClinicDB) 上评估了GroupKAN。这些基准测试涵盖多种医学影像模态, 涉及超声、组织病理学和结肠镜分割任务。

Busi[32]数据集包含780幅乳腺超声图像, 已标注良性、恶性及正常病例的肿瘤分割。该数据集具有显著的散斑噪声和低对比度特征。所有图像均调整为 256×256 像素。

GlaS[33]包含245张用于结直肠腺体分割的组织学图像。该数据集具有高度腺体变异性和结构变形特征, 尤其在良性与恶性样本之间表现显著。图像尺寸调整为 512×512 。

CVC-ClinicDB[34]包含612帧带有像素级息肉标注的结肠镜图像。该数据集涉及显著的光照变化和尺度变化。图像被调整为 256×256 的尺寸。

方法	平均分段		效率	
	Iu↑	F1↑	每秒浮点运算次数	参数(M)
U-Net [6]	75.84±2.26	85.37±1.69	436.94	31.04
Att-Unet [17]	76.23±1.95	85.69±1.42	531.78	34.9
U-Net++ [15]	76.65±1.91	85.97±1.40	1109	36.6
U-NeXt [20]	72.51±1.22	83.52±1.05	4.58	1.47
Rolling-UNet [21]	76.63±1.16	86.11±1.17	16.82	1.78
U-Mamba [22]	77.92±1.56	87.00±1.36	2087	86.3
U-KAN [13]	78.69±1.24	87.26±1.14	14.02	6.35
群KAN (我们的)	79.80±1.27	88.07±1.19	7.72	3.02

表2: Busi、GlaS和CVC-ClinicDB数据集上的平均分割性能与模型复杂度。GroupKAN在保持显著低于U-KAN的参数量和浮点运算次数（FLOPs）的同时，实现了比现有骨干模型更高的交并比（IoU）和F1分数。

4.2 实施细节

所有实验均使用PyTorch在单个 NVIDIA RTX 3090 GPU上进行。为确保公平比较，我们遵循了与U-KAN[13]相同的实验设置，包括随机种子初始化和评估协议。对于所有数据集，模型使用Adam优化器以8的批量大小训练400个周期，初始学习率为 1×10^{-4} ，并采用余弦退火法调度至 1×10^{-5} 。损失函数结合二元交叉熵（BCE）和Dice损失以平衡像素级准确性和区域重叠。训练期间应用了标准数据增强技术，包括随机旋转和翻转。每个数据集被随机划分为80%的训练集和20%的验证集。为确保稳健性，表.1和表.2报告了不同随机种子（包括数据分割）下三次独立运行的平均结果，而表.3–表.8展示了固定种子下单次运行的结果，以隔离各消融效果的影响。所有浮点运算次数（FLOPs）均在 512×512 的输入分辨率下进行测量，以确保不同模型间计算效率的比较具有可比性。所有实验均在此统一配置下完成。

4.3 与常用分割骨架的比较

表1在三个基准数据集上将GroupKAN与几种成熟的分割骨干网络进行比较。我们评估了基于卷积的模型（U-Net[6]、U-Net++[15]）、基于注意力的方法（Att-Unet[17]、U-Mamba[22]）以及MLP式架构（U-NeXt[20]、Rolling-UNet[21]）。U-KAN[13]作为我们的主要基线模型。GroupKAN在所有数据集上均实现了最高的交并比（IoU）和F1分数，展现出卓越的分割精度。如表2所示，其结构也更为轻量，参数数量和FLOPs均少于U-KAN（3.02M vs. 6.35M; 7.72 vs. 14.02 GFLOPs），同时IoU提升了+1.11%。

图5的定性分析结果充分展现了GroupKAN在生成精准分割边界和保留精细结构细节方面的卓越能力。相较于U-KAN等传统方法，GroupKAN能更有效地应对过度分割和分割不足问题，显著提升了复杂解剖区域的清晰度。这些直观的可视化效果进一步印证了GroupKAN的优越性，证明该算法在医疗图像分割领域堪称实力派选手，完美平衡了精度与效率之间的关系。

为进一步验证观察到的性能提升的可靠性，我们在Busi、GlaS和CVC数据集上进行了三次独立运行的单侧Wilcoxon符号秩检验[35]（ $n=9$ 对）。GroupKAN的交并比（IoU）（ $W=39.0$, $p=0.027$ ）和F1分数（ $W=45.0$, $p=0.002$ ）均显著高于U-KAN，证实这些改进在 $p<0.05$ 水平上具有统计学意义。该分析进一步证实GroupKAN的性能提升是持续的，而非由随机初始化或数据分割变化所致。

4.4 消融研究

4.4.1 GKT 层数。

我们评估了GKT层深度对分割性能的影响。如表3所示，三层配置的IoU和F1值最高，优于更深的变体。虽然增加GKT层数会增加参数量

为标题运行标题

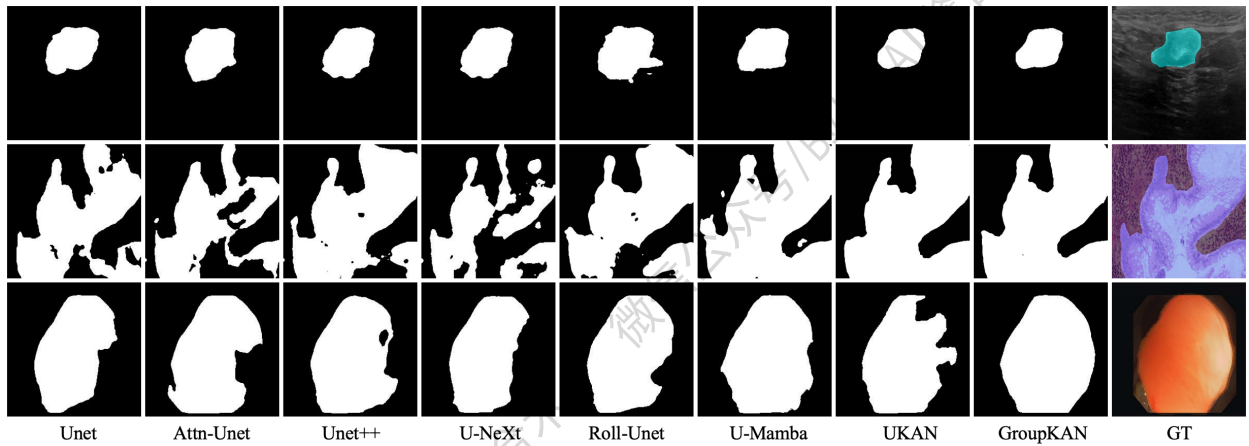


图5: Busi、GlaS与CVC-ClinicDB数据集分割结果的定性对比。GroupKAN在异质性医学影像模态中生成更准确且一致的掩膜，与真实标注高度吻合。

(5层时参数量高达347万)，但并未转化为更高的准确率，这可能是由于过拟合或优化不稳定所致。3层架构（参数量302万）在准确率与模型复杂度之间实现了最佳平衡。

#GKT	IoU↑	F1↑	参数(M)
1 层	60.63	75.28	2.56
2 层	63.13	77.12	2.79
3 层	67.66	80.52	3.02
4 层	65.99	79.60	3.24
5 层	65.95	79.51	3.47

表3: KAN组 GKT 层数消融研究。三层变体在参数开销适中的情况下，实现了最高的IoU和F1分数。

4.4.2 GKT 与 MLP 的影响

我们对比了基于 GKT 和 MLP 的配置方案，如表4所示。三层 GKT 架构在参数数量适中时，取得了最高的IoU和F1分数。混合配置方案（如 MLP + GKT + GKT 和 GKT + MLP + GKT）虽然准确率略有下降，但仍优于纯 MLP 基线。值得注意的是，MLP ×3的配置方案尽管参数更多，但表现最差。这些结果凸显了 GKT 层在提升分割精度的同时保持模型效率的重要性。

模型	IoU↑	F1↑	参数(M)
GKT×3	67.66	80.52	3.02
MLP+GKT+GKT	66.12	78.93	3.08
GKT+MLP+GKT	65.81	78.58	3.08
GKT+GKT+MLP	65.94	78.62	3.08
MLP×3	63.96	77.55	3.17

表4: GKT 与 MLP 模型性能对比的消融研究。

4.4.3 超参数配置

我们探讨了不同超参数设置下IoU随参数数量的变化情况，这些设置由 G_{KA} （分组KAN激活中的组别）和 G_{GKT} （分组KAN变换中的组别）定义，如图6所示。三维图通过气泡大小（参数）和颜色（IoU）可视化每种配置，虚线将点投影到 $Z=62$ 的基平面。在所有组合中，标记为红色星号的 16×16 设置实现了最高的IoU（67.66），

为标题运行标题

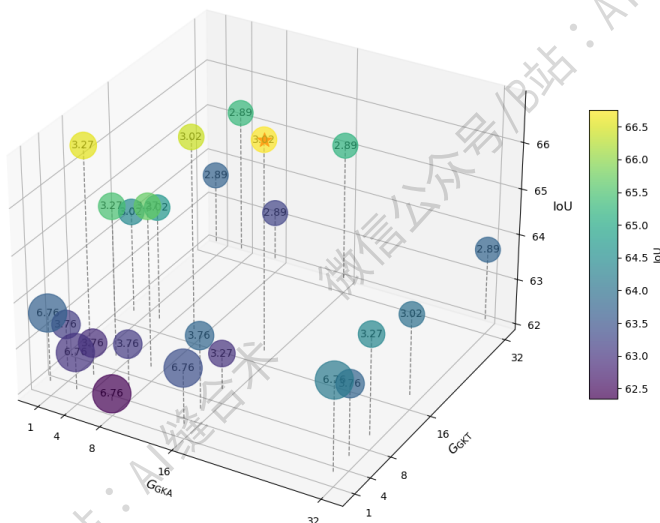


图6: G_{KA} 和 G_{KT} 配置下IoU和参数计数的3D可视化。气泡大小表示模型大小(M)，颜色代表IoU，红色星号标记最优设置。

在分割精度与模型复杂度之间取得平衡。值得注意的是，过粗或过细的分组都会降低性能，这表明需要调整分组粒度。这些结果凸显了分组配置的敏感性及其在优化模型设计中的核心作用。

4.4.4 模型标度

我们通过改变GroupKAN中的通道维度 C_1 , C_2 和 C_3 来研究模型缩放（见表5）。较大的模型始终能产生更高的IoU和F1值，但代价是参数和计算量的增加。默认的GroupKAN配置在性能和效率之间实现了良好的平衡，而GroupKAN-S则提供了一个轻量级的替代方案，仅带来轻微的精度折损。

模型	C_1	C_2	C_3	IoU↑	F1↑	参数
G-KAN-S	64	96	128	65.89	79.29	0.87
G-KAN	128	160	256	67.66	80.52	3.02
G-KAN-L	256	320	512	68.36	80.95	12.00

表5: 通过编码器通道 (C_1 , C_2 , C_3) 对GroupKAN模型进行缩放的消融实验。“G-KAN”指基础GroupKAN模型；G-KAN-S和G-KAN-L分别为其小规模和大规模变体。

4.4.5 GKA 的影响。

与固定型 (ReLU[25]、GELU[26]) 和可学习型 (TeLU[27]、GoLU[28]) 激活函数相比，我们的 GKA 始终表现更优，尤其在反映精细结构更好区分的F1分数上。我们进一步发现，在补丁嵌入后插入激活函数能提升所有变体，其中我们的方法获得最大收益。这些发现凸显了结构化、群体感知激活函数在密集医学图像分割中的优势。

GKT 效应

我们对分组KAN变换 (GKT) 及其卷积组件进行消融分析。移除1×点卷积会导致性能下降 (IoU 0.6552, Dice 0.7890)，参数量减少至261万。移除3×深度卷积进一步降低准确率 (IoU 0.6246, Dice 0.7666，参数量299万)。完全移除 GKT 则获得最低分数 (IoU 0.6015, Dice 0.7483，参数量277万)。包含两种卷积的完整配置

为标题运行标题

激活函数	Iu↑	F1↑
没有一个	66.10	78.22
ReLU [25]	66.63	79.24
GELU [26]	66.45	79.46
GOLU[28]	66.84	79.82
TeLU [36]	66.44	79.22
GKA（我们的）	67.66	80.52

表6：补丁嵌入后激活函数的对比。GKA（本研究）在IoU和F1指标上优于固定型（ReLU、GELU）和可学习型（TeLU、DyT）变体。

配置	I/OU	骰子	参数(M)
1 × 1 PWConv	0.6552	0.7890	2.61
无 3 × 3 DWConv	0.6246	0.7666	2.99
无 GKT	0.6015	0.7483	2.77
GKT（含PW+DW）	0.6766	0.8052	3.02

表7：GKT 消融及其相关卷积的影响。GKT 提供主要的功能转换，而PWConv和DWConv则增强组间及空间交互作用。

达到最佳性能（IoU 0.6766, Dice 0.8052, 3.02M）。这些结果证实 GKT 对于精确的特征变换至关重要，而PWConv和DWConv分别支持跨组和空间交互。这些结果表明 GKT 在参数开销最小的情况下提高了分割精度，体现了其参数效率。

4.4.6 可解释性分析。

我们通过分析激活模式（图7）进一步评估GroupKAN的可解释性。左上图像（U-KAN）未能定位目标区域，其似真IoU为0.41。右上变体（未使用 GKT 的GroupKAN）表现更差（0.28），表明缺乏 GKT 导致聚焦效果下降。加入 GKT（左下）后与真实值对齐度提升，似真IoU达到0.52。右下显示GT掩码。为验证这些发现，我们报告了测试集的平均似真IoU（表8）：U-KAN为0.465，未使用 GKT 的GroupKAN降至0.281，而使用 GKT 的GroupKAN达到0.517。这些结果证实 GKT 能增强激活值与真实值的一致性，并提升分割任务的可解释性。

方法	平均似然IoU
U-KAN	0.465
无 GKT 的Ours	0.281
我们的w/ GKT	0.517

表8：测试集上平均似然IoU比较。GKT 提高了激活对齐度和可解释性。

5 结论

在本研究中，我们提出GroupKAN——一种基于分组结构样条建模的轻量级医学图像分割网络。该网络采用分组KAN激活来建模标记级非线性，以及分组KAN变换以实现高效的分组通道交互，将U-KAN中KAN层的复杂度从 $O(C^2)$ 降低至 $O(C^2/G)$ 。在Busi、GlaS和CVC基准测试中，GroupKAN作为骨干网络表现强劲，仅使用U-KAN参数的47.6%（3.02百万对比6.35百万）即可达到79.80%的平均IoU。此外，合理性IoU评估显示激活图与真实值的对齐度提升，支持GroupKAN在临床分割中的可解释性。这为轻量级且可解释的临床分割确立了新范式。

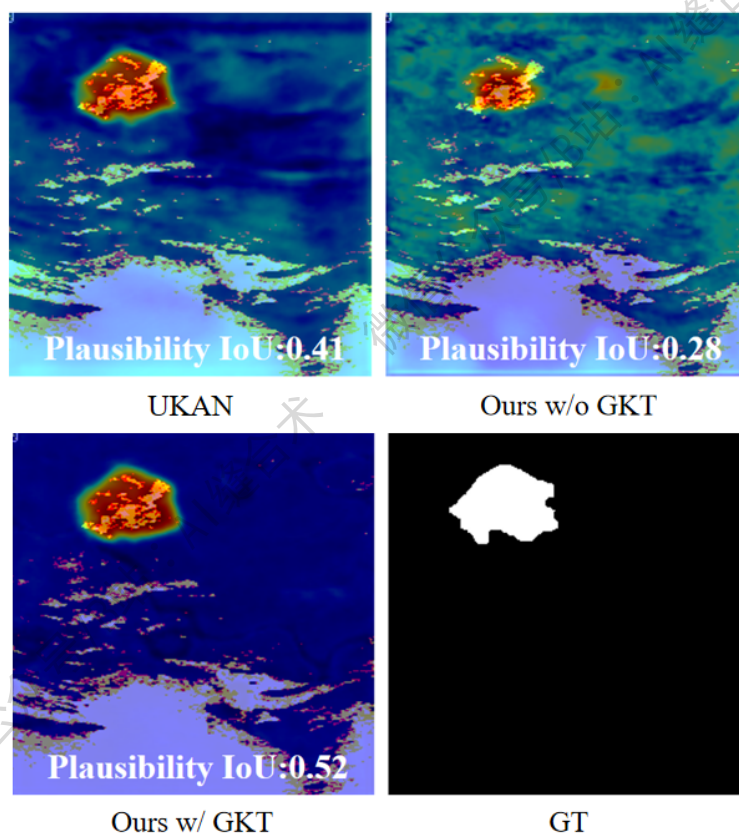


图7: 用于可解释性比较的通道激活图。带 GKT 的GroupKAN（左下）与GT掩码（右下）的对齐效果最佳，达到最高的似然IoU（0.52）。U-KAN和不带 GKT 的GroupKAN对齐效果较差，凸显了 GKT 在提升可解释性方面的作用。

参考文献

- [1] 王日生、雷涛、崔瑞霞、张炳涛、孟红英和Asoke K Nandi. 基于深度学习的医学图像分割：综述。《IET 图像处理》，16(5):1243–1267,2022。
- [2] KKD Ramesh、G Kiran Kumar、K Swapna、Debabrata Datta 和 S Suman Rajest. 医学图像分割算法综述。《EAI 批准的普适健康与技术汇刊》，7(27)，2021。
- [3] Sohaib Asif、Yi Wenhui、Saif ur Rehman、Qurrat ul Ain、Kamran Amjad、Yi Yueyang、Si Jinhai 与 Muhammad Awais. 机器学习在医学诊断中的进展与前景：揭示诊断精准性的未来。《计算工程方法档案》，32(2):853–883,2025年。
- [4] 张玉涵、马晓、李明超、黄坤、朱杰、王淼、xi王、吴梦林和彭安恒. 通用医学基础模型从多模态MRI图像中改善前列腺癌分割。《npj Digital Medicine》，8(1):372,2025。
- [5] Enerst Edozie、Aliyu Nuhu Shuaibu、Ukagwu Kelechi John 和 Bashir Olaniyi Sadiq. 基于深度学习的视觉目标检测最新进展综述。《人工智能评论》，58(9):277,2025年。
- [6] 奥拉夫·罗内伯格、菲利普·菲舍尔与托马斯·布罗克斯。U-net：用于生物医学图像分割的卷积网络。收录于《国际医学图像计算与计算机辅助干预会议》，第234–241页。施普林格出版社，2015年。
- [7] Md Maruf Hossain Shuvo、Syed Kamrul Islam、Jianlin Cheng和Bashir I Morshed. 资源受限边缘设备上深度学习推理的高效加速：综述。《IEEE 学报》，111(1):42–91,2022年。