

视觉Transformer是循环注意力学习器

韩东晨^{1*}、李天宇^{2*}、王子怡¹、黄高^{1†}

¹清华大学北京核工业学院自动化系

²清华大学跨学科信息科学研究院

摘要

自注意力机制一直是视觉Transformer技术进展的关键因素。然而，其二次复杂度在高分辨率场景下会带来沉重的计算负担，限制了实际应用。先前的方法试图通过引入局部性或稀疏性等人工设计的模式来缓解这一问题，但不可避免地会牺牲模型容量。本文提出了一种名为**循环注意力**的新型注意力范式，充分利用了自注意力机制固有的高效模式。具体而言，我们首先发现视觉Transformer中的自注意力矩阵通常近似于具有循环块的块循环矩阵（BCCB），这是一种结构化矩阵，与其他矩阵的乘法运算可在 $O(N \log N)$ 时间内完成。基于这一有趣特性，我们将注意力图显式建模为其最近邻 BCCB 矩阵，并提出高效的计算算法以实现快速运算。该方法与传统自注意力机制高度相似，仅在使用 BCCB 矩阵方面存在差异。由于我们的设计灵感源自固有的高效范式，因此不仅实现了 $O(N \log N)$ 的计算复杂度，还基本保持了标准自注意力机制的容量。针对多种视觉任务的大量实验验证了我们方法的有效性，证实循环注意力机制可作为视觉Transformer架构中自注意力机制的有前景替代方案。

附录: github.com/LeapLabTHU/Circulant-Attention

1 引言

近年来，Transformer模型在计算机视觉领域迅速崭露头角。得益于自注意力机制的卓越性能，视觉Transformer能够有效从大规模数据中学习，已在图像分类（Dosovitskiy 等，2021）、目标检测（Carion 等，2020）、语义分割（Xie等，2021）及多模态任务（Xia 等，2024）等多个领域取得显著成果。

然而，将自注意力机制整合到视觉架构中也带来挑战。自注意力机制的二次复杂度 $O(N^2)$ 在应用于全局感受野时会导致计算成本过高。先前研究（Wang 等人 2021；Liu 等人 2021；Zhu 等人）

*这些作者的贡献度相同。

†通讯作者。

版权所有 © 2026，人工智能促进协会（www.aaii.org）。保留所有权利。




图1：纯自注意力机制与所提出的循环注意力机制示意图。 σ 表示Softmax函数， Θ 为哈达玛积， $\mathcal{F}_{2D}$ 、 $\mathcal{F}_{2D}^{-1}$ 分别表示二维离散傅里叶变换（DFT）及其逆变换。我们的循环注意力机制在很大程度上继承了自注意力机制的范式，只是采用了 BCCB 注意力矩阵。这一简单改进使得我们的设计能够通过基于DFT的乘法运算高效计算，从而实现 $O(N \log N)$ 的复杂度。为简化计算过程，省略了缩放因子和头部求和步骤。具体细节请参阅第4节。

Han等人（2023年）、Wang等人（2025年）通过引入手工设计的模式（如限制感受野范围或引入稀疏性）来应对这一挑战。虽然这些手工设计能有效降低计算需求，但其本质上相当于对自注意力机制施加的外部约束，这不可避免地会削弱模型的长距离建模能力并限制其扩展性。

本文发现了一个有趣现象：视觉Transformer中的注意力图频繁逼近一种特殊矩阵——循环块块循环矩阵（BCCB）。这类矩阵是二维场景中循环矩阵的扩展形式，其与其他矩阵的乘法运算可通过二维离散傅里叶变换（DFT）高效实现。这表明标准自注意力机制虽然计算成本为 $O(N^2)$ ，却能内在地学习出可通过 $O(N \log N)$ 复杂度计算的高效模式。这一发现促使我们重新思考自注意力机制的设计，并提出一个极具说服力的研究问题：

我们能否将注意力图显式设置为BCCB 矩阵以提升计算效率，同时保持基础自注意力机制的高度表达能力？

为回答这个问题，我们深入探究自注意力操作的本质，提出名为**循环注意力**的新范式以充分利用观测模式。具体而言，我们通过将原始自注意力矩阵垂直投影到 BCCB 矩阵子空间，显式地将注意力图转换为 BCCB 矩阵。我们证明这种数学重构可通过二维离散傅里叶变换实现注意力分数和输出特征的高效计算，从而将计算复杂度从 $O(N^3)$ 降低至使用快速傅里叶变换算法（FFT）时的 $O(N \log N)$ 。如图1所示，该方法与传统自注意力机制高度相似，区别在于直接生成 BCCB 注意力矩阵并将密集矩阵乘法替换为基于DFT的操作。基于此设计，我们引入标记重加权模块以克服 BCCB 结构的固有局限，进一步提升模型容量。

我们通过图像分类、目标检测和语义分割等多种视觉识别任务中开展大量实验，验证了设计方案的有效性。实验结果表明，所提出的循环注意力机制具有高效性和表达能力，这使其成为视觉Transformer架构中自注意力机制的潜在替代方案。

我们的主要贡献与要点如下：

- 我们发现视觉Transformer中的注意力图常采用循环块（CirculantBlocks, BCCB）来近似块循环矩阵，这是二维场景中循环矩阵的扩展形式。我们对该现象进行了详细分析和可视化展示。
- 我们提出了一种名为循环注意力机制的新方法，该机制利用观测到的 BCCB 模式实现高效计算，时间复杂度为 $O(N \log N)$ 。我们的方法作为插件式注意力模块，可应用于多种视觉Transformer模型。
- 在图像分类、目标检测及语义分割领域的大量实验表明，循环注意力机制在效率与表达能力之间实现了理想平衡，这使其成为广泛采用的自注意力机制的一种有前景的替代方案。

2 相关工作

Vision Transformer. 近年来，Transformer架构与注意力机制在计算机视觉领域取得了显著进展（Vaswani等人，2017）。然而，自注意力机制的二次计算复杂度在处理全局特征图时会导致不可控的成本。为解决这一问题，研究者通过引入局部性或稀疏性等人工设计模式，提出了多种降低计算开销的方法。局部方法如Swin Transformer（Liu等人，2021）将注意力限制在非重叠窗口内，从而降低计算成本；CSwin（Dong等人，2022）通过引入十字形窗口扩展该思路以增强上下文信息；Neighborhood Attention Transformer（NAT）（Hassani等人，2023）通过将注意力限制在每个查询

符号说明	描述
$\mathcal{F}_{1D}, \mathcal{F}_{1D}^{-1}$	一维离散傅里叶变换（DFT）及其逆变换
$\mathcal{F}_{2D}, \mathcal{F}_{2D}^{-1}$	二维离散傅里叶变换（DFT）及其逆变换
$(\cdot)^*$	复共轭
σ	对每行执行Softmax运算。
$\odot$	哈达玛积，逐元素乘积。我们定义的基于密度泛函理论（DFT）的矩阵乘法。
$\ \cdot\ $	弗罗贝尼乌斯范数
$\langle \cdot, \cdot \rangle$	弗罗贝尼乌斯内积

表1: 本文使用的重要符号说明。

的局部邻域内进一步模拟卷积操作。除上述设计外，另一研究方向采用稀疏注意力范式：PVT（Wang等人，2021）通过键值降采样降低计算复杂度，DAT（Xia等人，2022）提出输入依赖型稀疏注意力模式；BiFormer（Zhu等人2023年研究采用双层路由注意力机制，可动态确定每个查询的感兴趣区域。尽管这些手工设计的注意力模式效率较高，但不可避免地会削弱全局自注意力机制的表现力。本文通过利用自注意力机制固有的高效结构，在效率与表现力之间实现了优化平衡。

基于DFT的高效架构。离散傅里叶变换（DFT）长期以来一直是数字图像处理中的重要工具（Pitas 2000）。近期研究将DFT与快速傅里叶变换（FFT）相结合，用于设计高效的网络组件（Li等 2021；Rao等 2021；Guibas等 2021；Huang等 2023；Kong等 2023）。GF-Net（Rao等 2021）利用DFT的卷积定理构建全局深度卷积模块，通过 FFT 实现 $O(N \log N)$ 复杂度。FNO（Li等 2021）进一步将该方法推广至密集全局卷积。AFNO（Guibas等 2021）与AFFNet（Huang等 2023）通过输入依赖型频率滤波器实现了等效的动态深度卷积。本文采用二维DFT与 FFT 算法，高效实现循环注意力机制。

3 前言

本节重新阐述自注意力机制、循环矩阵及 BCCB 矩阵的数学模型。为便于理解，我们在表1中对关键符号进行归纳总结。

3.1 注意形成

我们首先简要回顾视觉Transformer模型中基础自注意力机制的计算（Vaswani等人，2017）。考虑图像标记序列 $\mathbf{x} \in \mathbb{R}^{N \times C}$ ，其中 $N=H \times W$ ， H ， W ， C 分别表示特征图的高度、宽度和维度。在每个注意力头中， $\mathbf{x}$ 通过投影矩阵 $W_{Q/K/V} \in \mathbb{R}^{C \times d}$ 转换为 $\mathbf{Q}$ ， $\mathbf{K}$ ， $\mathbf{V} \in \mathbb{R}^{N \times d}$ ，其中 d 为头维度。基于此，自注意力机制计算注意力权重

并根据标准化注意力分数将输出值计算为加权和：

$$\mathbf{A} = \mathbf{Q}\mathbf{K}^\top / \sqrt{d}, \quad \mathbf{O} = \sigma(\mathbf{A})\mathbf{V}, \quad (1)$$

其中 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 为原始注意力矩阵， σ 表示 Softmax 函数。

3.2 循环矩阵

一个 $N \times N$ 矩阵 $\mathbf{C}$ 是循环矩阵当且仅当每一行都是前一行的循环移位。其形式为：

$$\mathbf{C} = \begin{pmatrix} c_0 & c_1 & \cdots & c_{N-1} \\ c_{N-1} & c_0 & \cdots & c_{N-2} \\ \vdots & \vdots & \ddots & \vdots \\ c_1 & c_2 & \cdots & c_0 \end{pmatrix} \quad (2)$$

此类矩阵可通过其第一行 $\mathbf{c} = [c_0, c_1, \dots, c_{N-1}]$ 完全确定，其中 $C_{i,j} = c_{j-i \pmod{N}}$ 。

循环矩阵 $\mathbf{C} \in \mathbb{R}^{N \times N}$ 与向量 $\mathbf{x} \in \mathbb{R}^N$ 的乘积可表示为：

$$(\mathbf{C}\mathbf{x})_i = \sum_{j=0}^{N-1} C_{i,j} x_j = \sum_{j=0}^{N-1} c_{(j-i) \pmod{N}} x_j \quad (3)$$

令 $k = (j - i) \pmod{N}$ ，这意味着 $j = (i+k) \pmod{N}$ 。我们可以将该表达式重写为：

$$(\mathbf{C}\mathbf{x})_i = \sum_{k=0}^{N-1} c_k \cdot x_{(i+k) \pmod{N}} \quad (4)$$

这正是 $\mathbf{c}$ 与 $\mathbf{x}$ 之间一维圆形互相关函数的定义，即深度学习采用圆形填充的一维深度卷积（其中卷积概念不涉及核翻转）。因此，乘积 $\mathbf{y} = \mathbf{C}\mathbf{x}$ 可通过 *互相关定理*（Wang 2019）实现，该定理指出互相关结果的傅里叶变换等价于第一信号共轭傅里叶变换与第二信号傅里叶变换的逐元素乘积。数学表达式为：

$$\mathcal{F}_{1D}(\mathbf{C}\mathbf{x}) = \overline{\mathcal{F}_{1D}(\mathbf{c})} \odot \mathcal{F}_{1D}(\mathbf{x}). \quad (5)$$

因此，我们得出：

$$\mathbf{C}\mathbf{x} = \mathcal{F}_{1D}^{-1} \left(\overline{\mathcal{F}_{1D}(\mathbf{c})} \odot \mathcal{F}_{1D}(\mathbf{x}) \right), \quad (6)$$

其中 $\mathcal{F}_{1D}$ 、 $\mathcal{F}_{1D}^{-1}$ 表示一维离散傅里叶变换（DFT）及其逆变换， $\odot$ 为逐元素（哈达玛）乘积， $\overline{(\cdot)}$ 表示复共轭。借助快速傅里叶变换算法，我们可以以 $\mathcal{O}(N \log N)$ 的时间复杂度计算 $\mathbf{y} = \mathbf{C}\mathbf{x}$ 。

3.3 BCCB 矩阵

带循环块的循环矩阵块（BCCB）是循环矩阵（Davis 1979）的二维推广形式。BCCB 矩阵 $\mathbf{B} \in \mathbb{R}^{N \times N}$ ， $N = H \times W$ 具有由 $H \times H$ 个块组成的块循环结构：

$$\mathbf{B} = \begin{pmatrix} \mathbf{C}_0 & \mathbf{C}_1 & \cdots & \mathbf{C}_{H-1} \\ \mathbf{C}_{H-1} & \mathbf{C}_0 & \cdots & \mathbf{C}_{H-2} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{C}_1 & \mathbf{C}_2 & \cdots & \mathbf{C}_0 \end{pmatrix} \quad (7)$$




图 2: $N \times N$ 注意力图来自 DeiT（Touvron 等人，2021），其中 $N = H \times W$ ， $H = W = 14$ 。在无人工约束条件下，Vision Transformer 中的自注意力模块学习近 BCCB 模式。为便于观察，我们使用灰色虚线将矩阵划分为 $H \times H$ 形状为 $W \times W$ 的块。放大查看最佳效果。

其中每个块 $\mathbf{C}_i$ 是一个大小为 $W \times W$ 的循环矩阵。与循环矩阵类似，BCCB 矩阵 $\mathbf{B}$ 完全由其第一行 $\mathbf{b} = [c_0, c_1, \dots, c_{HW-1}]$ 决定。设 $\hat{\mathbf{b}}, \hat{\mathbf{x}} \in \mathbb{R}^{H \times W}$ 分别表示 $\mathbf{b}, \mathbf{x}$ 的二维重构版本。如附录所证明，乘法运算 $\mathbf{y} = \mathbf{B}\mathbf{x}$ 等价于二维圆形互相关在 $\hat{\mathbf{b}}$ 与 $\hat{\mathbf{x}}$ 之间，即深度学习中采用圆形填充的二维深度卷积操作。与一维场景类似，该操作可通过二维离散傅里叶变换（DFT）实现（Davis 1979）：

$$\mathbf{B}\mathbf{x} = \mathcal{F}_{2D}^{-1} \left(\overline{\mathcal{F}_{2D}(\hat{\mathbf{b}})} \odot \mathcal{F}_{2D}(\hat{\mathbf{x}}) \right) \triangleq \hat{\mathbf{b}} \circledast \hat{\mathbf{x}}, \quad (8)$$

其中 $\mathcal{F}_{2D}$ 、 $\mathcal{F}_{2D}^{-1}$ 表示二维离散傅里叶变换及其逆变换。该图是我们定义的基于 DFT 的乘法运算。为简化说明，本文未展示一维 $\mathbb{R}^N$ 序列与二维 $\mathbb{R}^{H \times W}$ 特征图之间的重塑操作，并将 $\mathcal{F}_{2D}$ 、 $\mathcal{F}_{2D}^{-1}$ 的输入/输出定义为一维序列。

4 方法

4.1 视觉 Transformer 中的高效模式

自注意力机制以二次复杂度 $\mathcal{O}(N^2)$ 计算每个查询与键之间的成对相似度。然而我们发现一个有趣现象：在实践中，视觉 Transformer 倾向于学习结构更严谨且高效的注意力模式。具体而言，在图 2 中，我们可视化了从 DeiT 模型（Touvron 等人，2021）中提取的若干注意力矩阵。这些矩阵与具有循环块（BCCB）的循环块矩阵高度相似。如第 3 节所述，与 BCCB 矩阵相乘等价于二维全局卷积操作，可通过快速傅里叶变换算法在 $\mathcal{O}(N \log N)$ 时间内完成。这表明尽管自注意力机制在形式上涉及二次复杂度，但其隐含地继承了高效结构。




图3：连续查询的 $N \times N$ 注意力矩阵与 $H \times W$ 注意力分布，其中 $N=H \times W$ ， $H=W=14$ 。红色点对应查询标记。当呈现 BCCB 模式时，注意力分布显示出类似卷积的平移不变性。

为深入理解这一现象，我们在图3的注意力矩阵中展示了相邻查询标记（红色标注）的注意力分布。关键发现是：注意力分布呈现出与查询位置移动相对应的近似的平移不变性，这与 BCCB 矩阵实现的二维全局卷积行为完全一致。该结果进一步证实，视觉Transformer中学习的注意力机制与 BCCB 矩阵具有高度相似性。

基于上述发现，一个关键研究问题随之浮现：我们能否明确强制注意力矩阵具有 BCCB 结构？

在下一节中，我们将通过循环注意力机制来回答这个问题，这是一种采用 BCCB 注意力矩阵的新型注意力机制。通过施加这种结构先验，我们旨在将 BCCB 矩阵的有益特性（即 $O(N \log N)$ 复杂度和固有的平移不变性）显式编码到注意力机制中，从而同时获得效率与表达能力的双重优势。

4.2 循环注意力

我们的循环注意力机制通过其最近的循环块（BCCB）矩阵 $\tilde{A}$ ，近似原始注意力图 $A \in \mathbb{R}^{N \times N}$ 。形式上，我们有

$$\tilde{A} = \arg \min_{B \in \mathcal{B}} \|A - B\|_F \quad (9)$$

其中 $\mathcal{B}$ 表示 $N \times N$ BCCB 矩阵子空间， $\|\cdot\|_F$ 表示弗罗贝尼乌斯范数。因此， $\tilde{A}$ 是 A 在 BCCB 矩阵子空间中的正交投影。如第3节所述， $N \times N$ BCCB 矩阵可通过其第一行完全确定。令 B_k 表示第一行为 k 位全1向量的 BCCB 矩阵，不难看出 $\{B_0, \dots, B_{N-1}\}$ 构成了 BCCB 矩阵子空间的基向量。此外，我们有

$$\langle B_k, B_k \rangle = N, \langle B_k, B_j \rangle = 0, k \neq j, \quad (10)$$

其中 $\langle \cdot, \cdot \rangle$ 表示Frobenius内积，即两个矩阵逐元素乘积的和。等式(10)表明 $\{B_0, \dots, B_{N-1}\}$ 是一个正交基。因此，BCCB 矩阵子空间中的正交投影 $\tilde{A}$ 可表示为：

$$\begin{aligned} \tilde{A} &= \sum_{k=0}^{N-1} \frac{1}{N} \frac{\langle A, B_k \rangle}{\langle B_k, B_k \rangle} B_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} \langle A, B_k \rangle B_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} \langle \frac{QK^\top}{\sqrt{d}}, B_k \rangle B_k \end{aligned} \quad (11)$$

通过 BCCB 注意力矩阵 $\tilde{A}$ ，我们的循环注意力将输出计算为 $O = \tilde{A}V$ ，类似于标准自注意力机制（参见等式(1)）。

高效计算算法。当使用上述投影公式计算时，所提出的循环注意力机制仍会产生 $O(N^2)$ 复杂度。本文证明，通过采用二维离散傅里叶变换，我们的方法可在 $O(N \log N)$ 时间内等效计算。

具体来说，由于 $\tilde{A}$ 是一个 BCCB 矩阵，其整体结构由第一行决定。我们将该行记为 $\mathbf{a}$ ，其表达式为：

$$\mathbf{a} = \frac{1}{N\sqrt{d}} [QK^\top, B_0, \dots, QK^\top, B_{N-1}] \quad (12)$$

根据 BCCB 矩阵的特性， B_k 实际上对应于二维空间中的空间位移。定义

$$\Delta h = \lfloor k/W \rfloor, \Delta w = k \bmod W. \quad (13)$$

然后我们有

$$\begin{aligned} a_k &= \frac{1}{N\sqrt{d}} \langle QK^\top, B_k \rangle \\ &= \frac{1}{N\sqrt{d}} \sum_{h=0}^{H-1} \sum_{w=0}^{W-1} \langle \hat{Q}_{h,w}, \hat{K}_{h+\Delta h, w+\Delta w} \rangle, \end{aligned} \quad (14)$$

其中 $\hat{Q}, \hat{K} \in \mathbb{R}^{H \times W \times d}$ 是通过圆形填充（用于处理边界条件）对 $Q, K \in \mathbb{R}^{N \times d}$ 进行二维重塑后的版本。可以观察到 a_k 是圆形交叉-

Q 与 K 之间的相关性结果，这正是深度学习中的卷积概念（参见第3节）。因此， $\mathbf{a}$ 可通过二维离散傅里叶变换（2D DFT）高效计算：

$$\begin{aligned} \mathbf{a} &= \frac{1}{N\sqrt{d}} \left[\mathcal{F}_{2D}^{-1} \left(\mathcal{F}_{2D}(Q) \odot \mathcal{F}_{2D}(K) \right) \right] \cdot \mathbf{1}_{d \times 1} \\ &= \frac{1}{N\sqrt{d}} (Q \otimes K) \cdot \mathbf{1}_{d \times 1}, \end{aligned} \quad (15)$$

其中 $\otimes$ 是我们在第3.3节中定义的基于DFT的矩阵乘法，且 $Q, K \in \mathbb{R}^{N \times d}$ ， $\mathbf{1}_{d \times 1} \in \mathbb{R}^{d \times 1}$ 是一个全1向量，对应于隐式求和。内积 d 大于 $Q_{h,w}$ 与 $\hat{K}_{h+\Delta h, w+\Delta w}$ 之间的内积在等式(14)中。

由于 $\tilde{A}$ 是一个 BCCB 矩阵且 ξ 是每行上的Softmax函数， $\xi(\tilde{A})$ 同样是一个 BCCB 矩阵，且 $\xi(\mathbf{a})$ 表示其第一行。如第3节所述，输出 $O = \xi(\tilde{A})V$ 因此可通过以下方式高效计算：

$$\begin{aligned} O &= \mathcal{F}_{2D}^{-1} \left(\mathcal{F}_{2D}(\sigma(\mathbf{a})) \odot \mathcal{F}_{2D}(V) \right) \\ &= \xi(\mathbf{a}) V. \end{aligned} \quad (16)$$

方法	计算资源 # 参数浮点运算次数			第1名
DeiT-T (Touvron等, 2021年)	224 ²	5.7M	1.2G	72.2
CA-DeiT-T	224 ²	6.1M	1.2G	75.0 (+2.8)
DeiT-S (Touvron等, 2021年)	224 ²	22.1M	4.6G	79.8
CA-DeiT-S	224 ²	23.8M	4.8G	81.0 (+1.2)
DeiT-B (Touvron等, 2021年)	224 ²	86.6M	17.6G	81.8
CA-DeiT-B	224 ²	93.6M	18.9G	82.3 (+0.5)
PVT-T (Wang等, 2021年)	224 ²	13.2M	1.9G	75.1
CA-PVT-T	224 ²	12.2M	2.0G	78.1 (+3.0)
PVT-S (Wang等, 2021年)	224 ²	24.5M	3.8G	79.8
CA-PVT-S	224 ²	22.8M	4.0G	81.7 (+1.9)
PVT-M (Wang等, 2021年)	224 ²	44.2M	6.7G	81.2
CA-PVT-M	224 ²	42.5M	6.8G	82.6 (+1.4)
PVT-L (Wang等, 2021年)	224 ²	61.4M	9.8G	81.7
CA-PVT-L	224 ²	58.6M	10.1G	82.9 (+1.2)
Swin-T (Liu等, 2021年)	224 ²	29M	4.5G	81.3
CA-Swin-T	224 ²	28M	4.6G	82.2 (+0.9)
Swin-S (Liu等, 2021年)	224 ²	50M	8.7G	83.0
CA-Swin-S	224 ²	50M	8.8G	83.6 (+0.6)
Swin-B (Liu等, 2021年)	224 ²	88M	15.4G	83.5
CA-Swin-B	224 ²	88M	15.7G	83.9 (+0.4)
Swin-B (Liu等, 2021年)	384 ²	88M	47.0G	84.5
CA-Swin-B	384 ²	88M	47.1G	85.1 (+0.6)

方法	计算资源 # 参数量	浮点运算次数	第1名
SLAB-T (Guo等, 2024年)	224 ²	29M 4.5G	81.8
VMamba-T (Liu等, 2024年)	224 ²	31M 4.9G	82.5
SOFT-S++ (Lu等, 2024年)	224 ²	27M 4.5G	82.6
PolaFormer-T (Meng等, 2025年)	224 ²	29M 4.5G	82.6
LocalVMamba-T (Huang等, 2024年)	224 ²	26M 5.7G	82.7
VVT-S (Sun等, 2023年)	224 ²	26M 5.6G	82.7
Agent-CSwin-T (Han等, 2024c)	224 ²	21M 4.3G	83.1
FasterViT-1 (Hatamizadeh等, 2024年)	224 ²	53M 5.3G	83.2
EfficientViT-B3 (Cai等, 2023年)	224 ²	49M 4.0G	83.5
CAT-T	224 ²	27M 4.3G	83.6
LocalVMamba-S (Huang等, 2024年)	224 ²	50M 11.4G	83.7
QFormer _h -S (Zhang等, 2024)	224 ²	51M 8.9G	84.0
BiFormer-B (Zhu等, 2023年)	224 ²	57M 9.8G	84.3
MILA-S (Han等, 2024b)	224 ²	43M 7.3G	84.4
TransXNet-B (Lou等, 2025年)	224 ²	48M 8.3G	84.6
CAT-S	224 ²	51M 7.9G	84.5
VMamba-B (Liu等, 2024年)	224 ²	89M 15.4G	83.9
InLine-Swin-B (Han等, 2024a)	224 ²	88M 15.4G	84.1
SOFT-L++ (Lu等, 2024年)	224 ²	85M 15.4G	84.1
FasterViT-3 (Hatamizadeh等, 2024年)	224 ²	160M 18.2G	84.9
OverLock-B (Lou和Yu 2025)	224 ²	95M 16.7G	85.1
CAT-B	224 ²	90M 15.2G	85.0

表2: ImageNet-1K数据集上与基线模型(左)及高级方法(右)的对比分析

图1展示了所提出的循环注意力范式。可以看出,我们的设计在结构上与标准自注意力机制相似,主要区别在于采用了BCCB注意力矩阵和基于DFT的高效乘法运算。

复杂度分析。基于高效计算算法,我们循环注意力机制的整体复杂度可表示为:

$$\begin{aligned} \mathfrak{h}(\text{CA}) = & \underbrace{2N(\log_2 N)d + 2Nd + N\log_2 N}_{\text{DFT、产品、等式(7)中的 IDFT}} + \\ & \underbrace{N(\log_2 N)(d+1) + 2Nd + N(\log_2 N)d}_{\text{DFT、产品、等式(8)中的 IDFT}} \quad (17) \end{aligned}$$

$$= N(\log_2 N)(4d+2) + 4Nd, \text{ 这比纯自注意力机制的计算复杂度高效得多:}$$

$$\mathfrak{h}(\text{SA}) = N^2 d + N^2 d = 2N^2 d. \quad (18)$$

令牌重加权模块。在标准自注意力机制中,原始注意力图 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 会应用逐行Softmax操作,确保每行总和为1。值得注意的是,该操作不会约束 $\mathcal{F}(\mathbf{A})$ 的列总和,导致某些键在不同查询中可能累积更高的总注意力分数。因此,不同查询会强调相似的键值组合,有助于模型区分更具信息量的令牌。然而,我们循环注意力图 $\mathcal{F}(\tilde{\mathbf{A}})$ 的块循环结构同时强制行总和与列总和均为1,从而限制了其突出显著令牌的能力。为此,我们引入了一种简单而有效的令牌重加权方法以优化设

计。具体实现方式有两种:预重加权

$$\mathbf{O} = \text{CirAttn}(\mathbf{Q}, \mathbf{K}, \mathbf{V} \odot \mathbf{T}), \quad (19)$$

以及重加权后

$$\mathbf{O} = \text{CirAttn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) \odot \mathbf{T}, \quad (20)$$

其中 $\mathbf{T} = \text{SiLU}(x\mathbf{W}_T) \in \mathbb{R}^{N \times d}$ 是输入依赖的标记重加权因子,CirAttn表示我们的循环注意力算子。

4.3 实施

我们的循环注意力机制作为插件模块,可应用于多种视觉Transformer模型。为验证效果,我们选取了三种代表性Transformer架构:DeiT(Touvron等人,2021)、PVT(Wang等人,2021)和Swin Transformer(Liu等人,2021)来实现该方法。这三种模型分别对应全局自注意力、稀疏注意力和局部注意力机制。通过将原始注意力模块替换为循环注意力模块,我们构建了实验模型。由于该方法具有 $N \log N$ 复杂度优势,可在早期阶段直接处理高分辨率特征图而无需承担高昂计算成本。因此对于Swin和PVT等分层模型,我们主要将注意力替换机制限制在前两个阶段。除基线改进外,我们还开发了名为循环注意力Transformer(CAT)的专用模型系列,用于与各类先进视觉Transformer进行对比。详细模型架构参见附录。

基于COCO数据集的Mask R-CNN目标检测方法									
脊梁骨	浮点运算次数	学校	AP ^b	AP ^b ₅₀	AP ^b ₇₅	AP ^m	AP ^m ₅₀	AP ^m ₇₅	
PVT-T	240G	1x	36.7	59.2	39.3	35.1	56.7	37.3	
CA-PVT-T	218G	1x	40.5	63.4	43.9	37.9	60.4	40.7	
PVT-S	305G	1x	40.4	62.9	43.8	37.8	60.1	40.3	
CA-PVT-S	269G	1x	44.2	66.9	48.3	40.7	63.9	43.7	
PVT-M	392G	1x	42.0	64.4	45.6	39.0	61.6	42.1	
CA-PVT-M	356G	1x	45.2	67.7	49.4	41.2	64.7	44.1	
PVT-L	494G	1x	42.9	65.0	46.6	39.5	61.9	42.5	
CA-PVT-L	444G	1x	46.3	68.8	50.8	41.9	65.4	45.0	
斯温-T	267G	1x	43.7	66.6	47.7	39.8	63.3	42.7	
CA-Swin-T	269G	1x	44.5	67.3	48.9	40.5	64.2	43.5	
猪-S	358G	1x	45.7	67.9	50.4	41.1	64.9	44.2	
CA-Swin-S	361G	1x	46.8	69.3	51.7	42.2	66.2	45.3	
猪B型流感病毒	503G	1x	46.9	-	-	42.3	-	-	
CA-Swin-B	507G	1x	47.5	70.1	52.2	42.8	66.8	45.9	
斯温-T	267G	3x	46.0	68.1	50.3	41.6	65.1	44.9	
CA-Swin-T	269G	3x	46.7	68.8	51.2	42.5	65.9	45.9	

表3: COCO数据集上的结果。浮点运算次数 (FLOPs) 的计算采用1280 × 800的输入分辨率。

5 实验

本节通过大量实验评估所提方法的有效性, 实验涵盖ImageNet分类任务 (Deng等, 2009)、COCO目标检测任务 (Lin等, 2014) 以及ADE20K语义分割任务 (Zhou等, 2019), 并同步提供可视化结果与分析报告。

5.1 ImageNet分类

ImageNet-1K (Deng等人, 2009) 数据集包含128万张训练图像和5万张验证图像, 涵盖1000个类别。为确保公平比较, 我们采用与基线模型相同的训练参数设置。具体而言, 模型从零开始训练300个周期, 使用AdamW优化器 (Loshchilov和Hutter, 2018), 采用余弦学习率衰减策略, 并在前20个周期进行线性预热。初始学习率设为 1×10^{-3} , 权重衰减率为0.05。数据增强与正则化策略包括RandAugment (Cubuk等人, 2020)、Mixup (Zhang等人, 2018)、CutMix (Yun等人, 2019) 以及随机擦除法 (Zhong等人, 2020)。

从表2左侧数据可以看出, 将三种代表性模型中的自注意力机制替换为循环注意力机制后, 性能均呈现持续提升趋势。例如, 循环注意力机制改进的DeiT模型 (CA-DeiT) 表现优于采用全局自注意力机制的基准模型DeiT (Touvron等人, 2021年)。这表明我们的方法不仅具有高效性优势, 还能有效促进视觉Transformer模型的学习过程。与稀疏注意力机制PVT (Wang等人, 2021年) 及局部注意力机制Swin Transformer (Liu等人, 2021年) 相比, 循环注意力机制展现出显著优势。我们的CA-PVT-S模型仅使用30%的参数数量和40%的浮点运算量, 其准确率已与PVT-L模型持平。这些结果证实循环注意力机制可作为自注意力机制的可靠替代方案。

表2右侧将我们的CAT模型与多种最先进的视觉Transformer及Mamba变体进行了对比。

ADE20K语义分割研究				
脊梁骨	方法	浮点运算次数	#参数	微损伤
PVT-T	S-FPN	158G	17M	35.7
CA-PVT-T	S-FPN	135G	16M	39.4
PVT-S	S-FPN	225G	28M	39.8
CA-PVT-S	S-FPN	187G	26M	42.3
PVT-M	S-FPN	315G	48M	41.6
CA-PVT-M	S-FPN	278G	46M	43.7
PVT-L	S-FPN	420G	65M	42.1
CA-PVT-L	S-FPN	369G	62M	44.2
斯温-T	UperNet	945G	60M	44.5
CA-Swin-T	UperNet	947G	59M	45.2
猪-S	UperNet	1038G	81M	47.6
CA-Swin-S	UperNet	1040G	80M	48.6

表4: 语义分割结果。浮点运算次数 (FLOPs) 是在分辨率512 × 2048的输入图像上对编码器和解码器进行计算得出。S-FPN 是SemanticFPN (Kirillov等人, 2019年) 模型的简称。




图4: 自注意力机制与所提出的循环注意力机制在以下指标上的对比: (a)浮点运算次数(FLOPs), (b)推理帧率(inference FPS), 以及(c、d)吞吐量-精度折衷关系。吞吐量测试基于RTX3090 GPU进行。

我们发现循环注意力机制比高度优化的方法能取得更优的结果, 这验证了本方法的优越性能。

5.2 目标检测

COCO (Lin等人, 2014) 目标检测与实例分割数据集包含11.8万张训练图像和5千张验证图像。我们沿用了基线模型的训练与测试策略, 结果如表3所示。循环注意力机制通过 $O(N \log N)$ 复杂度实现了高效的全局建模, 特别适用于高分辨率图像建模场景。值得注意的是, CA-PVT-S模型在1.3个框平均精度上超越了规模更大的PVT-L模型, 且所需的浮点运算量显著减少。相较于分类任务中CA-PVT-S与PVT-L模型达到相同准确率的情况, 这种性能优势更为突出。这些结果充分证明了本方法在高分辨率场景中的优越性。




图5: CA-DeiT模型中等效全局卷积核的示意图。

5.3 语义分割

ADE20K数据集（Zhou等人，2019年）是语义分割领域的权威基准集，包含2万张训练图像、2千张验证图像及150个语义类别。我们采用与基线模型相同的参数配置。与目标检测任务类似，表4结果表明循环注意力机制能持续提升PVT和Swin模型的性能表现。在计算成本和参数量相当或更优的情况下，我们观察到最大可达3.7%的平均交并比（mIoU）提升幅度。

5.4 分析与可视化

效率分析。得益于 $O(N \log N)$ 复杂度，我们的循环注意力机制相较于自注意力操作展现出显著的效率优势。如图4(a)所示，在 1536^2 图像分辨率下，CA-DeiT-T所需的浮点运算量减少了8×，凸显了其在高分辨率建模任务中的潜力。此外，这些理论节省直接转化为实际增益——图4(b)中我们的方法在 1536^2 分辨率下实现了7×的加速比。另外，图4(c, d)表明在默认ImageNet分辨率 224^2 下，我们的模型在吞吐量与精度之间取得了更优的平衡，推断速度提升高达1.5×的同时性能也得到改善。

可视化分析。如第3.3节所述，BCCB矩阵对应二维全局卷积运算。因此，等效全局卷积核的可视化与解释变得直观易懂。如图5所示，我们的模型可根据输入图像生成多种等效卷积核。例如，针对首张图像，模型可生成鸟形与线状卷积核（前两种）。此外还存在侧重空间模式的卷积核类型，包括局部特征、全局特征、半平面特征、条带状特征及十字形特征等。

5.5 消融研究

我们通过消融研究评估循环注意力设计中各组件的贡献度。实验在CA-DeiT框架下于ImageNet-1K数据集上进行。如表5所示，我们从DeiT基线模型开始，依次引入设计方案。单纯引入循环注意力仅导致可忽略的0.1%性能下降，表明BCCB模式适用于视觉Transformer且未牺牲表达能力。基于此，我们发现设计方案受

	浮点运算次数 # 参数		账户	差异
DeiT-S（Touvron等，2021年）	4.6G	22M	79.8	-1.2
+ 循环注意力	4.4G	22M	79.7	-1.3
+ 头尺寸 $d=1$	4.4G	22M	80.2	-0.8
令牌预重加权+	4.8G	24M	80.9	-0.1
票据后重估价	4.8G	24M	81.0	我们的
DeiT-S + Token重加权	5.0G	24M	80.0	-1.0

表5: 基于DeiT-S的关键设计消融分析

益于较小的头维度和更多头数量。将头维度 $d=1$ 设置可将准确率提升至80.2%，优于DeiT-S基线模型。这归因于循环注意力分数是 N 个查询-键对的总和（参见等式(14)），因此具有等效头维度 Nd ，当 $d=1$ 时仍足够大。此外，我们研究了等式(19)和等式(20)中定义两种标记重加权方法。两种设计均带来进一步提升，而重加权后方案效果略优。值得注意的是，标记重加权对DeiT-S基线模型的增益有限。本文采用重加权后处理作为默认方法，在DeiT-S数据集上实现了81.0%的准确率。这些结果证实了我们设计方案的有效性。

6 结论

本文揭示了视觉Transformer中一个有趣的模式：自注意力图常呈现近似块循环结构（含循环块BCCB）。这一发现直接启发我们设计了循环注意力机制——这种创新性注意力范式通过充分利用该固有模式，在保持表达能力的同时显著提升计算效率。通过分类任务、目标检测及语义分割等场景的大量实验验证，所提出的循环注意力机制展现出卓越性能，为视觉Transformer架构提供了高效且具有竞争力的自注意力替代方案。