

BinaryAttention: 面向视觉与扩散变换器的单比特 QK 注意力机制

肖超东^{1,2}、张正强^{1,2}、张磊^{1,2,†}

¹香港理工大学²OPPO研究所

chaodong.xiao@connect.polyu.hk, csizhang@comp.polyu.edu.hk

摘要

Transformer 模型已取得广泛且显著的成功，但其注意力模块的计算复杂度仍是视觉任务中的主要瓶颈。现有方法主要采用8位或4位量化技术来平衡效率与精度。本文通过理论论证指出，注意力机制的二值化处理能够保留本质相似性关系，并提出 **BinaryAttention**——一种快速精准实现1位量化注意力的有效方法。具体而言，我们在计算注意力时仅保留查询向量与键向量的符号信息，将浮点点积运算替换为位操作，显著降低计算成本。通过引入可学习偏置项缓解1位量化固有的信息损失，并实现端到端加速。为保持注意力精度，我们采用量化感知训练与自蒸馏技术，在确保符号对齐相似性的同时降低量化误差。在A100 GPU上，BinaryAttention的运算速度比FlashAttention2快2倍以上。在视觉Transformer和扩散Transformer基准测试中开展的大量实验表明，BinaryAttention不仅与全精度注意力机制表现相当，甚至更胜一筹，充分验证了其有效性。我们的研究为全精度注意力机制提供了高效且有效的替代方案，推动了低比特视觉与扩散Transformer技术的发展边界。相关代码和模型可访问 <https://github.com/EdwardChasel/BinaryAttention> 获取。

1. 引言

Transformer模型[74]在多个领域取得了重大突破，从自然语言处理[6, 11, 17, 26, 60, 71, 73]到视觉任务[10, 18, 30, 49, 56, 62, 68]，再到多模态基础模型[1, 41, 42, 48, 59, 75]，这主要得益于注意力机制的表达能力。尽管取得了显著进展，但这种成功也伴随着代价：标准注意力机制会随序列长度呈二次方增长，导致对计算资源的需求呈指数级上升。

[†] 通讯作者。本研究由PolyU-OPPO联合创新研究中心资助。




图1. 上图：FlashAttention2与BinaryAttention在视觉任务上的性能对比。下图：由BinaryAttention驱动的DiT-XL/2[56]生成的图像示例。

长上下文和高分辨率任务。为缓解这一瓶颈，大量研究[15, 22, 23, 58, 67, 70]致力于加速Transformer模型。这些方法可大致分为架构优化、模型量化和硬件优化三大类。

架构优化通过改进注意力机制来降低计算开销。线性注意力机制[2, 37, 76, 82, 84]用线性复杂度的核计算替代了二次点积运算。稀疏注意力机制[3, 21, 63, 69, 78, 85]将计算范围限定在选定的标记对子集内。最新状态空间模型[14, 23, 25]则采用递归数据依赖选择机制替代传统注意力机制。尽管这些方法效果显著，但在不同模型和任务场景中往往难以维持标准注意力机制的表达能力。

模型量化[9, 22, 36]是一种通过降低数值精度来加速训练与推理同时缩减内存占用的原理性方法。线性层的量化技术已得到深入研究[20, 31, 39, 44, 46, 50, 51, 79, 81]且相对成熟。相比之下，SageAttention[87–89]等近期研究则日益聚焦于注意力机制的量化。与线性层不同，由于注意力机制的动态特性和敏感的softmax归一化过程，其量化面临独特挑战。因此这些方法通常采用8位或4位表示-

为在效率与精度之间保持实际平衡，采用了多种数据类型（例如INT8、FP8、INT4和FP4）。然而，将精度进一步降低至4位以下水平（尤其是二进制表示形式）仍面临重大挑战，因为极端的信息丢失和优化稳定性问题会导致性能急剧下降。

硬件优化通过采用专用硬件设计和内核优化技术来加速Transformer模型的运行。诸如FlashAttention [13, 15, 65]等突破性技术，在不改变模型架构或牺牲精度的前提下，实现了GPU上的显著加速效果。尽管这些优化方案效果显著，但另一种替代方案则聚焦于极端低精度注意力计算。具体而言，采用二进制表示形式的矩阵乘法运算可在现代硬件上高效实现[35]。因此，开发高效且适配硬件的二进制注意力机制，已成为突破Transformer模型效率极限的关键需求。

本文从理论层面分析了注意力计算中二进制表示的可行性，并指出即使在二进制空间中也能保留本质相似性关系。基于这一发现，我们提出**Binary Attention**——一种新型量化方法，可实现快速精准的1位量化注意力机制。如图1所示，该方法在视觉处理和扩散变换器场景中展现出显著潜力：通过将注意力查询与键值量化为1位表示，将标准点积注意力分数转化为基于距离和方向的计算机制，仅需超高效的位级XNOR与popcount指令即可完成运算。虽然这能大幅降低计算成本，但若仅依赖二进制空间中的相似性特征，会导致注意力分布过度均匀或扁平化，因为原始标记的关键幅度信息会被忽略。为缓解这种平坦化效应，我们引入了可学习偏置项，该偏置项设计为高密度、位置敏感或上下文感知型，从而实现具有表达力和区分度的1位量化注意力机制。此外，我们设计了混合量化方案，对注意力权重和值进行8位精度量化，实现端到端加速。最后，针对1位量化带来的固有近似误差及分布偏移问题，我们采用量化感知训练（QAT）[36]与自蒸馏[34]技术，引导模型学习与全精度对应值高度相似的二进制表示。

通过将FlashAttention2[13]的硬件加速方法适配至BinaryAttention核心架构，我们在A100 GPU上实现了比FlashAttention2超过100%的推理加速效果。针对图像分类、目标检测、图像分割及图像生成等基础视觉任务，我们对BinaryAttention在视觉Transformer和扩散Transf-

ormer上的表现进行了全面评估。实验结果表明，BinaryAttention在图像处理任务中的表现始终达到甚至超越全精度注意力机制的对应方案。本研究为全精度注意力机制提供了高效且实用的替代方案，显著推动了视觉任务领域高效Transformer架构的研发进程。

2. 相关工作

注意力架构。针对Transformer中注意力机制的二次复杂度问题，学界已对注意力计算架构进行重大重构尝试，包括线性注意力[2, 37, 76, 82, 84]、稀疏注意力[3, 21, 63, 69, 78, 85]以及状态空间模型[14, 23, 25]。线性注意力通过重构注意力计算过程以实现线性复杂度。例如Katharopoulos等人提出的方案。[37]用精心设计的核函数替换了softmax操作。Wang等人[76]提出的Linformer采用了一种替代性设计，通过低秩矩阵分解近似注意力计算。Yang等人[82]基于门控delta规则的广义线性注意力机制，在保持线性复杂度的同时支持更具表现力的变体设计。稀疏注意力方法通过将交互作用限制在策略性选取的标记对上降低复杂度，常见设计包括滑动窗口[3, 63]、sink[69, 78]以及混合模式[21, 85]。近年来，状态空间模型（SSMs）[14, 23, 24, 54, 91]应运而生，通过高效的循环扫描过程替代传统注意力机制。以Mamba模型[14, 23]为例，研究证实SSMs能在保持线性复杂度的同时实现类Transformer性能。

量化技术。量化技术通过降低模型精度来实现加速，可分为两类：后训练量化（PTQ）[20, 46, 50, 87–89]无需重新训练即可最小化量化误差，以及量化感知训练（QAT）[31, 39, 44, 51, 79, 81]在训练或微调过程中模拟量化效应。Frantar等人。[20]提出了GPTQ，该方法通过利用二阶统计量对权重参数进行量化。Lin等人。[46]开发了AWQ，该方法通过根据激活分布确定通道级缩放因子来保护显著权重。已有多方法将量化技术专门应用于视觉Transformer的二进制空间[31, 39, 79]。最新研究将量化技术扩展至注意力机制的计算领域。Zhang等人。[89]引入了SageAttention模型，该模型采用基于块的INT8量化技术处理注意力查询与键值。SageAttention2[87]将查询与键值量化为INT4，并在FP8精度下计算注意力图及值。SageAttention3[88]进一步将注意力计算统一为FP4精度。

硬件优化。该策略通过释放硬件性能来提升效率。Lefaudoux等人

[40] 开发了xFormers模型，该模型通过定制化且内存高效的 CUDA 内核来优化注意力机制。Dao 等人。[15] 提出了IO感知分块注意力机制并开发了FlashAttention算法，实现了显著的加速效果。FlashAttention2[13]通过改进并行计算能力和线程束级分区策略进一步优化了该架构。FlashAttention3[65]则充分利用Hopper GPU架构的优势，采用异步通信机制与FP8张量核心进行协同运算。基于这些技术突破，SageAttention[87–89]将FlashAttention与低精度量化技术深度融合，最终实现了整体效率的大幅提升。

3. 前言

模型量化[22]旨在将网络模型的高比特（例如FP32）权重和激活值量化为低比特表示（例如INT8），以实现高效部署。一种简单方法是均匀量化，它将浮点值线性映射到离散的等级集合上。对于给定的全精度向量 $\mathbf{x} \in \mathbb{R}^d$ ，该过程可描述为： $\tilde{\mathbf{x}} = \lceil \mathbf{x}/s \rceil + z$ ， $\hat{\mathbf{x}} = s(\tilde{\mathbf{x}} - z)$ ，其中 $\tilde{\mathbf{x}}$ 为量化值， $\lceil \cdot \rceil$ 表示取整运算， s 为缩放因子， z 为零点， $\hat{\mathbf{x}}$ 表示近似原始 $\mathbf{x}$ 的反量化值。极端情况是二进制量化[57]，它将近似简化为 $\hat{\mathbf{x}} = \alpha \text{sign}(\mathbf{x})$ ，其中包含最优缩放因子 α 。该逐元素函数符号 $(\mathbf{x})$ 将非负值映射为1，其他值映射为-1。

注意力是Transformer架构的基石。给定长度为 N 的输入 $\mathbf{x} \in \mathbb{R}^{N \times d}$ ，单头softmax注意力[74]通过以下方式计算输出 $\mathbf{y} \in \mathbb{R}^{N \times d}$ ：

$$\mathbf{y}_i = \sum_{j=1}^N \left(\frac{\exp(\mathbf{q}_i^T \mathbf{k}_j / \sqrt{d})}{\sum_{j=1}^N \exp(\mathbf{q}_i^T \mathbf{k}_j / \sqrt{d})} \right) \mathbf{v}_j = \sum_{j=1}^N P_{ij} \mathbf{v}_j, \quad (1)$$

其中查询、键和值标记 $(\mathbf{q}_i, \mathbf{k}_j, \mathbf{v}_j \in \mathbb{R}^d)$ 通过使用可学习权重矩阵对 $\mathbf{x}$ 进行投影生成。 P_{ij} 是基于 $(\mathbf{q}_i, \mathbf{k}_j)$ 计算得到的注意力系数。

4. 二元注意

4.1. 二元注意力机制的理论动机

我们首先在标准注意力机制与二元注意力机制之间建立理论桥梁，以证明我们方法的可行性。如等式 (1) 所示，softmax注意力机制通过对数值进行加权求和来计算注意力值。注意力系数 P_{ij} 由查询词与关键词之间的点积相似度 $S_{ij} = \mathbf{q}_i^T \mathbf{k}_j$ 决定。这种相似度可以从两个互补的角度进行解读。

假设查询 $\mathbf{q}_i$ 和键 $\mathbf{k}_j$ 经过 L_2 归一化处理，这是常见的 QKNorm 方法[32]。令 $\|\mathbf{q}_i - \mathbf{k}_j\|_2^2 = \|\mathbf{q}_i\|_2^2 + \|\mathbf{k}_j\|_2^2 - 2\mathbf{q}_i^T \mathbf{k}_j$ ，注意力系数可表示为：

$$P_{ij} \propto \exp(-\|\mathbf{q}_i - \mathbf{k}_j\|_2^2 / \tau), \quad (2)$$

其中 τ 为缩放因子。该公式表明softmax注意力机制实际上在欧几里得空间中表现为基于距离的度量。另一种形式下，点积相似度可重写为 $\mathbf{q}_i^T \mathbf{k}_j = \|\mathbf{q}_i\|_2 \|\mathbf{k}_j\|_2 \cos \theta$ ，其中 θ 表示查询 $\mathbf{q}_i$ 与键 $\mathbf{k}_j$ 之间的夹角。通过 L_2 归一化处理，注意力系数因此与余弦相似度成正比，并由 τ 进行缩放：

$$P_{ij} \propto \exp(\cos \theta / \tau). \quad (3)$$

这表明注意力机制可解释为作用于方向相似性。

基于上述标准注意力机制的双重视角，我们探究这些关系是否能在对其进行1位量化时得以保留。我们将查询 $\mathbf{q}_i$ 和键 $\mathbf{k}_j$ 的二进制对应表示为 $\mathbf{s}_i = \text{sign}(\mathbf{q}_i)$ ， $\mathbf{t}_j = \text{sign}(\mathbf{k}_j) \in \{-1, 1\}^d$ 。此时点积相似度可直接通过汉明距离表示为 $S_{ij} = \mathbf{s}_i^T \mathbf{t}_j = d - 2 \|\mathbf{s}_i - \mathbf{t}_j\|_H$ ，其中汉明范数 $\|\mathbf{x}\|_H$ 定义为 $\mathbf{x}$ 的非零元素数量。因此注意力系数可表示为：

$$P_{ij} \propto \exp(-\|\mathbf{s}_i - \mathbf{t}_j\|_H / \tau). \quad (4)$$

这表明二进制注意力在汉明空间中作为基于距离的度量指标运作，反映了标准注意力中的欧几里得距离。除此之外，它还保留了方向相似性。由于二进制域中的点积 $\mathbf{s}_i^T \mathbf{t}_j$ 等于 $d \cos \theta$ ，注意力系数可等效表示为 $P_{ij} \propto \exp(\cos \theta / \tau)$ 。


尽管上述分析揭示了二元注意力机制与标准注意力机制在各自空间中的结构相似性，但统计层面存在更根本的关联。我们证明二元注意力机制能够保留原始查询与键的协方差结构，如下定理1所示。

定理 1. 考虑两个随机变量 $\mathbf{q}, \mathbf{k} \in \mathbb{R}^d$ 。假设 $\mathbf{z} = (\mathbf{q}^T, \mathbf{k}^T)^T \in \mathbb{R}^{2d}$ 是一个零均值高斯向量，其协方差矩阵为 Σ ，其中 $\Sigma = [\Sigma_{qq} \quad \Sigma_{qk} \quad \Sigma_{kq} \quad \Sigma_{kk}]$ 。Denote $D_q = \text{diag}(\Sigma_{qq})'$ ， $D_k = \text{diag}(\Sigma_{kk})$ 且 $\mathbf{C} = D_q^{-2} \Sigma_{qk} D_k^{-2}$ 。对于任意 $\mathbf{s} = \text{sign}(\mathbf{q})$ 和 $\mathbf{t} = \text{sign}(\mathbf{k})$ ，有：


$$\mathbb{E}[\mathbf{s} \mathbf{t}^T] = \frac{\arcsin \mathbf{C}}{\pi}.$$

证明。 证明详见补充文件。□定理1表明，由二元查询


与键形成的外积是原始值的一致估计量



(a) BinaryAttention的整体概述



(b) 标准注意



(c) 二元注意

图2. BinaryAttention模型概述与对比分析。(a) BinaryAttention的计算过程包含三个核心步骤：将查询向量和键向量转换为缩放二进制表示、应用偏置增强机制、以及对注意力系数和数值进行量化处理。子图(b)和(c)分别展示了标准注意力机制与我们提出的BinaryAttention模型的注意力图（上）及对应激活图（下），结果表明尽管采用1位量化技术，BinaryAttention仍能保持与标准注意力机制相当的表达能力。

协方差矩阵。关键在于，协方差矩阵与Gram矩阵具有相同的非零特征谱，后者包含查询向量与键向量之间的所有成对点积，从而决定了标准注意力机制的核心关系结构。定理1为二元注意力机制的性能提供了性能保证，确保了其表达能力。

4.2. 二元注意力机制的构建

我们现提出BinaryAttention，一种高效的1位qkattention方法。如图2(a)所示，BinaryAttention包含以下三个关键组件。

缩放二进制表示。标准注意力机制中的主要计算瓶颈在于查询向量与键向量之间的浮点矩阵乘法运算。为解决这一问题，我们采用高效的二进制替代方案来替代该昂贵运算。具体而言，我们首先通过缩放1位量化函数将查询向量 q_i 和键向量 k_j 量化为二进制值：

$$s_i = \mu_q \text{符号}(q_i), t_j = \mu_k \text{符号}(k_j), \quad (5)$$

其中 $\mu_q, \mu_k \in \mathbb{R}_{\geq 0}$ 分别表示沿标记轴和通道轴的查询与键的均值。点积相似度 S_{ij} 的计算方式为 $\mu_q \mu_k s_i^T t_j$ （二进制空间），该方法不仅在统计上与其全精度对应方法保持一致，还能通过利用位XNOR和位移指令实现极高效率。

偏差增强。虽然查询和键的1位量化在计算效率上具有优势，但会带来两个可能降低注意力机制性能的挑战：幅度信息的丢失以及注意力分数的分布偏移。二进制表示将不同尺度的数据投影到单位超球面上，导致原始全精度点积所捕捉的细微关系被削弱。因此，二进制空间中的softmax分布容易产生过于均匀的注意力系数，难以有效区分显著特征。为解决这一问题，我们引入如下偏置项：

$$S_{ij} = \mu_q \mu_k s_i^T t_j / \sqrt{d} + b_{ij}, \quad (6)$$

其中 $b_{ij} \in \mathbb{R}$ 表示可选偏置项，可根据不同应用场景和架构进行定制。例如，该偏置项可采用密集可学习矩阵结构，以提升二进制空间中点积相似度的秩值；亦可设计为位置敏感型或上下文感知型，从而显式建模空间结构特征及上下文特定先验信息。

偏置项作为一种校正机制，将上下文或结构信息重新引入注意力系数的计算过程，从而有效避免注意力分布的坍塌现象，使BinaryAttention能够捕捉视觉任务中至关重要的复杂长程依赖关系。

注意力系数与数值的量化。为实现整体注意力计算的加速，我们将低比特计算进一步扩展至注意力系数和数值计算（这两者主要受内存限制）。为此，BinaryAttention将二进制空间中的点积相似度与针对这两个组件定制的特定8位量化方案相结合。对于注意力系数 P_{ij} （其通过softmax操作自然约束在 $[0, 1]$ 范围内），我们采用静态比例为1/255的无符号8位量化；对于数值 v_j （通常呈现更复杂的统计分布且存在通道间异常值），我们采用通道级8位量化策略，比例为 δ_v 。量化过程及后续数值聚合公式如下：

$$\tilde{P}_{ij} = \lceil P_{ij} \times 255 \rceil, \tilde{v}_j = \lceil v_j / \delta_v \rceil, y_i = \sum_{j=1}^N \frac{\delta_v}{255} \tilde{P}_{ij} \tilde{v}_j \quad (7)$$

其中， $\tilde{P}_{ij}$ 和 $\tilde{v}_j$ 表示量化后的8位整数。

该设计在通过适当的缩放因子保持精度的同时，实现了高效的整数运算。

注。 BinaryAttention框架通过其三大核心组件，在计算效率与表征能力之间实现了平衡。缩放二进制表征支持硬件友好型计算，可选偏置项恢复判别能力，混合量化技术确保端到端加速效果。如图2(b)和2(c)所示，BinaryAttention生成的注意力图与激活图呈现出与标准注意力机制高度相似的模式特征，均聚焦于具有高相关性的相似区域。这种一致性表明，即使在极端1位量化条件下，BinaryAttention仍能保持标准注意力机制所具备的内容导向动态路由及长距离依赖建模能力。

4.3. 硬件感知实现

我们充分利用现代GPU硬件的性能优势来实现BinaryAttention算法，该算法在FlashAttention2[13]的基础原理之上进行了改进，并引入了专门优化方案。完整算法流程详见补充文件中的算法1。具体而言，我们采用NVIDIA 张量核心中的快速mma.s32.b1.s32 PTX 指令（算法1中称为‘BinaryMatmul’），用于二进制查询与键值之间的相似度计算。对于注意力系数与数值的乘法运算，我们采用mma.s32.u8.s8.s32指令（算法1中称为‘IntMatmul’），该指令专为混合精度8位矩阵运算进行优化。

我们的实现方案保留了FlashAttention2[13]的内存层次结构优化与块拼接策略，但针对二值化和低精度场景进行了专门适配。这种硬件感知设计通过注意力计算的极端量化技术，确保BinaryAttention能够实现显著的性能提升。

5. 实验结果

我们通过大量实验来评估BinaryAttention的效率与有效性。其主要竞争对手是FlashAttention2[13]和SageAttention[89]，它们与BinaryAttention具有相同的目标——即加速标准注意力机制的计算。虽然线性注意力[5, 7, 27, 28, 66, 83]和SSMs[54, 91]也能提升效率，但它们通过显著改变注意力计算架构来解决二次复杂度问题，这与我们的研究方向存在正交关系。此外，传统模型量化方法[45, 86]主要针对线性层而非注意力计算进行优化，因此也与我们的研究形成互补。

在后续实验中，我们以FlashAttention2作为基线模型来实现本方法。




图3. A100 GPU上的内核速度对比




图4. A100 GPU上的端到端吞吐量与加速比对比。采用ViT[18]模型。

5.1. 效率比较

两个矩阵乘法主导了标准注意力计算：查询与键之间的交互（ QK^T ）以及值的聚合（ PV ）。BinaryAttention的加速源于现代硬件上低精度算术运算的巨大吞吐量优势。具体而言，NVIDIA A100张量核心在FP16浮点运算中提供312 TFLOPs/s的理论吞吐量，在INT8整数运算中达到624 TFLOPs/s，二进制运算更高达4992 TOP/s。通过采用二进制表示实现 QK^T 并结合INT8量化实现 PV ，BinaryAttention在这类计算中分别实现了16×和2×的理论加速比，使得标准FP16注意力机制的整体理论性能提升达3.5×。

在实际应用中，加速性能受限于内存带宽和I/O限制。我们通过多种注意力机制实现对BinaryAttention的效率进行基准测试，包括Torch[55]、xFormers[40]、FlashAttention2[13]以及SageAttention[89]。图3展示了在A100 GPU上头维度为128时不同序列长度下的核速度对比。可以看出BinaryAttention始终优于所有竞争方法，具体而言，其速度分别比FlashAttention2快约2×、比SageAttention快约1.4×。

此外，我们对ViT[18]模型进行了端到端推理，并评估了对数标准吞吐量。

如图4所示，补丁尺寸为8。虽然我们的方法和SageAttention在低分辨率下由于量化开销导致速度略低于FlashAttention2，但BinaryAttention在高分辨率下显著优于所有方法，在 1024×1024 输入下较FlashAttention2实现1.5×的加速比，较SageAttention达到1.3×的加速比。这进一步证明我们的BinaryAttention与现代硬件兼容，能够实现更高效率。

5.2. 图像分类

设置。我们首先使用ImageNet-1K[16]评估图像分类任务。根据DeiT[72]的方法，我们开发了三种BinaryAttention变体，即-tiny（微型）、-small（小型）和-B（基础模型），通过将所有标准注意力模块替换为BinaryAttention模块实现。我们采用DeiT[72]中的实验设置，具体细节详见补充文件。模型采用自蒸馏[34]策略进行微调，其中全精度模型作为教师模型使用。

我们与基于量化的方法PTQ4ViT[86]（W8A8）、I-ViT[45]（W8A8）以及注意力量化方法SageAttention[89]进行对比。同时参考Linear Transformers[5, 7, 27, 28, 66, 83]和SSMs[54, 91]进行对比。遵循[31, 61]方法，我们分别统计二元运算（BOPs）和浮点运算（FLOPs），并将总运算量（OPs）表示为 $OPs = BOPs / 64 + FLOPs$ 。**结果。**表1展示了对比结果。BinaryAttention在多个维度上展现出持续的性能优势。相较于基线模型DeiT（采用FlashAttention2实现）和近期提出的SageAttention，BinaryAttention在降低计算成本的同时实现了更高的准确率。例如，BinaryAttention-T达到72.88%的top-1准确率，较DeiT-T提升0.68%，较SageAttention-T提升0.77%，且运算量更少。BinaryAttention-S与BinaryAttention-B在 224×224 分辨率下分别达到80.24%和82.04%的top-1准确率，较SageAttention分别提升0.42%和0.21%。值得注意的是，在更高分辨率 384×384 下，BinaryAttentionB在50.2G运算量下实现了83.64%的最高准确率，其性能优于DeiT-B（83.1%，55.4G运算量）和SageAttention-B（82.89%，53.2G运算量）。

与W8A8量化方法相比，BinaryAttention虽然需要更多运算单元（OPs），但能提供更优的精度。BinaryAttention-T需要1.1G OPs，高于PTQ4ViT-T（0.3G OPs），但精度显著提升（72.88% vs. 71.6%）。值得注意的是，BinaryAttention可与线性层量化技术无缝集成。当与PTQ4ViT结合使用时，BinaryAttention和SageAttention都能大幅降低运算需求，同时保持高精度。具体而言，BinaryAttention-B+PTQ4ViT仅需13.5G OPs即可实现83.55%的top-1精度，较SageAttention-B+PTQ4ViT多出0.57%，且运算量减少3G。

我们还将线性变换器（Linear Transformers）和结构

方法	Reso.	#Param.	OPs	第1名
Hydra-T [5]	224 ²	6M	1.1G	68.3
Efficient-T [66]	224 ²	6M	1.1G	70.2
DeiT [83]	224 ²	6M	1.1G	70.8
增强型T[7]	224 ²	6M	1.1G	72.9
Flatten-T [27]	224 ²	6M	1.1G	74.1
InLine-T [28]	224 ²	7M	1.1G	74.5
内联-S	288 ²	17M	5.0G	80.2
内联B型	448 ²	24M	17.2G	82.3
S4ND-ViT-B [54]	224 ²	89M	-	80.4
Vim-T [91]	224 ²	7M	1.5G	76.1
Vim-S	224 ²	26M	5.1G	80.3
Vim-B	224 ²	98M	18.9G	81.9
DeiT-T [72]	224 ²	6M	1.2G	72.2
脱铁素-S	224 ²	22M	4.6G	79.8
DeiT-B	224 ²	87M	17.6G	81.8
DeiT-B	384 ²	87M	55.4G	83.1
W8A8 量化				
PTQ4ViT-T [86]	224 ²	6M	0.3G	71.6
PTQ4ViT-S	224 ²	22M	1.2G	79.5
PTQ4ViT-B	224 ²	87M	4.5G	81.5
PTQ4ViT-B	384 ²	87M	14.2G	83.0
I-ViT-T [45]	224 ²	6M	0.3G	72.2
I-ViT-S	224 ²	22M	1.2G	80.1
I-ViT-B	224 ²	87M	4.5G	81.7
注意力量化				
SageAttention-T [89]	224 ²	6M	1.2G	72.11
+PTQ4ViT	224 ²	6M	0.4G	71.63
SageAttention-S + PTQ4ViT	224 ²	22M	4.5G	79.82
SageAttention-B+ PTQ4ViT	224 ²	22M	1.3G	79.38
SageAttention-B+ PTQ4ViT	224 ²	87M	17.3G	81.83
SageAttention-B+ PTQ4ViT	224 ²	87M	4.8G	81.58
SageAttention-B+ PTQ4ViT	384 ²	87M	53.2G	82.89
SageAttention-B+ PTQ4ViT	384 ²	87M	16.5G	82.98
BinaryAttention-T	224 ²	6M	1.1G	72.88
+PTQ4ViT	224 ²	6M	0.3G	72.61
BinaryAttention-S	224 ²	22M	4.3G	80.24
+PTQ4ViT	224 ²	22M	1.2G	79.81
BinaryAttention-B	224 ²	87M	17.0G	82.04
+PTQ4ViT	224 ²	87M	4.4G	81.91
BinaryAttention-B	384 ²	87M	50.2G	83.64
+PTQ4ViT	384 ²	87M	13.5G	83.55

表1. ImageNet-1K数据集上图像分类性能对比

化空间模型（SSMs）纳入对比分析以供参考。虽然Flatten-T、InLine-T和Vim-T在某些配置下能获得更高精度，但其扩展能力存在明显局限。InLine-S/B需要更大的输入规模，Vim-S/B则需显著增加参数量与运算量。相比之下，BinaryAttention无需架构调整即可保持稳定性能表现。

上述综合评估结果表明，BinaryAttention在保持标准注意力机制表达能力的同时，实现了显著的效率提升，充分彰显了其有效性。

(a) 掩码 R-CNN															
脊梁骨	AP ^b	AP ^b ₅₀	AP ^b ₇₅	AP ^b _s	AP ^b _m	AP ^b	AP ^m	AP ^m ₅₀	AP ^m ₇₅	AP ^m _s	AP ^m _m	AP ^m _l	#参数。	OPs	
脱铁素T	41.11	62.24	44.71	23.50	44.00	56.56	37.26	59.20	39.63	17.35	39.55	56.62	28M	338G	
SageAttention-T	41.10	62.21	44.65	23.52	44.02	56.43	37.26	59.23	39.62	17.39	39.57	56.61	28M	327G	
BinaryAttention-T	41.29	62.04	44.91	23.99	44.62	55.81	37.26	59.10	39.68	17.71	39.89	55.85	28M	313G	
脱铁素-S	45.49	67.29	49.10	28.91	48.56	61.57	40.87	63.90	43.57	21.95	43.56	60.89	44M	440G	
SageAttention-S	45.48	67.23	49.13	28.87	48.65	61.62	40.85	63.90	43.59	21.92	43.52	60.86	44M	418G	
BinaryAttention-S	45.86	67.29	49.77	30.03	49.16	61.72	41.01	64.10	43.68	22.39	43.71	60.34	44M	390G	
DeiT-B	47.99	69.46	52.07	31.59	51.11	64.04	42.98	66.48	46.29	23.82	45.64	61.85	111M	785G	
SageAttention-B	47.97	69.46	52.08	31.64	51.13	63.97	42.99	66.50	46.29	23.82	45.65	61.83	111M	742G	
BinaryAttention-B	48.28	69.98	52.58	31.96	51.68	63.44	43.24	66.75	46.44	24.60	46.10	61.03	111M	685G	

(b) 级联M 询问R-CNN															
脊梁骨	AP ^b	AP ^b ₅₀	AP ^b ₇₅	AP ^b _s	AP ^b _m	AP ^b	AP ^m	AP ^m ₅₀	AP ^m ₇₅	AP ^m _s	AP ^m _m	AP ^m _l	#参数。	OPs	
脱铁素T	46.39	64.58	50.11	27.05	50.03	63.71	39.90	61.75	42.91	19.37	42.75	59.73	58M	595G	
SageAttention-T	46.45	64.59	50.10	27.11	50.09	63.70	39.91	61.70	42.90	19.39	42.73	59.68	58M	584G	
BinaryAttention-T	46.64	64.79	50.37	28.07	50.24	63.14	40.12	62.00	43.05	20.54	42.94	59.46	58M	570G	
脱铁素-S	49.44	68.10	53.16	32.01	53.20	65.18	42.52	65.12	45.90	23.32	45.40	60.89	75M	696G	
SageAttention-S	49.46	68.16	53.20	32.07	53.22	65.14	42.51	65.13	45.93	23.41	45.38	60.88	75M	675G	
BinaryAttention-S	49.63	68.00	53.65	32.83	53.00	65.70	42.72	65.42	46.09	23.80	45.23	61.37	75M	647G	
DeiT-B	50.21	68.63	54.53	33.29	53.43	65.56	43.49	66.25	47.05	24.69	46.03	61.05	141M	1041G	
SageAttention-B	50.20	68.62	54.55	33.29	53.39	65.58	43.48	66.27	47.06	24.55	45.98	61.06	141M	999G	
BinaryAttention-B	50.16	68.80	54.09	32.90	53.31	66.26	43.49	66.28	47.15	24.28	46.17	62.23	141M	941G	

表2. COCO数据集上目标检测与实例分割的对比分析。目标检测结果（OPs）的计算采用1024 × 1024的输入分辨率。

脊梁骨	裁剪大小	微损伤 (SS)	微损伤 (MS)	#参数。	OPs
脱铁素T	512 ²	39.82	40.68	11M	227G
SageAttention-T	512 ²	39.82	40.68	11M	198G
BinaryAttention-T	512 ²	39.93	40.89	11M	159G
脱铁素-S	512 ²	44.67	46.01	43M	744G
SageAttention-S	512 ²	44.67	46.01	43M	687G
BinaryAttention-S	512 ²	44.75	45.95	43M	610G
DeiT-B	512 ²	46.86	47.74	166M	2654G
SageAttention-B	512 ²	46.86	47.74	166M	2539G
BinaryAttention-B	512 ²	47.76	48.37	166M	2384G

表3. ADE20K数据集上语义分割性能对比。‘SS’与‘MS’分别代表单尺度测试与多尺度测试。操作点（OPs）的计算采用512 × 2048的输入分辨率。

5.3. 目标检测与实例分割

设置。随后我们使用COCO 2017数据集[47]和Detectron2 [77]库评估目标检测与实例分割任务。Following ViTDet [43]，我们采用 Mask RCNN[29]和Cascade Mask R-CNN [8]作为检测器头，并以ImageNet-1K预训练的 BinaryAttention-T/S/B作为骨干网络。训练过程中采用AdamW优化器，beta参数设为(0.9,0.999)，动量值为0.9，批量大小为64。初始学习率设为0.001，权重衰减率为0.1，采用线性学习率衰减策略并进行250次预热迭代。

结果。结果详见表2。BinaryAttention在较低计算成本下展现出竞争力。对于Mask R-CNN头部，BinaryAttention-T在掩码mAP为37.26时比DeiT-T获得0.18更高的box mAP，同时与DeiT-T相比减少25G操作量，与SageAttention-T相比减少14G操作量。BinaryAttention-S在box mAP上优于DeiT-S 0.37，在掩码mAP上优于DeiT-S 0.14，对小尺寸目标具有显著提升效果（小box mAP从28.87提升至30.03）。BinaryAttention-B保持对DeiT-B的优越性能，但在大尺寸目标上表现略逊一筹。Cascade Mask R-CNN头部也呈现类似趋势。BinaryAttention-T和-相较于其DeiT对照组，持续获得稳定收益。S模型达到了49.63的盒子平均精度（box mAP）和42.72的掩码平均精度（mask mAP）。此外，BinaryAttention-B在准确率与效率之间实现了更优的平衡，其全精度版本在操作数（OPs）减少10%的情况下仍能保持同等性能。

5.4. 语义分割

设置。我们进一步在ADE20K[90]和MMSegmentation[12]数据集上评估BinaryAttention在语义分割中的表现。遵循[19]的方法，我们采用广泛使用的UPerNet[80]作为分割器，并使用预训练模型作为骨干网络。模型以32的批量大小进行60K次迭代训练，采用AdamW优化器（权重衰减率为0.01），初始学习率为 6×10^{-5} 并采用线性学习率衰减策略，训练前进行1500次预热迭代。

结果。如表3所示，BinaryAttention实现了im-

方法	OPs	步骤	FID↓	sFID↓	IS↑	Pre.↑	Re.↑	FID↓	sFID↓	IS↑	Pre.↑	Re.↑
(cfg=1.25) FlashAttention2			DiT-S/2					SiT-S/2				
		400K	54.73	10.21	26.83	0.42	0.57	46.33	7.89	31.99	0.46	0.59
6.1G SageAttention	5.8G	400K	54.74	10.21	26.86	0.42	0.57	46.32	7.89	32.00	0.46	0.59
二元注意	5.5G	200K	49.76	10.40	30.14	0.45	0.57	41.40	7.99	36.49	0.48	0.59
(cfg=1.50) FlashAttention2			DiT-S/2					SiT-S/2				
		400K	43.87	8.82	35.16	0.48	0.55	36.26	7.09	42.24	0.52	0.56
6.1G SageAttention	5.8G	400K	43.90	8.82	35.19	0.48	0.55	36.25	7.09	42.25	0.52	0.56
二元注意	5.5G	200K	38.96	8.95	40.12	0.50	0.56	31.18	7.12	50.54	0.55	0.56
(cfg=1.25) FlashAttention2			DiT-XL/2					SiT-XL/2				
118.6G SageAttention	117.1	7000K	3.22	5.28	201.77	0.76	0.62	3.62	5.23	193.51	0.75	0.64
G		7000K	3.24	5.29	201.72	0.76	0.62	3.68	5.25	191.57	0.75	0.64
BinaryAttention	115.0G	4000K	4.26	6.33	199.59	0.72	0.65	4.22	5.74	191.57	0.74	0.65
(cfg=1.50) FlashAttention2			DiT-XL/2					SiT-XL/2				
118.6G SageAttention	117.1	7000K	2.27	4.60	278.24	0.83	0.57	2.15	4.60	258.09	0.81	0.60
G		7000K	2.27	4.59	278.03	0.83	0.58	2.16	4.63	256.07	0.80	0.61
BinaryAttention	115.0G	4000K	2.19	5.01	278.03	0.80	0.61	2.21	4.89	250.02	0.79	0.61

表4. ImageNet 256 × 256数据集上基于类别条件的图像生成对比



图5. DiT-XL/2（配置参数=1.50）采用FlashAttention2与BinaryAttention生成图像的定性对比。

在语义分割任务中展现出卓越的性能表现。例如，BinaryAttention-T模型仅需更少的操作步骤（OPs），即可实现单尺度mIoU值39.93和多尺度mIoU值40.89，分别比DeiT-T模型高出0.11和0.21 mIoU。BinaryAttention-S在单尺度mIoU指标上略优于DeiT-S，而在多尺度测试中与基线模型表现几乎持平。BinaryAttention-B则实现了显著提升，单尺度mIoU值达47.76，多尺度mIoU值为48.37，分别超越DeiT-B模型0.90和0.63 mIoU，同时将计算成本降低270G操作步骤。这些结果证实，BinaryAttention在保持语义分割关键细粒度细节的同时，展现出对复杂场景理解的卓越能力。

5.5. 图像生成

设置。最后，我们探讨BinaryAttention在类别条件图像生成任务中的适用性。基于扩散变换器（DiT）[56]和可扩展插值变换器（SiT）[52]，我们将它们的标准注意力模块替换为我们的BinaryAttention。所有模型均在ImageNet数据集上以256 × 256图像分辨率进行训练，

小型模型使用20万次迭代，XL变体使用4000万次迭代，采用原始训练配置且未调整任何超参数。模型初始化时使用预训练的DiT和SiT模型。评估阶段通过250次采样步骤生成5万张图像，其中DiT采用DDPM调度器，SiT使用ODE求解器。ε嵌入距离（FID）[33]、滑动FID（sFID）[53]、嵌入分数（IS）[64]以及精确率与召回率[38]用于评估生成性能。

结果。结果汇总于表4。对于DiT-S/2和SiT-S/2模型，BinaryAttention在运算量更少的情况下，相较于FlashAttention2和SageAttention展现出显著提升。在40万步训练时，其不同无分类器引导（cfg）尺度下的FID值较基线模型大幅降低，同时保持更高的IS值和精确度。针对XL模型，当使用较小cfg尺度时（4000万步训练），BinaryAttention性能略有下降；但采用更高cfg值（1.50）时，其表现可与FlashAttention2和SageAttention持平甚至超越，DiT-XL/2模型的FID值最低达到2.19。图5的定性对比进一步表明，BinaryAttention生成图像质量与全精度模型相当，输出图像细节丰富且结构一致。

5.6. 消融研究

我们首先通过一系列消融实验来分析BinaryAttention的核心组件，包括缩放二值表示、偏差增强以及自蒸馏策略。实验在ImageNet-1K[16]基准数据集上使用DeiT[72]架构进行，结果汇总于表5。

缩放二进制表示法。我们评估了缩放因子在二进制表示中的作用。当缩放不

尺度偏差蒸馏			DeiT-T DeiT-S DeiT-B Top-1 准确率		
基线值（全精度）			72.2	79.8	81.8
✗	✗	✗	71.95	79.59	81.10
✓	✗	✗	72.42	79.81	81.33
✓	✗	✓	72.44	79.97	81.99
✓	✓	✓	72.88	80.24	82.04

表5. 基于DeiT架构在ImageNet-1K基准数据集上对BinaryAttention进行消融研究，涉及缩放二值表示、偏差增强及自蒸馏策略。

	CosSim相对L1 RMSE 精度			
图层 (0)	0.9186	0.4840	0.4165	0.7716
第6层	0.8740	0.7353	0.5084	0.7301

表6. DeiT-B模型在ImageNet-1K验证集上FlashAttention2与BinaryAttention注意力模式的对比分析

在实际应用中，BinaryAttention方法会导致所有模型性能下降：DeiT-T、-S和-B模型的top-1准确率分别下降0.25%、0.21%和0.70%。通过引入缩放因子可有效解决这一问题，该方法通过最小化量化误差实现性能提升，其中DeiT-T模型甚至超越了其全精度基线（72.42% vs. 72.2%），这表明在二进制空间中保持表征能力的关键在于采用恰当的缩放策略。

偏差增强。我们采用可学习的相对位置偏差[49]作为偏置项，该方法在不同模型规模下展现出显著效果：对DeiT-T和DeiT-S模型分别提升准确率0.44%和0.27%，对DeiT-B模型则实现小幅提升（从81.99%增至82.04%）。这种差异源于模型容量与二值表示表达能力之间的内在关联——小模型因维度限制导致注意力模式多样性不足，更容易出现分布坍塌现象；偏置项通过引入上下文或结构信息有效缓解了这一问题。而大模型由于高维二值表示天然保留了更丰富的相似性结构，因此提升幅度相对有限。

自身蒸馏策略。我们研究了自身蒸馏的作用：该策略虽对DeiT-T和DeiT-S模型仅有小幅提升，却使DeiT-B模型的准确率显著提高0.66%。这一改进表明，自身蒸馏能有效抵消量化误差导致的分布偏移，同时促进二进制表示与其全精度对应模型之间的符号对齐相似性。

注意力模式保真度。我们进一步分析BinaryAttention是否保留了原始注意力动态特征。采用余弦相似度、相对L1距离、RMSE和精确度作为评估指标，其中精确度用于衡量匹配前100个最受关注标记的准确性。如表

方法	第1名	备忘录（512）	备忘录（1024）
FlashAttention2	72.2	1705M	5304M
Sage注意力	72.11	1705M	5304M
BinaryAttention (den.)	72.88	3246M	29904M
BinaryAttention (dec.)	72.97	1706M	5307M

表7. DeiT-T在512和1024分辨率下采用FlashAttention2、SageAttention及BinaryAttention进行的记忆力对比分析

FlashAttention2	SageAttention	BinaryAttention	篙 Q&K	篙 V
175.3毫秒	124.6毫秒	88.2毫秒	2.8ms	1.9ms

表8. 在A100 GPU上测量的注意力核与量化组件的延迟时间。

6所示，BinaryAttention在ImageNet-1K验证集上与全精度注意力机制保持高度一致性，余弦相似度超过0.87且精确度约0.75，这表明BinaryAttention能有效保留关键关系模式与结构关联特征。

内存占用与量化开销。最后，我们在表7中报告内存占用情况，在表8中展示量化开销。BinaryAttention主要因偏置项导致额外内存消耗：当采用密集偏置时，内存占用随分辨率快速增加；而采用可分解偏置（例如空间方向求和运算）时，开销几乎可忽略不计。量化成本相对较低，查询与键操作耗时2.8毫秒，值操作耗时1.9毫秒（总耗时4.7毫秒），约占BinaryAttention核函数的5%。

6. 结论

我们提出了BinaryAttention——一种简单却精准高效的1位量化注意力机制，专为视觉任务和扩散变换器设计。通过建立理论保证确保二进制空间中标记相似性得以保留，我们在标准注意力机制中融入了缩放二进制表示、偏差增强和混合量化技术，相较FlashAttention2实现了2×的加速比。在图像分类、检测、分割及生成等任务的大量实验中，BinaryAttention仅使用1位表示即可达到与全精度注意力机制相当甚至更优的性能，充分证明其在实际视觉任务中实现超低精度推理部署的潜力，且不会影响整体性能表现。

局限性。尽管在计算 QK^T 相似度方面实现了显著加速，但 PV 乘法运算采用了更为保守的量化方式，仍有提升端到端效率的空间。此外，当前方法主要聚焦于优化注意力计算，未来可进一步探索联合量化MLP层等其他组件的互补潜力。