


核心速览



(b) Standard Attention



(c) Binary Attention

论文题目: BinaryAttention: One-Bit QK-Attention for Vision and Diffusion Transformers

中文题目: BinaryAttention: 用于视觉和扩散变换器的单比特 QK-注意力机制

论文链接: <https://arxiv.org/pdf/2603.09582v1>

所属单位: 1 香港理工大学, 2 OPPO 研究院

核心速览:

本文提出 BinaryAttention, 一种 1 位 QK 注意力方法, 通过将查询和键量化为 1 位表示, 用位运算替代浮点积计算, 并结合可学习偏置、量化感知训练和自蒸馏技术, 在 A100 GPU 上实现比 FlashAttention2 快 2 倍以上的推理速度, 同时在视觉 Transformer 和扩散 Transformer 的图像分类、检测、分割及生成任务中, 性能匹配甚至超过全精度注意力, 为低比特 Transformer 提供了高效解决方案。

https://mp.weixin.qq.com/s/Frp_VR19LxfSPEEajQYwdg

```
BinaryAttention(  
  (qkv): Linear(in_features=64, out_features=192, bias=False)  
  (attn_drop): Dropout(p=0.0, inplace=False)  
  (proj): Linear(in_features=64, out_features=64, bias=True)  
  (proj_drop): Dropout(p=0.0, inplace=False)  
)  
input_tensor_shape : torch.Size([1, 1024, 64])  
output_tensor_shape : torch.Size([1, 1024, 64])
```

哔哩哔哩/微信公众号: AI缝合术, 独家整理!