

# 自注意力机制及其无限延伸：迈向具有无限自注意力的线性变换器

Giorgio Roffo<sup>1</sup> 以及 卢克·帕尔默<sup>2</sup>

<sup>1</sup> Equixly API 安全性

giorgio.roffo@equixly.com

<sup>2</sup> GlimpseML, 英国伦敦

**摘要。** softmax 注意力机制的二次成本限制了 Transformer 在高分辨率视觉任务中的可扩展性。我们提出 *无限自注意力* (InfSA) ——一种谱重构方法，将每个注意力层视为内容自适应标记图上的扩散步骤，通过注意力矩阵上的折扣 Neumann 级数累积多跳交互作用。该框架将自注意力与经典图中心性度量 (Katz、PageRank 和特征向量中心性) 相结合，生成可解释且结构基础的标记权重。进一步研究表明，该 Neumann 核与吸收马尔可夫链的基本矩阵 [30, 44] 一致，将每个标记的中心性得分与其在吸收前的随机游走期望访问次数相关联。基于此，我们提出 *线性 InfSA* ——一种  $O(N)$  变体，无需构建  $N \times N$  矩阵即可近似隐式注意力算子的主特征向量。它维持一个固定大小的辅助状态  $O(d_h)$ ，其中  $d_h$  是每头维度，与序列长度  $N$  无关——可与标准 Vision Transformers 实现无缝集成，并支持在  $4096^2$  分辨率下进行稳定的前向和后向传递，在  $9216^2$  分辨率下进行推理 (约 332k token)。集成到 4 层 ViT 中

5350 万参数和 59 GFLOPs 在  $224^2$  上，Linear-InfSA 在 ImageNet-1K 上达到 84.7% 的 top-1 精度，相较于采用相同训练方案的标准 4 层 ViT 基线模型 (81.5%) 实现了 +3.2 个百分点的纯架构性能提升。在 ImageNet-V2 上，所有 InfViT 变体均超越所有对比基线模型 (最高达 79.8% vs. 最佳先验方法的 76.8%)，表明其在分布偏移下具有稳健的泛化能力。注意力质量评估证实了语义导向的注意力图：MoRF-AOC 达到 76.0% 的准确率和 76.1% 的边界框 PR-AUC，而 softmax ViT 分别仅达到 42.6% 和 56.2%。在 A100 40GB GPU 上的可扩展性基准测试中，Linear-InfViT 以 0.87 J/img 的能耗实现 231 img/s 的吞吐量——相较于同等深度的标准 ViT 模型，吞吐量和能耗均提升 13 $\times$ ，且是唯一在完成  $9216^2$  推理时未出现内存耗尽的测试模型。线性近似方法能精确恢复完整二次算子的主导特征向量 (余弦相似度 0.985)。代码可在: [huggingface.co/groffo/infinite-self-attention](https://huggingface.co/groffo/infinite-self-attention) 获取。

**关键词：** 图扩散注意力机制 · 吸收马尔可夫链 · 线性复杂度视觉变换器 · 特征向量中心性 · 可解释注意力图

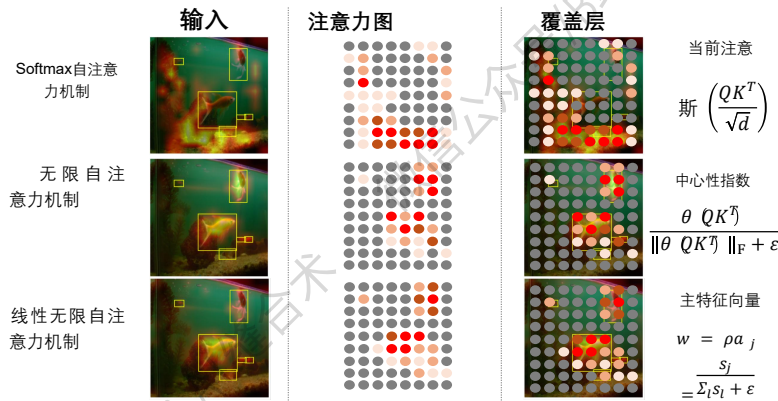


图1：注意力图对比。ImageNet数据集上ViT-L/16模型注意力图的可视化结果。Softmax注意力机制将焦点分散至背景区域，而InfSA变体则能生成更锐利且与目标物体对齐的激活特征。

## 1 引言

Transformer架构是现代视觉[12, 35, 41]与语言模型[6, 53, 55]的基础，但其二次注意力成本限制了在高分辨率和长上下文场景中的可扩展性[9, 56]。这促使了众多高效注意力机制的出现[2, 11, 57, 61]。这一计算瓶颈还带来了环境成本：预计到2030年数据中心能耗将增长近一倍[28, 54]，而二次注意力机制主导了Transformer的能耗预算[50]。

尽管取得了进展，但大多数高效变体在缺乏令牌交互原理模型的情况下，仅对注意力矩阵进行近似处理或稀疏化处理。标准Transformer模型通过隐式聚合堆叠层间的依赖关系，对多跳影响或可解释性控制能力有限。实证分析进一步表明，注意力权重可能会突出扩散性或语义无关区域[1, 8]。图论框架提供了更结构化的视角：扩散过程通过Katz中心性[29]、PageRank[3, 39]和特征向量中心性[5]等中心性度量量化节点影响力，从而实现显式多跳推理与结构可解释性——但此类原理在Transformer架构中仍待深入探索。值得注意的是，Rofo等人已建立了加权图上的无限路径聚合与吸收马尔可夫链之间的关联。[44]，证明了次随机游走的基本矩阵会产生与中心性评分相同的Neumann核 $N = (I - \gamma A)^{-1}$ ，其中元素 $N_{ij}$ 等于从节点 $i$ 出发时在节点 $j$ 处达到吸收状态前的预期访问次数。

我们提出无限自注意力机制 (InfSA)，这是一种基于谱扩散视角的注意力机制，通过截断的诺伊曼级数构造实现跨层信息聚合，类似于Katz/PageRank评分中使用的无限路径核[44, 45]。该诺伊曼核可被解释为吸收马尔可夫链[30, 44]：标记表示注意力网络上随机游走的瞬态状态。

图中，它们的中心性分数对应于扩散终止前的预期访问次数。我们还开发了 *Linear-InfSA*，这是一种可扩展的  $O(N)$  变体，通过  $\mathbf{A}^{k \rightarrow \infty}$  特征向量极限近似主导注意力方向（见图1）。集成到 Vision Transformers 中时，InfSA 可实现强大的 ImageNet-1K/V2 精度、更锐利且更局部化的注意力图，并稳定扩展至 4K–9K 输入规模；推导过程详见补充材料。

#### 贡献

- 我们将注意力传播与特征向量动力学及非线性 Perron–Frobenius 理论相结合，从而为全局标记影响提供了理论框架。
- 我们提出 *InfSA*——一种通过图扩散与诺伊曼级数路径积分实现自注意力机制的谱泛化方法，并证明所得注意力图具有吸收马尔可夫链解释：其中标记中心性等于吸收前的期望随机游走访问次数。
- 我们提出 *Linear-InfSA*，一种  $O(N)$  近似方法，无需构建注意力矩阵，并采用固定大小的  $O(d)$  辅助状态（与  $N$  无关），从而实现对高分辨率的稳定扩展。
- 视觉任务实验验证了可解释性、鲁棒性及可扩展性；InfSA 为高效人工智能架构奠定了概念基础。

本文其余部分结构安排如下：第2节综述了高效注意力机制、图中心性及状态空间模型的相关研究；第3节从路径积分视角推导 Pure InfSA 及其吸收马尔可夫链解释，并引入 Linear-InfSA；第4节评估了可扩展性、注意力质量及分类性能；第5节进行总结。

## 2 相关工作

**高效注意力机制。**softmax 注意力机制的二次成本推动了多种二次替代方案的出现：Linformer[57]将键映射至固定秩；Performer[9]采用核随机特征；SOFT[36]应用无 softmax 核函数；FLatten[20]在聚焦线性注意力中恢复秩；Agent Attention[22]通过代理标记桥接 softmax 与线性注意力；MLLA[21]将 Mamba 式门控重构为线性注意力；Fastformer[60]用加法池化替代成对注意力；FlashAttention[10, 11]通过融合核优化 softmax 但保持  $O(N^2)$  计算量。所有方法均近似处理或稀疏化注意力矩阵而未建模多跳标记影响。我们的 Linear-InfSA 在  $O(N)$  时间复杂度下计算标记中心性，其状态复杂度为  $O(d)$  且与  $N$  无关，同时保持与 ViT 模块的即插即用兼容性。

**图中心性与马尔可夫解释。**关注机制已被关联到图推理[46, 59]，但鲜有研究对显式标记扩散进行建模。我们将注意力机制形式化为内容自适应亲和图，并将其与 Katz 中心性[29]、PageRank[3, 39]及无限特征选择 (Inf-FS) [44, 45]相连接，其中 Neumann 核与吸收马尔可夫链的基本矩阵一致[30]。TokenRank[13]独立地将注意力解释为

一个马尔可夫链，用于计算闭链的平稳分布； $\text{InfSA}$ 则计算吸收链的基本矩阵 $N=(I-\gamma A)^{-1}$ ——该矩阵编码的是预期访问次数而非稳态概率。在可解释性方面，注意力展开[1]、注意力流[8]和扰动显著性[17]通过启发式方式传播相关性，而MoRF/LeRF[47]则通过掩码评估忠实度。 $\text{InfSA}$ 将中心性直接嵌入机制中，实现了注意力机制、扩散机制和归因机制的统一。

**状态空间与卷积模型。**诸如Mamba[19]和 RWKV[40]等状态空间模型，连同视觉适配模型MambaVision[23]和HyenaPixel[49]，通过递归或长卷积实现次二次建模，但未能从图中心性中推导出标记重要性； $\text{InfSA}$ 的谱公式具有互补性。

### 3 无限自注意力机制 (InfSA)

**无限自注意力 (InfSA)** 通过基于谱分析和路径解释的标记交互建模多跳依赖关系，对Transformer自注意力[12]进行泛化，其灵感源自无限特征选择 (Inf-FS) [44, 45]。该方法将注意力机制与经典图扩散和排序算法（如Katz、PageRank [29, 39]）相结合，并融入了近期关于注意力机制的谱分析视角[44, 46, 51, 52]。我们推导出与标准Transformer模块兼容的分层公式，并提出可扩展的 $\text{Linear-InfSA}$ 变体——该变体在保留ViT残差结构[12]的同时，绕过了 $N \times N$ 注意力矩阵 $O(N)$ 的复杂度。

#### 3.1 注意力图

我们将自注意力[12, 55]解释为在全连接内容自适应图 $G=(V, E)$ 上的扩散过程，其中每个标记为节点，每条边 $(i, j)$ 具有由注意力分数导出的权重 $A_{ij} \geq 0$ 。设 $A \in \mathbb{R}^{N \times N}$ 表示注意力矩阵， $V \in \mathbb{R}^{N \times d}$ 表示值矩阵。自注意力更新是一个扩散步骤：

$$Y = AV, \quad (1)$$

其中每个输出标记会聚合所有其他标记的值，并通过注意力机制进行加权[7, 59]。当 $A$ 为行随机矩阵（ $A\mathbf{1}=\mathbf{1}$ ）时，这相当于对 $G$ 进行的随机游走算子[38]。将 $A$ 视为亲和矩阵，可将注意力机制与中心性度量指标（如PageRank[3]、Katz [29]、特征向量中心性）以及InfFS[44, 45]相关联——后者通过加权图结构重要性对特征进行排序（见图1）。

#### 3.2 无限自注意力机制 (InfSA)：注意力图上的路径积分

我们通过提出**无限自注意力 (InfSA)**<sup>3</sup>扩展了注意力图视角，该框架灵感来源于无限路径积分方法。

<sup>3</sup> 术语“**Infinite**”指的是极限诺伊曼级数，即， $\lim_{L \rightarrow \infty} \sum_{t=0}^L \gamma^t A^t$ 以及特征向量极限 $v = \lim_{k \rightarrow \infty} A^k x$ 。 $0 \ll A^k x_0 \ll 1$ 。注意：实际计算-

由Rofo等人提出。[44,45]该方法通过聚合特征亲和图上所有路径的权重对特征进行排序，累加矩阵幂 $A+A^2+\dots$ ，并通过 $(I-rA)^{-1}-I$ 闭合级数。我们将此构造映射到自注意力机制：标记替换特征，注意力矩阵替代特征亲和矩阵，最终得到的无限路径得分即为标记中心性。

**令牌图上的路径。**设 $\pi=(v_0=i, v_1, \dots, v_{t-1}, v_t=j)$ 表示注意力图 $G$ 中从令牌 $i$ 到令牌 $j$ 的长度为 $t$ 的路径。路径权重是边上注意力权重的乘积：

$$w(\pi) = \prod_{k=0}^{t-1} A(v_k, v_{k+1}). \quad (2)$$

该产品用于测量路径上的累积亲和力：当所有连续标记项彼此相关时，其值较高。

**对所有固定长度路径的聚合。**设 $\pi_{ij}^t$ 为从 $i$ 到 $j$ 的所有长度为 $t$ 的路径集合。长度为 $t$ 的路径的总贡献为

$$R_t(i, j) = \sum_{\pi \in \pi_{ij}^t} w(\pi). \quad (3)$$

根据标准矩阵代数[25]，这等于 $A$ 的 $t$ 次方的 $(i, j)$ 元素：

$$R_t = A^t. \quad (4)$$

换句话说， $A^t(i, j)$ 聚合了注意力图上从标记 $i$ 到标记 $j$ 的所有长度为 $t$ 的路径对所有路径的贡献。

**固定路径长度下的标记得分。**为衡量路径长度 $t$ 下标记 $i$ 的重要性，我们对所有目标标记进行边际化处理：

$$c_t(i) = \sum_{j=1}^N A^t(i, j). \quad (5)$$

分数 $c_t(i)$ 量化了标记 $i$ 在 $t$ 所有交互标记子集中所占的参与度：所有子集中的分数越高，标记 $i$ 在该交互深度上的中心性就越强。

**对所有路径长度进行聚合。**令牌重要性的完整评估考虑了所有深度 $t=1, 2, \dots$ 然而，当 $\rho(A) \geq 1$ 时，未正则化的 $\sum_{t \geq 1} A^t$ 可能发散。根据[44,45]，我们引入折扣因子 $\gamma \in (0, 1/\rho(A))$ ，该因子对较长路径进行几何衰减：

$$\check{c}(i) = \sum_{t=1}^{\infty} \gamma^t c_t(i) = \sum_{t=1}^{\infty} \sum_{j=1}^N \gamma^t A^t(i, j). \quad (6)$$

该函数的值是有限的。我们使用 $\gamma$ 表示衰减（折现）因子，并将 $\rho(\cdot)$ 专用于矩阵的谱半径。

通过几何矩阵级数的闭式表达。正则化无限路径矩阵为  $\tilde{C} = \sum_{t=1}^{\infty} (\gamma A)^t$ . 根据矩阵几何幂级数的收敛性质[25], 若  $\gamma < 1/\rho(A)$  则  $\rho(\gamma A) < 1$  且:

$$\tilde{C} = (I - \gamma A)^{-1} - I. \quad (7)$$

该证明依赖于格尔夫德公式:  $\rho(\gamma A) = \rho((\gamma I)A) \leq \rho(\gamma I)\rho(A) = \gamma \rho(A) < 1$ , 这保证了  $\lim_{t \rightarrow \infty} (\gamma A)^t = 0$ , 从而绝对收敛-  
该序列的生成[18, 25]。矩阵  $\tilde{C}$  编码了所有交互深度下每个标记对其他所有标记的累积折现影响。

当  $\rho(\gamma A) < 1$  时, 折扣路径和  $\tilde{C}$  具有自然的概率学解读: 它与吸收马尔可夫链的基本矩阵一致[30, 44]。从这个视角来看, 标记是注意力图上随机游走的瞬态状态, 每一步具有互补的吸收概率;

尝试  $C_{ij} + \delta_{ij}$  等于从  $i$  开始吸收过程前对令牌  $j$  的预期访问次数。我们将在第3.3节中完整阐述这一解释。

**令牌中心性评分。**最终的单个令牌评分是通过对其目的地进行边际化处理获得的:

$$\tilde{c}^*(i) = [\tilde{C} \mathbf{e}]_i = [(I - \gamma A)^{-1} \mathbf{e}]_i - 1. \quad (8)$$

按  $\tilde{c}$  降序对标记进行排序  $\tilde{y}$  yields 根据注意力图中的结构重要性进行原则性排序, 其中最具影响力的标记——即参与大量高权重多跳交互的标记——会出现在顶部。**分层实现。**在具有  $L$  层的Transformer模型中,  $A^{(l)}$  表示第  $l$  层的注意力矩阵。InfSA通过几何衰减方式累积注意力后输出:

$$S_L = \sum_{t=1}^L \gamma^t (A^{(0)} \dots A^{(l)}) X^{(0)}. \quad (9)$$

其中每一层都会逐步增加更长的有效路径。标准自注意力机制对应  $L=1$  的情况。

当所有  $l$  对应的  $A^{(l)} = A$  时, 该部分和近似于诺伊曼级数恒等式:

$$\sum_{t=1}^{\infty} \gamma^t A^t = (I - \gamma A)^{-1} - I, \quad \gamma < 1/\rho(A), \quad (10)$$

这与等式7相吻合。在异质性情况下, Frobenius归一化 ( $\|\hat{A}^{(l)}\|_F = 1$ , 等式11) 确保了  $\|S_L\| \leq \gamma/(1-\gamma)$  对  $\gamma < 1$  成立, 从而保证了无论层间差异如何输出结果均有界。由于级数在深度  $L$  处截断,  $\gamma$  还可作为可调设计参数来调节深层的贡献度。

**矩阵属性与归一化。**为在每一层构建正算子, 我们使用  $\tilde{A} = \phi(QK^\top)$ , 其中  $\phi = \text{ReLU}$  保证非负性。随后进行弗罗贝尼乌斯归一化:

$$\hat{A} = \frac{\tilde{A}}{\|\tilde{A}\|_F + \epsilon}, \quad (11)$$

其中  $\|\cdot\|_F$  为弗罗贝尼乌斯范数,  $\varepsilon$  用于避免除以零的情况。由此可得  $\hat{A} \geq 0$  且能量有界。

**每层输出。**在每一层  $l$  上, Pure InfSA 计算:

$$Z^{(l)} = \hat{A}^{(l)} V^{(l)}, \quad \hat{A}^{(l)} = \frac{[Q^{(l)} K^{(l)\top}]_+}{\| [Q^{(l)} K^{(l)\top}]_+ \|_F + \varepsilon}, \quad (12)$$

替换传统注意力机制中的标准 softmax  $(QK^\top / \sqrt{d_k}) V$ 。所有  $L$  层的累积输出为  $S_L = \sum_{l=1}^L \gamma^l Z^{(l)}$ 。

与 softmax 不同, 后者生成行随机矩阵 ( $A\mathbf{1}=\mathbf{1}$ ), 并导致通过向平稳分布混合实现过度平滑[32, 37], Frobenius  $\hat{A}$  归一化将总矩阵能量  $\|A\|_F=1$  进行约束, 从而提供充分的  $\hat{A}$  算子具有收缩性条件 ( $\rho(A) < 1$ )。这确保了解的  $\hat{A}$  计数序列  $\varepsilon \gamma^t A^t$  保持收敛性, 并将每一层从概率混合步骤转化为 **中心性计算**: 标记符根据其结构重要性进行加权——类似于 Katz 中心性[29]——而非基于局部概率质量。吸收马尔可夫链解释 (第3.3节) 直接依赖于这种次随机性。

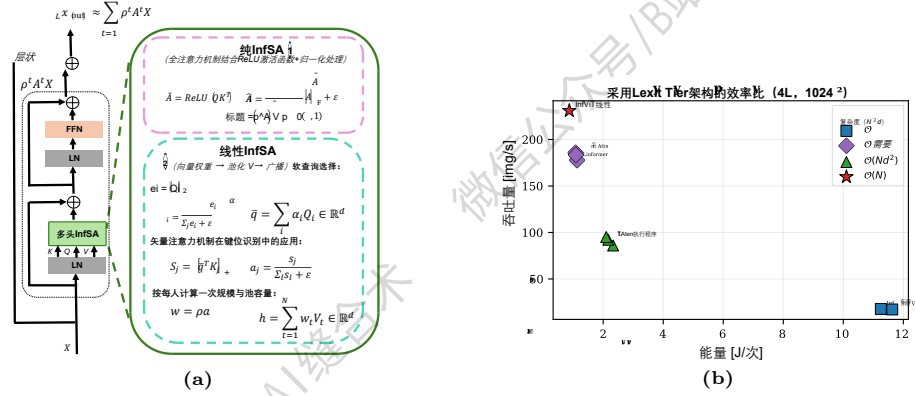
在此公式中,  $t$  表示注意力图中的跳跃次数——等价于标记到标记路径的长度;  $\gamma$  定义了远距离效应的范围或衰减; 而  $L$  是 Transformer 的深度, 作为无限求和的截断点。因此, 每一层  $l$  都近似于底层注意力算子的  $l$  次幂  $A^l$ , 且累积过程 (9) 实现了对长度不超过  $L$  的所有路径的显式积分, 将图扩散直接嵌入到 Transformer 计算中。

指数衰减  $\gamma^l$  引入了显式深度偏置, 可限制过度传播并避免过度平滑[32, 37]: 早期层贡献更强, 而深层路径则被衰减。若  $\gamma$  通过学习 (通过 Sigmoid 函数约束在  $(0, 1)$  范围内), 则能自适应地调整每个头的积分时间范围。我们在预训练网络变压器 (见图28 - InSp\_2) 中实现 InfSA, 通过在每一层计算  $A$  并累积输出  $S_L = \sum_{l=1}^L \gamma^l Z^{(l)}$ 。

### 3.3 InfSA 的吸收马尔可夫链解释

Pure InfSA (等式 10) 的 Neumann 级数公式化形式通过吸收马尔可夫链 [30, 44, 48] 可直接进行概率解释。这种关联表明 InfSA 通过令牌图上的随机游走计算期望访问次数, 从而将自注意力机制与经典随机过程联系起来。

**建筑。**设  $\hat{A} \in \mathbb{R}_{\geq 0}^{N \times N}$  为弗罗贝尼乌斯归一化注意力矩阵  $\hat{A}$  (等式 11) 和  $\gamma \in (0, 1/\rho(A))$  衰减因子。图3展示了关键直觉: 单次幂法步骤 (一阶注意力机制) 会错误识别最重要的标记, 而迭代至稳态——相当于 InfSA 计算的 Neumann 级数极限——则能正确揭示全局结构重要性。



**图2: (a) Pre-LN ViT 模块中的 InfSA。** 标准Transformer架构中的两种 InfSA 变体: (1) *Pure InfSA* 采用全注意力机制结合ReLU和Frobenius归一化, 跨层累积折扣输出; (2) *Linear InfSA* 计算软标记分数、按头池化值并采用逐层缩放进行上下文广播。两种方案均可无缝集成到Transformer模块中。 (b) 不同复杂度层级下的效率对比 (4L, 1024<sup>2</sup>)。九种注意力机制的推理吞吐量与每图像能耗对比 (按渐近复杂度着色)。InfViT Linear ( $O(N)$ , 红星标记) 在最低能耗下实现最高吞吐量。

通过多跳传播实现。定义

$$\mathbf{M} = \gamma \mathbf{A}, \quad R_i = 1 - \gamma \sum_{j=1}^N \hat{A}_{ij}, \quad (13)$$

其中  $\mathbf{M}_{ij} \geq 0$  表示从标记  $i$  到标记  $j$  的转移概率,  $R_i \geq 0$  表示标记  $i$  处的每步吸收概率。矩阵  $\mathbf{M}$  是次随机的 ( $\mathbf{M}\mathbf{1} \leq \mathbf{1}$ , 且至少有一行满足严格不等式) 当且仅当  $\gamma \max_i \sigma_i < 1$ , 其中  $\sigma_i = \sum_j A_{ij}$  Frobenius 归一化约束  $\|\mathbf{A}\|_F = 1$ , 该条件确保  $\rho(\mathbf{M}) = \gamma \rho(\mathbf{A}) < 1$ 。我们通过添加单一吸收态  $\mathbf{a}$  来扩充  $N$  个标记状态, 从而得到标准形式[30]:

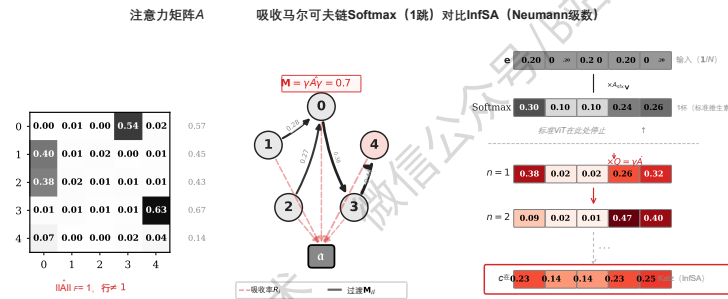
$$\mathbf{P} = \begin{pmatrix} \mathbf{M} & \mathbf{R} \\ \mathbf{0}^\top & 1 \end{pmatrix} \in \mathbb{R}^{(N+1) \times (N+1)}, \quad (14)$$

其中  $\mathbf{R} = (R_1, \dots, R_N)^\top$ , 且  $\mathbf{P}$  为行随机变量。标记符表示瞬态状态; 吸收态  $\mathbf{a}$  代表扩散过程的终止。

该链的基本矩阵为

$$\mathbf{N} = (\mathbf{I} - \mathbf{M})^{-1} = (\mathbf{I} - \gamma \hat{\mathbf{A}})^{-1} = \sum_{t=0}^{\infty} (\gamma \mathbf{A})^t, \quad (15)$$

这正是 InfSA (等式10) 中已隐含的 Neumann 核。项  $N_{ij}$  具有具体的概率意义 [30, 48]: 它等于在吸收前随机游走访问标记  $j$  的期望次数, 前提是



**图3: Softmax注意力机制（单跳）与InfSA（Neumann序列）对比。**左图：弗罗贝尼乌斯归一化的 $A$ （ $\|A\|_F=1$ ）；与softmax不同，行和会变化。中间：吸收 $\gamma$ 在马尔可夫链 $M=\gamma A$ 中；红色虚线箭头表示吸收 $R_i=1-\sum_j M_{ij}$ 到 $a$ 中。右图：从全1输入 $e$ （8）出发：softmax注意力（行随机，单跳）通过列和将标记0排在首位，因为许多标记直接关注它。InfSA进一步迭代 $M$ ；当 $n=2$ 时，链 $0 \rightarrow 3 \rightarrow 4$ 将质量重定向至标记4，且Katz中心性 $c^{in}$ 正确识别标记4为全局最重要——多跳结果标准自注意力机制未能捕捉到这一点。

从标记 $i$ 开始。InfSA路径积分矩阵 $S=N-I=(I-\gamma A)^{-1}-I$ ，因此计算了预期访问次数（不包括起始状态）。

令牌中心性作为预期路径持续性。对 $N$ 进行行和列求和可得到两种互补的中心性度量：

- 出向影响力： $coi^{out}=\sum_j N_{ij}$ 表示从令牌 $i$ 出发时，在被吸收前预期的令牌访问总数。具有高出向影响力的令牌会引发冗长且信息丰富的路径。
- 入站中心性： $cinj=\sum_i N_{ij}$ 表示所有起点对标记 $j$ 的总预期访问次数。具有高入站中心性的标记在注意力图中具有结构重要性。

这些分数与Katz中心性[29]一致，证实InfSA是根据全局结构角色而非局部查询-键亲和力和对标记进行排序。

**为何Frobenius归一化能够实现吸收。**Softmax归一化 $\gamma$

给出行随机矩阵（ $A1=1$ ），对应于无吸收态的闭合马尔可夫链——这是过度平滑现象的来源[32]。Frobenius正规-

该方法通过消除行随机性（实际应用中 $\rho(A)<1$ ），在每一步引入正吸收概率并确保收敛性。这种吸收链观点在结构上与Rofo等人提出的马尔可夫解释完全一致。[44,45]其中特征表现为瞬态状态，基础矩阵根据预期行走持续性对其进行排序。InfSA将这一原理从特征图扩展至标记图：当某个标记在扩散终止前参与多次长距离、高概率的行走时，其中心性值会显著提升。

### 3.4 线性InfSA：高效中心性近似算法

为降低显式多跳累积的成本，*Linear-InfSA*通过隐式注意力矩阵的主特征向量来近似标记中心性。

tion算子，而无需形成完整矩阵 $A$ 。具体而言，它近似了由Pure InfSA（等式7）计算出的Neumann核 $\tilde{C} = (I - \gamma^* A)^{-1} - I$ 的主导特征向量，用单个 $O(N)$ 次幂迭代步骤替代了 $O(N^2)$ 矩阵求逆运算。这实现了通过简单向量运算和归一化迭代计算全局影响的线性时间近似。设 $X = [x_1, \dots, x_N]$ 为输入标记， $W_Q, W_V$ 为查询与值投影。我们将投影绑定并定义 $Q := XW_Q$ ，使得 $Q = K$ 。绑定 $Q = K$ 将注意力核限制为对称相似性度量 $(x^T W^T W x_j)$ ，从而舍弃非对称查询-键交互。这一设计选择的动机在于特征向量解释：Perron特征向量是对称算子 $A + A^T$ 的性质，因此对称性在结构上是合适的。非对称标记交互通过多头集成器及后续前馈网络得以恢复。

**软查询构建。**我们通过计算查询向量的 $\ell_2$ 范数来获取词元级能量：

$$e_i = \|Q_i\|_2, \quad (16)$$

提供一个反映标记在嵌入空间中显著性的正向信号[46]。这些能量值未经softmax归一化处理：

$$\alpha_i = \frac{e_i}{\sum_j e_j + \varepsilon}, \text{ 其中 } \alpha \in \mathbb{R}_+^N, \quad \|\alpha\|_1 = 1, \quad (17)$$

生成一个软重要性分数，该分数可作为正算子主导特征向量的代理[25, 29]。无需进行softmax或Frobenius归一化； $\ell_1$ 约束确保了数值稳定性。

**中心查询与键点注意力机制。**软性中心查询通过加权平均法获得：

$$q^- = \sum_i \alpha_i Q_i \in \mathbb{R}^d. \quad (18)$$

我们采用正核函数对键值进行评分计算：

$$S_j = [\bar{q}^T K_j]_+, \quad (19)$$

并再次使用L1约束进行归一化处理（ $Q = K$ ）：

$$a_j = \frac{S_j}{\sum_l S_l + \varepsilon}. \quad (20)$$

线性InfSA权重实现了对隐式注意力扩散算子主导特征向量的一阶Perron-Frobenius式近似。在非负性条件下（或经过微小下界处理后的强正性条件下），该迭代过程是一个保持阶数的1-齐次映射，其归一化迭代结果会收敛到唯一的特征向量；在严格非负性情况下，该方法恰好退化为经典幂法。由此产生的 $O(N)$ 复杂度较标准ViT实现了13.4 ×的加速比，绝对吞吐量达231 img/s，且在1024<sup>2</sup>分辨率下仅需0.87 J/img的能量消耗（参见图4中的效率仪表盘）。

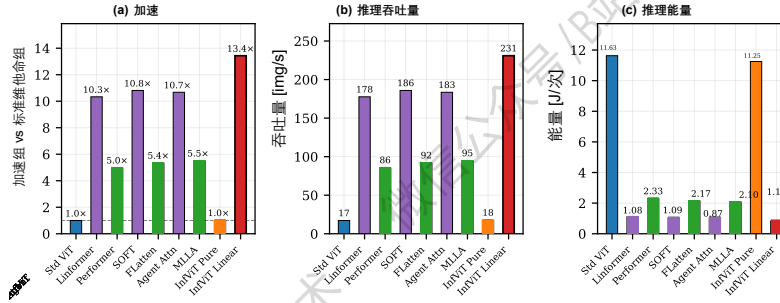


图4：效率仪表盘（4L-64H，推理速度为 $1024^2$ ）。相较于标准ViT的加速比、绝对吞吐量及每图像能耗。InfViT Linear ( $O(N)$ ) 在0.87 J/图像时实现13.4 ×的加速比。

最终上下文池化。头部输出通过以下加权值之和计算得出：

$$h = \sum_{t=1}^N w_t V_t, \text{ 其中 } w = \gamma a, \quad (21)$$

采用与Pure InfSA相同的缩放机制。生成的上下文向量 $h$ 随后被广播至所有标记位置，并在各头之间进行合并（参见图2a 2）。

设计上与查询无关的加权。权重向量 $a$ 仅依赖于键（等价于查询，因为 $Q=K$ ），并在所有位置间共享——这是特征向量极限的直接结果，其中算子由其主特征向量 $v$ 主导，生成有效秩为1的矩阵 $vv^T$ 。我们通过使用64个头（标准ViT中为16个）恢复表达能力，使得每个头捕获不同的中心性模式；在冻结检查点上， $a$ 与真实Perron特征向量的平均余弦相似度达到0.985（补充材料第3节）。每个Linear-InfSA头生成秩为1的输出（共享上下文广播至所有位置）。当使用64个头且每个头维度 $d_h=12$ 时，拼接输出覆盖 $64 \times 12=768$ 维子空间，与标准ViT容量相匹配。

Linear-InfSA避免构建完整的注意力矩阵，将复杂度从 $O(N^2)$ 降低至 $O(N)$ 。向量 $a$ 是主导特征向量[31, 48]的线性时间替代量，经典上通过 $v = \lim_{k \rightarrow \infty} A^k x_0 / \|A^k x_0\|_1$ 得到；这种 $k \rightarrow \infty$ 的特性促使Linear-InfSA中使用“无限”这一术语。等式(19)中的ReLU抑制反向对齐标记，在非负性条件下该映射定义了一个正1-齐次算子，其迭代结果通过非线性Perron–Frobenius理论收敛至唯一方向[4, 31]（完整收敛论证参见补充材料）。

与全局池化的关系。尽管每个头部的输出是一个广播上下文向量，但Linear-InfSA无法简化为通用全局池化[26]或加性注意力聚合[60]：权重向量 $a$ 是非线性Perron–Frobenius算子的唯一不动点，其谱编码了完整的词间相似性结构，而非学习得到或启发式显著性分数。这种谱基础性通过实证得到验证—— $a$ 实现了0.985的平均余弦相似度与

**表1: A100 40 GB (批次=1) 上的可扩展性基准测试。**推理规模为 $1024^2$  (4 096 个标记, 补丁16); 训练规模为 $512^2$ 。能耗:  $E = P \cdot \Delta t$ ;  $P_{tr}=300W$ ,  $P_{inf}=200W$ 。类型: **Q**= 二次型, **L**= 线性/次二次型, **I**= InfSA。所有非InfViT模型的OOM均超过 $1024^2$ ; Max Res为未发生内存故障时达到的最高分辨率。

| 模型                                   |   | 类型        | 复杂度参数  | 延迟[毫秒]              |                      | 吞吐量 [img/s] |        | 能量 [J/次] |        | 最大残余     |
|--------------------------------------|---|-----------|--------|---------------------|----------------------|-------------|--------|----------|--------|----------|
|                                      |   |           |        | 火车                  | 下部                   | 火车          | 下部     | 火车       | 下部     |          |
| 24层, 16个探头 配置 ( $d_h=48$ ) ——公平深度 比较 |   |           |        |                     |                      |             |        |          |        |          |
| 标准维生素                                | Q | $O(N^2d)$ | 330.6M | 60.18               | 113.13               | 16.62       | 8.84   | 18.05    | 22.63  | $1024^2$ |
| Linformer [57]                       | L | $O(Nd)$   | 331.5M | 55.64               | 38.95                | 17.97       | 25.67  | 16.69    | 7.79   | $1024^2$ |
| 表演者[9]                               | L | $O(Nd^2)$ | 330.3M | 58.14               | 42.80                | 17.20       | 23.36  | 17.44    | 8.56   | $1024^2$ |
| SOFT [36]                            | L | $O(Nd)$   | 330.8M | 56.10               | 36.44                | 17.83       | 27.44  | 16.83    | 7.29   | $1024^2$ |
| Ftatten [20]                         | L | $O(Nd^2)$ | 330.5M | 57.82               | 40.15                | 17.29       | 24.91  | 17.35    | 8.03   | $1024^2$ |
| 代理收件人[22]                            | L | $O(Nd)$   | 331.0M | 56.55               | 35.81                | 17.68       | 27.93  | 16.97    | 7.16   | $1024^2$ |
| MLLA [21]                            | L | $O(Nd^2)$ | 330.4M | 57.38               | 39.52                | 17.43       | 25.30  | 17.21    | 7.90   | $1024^2$ |
| InfViT Pure                          | I | $O(N^2d)$ | 330.6M | 60.25               | 110.20               | 16.59       | 9.07   | 18.08    | 22.04  | $1024^2$ |
| InfViT线性                             | I | $O(N)$    | 305.4M | 55.52               | 25.28                | 18.01       | 39.56  | 16.66    | 5.06   | $9216^2$ |
| 4层64头配置 ( $d_h=12$ ) ——建议的轻量型        |   |           |        |                     |                      |             |        |          |        |          |
| 标准维生素                                | Q | $O(N^2d)$ | 57.7M  | 19.26               | 58.16                | 51.93       | 17.19  | 5.78     | 11.63  | $1024^2$ |
| Linformer [57]                       | L | $O(Nd)$   | 58.3M  | 12.49               | 5.63                 | 80.04       | 177.62 | 3.75     | 1.13   | $1024^2$ |
| 表演者[9]                               | L | $O(Nd^2)$ | 57.5M  | 15.45               | 11.63                | 64.72       | 85.98  | 4.64     | 2.33   | $1024^2$ |
| SOFT [36]                            | L | $O(Nd)$   | 57.9M  | 12.18               | 5.38                 | 82.10       | 185.87 | 3.65     | 1.08   | $1024^2$ |
| Ftatten [20]                         | L | $O(Nd^2)$ | 57.6M  | 14.92               | 10.85                | 67.02       | 92.17  | 4.48     | 2.17   | $1024^2$ |
| 代理收件人[22]                            | L | $O(Nd)$   | 58.1M  | 12.35               | 5.45                 | 80.97       | 183.49 | 3.71     | 1.09   | $1024^2$ |
| MLLA [21]                            | L | $O(Nd^2)$ | 57.5M  | 14.68               | 10.52                | 68.12       | 95.06  | 4.40     | 2.10   | $1024^2$ |
| InfViT Pure                          | I | $O(N^2d)$ | 57.7M  | 19.55               | 56.27                | 51.15       | 17.77  | 5.87     | 11.25  | $1024^2$ |
| InfViT Linear <sup>a</sup>           | I | $O(N)$    | 53.5M  | 9.41                | 4.33                 | 106.27      | 230.95 | 2.82     | 0.87   | $9216^2$ |
| 极高分辨率应力测试 (仅限线性InfViT——其余均为OOM)      |   |           |        |                     |                      |             |        |          |        |          |
| InfViT Linear (4L)                   | I | $O(N)$    | 53.5M  | 199.22 <sup>a</sup> | 320.27 <sup>b</sup>  | 5.02        | 3.12   | 59.77    | 64.05  | $9216^2$ |
| InfViT Linear (24升)                  | I | $O(N)$    | 305.4M | —                   | 1783.17 <sup>b</sup> | —           | 0.56   | —        | 356.63 | $9216^2$ |

<sup>a</sup>主模型。<sup>b</sup>训练集为 $4096^2$  (65k标记)。<sup>c</sup>推理集为 $9216^2$  (332k标记)。 $O(N)$  = 与头向量维度无关。

真实的Perron特征向量 (补充材料第3节) ——并确保聚合过程能够捕捉全局图中心性而非局部标记显著性。

## 4 实验

我们通过将InfSA集成到具有16像素块大小的4层视觉Transformer (ViT) 中进行评估。*Pure InfViT*采用16个全注意力头, 而*Linear InfViT*采用64个轻量级头。两种模型的计算量和参数量具有可比性 (5800万对比5300万)。完整训练细节详见补充材料。

### 4.1 极端输入分辨率下的可扩展性研究

我们在A100 40GB显存 (批次=1) 上对 $224^2$ 至 $9216^2$ 分辨率范围内的九种注意力机制进行基准测试。当分辨率达到 $9216^2$ 且补丁尺寸为16时, 序列长度达到 $N=331,776$ 个标记——是FlashAttention辅助二次模型约5万上限的6.6 ×倍[11]。FlashAttention消除了 $O(N^2)$ 内存墙, 但保留了 $O(N^2)$ 计算量, 使得33万标记的规模难以实现。*Linear InfViT*呈现近线性扩展特性, 且是唯一无需OOM即可完成全分辨率范围的模型 (参见补充材料中延迟-分辨率曲线图, 图11)。

表1报告了 $1024^2$ 下九种机制的延迟、吞吐量和能耗。次二次方法分为三个层级: (i) $O(Nd^2)$ 特征图注意力机制 (Performer、FLatten、MLLA); (ii) $O(Nd)$ 基于投影的方法 (Linformer、SOFT、Agent Attn); (iii) $O(N)$ InfViT线性模型。在4L-64H配置下,

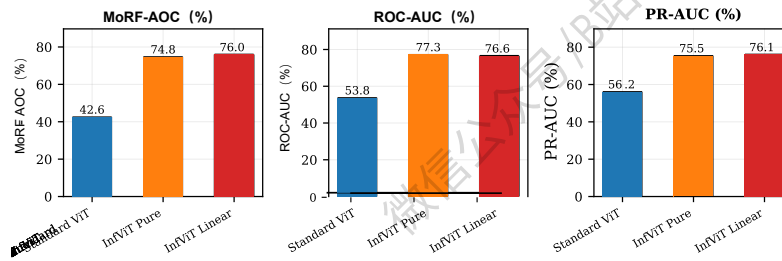


图5：注意力质量总结。MoRF-AOC、ROC-AUC及PR-AUC (%)。两种InfSA变体均比标准ViT高出20–34个百分点。完整曲线见补充材料（图7、8）。

InfViT Linear在0.87 J/img能量密度下达到231 img/s的吞吐量——比标准ViT（17.19 img/s, 11.63 J）快13 ×且成本更低，比所有次二次基线模型快1.2–2.7 ×（图4）。在9216<sup>2</sup>（332k标记）输入量下，InfViT Linear 4L模型维持3.12 img/s的吞吐量；其他所有模型均触发内存溢出。如图2b所示，InfViT Linear占据吞吐量-能量空间的左上角，与所有 $O(Nd)$ 和 $O(Nd^2)$ 基线模型形成明显分离。补充材料中提供了4L与24L模型的深度对比（图9）。

#### 4.2 注意力质量：退化与定位

我们评估InfSA注意力图是否在ImageNet-1K验证集上具有语义基础。注意力图从具有各自注意力机制的24层模型中提取（ViT-L/16骨干网络，14 × 14标记，3.04亿参数），遵循可解释性评估的标准实践。**MoRF降解**[47]逐步移除高关注度区域并追踪置信度下降（曲线下面积，AOC ↑）。线性InfSA实现最陡峭的MoRF下降（AOC=76.0%），其次是Pure InfSA（71.7%）；标准ViT的平坦曲线（AOC=42.6%）显示弥散注意力。对于LeRF（最不相关优先法），Pure InfSA保持最高保留率（AUC=65.3%）。**边界框定位**将注意力视为针对ImageNet真实框（2 088 张图像）的区域级检测器。Pure InfSA在ROC-AUC（77.3%）和PR-AUC（76.1%）上领先，而标准ViT分别为53.8%和56.2%（+20–24个百分点）。两项评估均证实InfSA产生空间选择性、语义对齐的注意力（图5）。

#### 4.3 ImageNet分类结果

所有模型均在ImageNet-1K（128万张图像，300个epoch，批量64）上采用DeiT风格的训练方案[53]进行训练，未使用外部数据、蒸馏技术或自监督预训练。我们的ViT基线模型达到81.5%的准确率；**Linear InfViT 4L**（84.7%，5350万参数，59 GFLOPs）带来的+3.2pp增益完全源于架构设计。需注意InfViT-4L的运算量为59 GFLOPs（224<sup>2</sup>），而ViT-B/16因采用64头设计仅需17.5 GFLOPs。然而Linear-InfSA的 $O(N)$ 复杂度意味着该差距

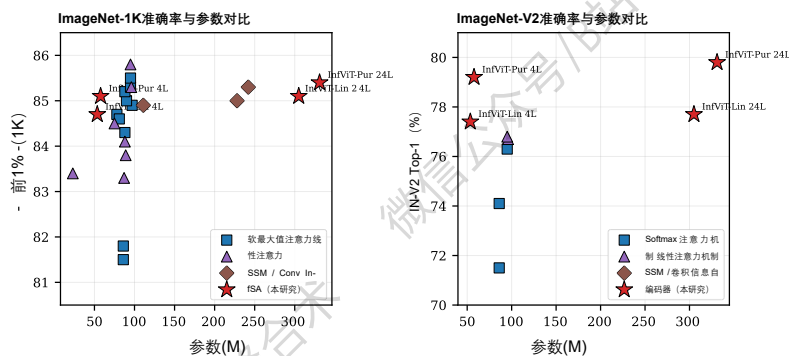


图6: 准确率与参数关系。ImageNet-1K (左) 和ImageNet-V2 (右) 模型在参数数量上的top-1准确率对比。InfViT变体 (红色星号) 在较低参数数量下即可达到具有竞争力或更优的准确率。在ImageNet-V2数据集上, 所有四个InfViT模型均优于所有基线模型。

在更高分辨率下会变窄, 并在超过约 $512^2$ 时发生反转, 此时二次基线模型的FLOPs随 $N^2$ 增长, 而InfViT模型则呈线性增长。图6展示了ImageNet-1K和ImageNet-V2 [42]的top-1准确率随参数数量的变化趋势。在IN-1K数据集上, *InfViT Pure 24L*达到85.4%, 与 *RAVLT -L*[14] (85.8%) 相差仅0.4个百分点。4L变体 (Pure 85.1%, Linear 84.7%) 在参数量约减半的情况下, 优于Agent Attn-B (84.1%) 和FLatten ( $\leq 84.5\%$ )。在IN-V2数据集上, 所有四种InfViT模型均超越所有基线模型 (最高达79.8% vs. *RAVLT -L*的76.8%), 表明其具有强泛化能力。24L模型在参数成本增加6×的情况下, 仅比4L模型提升0.3–0.4个百分点; 4L-64H变体为推荐配置。完整方法对比表见补充材料 (表3)。

消融实验结果 (路径衰减 $\gamma$ 与激活函数) 详见补充材料 (表4)。简要说明: 使用ReLU激活函数时, 准确率与MoRF-AOC在 $\gamma=0.7$ 时达到峰值 (分别为84.7%和76.0%); 在线性InfSA权重向量与完整算子的Perron特征向量进行余弦相似度计算时, 在小规模标记集上可达到0.985的相似度 (补充材料第3节)。

## 5 结论

我们提出无限自注意力机制 (InfSA), 这是一种可扩展且可解释的softmax注意力替代方案, 通过将标记交互重构为图扩散过程实现。纯InfSA采用弗罗贝尼乌斯归一化算子——确保收敛性Neumann级数积分的收缩特性以捕捉多跳依赖关系; 而线性InfSA则通过隐式注意力算子的主特征向量, 在线性时间内近似全局影响, 其辅助注意力状态复杂度为 $O(d)$ 且与序列长度无关。两种变体均保持与预线性化Transformer的兼容性, 并基于非线性Perron-Frobenius理论提供了收敛性保证。

经验表明, InfViT模型在分类、定位和可扩展性任务中均表现出强劲性能。纯InfViT可提升ImageNet准确率和注意力对齐效果, 而线性InfViT可扩展至 $9216^2$ 分辨率, 同时保持13×的参数规模。

在同等深度下，其能效优于标准ViT模型。紧凑型四层变体仅需部分参数量即可达到或超越大型基线模型的准确度，从而实现实际部署。InfSA所基于的图论原理具有模态无关性，可自然扩展至自然语言处理、多模态模型、视频理解及密集预测任务等领域；代码可在[github.com/giorgioroffo/infinite-self-attention](https://github.com/giorgioroffo/infinite-self-attention)获取。

## 致谢

本研究部分基于MindVisionLabs (MVL, 英国伦敦) 与TRI丰田汽车欧洲公司合作期间探索的概念方向。同时，我们衷心感谢Equixly API Security对本研究的支持。

## 参考文献

1. Abnar, S., Zuidema, W.: 量化变压器中的注意力流。见: ACL (2020)
2. Beltagy, I., Peters, M.E., Cohan, A.: Longformer: 长文档转换器。见: arXiv预印本 arXiv:2004.05150 (2020)
3. Bianchini, M., Gori, M., Scarselli, F.: 《PageRank内幕》。ACM 互联网技术汇刊 (TOIT) 5(1), 92–128 (2005)
4. Birkhof, G.: Jentzsch定理的推广。《美国数学学会会刊》85, 219–227 (1957年)
5. Bonacich, P.: 社会网络中的中心性: 概念澄清。《社会网络》1(3), 191–235 (1972)
6. Brown, T.B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A. 等: 语言模型是少样本学习器。神经信息处理系统进展 (NeurIPS) (2020)
7. Buades, A., Coll, B., Morel, J.M.: 一种用于图像去噪的非局部算法。收录于: 2005年 IEEE Computer Society 会议 Computer Vision 与 Pattern Recognition 会议 (CVPR '05)。第2卷, 第60–65页。IEEE (2005)
8. Chefer, H., Gur, S., Wolf, L.: 变换器可解释性超越注意力可视化。见: CVPR (2021)
9. Choromanski, K., Likhoshesterov, V., Dohan, D., Song, X., Gane, A., Sarlos, T., Hawkins, P., Davis, J., Mohiuddin, A., Kaiser, L., Belanger, D., Colwell, L., Weller, A.: 表演者注意力机制的重新思考。载于: 国际学习表征会议 (ICLR) (2021)
10. Dao, T.: Flashattention-2: 具有更好并行性和工作分区的更快注意力机制。arXiv预印本 arXiv:2307.08691 (2023)。 <https://doi.org/10.48550/arXiv.2307.08691>
11. Dao, T., Zhang, Z., Ramsundar, B., Re, C.: Flashattention-2: 具有更好并行性和工作划分能力的快速注意力机制。见: NeurIPS (2023)
12. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N.: 一张图片胜过16×16个单词: 大规模图像识别中的Transformer模型。见: 国际学习表征会议 (ICLR) (2021), <https://arxiv.org/abs/2010.11929>