



核心速览



论文题目: Self-Attention And Beyond the Infinite: Towards Linear Transformers with Infinite Self-Attention

中文题目: 自注意力与超越无限: 迈向具有无限自注意力的线性 Transformer

论文链接: <https://arxiv.org/pdf/2603.00175v3>

所属单位: 1. Equixly API Security 2. GlimpseML

核心速览:

本文针对 Transformer 中 softmax 注意力的二次成本限制高分辨率视觉任务可扩展性的问题, 提出 Infinite Self-Attention (InfSA), 通过谱重构将注意力层建模为内容自适应令牌图上的扩散步骤, 利用 Neumann 级数

累积多跳交互，其核心矩阵与图中心性度量（如 Katz、PageRank）及吸收马尔可夫链的基本矩阵相关，赋予令牌权重可解释性。进一步提出 Linear-InfSA，通过近似隐式注意力算子的主特征向量实现 $O(N)$ 复杂度，在 ImageNet 上实现高精度、高吞吐量和低能耗，并支持超大规模分辨率输入。

https://mp.weixin.qq.com/s/A_nU8rjGNnC-OOaqpO6onA

```
InfSAAttention(  
    (q_proj): Linear(in_features=512, out_features=512, bias=True)  
    (k_proj): Linear(in_features=512, out_features=512, bias=True)  
    (v_proj): Linear(in_features=512, out_features=512, bias=True)  
    (out_proj): Linear(in_features=512, out_features=512, bias=True)  
)  
input_tensor_shape : torch.Size([4, 197, 512])  
output_tensor_shape : torch.Size([4, 197, 512])
```

哔哩哔哩/微信公众号：AI缝合术，独家整理！

pure_infsa

```
InfSAAttention(  
    (q_proj): Linear(in_features=512, out_features=512, bias=True)  
    (k_proj): Linear(in_features=512, out_features=512, bias=True)  
    (v_proj): Linear(in_features=512, out_features=512, bias=True)  
    (out_proj): Linear(in_features=512, out_features=512, bias=True)  
)  
input_tensor_shape : torch.Size([4, 197, 512])  
output_tensor_shape : torch.Size([4, 197, 512])
```

哔哩哔哩/微信公众号：AI缝合术，独家整理！

linear_infsa