


核心速览



论文题目: **ATTENTION RESIDUALS**

中文题目: 注意力残差

论文链接: <https://arxiv.org/pdf/2603.15031>

官方 github: <https://github.com/MoonshotAI/Attention-Residuals>

所属单位: Kimi Team

核心速览:

本文针对现代 LLM 中标准残差连接 (PreNorm) 的固定权重积累导致隐藏状态随深度增长、层贡献稀释的问题，提出 Attention Residuals (AttnRes)，通过 softmax 注意力机制让每层选择性聚合前层输出，并引入 Block AttnRes 将层分组为块以降低内存和通信开销。实验表明，AttnRes 在不同模型规模上持续提升性能，集成到 Kimi Linear 架构 (48B 参数) 预训练 1.4T tokens 后，缓解了 PreNorm 稀释问题，优化了梯度分布，下游任务性能全面提升。

<https://mp.weixin.qq.com/s/c4Q3yofxzsr8XXW1zTE9A>

```
BlockAttentionTransformerLayer(  
  (attn_res_proj): Linear(in_features=64, out_features=1, bias=False)  
  (attn_res_norm): RMSNorm()  
  (mlp_res_proj): Linear(in_features=64, out_features=1, bias=False)  
  (mlp_res_norm): RMSNorm()  
  (attn_norm): RMSNorm()  
  (attn): MultiheadAttention(  
    (out_proj): NonDynamicallyQuantizableLinear(in_features=64, out_features=64, bias=True)  
  )  
  (mlp_norm): RMSNorm()  
  (mlp): Sequential(  
    (0): Linear(in_features=64, out_features=256, bias=True)  
    (1): GELU(approximate='none')  
    (2): Linear(in_features=256, out_features=64, bias=True)  
  )  
)  
输入形状: torch.Size([2, 10, 64])  
输出形状: torch.Size([2, 10, 64])  
  
哔哩哔哩/微信公众号: AI缝合术, 独家整理!
```