

EccoMamba: 用于医学图像分割的增强型跨层级连续性正交Mamba算法

徐俊林¹、李金灿²、崔飞飞³、张壮⁴、杨佳亮⁵、金书婷^{1*}、金强国^{6*}

孟亚杰^{4*}

¹中国湖北省武汉理工大学计算机科学与技术学院

²海南师范大学数学与统计学院, 中国海南

³海南大学计算机科学与技术学院, 中国海南

⁴中国湖北省武汉纺织大学计算机科学与人工智能学院

⁵Geneis北京有限公司, 中国北京

⁶中国山西西北 Polytechnical University 软件学院

shutingjin@wust.edu.cn, qgking@nwpu.edu.cn, myj@hnu.edu.cn

摘要

医学图像分割在临床诊断、病灶量化及术前规划中具有至关重要的作用。然而, 现有的基于Mamba的架构依赖于固定方向序列建模并将图像展平为一维(1D)序列, 难以捕捉层次化的解剖特征与空间依赖关系, 从而限制了其对复杂医学结构的表征能力。为解决这些局限性, 我们提出了EccoMamba(增强型跨层级连续正交Mamba)——一种专为医学图像分割设计的U型编码器-解码器框架。在编码器的下采样路径中, 我们引入了层级聚合增强(HAE)模块, 该模块将多尺度卷积与层级注意力机制相结合; 注意力分支进一步整合了跨通道交互, 使模型能够选择性强化语义相关的特征, 同时抑制无关背景响应。针对跳跃连接, 我们设计了结构连续性正交(SCO)模块, 通过正交轴向位移(AS)建模跨维度依赖关系来保持空间连续性, 从而减少方向偏差并提升解剖一致性。在ISIC 2018、ISIC 2017、Synapse和ACDC四个基准数据集上的大量实验表明, EccoMamba在分割精度和结构保真度方面均持续优于当前最先进的方法。

代码: <https://github.com/Biowust/EccoMamba>

引言

医学图像分割在临床诊断、病变检测、术前规划及治疗评估中具有关键作用(Ronneberger、Fischer与Brox, 2015)。该技术对于识别复杂的器官结构及检测细微病理区域至关重要。然而, 医学图像通常存在显著的模式异质性(如CT、MRI、WSI)、模糊的结构边界、高度的解剖学变异以及标注数据匮乏等问题(Chen)。

*通讯作者

版权所有 © 2026, 人工智能促进协会(www.aaai.org)。保留所有权利。

(Zhou等人, 2018; Zhou等人, 2024)。这些挑战显著限制了传统分割方法的泛化能力。

近年来医学图像分割领域的进展主要可分为两大类。第一类聚焦于基于卷积神经网络(CNN)的架构。诸如U-Net及其变体(例如UNet++(Zhou等人, 2018)、AttentionUNet(Zhu等人, 2022)、UCTransNet(Wang等人, 2022)和UNetR(Hatamizadeh等人, 2022))等模型, 通过采用编码器-解码器结构和跳跃连接来捕捉局部空间上下文, 从而实现精准的边界定位。然而, CNN本身具有感受野有限的固有缺陷, 这限制了其建模全局交互的能力, 常导致解剖预测结果存在碎片化问题。第二类则是基于Transformer的模型(Dosovitskiy等人, 2020), 包括TransUNet(Chen等人, 2024)、Swin-UNet(Cao等人, 2022)和MISSFormer(Huang等人, 2022)。这些模型利用自注意力机制捕捉长程依赖关系, 但面临两个关键局限: 巨大的计算开销以及空间先验信息不足——这两点共同制约了边界精度与位置一致性。

近年来, Mamba架构(Gu和Dao 2023)作为一种选择性状态空间模型, 在医学图像分割领域已成为基于CNN和Transformer设计的有力替代方案, 这一点在VM-UNet(Ruan、Li和Xiang 2024)与MambaUNet(Wang等人2024)的研究中得到了验证。得益于其线性的计算复杂度, Mamba能够以相对紧凑的参数规模高效建模长程依赖关系。然而, Mamba将图像处理为扁平化的一维序列, 这破坏了医学成像所必需的内在二维或三维空间结构。因此, 在捕捉依赖连续空间线索的精细解剖细节(如心脏亚区和肿瘤边界)时存在困难。此外, Mamba单向序列处理方式引入了方向性偏差, 降低了其对水平和垂直结构进行对称感知的能力。再者, 由于缺乏明确的多尺度机制, 该架构在建模层级化解剖特征方面能力受限, 导致感知表征出现不平衡。

图像呈现效果不佳且分割性能欠佳，尤其在解剖结构复杂的区域。

为解决这些局限性，我们提出了**增强型跨层次连续性正交Mamba**（EccoMamba）——一种专为医学图像分割设计的U型编码器-解码器架构。EccoMamba通过提升Mamba主干网络建模局部空间连续性、多尺度解剖结构及正交方向依赖性的能力来增强其性能。具体而言，我们设计了两个关键组件：层次聚合增强（HAE）模块和结构连续性正交（SCO）模块。HAE模块通过并行多尺度卷积结合轻量级层次注意力机制来丰富多尺度特征表示；该注意力机制将通道调制与空间强调相结合，实现精确的边界定位和有效抑制无关背景区域。SCO模块通过沿水平和垂直轴执行正交轴向位移（AS），消除方向偏差，从而捕捉跨维度的空间依赖关系。该方法进一步采用轻量级卷积融合技术，以增强对称结构间的连续性并保留精细的解剖学细节。

本研究的主要贡献总结如下：

- 我们提出了一种新型HAE模块，旨在解决Mamba在建模层级化解剖特征方面的局限性。HAE将并行多尺度卷积与层级注意力机制相结合，能够在不同空间分辨率下捕捉特征，同时增强解剖学相关区域并保留结构边界。
- 我们引入SCO模块以克服Mamba模型的方向性偏差和空间不连续性。SCO在水平和垂直方向上均应用正交自适应稀疏化（AS），随后进行特征融合与上下文聚合，从而获得更一致的空间表征并提升结构保真度。
- 针对四个基准数据集（ISIC 2018、ISIC 2017、Synapse和ACDC）开展的大量实验表明，EccoMamba在多种评估指标上均展现出卓越的性能和强大的泛化能力。

相关工作

深度学习在医学图像分割中的应用

深度学习已成为医学图像分割领域的主流范式，基于卷积和注意力机制的架构在多种成像模态及解剖目标上均展现出优异性能。U-Net及其变体（如U-Net++（Zhou等人，2018）和Attention-U-Net（Zhu等人，2022））通过层次化特征提取和跳跃连接机制，有效捕捉了精细的空间细节。TransUNet（Chen等人，2024）将Transformer模块集成到U-Net编码器中以增强全局上下文建模能力；而Swin-UNet（Cao等人，2022）则利用Swin Transformer的层次化设计实现了更优的多尺度表征。UNetR（Hatamizadeh等人，2022）直接将ViT风格的编

码器应用于三维图像数据，实现了对体积空间依赖关系的端到端学习。TransBTS（Wang等人，2021）进一步探索了针对多模态融合的模式特异性注意力策略。SegFormer（Xie等人，2021）通过结合轻量级Transformer主干网络与紧凑的融合头，在准确性和效率之间取得平衡；DeiTUNet（Touvron等人，2021）则采用知识蒸馏技术提升了数据稀缺场景下的训练稳定性。尽管这些混合CNN-Transformer模型在建模长距离依赖关系方面非常有效，但它们通常具有较高的内存消耗，并且其长距离注意力机制可能存在不稳定性，这限制了它们在实际应用中处理高分辨率输入时的扩展能力。

状态空间模型

作为一种选择性状态空间模型，Mamba近期在视觉应用领域（包括医学图像分割）引起了广泛关注。多项最新研究探索了该模型在不同架构中的潜力：VM-UNet（Ruan、Li和Xiang，2024）将增强型注意力机制与多尺度融合相结合，显著提升了分割精度与效率；LightMUNet（Liao等人，2024）提出了轻量级Mamba模块，增强了其在资源受限环境中的适用性；Swin-UMamba（Liu等人，2024）将预训练的Swin Transformer与Mamba结合，提升了特征提取与泛化能力；MambaUNet（Wang等人，2024）采用纯视觉Mamba模块，更有效地处理复杂图像模式；UltraLight VM-UNet（Wu等人，2025b）采用并行Mamba分支架构，在保持皮肤病变分割性能竞争力的同时降低了参数开销；MTMamba（Lin等人，2024）设计了基于Mamba的解码器用于密集多任务分割，实现了多个子任务的一致性改进；MMRMamba（Zou等人）则进一步拓展了该模型的应用场景。2025年版本）采用了基于空间频率感知融合的Mamba算法，显著提升了多对比度MRI重建中的细节保留度与对比度一致性。

尽管取得了这些进展，Mamba仍存在固有的局限性。其单向序列结构难以捕捉医学图像中普遍存在的方向不变且对称的空间结构，这常常导致水平轴与垂直轴之间出现感知上的不对称现象。此外，由于缺乏明确的多尺度机制，该模型在建模不同尺寸器官间的语义差异方面能力受限，而这一点对于实现准确且稳健的医学图像分割至关重要。

方法

EccoMamba概述

如图1所示，EccoMamba基于受VM-UNet（Ruan、Li和Xiang 2024）启发的U型编码器-解码器架构构建。该架构将选择性状态空间建模与结构增强模块相结合，能够有效捕捉多尺度特征及空间依赖关系。




图1: (a) 所提出的EccoMamba架构概述; (b) 层级聚合增强 (HAE) 模块。 (c) 结构连续性正交 (SCO) 模块。 (d) 轴向位移 (AS) 通过应用正交位移 (水平与垂直方向) 及双卷积路径来模拟精细的空间依赖关系。

医学图像处理流程如下：输入图像首先通过块嵌入层转换为特征表示，随后由四阶段编码器进行处理，该编码器执行分层特征提取和渐进式下采样。每个编码器阶段均包含层级聚合增强（HAE）模块和视觉状态空间（VSS）模块。VSS模块利用选择性状态空间机制以线性计算复杂度建模长程依赖关系，从而高效捕捉全局上下文信息；HAE模块并行提取多尺度特征，并整合通道注意力与空间注意力机制以提升特征表征质量。为缓解Mamba模型固有的方向性偏差，其跳跃连接层额外配备了结构连续性正交（SCO）模块，该模块可沿水平和垂直方向执行轴向位移（AS）。在解码器中，特征图通过VSS模块进行渐进式上采样，并与经SCO优化的编码器特征融合，以恢复空间分辨率并生成最终分割输出。

层次聚合增强

医学图像通常呈现出高度多样的空间结构，其范围从精细的细胞图案到复杂的器官边界。这种多样性要求在保持空间连贯性的同时，能够捕捉不同尺度下的层级解剖特征。为应对这一挑战，我们推出了HAE模

块。

HAE模块首先沿通道维度将输入特征图 $X \in \mathbb{R}^{B \times H \times W \times C}$ 分割为两个相等的部分： $X_1, X_2 \in \mathbb{R}^{B \times H \times W \times (C/2)}$ ，其中 B 为批量大小， H 为高度， W 为宽度， C 为通道数。如图1(b)所示，HAE包含两个主要分支：多尺度卷积分支和层次注意力分支。在卷积分支中， X_1 进一步分为两条路径： $\tilde{x}_1$ 和 $\tilde{x}_2$ 。 $\tilde{x}_1$ 先经过 1×1 逐点卷积，随后通过深度可分离的 3×3 卷积（DWConv）和 GELU 激活函数来提取细粒度局部特征； $\tilde{x}_2$ 则经过 3×3 最大池化操作，再通过 1×1 卷积和 GELU 激活函数来聚合粗尺度上下文信息。两条卷积路径的输出被融合以形成 Y_1 。

输入的第二部分 X_2 会经过通道注意力和空间注意力处理。通道注意力首先应用全局平均池化和最大池化，得到 $F_{avg}(X_2)$ 和 $F_{max}(X_2)$ ，随后这些结果输入一个两层多层感知机（MLP）以生成通道权重：

$$W_{ca} = \sigma(\text{MLP}(F_{avg}(X_2)) + \text{MLP}(F_{max}(X_2))), (1)$$

$$X'_2 = X_2 \odot W_{ca},$$

其中 $\sigma(\cdot)$ 表示S形函数。

空间注意力模块沿**X92**的通道维度应用平均池化和最大池化,生成 $F_{avg}^{sp}(\mathbf{X92})$ 和 $F_{max}^{sp}(\mathbf{X92})$ 。将这些图拼接后通过一个 7×7 卷积层,得到:

$$W_{sa} = \sigma(\text{Conv}_{7 \times 7}(\text{Concat}[F_{avg}^{sp}(\mathbf{X92}), F_{max}^{sp}(\mathbf{X}'_2)]))。 \quad (2)$$

增强功能的具体实现如下:

$$\mathbf{Y}_2 = \mathbf{X}'_2 \odot W_{sa}。 \quad (3)$$

最终输出是通过将 $\mathbf{Y}_1$ 和 $\mathbf{Y}_2$ 拼接,并对原始输入应用残差连接得到的。

结构连续性正交模块

医学图像本质上沿解剖结构呈现出强烈的空间连续性。然而,传统的Mamba架构将二维特征图展平为一维序列,并采用单向处理方式,这会破坏空间连贯性并导致结构不连续性。SCO模块通过显式建模空间轴间的正交依赖关系来解决这一问题。

如图1(c)所示,输入 $\mathbf{X}$ 沿通道维度被分为两部分。每部分由不同的AS分支处理:其中一个使用 1×1 卷积实现高效的通道间交互,另一个则采用 3×3 卷积来捕捉更丰富的局部模式。在每个AS分支内(图1(d)),特征被投影为两个分量:一个水平位移,另一个垂直位移。零填充操作保持了原始空间尺寸。位移后的特征经过卷积并通过元素级加法进行融合,随后再进行第二次投影:

$$\begin{aligned} F_h &= \text{Conv}(\text{Shift}_h(F_1)), \\ F_v &= \text{Conv}(\text{Shift}_v(F_2)), \\ F_{AS} &= \text{Conv}_{1 \times 1}(F_h + F_v)。 \end{aligned} \quad (4)$$

两个AS分支的输出结果被合并并进一步优化:

$$\begin{aligned} F_{fused} &= F_{AS_{1 \times 1}} + F_{AS_{3 \times 3}}, \\ F_{out} &= \text{MLP}(\text{LayerNorm}(F_{fused})) + F_{fused}。 \end{aligned} \quad (5)$$

这种正交设计使SCO能够在保留解剖细节的同时更好地捕捉结构连续性。通过结合跨方向位移、双尺度卷积以及通道间交互作用,SCO有效降低了方向偏差,并增强了边界划分的清晰度。

损失函数

为提升多类别医学图像分割的性能,我们采用了一种由Dice损失和交叉熵损失组成的混合损失函数。交叉熵损失能确保像素级分类的准确性,而Dice损失则直接优化预测结果与真实标签之间的重叠度。总损失函数如下:

$$L_{total} = \lambda_{ce} \mathcal{L}_{ce} + \lambda_{dice} L_{dice}, \quad (6)$$

其中 λ_{ce} 和 λ_{dice} 用于平衡这两个组成部分的贡献。

实验

数据集

我们在四个公开可用的数据集上进行了大量实验,以评估所提出方法的有效性和鲁棒性。**ISIC 2017 和 ISIC 2018 数据集** (Milton 2019) 用于皮肤病变分割,分别包含 2,150 张和 2,694 张带有像素级标注的皮肤镜图像。对于**ISIC 2017**,数据按照官方协议被划分为 1,500 张训练图像和 650 张测试图像;而对于**ISIC 2018**,我们采用标准的 7:3 训练-测试划分比例,得到 1,886 张训练图像和 808 张测试图像。**ACDC 数据集** (Bernard 等人 2018) 专为自动心脏诊断开发,包含 100 名患者的 MRI 扫描图像,并配有右心室(RV)、左心室(LV)和心肌(MYO)的手动标注,数据划分为 70 个训练样本、10 个验证样本和 20 个测试样本。**Synapse 数据集** (Landman 等人 2015) 旨在实现多器官 CT 分割,包含来自 30 名受试者的八个器官标注数据,划分为 18 个训练样本和 12 个测试样本。

评估指标

所有方法在Synapse和ACDC数据集上的性能均采用Dice相似系数(DSC)和第95百分位Hausdorff距离(HD95)进行评估。对于ISIC 2018和ISIC 2017数据集,我们采用灵敏度(Sens)、特异度(Spec)、准确率(Acc)及DSC作为评估指标。

实施详情

所有模型均基于PyTorch实现,并在单块 NVIDIA RTX 4090 GPU上进行训练。我们采用AdamW优化器,其初始学习率为 1×10^{-3} ,权重衰减系数为 1×10^{-2} ,同时采用余弦学习率衰减策略。所有数据集的批量大小均统一设置为24。每个模型训练300个周期,并根据验证集DSC值选取最佳检查点。在Synapse数据集上进行推理时,采用滑动窗口策略以减少边界伪影;同时采用混合精度训练(AMP)技术以加速计算并降低内存占用。

与最先进方法的比较

我们将EccoMamba与来自三个类别的最先进(SOTA)方法进行比较。**基于U-Net的方法**包括MALUNet (Ruan 等人, 2022)、Attention Swin UNet (Aghdam 等人, 2023)、ASP-VM-UNet (Bao 等人, 2025)、MSCD -VM-UNet (Huang 等人, 2025)、LeViT-UNet-384 (Xu 等人, 2023)、UNetR (Hatamizadeh等人, 2022)以及TransClaw U-Net (Yao等人, 2022)。**基于Transformer的方法**包括TransUNet (Chen等人, 2024)、Swin-UNet (Cao 等人, 2022)、MISSFormer (Huang 等人, 2022)、SynergyNet (Gorade 等人, 2024)、MixFormer (Liu 等人, 2025a)、HiFormer-L (Heidari 等人, 2023)、CSWinUNet (Liu 等人, 2025b)和GLoG-CSUNet (Zarch 等人, 2025)。**基于Mamba的方法**包括VMUNet (Ruan, Li 和 Xiang, 2024)、HC-Mamba (Xu, 2024)、H-VmUNet (Wu等人, 2025a)以及CC-ViM (Zhu等人)。

方法	ISIC 2018				ISIC 2017			
	感知：DSC	感知：IoU	感知：F1	感知：DSC	感知：DSC	感知：IoU	感知：F1	感知：DSC
MALUNet	88.90	97.25	95.48	89.31	88.24	97.62	95.83	88.96
注意：Swin U-Net	80.57	98.26	94.80	85.40	84.92	98.47	95.91	88.59
UltraLight VM-UNet	88.32	95.96	93.86	88.76	85.02	98.11	96.14	86.89
LightM-UNet	88.29	97.65	95.55	88.98	87.04	97.74	95.95	87.80
HC-Mamba	88.90	97.08	94.84	89.26	86.99	97.47	95.17	88.18
VM-UNet	88.82	96.49	94.39	89.67	91.87	96.30	95.63	86.35
H-VmUNet	89.96	95.37	93.89	88.97	84.94	98.20	96.21	87.09
CC-ViM	88.74	97.32	95.23	90.06	88.70	97.19	95.60	88.74
MSCD-VM-UNet	89.71	97.05	95.26	90.21	90.44	97.23	95.92	88.78
ASP-VM-UNet	89.97	95.33	93.83	89.09	83.25	96.64	93.48	85.77
EccoMamba	90.84	96.82	95.17	91.18	88.60	98.29	96.84	89.39

表1： ISIC 2018与 ISIC 2017数据集分割性能对比。

2025年)。所有方法均在我们的实验条件下进行了复现与评估。

ISIC 数据集上的皮肤病变分割。如表1所示，EccoMamba在 ISIC 2018和 ISIC 2017两个数据集上均取得了最佳整体性能。在 ISIC 2018数据集上，其DSC值达到91.18%，比此前最佳方法（88.98%）高出2.20个百分点；在 ISIC 2017数据集上，EccoMamba同样实现了最高的 DSC 值（89.39%）和最高的分类准确率（96.84%），同时保持了具有竞争力的敏感性和特异性。这些结果表明，所提出的架构在多种成像条件下对复杂病变边界的分割尤为有效。

ACDC 数据集上的心脏分割。如表2所示，EccoMamba在 ACDC 数据集上取得了最高性能，DSC值达91.83%，优于VM-UNet（Ruan、Li 和 Xiang 2024）的91.04%。这些结果凸显了EccoMamba在保持分割一致性与准确性方面的强大能力，尤其在解剖结构复杂的区域表现突出。

Synapse数据集上的多器官分割。如表3所示，EccoMamba在多器官分割任务中取得了最高的平均DSC值（81.51%），同时HD95值为22.02，表现具有竞争力。该模型在大多数器官上均达到最佳或次佳性能，展现出对大小解剖结构的强大泛化能力。尤其值得注意的是，其在大型器官（如肝脏）和解剖结构复杂的区域（如胃部）上取得的高DSC分数，充分证明了所提出的模块在建模多尺度上下文信息和空间连续性方面的有效性。

我们进一步对所有测试对象的DSC评分进行了配对t检验。EccoMamba相较于所有基线模型均实现了具有统计学意义的改进（ $p < 0.01$ ），表明所观察到的提升并非由随机变异所致。

消融研究

表4中的消融研究揭示了HAE模块与SCO模块在 ISIC 2018数据集上的独立及协同贡献。引入HAE模块（Base+HAE）将DSC值从88.52%提升至90.42%，证明

方法	RV	MYO	LV	差示扫描量热法（DSC）	HD95
UNetR	85.29	86.52	94.02	86.61 ± 1.63	—
LeViT-UNet-384	89.55	87.64	93.76	90.32 ± 1.24	—
Swin-UNet	87.94	86.78	94.71	89.81 ± 1.11	1.32 ± 0.98
MISSFormer	86.36	85.75	91.59	87.90 ± 1.79	6.85 ± 0.21
SynergyNet	87.68	86.60	95.06	89.78 ± 1.28	1.50 ± 0.07
TransNet	88.86	84.54	95.73	89.71 ± 1.15	1.82 ± 0.06
VM-UNet	88.44	89.22	95.45	91.04 ± 1.12	1.30 ± 0.95
混合前体	89.02	88.46	95.55	91.04 ± 1.07	1.42 ± 0.21
GLoG-CSUNet	86.63	88.36	94.87	89.95 ± 1.26	4.14 ± 0.18
EccoMamba	89.91	89.71	95.87	91.83 ± 1.06	1.37 ± 0.11

表2： ACDC 数据集分割性能对比。




图2： EccoMamba与其他模型在 ISIC 2017数据集上的可视化对比。真实标注结果以蓝色等高线表示，分割结果则以红色显示。

其能有效捕捉多尺度上下文信息并优化模糊的病灶边界；加入SCO模块（Base+SCO）后DSC升至90.22%，表明该模块可增强空间连续性，并在解剖结构清晰的区域实现更精准的病灶定位。当两个模块整合到完整的EccoMamba模型中时，DSC达到91.18%，证实了HAE与SCO在生成更精确且结构连贯的分割结果方面的互补优势。

分割结果的可视化

为更直观地比较分割性能，我们在 ISIC 2017数据集上对EccoMamba及若干代表性模型的结果进行了可视化展示（见图2）。可视化结果表明：EccoMamba生成的分割轮廓更为精确、平滑，与真实标注的一致性更高，尤其在病变边界模糊或难以辨别的复杂场景中表现突出。与其他方法相比，EccoMamba展现出更强的轮廓对齐能力及更精细的结构描绘效果，充分体现了其在不同类型病变中保持解剖学一致性方面的卓越优势。

方法	主动脉	胆囊	肾脏（左）	肾脏(R)	肝脏	胰	脾脏	胃	DSC（%）	HD95
TransDeepLab	86.02	68.17	81.66	78.72	93.41	60.67	85.12	75.53	78.66 ± 1.71	29.38 ± 1.92
UNetR	89.80	56.30	85.60	84.52	94.57	60.47	85.00	70.46	78.34 ± 1.68	18.59 ± 1.74
TransClaw U-Net	85.87	61.38	84.83	79.36	94.28	57.65	87.74	73.55	78.08 ± 1.59	26.38 ± 1.83
LeViT-UNet-384	87.33	62.23	84.61	80.25	93.11	59.07	88.86	72.76	78.53 ± 1.43	16.84 ± 1.64
Swin-UNet	85.71	66.08	82.73	78.46	93.90	58.90	88.83	76.23	78.86 ± 1.39	24.80 ± 1.72
HiFormer-L	85.84	65.20	83.07	78.87	93.79	59.08	91.00	80.76	79.70 ± 1.41	20.82 ± 1.66
TransNet	87.22	60.04	81.92	76.39	94.41	54.54	84.72	76.19	76.93 ± 1.48	30.18 ± 1.94
VM-UNet	88.17	69.51	84.35	80.95	93.57	62.17	88.45	76.21	80.42 ± 1.40	24.84 ± 1.78
CC-ViM	85.90	67.44	85.86	80.85	94.13	62.06	89.10	79.58	80.62 ± 1.44	29.39 ± 1.83
SWMA-UNet	86.04	68.84	86.97	82.60	94.19	57.33	89.82	78.05	80.48 ± 1.42	18.30 ± 1.73
CSWin-UNet	87.13	63.89	82.54	78.94	94.64	64.05	88.38	80.66	80.03 ± 1.39	26.74 ± 1.76
GLoG-CSUNet	88.21	70.44	81.67	80.55	93.33	61.45	88.24	80.37	80.53 ± 1.41	24.12 ± 1.74
EccoMamba	87.43	72.01	83.82	81.01	95.29	60.64	90.18	81.67	81.51 ± 1.32	22.02 ± 1.71

表3：Synapse数据集上的分割性能比较。结果为三次独立运行的平均值（均值±标准差）。




图3：EccoMamba与其他模型在Synapse数据集上的可视化对比。红色方框标出了EccoMamba分割结果更为准确的区域。

图3展示了EccoMamba与其他竞争模型在Synapse数据集上的视觉对比结果。红色方框标出了包含解剖结构复杂器官的区域，例如肾脏、胰腺和胆囊。EccoMamba始终能生成更平滑的边界和更精确的形态，尤其在对比度较低或结构存在模糊性的区域表现尤为突出。例如，在第一行图像中，该模型准确区分了左右肾脏，并实现了精准的肝脏轮廓勾勒。相比之下，其他模型则出现了边界偏移和分割伪影现象，这充分证明了EccoMamba在模拟空间连续性及捕捉解剖结构方面的卓越性能。

图4展示了在 ACDC 数据集上的视觉对比结果。即使在边界模糊、组织形态复杂或结构紧密堆积的区域，EccoMamba仍能准确勾勒出左心室（LV）、右心室（RV）和心肌组织（MYO）等心脏结构。相比之下，其他模型则存在轮廓不连续或对齐偏差等问题。然而，EccoMamba在结构连续性和空间对齐方面表现更优，进一步验证了所提出的空间增强模块的实际效能与稳健性。

	感官：感觉	说明书	账户	视觉扫描质量 (DSC)
基础	86.63	96.56	93.84	88.52
Base+HAE	90.51	96.34	94.74	90.42
Base+SCO	90.57	96.15	94.62	90.22
EccoMamba	90.84	96.82	95.17	91.18

表4：EccoMamba在 ISIC 2018数据集上的消融研究。




图4：ACDC 数据集上的分割结果。红色方框标出了 EccoMamba 预测更为准确的区域。




图5：HAE模块的分阶段部署分析。

HAE模块的分阶段部署

为探究层次聚合增强（HAE）模块的最佳部署位置，我们开展了在不同位置应用HAE的实验：(1)编码器与解码器阶段均集成HAE；(2)仅解码器阶段集成HAE；(3)仅编码器阶段集成HAE。实验结果表明，仅编码器配置实现了最佳性能：在 ISIC 2018数据集上DSC得分为91.18%，在 ISIC 2017数据集上得分为89.39%，均优于编码器-解码器组合配置（90.51%和88.55%）及仅解码器配置（89.48%和88.76%）。这表明编码阶段的早期层次特征增强对实现最优分割性能至关重要。

方法	参数	浮点运算次数	记忆力
MISS Former（2023）	42.46M	7.28G	0.56 GB
LeViT-UNet-384（2023）	39.13M	2.25G	0.26 GB
Swin-UNet（2023）	27.17M	5.95G	0.31 GB
nn Former（2023）	150.05M	704.23G	7.09 GB
HiFormer-L（2023）	25.51M	17.81G	0.42 GB
TransNet（2024）	105.28M	593.00G	7.55 GB
VM-UNet（2024）	27.43M	3.15G	0.42 GB
H-VmUNet（2024）	8.97M	0.57G	0.35 GB
ULVM -UNet（2024）	0.18M	0.06G	0.15 GB
CSwin-UNet（2025）	23.57M	4.72G	0.31 GB
GLoG-CSUNet（2025）	40.62M	8.43G	0.58 GB
EccoMamba	38.30M	6.22G	0.63 GB

表5：模型参数及计算复杂度。

内存与计算效率

我们从参数数量、浮点运算次数（FLOPs）和内存消耗三个维度评估了EccoMamba的效率。如表5所示，EccoMamba需要3830万个参数、6.22 GFLOPs的运算能力及0.63 GB内存，实现了精度与复杂度之间的良好平衡。与 nnFormer（Zhou 等人，2023）和 TransUNet（Chen等人，2024）等复杂模型相比，EccoMamba不仅效率显著提升，其分割精度也更优。尽管超轻量设计（如 ULVM -UNet（Wu等人，2025b））的参数量和 FLOPs更少，但其精度低于EccoMamba，这表明我们的设计在性能与计算成本之间取得了更为均衡的平衡。

结论

在本文中，我们推出了EccoMamba——一个医学图像分割框架，该框架整合了两个关键组件：层次聚合增强（HAE）模块和结构连续性正交（SCO）模块。HAE模块通过并行多尺度卷积运算及轻量级注意力机制，在多个尺度上捕捉解剖特征，从而实现从精细到粗略的层次化表征；SCO模块则通过应用正交轴向位移（AS）来增强空间连续性，这些位移能够建模跨维度依赖关系并强化结构一致性。

针对四个基准数据集的大量实验验证了EccoMamba的有效性。具体而言，在 ISIC 2018、ISIC 2017、Synapse和 ACDC 上的评估表明，与现有最先进方法相比，我们的方法始终展现出更优的分割精度和鲁棒性。这些结果凸显了所提出的架构设计的实际价值及其在医学图像分析领域更广泛应用的潜力。

致谢

本研究获得中国国家自然科学基金（项目编号：62302156、62402351、62402349、62572401及62201460）和自然科学基金的资助。