

基于希尔伯特曲线的注意力机制：实现保持拓扑结构的图像张量表示，适用于语义分割网络

徐连刚¹、李刚^{1,2,3,4*}、宋悦^{1,2,3}、纪向新¹

¹同济大学上海智能自主系统研究所

²同济大学电子与信息工程学院

³国家自主智能无人系统重点实验室

⁴上海智能科学技术研究院

2410299@tongji.edu.cn lig@tongji.edu.cn

摘要

基于无人机的建筑缺陷分割仍面临诸多挑战，这主要源于复杂的表面纹理和光照变化。我们提出了TPSeg-former——一种保持拓扑结构的分割框架，可有效缓解此类场景下的错误分割问题。其解码器采用基于希尔伯特曲线的拓扑保持机制，在类别层计算过程中维持空间连续性和边界精度；轻量级多尺度融合模块提升了语义表征能力，而全局上下文建模则增强了整体感知效果。在建筑缺陷数据集上的实验表明，TPSeg-former性能优于现有分割方法，达到80.77%的mIoU和90.22%的准确率；在Dac10k数据集上，该模型展现出强大的泛化能力，在不同材质和缺陷类型下均实现44.27%的mIoU和60.32%的准确率。相关代码可访问<https://github.com/mumu-k/TPSegformer>获取。

1. 引言

尽管在自动驾驶、医学影像及无人机（UAV）应用领域的语义分割技术已取得显著进展，但将这些方法应用于建筑缺陷检测仍面临诸多挑战。无人机拍摄的建筑表面通常包含异质材料、复杂结构以及剧烈的光照或视角变化，导致裂纹、剥落层和苔藓生长等相互交织的缺陷难以准确分割[16, 22]。例如，在特定光照条件下，石材纹理可能模拟出裂纹形态，从而引发误检。Konior等人[13]研究发现材料特性与缺陷特征之间存在显著关联，但大多数模型未能充分考虑这些关系，从而限制了其在实际无人机检测场景中的鲁棒性

*通讯作者。




图1.不同空间遍历策略的比较。本文对比了三种映射方法——希尔伯特曲线法、行优先法和Z序法。其中希尔伯特曲线法能最佳地保持图像拓扑结构，有效减少误分割现象。

和泛化能力。

为缓解错误分割问题，近期研究通过架构优化提升了语义分割性能。部分研究采用多阶段上采样及编码器-解码器融合技术改进解码器，以获得更精确的预测结果[1, 15, 20]，但其复杂性与高计算需求限制了无人机的应用场景；另一些研究则利用先进的骨干网络[26]或特征精炼模块[35]增强上下文建模能力。最新研究表明，自注意力机制已实现优异的上下文建模效果[2, 12, 37]，但多数方法仍依赖行优先遍历进行特征展开，这会破坏空间连续性并削弱结构感知能力。

为应对这些挑战，我们提出了TPSegformer——一种轻量级且精度高的基于无人机的建筑缺陷分析分割网络。该网络将Swin Transformer-Tiny主干网络[17]与定制化的轻量化解码器（TPDecoder）相结合，以平衡准确性和效率。TPDecoder通过融合多尺度特征提升语

义一致性，并采用自注意力机制建模类别间依赖关系，从而降低分类混淆率。为保持空间结构完整性，我们引入了基于希尔伯特曲线的索引策略进行降维处理，在特征变换过程中保持拓扑连续性（如图1所示）。与Z序曲线等传统遍历方法相比，该方法在复杂缺陷分割场景中展现出更优的空间连贯性与鲁棒性。

最后，鉴于建筑结构缺陷分割领域目前数据集较为匮乏，本研究基于BD3建筑缺陷分类数据集[14]重建了一个分割数据集。该新数据集涵盖了三种典型缺陷类型（裂缝、剥落和苔藓）以及两大主要材料类别（石灰和石材）。利用该数据集，我们对TPSegformer进行了系统性评估，充分验证了其在真实建筑环境中的鲁棒性、准确性和泛化能力。

我们的主要贡献如下：

- **拓扑保持型轻量级解码器（TPDecoder）**：一种创新解码器，融合语义增强与高低特征融合技术，并采用基于希尔伯特曲线的遍历策略以保留空间拓扑结构，并通过注意力建模强化类间关联。结合Swin Transformer主干网络后，可实现高精度、低延迟的分割结果，非常适合用于基于无人机的建筑缺陷检测。
- **对希尔伯特曲线优势的全面验证**：理论与实验分析均表明，相较于传统的行优先遍历方法，希尔伯特曲线能更好地保持空间连续性并增强特征相关性，从而提升分割的鲁棒性和泛化能力。
- **高质量建筑缺陷分割数据集的开发**：基于BD3数据集，构建了一个包含标注缺陷类别（裂缝、剥落、苔藓）及材料分类的新分割数据集，为建筑缺陷分析提供了可靠的基准。

2. 相关工作

2.1. 分割解码器

编码器设计在从压缩后的编码器特征中重建细粒度分割结果方面起着关键作用，主要涉及特征重建、细节恢复以及多尺度上下文融合。

特征重建技术通过转置卷积或插值方法，逐步从低分辨率特征中恢复高分辨率预测结果。例如，TransU-Net[2]将基于Transformer的上下文建模与转置卷积相结合以提升空间分辨率；细节重建则依赖跳跃连接从浅层特征中提取空间信息——U-Net[20]率先采用了这一思路，而Zhang等人[33]则通过双跳跃上采样融合模块

（DSUFM）引入了双跳跃连接机制以优化特征传播效果。

多尺度上下文融合技术能够整合局部与全局特征。PSPNet[35]采用金字塔池化方法，DeepLab[3–5]使用扩张卷积[32]，而HRNet[26]则通过并行分支结构维持多分辨率表征。近期基于Transformer的方法（如ViT[7]和SegFormer[28]）则通过层次化标记嵌入及基于MLP的融合机制实现类似效果。

尽管这些解码器效果显著，但在长距离依赖建模方面存在困难，这促使近期研究中引入自注意力机制。

2.2. 自注意力

自注意力模型通过计算空间相关性来捕捉全局依赖关系[34]。该机制最初提出于Transformer架构[25]，并已被广泛应用于计算机视觉领域，以克服卷积神经网络（CNN）在捕捉长距离依赖关系方面的局限性。

然而，该算法对输入尺寸的二次复杂度会导致在密集特征图上产生较高的计算成本。为缓解这一问题，Tay等人[23]提出了稀疏注意力机制，将计算范围限制在局部或语义相关的区域；而Lin等人[15]则采用了移位窗口策略以实现高效的跨区域交互。

后续研究主要致力于提升模型效率与特征区分能力。Zhang等人[38]开发了注意力感知模块（AAM）以突出关键信息区域；Yin等人[30]则提出采用双解码器结构的区域自注意力机制（RSA），以实现更精细的语义区分。

然而，目前鲜有方法能在注意力计算过程中保持空间拓扑结构——这对于在复杂结构环境中实现精确的缺陷定位至关重要。

2.3. 填充空间的曲线

空间填充曲线建立了单维序列与多维空间之间的映射关系。1890年，皮亚诺提出了第一种此类曲线；随后希尔伯特提出更为实用的希尔伯特曲线[11]。后来，Z序曲线[18]通过交错排列二进制坐标实现空间遍历，成为高维数据映射中广泛采用的索引策略。

由于其空间连续性和拓扑保持特性，填充曲线已被广泛应用于图像处理领域。Tsinganos等人[24]将sEMG信号通过希尔伯特曲线转换为图像，用于基于CNN的手势识别；而其他研究[6, 21]则采用类似的映射方法进行图像混淆和加密，以增强结构完整性和安全性。

在语义分割领域，Zheng等人[36]首次将希尔伯特曲线引入自注意力机制中。




图2.所提出的分割网络架构总体示意图。(a) 采用Swin-Tiny作为分割网络的骨干网络，实现多尺度特征提取。(b) 特征增强：在解码初期阶段，采用双分支结构分别增强特征图的语义维度与空间维度。(c) TP解码器：将多分辨率特征图进行融合后，用于计算各类别特征层之间的相关性。

取代传统的行优先遍历方法以提升拓扑建模精度。然而，其研究缺乏对不同曲线类型的系统性比较以及对其对注意力机制影响的理论分析，有待进一步探索。

综上所述，现有研究分别处理解码器设计、注意力建模和空间编码问题，而多尺度融合、类间相关性及拓扑结构保留等核心问题仍未得到解决。TPSegformer通过语义增强、拓扑感知注意力机制以及基于曲线的索引技术，有效解决了这些不足，实现了稳健的建筑缺陷分割。

3. 保持拓扑结构的分割网络

3.1. 网络框架

分割网络的完整架构如图2所示。

所提出的分割网络基于三项核心原则设计——精度、轻量级架构及计算效率——以实现对无人机采集图像的有效语义分割。

在特征提取方面，采用Swin Transformer-Tiny变体作

为骨干网络，以平衡表征精度与计算效率。作为一种分层视觉变换器，Swin将特征图划分为非重叠且偏移的窗口，有效降低计算复杂度的同时提升多尺度表征能力。

与传统的基于CNN的骨干网络相比，该模型在建模长距离依赖关系和捕捉全局上下文信息方面表现出更强的能力，从而提高了分割精度。

主干网络通过连续下采样输出四个特征图： $X_1 \in \mathbb{R}^{B \times C \times 128 \times 128}$ 、 $X_2 \in \mathbb{R}^{B \times C \times 64 \times 64}$ 、 $X_3 \in \mathbb{R}^{B \times C \times 32 \times 32}$ 、 $X_4 \in \mathbb{R}^{B \times C \times 16 \times 16}$ ，其中 B 和 C 分别表示批量大小和通道数。

为提升解码性能，双分支特征增强模块分别提取语义信息与空间信息，并通过像素级乘法运算将二者融合以强化有意义的表征。在解码器中，多分辨率融合策略整合了来自 X_3 和 X_4 的增强特征，恢复精细边缘并生成类别特定层。随后计算这些层之间的相关性以建模类间关系。最后，基于填充曲线的拓扑保持型降维方法在相关性计算过程中保持结构一致性，从而增强

空间连续性并提升注意力模型的质量。

3.2. 保持拓扑结构的解码器

TPDecoder包含两个主要阶段：特征增强阶段以及解码与预测阶段。




图3.双分支特征增强。双分支设计同时捕捉全局语义信息与局部空间特征，显著提升了中间特征的表达能力。

特征增强。在主干网络完成特征提取后，细粒度细节可能会丢失，从而降低分割精度。为缓解这一问题，我们引入了一个基于ECANet[27]的特征增强模块，并额外添加了一个空间分支。该模块联合融合通道注意力机制与空间上下文信息，使网络能够聚焦于关键区域，如图3所示。

通道注意力分支遵循ECANet的设计架构。全局平均池化（GAP）首先生成通道级描述符，该描述符经过一维卷积层和Sigmoid激活函数处理后得到通道权重：

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j), \quad c = 1, 2, \dots, C, \quad (1)$$

$$w = \sigma(\text{Conv1D}(z)), \quad (2)$$

其中 X 表示输入特征图， σ 为Sigmoid函数。

空间分支层首先应用一个 3×3 卷积层，随后依次通过ReLU激活函数和批量归一化处理，以提取通道注意力机制常难以捕捉的局部纹理与边缘特征。

$$F_s = \text{BN}(\text{ReLU}(\text{Conv3} \uparrow^3(X))), \quad (3)$$

最终输出结果通过逐元素乘法运算获得：

$$X_{out} = F_s \odot w, \quad (4)$$

其中 $\odot$ 表示通道级乘法。

这种融合方法在保留全局语义线索的同时，强化了局部结构表征，从而提升了特征的表达力与区分度。

解码与预测。所提出的解码框架包含两个模块：高低特征融合模块（HLFF）和轻量级相关计算模块（LCCM），如图4所示。这两个模块协同工作，融合多分辨率特征并提升语义一致性，从而实现精确分割。




图4.保持拓扑结构的解码器。该双模块设计融合了多尺度特征，并建模拓扑感知相关性，以实现精确且稳健的分割效果。

HLFF 模块从主干网络中获取高分辨率特征图 $X_h \in \mathbb{R}^{B \times C1 \times H1 \times W1}$ 和低分辨率特征图 $X_l \in \mathbb{R}^{B \times C2 \times H2 \times W2}$ 。将低分辨率特征图像上采样至与 X_h 相同的尺寸，并沿通道维度拼接，形成 $X_{cat} \in \mathbb{R}^{B \times (C1+C2) \times H1 \times W1}$ 。为保持模型轻量化，融合过程采用深度可分离卷积：先使用 3×3 深度卷积进行空间特征提取，再通过 1×1 点卷积实现通道压缩。最终融合后的特征通过 3×3 卷积生成类别特定的特征层。

该 LCCM 在这些类别特定层之间引入了相关性建模。HLFF 输出经三个并行卷积分支处理，分别生成查询图（ Q ）、键图（ K ）和值图（ V ），随后进行降维处理。研究探索了三种映射策略：希尔伯特曲线遍历法、行优先遍历法以及Z序遍历法。

$$\mathcal{H}(x, y) = \sum_{k=0}^{n-1} 2^{2k} f_k(\text{bit}(x, k), \text{bit}(y, k)), \quad (5)$$

$$R(x, y) = x \times W + y, \quad (6)$$

$$\mathcal{Z}(x, y) = \sum_{k=0}^{n-1} [\text{bit}(x, k) 2^{2k} + \text{bit}(y, k) 2^{2k+1}], \quad (7)$$

所有三种映射均作用于二维坐标 $(x, y) \in [0, 2^n - 1]^2$ to a 1D index $h \in [0, 2^{2n} - 1]$ 。希尔伯特曲线[11]能保持局部空间连续性，在展平过程中有效减少拓扑畸变；而另外两种映射则用于消融效果的对比分析。

经过降维处理后， Q 与 K 计算类别间相似度，该相似度经Softmax归一化并由 V 加权。融合后的表示通过通道扩展和Sigmoid激活函数进行优化以生成注意力权重，这些权重通过元素级乘法调节类别特定层，最终得到增强型分割输出结果。

3.3. 辅助监督机制

为提升中间特征的判别能力，我们在SwinTransformer最后一阶段生成的输出特征图 X_3 上引入了辅助监督机制。该辅助分支采用包含五个卷积层的轻量级FCN头网络，其输出结果通过双线性插值放大至原始图像分辨率，并利用联合辅助损失函数进行优化，从而促进语义一致性并增强中间特征层面的边界学习效果。

联合辅助损失函数结合了Dice损失以及基于Sobel边缘检测的边缘感知损失：

$$\text{劳克斯} = \lambda \cdot \mathcal{L}_{\text{Dice}} + \lambda_{\text{edge}} \cdot L_{\text{Edge}}, \quad (8)$$

其中 λ_{dice} 和 λ_{edge} 为平衡因子。

Dice损失通过最大化预测结果与真实标签之间的重叠度来缓解类别不平衡问题：

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N p_i g_i}{\sum_{i=1}^N p_i^2 + \sum_{i=1}^N g_i^2 + \epsilon}, \quad (9)$$

其中 p_i 和 g_i 分别表示预测概率与独热编码的真实标签，且 $\epsilon = 10^{-3}$ 可避免除零错误。

为提升边缘定位精度，边缘感知损失函数采用Sobel算子提取梯度幅值图：

$$\mathcal{L}_{\text{Edge}} = \alpha \cdot \sqrt{\nabla p \cdot \nabla g}, \quad (10)$$

$$\begin{aligned} \nabla p &= \sqrt{(p \otimes K_x)^2 + (p \otimes K_y)^2}, \\ \nabla g &= \sqrt{(g \otimes K_x)^2 + (g \otimes K_y)^2}, \end{aligned} \quad (11)$$

其中 K_x 和 K_y 为Sobel核， ∇ 表示深度卷积。

这种联合监督机制明确指导网络主干学习细粒度的结构与边界信息，从而稳定训练过程并提升整体分割性能。

4. 实验

所有实验均在配备 NVIDIA GeForce RTX 4090 显卡（24GB显存）、Python3.8及PyTorch2.0.0+ CUDA 11.8的Linux工作站上完成。模型训练采用AdamW优化器，初始学习率为 6×10^{-5} ， $\beta=(0.9, 0.999)$ ，权重衰减系数设为0.01；为实现细粒度优化，采用了参数级配置策略：位置编码层与归一化层权重衰减系数设为零以保持模型稳定性，而解码器参数则采用10倍学习率乘数加速收敛。该设置有效稳定了训练过程并提升了整体学习效率。

表1. 通过局部性损失分析拓扑一致性。

方法	命令					
	2	3	4	5	6	7
先行处理	42	406	3630	30814	254142	2064766
希尔伯特曲线	15	63	255	1023	4095	16383
Z级订单	30	190	1086	5758	28926	139774

表2. 二维降维方法的运行时间比较（秒）。

方法	尺寸				
	8 × 8	16 × 16	32 × 32	64 × 64	128 × 128
先行处理	0.000000	0.000000	0.000000	0.000998	0.009974
希尔伯特曲线	0.000470	0.000999	0.005985	0.032912	0.130650
Z级订单	0.000000	0.000997	0.002991	0.010970	0.058365

4.1. 空间遍历策略的比较

本实验比较了三种降维策略——行优先法、希尔伯特曲线法和Z序遍历法——在二维图像展平过程中对拓扑结构的保留效果及计算成本的影响。

为评估空间信息损失，采用了一种局部损失度量指标，该指标测量扁平化序列中相邻元素相对于其二维位置之间的欧几里得距离：

$$\mathcal{L}_{\text{local}} = \sum_{i=1}^{N-1} \sqrt{p(i) - p(i+1)}^2, \quad (12)$$

其中 $p(i)$ 表示原始二维空间中第 i 个像素的坐标。

如表1所示，希尔伯特曲线实现了最低的局部性损失，表明其对二维空间连续性的保持能力最为优异；Z-Order方法表现中等；而Row-First方法的拓扑一致性最差。

如表2所示，Row-First算法实现了最快的运行时间，而希尔伯特曲线算法的计算成本较高。总体而言，希尔伯特遍历法在保持最佳拓扑结构的同时具有适中的开销，因此适用于对结构完整性要求严格且时间成本可接受的低分辨率特征图场景。

4.2. 与现有方法的比较

本研究中使用的分割数据集是从BD3分类数据集重建而来，并按5:1:1的比例划分为训练集、验证集和测试集。为评估分割性能，将TPSegformer与六种代表性网络进行了比较——CCNet[12]、SegFormer[28]、BiSeNetV2[31]、DDRNet[19]、PIDNet[29]以及DSNet[9]。定量结果如表3所示。

如表3所示，TPSegformer在所有类别中均持续优于所有基线方法，在裂隙、剥离物、苔藓和石灰岩类别中均达到最高准确率。其mIoU值为80.77%，ACC值为90.22%，超越了现有最佳性能。

表3. 不同分割网络在BD3数据集上的性能比较。缩写说明：
Fiss.—裂隙；Peel.—剥离；Moss.—苔藓。

方法	裂纹。剥离。苔藓。酸橙 石头					mIoU	会计事务所
CCNet[12]	53.86	81.21	60.03	94.83	70.90	72.17	82.53
SegFormer[28]	50.60	72.49	57.35	95.99	93.72	74.03	86.43
BiSeNetV2[31]	45.11	65.43	58.70	94.43	78.00	68.33	77.50
DDRNet[19]	48.68	44.99	54.95	87.81	78.36	62.96	88.49
PIDNet[29]	55.90	78.60	55.37	95.07	79.71	72.93	84.27
DSNet[9]	48.17	64.73	32.81	93.22	78.73	63.53	80.91
我们的；我们的	59.98	91.11	72.58	96.71	83.44	80.77	90.22

表4. TPSegformer内展平曲线的比较。

方法	mIoU (%)	准确率 (%)
先行处理	75.58	86.37
Z 级订单	77.89	88.00
希尔伯特曲线	79.49	89.51

以明显优势超越竞争对手。这一改进源于高-低特征融合模块与逐层相关计算模块之间的协同作用，二者共同提升了多尺度特征整合能力及空间拓扑结构的保留效果。

尽管 SegFormer 在石质类别上取得了最佳结果（93.72%），但其整体性能稳定性较差。BiSeNetV2 和 DDRNet 在复杂纹理（如剥落表面）上的表现不佳，而 DSNet 的泛化能力较弱（mIoU 仅为 63.53%），这进一步证实了 TPSegformer 在复杂多类别分割场景中的鲁棒性优势。

4.3. 消融实验

在本节中，我们分析了 TPSegformer 各关键组件的有效性，重点探讨：(1)TPDecoder 中不同降维曲线的影响；(2)TPDecoder 与各类骨干网络的兼容性；以及(3)联合辅助损失函数中超参数设置的影响。

TPDecoder 内部空间平展方法的比较。我们采用三种平展策略——Row-First、ZOrder 和 Hilbert 曲线遍历——评估 TPDecoder 的分割性能，以分析空间拓扑结构保持的影响。模型主干固定为 Swin Transformer-Tiny，并使用交叉熵损失函数。

如表 4 所示，希尔伯特曲线实现了最高的 mIoU 和 ACC 值，证实了在平坦化过程中保留空间拓扑结构能够提升注意力建模效果和分割精度。

主干架构对 TPDecoder 性能的影响。为评估 TPDecoder 的适应性，我们将其与三种代表性主干网络集成——HRNet（表 5）、与 HRNet 集成的 TPDecoder 评估、ResNet 以及 Swin Transform-

er。

脊梁骨	变体	mIoU (%)	准确率 (%)
HRNet[26]	HRNet18	78.29	83.63
	HRNet48	79.72	85.73
ResNet[10]	ResNet18	73.44	84.28
	ResNet34	78.00	87.91
	ResNet50	79.00	88.09
	ResNet101	78.22	86.87
斯温变压器[17]	斯温- T	79.49	89.51
	斯温- B	80.42	88.57
	斯温- L	81.37	90.02

使用 ResNet 和 Swin Transformer 模型，并评估其在 BD3 数据集上的分割性能。

如表 5 所示，Swin Transformer 系列模型整体性能最佳，其次为 HRNet，而 ResNet 的表现最差。值得注意的是，Swin-Tiny 模型的性能已与较大的 HRNet 及 ResNet 变体相当，充分体现了效率与精度之间的优异平衡。这些结果证实了 Swin Transformer 是 TPSegformer 中一种高效且可扩展的骨干网络选择方案。




图5. 模块层面针对特定类型建筑缺陷的关注分布。关注图显示，随着解码过程从 SEM 阶段进展至 LCCM 阶段，TPSegformer 对缺陷边界的关注度逐渐增强。

联合辅助监督中的超参数设置实验。为确定联合辅助损失函数的最佳配置，我们在以 Swin Transformer-Tiny 作为骨干网络的基础上，对 λ_{dice} 与 λ_{edge} 的不同组合在 BD3 数据集上进行了评估。结果如表 6 所示。

如表 6 所示，引入联合辅助损失函数能持续提升分割性能。最佳结果出现在 $\lambda_{dice}=0.5$ 且 $\lambda_{edge}=1.0$ 时，TPSegformer 模型的 mIoU 值达到 80.77%，ACC 值达到 90.22%，这证实了所提出的辅助损失函数的有效性。




图6.测试集上的分割结果。可视化对比表明TPSegformer具有更高的准确率和泛化能力，尤其在精细缺陷定位和边缘保留方面表现突出。

表6. 不同超参数组合下联合辅助损失的性能表现。

$\lambda_{\text{散子}}$			$\lambda_{\text{边}}$			指标（百分比）	
0	0.5	1	0	0.5	1	mIoU	会计事务所
✓			✓			79.49	89.51
	✓			✓		78.23	85.26
		✓			✓	79.83	85.48
✓					✓	79.82	89.4
	✓			✓		79.06	88.15
		✓			✓	79.22	87.52
✓					✓	79.84	86.46
	✓				✓	80.77	90.22
		✓			✓	79.56	87.1

一、监督。

4.4. 可视化实验

我们通过三项可视化实验验证TPSegformer的效能与实用性：首先生成注意力热图，直观展示TPDecoder各模块间的关注点分布；其次对比多网络的分割结果，凸显TPSegformer的独特优势；最后开展真实无人机视频实验，TPSegformer能精准识别建筑缺陷，充分证明其鲁棒性及实际应用潜力。

热图可视化。为说明不同TPDecoder模块如何关注建筑缺陷，我们针对三种缺陷类型绘制了注意力热图，如图5所示。

如图5所示，解码器逐步聚焦于缺陷区域。在SEM阶段，注意力分布较为粗略，部分缺陷未能被检测；在HLFF阶段，注意力增强，更多区域得以准确识别；最后，在LCCM阶段，激活信号高度集中于缺陷边界处，从而实现更精确的定位和更强的类别区分能力。

分割可视化分析。为进一步评估TPSegformer的视觉性能，我们使用训练好的模型权重在BD3数据集的测试集上生成了分割结果。

如图6所示，大多数竞争性网络由于空间拓扑结构保留不足以及多尺度上下文整合能力欠缺，普遍存在结构不连续性和边界模糊性问题。BiSeNetV2、DSNet和SegFormer在材料分割方面表现尤为明显，尤其在区分石灰与石材时存在严重错误；尽管DDRNet和PIDNet采用了增强型边缘监督机制，仍无法实现精确的边界划分；而CCNet在裂缝定位方面的表现则较差。

TPSegformer通过一种基于希尔伯特曲线的拓扑保持机制（该机制在特征展平过程中能维持空间邻接关系）以及一个高低特征融合模块（可增强多尺度语义表征），有效克服了上述局限性。这种设计实现了一致的全局-局部相关建模，从而实现精准的缺陷定位、平滑的边缘处理，并显著提升对复杂建筑表面的鲁棒性。

实地测试。为验证实际应用可行性，使用大疆Mavic 3 Pro无人机对实验现场进行视频拍摄。所采集数据采用TPSegformer软件进行视觉分割处理，如图7所示。




图7.基于无人机采集影像的现场验证。实地实验表明，TP-Segformer在真实的无人机飞行条件下仍能保持稳定的分割性能，证实了其实际应用可行性。

表7. TPSegformer与六种网络模型在Dac110k指标上的性能比较。

方法	裂缝	ACrack	湿润斑	花纹锈蚀	岩石袋	空腔区域	腔体剥落	涂鸦风化	支撑模板	暴露钢筋	承重接缝	排水设备	JTape	WConcor	mIoU	ACC					
DSNet[9]	0.00	8.64	9.82	20.03	32.51	2.04	37.01	23.48	25.22	53.31	48.57	17.67	3.87	59.74	36.97	25.48	66.15	21.8	7.41	26.30	38.32
PIDNet[29]	21.72	41.02	15.87	35.74	32.22	13.10	44.07	23.18	32.16	67.26	56.91	29.63	9.36	72.19	35.08	46.30	75.26	27.48	9.51	36.21	50.75
CCNet[12]	27.27	26.18	23.90	42.54	33.63	9.25	52.70	19.79	36.66	54.65	60.47	17.81	-4.08	68.95	34.34	47.57	82.45	24.81	14.55	35.87	47.96
SegFormer[28]	10.35	30.87	19.96	38.26	27.61	0.04	56.29	27.02	29.08	55.69	55.50	3.38	0.00	72.03	49.80	43.38	77.95	13.70	1.39	31.96	42.28
BiSeNetV2[31]	8.04	24.10	13.02	27.65	28.57	0.71	39.68	22.17	29.93	42.55	51.26	9.14	0.10	49.77	18.19	21.45	71.90	15.34	13.26	25.62	36.60
DDRNet[19]	26.83	27.55	22.33	27.65	31.69	9.12	55.68	17.18	36.14	66.01	53.70	16.03	2.21	73.27	41.26	54.16	73.26	25.31	4.60	34.95	49.60
我们的	38.60	28.85	31.26	52.51	43.58	16.78	62.70	25.18	44.43	64.24	61.88	27.01	6.88	82.48	43.92	64.11	89.5	35.01	22.10	44.27	60.32




图8.Dac110k分割结果的可视化展示。结果表明，与现有分割网络相比，TPSegformer在跨场景泛化能力和语义一致性方面均表现出显著优势。

如图7所示，TPSegformer能够精准从无人机拍摄的影像中检测裂缝。尽管在焦距调整过程中，靠近墙角的深色区域因相机稳定性问题最初导致轻微误判，但模型在画面稳定后迅速恢复并准确分割出实际裂缝。这些结果充分证明了TPSegformer在基于无人机的实际缺陷检测场景中具备出色的鲁棒性和适应性。

4.5. 泛化实验

为评估TPSegformer的泛化能力，我们在Dac110k数据集[8]上进行了实验，该数据集包含19类结构缺陷（如裂缝、剥落）及常见材料（如混凝土、沥青、砌体）在不同条件下的样本。表7将实验结果与六个基准模型进行了对比。

TPSegformer在19个类别中的12个类别均取得最佳性能，mIoU值达44.27%，ACC值达60.32%，分别比第二佳模型高出8.06%和9.57%。这些结果充分证明了其在不同缺陷类型及材料条件下均具备出色的泛化能力和稳定性。

如图8所示，TPSegformer在分割各类结构缺陷方面展现出明显优势。第一行中，该模型能精准检测出与真实标注（GT）一致的细微裂纹，而DSNet、PIDNet和SegFormer均未能实现这一目标；第二行中，尽管JTape区域在GT中标注缺失，TPSegformer仍能准确识别其结构特征，体现了强大的结构感知能力；第三行中，凹陷区域（红色圆圈）虽未标注于GT中，但TP-

Segformer仍正确判定为剥落现象，彰显其卓越的泛化能力和语义理解能力；第四行中，TPSegformer与SegFormer均能准确分割Ejoint区域，但TPSegformer生成的边界更为平滑清晰。

总体而言，TPSegformer在细粒度缺陷定位、边界精度以及复杂或未标注区域的鲁棒性方面表现卓越，并在多材料环境中展现出强大的跨域适应能力。

5. 结论

本文研究了建筑缺陷与建筑材料之间的关联，并提出了一种名为TPSegformer的轻量级语义分割网络，该网络旨在以高效计算方式实现高精度分割。TPSegformer采用Swin Transformer作为多尺度特征提取的核心架构，并引入轻量级TPDecoder模块来增强和融合特征信息，从而生成类别专属的分割图。基于希尔伯特曲线的降维策略在提升计算效率的同时保持空间拓扑结构；自注意力机制则用于建模类间依赖关系，有效降低误分割风险。

实地实验验证了TPSegformer在复杂建筑环境中的准确性、鲁棒性及适应性。未来工作将重点优化该模型，并将其部署于无人机平台，以支持智能建筑检测与缺陷分析。