

用于图像识别的无激活机制主干网络：MetaFormer风格视觉模型中的多项式替代方案

王杰弗里¹；乔纳森·格雷戈里¹；格里戈里奥斯·G·克里索斯¹

摘要

现代视觉骨干网络将点激活函数（如ReLU、GELU）和指数型softmax视为非线性处理的核心来源，但我们证明在MetaFormer架构风格的视觉骨干网络中这些组件并非必需。我们为三个核心运算单元（多层感知机、卷积层和注意力机制）设计了无需激活函数的多项式替代方案：通过哈达玛积替代传统非线性函数，生成与输入数据相关的多项式函数。这些模块可无缝集成到现有架构中——在专为视觉骨干网络设计的模块化框架MetaFormer中实现后，我们的PolyNeXt模型在ImageNet分类任务、ADE20K语义分割任务以及分布外鲁棒性测试中，均达到或超越了基于激活函数的传统模型性能。同时我们在降低计算成本的同时显著优于现有多项式网络，证明标准模块的多项式变体能够超越复杂的定制化架构。相关代码已发布于<https://github.com/jjwang8/PolyNeXt>。

1. 引言

现代视觉架构在前向层中依赖点激活函数（ReLU、GELU、SiLU），并在softmax注意力机制内部使用指数函数（Vaswani 等人，2017；Dosovitskiy 等人，2021）。这些激活函数的引入旨在提供非线性特性，使神经网络能够逼近复杂函数。然而，激活函数并非非线性的唯一来源。多项式提供了一个基础且已被充分理解的替代方案：根据Stone-Weierstrass定理，在紧致定义域上的任意连续函数均可被多项式一致逼近。

¹威斯康星大学麦迪逊分校，美国威斯康星州麦迪逊市。通讯地址：Jeffrey Wang <jjwang8@wisc.edu>。

第43届机器学习国际会议论文集，韩国首尔。PMLR 306,2026年。版权归属作者所有（2026年）。

与激活函数的逼近特性取决于架构深度和特定函数形式不同，多项式为函数逼近提供了天然的基础框架。

两个学习得到的线性投影之间的哈达玛积（元素级乘法）为构建多项式表示提供了一种简单机制。给定输入向量 $\mathbf{x}$ ，计算 $(\mathbf{W}_a \mathbf{x}) \otimes (\mathbf{W}_b \mathbf{x})$ 可得到关于输入特征的二次多项式，其中 $\mathbf{W}_a$ 和 $\mathbf{W}_b$ 是表示线性投影的学习权重矩阵， $\otimes$ 表示元素级乘法。通过在各层间组合此类运算，神经网络无需任何激活函数即可表示任意次数的多项式。该方法具有理论优势：次数随网络深度可预测地增长，且所得网络继承了多项式函数空间的逼近保证特性。

越来越多的研究致力于探索用乘法交互替代激活函数的多项式网络（Chrysos 等人，2020；2025）。这部分研究的部分动机源于全同态加密（FHE）——一种加密范式中，标准网络因采用非多项式激活函数而产生显著开销（Brakerski 等人，2014）。近期提出的MONet（Cheng 等人，2024）和 DTTN（Nie，2025）等架构已证明多项式网络能够接近基于激活函数模型的性能。然而，这些方法引入了与特定设计紧密耦合的多项式模块定制架构，这限制了其实际应用价值：采用这些方案需要完全采用全新架构；其定制设计难以轻松融入标准层的未来改进（如高效的注意力机制变体、更优的归一化处理）；且在端到端评估中，其性能仍逊于基于激活函数的模型。

我们采取了不同的方法：并非从头设计全新的架构，而是为现代视觉骨干网络中的标准模块开发多项式替代方案。我们的核心见解在于：通过保留传统组件的输入输出接口，多项式模块仍能与正交架构改进保持兼容。我们聚焦于三种基本单元：用于通道混合的多层感知机（MLP）、用于局部空间混合的卷积运算，以及用于全局空间混合的自注意力机制。此处混合指在特定维度




图1. ImageNet-1K数据集准确率对比。我们的多项式骨干网络（CPolyNeXt、APolyNeXt）在所有模型规模下均持续优于MetaFormer的各类实例（ConvFormer、CAFormer）以及先前的多项式网络（MONet、DTTN）。曲线展示了准确率随参数变化的关系。
(a) 参数以及(b)浮点运算次数（FLOPs）。

（无论是通道维度（各空间位置的特征）还是空间位置维度）上整合信息的操作。这些操作几乎涵盖了当代骨干网络中所有的非线性函数：MLP在线性投影之间应用逐点激活函数；可分离卷积将空间滤波与激活函数交织结合；注意力机制则利用softmax函数中的指数函数（Dosovitskiy 等人, 2021; Liu 等人, 2022; 2021）。此外，通过移除所有激活函数，我们的研究在开发适用于隐私与安全场景的 FHE 适配架构方面取得了进展。

我们引入的多项式模块包括：

PolyMLP通过两个并行线性投影的哈达玛积来替代前馈网络中的激活函数：

$$\text{PolyMLP}(x) = W_o((W_a x) * (W_b x)). \quad (1)$$

PolyConv通过元素级乘法将具有不同感受野的并行卷积分支融合在一起，从而替代可分离卷积中的激活函数。

PolyAttn用多项式核函数替换了softmax注意力中的指数函数，从而实现一种无需激活函数的注意力机制。

由于我们的改进针对的是特定操作（激活函数、指数函数）而非模块结构，因此仍与窗口注意力机制（Liu 等人, 2021）、稀疏模式（Child 等人, 2019）或高效注意力变体等架构改进保持兼容。

我们在MetaFormer框架内验证了我们的模块（Yu 等人, 2022; 2024）。MetaFormer为视觉骨干网络提供了包含可插拔混合操作的模块化模板。其实例ConvF-

ormer和CAFormer恰好采用了我们关注的核心组件：可分离卷积、自注意力机制以及门控MLP。这种模块化结构使我们能够在受控条件下独立测试每种多项式替换方案。由于这些核心组件已被广泛采用（Shi, 2024; Fan 等人, 2024; Zhu 等人, 2023），我们预期这些多项式替换方案能够超越MetaFormer并应用于其他框架。

要充分发挥多项式模块的全部潜力，必须解决稳定性方面的挑战。与不会放大输出值的ReLU激活函数不同，两个大数值的哈达玛积会产生更大的数值。这种乘法放大效应会在网络各层间累积，我们在早期实验中未采取适当控制措施时观察到了训练不稳定性。为应对这些挑战并实现包含200层网络的稳定训练，我们引入了轻量级稳定机制：通过Sigmoid参数化的标量对残差贡献进行Sigmoid尺度约束；采用多输入跳跃连接（借鉴NASNet方法Zoph等人, 2018）使每个单元接收来自前两个单元的特征信息，从而优化梯度流动。我们还发现多项式网络更适合采用“深度优先于宽度”的设计架构：在参数数量相同时，堆叠更深层的窄层结构优于宽度更大、深度较浅的配置（见3.5节）。现有的多项式网络普遍缺乏这些机制，反而采用宽度较大但深度较浅的设计方案，这限制了多项式次数的增长。

为评估我们的多项式模块，我们在MetaFormer风格的架构（Yu等人, 2024）中实例化了这些模块，采用了其四阶段分层结构并加入了我们的稳定机制。我们提出了两种模型变体：**CPolyNeXt**（全程使用多项式卷积）和**APolyNeXt**（结合多项式卷积）。




图2. 多项式模块基元。我们为三种核心视觉运算符引入了无需激活函数的替代方案：(a) PolyMLP用于通道混合，通过在输出投影前对两个线性投影（使用LayerNorm）进行哈达玛乘法运算，生成二次多项式；(b) PolyConv用于卷积空间混合，将可分离卷积中的激活函数替换为粗粒度（扩张）分支与细粒度深度方向分支（含通道反转）的哈达玛融合，随后进行整合并输出投影；(c) PolyAttn用于基于注意力的空间混合，共享 Q/K 投影层，通过 Q 、 K 、 V 上的深度卷积注入局部上下文，并用多项式注意力核 $(s \cdot QK^T + 1)^p$ 结合 ℓ_1 归一化替换softmax函数，其中 $s = \sigma(\lambda)$ 为可学习缩放因子， p 为多项式次数。与标准MLP/Conv/Attention模块逐层对比详见附录图。S4。

采用多项式注意力机制的卷积网络架构，可直接在相同尺度下与MetaFormer系列模型（ConvFormer、CAFormer）进行对比。我们的PolyNeXt骨干网络在标准测试集和鲁棒性评估中均达到或超越了这些基于激活函数的同类模型性能，同时以更低的计算成本优于现有的多项式网络。实验消融结果表明：重新引入激活函数会持续降低模型性能。

我们的贡献包括：

- **核心视觉原语的多项式替代方案。**我们提出PolyMLP、PolyConv和PolyAttn三种方法，它们用哈达玛积替代标准非线性函数，同时保留输入-输出接口以兼容架构优化。
- **证据表明，在MetaFormer风格的视觉骨干网络中激活函数并非必需。**我们提出了PolyNeXt——一系列多项式视觉骨干网络，并证明在不同模型规模下，多项式模块的表现均与基于激活函数的方案相当或更优；而重新引入激活函数则会持续降低性能。
- **一种轻量级稳定化方案。**我们引入了Sigmoid-Scale、多输入跳跃连接以及深度优先于宽度的单

元设计，从而能够稳定训练多达200层的多项式网络。

2. 相关工作

多项式网络与乘法网络。多项式网络通过乘法组合而非逐点激活函数来构建表示（Ivakhnenko, 1971; Shin & Ghosh, 1991）。两个线性投影的哈达玛积正是此类广泛应用于多项式网络的乘法运算之一，可在无需激活函数的情况下实现非线性特性。Π-Nets通过结构化跳跃连接形式化了这一架构（Chrysos等, 2020），后续研究则重点探讨其稳定性（Chrysos等, 2023）。感兴趣的读者可参考近期综述文献以获取该架构的完整分类体系（Chrysos等, 2025）。最新提出的MONet架构（Cheng等, 2024）与DTTN架构（Nie, 2025）均采用定制化的多项式架构及专用模块设计，在不过度依赖激活函数的前提下实现了高精度分类效果。哈达玛积也出现在压缩与激励网络（Hu等人, 2018）、门控线性单元（Dauphin等人, 2017; Shazeer, 2020）以及StyleGAN（Karras等人, 2019）中。我们提出的多项式层与这些先前架构中使用的层不同之处在于完全省略了激活函数。

MetaFormer与视觉骨干网络。MetaFormer将视觉Transformer的设计抽象为一个具有可插拔混合操作的模块化模板（Yu等人，2022）。即使使用平均池化也能获得具有竞争力的准确率这一发现表明，架构结构比具体的混合器更为重要。ConvFormer和CAFormer分别通过卷积层和混合卷积-注意力机制实例化该模板（Yu等人，2024）。我们采用MetaFormer是因为其模块化设计能够对多项式运算符与基于激活函数的对应运算进行可控评估。

关于线性注意力变体及深度网络稳定化技术的相关研究详见章节B。

3. 多项式模块

我们提出了针对通道混合（PolyMLP）、卷积空间混合（PolyConv）以及基于注意力的空间混合（PolyAttn）的无激活替换方法。图2总结了这三种基本方法；逐层对比结果详见附录图S4。

3.1. PolyMLP：无激活的通道混合

标准前馈网络在线性投影之间应用逐点激活函数（如GELU），而门控变体（如GLU Dauphin等人，2017；Shazeer，2020）则引入乘法交互项，但保留其中一个分支的激活机制。PolyMLP则完全取消了激活环节：

$$\text{PolyMLP}(x) = W_o((W_a x) * (W_b x)), \quad (2)$$

其中 W_a, W_b 为 $d \times d$ 投影到中间维度 d' ； W_o 为 $d' \times d$ 进行反向投影；在哈达玛积运算后应用LayerNorm归一化。由此得到输入变量的二次多项式（参见章节A）。

我们设定 $d'=d$ ，对应于 $2 \times$ 的扩展（小于典型的 $4 \times$ ），并通过增加深度来抵消这一影响（见第3.5节）。对于分类头部分，我们添加了一个内部跳跃机制：PolyHead(x)= $W_o(W_a x + (W_a x) * (W_b x))$ ，从而防止信息通过乘法交互产生瓶颈效应。

3.2. PolyConv：通过卷积实现多项式空间混合

MetaFormer的ConvFormer采用可分离卷积（先进行深度空间滤波，再进行逐点混合），并在投影之间引入激活函数（Yu等人，2024）。为将该激活函数替换为哈达玛积，我们引入了具有不同感受野的并行卷积分支。

该设计在乘法运算前最大化特征多样性：粗分支采用扩张式深度卷积（空间范围为 5×5 kernel, dilation 2, covering

9×9 ）以捕捉宏观上下文信息，而细分支则使用标准的 3×3 深度卷积来提取局部细节。我们在融合前对其中一个分支应用通道翻转（反转通道顺序），以进一步消除两者之间的相关性。

$$h = W_{in} x, \quad (3)$$

$$m = K_c(h) / \text{flip}(K_f(h)), \quad (4)$$

$$y = W_{out}(K(m)), \quad (5)$$

其中 W_{in} 和 W_{out} 为逐点（ 1×1 ）卷积运算， K_c 表示扩张粗分支， K_f 表示细分支， $\text{flip}(\cdot)$ reverses channels, and K is a 3×3 为凝聚卷积。LayerNorm层位于该模块之后。在第一阶段（最高分辨率阶段），为提升效率，我们采用 3×3 的扩张卷积层。

与先前在两个分支中采用相似结构的多项式网络（如MONet（Cheng等人，2024）和DTTN（Nie，2025））不同，PolyConv明确构建了异质感受野以生成跨尺度交互项。第4.3节中的消融实验验证了这一设计的有效性。

3.3. PolyAttn：基于注意力机制的多项式空间混合算法

自注意力机制将输出计算为价值向量 V 的加权组合，其中权重取决于查询与键之间的相似度。给定输入 X 时，标准注意力机制会将输入投影为查询 $Q=XW_Q$ 、键 $K=XW_K$ 以及值 $V=XW_V$ ，随后计算 $\text{softmax}(QK^T/\sqrt{d_k})V$ ，其中 d_k 为键维度。softmax函数中的指数项提供了非线性特性。

PolyAttn用多项式核函数替代指数核函数。我们计算未归一化的注意力权重。

$$A = (s \cdot QKT + 1)^p, \quad (6)$$

其中 $s=\sigma(\lambda)$ 是一个可学习的头部标量（初始化为匹配标准比例 $d_k^{-1/2}$ ，且 p 为多项式 $\wedge$ 。肌痛程度。随后我们应用 ℓ_1 归一化处理： $A_{ij} =$

$A_{ij} / \sum_k A_{ik}$ ，并计算 AV 。我们采用 $p=4$ ，该值可在表达力与数值稳定性之间取得平衡。

遵循PolyConv的架构设计，我们在 Q 、 K 和 V 上通过深度卷积来增强注意力机制，从而提供局部空间上下文信息，这与CvT（Wu等人，2021）及CoAtNet（Dai等人，2021）的方法类似。我们共享查询向量与键向量的投影表示以节省参数量。由于PolyAttn仅修改注意力核（用多项式替代指数函数），因此仍兼容窗口化处理（Liu等人，2021）或稀疏模式分析（Child等人，2019）等变体方法。

3.4. 深度多项式网络的稳定性研究

哈达玛积会放大较大的数值，且这种效应会在多层网络中累积。我们引入两种技术以实现数百层网络的稳定训练。




图3. PolyNeXt单元与稳定化机制。一个单元接收来自前两个单元的两个输入： x_{t-1} 和 x_{t-2} 。在多输入跳跃模块中，可学习的通道级标量 s_0 和 s_1 在求和及LayerNorm处理之前对 x_{t-1} 和 x_{t-2} 进行权重调整。归一化后的状态通过 X 重复的PolyNeXt堆栈（空间混频器后接PolyMLP）进行处理。每个残差分支均采用Sigmoid-Scale门控： $y = x + \sigma(\lambda)f(x)$ ，以约束残差更新并稳定深度哈达玛积网络。

Sigmoid缩放。每个子层的输出均通过可学习的Sigmoid函数约束标量进行缩放：

$$y = x + \sigma(\lambda) \cdot f(x), \quad (7)$$

其中 $f(x)$ 表示子层输出，而 $\sigma(\lambda) \in (0,1)$ 用于限定残差贡献。我们初始化 λ 使得 $\sigma(\lambda)$ 随深度增加而递减（参见第C.4节）。在推理时， $\sigma(\lambda)$ 可被前一层权重吸收，无需额外添加激活函数。

多输入跳跃连接。我们将网络划分为单元格，每个单元格包含多个混频器-PolyMLP对。遵循NASNet（Zoph等人，2018）的设计，每个单元格同时接收来自前一个单元格（ x_{t-1} ）和再前一个单元格（ x_{t-2} ）的输入：

$$\tilde{x} = s_0 * x_{t-2} + s_1 * x_{t-1}, \quad (8)$$

其中 $s_0, s_1 \in \mathbb{R}^C$ 为可学习的通道专属标量。组合输入在处理前需先经过LayerNorm归一化操作。

深度优先于宽度。一个深度为 L 的网络能够表示次数为 2^L 的多项式，其参数与 L 呈线性关系，这远少于显式参数化所有次数为 2^L 项所需的参数数量（Delal-leau & Bengio, 2011）。堆叠单元使得网络深度可超过以往的多项式架构。

3.5. 架构实例化：PolyNeXt

我们将多项式模块实例化于一个包含四个层级阶段的MetaFormer风格架构中。在每个阶段转换处，空间分辨率均减半，而通道维度则增加。相关示意图见附录图S5。

变体方案：CPolyNeXt在所有阶段均采用PolyConv进行空间混合，构建了纯粹的卷积多项式骨干网络；**APolyNeXt**则沿用了

CAFormer的混合设计：前两个阶段使用PolyConv（适用于高分辨率场景，此时全局注意力机制计算成本较高），后两个阶段则采用PolyAttn（适用于低分辨率场景，此时全局上下文信息更具优势）。

茎部与下采样。茎部是一个步长为4的 7×7 卷积层。在第1阶段，我们使用茎部输出来初始化两个跳跃输入（ x_{-2}, x_{-1} ）。对于第 $s > 1$ 阶段，我们使用前一阶段最后两个单元的输出来初始化（ x_{-2}, x_{-1} ）。阶段间的下采样会在求和之前，分别对两条跳跃路径（ x_{t-1} 和 x_{t-2} ）独立应用步长为2的卷积操作。

配置。附录中的表S9汇总了模型配置。我们将每对混频器-PolyMLP单元称为一个堆栈；每个单元中的堆栈数量随模型规模增大而增加。

4. 实验

我们在ImageNet-1K分类任务上评估了我们的多项式模块，并与MetaFormer实例化模型及现有的多项式网络进行对比。通过消融实验分别分析了各项设计选择的影响，结果表明：将多项式模块与我们提出的“深度优先于宽度”的设计理念及稳定化技术相结合时，其性能优于基于激活函数的替代方案。

4.1. 实验设置

数据集。我们在ImageNet-1K（Deng等，2009）上进行训练与评估，该数据集是图像分类领域的标准大规模基准集。其包含涵盖1000个类别的128万张训练图像和5万张验证图像。所有模型均在 224×224 分辨率下训练，未使用额外预训练数据。

训练方案。我们的训练配置基于MetaFormer（Yu等人，2024）和MONet（Cheng等人，2024），并针对多项式网络进行了调整。我们采用了较小的批量大小（1024对比4096）以及增强的正则化机制，因为多项式网络具有更高的容量且能从更强的正则化中获益。完整的训练细节（包括我们的丢弃策略和随机深度调度方案）详见C节。

基线模型。我们与以下模型进行对比：(1) MetaFormer的实例化模型ConvFormer和CAFormer（Yu等人，2024），它们使用了我们所研究的相同基础组件；(2) 先验多项式网络MONet（Cheng等人，2024）、DTTN（Nie，2025）以及StarNet（Ma等人，2024）；(3) 其他强大的基线模型。

模型规模。我们评估了四种模型尺寸：Tiny（T，约600万参数）、Small（S，约2600万参数）、Base（B，约4000万参数）和Large（L，约6000万参数）。为提升计算效率，消融实验均在Tiny规模下进行。

表1. ImageNet-1K分类结果。PolyNeXt各变体在所有尺度上均达到或超越同类基于激活函数的模型性能，同时比先前多项式网络高出2-3个百分点。模型在224 × 224分辨率下训练且未使用额外预训练数据。♦ 表示无需激活函数（多项式）的模型；† StarNet采用元素级乘法运算但保留激活值。

(a) 卷积 / MLP / 多项式卷积				(b) 注意 / 混合型			
模型	参数(M)	浮点运算次数 (G)	前 1 (%)	模型	参数(M)	浮点运算次数 (G)	前 1 (%)
微型模型 (<参数量1200万)				微型模型 (<参数量1200万)			
MogaNet-T (李等人., 2024)	5.2	1.1	79.0	FAN-T混合模型 (周等人, 2022)	7.0	3.5	80.1
StarNet-S4 † (Ma等人, 2024)	7.5	1.1	78.4	APolyNeXt-T♦	6.5	1.3	80.9
DTTN-T♦ (Nie, 2025)	7.1	2.4	77.9	小型模型 (约12-30百万参数)			
MONET-T♦ (Cheng等人, 2024)	10	2.8	77.0	CSWin-T (董等人., 2022)	23	4.3	82.7
CPolyNeXt-T♦	6.4	1.2	80.2	UniFormer-S (李等人, 2023)	22	3.6	82.9
小型模型 (约12-30百万参数)				BiFormer-S (朱等人, 2023)	26	4.5	83.8
ConvNeXt-T (刘等人, 2022)	29	4.5	82.1	TransNeXt-Tiny (Shi, 2024)	28	5.7	84.0
ConvFormer-S18 (Yu等人, 2024)	27	3.9	83.0	RMT-S (范等人, 2024)	27	4.5	84.1
DTTN-S♦ (Nie, 2025)	12	4.1	79.4	CA Former-S18 (Yu等人, 2024)	26	4.1	83.6
CPolyNeXt-S♦	26	4.8	83.9	APolyNeXt-S♦	26	5.3	84.3
中型模型 (约30-50百万参数)				中型模型 (约30-50百万参数)			
ConvNeXt-S (刘等人, 2022)	50	8.7	83.1	CSWin-S (董等人., 2022)	35	6.9	83.6
MogaNet-B (李等人., 2024)	44	9.9	84.3	UniFormer-B (李等人, 2023)	50	8.3	83.9
InternImage-S (王等人, 2023)	50	8.0	84.2	TransNeXt-Small (Shi, 2024)	50	10.3	84.7
UniConvNet-S (Wang & Xi, 2025)	50	8.5	84.5	CA Former-S36 (Yu等人., 2024)	39	8.0	84.5
ConvFormer-S36 (Yu等人, 2024)	40	7.6	84.1	APolyNeXt-B♦	41	9.3	84.9
MONET-S♦ (Cheng等人, 2024)	33	6.8	81.3	大型模型 (约50-100百万参数)			
DTTN-B♦ (Nie, 2025)	36	12.3	82.4	CSWin-B (董等人., 2022)	78	15.0	84.2
CPolyNeXt-B♦	40	8.5	84.7	MaxViT-S (Tu等人., 2022)	69	11.7	84.5
大型模型 (约50-100百万参数)				前B型 (朱等人, 2023)	57	9.8	84.3
MogaNet-L (李等人., 2024)	83	15.9	84.7	TransNeXt-Base (Shi, 2024)	90	18.4	84.8
ConvNeXt-B (刘等人, 2022)	89	15.4	83.8	RMT-B (范等人., 2024)	54	9.7	85.0
ConvFormer-M36 (Yu等人, 2024)	57	12.8	84.5	CA Former-M36 (Yu等人., 2024)	56	13.2	85.2
CPolyNeXt-L♦	57	12.6	84.9	APolyNeXt-L♦	57	13.3	85.2

4.2. 主要结果

表1展示了ImageNet-1K分类任务的实验结果。我们的多项式骨干网络在所有尺度上均能与MetaFormer模型的表现持平或更优，且以更低的计算成本显著超越现有多项式网络（性能提升达2-3个百分点）。这些结果表明激活函数并非构建高性能视觉骨干网络的必要条件。相较于传统多项式网络，其性能提升尤为显著：CPolyNeXt-S（参数量2600万，FLOPS计算量4.8亿，准确率83.9%）尽管参数量减少28%、FLOPS计算量降低61%，仍比DTTN-B（参数量3600万，FLOPS计算量12.3亿，准确率82.4%）高出1.5个百分点。APolyNeXt进一步证明，在视觉骨干网络中采用多项式注意力机制可作为softmax注意力机制的有效替代方案。

除了与我们的直接基准模型表现相当外，多项式模块在性能上也优于引入专门机制的架构。在卷积层方面，CPolyNeXt-B（4000万参数）达到84.7%，超越了使用可变形卷积的InternImage-S（Wang等, 2023）（5000万参数，84.2%），并在仅使用80%参数量的情况下与UniConvNet-S（Wang & Xi, 2025）（5000万参数，84.5%）持平；CPolyNeXt-L（5700万参数，84.9%）则仅以69%的参数量超越采用多阶门控聚合机制的MogaNet-L

（Li等, 2024）（8300万参数，84.7%）。在最大规模模型中，CPolyNeXt-L同样以约一半的参数量和FLOPS计算量超越ConvFormer-B36（Yu等, 2024）（1亿参数，84.8%）。在注意力机制方面，APolyNeXtS（2600万参数，84.3%）同时超越了引入保留自注意力机制的RMT-S（Fan等, 2024）（2700万参数，84.1%）以及采用像素聚焦注意力机制的TransNeXt-Tiny（Shi, 2024）（2800万参数，84.0%）。在中等规模模型中，APolyNeXt-B（4100万参数，9%）在82%的参数设置下优于TransNeXt-Small（Shi, 2024）（50M参数，84.7%）。这些对比表明：当适当稳定化后，多项式非线性模型无需复杂的架构创新即可提供足够的表达能力。图1直观展示了这些优异的扩展特性。相较于同等规模下的MetaFormer（详见第5节），深度优先设计确实会带来吞吐量成本；但我们的模型同时比MetaFormer及现有多项式网络显著降低GPU峰值内存消耗，并在保持相同精度的前提下仍更快。完整的吞吐量与内存性能对比详见表S11。

4.3. 消融研究

我们在CPolyNeXt-T和APolyNeXt-T上进行消融实验，以分离各设计选择的具体贡献。

表2.耐受性评估。多项式网络展现出卓越的耐受性，在分布外基准测试中与参数数量近两倍的模型表现相当；评估时未进行微调。♦表示无需激活函数。mCE：平均破坏误差（数值越低越好）。

模型	清洁	IN-C↓	IN-A	IN-R	IN-Sk
小型模型（约25–30 百万参数）					
斯温- T	81.3	62.0	21.6	41.3	29.1
ConvNeXt-T	82.1	53.2	24.2	47.2	33.8
ConvFormer-S18	83.0	51.7	25.3	48.7	35.2
CAFormer-S18	83.6	47.4	33.5	48.7	36.6
CPolyNeXt-S♦	83.9	47.9	35.1	49.4	37.8
APolyNeXt-S♦	84.3	45.0	39.6	49.7	37.5
中型模型（约35–50 个参数）					
斯温- S	83.0	52.7	32.3	45.1	32.4
ConvNeXt-S	83.1	51.2	31.2	49.5	37.1
莫奈-S♦	81.3	49.7	—	—	—
ConvFormer-S36	84.1	47.1	33.2	50.8	38.4
CAFormer-S36	84.5	44.7	40.9	51.7	39.5
CPolyNeXt-B♦	84.7	44.5	42.8	52.0	40.0
APolyNeXt-B♦	84.9	42.7	45.5	52.9	41.1
大型模型（约50–90百万参数）					
斯温- B	83.5	54.4	35.8	46.6	32.4
ConvNeXt-B	83.8	46.8	36.7	51.3	38.2
ConvFormer-M36	84.5	46.5	37.6	51.0	39.2
CAFormer-M36	85.2	42.6	45.6	51.7	39.6
CPolyNeXt-L♦	84.9	42.5	48.3	54.5	41.8
APolyNeXt-L♦	85.2	42.9	49.2	54.0	41.8

多项式模块与激活函数对比。表3通过将激活函数重新引入多项式模块来验证我们的核心论点。在所有模块中，激活函数均会持续降低性能：PolyConv最为敏感——将其替换为标准可分离卷积仅导致0.9个百分点的损失；无论激活函数被插入到哈达玛乘积之前、之后还是周围位置，都会影响准确率。对于PolyAttn而言，具体核函数的选择不如整体设计重要（用softmax替代多项式核仅造成0.1个百分点的影响），但完全用标准注意力机制替换PolyAttn则会导致1.3个百分点的损失，这表明共享的Q/K投影层与深度卷积层对性能提升的作用远超核函数本身。最显著的是，用加法运算替代哈达玛乘积会导致灾难性性能下降（_22.3个百分点），这证实了乘法交互作用对多项式模型架构至关重要。

稳定化与架构。表4验证了我们的稳定化技术及深度与宽度的设计方案。SigmoidScale至关重要，但起始几何参数（而非Sigmoid非线性函数本身）才是主要机制：将 $\sigma(\lambda)$ 替换为初始值相同的可学习标量仅需增加0.5个点；而LayerScale即使在较小初始化值（ 10^{-6} ，_0.8个点）下也会失效，标准初始化则会导致训练崩溃（_12.8个点）。Sigmoid与表3.多项式模块与激活函数对

比。重新引入激活函数会降低性能（负 Δ ）。CPolyNeXt-T基线：80.2%。APolyNeXt-T基线：80.9%。†需进行预热并使用后-MLP LayerNorm。‡头数量根据计算需求调整。

配置	Δ Acc (%)
CPolyNeXt-T	
多聚MLP $\rightarrow$ MLP + GELU †	_0.1 至 _0.4
多卷积 $\rightarrow$ 分离卷积 + GELU	−0.9
+ $\sigma(\mathbf{x}) * \mathbf{x}$ （第一分支）	−0.4
+ $\sigma(\mathbf{x} * \mathbf{x})$ （多重操作后的动作）	−1.0
+ $\sigma(\mathbf{x}) * \sigma(\mathbf{x})$ （两者均适用）	−0.6
仅细分支（无粗分支）	−0.5
哈达玛运算 $\rightarrow$ 加法	−22.3
APolyNeXt-T	
多聚MLP $\rightarrow$ MLP + GELU	−0.3
PolyAttn $\rightarrow$ Std Attn ‡	−1.3
多核 $\ell_1 \rightarrow$ 软最大值	−0.1
多项式次数 $p = 3$	−0.3
多项式次数 $p = 5$	−0.1

而自由标量变体则体现了第二个优化优势： $\sigma'(\lambda) = \sigma(\lambda)$ （ $1 - \sigma(\lambda)$ ）在更深的子层中会减小（即 $\sigma(\lambda)$ 值更小），从而将更新幅度与当前贡献大小相匹配。多输入跳跃连接和预单元归一化均发挥显著作用；在参数数量相同的情况下，更深的网络配置始终优于更宽的配置：每个单元使用3个堆栈比使用1个堆栈可提升1.5个百分点，这验证了多项式网络能从深度增加中获益——且多项式次数随深度呈指数增长。

配方敏感性。一个自然的问题是：我们的多项式模型是否依赖于其定制的训练方案，还是模块本身决定了性能表现？我们通过小规模交叉配方实验（表5）对此进行了验证——在相同的加速参数（torchCompile、AMP bfloat16）下，在ConvFormer-S18和CAFormer-S18的源代码库中重新训练后，其性能与已公开数据（82.9%和83.5%）的差异均控制在0.1以内。优化器的选择体现了模型特异性，但正则化效果具有双向传递特性：使用我们的正则化方案时，ConvFormer的性能基本保持不变（提升+0.1）；而采用完整训练方案时，CAFormer仅下降0.3；相比之下，ConvFormer在使用我们的优化器时性能急剧下滑。CPolyNeXt-S（_0.2）和APolyNeXtS（_0.4）几乎不受ConvFormer优化器的影响，这与MetaFormer模型在更换训练方案时的表现相当；表明多项式模块并不比标准架构更依赖于特定训练方案。

模块替换实验。为进一步验证模块层面的泛化能力，我们在CAFormer-S18中用PolyConv和PolyAttn替换了空间混叠器，同时保持CAFormer的架构、训练方案及FLOPs/参数数量不变。这两种替换均使ImageNet分类准确率提升0.1至0.3个百分点，表明多项式模块具备良好的迁移能力。

表4.稳定性与架构消融实验结果。在参数匹配条件下，深层结构优于广义结构。CPolyNeXt-T基线模型：80.2%。†训练过程直至后期才收敛；*可学习标量参数初始化为 $\sigma(\lambda)$ 但未使用Sigmoid函数。

配置	Δ Acc (%)
乙状结肠标度消融术	
→可学习标量（无 σ ）*	-0.5
→ LayerScale (init= 10^{-6})	-0.8
→ LayerScale (init=1.0)†	-12.8
跳过连接消融	
移除多输入跳过项；在单元格前	-0.6
移除归一化处理	-0.4
深度与宽度（匹配参数）	
更宽（每个细胞含2个堆栈）	-0.7
更宽（每单元1个堆栈）	-1.5

表5.小规模下的跨模型配方分析。使用另一家族优化器和/或正则化方法训练时，各模型相对于自身基线的 Δ 准确率。优化器选择需根据具体模型确定；正则化效果可双向传递。

配置	Δ Acc (%)
使用ConvFormer设置时的结果（CPolyNeXt-S: 83.9%；APolyNeXt-S: 84.3%）	
CPolyNeXt-S（配备ConvFormer优化器）；	-0.2 -
APolyNeXt-S（配备ConvFormer优化器）	0.4
使用我们的设置的ConvFormer-S18（基线值 82.9%）	
使用我们的优化器（是否包含正则化项均可）；同时采用正则化处理。	坍塌（约6%）+0.1
CAFormer-S18（使用我们的设置）基线值为83.5%	
使用我们的优化器	-0.4
通过我们的正则化方法.....	-0.3
根据我们的完整配方：	-0.3

超越 PolyNeXt 架构本身。

4.4. 稳健性评估

基于MetaFormer（Yu等人，2024）的研究成果，我们在ImageNet-C（Hendrycks & Dietterich，2019）（常见损坏类型如噪声和模糊）、ImageNet-A（Hendrycks等人，2021b）（自然对抗样本）、ImageNet-R（Hendrycks等人，2021a）（绘画与雕塑等渲染图像）以及ImageNet-Sketch（Wang等人，2019）上评估了模型的鲁棒性（未进行微调，见表2）。我们的多项式骨干网络在所有MetaFormer实例化模型中均展现出卓越的鲁棒性，在相似规模数据集上表现尤为突出，其中APolyNeXt在对抗样本数据和分布外数据上表现尤为优异。值得注意的是，我们的中规模卷积模型CPolyNeXt-B（4000万参数）在ImageNet-A（42.8 vs. 40.1）、ImageNet-R（52.0 vs. 51.1）及ImageNet-Sketch（40.0 vs. 39.5）上均超越ConvFormer-B36（1亿参数）；而CPolyNeXt-L（5700万参数）在ImageNet-C上的表现则达到或超过CAFormer-B36（9900万参数）（42.5 vs. 42.6）。

表6.ADE20K语义分割结果。在ConvNeXt配置下，UperNet经过160,000次迭代训练。在相同参数设置下，多项式骨干网络的表现均优于MetaFormer系列基线模型。

模型	参数(M)	MAC地址 (G)	mIoU
ConvFormer-S18（Yu等人，2024）	54	925	48.6
CAFormer-S18（Yu等人，2024）	54	1024	48.9
CPolyNeXt-S♦	54	941	50.6
APolyNeXt-S♦	55	1121	49.9

并且在参数量减少近一半的情况下，其性能优于ImageNet-R（54.5 vs. 53.9）。这些结果表明，多项式网络在保持高准确率的同时，还能实现优异的鲁棒性与效率之间的平衡。

4.5. ADE20K上的密集预测

为检验超越分类层面的迁移效果，我们在ADE20K数据集（Zhou等人，2019）上使用UperNet（Xiao等人，2018）并遵循ConvNeXt（Liu等人，2022）的训练方案（160000次迭代，AdamW优化器，学习率 $lr=10^{-4}$ 且权重衰减率为0.05），采用PolyNeXt特有的参数组（Sigmoid-Scale层无权重衰减、多输入跳跃层及归一化参数），且未进行额外调优。MetaFormer基线模型参数源自Yu等人（2024）。如表6所示，在匹配参数条件下，CPolyNeXt-S的表现优于ConvFormer-S18（+2.0 mIoU）和CAFormer-S18（+1.7 mIoU），并与ConvFormer-S36（6700万参数、1003G MACs下达到50.7 mIoU）在5400万参数和941 G MACs下表现相当。分割性能提升幅度远超我们的分类性能阈值，表明多项式结构主干网络特别适用于密集预测任务。APolyNeXt-S需对每个细胞梯度进行范数为5的裁剪；而卷积版本则无需调整。

4.6. 致FHE：完全多项式变体

虽然我们的主要模型已移除了所有逐点激活操作，但LayerNorm仍会成为FHE兼容推理过程中的障碍，因为它需要对加密后的数值进行除法运算和平方根计算。为解决这一问题，我们训练了完全多项式化的变体模型：将每个LayerNorm替换为与多项式运算兼容的BatchNorm——该方法在推理时通过分解后的仿射函数及运行统计量，分别对每个空间位置上的批次和通道（B、C）进行归一化处理。PolyAttn ℓ_1 归一化同样被替换为运行行和估计值（完整推导详见C.5节）。因此整个推理过程仅涉及加法和乘法运算。

如表7所示，我们的CPolyNeXt-S BN变体在ImageNet数据集上的准确率达到82.7%，较此前最佳的完全多项式模型结果（MONet-T BN，77.7%）提升了5.0个百分点。值得注意的是，CPolyNeXt-S BN（82.7%，2600万参数）不仅以更少的参数量超越了基于激活函数的强基线模型ConvNeXt-T（82.1%，2900万参数），其性能表现也更为接近最优水平。

表7.完全多项式变体。用与多项式兼容的BatchNorm替代LayerNorm后，整个推理过程仅涉及加法和乘法运算。CPolyNeXt-S BN模型达到82.7%的准确率，超越ConvNeXt-T (82.1%)，并比现有最佳完全多项式模型高出5.0个百分点。

模型	Params	浮点运算次数	LN ver.	聚 BN	Δ
先前多项式网络					
莫奈-T (BN) $\blacklozenge$	10.3M	2.8G	77.0	77.7	+0.7
DTTN -S (无标准) $\blacklozenge$	12.3M	4.1G	79.4	77.2	-2.2
我们的：我们的					
CPolyNeXt-T $\blacklozenge$	6.4M	1.2G	80.2	78.3	-1.9
APolyNeXt-T $\blacklozenge$	6.5M	1.3G	80.9	78.0	-2.9
CPolyNeXt-S $\blacklozenge$	26M	4.8G	83.9	82.7	-1.2

ConvFormer-S18 (83.0%) 与基准值相差不超过0.3个百分点。注意力机制变体的LN $\rightarrow$ BN差距较大 (APolyNeXt-T: $_2.9$ vs. CPolyNeXt-T: $_1.9$)，这反映了 ℓ_1 注意力归一化过程中存在的额外近似效应；而卷积变体的该差距随参数缩放逐渐缩小 (CPolyNeXt-S: $_1.2$)。

5. 讨论

从容量到可训练性。我们的研究表明，竞争性多项式网络面临的主要障碍并非表征能力，而是优化稳定性。多项式次数随网络深度呈指数增长，而参数量仅线性增加，这使得深度较大的多项式网络具有极强的表达能力。这种高表达性在实践中表现为需要更强的正则化措施（如较小的批量大小、更高的随机深度）。然而，网络深度也会加剧不稳定性：两个较大数值相乘会产生更大的结果，且这种效应会在各层间不断累积。早期的多项式网络通过采用较浅且较宽的设计来规避这种不稳定性，但代价是牺牲了深度带来的容量优势。我们的稳定化技术通过控制残差幅度（Sigmoid-Scale）、改进梯度流机制（多输入跳跃连接）以及精心设计归一化位置来解决这一问题。借助这些改进方案，我们仅需约200层网络即可实现训练，从而使多项式模块的性能达到甚至超越基于激活函数的同类模型（表1）。

为什么激活函数会带来负面影响？在多项式模块中添加激活函数本应增强表达能力，但在我们的深度优先于宽度的架构中却产生了相反效果。该计算块 ($W_a x^*$) ($W_b x$) 存在相互梯度耦合：在反向传播过程中，流入 W_a 的梯度会被 $W_b x$ 缩放，反之亦然，因此每个分支都会通过其相邻分支的输出进行学习。引入 GELU 函数可打破这种耦合关系——其对负输入值近乎零的导数会在梯度流动处形成“死区”。这解释了表3中的排序顺序： σ 表示 GELU 函数；将其应用于单个分支 ($\sigma W_a x^*$) ($W_b x$)， $\Delta = _0.4$) 可部分阻断一条梯度路径；

将其同时应用于两个分支 ($\sigma W_a x^* \sigma W_b x$)， $\Delta = _0$ 时则会阻断两条梯度路径。6) 该操作可独立阻断两条路径；而将其应用于乘积运算之后 ($\sigma ((W_a x)^*(W_b x))$ ， $\Delta = _1.0$) 效果最差，因为当乘积为负值时，单个门电路会同时阻断梯度向两个投影方向的传播。用加法运算替代乘法 ($\Delta = _22.3$) 则能完全消除这种梯度间的相互耦合，这证实了该耦合正是我们多项式模块中表达性非线性行为的核心来源。

局限性。我们的训练方案无法直接应用于标准计算流程：多项式网络需要更小的批量大小、渐进式丢弃策略以及精心设计的初始化参数以确保稳定训练。相较于结构更浅、宽度更大的架构，深度优先于宽度的设计即使在运算量相当的情况下也会产生吞吐量开销。由于乘法放大效应，哈达玛积对学习率非常敏感。最后，虽然我们提出的全多项式贝叶斯网络变体（第4.6节）表明 LayerNorm 并非实现无激活函数与归一化推理的绝对障碍，但端到端 FHE 部署仍是未来需要攻克的课题。

6. 结论

我们在现代视觉网络骨干架构的核心模块中引入了多项式替代方案：用于通道混合的PolyMLP、用于卷积空间混合的PolyConv，以及用于注意力机制驱动的空间混合的PolyAttn。每个模块均用哈达玛积替代逐点激活函数或指数运算，同时保持输入输出接口不变。结合轻量级稳定化技术与深度优先于宽度的设计方案，这些模块在ImageNet分类任务和分布外鲁棒性方面，在不同模型规模下均达到甚至超越传统基于激活函数的模型；并在ADE20K语义分割任务中展现出优异性能——我们的CPolyNeXt-S模型在相同参数设置下超越了ConvFormer-S18和CAFormer-S18（见第4.5节）。我们进一步证明无激活函数框架可扩展至归一化阶段：通过用兼容多项式的BatchNorm替代LayerNorm，我们的全多项式变体在ImageNet数据集上达到82.7%的准确率，较现有最佳全多项式模型提升5.0个百分点，并向 FHE 兼容推理目标迈进了一步（见第4.6节）。

除实证结果外，我们的研究还表明：激活函数（至少在现代视觉架构的图像识别任务中）并非表示机制的必要组成部分，而仅是应对深度神经网络优化难题的一种解决方案。一旦通过其他方式解决了训练稳定性问题，多项式交互项便能成为有效的非线性引入手段。未来研究方向包括：阐明多项式网络的优化动态特性；将其拓展至softmax注意力机制普遍应用的语言模型等领域；以及探索其 FHE 部署方案。