

CROWN: 一种用于三维医学分割中抗混叠降采样与相位校准融合的统一框架

黄兴茹^{1,2,3*}叶双华^{1,2*}黄兆⁵唐文文^{7†}周慧宇⁶
郑志文^{1,2,3†}刘晋^{1,2,3†}张小帅^{4†}

¹ 杭州电子科技大学, 杭州市 310018, 中国

² 维典公司, 中国北京 100015

³ 浙江省低空泛在网络技术重点实验室

杭州电子科技大学, 杭州市 310018, 中国

⁴ 中国海洋大学信息科学与工程学院, 青岛 266404, 中国

⁵ 阿伯丁大学自然与计算科学学院, 英国阿伯丁 AB24 3UE

⁶ 莱斯特大学计算与数学科学学院, 英国莱斯特市 LE1 7RH

⁷ 约翰斯·霍普金斯大学, 美国马里兰州巴尔的摩市 21218

摘要

精确的三维医学图像分割是诊断、治疗方案制定及纵向监测领域的关键环节。然而，采用各向异性体素间距进行常规采集以及异质性重建方式会导致降采样混叠效应和跨尺度对齐偏差，从而模糊图像边界、破坏结构完整性并降低可靠性。现有的U型卷积神经网络或Transformer架构既无法有效控制降采样过程中的混叠效应，也无法在解码器融合前明确对齐高分辨率图像数据，导致在设备与实验方案差异的情况下出现接口不稳定问题。为此，我们提出了一种名为“集合纤维化微局域协同注意力网络”（CROWN）的通用分割框架，该框架将采样理论与表征学习相结合，同时抑制混叠效应并校准跨尺度融合效果。CROWN由两个互补组件构成：微局域多相协同注意力降采样器（ μ PCAD）通过池化子带协同注意力机制结合显式抗混叠低通滤波器，实现轴向感知的多相分析；在降采样过程中既能保留边界相关的高频信息，又能有效抑制虚假相位成分。八相余集纤维化（OCF）技术能够有效跳过反向特征点，通过三维空间到深度的重构将其转化为余集，并利用边缘门控调制实现相位校正，从而向解码器输出紧凑、相位对齐且具备边界感知特性的特征。基于涵盖CT、MRI和OCT领域的15个公开数据集进行的广泛评估表明，CROWN算法相较于17种最新主流方法展现出业界领先性能：显著提升重叠度与拓扑一致性，持续降低边界误差，同时保持可控训练过程。

*等额贡献†通讯作者

训练与推理成本。该代码可在<https://github.com/IMOP-lab/CROWN>公开获取。

1. 引言

可靠的体积分割是CT、MRI和OCT中定量成像流程（如肿瘤体积测量、器官风险轮廓构建以及纵向疾病负荷追踪）的前提条件[18]。然而，常规数据采集与多站点数据整合会引入物理及实验方案的变异性，这些因素会直接影响输入体积的统计特性以及下游分割算法的稳定性[9]。各向异性体素间距与扫描模式会导致部分体积效应和层厚混叠现象；此外，异质性重建核函数、去噪流程及强度缩放都会改变空间统计特征与频率分布[58]。这些因素会削弱边缘梯度、扭曲边界，并产生平面间不一致性——而标准各向同性核函数与斑块标记化方法均无法有效修正这些问题[58]。因此，在单一参数条件下训练的模型往往将设备特异性信息与解剖结构相互交织，从而限制跨域泛化能力[9]。在实际采集条件下，将采样、混叠效应及边界证据视为相互关联的问题进行综合处理的数学模型，对于实现可靠的三维分割至关重要。

尽管从卷积神经网络到体积变换器技术取得了快速进展，但在机制层面仍存在三个关键差距[12]。

(i) 下采样混叠效应与边缘衰减。步长卷积和池化操作在不进行抗混叠处理的情况下压缩频谱，从而抑制细小结构并放大阶梯状伪影；与间距无关的各向同性滤波器会在各向异性条件下导致三轴特征对齐错误[58]。

(ii) 尺度与路径对齐偏差：解码器常将传播混叠高频成分的高分辨率跳跃序列进行融合，而低分辨率语义

特征缺乏边界感知的归纳偏置；此外，跳跃序列拼接会导致多尺度整合校准不佳[63]。（iii）扫描仪与协议引起的域偏移：例如，学习到的特征常编码与协议相关的模式[9]；全局注意力机制虽能聚合上下文信息，但在模糊界面处效果较差[12]；同时，频域处理可能以牺牲临床显著边缘为代价来衰减噪声[3]。这些问题促使我们设计一种既能联合控制降采样过程中的混叠效应，又能构建高分辨率证据融合机制的设计方案，从而确保边界定位与结构一致性在不同采样条件及设备间得以保持。

因此，我们提出了余集纤维化微局域协同注意力网络（CROWn），该框架通过两个互补组件将采样理论与表征学习相结合。微局域多相协同注意力抽取器（ μ PCAD）在下采样过程中执行轴感知的多相分析与协同注意力机制：它提取局部极值和背景上下文信息，将特征分解为多方向子带，并计算跨源注意力机制——将池化分支视为查询与键值，小波子带视为数值。经过融合后的特征会重新校准，并通过显式抗锯齿模糊处理进行降采样，从而生成低分辨率嵌入表示，在保留边界相关高频结构的同时抑制虚假成分。八相余集纤维化（OCF）则在解码器融合前重构跳跃连接：高分辨率特征经抗锯齿处理后，通过三维空间到深度变换转化为八个交错排列的余集；随后相位注意力机制对这些余集进行细化处理，同时基于三维Sobel响应导出的边缘门控项对特征进行调节[44, 59]。此外，深度可分离聚合技术能够生成紧凑且相位对齐的跳跃序列，这些序列在语义上更接近解码器尺度，且不易产生传输混叠。 μ PCAD与OCF将微观局部协同注意力机制与余集纤维化、边缘引导的跳跃校准方法相结合，实现了具有混叠感知特性的降采样处理，有效解决了各向异性及设备异质条件下体素分割存在的问题。

基于多种评估基准的测试结果均表明，在异质性采样条件下该方法具有稳定的准确率和边界质量。CROWn模型共使用2378万个参数及199.58亿次浮点运算（FLOPs）。消融实验验证了所设计的 μ PCAD与OCF模块的有效性；在各处理阶段同时应用这两个模块可实现最稳定的边界定位效果。主要贡献总结如下：

- 提出CROWn算法用于三维医学图像分割，将多相采样与微观局部分析相结合，并结合多尺度特征学习以解决混叠效应和边界退化问题。
- 设计 μ PCAD——一种抽取器，它将基于池化操作生成的查询/键值与小波子带值相结合，实现具有显式抗锯齿功能、考虑混叠效应且保留边界特性的降采样。

- 开发OCF，通过八相陪集分解、相位注意力机制及边缘门控调制技术对高分辨率跳跃特征进行重构，从而生成紧凑、相位对齐且具备边界感知能力的跳跃特征。
- 基于涵盖CT、MRI和OCT的15项基准测试开展的大量实验，验证了 μ PCAD与OCF方法的有效性以及模型复杂度报告机制的可靠性。

2. 相关工作

在三维医学图像分割领域，卷积神经网络（CNN）确立了基于体素的分析范式，该范式由3D U-Net[6]和V-Net[34]首创，并被RAUNet[36]、ResUNet[53]、SegResNet[35]、MultiResUNet[17]、HighRes3DNet[23]以及uC 3DUNet[16]进一步拓展；而nnU-Net[18]则提供了强大且可适应性强的基础模型。然而纯CNN存在局部感受野受限及各向异性采样等局限性。为解决长距离依赖问题，基于Transformer的[46]设计层出不穷：ViT[8]与Swin Transformer[28]实现了分层自注意力机制；而TransUNet[4]、TransBTS[47]、UNETR[12]、SwinUNETR[11]、UNETR++[43]、SegFormer3D[40]、UNesT[57]、Slim UNETR[37]、D-Former[49]、TransHRNet[54]、PHTrans[26]、LW-CTrans[20]、WaveFormer[1]、MAT3D[45]及nnWNet[62]等混合架构在多器官及肿瘤检测基准上均超越了经典CNN。与此同时，ConvNeXt[29]通过采用大尺寸卷积核及现代归一化与激活函数，重新审视卷积神经网络，以更优的计算与内存效率达到甚至超越Transformer性能；ConvNeXt基3D UX-Net[22]与MedNeXt[42]则在高分辨率CT与MRI任务中表现卓越。最近，状态空间模型（SSM）能够以线性复杂度捕捉长距离依赖关系：Mamba[10]及其视觉变体支撑了诸如U-Mamba[32]、SwinUMamba[24]、SegMamba[50]以及SegMamba v2[52]等架构，显著提升了对微小病变和纤细解剖结构的鲁棒性。

尽管进展迅速，目前尚无主流方法能在各向异性采样条件下同时实现全局上下文信息、精细细节描述以及部署级效率。我们的方法弥补了这一不足，并在多器官及肿瘤分割任务中均取得显著提升。

3. 拟议中的“皇冠”设计

3.1. 总体框架

为解决体积分割中存在的固有挑战（例如步长操作导致的特征失真以及体素各向异性下的信息丢失），我们提出了CROWn方法，其包含 μ PCAD和OCF两种算法（如图1所示）。 μ PCAD通过将空间池化与小波多相子带通过共注意力机制显式融合，在保留高频边界细节的同时实现了抗混叠降采样；OCF则结合八相空间-深度分解与边缘门控相位注意力机制，通过选择性传播

具有相位对齐性和边界感知特性的特征来校准跳跃连接层，从而弥合语义差异与解码器之间的鸿沟。

3.2. 微局域多相共关注抽取器

在各向异性体系间距下产生的混叠效应，以及高分辨率数据在尺度转换时的错位问题，均会加剧体积降采样的复杂性。为在保留边界特征的同时控制相位折叠现象， μ PCAD 提出了一种创新方法：将层间多相分析与跨源协同注意力机制及抗混叠预滤波技术相结合。

给定一个编码器特征 $\mathbf{X} \in \mathbb{R}^{B \times C_e \times D \times H \times W}$ ， μ PCAD 对与 W 轴正交的二维切片进行处理。对于每个切片索引 $w \in \{0, \dots, W-1\}$ ，生成 $\mathbf{X}^{[w]} = \mathbf{X}[:, :, :, w]$ ， $\mathbf{X}^{[w]} \in \mathbb{R}^{B \times C \times D \times H}$ 。两个 1×1 线性映射分别产生池化分支 $\sim \mathbf{Q}^{[w]} = \mathcal{C}_{\max}(\mathbf{X}^{[w]})$ 和 $\sim \mathbf{K}^{[w]} = \mathcal{C}_{\text{avg}}(\mathbf{X}^{[w]})$ ；在 (D, H) 格点上进行步长为 2 的最大值/平均值池化后，得到 $\mathbf{Q}^{[w]} = \mathcal{M}_2(\sim \mathbf{Q}^{[w]})$ 和 $\mathbf{K}^{[w]} = \mathcal{A}_2(\sim \mathbf{K}^{[w]})$ ，其空间尺寸为 $\frac{D}{2} \times \frac{H}{2}$ 。第三个 1×1 映射，即 $\sim \mathbf{Z}^{[w]} = \mathcal{C}_{\omega}(\mathbf{X}^{[w]})$ ，作用于 (D, H) 上、步长为 2 的可分离 Haar 变换：使用分析滤波器 $l = (2^{-1/2}, 2^{-1/2})$ 和 $h = (2^{-1/2}, -2^{-1/2})$ ，子带 $\mathbf{V}^{\sigma, [w]} \in \mathbb{R}^{B \times C_{\text{in}} \times \frac{D}{2} \times \frac{H}{2}}$ 对于 $\sigma \in \{LL, LH, HL, HH\}$ ，有

$$\begin{aligned} \mathbf{V}_{b,c,i,j}^{\sigma,[w]} &= \sum_{u=0}^1 \sum_{v=0}^1 \kappa_{u,v}^{\sigma} \tilde{\mathbf{Z}}_{b,c,2i+u,2j+v}^{[w]}, \\ \kappa^{LL} &= l \otimes l, \kappa^{LH} = l \otimes h, \\ \kappa^{HL} &= h \otimes l, \kappa^{HH} = h \otimes h. \end{aligned} \quad (1)$$

局部多相融合将六个源向量 $[\mathbf{Q}^{[w]} \parallel \mathbf{K}^{[w]} \parallel \mathbf{V}^{LL, [w]} \parallel \mathbf{V}^{LH, [w]} \parallel \mathbf{V}^{HL, [w]} \parallel \mathbf{V}^{HH, [w]}]$ 进行拼接，并依次应用卷积和 MLP 运算，最终得到 $\mathbf{L}^{[w]} \in \mathbb{R}^{B \times C_{\text{mid}} \times \frac{D}{2} \times \frac{H}{2}}$ 。与此同时，跨源协同注意力机制将子带证据传输至合并查询网格。设 Π_r 为空间降维后的键值网格（比例 r ）。对于每个头单元 $h \in \{1, \dots, H_a\}$ ，线性映射 $\mathbf{W}^Q \mathbf{h}$ 、 $\mathbf{W}^K \mathbf{h}$ 和 $\mathbf{V}^W \mathbf{h}$ 可生成对应标记。

$$\begin{aligned} \mathbf{q}_{b,i,j}^{[w],h} &= \mathbf{W}_h^Q \mathbf{Q}_{b,i,j}^{[w]}, \mathbf{k}_{b,i',j'}^{[w],h} = \mathbf{W}_h^K \mathbf{K}_{b,i',j'}^{[w]}, \\ \mathbf{v}_{b,i',j'}^{[w],h} &= \mathbf{W}_h^V [\mathbf{V}^{LL,[w]} \parallel \mathbf{V}^{LH,[w]} \parallel \mathbf{V}^{HL,[w]} \parallel \mathbf{V}^{HH,[w]}]_{b,i',j'}. \end{aligned} \quad (2)$$

将 δ_h 定义为人均缩放维度，则位置 (i, j) 处的共注意力合度为

$$\begin{aligned} \mathbf{A}_{b,i,j}^{[w]} &= \bigoplus_a (\mathbf{Q}^{[w]}, \mathbf{K}^{[w]}, \{\mathbf{V}^{\sigma,[w]}\}_{\sigma}) \\ &= \sum_{h=1}^{H_a} \sum_{(i',j') \in \Pi_r} \frac{\exp(\langle \mathbf{q}_{b,i,j}^{[w],h}, \mathbf{k}_{b,i',j'}^{[w],h} \rangle / \sqrt{\delta_h})}{\sum_{(u,v) \in \Pi_r} \exp(\langle \mathbf{q}_{b,i,j}^{[w],h}, \mathbf{k}_{b,u,v}^{[w],h} \rangle / \sqrt{\delta_h})} \mathbf{v}_{b,i',j'}^{[w],h}. \end{aligned} \quad (3)$$

具有低频结构的子空间组合为 $\mathbf{F}^{[w]} = \sigma(\alpha) \mathbf{L}^{[w]} + \sigma(\beta) \mathbf{A}^{[w]} + \gamma J(\mathbf{V}^{LL, [w]})$ ，其中 σ 为逻辑函数， J 用于对齐 LL 的通道。

通道方向的挤压激发从全局平均值 $\mu_b^{[w], c}$ 中形成对角门 $\rho^{[w]}$ 。

$\frac{4}{DH} \sum_{i,j} \mathbf{F}_{b,i,j}^{[w], c}$ 通过两个学习得到的线性映射和一个 Sigm-

oid 函数实现门控融合。 $\hat{\mathbf{F}}_{b,c,i,j}^{[w]} = \rho_{b,c}^{[w]} \mathbf{F}_{b,c,i,j}^{[w]}$ $\mathbb{R}^{B \times C_{\text{mid}} \times \frac{D}{2} \times \frac{H}{2} \times W}$ ， $\text{with kernel } k = (-1, 1, 1, 1)$ $\text{then a 1D depthwise convolution with kernel } k = (-1, 1, 1, 1)$ $\text{is applied, resulting in a } 1 \times 1 \times 3 \text{ learning projection extractor } D^{(2)}_w$ $\text{for processing } \text{rindAg} \text{ co pi as}$ $\text{giving } \mathbf{Y} = \mathcal{D}_w^{(2)}(\mathcal{B}_w(\hat{\mathbf{F}})) \in \mathbb{R}^{B \times C_{\text{out}} \times \frac{D}{2} \times \frac{H}{2} \times W}$ $\text{impact micr olocal transp} \text{关于 r t writes the entire map-}$ $\text{a single lattice-indexed o rm to nest co-atten tion}$ $\text{多相分析、门控处理及 } W \text{ 轴降采样:}$

后是一个 $1 \times 1 \times 3$ 学习投影抽取器 $D^{(2)}_w$ ，用于处理 $\text{rindAg} \text{ co pi as}$ $\text{giving } \mathbf{Y} = \mathcal{D}_w^{(2)}(\mathcal{B}_w(\hat{\mathbf{F}})) \in \mathbb{R}^{B \times C_{\text{out}} \times \frac{D}{2} \times \frac{H}{2} \times W}$ $\text{impact micr olocal transp}$ 关于 $\text{r t writes the entire map-}$ $\text{a single lattice-indexed o rm to nest co-atten tion}$ $\text{多相分析、门控处理及 } W \text{ 轴降采样:}$

$$\begin{aligned} \mathbf{Y}_{b,c',i,j,w'} &= \sum_{c=1}^{C_{\text{mid}}} \sum_{s \in \{-1,0,1\}} \Theta_{c',c,s} \left\{ \sum_{t \in \{-1,0,1\}} \kappa_t \left[\left(\sigma(\alpha) \Psi_c(\mathbf{Q}^{[w]}, \mathbf{K}^{[w]}, \{\mathbf{V}^{\sigma,[w]}\}_{\sigma}) \right. \right. \right. \\ &\quad \left. \left. + \sigma(\beta) \sum_{h=1}^{H_a} \sum_{(i',j') \in \Pi_r} \frac{\exp(\langle \mathbf{W}_h^Q \mathbf{Q}_{b,i,j}^{[w]}, \mathbf{W}_h^K \mathbf{K}_{b,i',j'}^{[w]} \rangle / \sqrt{\delta_h})}{\sum_{(u,v) \in \Pi_r} \exp(\langle \mathbf{W}_h^Q \mathbf{Q}_{b,i,j}^{[w]}, \mathbf{W}_h^K \mathbf{K}_{b,u,v}^{[w]} \rangle / \sqrt{\delta_h})} \right. \right. \\ &\quad \left. \left. \times \mathbf{W}_h^V [\mathbf{V}^{LL,[w]}, \mathbf{V}^{LH,[w]}, \mathbf{V}^{HL,[w]}, \mathbf{V}^{HH,[w]}]_{b,i',j'} \right. \right. \\ &\quad \left. \left. + \gamma J(\mathbf{V}^{LL,[w]})_{b,i,j} \right) \odot \rho_{b,c}^{[w]} \right\}_{\substack{c \\ w'=w'+s+t}}, \end{aligned} \quad (4)$$

其中 Ψ_c 表示应用于六路级联的 $3 \times$ 空间混合加通道 MLP； $\kappa_t \in \{1/4, 1/2, 1/4\}$ 用于编码固定的 W 轴模糊度； $\Theta_{c',c,s}$ 参数化学习得到的 $1 \times 1 \times 3$ 投影-抽取器； $\odot$ 表示通道级门控操作。 $\bar{w}$ 索引表示已被大幅缩减的 W 轴晶格。合并后的分支满足以下条件：

$$\begin{aligned} \mathbf{Q}_{b,c,i,j}^{[\bar{w}]} &= \max_{u,v \in \{0,1\}} [\mathcal{C}_{\max}(\mathbf{X}^{[w]})]_{b,c,2i+u,2j+v}, \\ \mathbf{K}_{b,c,i,j}^{[\bar{w}]} &= \frac{1}{4} \sum_{u,v \in \{0,1\}} [\mathcal{C}_{\text{avg}}(\mathbf{X}^{[w]})]_{b,c,2i+u,2j+v}, \end{aligned} \quad (5)$$

而 $\mathbf{V}^{\sigma, [w]}$ 由上述 Haar 求和式给出；所有求和均在有效晶格之外的指标处满足反射边界条件。

μ PCAD 扩展了中间信息流，并将相位分辨的空间与光谱证据融合为一组陪集对齐、边界感知的表征，从而在简化晶格上生成一个相位纠缠的隐含空间。

3.3. 八相 Coset 纤维化

在编码器-解码器架构中，当高分辨率跳跃特征被传递至较粗的解码器网格时，跨尺度融合会因混叠传播和相位错位而受到阻碍。因此，为在各向异性采样和异质点扩散函数条件下规范这一接口，引入了 OCF 变换——一种陪集纤维化变换，可实现抗混叠预滤波、八相空间-深度分解、相位选择性聚合以及边缘门控整合。设高分辨率跳跃函数 $\mathbf{U} \in \mathbb{R}^{B \times C_s \times D \times H \times W}$ 。一个具有核函数 $g(\delta)$ 的固定可分离低通滤波器 G ：

Π ，其中 $F(i, j, k) = \{\mathbf{P}_{(i, j, k)}^{p, q, r}\}_{pqr}$ ：

$$\mathbf{G} = \mathbf{N}_{\zeta} \left(\mathbf{M} \left(\left(\kappa \star (\Gamma \cdot \bigoplus_a \text{lift}_{\pi} [\mathcal{G} * \mathbf{U}]) \right) \right) \right), \quad (10)$$

with $(\text{lift}_{\pi}[\cdot])_{b,c,i,j,k}^{pqr} = (\cdot)_{b,c,2i+p,2j+q,2k+r}$.

因此，OCF增加了跳过路径上的中间数据流，将相位偏移高分辨率证据与解码器晶格对齐，并诱导出一个陪集纠缠的隐含空间，在分辨率降低的情况下仍能保留边缘局部细节。

4. 实验与结果分析

4.1. Datasets

我们在涵盖CT、MRI和OCT的15个公开基准数据集上评估了我们的方法，包括SegTHOR[21]、FLARE2022[33]、SKI10[14]、FeTA2021[39]、OIMHS[55]、MSD Brats肿瘤[2]、MSD 肺肿瘤[2]、MSD 胰腺肿瘤[2]、MSD 脾脏[2]、MSD 结肠癌[2]、HOCMvalvesSeg[60]、CrossMoDA 2021[7]、SLIVER07[13]、covid-19 CT Seg[19]以及FLARE2021[31]。数据集划分方式、分辨率及标注细节详见补充材料。

4.2. 实施细节

为标准化输入统计数据，需对强度值进行裁剪处理并应用最小-最大归一化。所有方法均采用相同的三维数据增强技术以确保可比性：随机旋转、随机平移和随机缩放，从而使基准表反映的是数据结构特征而非增强效果差异。需注意训练阶段采用AdamW优化器[30]配合DiceCE损失函数。图像数据被随机裁剪为96×96×96大小的图像块（批量大小为1），并执行320,000次优化迭代；推理阶段使用MONAI的三维滑动窗口算法（采用相同图像块尺寸），并对每个体数据输出解码结果。所有实验均在配备Python 3.10、PyTorch 2.5.1及CUDA 12.1的8台NVIDIA GeForce RTX 4090服务器上完成。

4.3. 与最先进方法的比较

为验证所提方法的有效性，我们在15个公开数据集上对CROWn与现有最先进方法进行了对比实验。评估指标包括交并比（IoU）、Dice系数和HD95值。如表1所示，实验结果充分证明了CROWn在这些基准测试中的有效性。

CROWn在各向异性数据集（FLARE2022、MSD 胰腺肿瘤）及精细结构数据（OIMHS）中均展现出显著提升。图2中的定性可视化对比结果进一步证实了这一趋势：CROWn能生成更清晰、无渗漏的胰腺肿瘤边界；在OIMHS数

据中可保持连续的层界面并减少阶梯状伪影；在多器官FLARE2022数据集中则能有效抑制虚假分割片段。

在重叠度指标方面，CROWn在所有数据集上均实现了最高的交并比（IoU）和Dice值。从边界误差角度而言，HD95值普遍降低，表明具备别名感知的降采样算法与校准跳跃融合技术能够在跨尺度整合过程中保留边缘特征信息。

实验结果与 μ PCAD和OCF的机制相符。 μ PCAD在下采样过程中通过将池化查询/键值与小波子带值结合，并应用显式抗锯齿处理，实现多相分析和跨源协同注意力机制。这种设计既能保留边界相关的高频内容，又能抑制由步长引入的虚假成分。 μ PCAD与OCF则通过八相余集分解、相位注意力和边缘门控调制对跳跃连接进行重构，在融合前将高分辨率证据对齐至解码器尺度，并减弱由混叠效应传播的高频伪影。 μ PCAD与OCF的协同作用不仅实现了稳定的重叠效果和更低的边界偏差，还提升了在各向异性间距及异构协议下的拓扑结构稳定性。

总体而言，CROWn在重叠度指标上实现了稳健且一致的最优性能，降低了边界误差，并提升了拓扑一致性。该方法在CT、MRI和OCT数据集上均展现出跨模态鲁棒性。

4.4. 消融研究

为验证支撑CROWn框架的采样-对齐假说：(i) 具有别名感知能力的降采样应在减弱步长相关伪影的同时保留边界相关的细节（ μ PCAD）；(ii) 相位分辨跳跃校准应使高分辨率证据与解码器晶格对齐（OCF）。因此，我们针对每个模块探讨四个问题：跨主干插入、定位（沿编码器或跳跃路径分阶段进行）、经典模块比较与归因（ μ PCAD的方向性；OCF的组件消融效应）。

4.4.1. μ PCAD 的有效性

(1) 编码器各阶段的合理布局。我们对比了在MSD肺肿瘤模型中，将 μ PCAD仅置于单一编码器阶段与分布于所有编码器阶段的情况。如补充材料表S2所示，将 μ PCAD均匀分布于所有阶段能带来最显著且稳定的性能提升，这表明混叠控制不仅适用于特定深度，更对每个降采样界面均具有积极作用。

(2) μ PCAD在骨干网络中的定性影响。在CNN、Transformer、ConvNeXt和Mamba基线模型中引入 μ PCAD可持续提升MSD胰腺肿瘤数据集及FLARE2022数据集上的重叠率与边界检测指标（详见补充材料表S3）。如图S1所示（补充材料），在经典骨干网络中集成 μ PCAD后，生成的分割结果具有更清晰、边界更连续的特点。

表1. 在15个公开基准数据集上与最先进的三维医学图像分割方法的比较。CROWn在所有数据集中均实现了最佳的交并比（IoU）和Dice值，在各向异性数据集及精细结构数据上表现尤为突出，充分体现了其强大的跨模态鲁棒性。

方法	根源	SegTHOR			FLARE2022			SKI10			FeTA2021			OIMHS		
		IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95
3D U-Net [6]	MICCAI 2016	83.46	90.66	2.87	80.17	87.87	10.98	78.46	86.73	3.51	78.54	87.79	2.41	87.69	93.18	2.91
V-Net [34]	3DV 2016	82.35	89.96	3.02	71.20	80.77	45.66	38.18	46.62	-	48.65	62.54	-	80.18	88.26	6.32
3D UX网络[22]	ICLR 2023	83.36	90.67	3.21	80.44	87.98	6.32	78.05	86.31	3.42	78.70	87.90	2.33	88.37	93.55	2.87
UNETR [12]	WACV 2022	80.25	88.59	3.83	73.74	82.83	13.68	76.46	85.25	4.72	77.41	86.99	2.58	85.65	91.85	4.36
SwinUNETR [11]	MICCAI 2022	83.14	90.43	3.16	80.57	88.18	12.76	77.53	85.84	4.18	78.25	87.58	2.47	88.15	93.44	3.34
nnFormer [61]	TIP 2023	77.90	86.95	4.25	71.55	81.32	18.80	76.52	85.29	4.13	78.38	87.70	2.38	73.03	82.27	19.25
MedNeXt [42]	MICCAI 2023	81.82	89.59	3.90	78.57	86.83	6.55	78.67	86.87	3.41	78.78	87.95	2.32	87.19	92.78	2.20
SegFormer3D [40]	CVPR 2024	78.66	87.51	4.30	71.51	80.99	22.50	69.54	79.30	-	76.38	86.38	2.58	82.89	90.02	3.64
SegMamba [50]	MICCAI 2024	83.64	90.78	2.97	81.58	88.86	9.21	78.42	86.70	3.43	78.96	88.08	2.29	88.83	93.83	2.66
UNesT [57]	Media 2023	83.38	90.62	2.94	80.58	88.31	8.37	78.25	86.54	3.41	78.82	87.99	2.32	88.69	93.76	2.72
SwinSMT [41]	MICCAI 2024	82.94	90.36	3.24	78.63	86.65	15.83	77.78	86.16	3.81	77.95	87.36	2.52	88.13	93.40	2.92
VSmTrans [25]	Media 2024	82.85	90.34	3.09	80.66	88.17	6.77	73.49	82.53	12.06	75.90	86.06	2.82	88.56	93.70	2.62
SegTom [38]	JBHI 2025	81.77	89.59	3.29	75.41	84.29	10.13	78.49	86.74	3.26	78.71	87.92	2.36	85.07	91.49	5.19
nnWNet [62]	CVPR 2025	82.73	90.25	3.03	69.60	79.69	-	43.29	51.88	-	29.40	40.65	-	77.81	86.82	15.02
SuperLightNet [56]	CVPR 2025	82.68	90.15	3.03	78.25	86.51	15.38	78.26	86.58	3.48	78.23	87.60	2.41	83.85	90.62	3.50
DiffUNet [51]	Media 2025	83.49	90.72	2.96	81.44	88.92	11.53	79.03	87.13	3.11	78.73	87.92	2.30	88.80	93.82	3.77
HiPaSNet [5]	《自然》杂志，2025年	82.55	90.15	3.24	77.61	85.95	12.62	77.47	85.98	4.26	78.71	87.92	2.36	87.50	93.00	2.83
皇冠（我们的）	-	84.05	91.05	2.86	82.65	89.76	4.30	79.16	87.26	3.12	79.04	88.13	2.30	89.68	94.36	2.60

方法	根源	MSD 子宫颈努尔			MSD 肺肿瘤			MSD 胰腺			MSD 脾脏			MSD 结肠癌		
		IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95
3D U-Net [6]	MICCAI 2016	67.24	78.74	4.93	58.93	73.20	79.68	54.14	67.99	26.36	91.84	95.74	1.05	42.90	55.69	96.14
V-Net [34]	3DV 2016	32.83	40.71	-	51.61	64.29	30.44	47.92	61.59	-	87.39	93.23	17.21	23.59	34.00	145.65
3D UX网络[22]	ICLR 2023	65.82	77.65	4.73	56.76	70.07	43.94	51.53	64.21	40.67	91.37	95.48	1.18	30.23	41.40	88.66
UNETR [12]	WACV 2022	63.05	75.33	7.18	44.43	57.72	129.54	38.80	51.69	25.63	89.84	94.61	1.68	18.91	28.35	127.05
SwinUNETR [11]	MICCAI 2022	66.08	77.87	5.27	59.52	73.29	51.46	50.39	63.43	44.79	91.48	95.53	1.13	33.84	46.41	130.48
nnFormer [61]	TIP 2023	61.65	74.28	6.69	50.01	63.63	49.72	47.83	60.99	24.57	83.83	91.19	68.29	19.31	29.95	214.26
MedNeXt [42]	MICCAI 2023	66.71	78.39	4.90	53.74	67.39	73.46	53.49	67.25	11.02	90.66	95.09	1.23	33.75	46.35	63.54
SegFormer3D [40]	CVPR 2024	52.94	65.44	-	39.58	53.50	127.71	46.15	59.48	-	76.68	86.37	4.67	30.46	42.43	77.79
SegMamba [50]	MICCAI 2024	67.24	78.75	4.91	57.14	70.97	44.35	54.85	67.69	17.67	92.38	96.03	1.18	38.99	52.61	95.38
UNesT [57]	Media 2023	65.41	77.33	5.18	57.44	70.41	20.56	51.40	65.04	14.17	91.84	95.74	1.10	39.03	50.76	63.78
SwinSMT [41]	MICCAI 2024	65.04	77.05	5.25	58.88	73.06	51.99	49.29	62.67	31.93	90.73	95.13	1.14	35.03	46.94	97.71
VSmTrans [25]	Media 2024	60.91	73.48	8.16	58.93	72.43	29.96	55.09	68.53	42.56	91.96	95.79	5.79	41.26	54.56	85.15
SegTom [38]	JBHI 2025	65.95	77.70	5.35	55.91	69.27	42.23	49.38	62.60	-	91.03	95.28	17.65	36.60	48.96	105.63
nnWNet [62]	CVPR 2025	32.27	39.96	-	51.08	64.67	16.47	47.78	60.49	-	90.31	94.83	1.66	27.04	37.81	99.94
SuperLightNet [56]	CVPR 2025	67.09	78.75	4.71	53.91	67.95	74.95	53.26	67.09	15.20	91.10	95.32	1.23	35.64	48.77	84.79
DiffUNet [51]	Media 2025	67.29	78.77	4.74	57.67	71.35	20.56	55.27	68.46	-	92.09	95.86	1.13	39.52	52.41	91.14
HiPaSNet [5]	《自然》杂志，2025年	67.35	78.90	4.79	53.88	67.33	46.58	53.09	66.57	66.52	91.62	95.61	1.27	35.33	47.58	134.45
皇冠（我们的）	-	67.61	79.07	4.71	60.46	73.63	14.66	56.68	70.20	11.72	92.65	96.17	1.18	43.80	55.89	75.99

方法	根源	HOCMvalvesSeg			CrossMoDA2021			SLIVER07			COVID-19 CT扫描图像			FLARE2021		
		IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95	IoU	骰子	HD95
3D U-Net [6]	MICCAI 2016	74.21	84.09	11.98	67.95	79.76	1.97	87.46	93.10	48.23	71.50	81.92	51.96	88.67	93.50	5.81
V-Net [34]	3DV 2016	58.49	71.90	29.67	68.08	79.65	2.10	83.03	90.46	71.60	8.78	13.68	-	77.00	85.12	14.59
3D UX网络[22]	ICLR 2023	74.30	84.19	11.99	66.79	78.76	2.60	90.62	95.03	26.23	71.44	81.75	57.31	88.97	93.66	4.47
UNETR [12]	WACV 2022	70.89	81.63	13.41	61.29	74.39	10.95	87.12	93.02	76.41	62.38	74.20	61.26	85.88	91.52	6.24
SwinUNETR [11]	MICCAI 2022	73.51	83.62	12.84	69.18	80.49	6.36	91.31	95.42	25.15	70.29	80.97	81.29	88.84	93.61	5.22
nnFormer [61]	TIP 2023	68.38	79.89	17.94	20.00	26.04	-	86.81	92.86	72.59	67.52	79.07	50.66	79.86	86.50	11.61
MedNeXt [42]	MICCAI 2023	73.44	83.53	12.11	67.25	78.93	1.84	89.88	94.55	51.30	70.06	80.55	34.54	89.27	93.91	2.33
SegFormer3D [40]	CVPR 2024	71.74	82.48	13.14	53.54	68.00	3.80	84.40	90.89	43.97	49.07	57.82	36.17	85.87	91.83	8.93
SegMamba [50]	MICCAI 2024	74.13	84.09	11.96	67.65	79.29	10.46	91.18	95.33	13.90	71.73	81.42	49.95	89.02	93.73	8.53
UNesT [57]	Media 2023	73.94	83.93	12.48	68.61	80.15	1.92	89.35	94.28	34.35	69.81	80.39	45.62	89.28	93.90	2.50
SwinSMT [41]	MICCAI 2024	74.14	84.06	11.63	68.99	80.40	10.22	89.89	94.62	28.22	68.81	79.55	46.39	88.66	93.56	3.25
VSmTrans [25]	Media 2024	73.38	83.45	13.43	67.32	79.20	14.83	91.35	95.46	27.07	64.31	75.53	81.06	88.25	93.17	19.65
SegTom [38]	JBHI 2025	69.59	80.58	14.75	67.58	79.42	1.95	83.52	90.43	58.13	62.88	74.49	67.64	87.66	92.88	2.94
nnWNet [62]	CVPR 2025	60.94	73.51	-	64.52	76.99	8.65	82.91	90.42	90.69	12.23	17.98	-	69.50	77.53	29.30
SuperLightNet [56]	CVPR 2025	71.18	81.84	13.67	64.09	76.39	23.96	89.87	94.61	16.95	72.62	82.87	36.32	86.91	92.30	8.34
DiffUNet [51]	Media 2025	73.96	83.96	12.48	68.51	80.05	1.80	90.24	94.81	41.17	71.09	81.63	60.21	88.71	93.59	4.80
HiPaSNet [5]	《自然》杂志，2025年	71.93	82.52	14.40	68.48	79.99	9.53	89.55	94.35	35.93	70.54	81.43	37.47	88.85	93.59	2.44
皇冠（我们的）	-	74.84	84.63	11.56	69.27	80.65	1.77	91.68	95.63	26.45	73.91	83.75	32.50	89.33	94.00	5.35

泄漏现象减少、孔洞更少，且小型结构得以更好地保留。对于那些天然下采样更容易产生混叠效应的主干网络，改进效果更为显著，这支持了以下观点： μ PCAD 提出的池化子带协同注意力机制与显式低通滤波器既能有效保留边界

相关细节，又能抑制步长引起的伪影。结果表明，基于多相位感知的协同注意力降采样方法具有广泛的适用性，而非特定于某种架构。




图2. MSD 胰腺肿瘤、OIMHS 和FLARE2022数据集的定性比较。

(3) 与经典模块相比。以3D U-Net作为骨干网络为基础，SE[15]、CBAM[48]、Transformer[46]、UXNet模块[22]、MedNeXt模块[42]或 μ PCAD均被集成到OIMHS的编码器中。如表2、图3及图S2（补充材料）所示，虽然通用通道/空间重加权或大核更新方法能起到一定作用，但 μ PCAD能产生最佳边界轮廓——即当体素具有各向异性时，考虑混叠效应的降采样比单纯提升容量更为有效。 μ PCAD通过将池化查询/键值与小波子带值结合，并采用显式抗混叠机制，直接管理降采样过程，从而在各向异性条件下更好地保留边缘细节。

表2. μ PCAD 与经典模块的比较。

方法	OIMHS			
	IoU	骰子	ASSD	HD95
3D U-Net [6]	87.69±2.79	93.18±1.75	0.54±0.57	2.91±5.45
+SE [15]	88.88±2.73	93.89±1.68	0.53±0.52	2.84±5.26
+CBAM [48]	88.56±3.06	93.69±1.92	0.47±0.50	2.81±5.14
+变压器[46]	88.26±3.10	93.50±1.96	0.69±0.68	2.99±5.43
+UXNet 块[22]	88.63±2.76	93.74±1.72	0.61±0.56	2.90±5.39
+使用 MedNeXt 阻塞[42]	88.79±2.86	93.83±1.77	0.52±0.52	2.83±5.25
+ μ PCAD（我们的）	89.31±2.86	94.14±1.74	0.44±0.36	2.43±4.28

(4) 轴向取向。对内部消融区域进行分析后发现， μ PCAD变体沿OIMHS上的D轴、H轴和W轴方向扩展。W轴构型在重叠度、边界特征及拓扑结构指标方面实现了最佳平衡（表3）。 μ PCAD的多相分析与协同注意力融合方法在抑制由步长效应引起的虚假相位成分的同时，有效提升了微局域高频信号检测精度，这与重叠度、边界特征及拓扑结构方面的改进效果一致。

表3. 关于 μ PCAD的轴向分析。

方法	OIMHS				
	IoU	骰子	ASSD	HD95	Adj-兰德
(D)	88.98±3.22	93.93±2.03	0.43±0.48	2.68±4.97	93.44±2.07
(H)	88.43±3.20	93.62±1.98	0.66±0.71	2.88±5.32	93.09±2.05
我们的(W)	89.68±2.61	94.36±1.56	0.42±0.46	2.60±4.99	93.92±1.64

总体而言，通过将基于聚类分析的查询结果与键

值、小波子带值共同处理，并应用显式低通滤波器， μ PCAD能有效降低跨骨干网络及数据集的步长引起的混叠现象，在厚切片轴方向上边界尤为清晰且稳定。

4.4.2. OCF 的有效性

(1) 在跳跃连接处的分阶段放置。如补充材料表S4所示，将OCF应用于单个跳跃连接与应用于所有跳跃连接时，后者效果更优。该方法能在每个融合点实现相位校准传输，而不仅限于瓶颈区域或最高分辨率处。

(2) OCF在不同骨干网络上的定性影响。如表S5和图S3（补充材料）所示，在MSD胰腺肿瘤数据集和FLARE2022数据集上，通过OCF增强多种基线模型能持续提升模型重叠率并降低边界误差。这一效果在存在跳跃融合不稳定的模型（即采用八相空间到深度结构并结合相位注意力机制的模型）中尤为显著，此类模型可提供更易于融合的解码器尺度特征。

(3) 与经典模块相比。在OIMHS数据集上，我们对比了使用3D U-Net时，在跳跃路径中分别采用SE[15]、CBAM[48]、Transformer[46]、UXNet模块[22]以及MedNeXt模块[42]与仅在跳跃路径中使用OCF的效果。如表4、图4及图S4（补充材料）所示，OCF能实现更优的重叠度与边界精度之间的平衡；且相较于经典模块，对跳跃路径中的跨尺度相位对齐进行校正对边界保真度的影响更为显著。

表4. OCF 与经典模块的对比。

方法	OIMHS			
	IoU	骰子	ASSD	HD95
3D U-Net [6]	87.69±2.79	93.18±1.75	0.54±0.57	2.91±5.45
+SE [15]	88.22±3.05	93.49±1.90	0.58±0.54	2.86±4.71
+CBAM [48]	88.39±3.11	93.49±1.90	0.58±0.54	2.86±4.71
+变压器[46]	88.49±3.14	93.64±1.96	0.48±0.52	2.82±5.31
+UXNet 块[22]	88.37±2.90	93.58±1.81	0.56±0.53	2.82±5.12
+使用 MedNeXt 阻塞[42]	88.75±3.01	93.81±1.85	0.64±0.67	2.88±5.63
+OCF（我们的）	88.89±3.07	93.88±1.92	0.48±0.43	2.64±4.71

(4) OCF内部的组件归因。关于FLARE2022的详细组




图3. 在 OIMHS 数据集上 μ PCAD 的定性比较。




图4. 在 OIMHS 数据集上 OCF 的定性比较。

件研究总结于表5。移除抗混叠预滤波器、强制采用均匀（非注意力）相位混合、打乱余集相位或省略边缘门控操作，均会降低完整 OCF 方案的有效性。完整的配置方案（抗混叠处理、八相分解、相位注意力机制、边缘门控整合）能产生叠加增益效应，这证实了谱预处理与相位选择性传输均为实现稳定跳过融合所必需的元素。

表5. 关于 OCF 的相位抗锯齿处理。

方法	FLARE2022				
	IoU	骰子	ASSD	HD95	Adj-兰德
w/o 模糊	81.96±8.62	89.15±6.24	1.33±1.07	4.46±5.00	89.10±6.27
w/o 阶段注意	81.94±7.69	89.26±5.46	1.27±1.10	5.33±5.46	89.21±5.48
已修复位移相	81.53±9.02	88.80±6.62	1.22±1.09	4.62±5.27	88.75±6.64
我们的：我们的	82.65±7.20	89.76±5.03	1.17±0.96	4.30±4.93	89.70±5.04

总体而言，OCF 通过八相空间-深度分解、相位选择性注意力机制以及边缘门控技术，有效实现了高分辨率跳跃融合的正则化。这些机制协同作用，抑制了混叠效应传播与对齐偏差，从而实现相位相干的特征整合并提升边界保真度。

4.5. 模型复杂度比较

为评估计算效率，我们使用htop Python库报告了参数数量和FLOPs值，并以 $96 \times 96 \times 96$ ，作为输入数据（如表6所示）。CROWn模型包含2378万个参数，对应的FLOPs值为199.58G。虽然较小规模的模型能降低计算量，但其在表1中的各项指标普遍较低；相反，高容量设计虽增加了参数数量和FLOPs值，但在不同数据集上并未带来一致的性能提升。CROWn在参数与精度之间取得了良好的平衡：其计算开销显著低于3D UX-Net [22]、SegMamba [50]和nnWNet [62]等大型模型堆栈，同时其精度及边界/拓扑度量指标仍具有竞争力。这种效率特性与 μ PCAD 和 OCF 的设计初衷一致——基于别

名感知的降维策略将计算资源集中在网络尺度转换处而非更深或更宽的主干网络中；而基于陪集分组且相位对齐的跳跃机制则能在融合前减少冗余的高分辨率通道。因此，CROWn既避免了大型Transformer模型的复杂结构负担，又克服了CNN的全局建模局限性，在保持准确性和结构一致性的同时实现了适中的计算开销。

表6. 代表性三维医学分割模型在 $96 \times 96 \times 96$ 输入尺寸下的模型规模、计算参数及FLOPs性能。

方法	Params	浮点运算次数	方法	Params	浮点运算次数
3D U-Net [6]	5.75 M	135.88 G	V-Net [34]	45.61 M	331.10 G
3D UX网络[22]	53.00 M	631.76 G	UNETR [12]	92.62 M	82.58 G
SwinUNETR [11]	61.99 M	329.46 G	nnFormer [61]	149.10 M	224.36 G
MedNeXt [42]	11.64 M	174.10 G	SegFormer3D [40]	4.49 M	4.97 G
SegMamba [50]	64.24 M	655.62 G	UNesT [57]	84.88 M	258.11 G
SwinSMT [41]	15.51 M	83.71 G	VSmTrans [25]	49.86 M	358.89 G
SegTom [38]	3.85 M	49.71 G	nnWNet [62]	52.23 M	648.26 G
SuperLightNet [56]	2.75 M	19.52 G	DiffUNet [51]	178.12 M	6333.85 G
HiPaSNet [5]	6.40 M	123.58 G	我们的：我们的	23.78 M	199.58 G

5. 结论

本文介绍了CROWn——一种将采样理论与表示学习相结合的体积分割框架，能够有效处理异质性间距和显著各向异性问题。 μ PCAD 通过将池化描述符与小波子带融合，实现了具有抗混叠特性的下采样处理：既能保留边界相关的高频成分，又能抑制步长伪影。OCF 采用抗混叠机制，并通过空间-深度分解、相位注意力及边缘门控调制对跳跃特征进行相位对齐。这些模块协同作用，通过校准的多尺度融合实现精确的局部轮廓划分与稳定的全局结构。在涵盖CT、MRI和OCT的15个公开数据集上，CROWn在重叠率、边界精度和拓扑结构指标方面均展现出稳定提升。未来研究方向包括采用自适应模态权重的更强多模态融合技术，以及迁移学习与领域适应方法（如自监督预训练和测试时适应）。此外，我们计划开发基于不确定性感知的边界监督机制以及基于拓扑结构的跳跃特征选择方案，以实现更精细的结构解析。