

MARSS：基于模块化注意力机制与状态空间模型的雷达语义分割

陈凤宇*清华大学 SIGS

中国深圳

chenfy23@mails.tsinghua.edu.cn

田坦*清华大学 SIGS

中国深圳

tt23@mails.tsinghua.edu.cn

滕丽† 清华大学 SIGS

中国深圳 liteng21@mails.tsinghua.

edu.cn

圆天拳清华大学深圳

SIGS，中国

qyt23@mails.tsinghua.edu.cn

廖清民† 清华大学 SIGS

中国深圳 liaoqm@tsinghua.

edu.cn

摘要

雷达语义分割 (RSS) 对于在恶劣条件下实现稳健的感知至关重要，但面临着独特的挑战：雷达频率图具有高度各向异性、多尺度性、稀疏性和噪声性强的特点。专为相机图像设计的传统CNN或Transformer架构无法充分应对这些特性，导致性能下降。我们提出 MARSS (模块化注意力增强型雷达语义分割) 这一创新框架，通过整合三个专用模块来解决雷达特有的问题。编码器中的RADE模块采用轻量级通道自注意力机制和深度卷积运算，能够稳健地编码含噪声且各向异性的特征；中间层中的RFAF模块通过多尺度特征融合和区域级注意力机制提取关键雷达特征；解码器中的RADM模块则结合状态空间模型与轴向自注意力机制，重建具备各向异性及时序感知特性的分割掩码。这些组件协同作用可有效抑制噪声、分离距离-多普勒特征，并确保时空一致性。在Carrada数据集上，MARSS算法的表现显著优于以往的RSS方法，尤其对于小型快速移动目标而言。

1. 引言

雷达传感器因其在低能见度或恶劣天气条件下的高可靠性，正日益广泛地应用于自动驾驶[23]和机器人技术[13]领域。与RGB图像不同，雷达回波信号通常以频域图形式呈现。

(例如距离-多普勒法和距离-角度法)。该频率图能提供关于物体速度的丰富信息，但也为语义分割带来了独特的挑战。

首先，雷达频率图具有各向异性[18]，每条轴线代表不同的物理量。雷达图像中的模式表现出显著的方向性偏差：如图1所示，特征在距离维度和速度维度上的表现均不同。这与RGB影像中各向同性的纹理模式形成鲜明对比[20]。专为相机图像设计的传统卷积神经网络 (CNN) 并不适合捕捉这种水平/垂直方向上的上下文不平衡特性。

其次，雷达成像具有固有的空间多尺度特性。例如，大型缓慢移动的物体会产生宽幅、低频的反射信号（在距离范围内分布广泛但多普勒效应较窄）；而小型快速移动的物体则会产生尖锐的高频条纹信号（距离范围较窄但多普勒效应较宽）。分割模型必须超越固定的感受野范围，才能处理此类多尺度频率信息[29]。

此外，雷达图像具有极高的稀疏性和噪声特性[15]。雷达快速傅里叶变换 (FFT) 图像中的大多数像素几乎不显示回波信号（呈现黑色背景），仅在车辆、行人等真实反射体所在位置出现少量峰值。同时，雷达信号还受到斑点噪声和多径伪影的影响，导致某些区域出现误检响应且信噪比较低；小型目标的信号强度可能仅略高于噪声基底水平。这种高动态范围与高噪声环境使得分割网络难以学习到有效的特征参数。

为解决这些局限性，我们提出了 MARSS —— 一个基于模块化注意力机制的雷达语义分割框架，该框架将雷

¹同等贡献。

²通讯作者。




图1。从左至右，各图分别展示了：(a) 同步拍摄的相机图像；(b) 三维距离-多普勒（RD）输入信号的幅度表示；以及 (c) 二维距离-角度（RA）表示。雷达频率图本质上是三维结构，涵盖距离轴、角度轴和多普勒轴三个维度；沿任一维度进行投影即可获得相应的透视视图。如图所示，雷达频率数据在不同方向上均呈现显著各向异性特征，目标信号表现为嵌入在强烈背景噪声中的尖锐峰值。

达特有的设计原则融入网络的每个阶段。MARSS 包含三个受最新研究进展启发的创新模块：在编码器中，RADE利用通道注意力和空间注意力[24]来稳健地编码含噪声特征；在特征融合层，RFAF实现了多尺度特征融合与区域级注意力机制[21]；在解码器中，RADM将Mamba状态空间模型[5, 12]与轴向自注意力机制相结合，有效处理雷达数据中的各向异性和长距离依赖性。这些模块相互协同，共同应对雷达数据的低信噪比、各向异性及时变特性。

我们在公开的Carrada数据集[17]上评估了 MARSS 模型。结果表明，MARSS 显著优于现有方法，尤其在检测小型快速目标时提升了鲁棒性；消融实验进一步证实了各模块间的协同增效作用。综上所述，我们的贡献如下：

- MARSS 框架：我们提出了一种模块化RSS网络，通过以下模块嵌入雷达特有的归纳偏置特征（各向异性、稀疏性、多尺度特性）：
 - a) RADE模块：一种新型编码器模块，结合通道注意力机制与空间注意力机制以抑制噪声并重新校准通道。
 - b) RFAF 模块：雷达特征自适应融合模块，可从雷达频谱图中不同尺度和位置分离出显著特征。
 - c) RADM 解码器：一种基于Mamba架构的解码器，结合Mamba状态空间模型与轴向自注意力机制，能够高效处理雷达数据中的各向异性及长程依赖性。
- 我们的研究结果证明了模块化设计在雷达感知领域的有效性，并在carrada和carrada-RAC数据集上树立了新的最先标准[17, 26]。

2. 相关工作

2.1. 雷达语义分割

RSS方法通过借鉴其他传感模态的技术并开发专用雷达运算器，已取得显著进展。早期方法主要将基于经典点云[23]或图像处理的流程应用于雷达数据：例如，erase-Net将雷达回波数据转换为点云表示，并由稀疏三维CNN进行处理；而RSS-Net[8]则采用U-Net[19]变体实现频率图分割；RAMP-CNN[4]进一步引入多尺度卷积和时空模块以捕捉运动特征；近期基于Transformer的模型（TransRSS[30]）及多视角融合方法（TransRadar[2]）则提升了全局上下文建模能力，并实现了距离-多普勒域与距离-角度域之间的跨视角一致性。与此同时，针对雷达特性的运算器如PeakConv[26]、AdaPKC[11]和 TARSS -Net[28]着重强调峰值响应或时间相干性。尽管如此，现有大多数方法仍未有效分离雷达频谱中嵌入的方向分量。相比之下，我们的研究直接针对这一局限性，引入了旨在自适应分离方向性信息与多尺度信息的注意力模块。

2.2. 图像语义分割

在图像语义分割领域，U-Net[19]等编码器-解码器架构仍是主流范式。为增强多尺度上下文感知能力，空洞空间金字塔池化（ASPP）模块[1]已被广泛应用于特征增强。与此同时，各类注意力机制进一步提升了特征细化效果：SENet[7]通过建模通道间依赖关系，CBAM[24]则融合了通道注意力与空间注意力。受这些设计启发，我们提出的 RFAF 模块结合通道注意力与空间注意力实现多尺度特征融合，以适应雷达信号的稀疏性和噪声特性。除像素级注意力外，区域级注意力[21]已被证明能有效突出任务相关区域。基于此，我们将类似的区域级注意力方案应用于雷达特征表示学习，重点提取对应物理目标的回波信号同时抑制杂波干扰。为更深入地捕捉长程依赖关系，轴向自注意力机制[22]可沿各个轴向分解二维注意力分布；而结构化状态空间模型（SSM）[5]则具备强大的序列建模能力。我们的 RADM 模块将基于SSM的建模方法与轴向注意力机制相结合，分别捕捉径向轴与多普勒轴上的依赖关系，有效融合了状态空间动态建模的高效性与注意力机制的表达能力。总体而言，所提出的模块将雷达特有的先验信息融入雷达系统中。




图2.提出的 MARSS 网络架构：MARSS 以雷达频率图的三种视角视图作为输入。每个视图首先经RADE模块增强以优化原始特征，随后输入编码器分支；中间特征再由 RFAF 模块进一步强化，并与未增强版本进行拼接；最终通过 RADM 重建，并利用解码器将其解码为语义分割掩码。

语义分割任务，从而弥合了视觉架构与雷达感知模型之间的差距。

3. 方法

整个 MARSS 架构遵循编码器-解码器范式[16]，各阶段均配备专用模块（如图2所示）。我们通过独立处理路径对雷达频谱图的三种视角图像（距离-多普勒、角度-多普勒及距离-角度）进行处理，并在输出端将其解码为距离-多普勒与距离-角度目标掩码。我们提出的三个雷达特征增强模块（RADE、RFAF 和 RADM）分别嵌入分割流程的编码器阶段、中间特征交互阶段及解码器阶段，以提供强大的雷达感知引导。此外，我们在编码阶段和特征融合阶段均采用小波变换引导的REM（雷达增强模块），用于实现轴向解耦及各向异性雷达特征的增强。

3.1. REM：雷达增强模块

REM算法在数据处理流程的编码阶段及中间特征融合阶段均基于小波变换。二维离散小波变换将信号分解为LL、LH、HL和HH四个子带，分别包含低频分量、高频分量及对角分量；该变换实现了多分辨率与多方向分析功能[3, 14]。后续每个处理分支都将聚焦于特

定子带，从而有效捕捉雷达频率图中的各向异性特征及多频段特性。

如图3所示，每个REM单元包含四个分支（类似于小波变换）：LL分支采用一种 1×1 个卷积层用于提取全局低频信息，而HH分支进一步引入 3×3 个卷积层以建模对角线高频成分。LH分支首先应用一个垂直方向的 1×3 轴向卷积来捕获垂直方向上的低频特征，然后再使用一个水平方向的 3×1 axial convolution and a standard 3×3 卷积来聚合水平方向的高频特征；HL分支则执行相反的操作。




图 3. REM：雷达增强模块

3.2. RADE：基于雷达信息的去噪编码器

雷达频谱本质上具有低信噪比特性，并呈现各向异性的




图4. RADE: 雷达感知去噪编码器。注意DWC代表深度卷积，PWC代表点卷积（例如1×1卷积）。

杂波模式，这使得信道畸变和空间干扰都成为高质量语义分割中的主要难题。为获取抗噪性强且能保留结构特征的特征，我们提出了雷达感知去噪编码器（RADE），该模型将轻量级信道校准与CBAM风格[24, 27]的双注意力机制精炼相结合。在REM特征增强阶段后引入RADE，可确保后续网络层接收经过噪声抑制和目标增强处理的特征；这些优化后的特征随后输入编码器，并采用三维卷积神经网络（3D CNN）进行处理。

给定输入 $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ ，RADE首先使用GELU进行 1×1 投影以生成谱压缩表示，并采用挤压-激励式信道加权方法抑制噪声主导的信道：

$$\mathbf{X}_c = \sigma_{\text{sig}}(f_{\text{MLP}}(\text{GAP}(\mathbf{X}))) \odot \mathbf{X}, \quad (1)$$

其中GAP提取全局频谱统计量，而 f_{MLP} 则生成信道重要性系数。该操作通过降低受干扰或多径衰落影响信道的权重，从而稳定雷达频率区间。

为进一步突出频谱-多普勒网格中具有几何意义的区域，RADE算法采用基于通道聚合描述符计算出的空间注意力掩模：

$$\mathbf{X}_s = \sigma_{\text{sig}}(\text{Conv}_{7 \times 7}([\text{AvgPool}; \text{MaxPool}](\mathbf{X}_c))) \odot \mathbf{X}_c. \quad (2)$$

该空间掩模可增强局部反射结构（如物体边界或微动条纹），这些结构是雷达图像语义分割的关键特征。

通过将信道去噪与空间结构建模相结合，RADE能够同时实现针对特定视图的噪声抑制以及基于几何特征的图像增强。信道注意力机制可有效缓解不同雷达接收器或频段间的信号不稳定性；空间注意力机制则能在复杂杂波环境中保持目标图案的一致性。因此，RADE能生成稳健且低噪声的潜在特征表示，显著提升复杂雷达场景下的分割精度。




图5. RFAF: 雷达特征自适应融合模块。PWC表示逐点卷积（例如1×1卷积）。

3.3. RFAF: 雷达特征自适应融合模块

在网络的中间层中，雷达特征通常呈现复杂的多尺度模式，需要同时对不同尺度的特征进行处理，并重点关注关键区域。我们提出了雷达特征自适应融合（RFAF）模块，该模块整合了多尺度特征融合与区域级注意力机制，专门针对雷达数据的特点而设计。

RFAF模块首先通过空洞层或池化层在多个分辨率下提取特征，生成融合特征 x_{fused} ；随后该融合特征被输入两个并行处理阶段：

多尺度融合阶段[25]将 x_{fused} 输入两个注意力分支：通道注意力分支和空间注意力分支。在通道注意力分支中，我们应用全局平均池化、 1×1 bottleneck conv, ReLU, then a 1×1 卷积扩展和Sigmoid函数来生成通道权重 ch_{attn} ，计算结果为 $x_{\text{channel}} = x_{\text{fused}} \odot ch_{\text{attn}}$ 。在空间注意力分支中，我们采用 7×7 卷积加Sigmoid函数生成空间权重 sp_{attn} ，得到 $x_{\text{spatial}} = x_{\text{fused}} \odot sp_{\text{attn}}$ 。这些经过注意力调节的图谱随后进行元素级相加，并通过 1×1 卷积层进行融合。

区域注意力阶段[21]作用于特征图（ B, C_{in}, H, W ），并通过双分支设计捕捉特定区域的重要性。为

更准确地建模雷达特有的各向异性特性，RFAF 引入了区域注意力单元：该单元分别处理水平和垂直邻域，形成十字形接收模式。一个分支负责区域级注意力计算，另一个分支则执行多尺度扩张操作；两者的输出结果被拼接后重新投影至 C 个通道：

$$Y = g([\text{RegAtt}(\mathbf{X}_{c+s}) \text{ 轰 MS-Dilated}(\mathbf{X}_{c+s}))], \quad (3)$$

其中 $\mathbf{X}_{c+s}$ 表示第一阶段的融合输出。这种注意力堆叠机制明确捕捉了雷达频谱中常见的方向性特征——水平多普勒轨迹、垂直延伸的距离响应以及小型目标斑块——从而使网络能够根据各区域各向异性特性对其进行处理。

最终，多尺度融合分支与区域注意力分支的输出结果被融合，并通过残差连接层加入原始输入特征。RFAF 模块能够自适应地增强显著的多尺度特征、抑制噪声，在雷达图中分离不同的频段与空间模式，同时突出关键局部区域。该方法尤其适用于分离各向异性雷达频谱中的重叠特征。

3.4. RADM：雷达状态空间解码模块

该解码器旨在根据编码特征重建分割掩码，同时有效处理雷达数据中的各向异性及长程依赖性。我们设计了一种雷达状态空间解码器（RADM）模块，该模块融合了Mamba状态空间模型[5]与轴向自注意力机制的优势。RADM 将输入数据 (B, C, H, W) 划分为三个分支，分别捕捉不同的交互关系[10]：

1. 空间分支：该分支对张量进行重新排序以展平宽度维度：形状 $(B \times W, H, C)$ 。线性投影将通道数减少至 c_1 。随后我们应用基于Mamba的视觉状态空间块（VSSB）来实现局部空间-通道交互，再沿剩余轴应用轴向自注意力机制（ASA）以建模长距离依赖关系，最终得到形状特征 $(B \times W, H, c_1)$ 。这些特征被重塑为 (B, c_1, H, W) 。VSSB 通过选择性状态空间机制自适应地聚焦关键特征，同时保持线性计算复杂度。
2. 多普勒分支：在此阶段，我们将高度轴 $(B \times H, W, C)$ 展平并缩减为 c_2 个通道。经过 VSSB 局部交互和轴向自注意力机制后，数据结构重新调整为 (B, c_2, H, W) 。该分支分别显式建模各维度（距离维度与多普勒维度）间的依赖关系，并利用状态空间模型有效捕捉各向异性结构特征。

三个分支（通道 c_1, c_2, c_1 ）的输出被拼接成 $(B, 2c_1 + c_2, H, W)$ 。通过一个 1×1 卷积层将这些输出融合为 C 个通道，与输入深度相匹配；残差连接层则加入原始输入特

征图。RADM 模块的核心优势在于结合了状态空间模型与轴向注意力机制的优点：

- 状态空间模型[12]：通过选择性机制自适应地聚焦关键特征，同时保持线性计算复杂度，适用于处理雷达数据的长序列特性。
- 轴向自注意力[10]：分别处理沿距离轴和多普勒轴的模型依赖关系，有效应对雷达数据中的各向异性问题。
- 多分支结构：从不同维度捕获特征表示，提供互补的上下文信息。

这种组合使 RADM 能够处理雷达数据的复杂特性，同时在计算效率与解码质量之间实现良好平衡。

最后，在完成 RADM 后，我们应用标准上采样层和卷积层为每个视角生成最终的分割掩码。我们采用 softmax 激活函数，并结合加权交叉熵损失与 Dice 损失进行训练，以确保各类别间的均衡学习效果。




图6. RADM：雷达状态空间解码器模块。DWC表示深度卷积，PWC表示点卷积（例如 1×1 卷积）。

3.5. 训练损失

经过三阶段编码-解码过程后，MARSS 从RA视图和RD视图中生成语义分割掩码。这些掩码通过多任务损失函数与对应的基准真实值进行比较。每个视图的损失函数结合了加权交叉熵、Dice损失以及时间一致性损失[16]：

表1. Carrada平台上的性能比较。结果以mIoU和mDice指标表示，分别针对RD视图和RA视图。最佳结果如下：
粗体表示最优解，下划线表示次优解。

框架；结构	RD 视图		RA 视图		#参数 @帧数
	mIoU	mDice	mIoU	mDice	
FCN	54.70%	66.30%	34.50%	40.90%	134.3M@3
U 网络	55.40%	68.00%	32.80%	38.20%	17.3M@3
DeepLabv3++	50.80%	61.60%	32.70%	38.30%	59.3M@3
RSS网络	32.10%	36.90%	32.10%	37.80%	10.1M@3
斜坡- CN	56.60%	68.50%	27.90%	30.50%	106.4M@9
TMVA 网络	56.10%	68.00%	37.70%	46.20%	5.6M@5
穿透雷达	57.20%	69.10%	39.90%	49.50%	4.9M@5
T-RODNet	-	-	43.50%	53.60%	162.0M@4
PKCIn 网络	60.70%	72.60%	43.10%	53.70%	6.3M@5
AdaPKC ^ξ -Net	61.20%	73.10%	44.10%	55.10%	6.3M@5
AdaPKC ^θ -Net	61.50%	73.60%	43.60%	54.50%	6.3M@5
AdaPKC ^ξ -Net ^{FiT}	<u>62.10%</u>	<u>74.00%</u>	<u>44.30%</u>	<u>55.50%</u>	6.3M@5
MARSS (我们的)	63.26%	75.18%	46.97%	58.78%	9.3M@5

$$\mathcal{L}_{\text{wCE}}(\mathbf{y}, \mathbf{p}) = -\frac{1}{K} \sum_{k=1}^K w_k \sum_{(m,n) \in \Omega} \mathbf{y}[m, n, k] \log \mathbf{p}[m, n, k], \quad (4)$$

$$\mathcal{L}_{\text{SDice}} = \frac{1}{K} \sum_{k=1}^K \left[1 - \frac{2 \sum_{(m,n)} \mathbf{y}[m, n, k] \mathbf{p}[m, n, k]}{\sum_{(m,n)} \mathbf{y}^2[m, n, k] + \mathbf{p}^2[m, n, k]} \right], \quad (5)$$

$$\mathcal{L}_{\text{CoL}}(\mathbf{p}^{RD}, \mathbf{p}^{RA}) = \|\hat{\mathbf{p}}^{RD} - \hat{\mathbf{p}}^{RA}\|_F^2, \quad (6)$$

$$L = \lambda_{\text{wCE}} (\mathcal{L}_{\text{wCE}}^{RD} + \mathcal{L}_{\text{wCE}}^{RA}) + \lambda_{\text{SDice}} (\mathcal{L}_{\text{SDice}}^{RD} + \mathcal{L}_{\text{SDice}}^{RA}) + \lambda_{\text{CoL}} \mathcal{L}_{\text{CoL}}, \quad (7)$$

其中 $\mathbf{y} \in \{0,1\}^{M \times N \times K}$ 表示独热编码的真实值张量， $\mathbf{p} \in [0,1]^{M \times N \times K}$ 代表预测概率张量； M 和 N 为雷达视图的空间维度（高度与宽度）， K 为类别总数。 $\Omega = [1, M] \times [1, N]$ 表示空间坐标集，其中 (m, n) 为空间位置索引。 w_k 表示类别 k 的归一化权重，其大小与该类别在训练集中的出现频率成反比。 $\mathbf{p}^{RD}$ 和 $\mathbf{p}^{RA}$ 分别对应距离-多普勒（RD）视图和距离-角度（RA）视图的预测概率图。 $\hat{\mathbf{p}}^{RD}$ 与 $\hat{\mathbf{p}}^{RA}$ 则是通过沿非共享轴（多普勒或角度维度）应用 $\max(\cdot)$ 运算得到的聚合特征图。 $\|\cdot\|_F$ 表示弗罗贝尼乌斯范数。 λ_{wCE} 、 λ_{SDice} 和 λ_{CoL} 分别为各损失项的权重系数。

每个损失组件均实现了针对特定视图的学习。通过多视图分割任务进行训练，可促使模型充分利用雷达频率图的多维结构，并提升跨视图一致性，从而增强分割效果[16]。

4. 实验

4.1. 数据集与指标

我们在carrada[17]和carrada-RAC[26]数据集上评估MARSS模型性能。carrada数据集由FMCW毫米波雷达采集，包含多个场景下同步拍摄的相机-雷达图像数据，涵盖行人、骑行者、车辆及背景四种物体类别，并提供维度为 $256 \times 256 \times 64$ 的距离-角度-多普勒（RAD）张量，支持通过距离-方位角（RA）和距离-多普勒（RD）两种表示方式实现多视角分割。所有对比模型均采用与先前研究[6, 26]相同的数据划分方案，以确保公平性。carrada-RAC是原始carrada数据集的重新校准版本，标注一致性更高。我们采用标准评估指标：在RD视图和RA视图上分别计算平均交并比（mIoU）和平均Dice系数（mDice），较高的mIoU和mDice值表明分割质量更优。

实施细节

MARSS采用连续五帧序列作为时间建模的输入数据，这与PeakConv[26]所采用的协议一致。范围-角度（RA）视图的输入分辨率设置为 256×256 ，其他视图则为 256×64 。




图7. 雷达分割结果可视化：最左侧图像为对应的RGB相机图像。第一行为RDView图像，第二行为RA-View图像。从左至右依次为：(a)原始RA/RD数据；(b)分割掩模真实值；(c)TransRadar分割结果；(d) TMVA -Net分割结果；(e)AdaPKC-Net^{FiT}分割结果；(f) MARSS（本研究）分割结果。在分割掩膜中，红色代表行人，黄色代表骑行者，蓝色代表车辆。

该模型同时适用于角度多普勒（AD）和距离多普勒（RD）两种视图。模型训练在两块 NVIDIA RTX 3090 GPU上使用Adam优化器完成[9]，初始学习率设为0.0001，并在整个训练过程中采用指数退火策略。每个模型均训练300个周期，批量大小为3。损失函数结合了加权交叉熵、Dice损失和时间相干性损失，并采用[6]推荐的超参数设置。

4.2. 主要实验

我们对Carrada基准数据集的全面评估表明，MARSS在性能上显著优于当前最先进的方法。如表1所示，在RD视图上达到63.26%的mIoU值，在RA视图上达到46.97%的mIoU值，这直接源于其针对引言部分所述雷达核心挑战所采取的系统性解决方案。相较于AdaPKC-NetFiT模型，在具有挑战性的RA视图上mIoU值提升了2.67%，这一显著提升充分证明了MARSS在处理雷达固有各向异性问题上的有效性——距离轴与多普勒/速度轴所承载的物理信息存在本质差异。考虑到传统方法在RA表示中常面临方向特征不平衡的问题，这种性能差距尤为突出。该框架在两种视图下均展现出持续优异的表现（尤其体现在carrada-RAC数据集上取得的55.2%最高全局mIoU值），有力验证了我们在整个网络架构中融入雷达专用归纳偏置的方法的有效性。

值得注意的是，MARSS仅使用930万参数便实现了这些突破性进展，其效率远高于T-RODNet（需1.62亿参数）等方法，同时输出更优的结果。这种高效性源于其针对性模块设计：RADM解码器将Mamba状态空间模型与轴向自注意力机制相结合，有效解决了传统骨干网络中存在的特征混杂问题，在保持线性复杂度的同时实现对长距离相关信息的自适应聚焦。该模型在处理小尺寸/高速目标时表现出色——这些目标在频谱图中呈现为清晰的高频条纹——进一步证明了MARSS能够从雷达数据中显著存在的背景杂波和斑点伪影中精准提取有效信号。

我们还将carrada-RAC数据集上将我们的方法与现有方法进行了比较。如表2所示，所提出的模型在RA视图和全局视图上均表现出优异性能，同时在RD视图上也取得了相当的结果。

图7展示了在Carrada数据集上针对复杂场景（如低信噪比、小型快速移动物体（如汽车））的分割结果。MARSS生成的掩膜比基线方法更准确且时间一致性更高。

4.3. 消融研究

我们的系统性消融研究揭示了每个模块如何具体解决引言中所述的雷达现象。未采用所提模块的基础模型在RD指标上达到61.16%的mIoU，在RA指标上达到41.04%，均表现优异。

表2. 在carrada-RAC上的性能比较。结果以RD视图和RA视图的mIoU和mDice指标表示。最佳结果用**粗体**表示，次优结果用下划线表示。

框架；结构	#参数@帧数	RD 视图		RA 视图		全局视图	
		mIoU	mDice	mIoU	mDice	mIoU	mDice
TMVA 网络	5.6M@5	59.7%	69.9%	46.6%	57.9%	53.2%	63.9%
PKCIn 网络	6.3M@5	60.6%	72.4%	47.3%	58.7%	54.0%	65.6%
AdaPKC ^{θ} -Net	6.3M@5	60.7%	72.7%	48.1%	59.6%	54.4%	66.2%
AdaPKC ^{ξ} -Net	6.3M@5	61.6%	73.6%	47.9%	59.3%	<u>54.8%</u>	66.5%
AdaPKC ^{ξ} -Net ^{FiT}	6.3M@5	60.8%	72.7%	<u>48.8%</u>	<u>60.5%</u>	<u>54.8%</u>	<u>66.6%</u>
MARSS（我们的）	9.3M@5	<u>61.4%</u>	<u>73.4%</u>	49.0%	60.9%	55.2%	67.2%

表3. 消融研究：评估本框架中各模块（RADE、RFAF、RADM）的贡献度。结果以数据形式呈现。针对RD和RA视图的mIoU与mDice指标。最佳结果以**粗体**显示，次优结果以下划线标注。

RADE	RFAF	区域酸沉降模式	RD 视图		RA 视图	
			mIoU	mDice	mIoU	mDice
✓	✓	✓	61.16%	72.91%	41.04%	50.49%
			62.35%	74.24%	41.57%	51.69%
			62.45%	74.48%	44.70%	55.69%
✓	✓	✓	62.52%	74.35%	45.33%	<u>56.69%</u>
			62.89%	<u>74.72%</u>	<u>45.33%</u>	<u>56.59%</u>
✓	✓	✓	62.43%	74.09%	43.53%	54.09%
✓	✓	✓	<u>62.90%</u>	74.64%	43.76%	54.71%
			63.26%	75.18%	46.97%	58.78%

这凸显了RA视图处理的特殊难度。RADE模块在RD视图上实现了+1.19%的mIoU提升，充分证明其通过协同信道与空间注意力机制有效抑制雷达固有噪声的优势；而 RFAF 模块在RA视图上取得的+3.66%显著提升，则验证了其处理距离信息与角度信息方向性失衡问题的多尺度融合能力。

最显著的是，RADM 解码器在RA视图上实现了最强的独立性能提升（mIoU指标提高4.29%），这直接验证了其通过Mamba状态空间机制实现各向异性建模的能力。将三个模块组合使用时展现出协同效应：虽然RADE+ RFAF 和 RFAF + RADM 能获得相近的雷达目标检测性能（mIoU值为62.89%-62.90%），但完整的 MARSS 架构在雷达目标检测上达到最优的63.26% mIoU，在RA视图上则达到46.97%。最具说服力的协同效果体现在RA视图上——整个框架比最佳双模块组合高出1.64%的mIoU，表明这三个模块对于全面应对雷达特有的挑战（包括噪声抑制、多尺度特征融合及方向依赖建模）均不可或缺。我们提出的 MARSS 是

5. 结论

一种基于模块化注意力机制的雷达语义分割架构，专门针对雷达系统的独特挑战设计：通过集成定制化模块——用于抗噪编码的RADE、负责多尺度与区域特征选择的 RFAF，以及结合状态空间模型进行各向异性解码的 RADM——MARSS 能够有效保留方向性和时间信息。在carrada基准测试上的实验表明，该方法实现了最先进的性能，显著优于现有技术（如AdaPKC）。我们的消融实验证实各组件均发挥互补作用，其中解码阶段引入的状态空间模型尤其有效提升了长距离依赖建模能力。

尽管 MARSS 实现了最先进的性能，但仍存在若干局限：其多模块设计增加了结构复杂性；且其不同雷达硬件配置及极端天气条件下的泛化能力尚需进一步验证。未来研究将重点聚焦于模型压缩以提升实时系统的运行效率、探索跨数据集的领域适应方法以增强泛化能力，并将框架扩展至多传感器融合范式以实现鲁棒的全天候感知能力。