

遥感林业相似性卷积算法

王世宽¹陈远功²冯建洲^{1*}莱英毅

吴梦泉³、刘龙星⁴、袁海伟¹、郭明斌

¹广州大学²香港理工大学

³鲁东大学⁴南京大学

孟3

1

摘要

卷积神经网络的最新进展

遥感技术 (CNN) 显著推动了林业遥感测绘领域的发展。然而，传统卷积运算在提取复杂森林特征时存在固有局限：其固定的感受野难以涵盖多尺度森林属性，且对背景信息的关注不足会削弱整体特征表征效果。为解决这些问题，我们提出相似卷积 (SimConv)，通过建模特征关系实现动态卷积核尺寸选择。SimConv可根据输入特征的语义相关性自适应调整感受野，从而增强对林业背景信息的捕捉能力，并提升目标特征间的区分度。在此基础上，我们开发了以SimConv为核心特征提取网络的SIMNet。基于多个遥感数据集的实验结果表明，SIMNet在特征提取精度方面优于现有方法。代码详见 <https://github.com/WangShiK/SimConv>。

1. 引言

森林土地是至关重要的生态资产，对全球碳循环监测、生物多样性保护及高精度制图具有关键作用[1, 33, 34]。在全球气候变化日益加剧的背景下，精确的森林空间分布数据对于有效实施森林资源管理、生态修复及可持续发展评估至关重要[12, 47]。传统森林制图技术通过整合多源遥感数据以提升精度[3]，但时空分辨率差异、采集规范不统一及数据格式差异等问题，常导致数据融合过程中出现配准错误与语义不一致等关键问题[56]。更严重的是，传统方法（人工判读、基于规则的




图1. 使用所提出的卷积运算与标准卷积运算构建的CNN的映射结果。GT代表真实标注 (Ground Truth)。(a)展示了使用标准卷积构建的CNN，(b)展示了使用我们提出的SimConv构建的CNN。图中详细展示了SimConv相对于标准卷积的映射效果。

分类方法未能捕捉森林结构的复杂性和异质性——导致所得结果无法满足现代林业对精确性、效率性和自动化的要求[19]。

随着高分辨率卫星遥感技术的快速发展以及卷积神经网络 (CNN) 的广泛应用，光学卫星影像已成为森林资源调查的基础数据源——其空间分辨率可达亚米级，且纹理信息丰富[40, 41]。其在森林边界划定等关键任务中的实用性已得到广泛认可[3, 30, 47]。尽管CNN在林业制图中取得了显著成效，但标准卷积运算在复杂森林场景中存在固有的结构局限性：它们采用固定的核尺寸，无法自适应地捕捉层次化且空间变化的特征关系。这导致其难以处理遥感影像中的多尺度特征与异质背景。此类局限性常导致模型遗漏关键的精细特征，直接削弱制图精度与鲁棒性[11, 29, 38]（见图1）。

为解决传统卷积方法在遥感森林制图中的局限性，我们提出了一种领域特定方法——相似性卷积 (SimConv)。SimConv通过空间维度 (x/y) 建模特征间的内在关联性，进而动态选择最优卷积核尺寸以实现自适应、上下文感知的特征提取。该方法能够捕捉遥感数据中细微复杂的特征特征，显著提升林业制图的细节表现与精度水平。

* 通讯作者: gongjzh@gzhu.edu.cn

放

本文的主要贡献如下：

- 我们提出了一种基于SimConv的高效任务特定特征提取编码器，利用其动态感受野从遥感影像中捕获更具区分性的特征。
- 为增强语义整合能力，我们在解码器中引入了一种新型小波特征融合模块（WFFM），该模块通过融合深度特征与浅层特征，利用多尺度上下文信息实现精准映射。
- 通过结合SimConv编码器和WFF增强型解码器，我们构建了SIMNet——这一专为遥感林业制图设计的模型，在空间适应性与语义丰富性之间取得平衡，从而实现精准高效的性能表现。
- 针对三个基准数据集的广泛评估表明，SIMNet在各类林业制图任务中始终优于现有方法，这验证了SimConv与SIMNet作为稳健实用框架在复杂遥感环境下森林资源监测中的有效性。

2. 相关作品

近年来，卷积神经网络（CNN）在遥感图像分析领域取得了重大突破，显著提升了基于光学影像的林业制图精度与自动化水平[15]。然而，标准卷积网络固有的固定感受野特性限制了其对森林区域复杂多变空间结构的有效捕捉能力[26]。为解决这一问题，研究者提出了结构增强方案，旨在弥合静态卷积机制与真实场景动态空间特征之间的差距[8, 42, 55]。

遥感影像中的林业目标识别面临额外挑战，因其目标尺度范围广泛，从单株树木到广阔森林冠层均需处理。传统具有固定感受野的卷积架构往往难以适应这种多尺度变化，导致特征提取性能欠佳[24]。因此，自适应感受野与多尺度特征感知技术已成为该领域亟待解决的关键研究课题。

在现有方法中，无孔空间金字塔池化（ASPP，应用于DeepLabv3+）[5]通过采用不同膨胀率的并行卷积有效建模多尺度上下文信息。DenseASPP[48]在此基础上通过密集堆叠膨胀卷积结构进行扩展——这种设计能增强跨连续尺度的语义感知能力，并提升对不同尺寸森林物体的适应性。然而，这两种方法均高度依赖人工设计的感受野结构，且缺乏对目标实际语义尺度的动态适应能力。在复杂背景或尺度重叠场景中，其泛化能力存在明显局限[23]。




图2。(a)标准型；(b)可变形型；(c)动态型：全局根据输入生成权重；(d)提出的SimConv：自适应地从输入中选择核尺寸。

HRNet[37]采用了不同的方法：它通过维护并行的多分辨率分支来保留高分辨率空间信息——这对于森林边界划定等精确任务至关重要。其同步进行的多尺度特征学习显著提升了模型的准确性和鲁棒性。然而，HRNet高昂的计算成本和复杂的结构使其难以实际应用。

为解决传统卷积神经网络的刚性问题，可变形卷积[7]通过引入可学习偏移量来调整核采样位置以适应目标几何结构，从而提升复杂形状建模能力。LDConv等扩展方法[53]进一步增强了空间适应性，而动态方法（DyConv[6]、ODConv[17]）则通过生成输入依赖性权重来提升上下文敏感度。然而这些方法仍缺乏语义引导的感受野调整机制——如图2所示，卷积核尺寸仍保持有效固定状态，导致其在具有复杂语义变化的场景中表现受限。

为解决现有方法的不足，我们提出了一种创新的卷积运算——SimConv。该算法能根据输入特征自适应选择卷积核尺寸，从而实现更精细的特征提取和更强的语义关联性。针对传统卷积运算固定的感受野及特征关系建模能力不足的问题，SimConv有效解决了复杂语义场景下的智能感受野调整难题。实验验证表明，该方法在遥感林业制图领域显著提升了性能，为未来研究提供了新的见解。

3. 方法论

本节将基于SimConv和SIMNet对相关设计进行详细阐述。

3.1. SIMNet的整体架构

所提出的SIMNet架构（图3）的核心创新在于引入了分层特征交互机制。在编码器中，我们基于SimConv设计了SimBlock模块，其中传统的池化层被HWD[46]模块取代。这一设计能够在保持多通道信息的同时实现分辨率的渐进式降低。




图3. SIMNet整体架构




图4. 类似卷积架构

空间上下文尺度。在解码器中，深度特征 X_1 通过 WFFM 进行上采样，并借助二维离散小波变换分解为子带表示（ LH 、 HH 、 LH 、 HL ）。这些特征与浅层特征 X_2 进行拼接，通过 BRC 模块实现维度对齐，从而促进高层语义与精细空间细节之间的高效交互。

3.2. 相似性卷积

标准卷积运算（定义于等式1）通过滑动窗口，在输入特征图 $I \in \mathbb{R}^{B \times C \times H \times W}$ 上应用固定尺寸的核 $k \in \mathbb{R}^{m \times n}$ 。尽管该设计简单，但存在两个关键局限性：(1) 感受野是预先确定的，无法适应输入尺度的变化；(2) 局部采样机制独立处理特征，忽略了它们之间的内在关联。因此，传统卷积通常无法捕捉复杂场景中的判别

性多尺度上下文信息，从而限制了学习特征的表征能力。

$$O(i, j) = \sum_m \sum_n I(i - m, j - n) \cdot k(m, n) + b \quad (1)$$

为克服这些局限性，我们提出 SimConv——一种动态选择核尺寸的自适应卷积算子。如图4所示，根据目标尺度分布预先定义一组候选核（ K_1, K_2, K_3 ），SimConv 随后确定局部窗口尺寸 $h \times w$ ，其定义为候选核边长的最小公倍数（LCM）。该设计基于两个关键考量：(1) 确保

(1) 每个候选核的接收野完全包含在窗口内，从而完整保留多尺度特征信息；(2) 选择与所有核兼容的最小窗口尺寸，既避免冗余计算又实现精度与效率的平衡。最终生成的窗口用于提取局部特征表示：

$$h, w = LCM(K_1, K_2, K_3) \quad (2)$$

$$I[\text{窗口}] = I[\text{高度}, \text{宽度}] \quad (3)$$

$I[\text{window}] \in \mathbb{R}^{B \times C \times h \times c}$ 表示特征 I 局部窗口内的特征信息。为考虑局部与全局上下文之间的关系，必须获取局部全局特征权重 $Window$ ：

$$\text{权重} = \text{Conv}_{1 \times 1}(\text{Reshape}(I[\text{window}])) \quad (4)$$

接下来，SimConv 根据每个局部窗口内的背景信息自适应地选择卷积核尺寸。具体而言，我们计算窗口沿两个空间维度（ x 和 y ）的特征响应之间的相关性 R ，以指导核选择。 x 方向的相关性首先按以下公式计算：

$$RI_{[\text{window}]_x} = I[\text{window}](x+1, y) - I[\text{window}](x, y) \quad (5)$$

于 y 方向的连接：

$$RI_{[\text{window}]_y} = I[\text{窗口}](x, y+1) - I[\text{窗口}](x, y) \quad (6)$$

为评估 x 和 y 方向上的特征相关性，我们引入阈值 R_θ (0.1)：低于 R_θ 的数值表示存在显著相关性（赋值为 1），否则为 0，从而生成反映局部特征相关性的布尔矩阵 M 。根据 M 中 1 的占比并与阈值 M_θ (0.4) 进行比较，自适应选择卷积核：当占比超过 M_θ 时使用大核以捕捉更广泛的空间依赖关系；否则使用小核。该策略使 SimConv 能够根据局部上下文动态调整感受野， θ 表示该阈值。每个阈值均具有理论依据： R_θ 参考了基于统计相关性的特征选择方法（例如皮尔逊系数）[27]，而 M_θ 则基于信息论（结合熵和互信息等概念进行特征关联评估）[9]。

$$K = \begin{cases} K_2, \frac{M[1]}{M[1]+M[0]} > M_\theta \\ K_3, \frac{M[1]}{M[1]+M[0]} \leq M_\theta, \end{cases} \quad (7)$$

考虑到局部窗口上下文，选择自适应核 K 来提取特征 $feat2$ 。为评估其质量与完整性——特别是在特征缺失或信号较弱的区域——我们引入了与原始输入的附

加相关机制。首先使用基线核 K_1 获取参考特征 $feat1$ ，随后通过余弦相似度衡量 $feat1$ 与 $feat2$ 之间的相似性，该方法通过计算特征向量间的角度距离来捕捉方向一致性。该相似度作为特征选择标准，使模型能够优先选取更具代表性且语义一致的特征。

$$\text{Similarity} = \frac{\sum_i x_i \cdot y_i}{\sqrt{\sum_i x_i^2} \times \sqrt{\sum_i y_i^2}} \quad (8)$$

随后，通过代入待评估特征，我们得到：

$$E = \frac{\sum_{i=1}^n feat_i \cdot I[\text{window}]_i}{\sqrt{\sum_{i=1}^n feat_i^2} \times \sqrt{\sum_{i=1}^n I[\text{window}]_i^2}} \quad (9)$$

随后，应用评估阈值来衡量不同卷积核生成特征之间的一致性。具体而言，我们计算两个评估值： E_1 （源自标准卷积核 K_1 ，输出特征记为 $feat1$ ）和 E_2 （源自自适应选择的核 K ，输出特征记为 $feat2$ ）。绝对差异 $D = |E_1 - E_2|$ 用于量化 $feat1$ 与 $feat2$ 之间的一致性：较小的 D 表示较高一致性，较大的 D 则意味着较低一致性。

该差异 D 随后与预设阈值 E_θ （设定为 0.15[25, 32]）进行比较。为将这种一致性信息纳入特征选择过程，我们定义以下规则以确定 $I'[\text{窗口}]$ 内的输出特征：

$$I'[\text{window}] = \text{Weight} + \begin{cases} feat1, \text{if } D > E_\theta \\ feat2, \text{if } D < E_\theta \\ \frac{feat1+feat2}{2}, \text{other} \end{cases} \quad (10)$$

若差异值低于设定阈值，则对应的卷积特征被视为有效并予以保留。最终输出仅选取符合该标准的特征，从而确保提取表征的可靠性和鲁棒性。阈值选择方案通过消融实验进行了深入验证。

3.3. 小波特征融合模块

为更有效地利用深度特征与浅层特征信息，我们提出了一种名为小波特征融合模块（WFFM）的新型特征融合模块，如图 3 所示。设 X_1 表示深度层特征， X_2 表示浅层特征。首先，将 X_1 以 4 倍因子进行上采样，使其空间分辨率与

X_2 。经过上采样的深度特征随后通过小波变换进行处理，将其分解为高频和低频分量。这些分量随后被整合，形成一个精炼的表示，记为：

$$LL, HH, LH, HL = 2D\text{-DWT}(Upsample_{\times 4}(X_1)) \tag{11}$$
$$X_1' = \text{连接}(LL, HH, LH, HL) \tag{12}$$

传统的上采样方法（如双线性或双三次插值）常会产生锯齿状伪影，这不仅会降低图像质量，还会削弱特征融合的效果。为解决这一问题，我们采用小波变换技术——该方法凭借其固有的多分辨率特性与方向敏感性，能够实现更平滑的像素过渡并抑制视觉失真，从而获得更自然、精准的特征表示。在完成小波分解后，通过标准卷积运算恢复通道维度，实现与浅层特征 X_2 的有效整合。所提出的基于小波变换的特征融合模块，既实现了深度特征与浅层特征信息的高效协同利用，又提升了语义特征表征质量，最终显著增强了模型的学习性能。

4. 实验与结果

4.1. 数据集

为评估所提出方法在林业制图中的应用效果，我们基于三个具有不同空间分辨率的数据集构建了基准集。第一是高分二号**红树林数据集**[50]，这是一个分辨率为1米（512×512像素）的二分类数据集，其特征是复杂海岸湿地背景下的斑块状红树林分布。第二是**LoveDA**[39]，包含5,987幅0.3米 GSD 的高分辨率影像（原始尺寸1024×1024像素，经缩放处理为512×512像素），涵盖7种土地覆盖类型。第三是**WHDL D**[35, 36]，这是一个包含4,940幅2米分辨率影像（256×256像素）的多标签数据集，标注了6种土地覆盖类型。

4.2. 实验设置

所有模型均基于PyTorch框架构建，并在单块 NVIDIA RTX 4090 GPU上完成训练。为加速收敛速度并缓解类别不平衡问题，我们采用AdamW优化器配合焦点损失与Dice损失的混合损失函数。训练过程从零开始构建模型架构，未使用预训练权重参数。初始学习率设定为5e-5，并通过余弦退火法进行动态调整。训练配置根据数据集特性定制：红树林数据集采用50个训练周期（批量大小4），LoveDA模型（批量大小4）与 WHDL D 模型（批量大小8）则采用100个训练周期。为提升模型泛化能力，训练过程中应用随机缩放、水平翻转和平移等标准数据增强技术，验证阶段则采用未增强数据确保公

平性。性能评估指标包括总体准确率（OA）、平均交并比（mIoU）以及F1分数，这些指标均基于累积混淆矩阵计算得出，以确保结果的稳定性和统计学可靠性。

4.3. 结果

本节将所提出的模型与主流基准模型进行性能对比。针对Mangrove和LoveDA数据集，我们比较了三种代表性架构：(1) 基于CNN的模型，(2) Vision Transformer（ViT），以及(3) 状态空间模型（Mamba）。对于标注密集的 WHDL D 数据集，我们重点研究经典CNN分割网络，并进一步融入先进的卷积变体（DyConv、ODConv、LDConv）及特征融合策略（注意力门控跳跃连接、多尺度聚合）以进行交叉验证。在所有具有不同特性的数据集上，所提出的模型均持续展现出更优的性能表现。

表1. 红树林数据集的定量分析。

方法	BG	红树林	F1	OA	微损伤
ABCNet [22]	95.82	72.94	91.16	96.24	84.38
CCNet [14]	96.42	77.42	92.73	96.81	86.92
CGNet [44]	96.84	79.90	93.61	97.19	88.37
Deeplabv3+ [5]	96.05	74.98	91.85	96.47	85.51
DenseASPP [48]	96.86	80.13	93.69	97.21	88.50
DSAT-Net [51]	96.28	75.81	92.21	96.67	86.05
ENet [28]	96.22	76.43	92.36	96.63	86.32
MANet [21]	96.48	77.52	92.78	96.86	87.00
PSPNet [54]	96.16	75.75	92.12	96.57	85.95
SDSC-UNet [52]	96.55	78.11	92.98	96.93	87.33
SegNet [2]	95.45	72.17	90.76	95.93	83.81
CMTFNet [43]	96.68	78.81	93.23	97.04	87.74
DBBANet [20]	96.18	76.00	92.21	96.59	86.09
CARENet [31]	96.78	79.58	93.50	97.14	88.18
SFFNet [49]	96.29	76.69	92.46	96.70	86.49
SIMNet	97.24	82.36	94.47	97.56	89.80

红树林数据集：如表1所示，所提出的方法在精细红树林制图任务中展现出显著的性能优势。具体而言，该方法在红树林类别上的交并比（IoU）达到82.36%，较次优模型实现了2.23%的绝对提升。此外，基于mIoU指标分析，该方法较基线模型提升了1.3%，充分证明其在处理具有离散植被模式的复杂海岸湿地场景时具有卓越表现。

LoveDA数据集：如表2所示，SIMNet在森林提取任务中展现出显著的性能优势。值得注意的是，它是唯一一个森林提取准确率超过75%阈值的模型，这凸显了其

表2. LoveDA数据集的定量分析

方法	BG	建筑物	路	水	贫瘠症	森林	农业	F1	OA	微损伤
ABCNet [22]	59.49	56.20	54.98	70.67	39.00	74.07	62.88	74.33	77.92	59.61
CCNet [14]	57.35	62.30	61.55	73.31	46.50	74.35	63.66	76.79	78.21	62.72
CARENet [31]	56.15	62.85	63.39	72.68	44.69	74.13	64.36	76.66	77.98	62.61
DFANet [18]	55.34	57.08	54.16	69.50	30.21	72.58	58.99	71.88	75.63	56.84
DMNet [10]	59.20	62.10	63.53	73.35	42.90	74.74	64.50	76.89	78.75	62.90
DSAT-Net [51]	56.15	59.83	58.07	69.44	37.94	73.21	58.70	73.77	76.19	59.05
ENet [28]	57.37	61.71	62.01	72.41	44.86	73.66	62.88	76.27	77.76	62.13
MANet [21]	57.40	61.39	61.74	72.60	44.29	73.87	63.63	76.29	77.97	62.13
SDSCU-Net [52]	57.75	62.52	59.71	71.23	39.62	73.76	61.68	75.22	77.47	60.94
SegNet [2]	55.70	60.97	59.57	72.59	42.28	73.45	62.60	75.39	77.17	61.02
DBBANet [20]	55.07	61.92	61.32	74.47	46.08	73.79	64.27	76.63	77.77	62.42
SFFNet [49]	55.60	61.51	63.66	72.16	41.13	74.36	62.54	75.86	77.47	61.57
SIMNet	58.00	63.72	63.33	73.16	46.57	75.04	65.03	77.50	78.71	63.55

表3. WHDL D 数据集的定量分析。

方法	建筑物	路	路面	植被	裸土	水	F1	OA	微损伤
ABCNet [22]	54.34	52.84	37.16	78.58	35.41	92.24	72.17	82.14	58.43
CCNet [14]	51.66	57.25	38.99	77.71	40.35	91.58	72.99	81.71	59.59
CGNet [44]	51.66	59.09	40.56	78.80	41.84	92.58	74.00	82.41	60.76
Deeplabv3+ [5]	51.49	56.97	40.96	78.35	38.91	92.50	73.37	82.03	59.86
DenseASPP [48]	53.30	60.26	41.27	79.11	40.94	92.80	74.36	82.76	61.30
DFANet [18]	46.19	46.84	33.41	74.53	32.26	88.22	67.82	78.71	53.58
ENet [10]	47.46	56.19	39.31	77.97	40.37	92.32	72.60	81.36	58.94
GCNNet [4]	51.97	58.88	40.89	78.45	40.86	92.16	73.85	82.26	60.54
ISANet [13]	52.70	59.14	40.99	78.62	40.73	92.36	73.98	82.36	60.76
MANet [21]	53.84	58.57	41.57	79.19	40.66	92.80	74.23	82.75	61.11
SegNet [2]	45.00	47.35	37.22	74.92	34.91	90.73	69.08	79.08	55.02
UPerNet [45]	54.10	57.52	40.69	78.93	40.38	93.05	73.90	82.72	60.78
SIMNet	56.57	60.47	43.46	80.71	41.96	94.02	75.72	83.93	62.87

在捕捉森林相关特征方面具有显著有效性。此外，SIMNet在所有对比方法中实现了最高的mIoU值，充分体现了其在复杂土地覆盖场景下强大的整体分割能力。

WHDL D 数据集：如表3所示，SIMNet在 WHDL D数据集上持续展现出技术优势。在所有基于卷积神经网络（CNN）的方法中，SIMNet以80.71%的森林土地分类准确率位居榜首，较次优方法绝对提升1.52%。此外，其在平均交并比（mIoU）指标上仍保持1.57%的领先优势。这一量化优势直接验证了所提方法在解析复杂土地特征方面的有效性，并凸显其在森林资源制图实际应用中的巨大潜力。

不同卷积方法的比较：表4详细对比了所提出的SimConv运算器与包括LDConv、ODConv和DyConv在

内的多项前沿卷积技术。在具有挑战性的森林测绘任务中，SimConv在所有评估指标和语义类别上均展现出持续的优势。值得注意的是，这种性能提升仅伴随着计算成本的微小增加——具体而言，额外增加了0.0016 GFLOPs运算量和0.0004百万个参数。在植被和水体等难以分割的类别中，SimConv分别达到80.71%和94.02%的IoU分数，较现有方法实现了显著改进。这些结果凸显了SimConv通过动态核尺寸选择自适应捕捉上下文与结构信息的增强能力。这种自适应特性在林业测绘等遥感场景中尤为有益——此类场景需要处理具有高度空间变异性与复杂地形特征的数据。

表4. 卷积方法的定量分析。FLOPs与 Params表示单次卷积运算的计算量。

方法	建筑物	路	路面植被		裸土	水	F1	OA	微损伤	浮点运算次数(G)	Attrs (M)
SimConv	56.57	60.47	43.46	80.71	41.96	94.02	75.72	83.93	62.87	0.0456	0.0011
LDConv [53]	44.60	32.01	31.45	71.93	27.60	82.91	62.80	75.01	48.42	0.0185	0.0001
ODConv [17]	54.40	59.97	43.76	80.01	41.08	93.75	75.31	83.17	62.18	0.0440	0.0007
DyConv [6]	52.48	57.93	41.48	78.37	37.75	90.48	73.35	82.04	59.75	0.0440	0.0004

细粒度特征提取

主流特征融合方法比较：

表5展示了主流特征融合方法在遥感图像语义分割中的对比效果。无论是类别特定分割精度还是整体性能指标，均凸显了 WFFM 方法的优势。具体而言，植被类别分割精度较其他融合方法提升至少1.38%，而反映整体性能的平均交并比（mIoU）则较竞品方案高出至少2.04%。这些结果表明，WFFM 通过更有效地整合深度语义特征与浅层细节特征，显著提升了模型对遥感图像语义信息与空间细节的双重捕捉能力，相较现有策略展现出显著改进优势。

5. 消融研究

本节将系统分析SIMNet核心模块的工作机制，并深入探讨SimConv卷积核中不同相似性阈值设置对模型性能的影响。

5.1. SIMNet特征提取与特征融合

为评估SIMNet各核心组件的独立贡献，我们在三个基准数据集上进行了消融实验，结果汇总于表6。

特征提取性能验证：移除所提出的特征提取模块后，所有数据集上的性能均出现显著下降。这证实了该模块在捕捉显著物体特征与精细细节的同时，还能有效利用上下文背景信息。此外，针对不同尺度的评估结果表明，该模块具备强大的多尺度特征提取能力，确保在不同分辨率和场景复杂度下保持稳定性能表现。

特征融合性能验证：同样地，移除所提出的特征融合机制也会导致性能显著下降。这验证了我们的融合策略在整合深度语义信息与浅层空间信息方面的有效性，提升了模型对多尺度特征的利用能力。通过优化层次化特征表示的利用方式，显著增强了复杂遥感场

景中物体识别与分类的准确性和鲁棒性。

5.2. 阈值的选择

为验证SimConv模块阈值设置的理论依据，我们在 WHDL D 数据集上进行了对照实验，重点关注第3节中引入的关键阈值：(1)特征相关性阈值 R_{θ} ，用于评估 x 方向与 y 方向的特征相关性；(2)卷积核选择阈值 M_{θ} ，用于确定核尺寸。这些阈值被系统性地调整，并评估了其对核尺寸选择的影响。表7所示结果表明，当图像分辨率降低时， $R_{\theta}=0.1$ 与 $M_{\theta}=0.4$ 的组合方案在保持优异性能的同时，使mIoU下降速度最慢。这证明所选参数设置能够实现核尺寸的精确自适应调整，从而使模型达到最优性能。

为了进一步评估阈值对特征质量评估的影响，我们按照表8所述进行了消融实验。实验结果表明，在基于相似性的评估中，0.15的阈值能最准确地反映特征的有效性，从而使SimConv能够做出更精确且具有上下文感知能力的特征选择决策。这些实验共同验证了SimConv中阈值选择的经验性设计方案，并证实了该阈值在提升模型特征提取与表征能力方面的关键作用。

5.3. 卷积核列表组合

为验证SimConv模块中阈值设置的合理性，我们在 WHDL D 数据集上针对第三层进行了对照实验。此外，为验证第3.2节提出的卷积核列表有效性，我们使用 WHDL D数据集开展了多核组合消融实验。实验结果如表9所示。实验表明，采用1、3、5、7、9等不同核尺寸构建编码器的混合卷积核策略，在分类准确率和整体一致性等核心指标上均达到最优性能。同时该方案保持了轻量级设计，参数量仅73.78个。

表5. 主流特征融合方法的定量分析

方法	建筑物	路	路面	植被	裸土	水	F1	OA	微损伤
多尺度特征添加[16]	53.34	56.19	41.17	79.33	42.06	92.88	74.08	82.75	60.83
注意力门控跳跃连接[27]	44.47	47.86	37.46	77.22	34.31	91.19	69.61	79.80	55.42
WFFM	56.57	60.47	43.46	80.71	41.96	94.02	75.72	83.93	62.87

表6. 所提出SIMNet模型中各组件的消融研究。

数据集	尺寸	SimConv	WFFM	微损伤	F1
红树林	512	✓	✓	89.80	94.47
	512	✓	×	89.45	94.25
	512	×	✓	88.55	93.72
	256	✓	✓	88.39	93.62
	256	✓	×	87.98	93.38
	256	×	✓	86.05	92.18
	256	×	×	85.12	91.85
洛达	512	✓	✓	63.55	77.50
	512	✓	×	61.79	75.94
	512	×	✓	62.27	77.80
	256	✓	✓	63.86	77.68
	256	✓	×	62.15	76.34
	256	×	✓	62.86	76.99
	256	×	×	61.98	76.12
WHDL	256	✓	✓	62.87	75.72
	256	✓	×	61.37	74.57
	256	×	✓	62.10	75.07
	128	✓	✓	61.41	74.64
	128	✓	×	60.17	73.64
	128	×	✓	59.07	72.50
	128	×	×	58.12	71.85

表7. 提出的SIMNet模型中各组件的消融研究。

输入大小	R_{θ}	M_{θ}	F1	OA	微损伤
256	0.05	0.30	75.25	83.68	62.42
	0.10	0.40	75.72	83.93	62.87
	0.20	0.50	75.41	83.69	62.49
128	0.05	0.30	74.25	82.42	60.75
	0.10	0.40	74.64	82.87	61.41
	0.20	0.50	74.20	82.59	60.97

显著低于所有其他核函数组合。相比之下，固定尺寸核函数方案（如1、5、9或1、7、9）偶尔能达到与混合方法相近的性能水平，但所需参数量大幅增加（例如1、5、9组合达到165.5个参数），远超混合配置方案。这些研究结果明确表明——

表8. 阈值消融实验的定量分析

E_{θ}	F1	OA	微损伤
0.10	75.64	83.83	62.73
0.15	75.72	83.93	62.87
0.20	75.56	83.73	62.62

表9. 卷积核组合的定量分析

K_1, K_2, K_3	F1	OA	微损伤	Attrs (M)
1,3,9	75.46	83.65	62.45	165.56
1,7,9	75.37	83.63	62.44	199.08
3,3,5	75.14	83.36	62.01	81.74
3,5,7	74.71	83.32	61.40	137.61
杂种	75.72	83.93	62.87	73.78

该策略使得混合卷积核能够在保持参数效率的同时，更有效地从遥感图像中捕捉多尺度特征，因此特别适用于特征映射任务。

6. 结论

总之，我们提出了创新的相似性卷积（SimConv）方法，该方法通过关注特征间的内在关联性来自适应选择卷积层尺寸。这种动态方法能够实现更高效、更精准的特征提取，突破了传统卷积层固定感受野的局限性。基于SimConv构建的SIMNet模型在多个林业测绘数据集上展现出卓越性能，取得了最高的准确率和评估分数。这些结果验证了SimConv的有效性，并将SIMNet确立为林业调查应用中一种强大且具有竞争力的解决方案。

7. 致谢

本研究获得中国国家自然科学基金项目（NSFC）资助（项目编号：42571358、42293270、4243000531）。