

HyPCA-Net: 推动医学图像分析中的多模态融合技术发展

乔伊·达尔^{1,*}曼尼什·库马尔·潘迪^{2,*}德巴希斯·达斯·查克拉达尔^{3,*}玛丽亚姆·哈吉哈特⁴阿扎德·阿拉维⁵萨吉布·米斯特里⁶纳亚尔·扎伊迪⁷

¹印度罗帕尔印度理工学院²；印度RoentGen Health³；瑞典吕勒奥理工大学

⁴QUT，澳大利亚⁵；RMIT大学，澳大利亚⁶；科廷大学，澳大利亚⁷；迪肯大学，澳大利亚




图1。(A)单模态基线方法（例如 DDA -Net[7]、NAT[12]、potter[39]等）与计算成本高昂的多模态融合学习（MFL）方法（例如 DRIFA -Net[10]、hamlet[16]、MuMu[17]等）与我们提出的框架HyPCA-Net的性能对比。气泡大小反映参数数量（气泡越大表示参数越多）。(B-C)三种注意力机制的高层次对比：单注意力机制[12, 39]、级联注意力机制[10]以及我们提出的混合注意力机制（HyPCA-Net）。(C)HyPCA-Net的总体架构概述，其包含HyPCA模块，该模块整合了：(i)通过 SCPFA 模块中的CHIA和SHIA实现的并行空间-通道融合；(ii)通过 DVCA 模块实现的级联混合空间双域建模。

摘要

多模态融合框架通过整合多种医学影像模态（如MRI、CT），在皮肤癌检测、痴呆症诊断及脑肿瘤预测等应用中展现出巨大潜力。然而，现有的多模态融合方法面临显著挑战：首先，它们通常依赖**计算成本高昂的模型**，限制了其在资源匮乏环境中的适用性；其次，它们常采用**级联注意力模块**，这可能**增加模块间转换时信息丢失的风险**，并削弱其**有效捕获跨模态稳健共享表征**的能力，从而限制了其在多疾病分析任务中的泛化能力。为解决这些局限，我们提出混合并行融合级联注意力网络（HyPCA-Net），该网络包含两个核心创新模块：(a)计算效率高的残差自适应

*这些作者贡献相同。

(a) 用于捕获精细模态特定表征的注意力学习模块；(b) 旨在跨多种模态学习鲁棒共享表征的双视图级联注意力模块。在十个公开数据集上的大量实验表明，HyPCA-Net显著优于现有主流方法，性能提升高达5.2%，计算成本降低高达73.1%。代码：<https://github.com/mistil203/HyPCA-Net>。

1. 引言

多模态数据在实际应用中至关重要，尤其在医学图像分析领域。MRI、CT和CXR等成像技术可提供互补的解剖学与功能信息，这对肿瘤及其他病理诊断具有关键意义[10]。尽管深度学习已实现高效诊断——但采用特征融合或注意力机制的单模态模型，常因输入噪声及过拟合风险而表现欠佳[7, 9, 10, 12, 39]。多模态




图2. HyPCA-Net框架的总体架构分为两个阶段：(A) RMIL，用于学习鲁棒的共享表示 $\{xSi\}_{i=1}^m$ ；以及(B) MML 模块，用于执行多疾病分类。在 RMIL 阶段，我们提出的新型(C)HyPCA模块包含 RALA 模块（用于优化单峰特征 $\{x9i\}_{i=1}^m$ ）和(D) DVCA 块（用于捕获双域多模态信息）

融合技术通过跨异构模态学习共享表征来缓解这些问题[3, 8]（图1(B)）。注意力机制进一步补充了这种学习过程，使模型能够聚焦于显著区域或生物标志物，从而提升各类医学影像任务中的表征学习效果[15–17, 21]（图1(B)）。尽管近期取得了进展，现有的多模态融合框架[10, 16, 17, 21]仍因标准卷积和多阶段注意力机制而产生高昂的计算成本（挑战1），限制了其在医疗人工智能领域的可扩展性。其顺序（级联）注意力设计还会在模块间转换过程中导致渐进式信息丢失（挑战2），限制了判别性模式的保留，从而导致性能欠佳[23, 35]。这些方法未采用并行融合注意力机制，而后者能够保留关键信息并增强表征学习效果[23, 35]。

为解决这些局限性，我们提出了一种**混合并行融合级联注意力网络——HyPCA-Net**——这是一种多模态融合框架，能够在保持信息完整性的前提下，以最低计算成本实现最优性能（图1(C)）。该框架通过两个创新模块应对上述挑战：**残差自适应学习注意力（RALA）**模块和**双视角级联注意力（DVCA）**模块，其性能优于现有最先进方法（图1(A)）。值得注意的是，RALA 与 DVCA 共同构成了我们创新的 HyPCA 模块（如图2所示）。当该模块集成到包含 RMIL 和 MML 两个阶段的多模态学习框架中时，我们将其称为 HyPCA-Net。HyPCA-Net 的各组件及其各模块的输入输出结构如图2所示。

HyPCA-Net 在多种医学影像模态中实现了最优性能与最低计算成本的平衡。具体而言，RALA 模块通过高效的**空间-通道卷积自适应学习注意力（scala）**模块，**并行学习增强的多尺度空间-通道表征，同时应对两大挑战**。该设计既保持了计算效率，又丰富了表征多样性，同时规避了级联注意力机制的顺序性瓶颈。另一方面，DVCA 模块**通过利用级联混合空间和双域**

信息整合来解决第一个挑战。通过优化这些空间和域中的多模态特征，DVCA 在降低计算开销的同时学习出稳健的共享表征。通过整合这些组件，HyPCA-Net 能够适应多种医学影像场景的学习需求，并在多疾病分类任务中展现出强大的泛化能力。**我们的主要贡献可总结如下：**

- 我们提出 HyPCA-Net，这是一个多模态融合框架，它无缝整合了并行融合注意力模块与级联注意力模块，能够在实现最优性能的同时以最低计算成本学习出稳健的共享表示。
- 我们提出了一种新型 RALA 模块，该模块通过结合多尺度卷积与并行的空间-通道融合注意力模块，增强单峰型表征，从而通过联合捕捉多样的空间与通道依赖关系，逐步优化特征。
- 我们提出了一种新型 DVCA 模块——级联注意力模块，该模块在混合表示空间内整合双域信息，从而学习出稳健的共享特征。
- 我们在十个不同的医学影像数据集上进行了大量实验，结果表明 HyPCA-Net 始终优于当前最先进的方法。

为提高清晰度，我们在表1中汇总了全文使用的所有缩写符号。

2. 相关作品

早期的多模态融合研究主要聚焦于自然视觉与医学影像应用[5, 18, 27]。具体而言，现有框架（例如结合 CNN 与 Transformer 的 MTTU -Net，用于胶质瘤分割和 IDH 预测）虽未对精细表征提供明确的注意力机制[5]。近期基于注意力机制的设计——DDA -Net[7]、MADGNet[25]、NAT[12]、potter[39]及 EMCAD——在表征学习方面取得了显著进展[14–17, 21]。通过并行或级联注意力机制等结构设计，将注意力机制融入多模态融合框架——




图3. (A) RALA 块 (HyPCA 的第一个主成分) 的概览, 该块由尺度块(B)构成; 而尺度块又由 MSHC 块(C)和 SCPFA 块(D)组成。SCPFA 块包含 SHIA(E)和 CHIA(F)两个子成分。

表1. 基于模块和组件的缩写列表。

缩写	满期	出现在.....中
HyPCA-Net	混合并行融合级联注意力网络	Sec. 1, 3
HyPCA	HyPCA模块 (RALA + DVCA)	Sec. 3
RMIL	稳健的多模态信息学习	Sec. 3.1
RALA	残差自适应学习注意力机制	Sec. 3.1.1
比例尺	空间-通道卷积自适应学习注意力机制	Sec. 3.1.1
MSHC	多尺度空间异质卷积	Sec. 3.1.1
SCPFA	空间-通道并行融合注意力机制	Sec. 3.1.1
什叶派	空间整体性信息学习注意力机制	Sec. 3.1.1
CHIA	渠道整体性信息学习注意力	Sec. 3.1.1
DVCA	双视图级联注意力机制	Sec. 3.1.2
Hy-SFA	混合空间融合注意力机制	Sec. 3.1.2
TFSI	令牌空间频率-空间整合	Sec. 3.1.2
联邦国防通信管理局	特征空间双求解器通道注意力机制	Sec. 3.1.2
HCA	异构通道注意力机制	Sec. 3.1.2
MMMUA	多尺度、多频率的相互更新注意力机制	Sec. 3.1.2
FCIF	频域信道信息融合	Sec. 3.1.2
特异的非特异性免疫反应	空间域多尺度信息融合	Sec. 3.1.2
MCBI	相互交叉双向相互作用	Sec. 3.1.2
最大公约数	层次化通道融合	Sec. 3.1.2
MML	多模态多任务学习	Sec. 3

ules——显著提升了性能[14–17, 21]。例如, Gloria整合了全局-局部注意力机制, 将放射学图像与文本报告对齐以实现高效的标签学习[15]; 而M³Att则采用互注意力和迭代交互机制, 融合视觉与语言特征用于参考图像分割[21]; hamlet和MuMu则运用层次化及引导式多模态注意力实现人体活动识别[16, 17]。CAF和DR-IFA-Net等方法通过协同注意力融合与级联双注意力策略, 应用于皮肤癌诊断和多疾病分类[10, 14], 彰显了注意力机制的多功能性。尽管近期取得进展, 现有框架仍存在计算量大、模块间信息丢失易发等问题, 限制了稳健的表征学习能力。为解决此问题, 我们提出了一种基于混合注意力的融合架构, 以平衡性能与效率——这对可扩展的医疗人工智能至关重要。详见补充材料更多细节。

3. 方法

问题表述。 给定输入 $X = \{x_i\}_{i=1}^m$ 从 m 种异构模态和标签 $Y = \{y_j\}_{j=1}^n$ (对应 t 个任务) 中提取数据, 我们的网

络 $F(\cdot)$ 旨在学习鲁棒的共享表示 $X^s = \{\{xsi\}_{i=1}^m\}$ 这有助于建立映射关系 $F(X) \rightarrow Y$, 从而在最小计算成本下实现高性能的联合优化。

方法概述。 我们对 HyPCA-Net 框架 (参考图2) 进行了全面概述。HyPCA-Net 包含两个关键阶段: 1) 鲁棒多模态信息学习 (RMIL) ——学习鲁棒的共享表示; 2) 多模态多任务学习 (MML)

– 灵感源自 DRIFA-Net[10]——该方法能够支持多种下游任务 (例如多疾病分类), 并位于 RMIL 阶段之后。具体而言, RMIL 阶段生成的共享表示 X^s 可用于跨 $i \in [1: m]$ 种模态对多种疾病进行分类。该方法通过损失函数 $\mathcal{L}_{MML}$ 将输入 X 映射为输出预测 Y , 其中 λ_{it} 用于控制每个任务模态特定损失 $\mathcal{L}_{it}$ 的权重。最优模型参数 β^* 通过最小化 $\mathcal{L}_{MML}$ 获得, 即:

$$\mathcal{L}_{MML} = \sum_{t=1}^T \sum_{i=1}^m \lambda_{it} \cdot \mathcal{L}_{it}^*(F(X^s; \beta); Y); \beta^* = \arg \min_{\beta} (\mathcal{L}_{MML}), \quad (1)$$

其中 β 表示 HyPCA-Net 的参数。下文将详细讨论 RMIL 阶段。

3.1. 稳健的多模态信息学习

鲁棒多模态信息学习 (RMIL) 阶段由 m 个并行的模态专用分支组成, 每个分支包含 b 个级联的 HyPCA 模块 (见图2)。每个模块通过引入并行融合注意力 (通过残差自适应学习注意力 (RALA) 模块, 该模块捕捉多尺度空间与通道依赖关系以学习精细的单模态表示 $X^g = \{x_i^g\}_{i=1}^m$), 将两个注意力子模块整合为混合设计。 $\{x_i^g\}_{i=1}^m$ 采用级联注意力机制 (通过双视图级联注意力 (DVCA) 模块, 该模块整合空间与频率域信息, 以捕获稳健的共享表征)。

$X^s = \{x_i^s\}_{i=1}^m$ 接下来，让我们详细探讨这些模块的具体内容。

3.1.1. 残差自适应学习注意力机制

残差自适应学习注意力（RALA）子模块（参见图3(A)）通过以最低计算成本同时捕捉多尺度空间模式与通道依赖关系，从而优化特征表示。该模块旨在解决 EMCAD[31]存在的三大缺陷：(1)单阶段多尺度处理；(2)同质分支设计；(3)缺乏空间-通道融合机制。RALA 通过采用名为“空间-通道卷积自适应学习注意力”（scala）的组件（图3(B)）来克服这些局限性。

—该模型包含两个核心组件：A) 多尺度空间异质卷积（MSHC）和 B) 空间通道并行融合注意力（SCPFA）。具体而言，为实现级联式信息细化：

RALA 模块用一对尺度模块替换了 EMCAD 中的 MSDC 模块（参见图3(A)），从而实现渐进式的多尺度表征细化；其次，为实现异质分支设计，每个 MSHC 模块在不同分支上采用不同尺度的异质卷积，以促进表征多样性；最后，为实现空间通道融合，SCPFA 模块联合学习空间与通道依赖关系，从而为下游任务生成更丰富的表征。形式上，给定特定模态的输入 x_i ——可获得细化表征 $\{x_i'\}_{i=1}^m$ 。RALA ($\cdot$) 区块可表示为：

$$\text{RALA}(x_i) = \text{R}(x_i + \text{BNPC}(\text{scala}(\text{R}(\text{BN}(\text{scala}(x_i))))))$$

渐进级联细化尺度 $(x_i) = x_i +$

$$\text{SCPFA}(\text{MSHC}(x_i))$$

(2)

其中跳跃连接可稳定梯度流并促进特征复用；BNPC ($\cdot$) = BN(PC ($\cdot$)) 分别对应批量归一化与逐点卷积；R ($\cdot$) 表示ReLU激活函数。接下来，我们将讨论 MSHC 和 SCPFA 模块。

(A) 多尺度空间异质卷积。

多尺度空间异构卷积（MSHC）模块（参见图3(C)）采用了通过组逐点卷积（GPC）、扩张深度卷积（DDC）和深度卷积（DWC）获得的异构卷积分支——其尺度 k 各不相同 (1×1 、 3×3 、 5×5)¹。为进一步促进通道间通信，我们应用了通道洗牌操作 CS ($\cdot$)。最后，通过一系列 GPC、DWC及滑动DWC（记为 SDWC）层，可恢复原始通道维度，明确捕捉通道间依赖关系，并进一步优化表征效果。MSHC ($\cdot$) 模块的操作流程可总结如下：

¹该设计促进了分支间的异质性，通过融合各分支的输出来捕捉精细的多尺度空间模式，从而生成丰富的表征 $x_{9i} = \text{MSHC}(\cdot)$ ，进而增强了表征多样性。




图4.Hy-SFA（DVCA 模块的关键组件）的整体架构，包含(A) TFSI 模块和(B) FDCA 模块。FDCA 模块集成了异构通道注意力机制（HCA）。

$$\text{MSHC}(x_i) = \text{SDWC}\left(\text{GPC}\left(\text{DWC}\left(\text{CS}\left(\theta\left(\bigvee_{k \in \{1,3,5\}} \text{HC}_k(x_i)\right)\right)\right)\right)\right). \quad (3)$$

分支层面的异质性

其中 $\text{HC} \in \{\text{GPC}, \text{DWC}, \text{DDC}\}$ ，且 θ 表示融合操作。(B) 空间-通道并行融合注意力机制。空间-通道并行融合注意力（SCPFA）模块（参见图3(D)）通过联合学习空间与通道特征来增强模态特异性表征，其包含两个核心组件：(1)通道整体信息学习注意力（CHIA）；(2)空间整体信息学习注意力（SHIA）。在设计 CHIA（图3(F)）时，我们采用多种全局池化操作——全局平均池化（GAP）、全局最大池化（GMP）、全局最小池化（GMN）和全局求和池化（GSP），以捕捉长程通道上下文；而在设计 SHIA（图3(E)）时，则运用多视角局部池化操作——平均池化（AP）、最大池化（MP）、最小池化（MN）和求和池化（SP），以学习细粒度空间细节。在每个分支中，最终得到的不同上下文被融合以捕捉多样化的依赖关系。他们应用 Sigmoid $\sigma(\cdot)$ 函数来获取通道注意力图 $A_C = \text{CHIA}(\cdot)$ 和空间注意力图 $A_S = \text{SHIA}(\cdot)$ 。我们将这些图整合为联合注意力图 $A_{SC} = \text{SCPFA}(\cdot)$ ，从而重新校准输入特征 x_i' ，得到优化后的表征。我们将 SCPFA ($\cdot$) 的块操作表示为：

$$x_{9i} = x_{9i} \circ \text{SCPFA}(x_{9i}), \quad (4)$$

$$\text{SCPFA}(x_{9i}) = \sigma(\text{SHIA}(x_{9i}) + \text{CHIA}(x_{9i})).$$

在哪里：

$$\text{CHIA}(x_{9i}) = \sigma(\text{FC}(\text{GAP}(x_{9i}) + \text{GMP}(x_{9i}) + \text{GMN}(x_{9i}) + \text{GSP}(x_{9i}))).$$

$$(5) \text{SHIA}(x_{9i}) = \sigma(\text{Conv}(\text{AP}(x_{9i}) + \text{MP}(x_{9i}) + \text{MN}(x_{9i}) + \text{SP}(x_{9i}))).$$

(6) 其中 $\circ$ 表示哈达玛积，FC 和 Conv 分别表示全连接层和卷积层。




图5. (A) MMMUA 模块 (DVCA 模块的关键组件) 概述。该模块由 MCBi (B)、FCIF (C) 和 SMIF (D) 三个子模块组成。MCBi 模块整合了 FCIF 和 SMIF 模块的输出；FCIF 模块采用层次化通道融合 (HCF) 机制。

3.1.2. 双视图级联注意力机制

双视图级联注意力 (DVCA) 模块 (图2(D)) 旨在通过两个级联模块，从多模态输入 X' 中学习鲁棒的共享表示 X^s ：即混合空间融合注意力 (Hy-SFA) ——用于捕捉混合空间 (标记与特征空间) 中模态特异性的多样化通道依赖关系；以及多尺度多频率互更新注意力 (MMFU) ——通过捕获双域 (空间与频率) 信息来丰富多模态上下文表示。下文将对这两个模块进行详细讨论。

(A) 混合空间融合注意力。令牌空间注意力 (例如基于窗口的局部注意力) [22] 能够捕捉精细的空间交互关系，而特征空间方法 (例如通过二维离散余弦变换实现的频域注意力) [29] 则能增强纹理区分能力。然而，这些范式尚未在同一模块内实现协同注意力机制，导致多模态融合流程中缺乏混合空间交互机制。为填补这一空白，我们提出了混合空间融合注意力 (Hy-SFA) 模块 (图4)，该模块通过两个级联子模块——TFSI 和 FDCA——联合捕捉令牌空间与特征空间之间的多样化通道依赖关系，从而增强每个模态输入 x_i' ，实现跨域上下文交换。

- **令牌空间频率-空间集成 (TFSI)** 通过联合处理每个局部窗口内的空间和频率令牌来学习互补的双域信息 (图4(A))。具体而言，给定输入 x_i' 和窗口大小 w ，我们首先沿空间轴将 x_i' 循环平移 $lw/4$ 像素，并将其划分为非重叠的 $w \times w$ 窗口。在每个窗口中，TFSI 直接从窗口化特征中捕获空间令牌 $S_t \in \mathbb{R}^{w \times c}$ ，并捕获频率令牌 $F_t \in \mathbb{R}^{w \times c}$ 。

通过归一化的二维离散余弦变换 (DCT) 实现。每个标记集分别经过 MLP (f_θ) 和 Sigmoid σ 处理，从而得到注意力权重：

$$\alpha_{sp} = \sigma(f_\theta(S_t)) \text{ 且 } \alpha_f = \sigma(f_\theta(F_t)). \quad (7)$$

通过突出每个领域的信息性特征来融合加权标记流，从而获得双域输出 U_d ：

$$U_d = (\alpha_{sp} \odot \alpha_f) + (1 - \alpha_{sp}) \odot S_t. \quad (8)$$

- **特征空间双求解器通道注意力 (FDCA)** (图4(B)) 通过将特征空间中的双域标记 $U_d \in \mathbb{R}^{H \times W \times C}$ 视为连续深度流的初始状态 (H_0)，并遵循神经常微分方程 (ODE) 公式 [4] 对其进行优化。随后对 H_0 应用一个 GAP 及一个 Sigmoid 激活函数密集层，从而获得用于后续处理的自适应步长 $\tau \in (0, 1]$ 。为捕捉互补尺度上的信息，FDCA 并行使用两个离散常微分方程 (ODE) 求解器——针对粗粒度上下文采用一阶欧拉步 (U_e)，针对细粒度细节采用二阶龙格-库塔 (RK2) 步 (U_r)，具体形式如下：

$$U_e = H_0 + \tau f_\theta(H_0), \\ k_1 = f_\theta(H_0), \quad k_2 = f_\theta(H_0 + \frac{\tau}{2} k_1), \quad U_r = H_0 + \tau k_2. \quad (9)$$

其中 k_1, k_2 表示 RK2 更新中的中间斜率。生成的提议通过注意力权重 α_p (由密集 $\rightarrow$ softmax 层生成) 进行自适应融合——该权重会突出信息量更大的更新结果，而跳跃连接则保留原始特征 H_0 ，从而生成能够同时捕捉粗粒度与细粒度细节的提炼表征 U_{fu} ：

$$U_{fu} = \alpha_p (U_e + U_r) + (1 - \alpha_p) H_0. \quad (10)$$

我们通过应用多种全局池化操作实现了异构通道注意力机制 (HCA) (图4(B))。

将GAP、GMP、GMN和GSP等注意力机制应用于最终生成的细节 ($\mathbf{U}_{fu}$)，以捕捉多样化的通道统计信息。随后对这些上下文信息进行聚合，通过MLP层并结合Sigmoid函数处理，生成混合空间注意力图 (A_{HS})，该图可根据学习到的通道重要性对通道进行重新加权，从而提取增强型特征：

$$A_{HS} = \sigma(f_{\theta}(\text{GAP}(\mathbf{U}_{fu}) + \text{GMP}(\mathbf{U}_{fu}) + \text{GMN}(\mathbf{U}_{fu}) + \text{GSP}(\mathbf{U}_{fu}))) \quad (11)$$

$$\mathbf{U}_{out} = \mathbf{U}_{fu} \otimes A_{HS}. \quad (12)$$

输出 $\mathbf{U}_{out}$ 经过循环移位反转和窗口重构后恢复到原始空间位置，从而为每个窗口尺度 ws 得到 $\mathbf{x} \sim i, ws$ (图3(B))。与此同时，相同的全局池化操作被应用于所有窗口中的频域标记 $\mathbf{F}_t$ ，随后通过融合这些标记来学习多样化的通道描述符 ($\mathbf{C}_e$) (图3(A))：

$$\mathbf{C}_e = \text{GAP}(\mathbf{F}_t) + \text{GMP}(\mathbf{F}_t) + \text{GMN}(\mathbf{F}_t) + \text{GSP}(\mathbf{F}_t). \quad (13)$$

我们分别计算实例特定的注意力权重，即 $\omega_{i,ns}$ 和 ω_g ，作用于 $\mathbf{C}_e$ 和 α_p ；随后将这些权重分配给 $\mathbf{x} \sim i, ws$ ，并利用原始输入 x_i' 的SP层，最终得到优化后的表示：

$$\omega_{i,ns} = \text{softmax}(\mathbf{C}_e), \quad \omega_g = \alpha_p. \quad (14)$$

$$x_i' = x_i' + \text{SP} \left(\sum_{ws=1}^2 (w_{ins,ws}^{(i)} w_{g,ws}) \hat{x}_{i,ws} \right). \quad (15)$$

(B) 多尺度多频互更新注意力机制：(MMMUA) 模块 (图5(A)) 通过跨模态互作用，从输入 $\mathbf{X}'$ 中联合学习多模态信息（借助Hy-SFA）。该模块在多个空间尺度和频段上运行，生成多模态空间-频率注意力图 A_{D_i} ，从而重新校准各模态特征，并学习出鲁棒的共享表示 $\mathbf{X}^s$ ：

$$\mathbf{X}^s = \mathbf{X}_9 \otimes A_{D_i} \otimes \omega_i. \quad (16)$$

其中，针对每种模态 i ，存在通道级别的可学习参数 ω_i 。为学习多模态空间-频率注意力图 A_{D_i} ，MMMUA 模块包含三个核心组件：

- **频域信道信息融合 (FCIF) 组件** (图5(C)) 通过将模态特定输入（例如 $\mathbf{x}_{91}$ ）分解为小波DWC生成的小波子带（记为WDWC：低-低(LL)、高-低(HL)、低-高(LH)和高-高(HH)²⁾，捕捉了多样的信道依赖关系。为从每个子带中学习不同的信道线索，我们设计了分层信道融合(HCF)方案（参见补充材料图1），该方案应用多种全局池化操作——GAP、GMP、GMN和GSP——以捕捉不同的信道上下文，即 C_{GAP} 、 C_{GMP} 、 C_{GMN} 和 C_{GSP} 。这些上下文随后被融合在一起。

²⁾这些子波段分别捕捉粗粒度结构、水平边缘、垂直边缘及细粒度纹理。

通过子频带间融合（公式18-20），整合并行与级联的加减运算，以学习全面且互补的频域信道细节 C_f ：

$$\begin{aligned} (\text{LL}, \text{HL}, \text{LH}, \text{HH}) &= \text{WDWC}(x_1'), \\ [C_{\text{Sum}}, C_{\text{Diff}}] &= \text{HCF}(\text{LL}, \text{HL}, \text{LH}, \text{HH}), \\ C_f &= \sum_j \omega_j \odot \text{DR}_j(\text{BN}_j(C_j)) \end{aligned} \quad (17)$$

其中 $C_j = [C_{\text{Sum}}, C_{\text{Diff}}]$ ，DR 和 BN 分别表示丢弃(dropout)和批量归一化(batch norm)。HCF 可表示为：

$$\begin{aligned} C_{\text{GAP}} &= \sum T \text{GAP}(T), \quad C_{\text{GMP}} = \sum T \text{GMP}(T), \\ C_{\text{GMN}} &= \sum T \text{GMN}(T), \quad C_{\text{GSP}} = \sum T \text{GSP}(T) \end{aligned} \quad (18)$$

其中 $T \in \{\text{LL}, \text{LH}, \text{HL}, \text{HH}\}$ 。

$$\begin{aligned} C_{\text{Sum}} &= C_{\text{GAP}} + C_{\text{GMP}} + C_{\text{GMN}} + C_{\text{GSP}}, \\ C_{\text{Diff}} &= C_{\text{GMP}} / (C_{\text{GAP}} + C_{\text{GMN}}) \end{aligned} \quad (19)$$

- **空间域多尺度信息融合 (SMIF)**

(图5(D)) 展示了精细粒度的多尺度空间通道机制。具体而言，该方法先堆叠一个MSHC模块，再接入来自scala模块的SCPFA模块，以在不同尺度上优化表征 ($\mathbf{x} \sim m$)。随后，采用多种全局池化操作——GAP、GMP、GMN和GSP——来捕捉互补的通道上下文信息，并通过融合这些信息来学习多样化的空间-通道依赖关系，

即： C_{SP} ：

$$\begin{aligned} \hat{x}_m' &= \text{SCPFA}(\text{MSHC}(x_m')), \\ C_{SP} &= \text{GMP}(\mathbf{x} \sim 9m) + \text{GAP}(\mathbf{x} \sim 9m) + \text{GMN}(\mathbf{x} \sim 9m) + \text{GSP}(\mathbf{x} \sim 9m). \end{aligned} \quad (20)$$

- **相互交叉双向交互 (MCBI) 组件** (图5(B)) 旨在整合频域信道上下文——即来自FCIF的 C_f ——与空间域空间信道细节——即来自SMIF的 C_{SP} ，用于处理多模态输入 $\mathbf{X}'$ ，从而通过互补信息交换实现相互增强。该组件采用双向交叉交互将模态 $\mathbf{x}_{91}$ 的 C_f 与模态 x_m' 的 C_{SP} 进行融合，反之亦然。这种非对称交互在保留模态特定特征的同时，相互更新信道依赖关系，捕捉互补的跨域空间信道信息。自适应缩放因子 ω_i 调节这些交互以提升判别能力。最终，Sigmoid激活函数生成跨域注意力图： $A_{D_i} = \text{MMMUA}(\cdot)$ ，用于突出关键信息。针对不同模态的原生区域，联合优化空间-通道相关性。注意力图的计算公式如下：

$$\begin{aligned} C_{SP} &= \omega_1 \odot C_{SP} + \omega_2 \odot C_f, \\ \hat{C}_f &= (\text{DR}(\text{BN}(\hat{C}_{SP})) \otimes \omega_3) + (C_f \otimes \omega_2), \end{aligned} \quad (21)$$

$$A_{D_i} = [\sigma_1(C_f), \sigma_2(C_{SP})].$$

摘要。HyPCA将RALA中的并行空间-通道融合(SCPFA=CHIA+SHIA)与级联融合技术相结合。

表2.HyPCA-Net与 SOTA 方法（M1-M8）在8个数据集（D1-D8）上的分类性能对比。加粗/下划线数值分别表示最佳/次佳结果。我们列出了每种方法的参数数量（单位：百万）及 GFLOPS。

数据集→ 模型↓	backbone	D1: Nickparvar			D2: IQ-OTHNCCD			D3: 结核病			D4: CNMC-2019			D5: HAM10000			D6: SiPaKMeD			D7: CRC			D8: CBIS-DDSM			全面的	
		ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	ACC	F1	AUC	#P	#F
DDA-Net	ResNet18	96.8	96.6	97.2	98.1	97.5	98.2	95.8	95.1	95.4	92.2	91.8	92.1	92.2	92.0	92.6	92.5	92.8	91.9	92.7	92.7	93.1	92.5	91.8	91.5	12.1	1.12
MSCAM	PVT2-B2	97.6	97.6	97.9	99.5	99.5	99.5	97.8	96.9	97.6	95.3	95.1	95.3	97.6	97.2	97.6	94.2	94.0	94.9	96.4	96.2	96.6	94.1	93.9	94.2	26.9	1.3
MFMSA	ResNet50	97.9	97.7	98.0	99.5	99.3	99.5	98.1	97.3	98.3	95.6	95.2	95.9	97.9	97.4	97.9	94.8	94.4	95.3	96.7	96.5	96.6	94.6	94.5	94.6	26.9	1.4
格洛丽亚	ResNet50	98.1	97.6	97.9	98.5	98.4	98.5	96.6	96.0	96.9	93.3	93.3	93.4	93.8	93.8	94.5	94.2	94.2	94.2	95.9	95.6	95.7	92.5	91.2	91.9	30.8	1.54
MTTU-Net	ResNet50	97.9	97.9	98.0	99.5	99.2	99.5	97.3	96.6	97.6	94.3	93.9	94.1	97.4	96.5	97.2	91.9	92.3	92.6	96.9	96.8	97.0	94.1	93.3	94.5	38.1	6.8
姆姆	ResNet50	96.8	96.8	97.2	98.2	97.9	98.7	97.1	96.4	96.8	93.4	93.1	93.9	92.8	92.4	93.2	92.3	91.7	92.9	95.9	95.3	95.9	92.1	91.6	92.5	56.6	2.97
M ³ Att	Swish-B	97.5	97.4	97.9	98.8	98.7	98.8	96.9	95.6	96.8	94.0	93.6	94.2	95.5	94.9	95.3	92.2	91.5	92.3	96.1	96.2	96.4	93.2	92.7	93.6	183	12.14
DRIFA-Net	ResNet18	98.4	98.4	98.7	99.7	99.5	99.5	98.2	97.5	98.6	96.4	96.3	96.7	98.2	97.9	98.5	95.6	95.5	95.9	97.0	96.8	97.1	95.2	95.1	95.4	53.8	4.83
HyPCA-Net18	ResNet18	98.8	98.7	99.0	99.8	99.8	99.8	98.9	98.0	99.2	97.2	97.1	97.5	99.4	99.3	99.7	95.7	95.7	96.1	98.3	97.9	98.5	96.3	96.2	96.5	14.47	2.25
HyPCA-Net50	ResNet50	99.2	99.1	99.3	99.9	99.9	99.9	99.1	98.3	99.4	97.5	97.3	97.9	99.6	99.6	99.8	96.7	96.4	97.2	98.5	98.1	98.7	96.9	96.6	97.2	28.4	3.03
HyPCA-Net-IN	Inception-v3	98.5	98.4	98.6	99.8	99.8	99.8	98.4	97.7	98.9	96.9	96.9	97.2	100	100	100	97.2	97.2	97.5	98.7	98.7	98.7	97.1	97.1	97.3	26.8	2.76
HyPCA-Net-ViT	ViT-Ti	99.4	99.4	99.3	99.9	99.9	99.9	99.2	98.8	99.2	97.9	97.7	98.1	100	100	100	97.7	97.7	97.7	98.8	98.7	98.8	97.8	97.5	98.2	22.5	3.42

表3. HyPCA-Net-Seg（SegNet 主干网络）与 HyPCA-Net- EMCAD（EMCAD 主干网络）在D9-D10数据集上与 SOTA 方法的性能对比

模型	D9: COVID-19		D10: ISIC		#P	#F
	召回率 (DSC)	证据	召回率 (DSC)	证据		
UNet	47.7	38.6	87.3	80.2	34.5	65.5
PolypPVT	81.7	74.4	90.4	83.9	25.1	5.3
MTTU-Net	82.2	75.7	89.2	82.6	71.6	20.9
MADGNet	83.9	76.9	90.2	83.8	31	14.2
PVT级联	84.1	77.3	90.4	84.0	34.1	7.6
EMCAD	85.8	78.6	90.9	84.1	26.8	5.6
DRIFA-Net	84.4	77.1	90.6	83.9	67.3	19.9
HyPCA-Net-Seg	88.2	80.9	92.7	85.3	21.7	8.04
HyPCA-Net-EMCAD	90.3	82.5	93.8	86.4	18.6	7.65

混合空间、DVCA 中的双域建模（Hy-SFA = TFSI → FDCA；MMMUA = FCIF + SMIF + MCBI）。并行步骤有效抑制了早期信息丢失，而级联结构则融合了标记空间与频率空间的证据，并实现了跨模态的空间与频率线索同步（参见图2-5）。这种并行→级联耦合机制在医学影像多模态融合领域尚属首创，能在较低计算成本下实现更高的性能提升（表2-6）。

4. 实验分析与结果数据集我们在十个公开的医学影像基准数据集上评估了 HyPCA-Net：分类任务中使用了 Nickparvar[26]、IQ-OTH NCCD[1]、Tuberculosis [32]、CNMC-2019[24]和 HAM10000。

[38]，SiPaKMeD[28]、CRC[20]、CBIS-DDSM[34]，分别标记为（D1-D8）。分割任务中我们使用了COVID-19肺部CT[19]和ISIC2018皮肤病变[6]数据集，分别标记为（D9-D10）。图像被调整为128 × 128 × 3（分类任务）或224 × 224 × 3（分割任务），并采用80/10/10的比例（训练集/验证集/测试集）进行划分，同时应用标准的实时数据增强技术。

模型我们将HyPCA-Net与一系列最先进的（SOTA）基线模型进行了全面评估。在分类任务中，单模态基线包括 DDA-Net、MADGNet的 MFMSA[25]以及 EMCAD的 MSCAM[31]（统称为M1-M3）；多模态融合基线则包含 Gloria[15]、MTTU-Net[5]、MuMu[17]、M3Att和 DRIFA-Net（统称为M4-M8）。在分割任务中，我们比较了 MTTU-Net和 DRIFA-Net（采用SegNet解码

器），以及 SOTA 单模态基线：UNet[33]、PolypPVT [11]、MADGNet、EMCAD 和 PVT-cascade[30]（统称为M9-M15）。值得注意的是，我们为HyPCA-Net配置了四种分类主干网络——ResNet-18[13]、ResNet-50[13]、Inception-v3[37]和 ViT-Ti[36]，以及用于分割任务的 SegNet[2]和 EMCAD[31]解码器（与我们的HyPCA-Net18编码器配合使用）。这些变体分别命名为HyPCA-Net18、HyPCA-Net50、HyPCA-Net-IN、HyPCA-Net-ViT、HyPCA-Net-Seg和HyPCA-Net- EMCAD。

符号说明我们报告的指标包括准确率（Acc）、F1分数（F1）、AUC、Dice分数（DSC）、交并比（IoU）、参数数量（百万个，#P）以及GFLOPs（#F）。详见 [补充材料中的数据、模型及训练细节](#)。

4.1. 性能比较

我们在表2和3中展示了实验结果，从中可以看出 HyPCA-Net在分类和分割数据集上表现出卓越性能，准确率范围达80.9%至100%。与 SOTA 单模态及多模态融合基线方法相比，HyPCA-Net性能提升了0.1%至43.9%，同时参数量最多减少92%，FLOPs最多降低81.47%。如图6所示，我们对D1和D5数据集进行了定性分析，进一步验证了其有效性。详见 [补充材料中的更多细节与结果](#)。

正如我们先前讨论的，为解决 **挑战1**，我们的 HyPCA-Net通过整合两个高效模块——RALA 和 DVCA，在最优性能与最低计算成本之间实现了有效平衡。由于级联设计本质上是 *顺序的*，它们会孤立处理不同方面，缺乏联合优化，因此 *难以完整保留信息的整体性*，最终 *限制了学习表征的丰富度* [23, 35]。相比之下，我们的混合注意力设计将并行融合注意力与级联注意力无缝结合，在保留整体线索的同时，*联合且级联式地建模混合空间及双域表征学习中的空间-通道依赖关系*。因此，HyPCA-Net克服了固有的局限性——

表4. HyPCA-Net18模块（左）及组件（右）的消融分析，重点展示了它们对D5–D6数据集性能提升的贡献。

集成模块			D5: HAM10000	D6: SiPaKMeD		模块内的集成组件							D5: HAM10000	D6: SiPaKMeD		
RALA	Hy-SFA	MMMUA	F1	F1	#P	MSHC	CHIA	什叶派	FCIF	MCBI	TFSI		账户	F1	账户	#F
×	×	×	93.2	89.3	23.4	×	×	×	×	×	×	×	93.2	93.1	89.5	89.3
×	×	✓	97.1	93.0	25.2	✓	×	×	✓	×	×	×	96.8	96.6	92.9	92.8
×	✓	×	96.7	92.8	28.1	✓	✓	×	✓	×	✓	×	97.6	97.6	93.9	93.7
×	✓	✓	98.6	94.9	30.5	×	×	✓	✓	×	×	×	97.3	97.2	93.6	93.4
✓	×	×	96.1	92.3	10.1	✓	✓	✓	✓	×	×	×	97.9	97.7	94.3	94.2
✓	×	✓	97.8	93.8	11.9	✓	×	×	✓	✓	✓	×	98.3	98.3	94.3	94.0
✓	✓	×	97.3	93.4	12.9	✓	✓	✓	✓	✓	✓	×	98.7	98.7	95.3	95.1
✓	✓	✓	99.3	95.7	14.5	✓	✓	✓	✓	✓	✓	✓	99.4	99.3	95.7	95.7

表5. HyPCA-Net- EMCAD 模块（左）及组件（右）的消融实验结果，突显了它们对D9–D10数据集性能提升的贡献。

集成模块			D9: COVID-19	D10: ISIC		模块内的集成组件							D9: COVID-19	D10: ISIC		
RALA	Hy-SFA	MMMUA	借据	借据	#P	MSHC	CHIA	什叶派	FCIF	MCBI	TFSI		借据	借据	#P	#F
×	×	×	82.8	75.5	85.9	79.1	27.2	×	×	×	×	×	82.8	75.5	85.9	79.1
×	×	✓	86.2	78.8	89.1	81.9	29.2	✓	×	×	×	×	85.5	78.2	87.4	81.2
×	✓	×	85.5	77.9	88.4	81.1	32.1	✓	×	×	×	×	86.5	79.1	88.9	82.5
×	✓	✓	88.5	80.9	90.7	84.1	34.4	×	×	×	×	×	86.2	78.8	88.5	82.1
✓	×	×	84.7	77.4	87.9	80.8	13.9	✓	✓	×	×	×	86.8	79.5	89.3	82.8
✓	×	✓	88.1	80.6	91.2	83.6	15.7	✓	×	×	×	×	87.6	80.1	90.6	83.7
✓	✓	×	87.4	79.7	90.3	82.8	16.6	✓	✓	✓	✓	×	89.1	81.0	92.7	85.5
✓	✓	✓	90.3	82.5	93.8	86.4	18.6	✓	✓	✓	✓	✓	90.3	82.5	93.8	86.4




图6. 本研究提出的HyPCA-Net框架与其他十种 SOTA 方法在两个基准数据集D5和D1上，采用GRAD-CAM技术对关键区域的可视化展示。

表6. 在保持其他组件不变的情况下，级联注意力（CA）与混合注意力（HA）在CHIA和SHIA模型中于D5和D6数据集上的性能比较（F1分数）。

哈	CA	D5	D6	#P	#F
✓	×	99.3	95.7	14.47	2.25
×	✓	98.9	95.2	14.47	2.25

这种方案完全基于级联架构，并直接解决了挑战2，从而实现了更稳健的共享表示学习。详见补充材料中的讨论部分。

4.2. 消融研究

我们在数据集D5-D6和D9-D10上评估了HyPCA-Net的关键组件，重点关注RALA（结合SCPFA）以及DV-CA中的Hy-SFA和MMMUA模块。表4-5显示，HyPCA-Net的性能较其消融变体提升了0.4%-7.9%，凸显了其混合注意力设计的有效性。此外，我们分析了各模块的贡献：SCALA中的MSHA、CHIA和SHIA；MMMUA中的FCIF、SMIF和MCBI；以及Hy-SFA中的TFSI和FDCA（表4-5）。HyPCA-Net相较于部分配置最高实现了7.9%的性能提升，表明这些模块具有互补作用。最后，我们比较了级联配置（CHIA → SHIA → DVCA）与混合配置（并行CHIA+SHIA → DV-CA）（表6）；混合变体实现了0.4%-0.5%的性能增益，在更低计算成本下获得了更稳健的共享表征。

可以推断，消融变体（表4-5）性能有限的原因在

于其无法以较低计算成本学习稳健的共享表征——

而这对于解决挑战1至关重要。为应对挑战2，我们注意到级联注意力架构由于缺乏并行级联（混合）融合而面临渐进式信息丢失，这阻碍了整体信息的保留并削弱了表征学习能力，最终导致性能下降（表6）[23, 35]。如前所述，HyPCA-Net通过其集成的混合注意力模块（RALA、Hy-SFA和MMMUA）同时解决了这两个挑战。具体而言，RALA通过并行融合高效捕捉多尺度空间-通道依赖关系，而Hy-SFA和MMMUA则建模互补的双域交互。我们的混合框架能够保留整体信息，以较低成本提升多疾病分类性能（更多结果见补充材料）。

5. 结论

我们提出HyPCA-Net，这是一个高效的多模态融合框架，专为提升医学图像分析性能而设计，非常适合实际医疗人工智能应用。HyPCA-Net在十个多样化的数据集上进行了评估，展现出在多种医学影像模态下的强大泛化能力。其性能比领先基线方法最高提升≈5.2%，计算成本降低≈73.1%。未来，我们计划将对抗鲁棒性与领域迁移适应融入HyPCA-Net，以实现鲁棒泛化。