

超越照明技术：极端暗部图像修复中的精细细节保留

张同顺^{1,2}、刘平平^{1,2*}、钟子轩³、张子健^{1,2}、周秋展⁴¹ 吉林大学计算机科学与技术学院² 吉林省立大学教育部符号计算与知识工程重点实验室³ 吉林大学软件学院⁴ 吉林大学通信工程学院

{tszhang23, zhongzx24}@mails.jlu.edu.cn, {liupp, zhangzijian, zhouqz}@jlu.edu.cn

摘要

在极暗图像中恢复精细细节仍面临巨大挑战，这主要源于严重的结构信息丢失和噪声干扰。现有的增强方法往往难以保留复杂的细节和清晰边缘，从而限制了其在文本识别和边缘检测等下游应用中的有效性。为解决这些问题，我们提出了一种以细节恢复为核心的高效双阶段方法。第一阶段引入残差傅里叶引导模块（RFGM），该模块能在频域有效恢复全局光照特征。RFGM通过残差连接捕捉阶段间与通道间的依赖关系，为高保真频率处理提供可靠的先验信息，同时降低因先验信息不可靠导致的误差累积风险。第二阶段采用专门用于纹理结构优化的互补Mamba模块：其中，Patch Mamba作用于通道拼接的未降采样图像块，通过精确建模像素级相关性，在不损失分辨率的前提下提升精细细节表现。(2) Grad Membre明确聚焦于高梯度区域，有效缓解了状态空间模型中的状态衰减问题，并优先重建清晰的边缘与边界。针对多个基准数据集及下游应用的大量实验表明，我们的方法在保持计算效率的同时显著提升了细节恢复性能。尤为重要的是，所提出的模块体积轻量，能够以极低的计算开销无缝集成到现有的基于傅里叶变换的框架中。

代码：<https://github.com/bywltzs/RFGM>

引言

在极暗条件下采集的图像常存在可见度低的问题，导致结构信息和细节信息大量丢失，从而限制了细粒度下游应用的性能（Xiao等人，2025；Yu等人，2025；Guo等人，2026）。传统的图像修复技术，如直方图均衡化（Pizer，1990）、Retinex理论（Guo、Li和Ling，2016）以及伽马校正（Rahman等人，2016），虽已被广泛研究，但仍面临诸多挑战。

*通讯作者

版权所有 © 2026，人工智能促进协会（www.aaai.org）。保留所有权利。



图1：在LOL-v1数据集上的文本检测性能对比。

这类模型在极端低光环境下表现不佳，且泛化能力有限，从而导致其性能下降。近年来，基于学习的方法（Zou等人，2024b；Weng等人，2025；Feijoo等人，2025）通过学习弱光与正常光照图像之间的映射关系，显著提升了图像重建质量和场景泛化能力。然而，这些方法主要侧重于全局亮度映射，难以有效保留细节特征；同时，其噪声控制能力有限，且架构复杂、参数量庞大，导致难以在性能与效率之间取得平衡。

为应对空间域方法固有的计算复杂性和参数效率挑战，频域方法（Wang、Wu和Zhi 2023；Li等人2023；Zhang等人2024；Feijoo等人2025；Cai等人2025；Zhang等人2025b；Zhao等人2025；Liu等人2025）已成为暗图像修复领域颇具前景的替代方案。虽然傅里叶域方法能在保持参数简洁的同时实现有效的全局信息建模，但这些方法通常依赖顺序简单卷积运算或引入不可靠的先验假设，从而导致频域信息冗余或丢失。此外，由于傅里叶域的全局建模特性，这些方法需采用额外的编码器-解码器结构来增强空间细节表征。然而，编码器-解码器架构难以捕捉精细结构与细节特征，且下采样过程必然会导致关键图像细节信息的丢失。

与此同时，Mamba（Gu和Dao 2023）基于暗色图像.....

年龄恢复方法（Zou 等人，2024a；Bai、Yin 和 He，2024；Weng 等人，2025）因其线性复杂度而备受关注，其中Mamba模型在平衡全局感受野与计算效率方面展现出巨大潜力。然而，这些方法采用固定的扫描规则对二维图像进行处理，生成一维标记序列，从而通过多次冗余扫描引入了数据冗余。此外，具有强关联特性的标记在序列中可能空间位置相距甚远（Guo 等人，2025b），这不仅削弱了标记间的建模能力，还限制了长距离依赖关系的建模效果。

基于这些关键局限性，我们提出了一种专为暗图像细节恢复设计的高效双阶段方法。该方法通过频域全局建模与空间域细节优化的协同结合，战略性地应对上述挑战。在**第一阶段**，我们引入了残差傅里叶引导模块（RFGM）。在傅里叶域中，振幅分量表征图像亮度，而相位分量则编码其结构细节。振幅恢复需要精确的振幅映射，而相位分量则需要稳健的自适应调整。因此，我们以残差方式利用阶段间和通道间的相关性，提供可靠的先验引导：将最优匹配的振幅分量作为残差傅里叶通道，为后续阶段的振幅映射提供先验指导；而相位分量则以残差方式为后续阶段提供额外的结构先验补偿。这种设计实现了对全局频域信息高效且稳健的恢复。在**第二阶段**，我们突破了单纯的光照处理，将重点转向精细细节的保留。为此，我们提出了协同工作的互补式双分支Mamba模块：Patch Mamba专注于像素级精细细节增强，而Grad Mamba则致力于结构纹理的重建。Patch Mamba作用于通道拼接且未经下采样的图像块，避免了编码-解码采样损失的缺陷，并通过精确建模像素级相关性来增强细节表现，既不牺牲分辨率也不增加计算负担。相比之下，Grad Mamba聚焦于高梯度区域，利用梯度分数预测来增强与梯度密切相关的标记间的交互作用。受MambaIRv2（Guo 等人，2025a）的启发，我们进一步将梯度预测分数与状态空间模型相结合，以缓解状态衰减问题，从而确保资源集中用于重建清晰的边缘和边界。

图1验证了我们方法在文本检测中的有效性，展示了其在极暗图像中恢复精细细节的能力。总体而言，我们的主要贡献如下：

- 我们提出了一种高效的暗图像修复框架，该框架专注于精细细节的保留。
- 我们提出了一种残差傅里叶引导模块（RFGM），该模块利用阶段间和通道间的相关性来增强先验引导能力，并缓解冗余和误差传播问题。

- 我们通过设计双分支模块克服了Mamba固有的局限性：Patch Mamba用于在不损失分辨率的情况下实现精细细节增强，而Grad Mamba则用于基于梯度驱动的结构边界重建。
- 大量实验表明，该方法在暗图像及下游任务（文本检测、边缘检测）的恢复质量方面均取得显著提升，同时仅需极低的计算开销，并与现有的基于傅里叶的方法保持兼容。

相关工作

基于频率的暗图像恢复方法。

频域处理方法（Wang、Wu 和 Zhi 2023；Huang 等人 2022；Feijoo 等人 2025）通过区分高频与低频信息、增强亮度同时降低噪声，已被证明具有显著效果。FourLLIE（Wang、Wu 和 Zhi 2023）利用傅里叶变换实现高效的全局特征提取，取代了SNR-Aware（Xu 等人 2022）中的Transformer模块，并大幅减少了参数数量。UHDFour（Li 等人 2023）通过利用不同分辨率下一致的振幅模式来提升超高清图像质量，但存在信息丢失的问题。DMFourLLIE（Zhang 等人 2024）通过引入红外先验信息增强频域信息，但未能充分考虑预训练模型的泛化局限性。基于小波的方法（如Wave-Mamba，Zou 等人 2024a）虽在超高清图像增强中应用了小波变换，但由于低频处理架构的复杂性而面临挑战（Jiang 等人 2023）。CWNet（Zhang 等人 2025a）结合因果学习与小波方法进行亮度恢复，但忽略了对图像细微差异的精细建模。

基于成员的暗图像恢复方法。

Mamba（Gu 和 Dao，2023）提出了具有选择性机制的输入依赖状态空间模型（SSMs），该模型已在超分辨率（Guo 等人，2025a）、分类（Xiao 等人，2024）和图像修复（Li 等人，2025）等多种任务中取得成功应用。在弱光增强领域，RetinexMamba（Bai、Yin 和 He，2024）结合Retinex理论提升了Mamba的效率；Wave-Mamba（Zou 等人，2024a）将Mamba与小波变换相结合；而MambaLLIE（Weng 等人，2025）则在状态空间模型中引入了隐式的Retinex感知机制。然而，这些方法仍未解决状态空间模型在二维应用中的局限性，从而阻碍了有效的标记建模。我们的研究不仅解决了状态空间模型的性能衰减问题，还开创性地实现了基于Mamba的像素级精细建模。

方法

概述

我们提出的两阶段方法的整体架构如图2所示。给定一张暗图像 $I \in \mathbb{R}^{H \times W \times 3}$ ，我们首先应用一个 3×3 卷积层来提取尺寸为 $\mathbb{R}^{H \times W \times C}$ 的浅层特征嵌入，其中 H 、 W 和 C 分别表示高度、宽度和通道维度。**第一阶段 - 频域**

通过快速傅里叶变换（FFT）转换至傅里叶域，得到幅度 A_{i-1} 和相位 P_{i-1} 分量。这些分量分别进行处理： A_{i-1} 和 P_{i-1} 经卷积运算后依次通过 ReLU 激活函数，分别得到 A_i 和 P_i 。对于幅度分量， A_{i-1} 和 A_i 均被展平为 $\mathbb{R}^{HW \times C}$ 形式，并进行矩阵相似度计算 $MS(\cdot, \cdot)$ ，得到相似度矩阵 $M \in \mathbb{R}^{C \times C}$ 。从 M 中选取 Top-1 向量 $V \in \mathbb{R}^{C \times 1}$ 作为对应于 A_{i-1} 与 A_i 之间最相似通道的索引。其目标是从 A_{i-1} 中亮度分布各异的通道中选取最可靠的亮度先验。随后，所选的先验信息通过 1×1 卷积运算进行扩展，并采用 Sigmoid 激活函数处理以生成先验引导 P_a 。接着，振幅 A_i 与 P_a 相乘，并与残差连接层相结合，从而完成前一阶段的先验引导融合。该过程可表述为：

$$\begin{aligned} M &= MS(A_{i-1}, A_i), \quad V = \text{Top-1}(M), \\ P_a &= \text{Sigmoid}(\text{Conv}(A_{i-1}[\text{Index}(V)])), \\ \tilde{A}_i &= A_i \times P_a + A_i. \end{aligned} \quad (1)$$

对于相位分量， P_{i-1} 与 P_i 沿通道维度进行拼接；其中前一阶段获得的相位信息起到结构补偿作用，并通过卷积层进行自适应融合。随后，经过 ReLU 激活函数和卷积运算，相位被恢复至原始尺度 $\sim P_i \in \mathbb{R}^{H \times W \times C}$ ：

$$\sim \pi = \text{卷积}(\text{拼接}(P_{i-1}, P_i)) + P_i) + \pi. \quad (2)$$

最后，经过处理的振幅 $\sim A_i$ 和相位 $\sim P_i$ 通过逆快速傅里叶变换（iFFT）进行组合，生成下一阶段的输出特征 F_i 。

第二阶段——空间域细节精炼动机分析。虽然频域光照恢复技术能有效解决暗图像中的低频亮度问题，但关键在于关注细粒度结构细节与边缘锐度的保留，而非仅限于光照调整。为此，我们提出了互补性的双分支 Mamba 模型，专门用于细粒度细节恢复。基于 Mamba 的恢复方法采用离散状态空间方程来建模标记之间的相互作用：

$$h_i = \bar{A}h_{i-1} + \bar{B}x_i, \quad y_i = Ch_i + Dx_i, \quad (3)$$

其中第 i 个标记完全取决于前序的 $i-1$ 个标记，从而在相邻像素之间建立了直接的因果关系。然而，这种扫描机制会破坏远距离特征之间的相关性，导致其在视觉任务中的效果较差。此外，因果建模可能会引发长程衰减效应，而多种固定方向扫描策略则会增加不必要的复杂性和信息冗余（Guo et al. 2025a）。

基于这些观察结果，我们并未受 Mamba 局限性的制约，而是反其道而行之：充分利用 Mamba 的独特特性，并将其转化为二维图像建模的优势。

Patch Mamba。图像细节体现在像素级别的变化与相关性中。然而，直接进行像素级操作会带来巨大的内存开销。虽然编码器-解码器架构能提升空间性能，但采样层不可避免地会丢失关键的像素级信息，这对精细细节的保留极为不利。由于我们主要关注相邻像素之间的关系，因此无需捕捉全局上下文依赖关系。Mamba 强大的扫描机制既能精准满足像素邻接要求，又能弱化远距离像素间的连接。然而，未经下采样的处理方式会增加计算负担并导致并行性能较差。因此，我们提出了 Patch Mamba——该模型在通道拼接的未下采样补丁上进行操作。如图2右上角所示，Patch Mamba 由两个残差块组成：第一个包含 LayerNorm 和 Patch SS2D，第二个包含 LayerNorm 和深度可分离卷积。

Patch SS2D 执行逐块选择性扫描。给定输入特征图 $F \in \mathbb{R}^{H \times W \times C}$ ，将其均匀划分为 (n, m) 个不重叠的块 $P_{i,j} \in \mathbb{R}^{h \times w \times C}$ ，其中 $h = \frac{H}{n}$ 且 $w = \frac{W}{m}$ 。这些补丁随后沿通道维度堆叠，形成 $\mathbb{R}^{h \times w \times n \cdot m \cdot C}$ 的结构，显著降低了扫描维度、减轻了计算负担，并提升了并行效率。需要注意的是，Patch SS2D 扫描策略涵盖了水平、垂直、对角线及其各自的反向方向，从而全面增强像素间相关性。扫描所有补丁后，结果会被重组为 $\mathbb{R}^{H \times W \times C}$ 以便后续处理。**Grad Mamba。**以往方法往往无法保留边缘锐度和纹理完整性，尤其是在梯度分布复杂的区域。为解决这一问题，我们提出了 Grad Mamba——一种梯度引导的状态空间模型，该模型明确针对高梯度区域，并优先重建清晰的边缘和边界。

如图2所示，Grad Mamba 基于编码器-解码器框架运行，与 Patch Mamba 形成互补。其整体结构与 Patch Mamba 相似。具体而言，给定输入特征 $F \in \mathbb{R}^{H \times W \times C}$ ，我们首先利用三个互补算子进行梯度分数预测：沿 x 和 y 方向的 Sobel 算子用于捕捉方向梯度，拉普拉斯算子用于检测边缘过渡。随后通过自适应归一化和可学习的缩放参数，将提取出的梯度幅度转换为优先级分数：

$$P_{grad} = \sigma\left(\frac{G_{mag} - G_{min}}{G_{max} - G_{min} + \epsilon} + \beta\right), \quad (4)$$

其中 $P_{grad} \in \mathbb{R}^{H \times W}$ 表示梯度优先级分数， β 为可学习的偏移参数， σ 表示 Sigmoid 函数， G_{min} 、 G_{max} 分别为每个样本的最小和最大梯度幅度。

根据梯度优先级分数 P_{grad} ，我们按照梯度重要性对标记进行排序，优先处理梯度较高的标记。这使得高梯度相关区域之间能够实现优先交互，同时避免长程衰减的限制。此外，受 MambaIRv2（Guo 等人，2025a）的启发，由于状态 C 在

方法	LOL-v1			LOL v2-Real			LOL-v2-Syn		
	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑	LPIPS ↓
Kind (张、张和郭, 2019)	20.87	0.7995	0.2071	20.01	0.8412	0.0813	22.62	0.9041	0.0515
MIRNet (Zamir等人, 2020)	24.14	0.8305	0.2502	22.11	0.7942	0.1448	22.52	0.8997	0.0568
Kind++ (Zhang等人, 2021)	18.97	0.8042	0.1756	20.59	0.8294	0.0875	21.17	0.8814	0.0678
具备信噪比感知功能 (Xu等人, 2022)	23.93	0.8460	0.0813	21.48	0.8478	0.0740	24.13	0.9269	0.0318
FourLLIE (王、吴和志, 2023)	20.99	0.8071	0.0952	22.34	0.8403	0.0573	24.65	0.9192	0.0389
UHDFour (Li等人, 2023)	22.89	0.8147	0.0934	19.42	0.7896	0.1151	23.64	0.8998	0.0341
Retinexformer (Cai等人, 2023年)	22.71	0.8177	0.0922	22.79	0.8397	0.0724	25.67	0.9295	0.0273
DMFourLLIE (张等人, 2024)	22.98	0.8273	0.0792	22.71	0.8583	0.0539	25.74	0.9308	0.0251
UHDFormer (Wang等人, 2024)	22.88	0.8370	0.1390	19.71	0.8320	0.0758	24.48	0.9277	0.0306
Wave-Mamba (Zou等人, 2024a)	22.76	0.8419	0.0791	20.35	0.8379	0.1908	24.69	0.9271	0.0584
RetinexMamba (白、尹和何, 2024)	23.15	0.8210	0.0876	21.73	0.8290	0.1164	25.89	0.9346	0.0389
MambaLLIE (Weng等人, 2025)	22.80	0.8315	0.0907	21.85	0.8276	0.1673	25.87	0.9400	0.0467
CWNet (张等人, 2025a)	23.60	0.8496	0.0648	23.31	0.8641	0.0532	25.74	0.9365	0.0241
CIDNet (Yan等人, 2025)	23.81	0.8574	0.0856	23.43	0.8622	0.1691	25.70	0.9419	0.0437
URetiexNet++ (Yan等人, 2025)	23.83	0.8390	0.2310	21.97	0.8360	0.2030	24.60	0.9270	0.1020
我们的	24.11	0.8517	0.0557	23.38	0.8662	0.0527	25.97	0.9408	0.0195

表1: 未使用真实标注数据的情况下, 对LOL-v1、LOL-v2-Real及LOL-v2-Syn (Yang等人, 2021) 数据集的定量比较真实含义。最佳结果和次佳结果分别用**粗体**和下划线标出。

方法	LSRW -华为		LSRW -尼康		效率	
	信号-噪音功率比	SSIM	信号-噪音功率比	SSIM	#参数	#浮点运算次数
善良的: 温和的	16.58	0.5690	11.52	0.3827	8.02	34.99
MIRNet	19.98	0.6085	17.10	0.5022	31.79	785.1
具备信噪比感知功能的	20.67	0.5911	17.54	0.4822	39.12	26.35
UHDFour	19.39	0.6006	17.94	0.5195	17.54	4.78
Retinexformer	21.23	0.6309	17.64	0.5082	1.61	15.57
Wave-Mamba	21.19	0.6391	17.34	0.5192	1.26	7.22
DMFourLLIE	21.47	0.6331	17.04	0.5274	0.75	5.81
Retinexmamba	20.88	0.6298	17.59	0.5133	3.59	34.76
CWNet	21.50	0.6397	17.38	0.5119	1.23	11.3
CIDNet	20.30	0.6054	17.16	0.4975	1.88	7.57
曼布利	20.98	0.6388	17.25	0.5084	2.28	20.85
我们的	21.59	0.6441	17.96	0.5342	0.37	4.39

表2: LSRW -Huawei与 LSRW -Nikon数据集的定量比较。

状态空间模型在注意力机制中与查询Q类似, 它具备类似注意力机制的能力, 能够关注图像中的高梯度区域, 从而使网络更专注于边缘信息和结构细节的重建。因此, 改进后的状态空间公式表述如下:

$$h_i = \bar{\mathbf{A}}h_{i-1} + \bar{\mathbf{B}}x_i, \quad y_i = (\mathbf{C} + \mathbf{G})h_i + \mathbf{D}x_i, \quad (5)$$

其中 $\mathbf{G} \in \mathbb{R}^{N \times D}$ 表示由 P_{grad} 导出的梯度引导矩阵, 其计算公式为:

$$\mathbf{G} = \text{线性}(P_{grad}) \cdot \mathbf{W}_{\mathbf{G}}, \quad (6)$$

其中 $\mathbf{W}_{\mathbf{G}}$ 是一个可学习的投影矩阵, 它将梯度分数转换到与输出投影矩阵 $\mathbf{C}$ 相同维度的空间中。在梯度较高的区域, 增强后的投影 $(\mathbf{C} + \mathbf{G})$ 会放大隐藏状态的贡献, 从而有效强化模型对边缘和结构信息的关注。通过这一机制, Grad Mamba能够在保持状态空间模型固

方法	PSNR ↑	SSIM ↑	LPIPS ↓
无/第一阶段	20.73	0.6331	0.1962
无/第二阶段	20.95	0.6387	0.1827
w/o RFGM	21.24	0.6374	0.1696
w/o 补丁 Mamba	21.54	0.6427	0.1612
无/毕业证书: 曼巴	21.21	0.6392	0.1831
完整模型	21.59	0.6441	0.1607

表3: 各组件的消融研究。

有的计算效率和序列建模能力的同时, 实现对结构细节的自适应增强。

实验

数据集与实验设置

数据集。我们在五个极端暗图像修复基准数据集上进行了全面实验: LOL-v1 (Yang等人, 2021) (485组训练集/15组测试集)、LOL-v2-Real (689组训练集/100组测试集)、LOL-v2-Syn (900组训练集/100组测试集)、LSRW -Huawei (Hai等人, 2023) (3,150组训练集/20组测试集) 以及 LSRW -Nikon (2,450组训练集/30组测试集)。这些数据集包含在极低光照条件下拍摄的严重欠曝图像, 对有效恢复视觉内容构成重大挑战。**实现细节。**我们的方法在 PyTorch 平台上实现了端到端。图像被随机裁剪至 256×256 分辨率, 并通过随机水平/垂直翻转和旋转进行增强。我们使用 ADAM 优化器, 参数设置为 $\beta_1=0.9$ 和 $\beta_2=0.99$, 初始学习率为 4.0×10^{-4} 。学习率调度采用 MultiStepLR 策略, 衰减步长为 5×10^4




图4：与最先进方法的视觉对比。从上至下分别为：LSRW -华为（第1行）、LSRW -尼康（第2行）2) LOL-v1（第3行）和LOL-v2-Real（第4-5行）数据集。

方法	信号/噪声功率比	SSIM	LPIPS	参数
FourLLIE（基线）	21.11	0.6256	0.1825	0.12
FourLLIE + RFGM	21.39	0.6425	0.1683	0.126
FourLLIE + RFGM + PatchSS2D	21.47	0.6433	0.1622	0.14
DMFourLLIE（基线）	21.47	0.6331	0.1781	0.75
DMFourLLIE + RFGM	<u>21.50</u>	<u>0.6408</u>	<u>0.1593</u>	0.756
DMFourLLIE + RFGM + PatchSS2D	21.52	0.6439	0.1492	0.77

表4：基于傅里叶方法的即插即用验证。

方法	UHDFour	FourLLIE	WaveMamba	曼布利	我们的
手艺	0.4103	0.4211	0.4390	0.3684	0.4500
PAN	0.1760	0.1290	0.1760	0.1880	0.2350

表5：文本检测方法H均值比较。

共进行 1×10^5 次迭代，衰减因子设为0.5。所有实验均在双NVIDIA RTX 4090 GPU（24GB显存）和Intel Core i9-14900 K处理器上完成，训练采用批量大小为8的参数设置，迭代次数为 2×10^5 次。实验采用 $\mathcal{L}_1$ 损失函数进行训练。

对比方法与评估指标。我们将本方法与多种 SOTA 方法进行对比，包括深度学习方法（Kind（Zhang、Zhang 和 Guo，2019）、Kind++（Zhang 等人，2021）、MIRNet（Zamir 等人，2020）、SNR-Aware（Xu 等人，2022）、CWNNet（Zhang 等人，2025a）、CIDNet（Yan 等人，2025）、URetiexNet++（Yan 等人，2025））、基于傅里叶的方法（FourLLIE（Wang、Wu 和 Zhi，2023）、UHD-Four（Li 等人，2023）、DMFourLLIE（Zhang 等人，2024））、基于Transformer的方法（Retinexformer（Cai 等人，2023）、UHDFormer（Wang 等人，2024））以及基于Mamba的方法（RetinexMamba（Bai、Yin 和 He，2024）、Wave-Mamba（Zou 等人，2024a）、MambaLLIE（Weng 等

人，2025））。所有方法均采用相同的公平性测试协议进行评估，以峰值信噪比（PSNR）、结构相似性指数（SSIM）（Wang 等人，2004）和学习感知图像块相似性（LPIPS）（Zhang 等人，2018）作为基准评估指标。

定量与定性结果

在LOL-v1、LOL-v2-Real和LOL-v2-Syn数据集上的对比结果。定量结果详见表1。在LOL-v1数据集上，我们的方法在保持竞争力的 SSIM 值的同时，取得了最高的 PSNR 和 LPIPS 值；在LOL-v2-Real数据集上，我们获得了第二高的 PSNR 值、最高的 SSIM 值以及最佳的 LPIPS 分数；在LOL-v2-Syn数据集上，我们的方法在所有评估指标上均表现最优。

LSRW -Huawei与 LSRW -Nikon数据集的对比。表2的结果表明，我们在两个数据集上均实现了最高的 PSNR 和 SSIM。**值得注意的是**，我们的方法计算效率极高，仅需**0.37**百万个参数和**4.34**吉次浮点运算。

视觉对比。图4展示了我们的方法在四个具有挑战性的极端暗色数据集上相较于最先进技术的有效性，凸显了其在恢复精细细节和保持极端暗条件下自然色彩平衡方面的卓越增强效果。

消融研究

组件消融实验。为评估所提出方法中各组件的贡献度，我们通过依次移除关键模块进行了消融实验。实验结果汇总于表3。移除第二阶段模块同样导致各项指标显著下降，这表明空间信息重建的重要性。每个组件对性能均具有可量化的影响，充分证明了本方法的稳健性。

组件计数与补丁SS2D效率验证。图5展示了组件计数的分析结果




图5：组件数量及Patch SS2D效率分析。图表展示了改变 RFGM、Patch Mamba和Patch SS2D数量对 PSNR 性能的影响。此外，效率分析还揭示了补丁数量、GPU 内存使用量与计算时间之间的关系。




图 6：故障案例示例。

Patch SS2D 模块的效率。图表展示了调整 RFGMs 数量、Patch Mamba 模块块数及 Patch SS2D 块数对 PSNR 性能的影响。具体而言，最左侧的图表表明六个 RFGMs 可获得最佳 PSNR 结果；第二张图表显示四个 Patch Mamba 模块块能有效平衡性能；第三张图表揭示 16 个 SS2D 块可使 PSNR 达到最大值。右下角图表的效率分析阐明了块数、GPU 内存占用量与计算时间之间的关系：当块数从 1 增加至 24 时，GPU 内存消耗和计算时间均显著下降。值得注意的是，使用 16 个块实现了最优平衡——计算时间缩短 47.7%（从 0.346 秒降至 0.181 秒），GPU 内存占用量减少 33.2%（从 9362MB 降至 6252MB）。**核心模块的即插即用效能。**RFGM 和 Patch SS2D 可无缝集成到现有基于傅里叶的方法中，且仅需极少额外参数。

表 4 显示，将我们的模块集成到 FourLLIE 和 DMFourLLIE 模型中后，性能得到显著提升，同时保持了高效率，从而验证了其有效性。**局限性。**通过对无监督数据集 DICM (Lee、Lee 和 Kim, 2012) 及 VV (Vonikakis、Kouskouridas 和 Gasteratos, 2018) 进行测试，我们发现本方法在抑制暴露效应方面表现欠佳，如图 6 所示。这一问题尤为明显——




图7：Canny边缘检测可视化效果。第一列展示输入图像及真实标注的RGB图像，随后呈现Canny边缘检测结果。我们还评估了省略第二阶段后的结果，证实该阶段对增强边缘细节具有重要作用。特别关注红色框标示区域的细节；放大后可获得更清晰的视觉对比度。与常难以保留精细细节的频域方法不同，我们采用双分支 Mamba 模型替换了 FourLLIE* 和 DMFourLLIE* 的第二阶段，验证了该方法在提升边缘清晰度方面的有效性。

面部及天空区域的齿状结构。

下游应用

边缘检测。为验证我们的方法在边缘检测方面的有效性，我们参考了图 7 所示的结果。增强版 Canny 边缘检测算法在保留精细节和清晰边界方面取得了显著提升，尤其是在用红色框标出的、展示复杂结构的区域。将这些结果与原始图像对比表明，我们的两阶段方法有效提升了边缘清晰度，成功恢复了在极暗条件下丢失的细节信息。

Text Detection.如表 5 所示，我们使用 Text-CP (Lin 等人, 2025)、craft (Baek 等人, 2019) 和 PAN (Wang 等人, 2019) 检测器对 LOL-Text 数据集进行了文本检测。H-Mean (即精确率与召回率的平均值) 表明我们的方法性能显著提升，这凸显了其在暗图像条件下有效提取细节的能力。

结论

在本研究中，我们提出了一种高效的两阶段方法，能够有效恢复极暗图像中的精细细节，显著提升了边缘和文本检测性能。该方法结合了残差傅里叶引导模块与互补的 Mamba 模块，显著增强了细节保留能力。展望未来，我们将进一步探索新的技术路径，不仅确保复杂细节的完整恢复，还能重建暗图像中的色彩语义一致性，从而全面提升图像质量并增强其在实际应用中的可用性。