

基于解混的丰度融合学习技术提升未注册高光谱图像的超分辨率

张英凯¹张涛²网妮¹范英^{1†}

¹北京理工大学²杭州电子科技大学 zhangyingkai@bit.edu.cn tzhang@hdu.edu.cn

cn{3420235028, fuying@bit.edu.cn}

摘要

未配准的高光谱图像 (HSI) 超分辨率 (SR) 技术通常旨在利用未配准的高分辨率参考图像来增强低分辨率 HSI 图像。本文提出了一种基于解混的融合框架，该框架通过解耦空间与光谱信息，同时减轻未配准融合带来的影响，并提升 SR 模型的学习能力。具体而言，我们首先采用奇异值分解进行初始光谱解混，在保留原始端元特征的同时，将后续网络专门用于优化初始丰度图。为充分利用未配准参考图像的空间纹理特征，我们引入了粗到细的可变形聚合模块：该模块首先使用粗金字塔预测器估算像素级流场和相似性图，随后进行亚像素级精细优化以实现参考特征的可变形聚合；聚合后的特征再通过一系列空间通道丰度交叉注意力模块进行进一步精炼。此外，本文还提出了一种空间通道调制融合模块，通过动态门控权重融合编码器与解码器特征，最终生成高质量、高分辨率的 HSI 图像。对模拟数据集和真实数据集的实验结果均表明，我们提出的方法实现了最先进的超分辨率性能。相关代码可访问 <https://github.com/yingkai-zhang/UAFI> 获取。

1. 引言

高光谱图像 (HSI) 提供了丰富的光谱信息，推动了多个领域的研究进展[33,38, 40]。然而，HSI 传感器通常面临空间分辨率与光谱分辨率之间的典型权衡关系：这类图像往往具有较高的光谱精度，但空间细节分辨率有限。因此，高光谱超分辨率 (SR) 已成为研究的重要方向。

单一 HSI 超分辨率方法[10, 26, 48]已展现出一定有效性，但其本质受限于单个输入中可获取的有限信

†通讯作者。




图1. 性能 (PSNR)、计算成本 (FLOPs) 和内存成本 (Params) 的对比。纵轴表示 PSNR (dB)，横轴表示 FLOPs。每个气泡的大小对应参数数量。

息。因此，基于参考图像的配准式 HSI 超分辨率方法 [28, 29] 受到越来越多的关注——该方法利用辅助的高分辨率 (HR) 参考图像来提升低分辨率 (LR) HSI 的空间分辨率。尽管这种方法效果显著，但其局限性在于必须假设 LR HSI 与 HR 参考图像完全对齐。在实际应用中，这种情况很少出现，因为平台振动、透视偏移或传感器采集时间差异都会不可避免地导致图像错位[47]。这一挑战促使了非配准式 HSI 超分辨率方法[19, 55]的开发，这些方法旨在联合实现图像对齐与融合。

部分研究[19, 52]通常采用两阶段流程：先使用预训练模块（例如 RAFT[39]）显式对齐参考图像，随后再通过空间-光谱耦合网络进行融合。然而，这些方法存在两大主要挑战。**首先**，对空间-光谱耦合融合的依赖限制了网络的学习能力（图1）；**其次**，显式对齐步骤常因固有的视差而引入纹理失真和伪影（图2 (a-c)）。




图2. 动机。(c) SSCH[52]内的显式对齐容易在变形图像中引入空间畸变和纹理伪影。(d)该结果验证了以下原理：利用对齐良好、高保真的丰度数据，可以从低分辨率对应图像重建高分辨率高光谱图像（HSI）。

分辨率和数据分布。

HSI固有的低秩特性[23, 35]源于其强烈的光谱相关性，这是图像恢复任务[12, 43]的基石，并支撑着光谱解混技术[13]。正如[8]所述，基于解混的方法[1, 18]对几何错位具有鲁棒性，而其他方法[5, 6]则更为敏感，需依赖对齐约束。受此启发，我们在图2(d)中对未配准的HSI超分辨率图像的光谱解混进行了分析。可以看出，将低分辨率HSI端元与结构清晰的高分辨率丰度数据结合使用能获得更优结果；相比之下，直接使用未配准参考图像进行混合虽能生成视觉上合理的图像，但由于实际存在错位问题，其定量性能较差。这种解耦策略将复杂问题转化为更具体的学习目标，从而简化了网络的优化过程。

在本文中，我们提出了一种基于解混的融合框架，该框架利用可变形聚合和空间通道调制融合技术来指导高光谱成像（HSI）超分辨率重建。具体而言，我们的方法将任务从直接融合空间-光谱特征转变为学习残差丰度图。首先，我们采用奇异值分解将HSI数据分解为端元和丰度信息，并通过未配准的参考图像进一步增强这些特征。接着，我们设计了一个从粗到细的可变形模块：该模块首先使用粗金字塔预测器估计像素级流图和相似性图，随后通过可变形卷积进行亚像素级精细优化，从而实现参考特征的有效聚合；最终，通过空间通道丰度交叉注意力机制对生成的特征进行

精细化处理，以提升其表征能力。此外，解码器中的空间通道调制融合模块会生成动态门控权重，以最优方式融合编码器与解码器的特征，确保对空间细节和光谱特征都能实现高保真重建。本研究的主要贡献总结如下：

- 我们提出了一种基于解混的技术框架，用于未配准的高光谱图像超分辨率（HSI SR）处理。该框架通过解耦空间信息与光谱信息，有效减轻了未配准融合带来的影响，并提升了超分辨率模型的学习能力。
- 我们提出了一种粗到细的可变形聚合模块，该模块采用空间通道丰度交叉注意力机制，能够实现鲁棒的特征聚合并提升表征能力。
- 我们设计了一种空间通道调制融合模块，该模块可生成动态门控权重，以动态融合编码器-解码器特征。这确保了最终高光谱图像（HSI）中精细空间细节与光谱特征均能实现高保真重建。

2. 相关工作

在本节中，我们综述了基于参考图像的超分辨率技术，包括配准后的HSI超分辨率与未配准的HSI超分辨率。

2.1. 注册的 HSI 超分辨率

注册式HSI超分辨率（SR）技术利用高分辨率（HR）参考图像来提供空间细节。大多数此类方法都严格假设低分辨率（LR）HSI图像与HR参考图像实现了完美配准。其中一条研究方向专注于采用手工设计先验知识的优化技术[1, 2, 13, 18, 20, 57]。尽管这些方法在一定程度上能够抵抗几何错位的影响，但由于依赖预设的先验知识，它们在处理复杂的现实场景时仍存在局限性。

近年来，包括卷积神经网络（CNN）和Transformer在内的多种深度学习方法已被提出[4, 11, 21, 22, 41, 42, 49–54]。另一条研究路径基于这些方法[7, 14–16, 27, 29, 50]，直接从数据中学习低分辨率高光谱图像（LSHSI）与高分辨率参考图像之间的映射关系，从而无需依赖人工设计的先验知识。然而，这些方法的性能取决于数据完全对齐的假设。这一理想化条件在现实场景中难以满足，严重削弱了这些配准融合方法的实际应用价值。

2.2. 未注册的 HSI 超分辨率

为降低对严格对齐先验的依赖并提升实际应用性，部分研究开始探索未配准的HSI超分辨率技术[8, 32, 37, 47, 55, 56]。这些方法通常基于模拟生成的未配准数据进行训练。




图3. 整体架构。我们采用基于解混机制的多尺度编码器-解码器架构，包含以下关键模块：(a) 粗细可变形聚合模块，(b) 空间通道丰度交叉注意力模块，以及(c) 空间通道调制融合模块，用于实现高质量高分辨率高光谱图像的超分辨率重建。

通过刚性或非刚性变换实现。主流策略采用两阶段流程：首先估计显式变换，然后将其应用。例如，某些方法通过优化[8]、空间变换器网络[32]或光流模型[19]来实现刚性或非刚性变换。Zhang等人[52]首先使用预训练的流模型，然后在后处理融合网络中对特征进行微调。现有主流方法存在以下局限：显式预对齐常会引入纹理伪影；而集成方法[36, 55]则受到耦合空间-光谱数据所施加的学习约束限制。因此，我们提出一种基于解混的融合网络，该网络通过隐式聚合特征，并辅以交叉注意力机制和调制融合技术，以减轻未配准融合带来的影响，并提升特征表征能力。

3. 基于解混的融合框架

在本节中，我们首先在3.1部分介绍本框架的提出动机与框架设计；随后在3.2、3.3和3.4部分详细阐述各关键模块的具体内容。

3.1. 动机与总体框架

动机。基于高分辨率图像（HSI）固有的低秩特性[8, 13, 35, 45]，光谱解混能够减轻未配准融合带来的不利影响，如文献[8]所述。受此启发，如图2(d)所示，我们对高分辨率HSI、低分辨率HSI以及高分辨率未配准RGB进行了解混分析。矩阵与张量分别定义为 $\mathbf{X}$ 和 $\mathbf{X}$ 。通过将低分辨率HSI的端元与高分辨率源的丰度信

息进行融合，可重建出高质量的HSI，即混合运算 $(\mathbf{E}_{lrhsi}, \mathbf{A}_{hrhsi})$ 。这使我们能够将融合任务从在复杂的耦合空间-光谱域中学习，转变为一个更易处理的问题：学习如何增强解耦后的丰度图。虽然参考RGB图像能为这些丰度提供必要的空间结构，但即使视觉上显得清晰， $\mathbf{E}_{lrhsi}$ 与 $\mathbf{I}_{hrrgb}$ 直接混合的方法由于实际对齐偏差，在定量上表现较差（图2(d)）。因此，为了有效聚合未配准的参考特征，我们提出了一种从粗到细的可变形聚合模块。该模块通过作用于深度特征而非像素，结合交叉注意力块，能够学习出稳健且清晰的特征表示，并更有效地利用未配准的参考信息来指导丰度图的增强。

我们框架的架构如图3所示。给定一个低分辨率HSI $\mathbf{X} \in \mathbb{R}^{h \times w \times B}$ 和一个未配准的高分辨率RGB $\mathbf{I} \in \mathbb{R}^{H \times W \times b}$ ，我们的目标是重建一个高分辨率HSI $\mathbf{Y} \in \mathbb{R}^{H \times W \times B}$ ，其中 H 、 W 和 B 分别表示高分辨率的高度、宽度和光谱波段数量。**解混。**为初始化解混过程，我们首先将低分辨率HSI $\mathbf{X}$ 上采样至目标空间维度，即 $\mathbf{X}_{\uparrow} \in \mathbb{R}^{H \times W \times B}$ 。随后，我们应用奇异值分解来解耦 $\mathbf{X}_{\uparrow}$ ，即 $\mathbf{X}_{\uparrow} = \mathbf{U}\mathbf{S}\mathbf{V}^T$ ，其中 $\mathbf{U} \in \mathbb{R}^{B \times B}$ 、 $\mathbf{S} \in \mathbb{R}^{B \times HW}$ 、 $\mathbf{V} \in \mathbb{R}^{HW \times HW}$ ，而 $\mathbf{X}_{\uparrow}$ 表示 $\mathbf{X}$ 被重塑为 $\mathbb{R}^{B \times HW}$ 。预估计的末端成员矩阵 $\mathbf{E} \in \mathbb{R}^{B \times K}$ 是通过从 $\mathbf{U}$ 中提取前 K 个左奇异向量构成的，其中 K 为末端成员的数量。丰度矩阵 $\mathbf{A} \in \mathbb{R}^{K \times HW}$ 可通过以下方式获得：

$$\mathbf{A} = \mathbf{E}^T \mathbf{X}_{\uparrow}, \quad (1)$$

其中 $\mathbf{A}$ 为初始丰度图，随后将其重塑为 $\mathbf{A} \in \mathbb{R}^{H \times W \times K}$ ，以便后续利用未注册的参考图 I 学习残差丰度图：

$$\hat{\mathbf{A}} = f(\mathbf{A}, \mathcal{I}(\theta)), \quad (2)$$

其中 $\mathbf{A}$ 为学习得到的残差丰度图， $f(\cdot | \theta)$ 表示我们的网络模型， θ 代表可学习参数。

混合。随后，我们通过 $\hat{\cdot}$ 重建剩余的HSI分量。与初始末端成员 $\mathbf{E}$ 混合 $\mathbf{A}$ ：

$$\mathbf{Y}_{res} = \hat{\mathbf{E}} + \mathbf{A}, \quad (3)$$

其中 $\mathbf{A} \in \mathbb{R}^{K \times HW}$ ，且 $\mathbf{Y}_{res} \in \mathbb{R}^{B \times HW}$ 。超分辨率高分率HSI $\mathbf{Y}$ 是通过将该学习得到的残差分量添加到初始上采样的HSI中获得的：

$$\mathbf{Y} = \mathcal{Y}_{res} + \mathcal{X}_{\uparrow}, \quad (4)$$

其中 $\mathcal{Y}_{res}$ 表示 $\mathbf{Y}_{res}$ 已被重塑为 $\mathbb{R}^{H \times W \times B}$ 的形状。

3.2. 从粗到细的可变形聚集

为有效利用未注册参考图像 I 中的空间信息以增强初始丰度图 $\mathbf{A}$ ，我们引入了粗到细可变形聚合（CFDA）模块（图3（a））。该模块的核心是基于动态预测先验流场引导的可变形卷积，该流场会逐步细化。我们首先从初始丰度图和参考图像中分别提取深度特征，记为 $\mathbf{F} \in \mathbb{R}^{H \times W \times C}$ 和 $\mathcal{F}_{ref} \in \mathbb{R}^{H \times W \times C}$ 。**粗金字塔流预测器：**在初始粗运动估计阶段，我们采用轻量级金字塔预测器计算初步流场。特征 $\mathbf{F}$ 和参考特征 $\mathcal{F}_{ref}$ 首先被下采样为 $\mathbf{F}_{\downarrow}$ 和 $\mathcal{F}_{ref\downarrow}$ ，随后通过卷积层预测低分辨率流场。该流场随后被上采样至原始分辨率，作为粗运动先验：

$$\mathcal{C}_{flow} = \text{Up}(\text{Conv}_{3 \times 3}(\mathbf{F}_{\downarrow}, \mathcal{F}_{ref\downarrow})), \quad (5)$$

其中 $\text{Up}(\cdot)$ 表示双线性上采样， $\text{Conv}_{3 \times 3}(\cdot, \cdot)$ 表示使用核尺寸为 3×3 的卷积运算以拼接输入。随后， $\mathcal{F}_{ref}$ 通过该粗流进行变形处理。变形后的特征随后与 $\mathbf{F}$ 拼接，并输入另一个卷积层以预测残差流 $\Delta \mathcal{C}_{flow}$ 和相似性图 $\mathbf{F}'_{sim}$ 。最终的先验流 $\mathcal{F}_{flow} \in \mathbb{R}^{H \times W \times 2}$ 是粗流与残差分量的叠加结果；而先验相似性图 $\mathcal{F}_{sim} \in \mathbb{R}^{H \times W \times 1}$ 通过应用sigmoid函数获得，用于指示高置信度区域：

$$\begin{aligned} \mathcal{F}_{flow} &= \mathcal{C}_{flow} + \Delta \mathcal{C}_{flow}, \\ \mathcal{F}_{sim} &= \text{Sigmoid}(\mathbf{F}'_{sim}). \end{aligned} \quad (6)$$

细粒度亚像素细化。预测的流场仅提供粗略位移信息，缺乏细粒度精度。为进一步提升精度，并受[44]研究启

发，我们对亚像素位移进行编码，提供详细的先验信息，使网络能够在每个采样位置捕捉精细的局部细节。首先提取流场 $\mathcal{F}_{flow}$ 的十进制分量 $\mathbf{d}_f \in \mathbb{R}^{H \times W \times 2}$ 。我们遵循先前研究[31, 44]的方法，采用频率位置编码：

$$\gamma(\mathbf{d}_f) = [\omega \mathbf{d}_f, \omega^2 \mathbf{d}_f, \dots, \omega^{N-1} \mathbf{d}_f], \quad (7)$$

其中， $\gamma(\mathbf{d}_f) \in \mathbb{R}^{H \times W \times 2N}$ ； (f) 表示角速度， N 表示频带数量。随后我们得到一个高维特征位置编码 $\mathcal{F}_{pe} \in \mathbb{R}^{H \times W \times 4N}$ ，该编码通过拼接一系列具有不同频率的正弦和余弦函数，实现了细粒度的亚像素位置信息表示：

$$\mathcal{F}_{pe} = \text{Concat}[\text{Sin}(\gamma(\mathbf{d}_f)), \text{Cos}(\gamma(\mathbf{d}_f))]. \quad (8)$$

随后，精炼网络将目标特征、变形参考特征及位置特征进行拼接，以预测残差偏移量和掩码：

$$\Delta \mathbf{P} = f_{re}(\text{Concat}[\mathbf{F}, \text{Warp}(\mathcal{F}_{ref}, \mathcal{F}_{flow}), \mathcal{F}_{pe}]), \quad (9)$$

其中 $\text{Warp}(\cdot)$ 表示扭曲操作。 $\Delta \mathbf{P}$ 可分解为 $\Delta \mathcal{P}_o$ 和 $\Delta \mathcal{P}_m$ ，它们对先前的粗流进行细粒度修正。可变形区域的最终偏移量 $\mathcal{O}$ 和调制掩模 $\mathbf{M}$ 可通过以下公式计算：

$$\begin{aligned} \mathcal{O} &= \mathcal{F}_{flow} + \text{Tanh}(\Delta \mathcal{P}_o), \quad (10) \\ \mathbf{M} &= \text{Sigmoid}(\mathcal{F}_{sim} \odot \Delta \mathcal{P}_m), \end{aligned}$$

其中 $\odot$ 表示逐元素乘法。最后，

聚合参考特征 $\mathcal{F}_{ref}$ 是通过使用偏移量 $\mathcal{O}$ 和掩模 $\mathbf{M}$ ，对原始参考特征 $\mathcal{F}_{ref}$ 应用调制变形卷积运算而获得的。

3.3. 空间-通道丰度交叉注意力机制

在从CFDA模块获取聚合特征后，我们引入了空间-通道丰度交叉注意力（SCACA）模块以进一步优化丰度图特征，如图3（b）所示。

我们首先通过一个轻量级自调制网络来调节聚合参考特征 $\mathcal{F}_{ref}$ ：

$$\mathcal{F}_{refm} = \mathcal{F}_{ref} + \mathcal{F}_{ref} \odot \text{Sigmoid}(\text{Conv}_{5 \times 5}(\mathcal{F}_{ref})), \quad (11)$$

其中 $\text{Conv}_{5 \times 5}$ 表示 5×5 的深度卷积操作。受[46]的研究启发，我们随后采用分层交叉注意力机制（依次进行空间交叉注意力和通道交叉注意力），以还原细节的精细特征。

空间丰度交叉注意力机制（SACA）。为增强丰度图的空间结构，我们采用基于窗口的交叉注意力机制。丰度特征 $\mathbf{F}$ 首先经过LayerNorm（LN）层处理，随后进行交互作用。

通过交叉注意力模块对调制后的聚合参考特征 $\mathcal{F}_{refm}$ 进行处理:

$$F' = F + \text{FFN}(\text{SACA}(\text{LN}(F), \hat{F}_{refm})), \quad (12)$$

其中 $\text{FFN}(\cdot)$ 包含多个卷积层和 GELU 个激活层。对于注意力块,输入丰度特征 Z 首先经过窗口划分操作,得到 $Z_w \in \mathbb{R}^{M \times M \times C}$,其中 M 为窗口大小。类似地, $\hat{F}_{refm}$ 被划分为不重叠的片段, $\hat{F}_{refw}$ 其中单个补丁为 $\mathcal{F}_{refw} \in \mathbb{R}^{M \times M \times C}$ 。因此,查询矩阵(Q)、键矩阵(K)和值矩阵(V)均源自 Z_w 。交叉注意力机制通过在最终注意力聚合前使用参考特征对值向量进行调制来实现。窗口内的核心操作可概括为:

$$\begin{aligned} V_{mod} &= V \odot \text{Reshape}(\hat{F}_{refw}), \\ \hat{Z} &= \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + B\right)V_{mod}, \end{aligned} \quad (13)$$

其中 B 是可学习的相对位置偏置。这使得模型能够利用参考特征的结构信息来指导丰度图的细化,从而学习精细的空间对应关系。**通道丰度交叉注意力(CA-CA)**。作为空间注意力的补充,CACA模块专注于优化丰度图的通道级特征,动态增强显著的光谱特征同时减弱无关特征。与空间注意力类似, Q 、 K 和 V 矩阵均源自中间丰度特征 F' 。通道交叉注意力通过调节价值向量来实现:

$$V_{mod} = \hat{V} \odot \mathcal{F}_{refm}. \quad (14)$$

该操作根据聚合参考特征的通道特性,自适应地重新校准丰度特征的通道响应。通过结合这两种机制,SCACA模块能有效融合多模态信息,从而生成更精细的丰度图。

3.4. 空间-信道调制融合技术

为有效融合编码器-解码器架构中的层级特征并确保高保真重建效果,我们提出了一种空间通道调制融合(SCMF)模块。该模块旨在自适应地融合解码器阶段 $\mathcal{F}_{dec}$ 的特征与编码器阶段 $\mathcal{F}_{enc}$ 的对应特征。其核心原理是将融合过程解耦为两条并行且互补的路径:一条专注于空间调制,另一条专注于通道调制。首先将两个特征 $\mathcal{F}_{enc}$ 和 $\mathcal{F}_{dec}$ 沿通道维度拼接形成统一特征图 $\mathcal{F}_{cat}$,该特征图作为调制融合的输入。

空间调制。该调制方法旨在根据局部上下文增强或抑制空间细节。它由空间值分支和空间门控分支组成。值分支包含深度卷积层和 Leaky ReLU 激活函数,用于处理拼接后的特征以生成空间丰富的表征 V_{spa} ;与此同时,空间门控分支生成像素级门控权重 W_{spa} 。该权重通过卷积运算后接 Sigmoid 激活函数生成,可为每个空间位置分配重要性权重:

$$M_{spa} = \text{Sigmoid}(\text{Conv}_{3 \times 3}(\mathcal{F}_{cat})). \quad (15)$$

该调制的输出是数值与门控权重的逐元素乘积: $\mathcal{F}_{spa} = V_{spa} \odot M_{spa}$,其中 M_{spa} 会在通道维度上进行广播。**通道调制。**作为空间调制的补充,通道调制专注于自适应地重新校准通道级特征响应。它同样包含通道值分支和通道门控分支:值分支通过 1×1 卷积生成通道混合表示 V_{spe} ;通道门控分支首先使用全局平均池化(GAP)将全局空间信息聚合为通道描述符,随后该描述符经 1×1 卷积计算通道级注意力权重,并通过 Sigmoid 函数进行归一化:

$$M_{spe} = \text{Sigmoid}(\text{Conv}_{1 \times 1}(\text{GAP}(\mathcal{F}_{cat}))). \quad (16)$$

生成的注意力向量 $M_{spe} \in \mathbb{R}^{1 \times 1 \times C}$ 用于调制通道值特征,从而得到输出 $\mathcal{F}_{spe} = V_{spe} \odot M_{spe}$ 。

为了在融合过程中动态平衡空间信息与通道信息的贡献,从而获得更稳健、更高保真的重建结果,两种调制方式的输出通过逐元素相加进行融合。此外,为确保训练稳定性并保留解码器流的信息,该融合结果通过残差连接被添加到原始解码器特征 $\mathcal{F}_{dec}$ 中:

$$\hat{\mathcal{F}}_{dec} = (\mathcal{F}_{spa} + \mathcal{F}_{spe}) + \mathcal{F}_{dec}. \quad (17)$$

4. 实验

在本节中,我们首先介绍实验设置。随后,我们在模拟数据和真实数据上将我们的方法与若干最先进的方法进行比较。此外,我们还进行了消融实验以验证各模块的有效性。

4.1. 实验设置

数据集与指标。我们使用了两个不同的数据集:ICVL[3]和REAL[19]。ICVL数据集包含201对图像,分辨率为 1300×1392 ;




图4. 在模拟数据集（ICVL[3]）上的可视化对比。展示了基准真实值和输入的高光谱图像（HSI），其中显示了第20波段数据。图中呈现了不同方法在缩放因子（ $\times 4$ ）条件下对 ICVL 数据集的处理结果及误差图。

在实验中，图像被中心点裁剪至512尺寸。RGB参考图像通过尼康D700的光谱响应函数生成[2]。通过调整虚拟相机的姿态来控制新视角的生成，从而实现图像错位[25, 52]。REAL数据集包含60对未配准的HSI图像，涵盖室内外场景，均由配备SOC710-VP高光谱相机的双摄像头系统采集。参照[49, 52]的研究方法，我们在ICVL数据集中选取20对图像用于测试、其余用于训练；在REAL数据集中选取10对图像用于测试、其余用于训练。为评估性能，我们采用三项指标： β 峰值信噪比（PSNR）、结构相似性指数（SSIM）和光谱角度映射（SAM）。**实现细节：**遵循[52]的研究方法，我们使用高斯核（ $\mu=8, \sigma=3$ ）对HSI图像进行模糊处理，并通过缩放因子（例如， $\times 4$ 、 $\times 8$ 、 $\times 16$ ）进行下采样，以获得低分辨率HSI图像。我们使用Pytorch[34]开发了该模型，批量大小为1，并在单块Nvidia RTX 4090 GPU上进行训练。模型采用AdamW[30]优化器进行训练，权重衰减率为 5×10^{-5} ，学习率为 1×10^{-4} ，在ICVL数据集上训练150个周期，在REAL数据集上训练300个周期，以最小化 L_1 损失函数。所有方法均采用与本研究相同的训练参数设置，以确保公平比较。

4.2. 主要结果

竞争方法。我们将所提出的方法与若干最先进的（SOTA）超分辨率方法进行比较，包括单通道HSI超分辨率方法（SSPSR[17]、MCNet[24]、BiQRNN[9]和ESSA[48]）以及基于参考图像的HSI超分辨率方法（Optimized[7]、NonReg[55]、MoE-PNP[36]、HSIFN[19]、LRTN[28]、SRLF[29]和SSCH[52]）。**模拟数据集上的结果。**表1展示了在 $\times 4$ 缩放因子下对模拟ICVL数据集的定量比较。如表所示，我们的模型实现了41.84 dB的领先PSNR值和0.025的领先SAM值，证明了其在恢复空间去

表1. 在缩放因子 $\times 4$ 条件下进行的定量比较
模拟数据集，ICVL[3]。PSNR 单位为分贝（dB）。最佳结果和次佳结果分别以**粗体**和下划线标出。

方法	发生地	PSNR $\uparrow$	SSIM $\uparrow$	SAM $\downarrow$
双三次的	-	35.33	0.960	0.028
SSPSR [17]	TCI '20	40.19	0.982	0.033
MCNet [24]	RS '20	39.90	0.980	0.033
BiQRNN [9]	JSTAR '21	37.85	0.974	0.039
ESSA [48]	ICCV '23	38.41	0.977	0.057
优化后的[7]	CVPR '19	25.35	0.801	0.026
NonReg [55]	TGRS '22	33.47	0.949	0.131
MoE-PNP [36]	TNNLS '24	33.97	0.957	0.074
HSIFN [19]	TNNLS '24	41.14	0.983	0.041
LRTN [28]	IJCV '25	37.58	0.975	0.061
SRLF [29]	CVPR '25	38.75	0.977	0.041
SSCH-S [52]	IJCV '25	41.38	0.987	0.031
我们的	-	41.84	<u>0.986</u>	0.025

在尾部特征和光谱特征方面，该性能优于近期方法（包括SSCH-S[52]和HSIFN[19]），充分证明了我们提出方法的优势。

如图4所示，误差图展示了每个输出结果与真实值之间的绝对像素级差异。从视觉上可以明显看出，我们提出的方法相比所有竞争方法均实现了显著更低的误差。NonReg[55]和MoEPNP[36]等方法存在较大误差，而即使是近期的 SOTA 方法（如 HSIFN[19]和 SSCH-S[52]）在锐利边缘处也表现出明显的高误差模式。相比之下，我们方法的误差图呈现近乎深蓝色，证明了其能够准确恢复整体结构与高频细节。关于其他因素的更多细节详见补充材料。**真实数据集上的结果。**表2展示了在现实世界数据集REAL上针对 $\times 4$ 、 $\times 8$ 和 $\times 16$ 等不同缩放比例的全面定量比较。我们的方法在所有尺度和评估指标上均持续优于所有先前方法。值得注意的是，在最具挑战性的 $\times 16$ 尺度下，

表2. 在真实数据集REAL[19]上，不同方法在多种尺度因子下的定量比较。PSNR 单位为分贝（dB）。最佳结果见表中。而第二佳结果分别用**粗体**和下划线标出。

方法	发生地	缩放因子× 4			缩放因子× 8			缩放因子× 16			参数 (M)	浮点运算次数 (G)
		PSNR↑	SSIM↑	SAM↓	PSNR↑	SSIM↑	SAM↓	PSNR↑	SSIM↑	SAM↓		
双三次的	-	34.07	0.941	0.042	28.43	0.870	0.058	24.84	0.815	0.086	-	-
SSPSR [17]	TCI '20	39.04	0.976	0.040	31.13	0.906	0.069	27.20	0.851	<u>0.077</u>	20.82	180.40
MCNet [24]	RS '20	39.07	0.974	0.038	31.31	0.904	0.063	27.04	0.845	0.088	2.20	280.30
BiQRNN [9]	JSTAR '21	37.80	0.969	0.044	31.66	0.908	0.060	26.53	0.832	0.111	1.30	468.70
ESSA [48]	ICCV '23	39.94	0.982	0.040	31.85	0.913	0.064	26.70	0.918	0.111	11.10	78.14
优化后的[7]	CVPR '19	27.26	0.916	0.189	26.99	0.909	0.195	26.93	0.912	0.220	0.20	14.17
NonReg [55]	TGRS '22	31.60	0.951	0.081	30.00	0.923	0.167	29.09	0.904	0.584	2.00	161.61
MoE-PNP [36]	TNNLS '24	32.57	0.951	0.101	31.12	0.946	0.119	29.91	0.934	0.121	44.67	3040.81
HSIFN [19]	TNNLS '24	40.15	0.982	0.037	34.39	0.953	0.052	30.07	0.939	0.100	21.01	594.10
LRTN [28]	IJCVC '25	38.62	0.978	0.054	34.79	0.957	<u>0.066</u>	31.41	0.937	0.081	3.79	33.15
SRLF [29]	CVPR '25	39.06	0.978	0.043	34.63	0.953	0.064	31.12	0.929	0.091	1.33	20.31
SSCH-S [52]	IJCVC '25	41.16	0.986	<u>0.036</u>	36.19	0.969	0.052	31.91	0.940	0.084	11.01	165.68
我们的	-	42.05	0.988	0.033	37.23	0.972	0.046	32.28	0.942	0.065	5.94	96.17




图5. 在真实数据集REAL[19]上的可视化对比。展示了基准真实值及输入的高光谱图像（HSI），其中包含第20波段数据。图中呈现了不同方法在REAL数据集上使用缩放因子（× 4、× 8）时的结果及误差图。

我们的模型实现了32.28 dB的PSNR值，比第二佳方法SSCH-S[52]高出0.37 dB。这种优异性能的优势在× 8和× 4缩放比例下依然保持——相较于第二佳方法，我们分别实现了1.04 dB和0.89 dB的PSNR增益，充分证明了本方法在实际应用场景中的稳健性和有效性。此外，我们的模型以更高的计算效率实现了这一领先性能：仅需594万个参数和961.7亿次浮点运算，参数量约为SSCH-S的一半，运算量减少42%。这凸显了我们

在超分辨率精度与计算效率之间取得的卓越平衡。

如图5所示，我们的方法在多种缩放因子（× 4和× 8）下均能持续实现更优的视觉重建质量。这表明该方法能更准确地恢复具有挑战性的高频细节（如建筑线条和锐利物体边缘），而其他方法往往会产生残留伪影，进一步验证了我们所提出框架的实际有效性。更多可视化结果详见补充材料。

表3. 所提组件的消融研究。在REAL数据集上、缩放因子 $\times 4$ 条件下的结果。

Unmix SCACA CFDA SCMF				PSNR $\uparrow$ SSIM $\uparrow$ SAM $\downarrow$ Params			
X	X	X	X	41.26	0.984	0.036	5.08M
✓	X	X	X	41.41	0.986	0.034	5.05M
✓	✓	X	X	41.66	0.987	0.034	4.85M
✓	✓	✓	X	41.95	0.988	0.033	5.85M
✓	✓	✓	✓	42.05	0.988	0.033	5.94M

表4. CFDA 模块的消融研究。在放大倍数 $\times 4$ 的REAL数据集上的实验结果。

方法	PSNR $\uparrow$	SSIM $\uparrow$	SAM $\downarrow$	参数
无聚合	41.66	0.987	0.034	4.85M
w/ DCNv2 [58]	41.80	0.987	0.033	5.78M
w/ CFDA	41.95	0.988	0.033	5.85M

4.3. 消融研究

我们开展了一系列消融实验，以验证所提出的组件的有效性。除非另有说明，所有消融实验均在REAL数据集上以 $\times 4$ 的缩放因子进行。超参数分析结果详见补充材料。

如表3所示，我们将核心模块逐步添加到采用自注意力架构的基线模型中。**Unmix**策略的引入奠定了坚实基础（PSNR 达到 41.41 dB，SAM 达到 0.036）。随后，集成用于特征精炼的**SCACA**模块和用于聚合的**CFDA**模块，分别将 PSNR 提升至 41.66 dB 和 41.95 dB，这凸显了稳健特征聚合与精炼的重要性。最后加入**SCMF**模块后，性能进一步提升至 42.05 dB。这些改进验证了各组件对最终HSI的贡献效果。**CFDA 模块的作用**。表4专门分析了我们提出的聚合模块的贡献：与未使用聚合的基线模型（41.66 dB）相比，通用DCNv2[58]将 PSNR 提升至41.85 dB；而我们提出的 CFDA 模块则进一步将性能提升至41.95 dB。此外，如图6所示，我们提供了使用相同注意力模块的不同聚合模块生成的融合特征图的可视化对比。采用DCNv2聚合的特征存在严重伪影和文本模糊问题，而我们提出的模块能生成细节更清晰、呈现更纯净的图像。定量指标与视觉对比结果均充分证明了我们 CFDA 模块的卓越性能。

SCMF 模块的效果。为进一步验证 SCMF 模块的有效性，我们在不同尺度因子下进行了对比实验，结果如表5所示。引入 SCMF 后，在所有尺度因子下均实现了




图6. 不同聚合模块生成的融合特征图经相同注意力模块处理后的视觉对比。值得注意的是，标准DCNv2[58]会产生严重的伪影和模糊文本，而我们的 CFDA 生成的特征则具有更高的清晰度。

表5. SCMF 模块的消融研究。

方法	$\times 4$		$\times 8$		$\times 16$		参数
	PSNR $\uparrow$	SAM $\downarrow$	PSNR $\uparrow$	SAM $\downarrow$	PSNR $\uparrow$	SAM $\downarrow$	
w/o SCMF	41.95	0.033	37.02	0.047	31.90	0.068	5.85M
w/ SCMF	42.05	0.033	37.23	0.046	32.28	0.065	5.94M

稳定的性能提升。值得注意的是，随着超分辨率任务难度的增加，性能提升更为显著——在 $\times 16$ 尺度下 PSNR 增益达到0.38 dB。这凸显了 SCMF 在自适应融合多尺度特征以实现高保真重建中的关键作用。

5. 结论

在本研究中，我们提出了一种基于解混技术的融合框架，有效解决了未配准高光谱图像超分辨率处理中显式对齐（畸变或伪影）及空间-光谱耦合这两个关键挑战。通过采用光谱解混范式，我们的方法将问题分解为独立模块：粗到细可变形聚合（CFDA）模块实现稳健的特征聚合，空间通道丰度交叉注意力（SCACA）模块则实现高效的特征精炼。最终，空间通道调制融合（SCMF）模块确保了最终超分辨率高光谱图像在空间细节与光谱特征上的高保真重建。实验结果明确表明，我们的方法在超分辨率精度和视觉质量方面均优于其他最先进方法，这凸显了基于解混的融合框架在提升基于参考图像的高光谱超分辨率实际应用潜力方面的显著价值。