

利用动态跳跃连接增强U型网络的特征融合能力

岳曹^a、全松何^a、凯申王^a、建龙熊^a、张毅^a与陶何^a ^a四川大学计算机科学学院, 成都, 610065, 中国

文章信息

关键词:

测试时训练

医学图像分割: 动态卷积

ABSTRACT

U型网络凭借其跳跃连接机制, 已成为医学图像分割领域的基础框架——这种机制能够有效衔接高层次语义信息与低层次空间细节。尽管该架构取得了显著成效, 但传统跳跃连接仍存在两大关键局限: 特征间约束与特征内约束。特征间约束源于传统跳跃连接中特征融合的静态特性, 即信息沿固定路径传递而无视特征具体内容; 特征内约束则源于对多尺度特征交互关系建模不足, 导致全局上下文信息无法有效聚合。为突破这些局限, 我们提出了一种新型动态跳跃连接 (DSC) 模块, 通过自适应机制从根本上增强跨层连接性。该模块整合了两个互补组件: (1)测试时训练 (TTT) 模块: 该模块通过在推理阶段动态调整隐藏表示, 实现了基于内容感知的特征优化, 从而有效缓解特征间约束问题。(2) 动态多尺度核 (DMSK) 模块: 为缓解特征内部约束, 该模块根据全局上下文线索自适应选择核尺寸, 从而提升网络的多尺度特征整合能力。DSC模块具有架构无关性, 可无缝集成到现有的U型网络结构中。大量实验表明, 所提出的DSC模块在基于CNN、Transformer、混合CNN-Transformer以及Mamba的U型网络中均展现出即插即用的有效性。相关代码可在<https://github.com/BlackJack-Cao/U-like-Networks-with-DSC>获取。

1. 引言

医学图像分割已成为当代医疗应用中的基础任务, 是临床诊断、术前规划及疾病监测的重要组成部分。随着计算机断层扫描 (CT)、磁共振成像 (MRI)、超声检查和皮肤镜检查等医学影像技术的广泛应用, 产生了前所未有的海量高分辨率医学数据, 亟需自动化分析手段。传统的手动分割方法虽精度较高, 但耗时过长且易受观察者个体差异影响——尤其是在处理复杂解剖结构或细微病理变化时。在该领域, U-Net架构[1]因其先进的编码器-解码器框架 (结合跳跃连接机制) 而备受关注: 该框架能将编码器获取的低级空间信息与解码器生成的高级语义表征有效整合。

尽管U-Net取得了成功, 但我们发现了两个限制现有架构性能的根本性约束。近期的研究尝试解决跳跃连接的静态特性问题。例如, Attention U-Net[2]引入了注意力门控机制, 用于选择性加权通过跳跃路径传输的特征。然而, 这些方法中的注意力系数是基于训练过程中学习到的固定特征表示计算得出, 在推理阶段保持不变, 从而限制了其对多样化输入特征的适应能力。类似地, 虽然UNet++[3]和UNet3+[4]等方法提

出了采用嵌套式或全规模跳跃连接的架构改进方案, 而FuseUNet[5]将跳跃连接视为初始值问题框架中的离散节点, 但它们本质上依赖于预定义的融合策略, 无法根据输入特定内容进行动态调整。我们将这种根本性局限定义为特征间约束: 跳跃连接保持静态的传输路径, 无法根据输入特定特征进行动态调节。在医学影像领域, 解剖结构与病理病变表现出显著的异质性[6, 7, 8], 此类僵化的连接框架无法自适应地优化特征传播。

除了静态传输机制之外, 单个跳跃路径中还存在另一个关键限制。这一限制源于对自适应多尺度特征交互的建模不足。主处理流中的卷积操作已整合了多尺度机制。例如, SKNet[9]通过仅基于其自身并行分支局部统计信息进行注意力引导, 证明了动态核选择的有效性。然而, U型网络中的传统跳跃连接仍依赖固定尺寸的核来进行特征整合, 缺乏与输入特性相匹配的全局引导式动态多尺度适应能力。因此, 这些固定尺寸的核无法有效捕捉不同尺度的特征[10, 11]——考虑到医学图像中器官大小和形状的巨大差异, 这一问题尤为突出[6]。我们将此称为“特征内约束”, 其根源在于跳跃路径本身缺乏自适应的多尺度处理机制。

*通讯作者

✉ caoyue1@stu.scu.edu.cn (曹毅); tao_he@scu.edu.cn (何涛)

为同时解决这两个约束条件，我们提出了一种动态跳跃连接（DSC）模块，该模块将测试时训练（TTT）模块与动态多尺度核（DMSK）模块集成到U-Net架构中。我们的主要贡献总结如下：

- DSC模块是一款多功能即插即用模块，能够无缝集成于多种U型架构网络中——包括基于CNN的网络、基于Transformer的网络、混合CNN-Transformer网络以及基于Mamba的网络。
- 与现有将TTT集成在编码器或解码器组件中的方法不同，我们率先将TTT应用于跳跃连接。我们将静态路径转化为自适应机制，使其在推理过程中根据输入特征动态调节内部权重。
- DMSK模块基于全局上下文线索实现了自适应核尺寸选择机制。该机制通过动态多尺度特征提取有效缓解了特征内部约束问题；同时，借助通道注意力机制与空间信息聚合技术，显著提升了特征表征质量。

2. 相关工作

2.1. 跳转连接的发展

2.1.1. 隐式跳连接增强方法

隐式跳跃连接增强方法通过提升编码器生成特征的质量，从而提高跳跃连接的整体效能。这些优化后的特征随后会通过跳跃路径进行传输。TransUNet[12]采用基于Transformer的特征处理技术对编码器进行了改进；混合CNN-Transformer编码器产生的改进型全局特征表示为后续跳跃连接传输提供了更丰富的上下文信息。SwinUNet[13]在编码器中采用分层移窗注意力机制提升了特征表示质量，该机制生成了更具区分度的多尺度特征，并通过跳跃路径传递至解码器。HiFormer[14]则在编码器中结合CNN与Transformer路径，并采用跨尺度特征融合机制——这种跨尺度特征融合方法不仅提升了可用于跳跃连接传输的特征质量，还增强了编码器与解码器组件之间的整体信息流。

2.1.2. 显式跳连接修改方法

显式跳跃连接改进方法主要通过重构或扩展跳跃路径本身来增强特征整合能力。GridNet[15]提出了一种通用的编码器-解码器框架，利用特征图之间的网格结构连接来实现多尺度特征聚合；类似地，U-Net++[3]采用嵌套式密集跳跃路径，通过密集连接的卷积块实现

多尺度特征聚合；UNet3+[4]则运用全尺度跳跃连接，在解码器每个阶段明确聚合所有编码器层级的特征；FuseUNet[5]将跳跃连接概念化为初始值问题框架中的离散节点。隐式方法有效提升了特征质量，而显式方法优化了连接模式，但二者均本质上依赖静态架构——这些架构具有固定的传输路径和预设的核尺寸，无法在推理过程中动态适应输入特征特性。这一局限性限制了其在多种医学影像应用场景中的优化潜力。

2.2. 测试。时间训练

深度学习领域的最新进展将TTT[16, 17]引入作为一种创新方法，其特点在于计算复杂度呈线性且在推理过程中参数具有自适应动态特性。与采用固定参数的传统方法不同，TTT采用自监督学习框架，能够基于测试数据实现持续优化，从而显著提升模型应对分布偏移的能力。当前TTT在医学影像领域的应用已充分证明了其多功能性。Zhou等人[18]提出的TTTUNet将TTT层整合到传统U-Net架构的编码器中。[19]Xu提出了Med-TTT——一种视觉骨干网络，通过引入TTT层实现了具有线性计算复杂度的长距离依赖关系的有效建模。除医学影像领域外，TTT已成功应用于序列数据处理：Yang、Wang和Ge[20]开发了用于序列推荐任务的TTT4Rec，其中TTT层可实时适应用户的动态行为；在生物信息学领域，Meng等人.....[21]提出的scFusionTTT技术适用于单细胞多组学数据融合。该方法利用基于TTT的掩码自编码器来处理基因与蛋白质之间的序列关系。

3. 动机

医学图像分割面临着独特的挑战，这促使人们开发测试时自适应机制。与自然图像中物体外观在类别内保持相对一致不同，医学图像即使在同一解剖区域和成像模态下也表现出显著的样本间异质性。患者个体差异、病理变异、成像方案差异以及采集伪影等因素，使得每个测试样本的特征都可能与训练分布存在显著偏差。例如，不同患者的器官大小差异巨大，组织对比度因疾病状态而异，解剖边界也具有高度的形态变异性[6, 7]。由此产生一个关键问题：既然更简单的注意力机制就能实现特征加权，为何还需要测试时自适应机制？根本区别在于自适应性——诸如Attention U-Net[2]等注意力机制是通过静态参数计算注意力系数的。

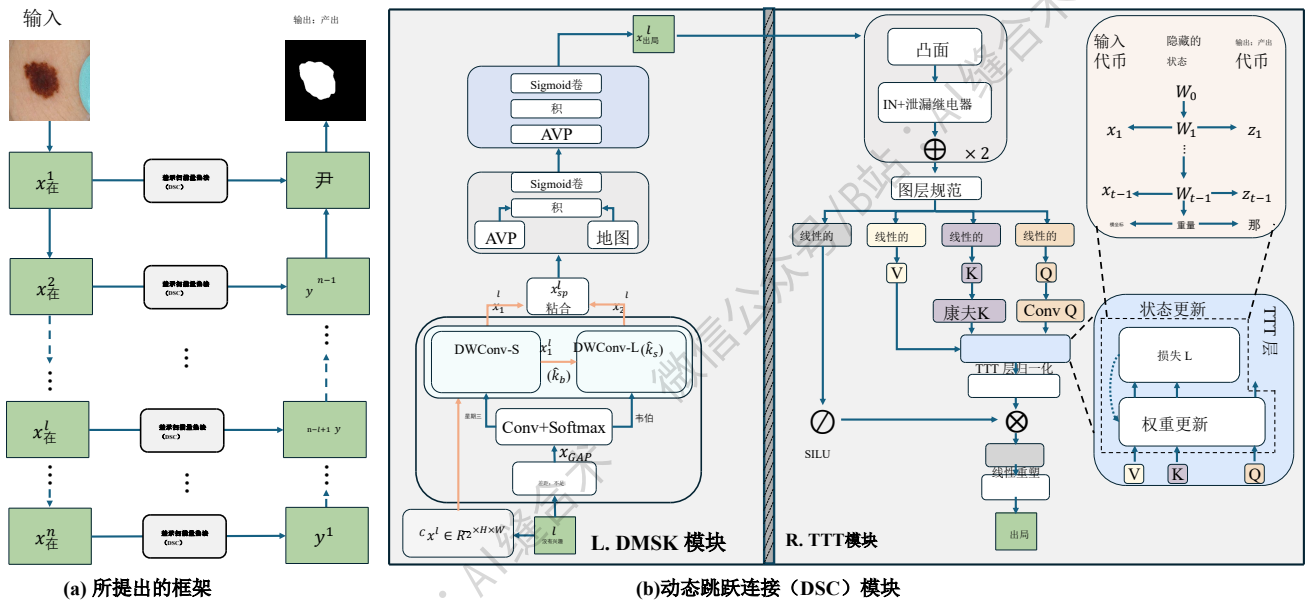


图 1: (a) 基于动态跳跃连接 (DSC) 模块的提案框架。(b) DSC 模块架构: DMSK 模块 (左侧) 根据全局上下文进行自适应多尺度核选择; TTT 模块 (右侧) 在推理过程中实现权重动态调整。输入特征 (x_{1in} , x_{2in} , ..., x_{nin}) 来自编码器层的数据通过 DMSK 和 TTT 进行处理, 实现特征的自适应传播至解码器。

这些参数是在训练过程中习得的。这些预设的转换方法无法适应个体测试样本特有的新解剖结构或成像特征。相比之下, TTT 通过将每个输入视为独立的学习问题, 实现了真正样本特定的适应能力。这种基于样本的自适应特性要求我们必须仔细考量如何在神经网络架构中整合此类机制。

尽管 TTT 在推理过程中实现了动态参数自适应方面展现出卓越能力, 但在 U 型架构中确定最佳集成点仍面临关键的设计决策, 这些决策具有独特的理论与实践意义。具体而言, 编码器组件、解码器组件或跳跃连接路径的选择会显著影响模型的自适应能力和整体性能。在编码器-解码器架构中, 跳跃连接的作用与编码器或解码器层截然不同: 编码器层在其处理流中执行渐进式特征抽象, 而解码器层则在其路径中进行语义到空间的重建; 跳跃连接则作为直接的特征传输通道, 将编码器层的空间细节完整传递至对应的解码器层。然而, 传统 U-Net 架构中的这种直接传输方式本质上是静态的, 无法适应输入数据的具体特征。医学图像的异质性特征——表现为解剖结构与病理状态的多样性——要求在这些传输节点实施自适应特征处理, 以优化编码器-解码器之间的特征整合。这创造了独特的优化机会, 使得跳跃连接成为 TTT 集成等自适应机

制的理想应用位置。

将 TTT 应用于跳跃连接路径 (而非编码器或解码器组件) 具有双重优势: 首先, 跳跃连接会在特征传递至解码器层进行整合之前对其进行处理; TTT 能够学习这些编码器特征的输入特定变换方式, 从而根据医学图像中不同的解剖结构和病理状况优化其与解码器处理过程的兼容性。其次, 通过将 TTT 应用于跳跃连接, 可在不修改编码器和解码器架构的前提下实现针对性的特征适应, 从而提供一种模块化的增强方案。

诸如 TTT-UNet[18] 等最新研究已证明, 将 TTT 应用于编码器组件时效果显著, 验证了 TTT 在医学图像分割中的广泛适用性。然而我们的分析表明, 跳跃连接路径是集成 TTT 的最佳位置——这得益于其在自适应特征传递中的独特作用以及更高的计算效率优势。

动态多尺度核方法在自适应捕捉不同空间尺度特征方面表现卓越, 这使其在医学图像分析领域尤为宝贵。尽管先前的研究 (如 SKNet[9]) 通过主骨干网络中基于局部分支统计量的注意力机制实现了动态核选择; MSU-Net[22] 主要在编码器中采用固定融合权重的静态多分支异构卷积; D-Net[23] 则利用多个大型核并结合全局上下文进行动态通道与空间选择——而我们的 DMSK 模块的独特之处在于: 专门在输入层内部应用了全局引导的动态核加权机制。

为跨层特征传输提供跳过连接路径。该针对性设计实现了细粒度、基于内容感知的多尺度聚合功能，与我们采用 TTT 增强的跳过连接机制无缝衔接，能够适应性地利用局部和全局上下文中的多尺度语义信息，从而满足医学图像分割中对输入特定特征适配的关键需求。

4. 方法

4.1. 框架结构

如图1(a)所示，我们提出的框架采用带有增强跳跃连接的编码器-解码器架构用于医学图像分割。令 $X \in \mathbf{RC} \times H \times W$ 表示输入特征，其中 C 、 H 、 W 分别代表通道数、高度和宽度。

编码器 $\mathcal{E}$ 包含一系列顺序降采样操作，可在多个分辨率层级提取层次化特征：

$$\{x^1_{1in}, x^2_{1in}, \dots, x^l_{1in}, \dots, x^n_{1in}\} = \mathcal{E}(X), \quad (1)$$

其中 x^l_{1in} 表示第 l 层的特征图

关于编码器。相应地，解码器 $\mathcal{D}$ 通过渐进式上采样操作来恢复空间维度：

$$\{y^1; \dots; y^{n-l+1}; \dots; y^n\} = \mathcal{D}(\{x^n_{1in}, x^{n-1}_{1in}, \dots, x^1_{1in}\});$$

(2) 其中 y^{n-l+1} 表示解码器第 l 层的特征图。

我们提出 DSC 模块作为本框架的核心创新。与传统 U-Net 架构直接拼接编码器特征 x_{lin} 与对应解码器特征 y^{n-l+1} 不同，我们的改进架构通过引入 DSC 模块对这一路径进行重构，以实现自适应特征处理。DSC 模块的设计旨在通过动态适应机制同时处理特征间与特征内约束。如图1(b)所示，每个 DSC 模块包含两个互补模块：DMSK 模块（图1(b.L)）和 TTT 模块（图1(b.R)）。DMSK 模块通过动态核选择自适应捕获多尺度空间依赖关系以处理特征内约束，而 TTT 模块则在推理过程中通过自监督适应机制处理特征间约束。这两个模块的整合将传统跳跃连接路径重构为如下形式：

$$y^{n-l+1} = \mathcal{F}_{\text{decode}}(y^{n-l}, \mathcal{F}_{\text{TTT}}(\mathcal{F}_{\text{DMSK}}(x^l_{1in}))). \quad (3)$$

当来自编码器的输入特征图 x_{lin} 进入 DSC 模块时，首先会经过 DMSK 模块 $\mathcal{F}_{\text{DMSK}}$ 。该模块对编码器特征进行处理，生成既能捕捉局部细节又能反映全局上下文的多尺度自适应表示。随后，这些优化后的特征会被传递至 TTT 模块 $\mathcal{F}_{\text{TTT}}$ ；该模块在推理阶段采用自监督学习机制，根据当前输入特征进一步优化特征表示。

经过处理的特征随后通过解码函数 $\mathcal{F}_{\text{decode}}$ 整合到相应的解码器层级。解码器在保持精细空间细节和高层次语义信息的同时，生成全分辨率的最终分割输出。

4.2. 动态多尺度核模块

为解决特征内部约束问题，我们提出了 DMSK 模块。该模块通过动态核选择机制，根据输入特征的特性自适应地捕捉局部与全局空间依赖关系。

为有效建模多尺度上下文关系，本文定义了两组核函数：小尺度核和大尺度核。前者能够提取精细的局部细节，而后者则能捕捉长程依赖关系。每种核函数均采用深度可分离卷积实现以降低计算复杂度；同时通过扩张卷积扩展感受野而不增加参数数量，从而确保能自适应地选择最适合每个输入的核函数。具体而言，对于输入特征 x_{lin} ，首先执行全局平均池化 (GAP) 操作以捕获全局通道统计信息：

$$x^l_{\text{GAP}} = \text{GAP}(x_{lin}); \quad (4)$$

小规模核选择的权重 w 是通过 s 计算得出的。作为：

$$w_s = \text{Softmax}(\text{Convl}_s(x^l_{\text{GAP}})); \quad (5)$$

其中 Convl_s 是一个 1×1 卷积层，用于映射 s 输入通道维度对应于小尺度核的数量 ($|L_s|$)。类似地，用于大规模核选择的权重 w_b 通过独立的卷积变换获得：

$$w_b = \text{Softmax}(\text{Convl}_b(x^l_{\text{GAP}})); \quad (6)$$

其中 Convl_b 是一个不同的 1×1 卷积层，将输入通道映射到大规模核的数量 ($|L_b|$)。因此， w_s 和 w_b 表示不同的选择概率，从而使模型能够自主确定每个输入实例中最相关的细粒度和粗粒度核。

随后，采用一种选择方法来确定核指数。为确保该离散选择过程在训练过程中可微分，我们采用了直通估计器 (Ste) [24]。

$$\hat{k}_s = \text{STE}_{\text{argmax}}(w_s), \quad \hat{k}_b = \text{STE}_{\text{argmax}}(w_b), \quad (7)$$

其中 $\hat{k}_s$ 和 $\hat{k}_b$ 分别表示所选小尺度与大尺度卷积核的索引。最终可获得最相关的小尺度与大尺度卷积核。

一旦确定了最相关的中小型及大型核函数，这些核函数便会以逐渐增大的核尺寸和膨胀率进行级联处理。

表1

数据集信息中，“# Targets”指定了每个数据集中不同的分割类别。

数据集	维度	# 训练图像	# 测试图像	# 目标
ISIC 2017 腹部	2D	1505	645	2
CT扫描	3D	50 (4794片)	50 (10894片)	13
腹部MRI内镜图像	3D	60 (5615片)	50 (3357片)	13
显微镜图像	2D	1800	1200	7
	2D	1000	101	2

该设计具有两大显著优势。首先，上下文信息在感受野内被递归聚合，从而使有效感受野尺寸能够逐步扩大[25]；其次，从更广的感受野中提取的特征对输出贡献更为显著，从而使 DMSK 能够捕捉更精确、信息更丰富的特征。其方法论包括将输入特征投影至较低维度，随后依次应用动态选择的核函数：

$$\begin{cases} x^l = \text{Project}(x_{in}^l), \\ x_1^l = \text{DWConv}_{(\hat{k}_s)}(x^l), \\ x_2^l = \text{DWConv}_{(\hat{k}_b)}(x_1^l). \end{cases} \quad (8)$$

随后将这些生成的特征进行拼接，并通过一个空间注意力模块进行优化；该模块同时采用平均池化（AVP）和最大池化（MAP）操作来捕捉全局空间关系。

$$\begin{cases} x_{sp}^l = \text{Concat}([x_1^l; x_2^l]), \\ w_a = \text{AVP}(x_{sp}^l), \\ w_m = \text{MAP}(x_{sp}^l), \\ [w_1; w_2] = \text{Sigmoid}(\text{Conv}([w_a; w_m])), \end{cases} \quad (9)$$

其中 w_1 和 w_2 均有助于从多个核分支中选择适应性特征。特征融合的校准是通过执行逐元素运算实现的：

$$x_{ch}^l = (w_1 \otimes x_{sp}^l) \oplus (w_2 \otimes x_{sp}^l), \quad (10)$$

在空间注意力之后是通道注意力，该机制强调不同通道间特征的重要性：

$$\begin{cases} w_{ch} = \text{Sigmoid}(\text{Conv}(\text{AVP}(x_{ch}^l))), \\ x_{out}^l = w_{ch} \otimes x_{ch}^l + x_{in}^l, \end{cases} \quad (11)$$

其中，通道级与空间注意力机制的设计通过使模型能够同时在空间和通道层面聚焦最具信息量的区域，从而补充了动态核选择方法，显著提升了特征表征效果。

4.3. TTT 模块

为缓解特征间约束，我们提出了 TTT 模块，该模块在推理过程中动态地用自适应特征传播替代静态跳跃连

接。它能够根据输入特征的具体特性实时调整特征路径。如图1(b.R)所示，TTT 模块对于在测试阶段提升模型的适应性至关重要。最初，来自模型的输出特征 x^l 通过 DMSK 模块通过两个连续的残差块进行处理[26]。每个残差块包含一个卷积层，随后是实例归一化[27]和泄漏 ReLU 激活函数[28]。接着对这些特征应用层归一化[29]，然后将其展平以准备进行线性变换。通过三个独立的线性变换分支处理这些特征，得到分别标记为 V 、 K 和 Q 的特征集；而第四个分支则采用 SiLU 激活函数[30]实现线性变换，以增强特征表示。最终， V 、 K 和 Q 的输出会被传递至 TTT 层，在该层完成隐藏状态更新。

在 TTT 层中，时间 t 的隐藏状态 h_t 被参数化为一个可训练模型 f ，该模型具有动态可调的权重 W_t 。这些权重通过基于当前输入 x_t 的梯度下降法进行优化：

$$W_t = W_{t-1} - \eta \hat{\partial} t(W_{t-1}; x_t), \quad (12)$$

其中 η 表示学习率。在基础的朴素版本中，自监督损失函数 t 旨在修复被损坏的输入数据。尽管这种直接的重构策略在特定场景下具有优势，但在建模输入序列中的复杂关系时（尤其是需要更深层次上下文理解的任务）会暴露出局限性。为克服这些限制，我们采用了一种先进的自监督任务方法，该方法利用输入数据的多视角特征。我们引入可学习的投影矩阵 θ_K 和 θ_V ，将输入数据映射到不同的特征空间：训练视角 $K = \theta_K x_t$ 用于提取关键学习特征，而标签视角 $V = \theta_V x_t$ 则作为重构目标：

$$t(W; x_t) = \|\mathbf{f}(K; w) - V\|_2^2, \quad (13)$$

该方法使模型能够自主聚焦于输入数据中最关键的特征，显著提升了其捕捉长程依赖关系及细微关联的能力。

最终输出特征 z_t 是通过测试视图 $Q = \theta_Q x_t$ 生成的：

$$z_t = f(Q; W_t), \quad (14)$$

表2

各数据集的配置参数如下：补丁尺寸指输入补丁的空间维度（对于二维数据集为高度和宽度；对于三维数据集为深度、高度和宽度）；“#阶段数”表示网络层级中的分辨率状态数量；“#每个轴的池化次数”代表沿不同空间轴进行的下采样操作次数。

配置	补丁大小	批量大小	# 阶段	# 按轴进行池化
ISIC2017	(256, 256)	8	4	(6, 6)
腹部CT	(40, 224, 192)	2	6	(3, 3, 5)
3D腹部MR成像	(48, 160, 224)	2	6	(3, 3, 5)
内镜检查术	(384, 640)	13	7	(6, 6)
显微镜检查	(512, 512)	12	8	(7, 7)





图2：显微镜图像中细胞分割的可视化示例（第一行）、MedNext网络+DSC模块（第二行）、内窥镜图像中的器械分割（第三行）以及U-Mamba网络+DSC模块（第四行）。

其中 s 可以是线性模型或多层感知机（我们在实现中采用线性模型）。引入 θ_Q 后，该模型能够在推理过程中动态调整特征注意力权重，并自动聚焦于不同测试样本最具区分性的特征，从而显著提升模型对新数据的适应能力。最后，TTT层的输出与第四分支的结果通过哈达玛积进行组合，随后经过线性变换和维度重塑，以满足解码器后续层所需的输入维度。

5. 实验

5.1. 数据集

为全面评估所提出的DSC模块的性能与可扩展性，我们在五个不同的医学图像数据集上进行了大量实验，这些数据集涵盖了多种成像模式、维度及分割目标。表1总结了这些数据集的核心特征。

5.1.1. ISIC 2017

ISIC 2017[31]数据集包含2,150张皮肤病变的皮肤镜图像，是推动皮肤病学及计算机辅助诊断发展的宝贵资源。该数据集涵盖多种皮肤疾病（包括良性与恶性病变），主要适用于黑色素瘤检测和皮肤癌分类任务。

5.1.2. 内镜图像

该数据集源自2017年MICCAI EndoVis挑战赛[32]，专注于内窥镜图像中的器械分割任务，涵盖七种不同器械：大型穿刺针驱动器、Prograsp钳、单极弯型剪刀、Cadierre钳、双极钳、血管封堵器及即插式超声探头。数据集包含1,800帧训练帧和1,200帧测试帧。

5.1.3. 显微镜图像

该数据集源自NeurIPS 2022细胞分割挑战赛[33]，专为显微镜图像中的细胞分割而设计，包含1,000张训练图像和101张测试图像。遵循U-Mamba[34]的研究方法，我们将此任务视为语义分割任务，重点关注细胞边界与内部结构，而非实例分割。

5.1.4. 腹部CT

腹部CT数据集 (Ma等人, 2024b) 是 MICCAI 2022炎症挑战赛的一部分，其训练集和测试集中均包含来自50例CT扫描的13个腹部器官的分割结果。这些分割器官包括肝脏、脾脏、胰腺、肾脏、胃、胆囊、食管、主动脉、下腔静脉、肾上腺和十二指肠。

5.1.5. 腹部MRI

Abdomen Mr数据集 (Ji等人, 2022) 源自 MICCAI 2022 AMOS挑战赛，专注于利用MRI扫描对相同的13个腹部器官进行分割。该数据集包含60幅MRI扫描图像用于训练，50幅用于测试。此外，我们通过将三维腹部MRI扫描转换为二维切片，生成了该数据集的二维版本。这种转换使我们能够在通用的二维分割框架内评估DSC块——该框架因计算需求较低而在实践中广泛应用。转换后保留了原有的13个器官，确保在二维和三维模态下评估结果具有一致性。

5.2. 实施详情

具体配置详见表2。为在计算效率与性能提升之间取得平衡，我们将DSC模块仅集成于瓶颈层（编码器与解码器之间的最深层连接处，此处特征维度最小但语义信息最为丰富）。这种策略性布局最大限度降低了参数开销（如表3所示），同时在最关键传输节点实现了最优的自适应特征细化效果。该实现方案在所有六种评估架构中均保持一致：两种基于CNN的分割网络（nnU-Net[35]和SegResNet[36]）、两种基于Transformer的网络（UNETR[37]和SwinUNETR[38]）、一种混合式CNN-Transformer网络（MedNext[39]）以及最先进的基于Mamba的网络（U-Mamba[34]）。

训练采用Dice损失和交叉熵损失的组合，并使用SGD优化器（初始学习率： $1e-2$ ）在单块A100 GPU上进行1000个训练周期。网络模块通过nnU-Net的自动配置功能完成设置。性能评估遵循U-Mamba[34]中建立的协议：对于ISIC2017皮肤病变分割、腹部器官分割和内窥镜器械分割采用Dice相似系数（Dice分数）和归一化表面距离（NSD）；显微镜细胞分割任务则采用F1分数。TTT模块采用了多项关键设计策略以确保其有效性与稳定性。基于小批量TTT策略[17]，推理过程中的梯度更新步数由 T/b 决定，其中 T 为特征序列长度， b 为小批量大小。在我们的实现中，采用 $b=16$

以平衡计算效率与适应质量。隐藏状态维度由缩减比例 $r=16$ 控制，其中中间维度计算公式为 $d=\max(C/r, 32)$ ，其中 C 表示输入通道数。投影矩阵 K 、 V 和 Q 通过 $1\times 1\times 1$ 卷积层实现，用于将输入特征从维度 C 映射到降维后的维度 d 。

5.3. 定量与定性分割结果

5.3.1. 二维数据集结果

对于二维任务，我们采用交叉验证方法，按照骨干网络的协议，将port Dice分数、NSD分数和F1分数以百分比形式呈现。表4展示了DSC模块集成在多种二维分割任务中的性能表现。TTT-UNet_Bot和Med-TTT是近期将TTT应用于医学图像分割任务的研究成果；其中Med-TTT仅提供二维结果，因其实现支持二维数据处理，且公开代码中未包含三维功能。DSC模块在所有评估架构中均展现出持续提升的效果：在内窥镜器械分割任务中，采用DSC的U-Mamba_Bot获得最高Dice分数 0.6733 ± 0.3217 ，较基线值（ 0.6540 ± 0.3008 ）显著提升；采用DSC的nnU-Net达到 0.6718 ± 0.3221 ，而未集成DSC时为 0.6264 ± 0.3024 ；SegResNet则从 0.5820 ± 0.3268 显著提升至 0.6620 ± 0.3029 。基于CNN的架构均表现出稳定的性能提升，证明本方法与传统卷积框架具有良好的兼容性；基于Transformer的架构同样从DSC集成中获益显著——UNETR分数从 0.5017 ± 0.3201 提升至 0.5137 ± 0.3201 ，SwinUNETR的F1分数从 0.5528 ± 0.3089 提升至 0.6064 ± 0.3408 ，而SwinUNETR的表现更为显著。这些改进尤为值得关注，因为基于Transformer的方法已内置复杂的全局注意力机制；这表明我们的动态跳跃连接方法为现有的自注意力计算提供了补充优势。在ISIC2017皮肤病变分割任务中，采用DSC的SwinUNETR达到 0.8820 ± 0.3190 ，而采用DSC的MedNext则达到 0.8901 ± 0.3821 。最突出的进步体现在细胞分割方面：采用DSC的U-Mamba_Bot获得 0.6101 ± 0.2465 的F1分数，远优于基线模型（ 0.5389 ± 0.2817 ）；nnU-Net的分数从 0.5383 ± 0.2657 提升至 0.5460 ± 0.2653 ，而SegResNet则从 0.5411 ± 0.2633 提高到 0.5779 ± 0.2748 。UNETR性能从 0.4357 ± 0.2572 大幅提升至 0.4856 ± 0.2637 ，表明动态适应机制对于那些在细粒度细胞特征区分上存在困难的架构尤其有益。

图2对不同二维分割场景进行了全面的定性分析。在显微细胞分割（上排）中，可视化结果展示了形态各异、大小、密度及聚类模式不同的细胞结构。其增强的分割能力

表3

在腹部MRI数据集上集成DSC模块前后，基线网络计算复杂度的对比。DSC模块仅按照第4.2节的配置在瓶颈层进行集成。报告的推理时间是按每个样本独立测量的。

模型	DSC模块	Attrs (M)	GFLOPs	推理时间（毫秒）
nnU-Net	×	31.2	524.8	37.26
	✓	32.6	525.3	41.30
SegResNet	×	18.8	636.8	102.70
	✓	19.2	645.4	290.04
UNETR	×	93.0	194.5	39.46
	✓	94.5	195.6	83.91
SwinUNETR	×	62.1	830.7	165.44
	✓	67.8	831.1	168.20
MedNext	×	11.1	309.4	174.40
	✓	12.2	313.1	216.22
Mamba_Bot	×	41.9	792.1	100.54
	✓	43.3	792.3	109.31

表4

二维分割任务的结果总结。在DSC模块列中，“-”表示与DSC模块集成无关的方法，“×”表示未使用DSC模块的基线方法，“”表示已集成DSC模块的方法。“*”和“†”表示实验结果源自现有研究：其中“*”引自[34]，“†”引自[18]。

方法	DSC模块	内窥镜检查器械		ISIC 2017		显微镜下的细胞
		骰子	NSD	骰子	NSD	F1
Med-TTT	-	0.5011±0.3168	0.5319±0.3033	0.8149±0.3105	0.8642±0.2974	0.4018±0.2239
TTT-UNet_Bot	-	0.6643±0.3018 [†]	0.6799±0.3056 [†]	0.8878±0.3216	0.9103±0.3164	0.5818±0.2410 [†]
nnU-Net	×	0.6264±0.3024*	0.6412±0.3074*	0.8825±0.2739	0.9120±0.3110	0.5383±0.2657*
	✓	0.6718±0.3221	0.6865±0.3182	0.8846±0.2634	0.9210±0.3354	0.5460±0.2653
SegResNet	×	0.5820±0.3268*	0.5968±0.3303*	0.8763±0.3521	0.9070±0.3619	0.5411±0.2633*
	✓	0.6620±0.3029	0.6782±0.3410	0.8796±0.3211	0.9108±0.3117	0.5779±0.2748
UNETR	×	0.5017±0.3201*	0.5168±0.3235*	0.8499±0.3328	0.8850±0.3198	0.4357±0.2572*
	✓	0.5137±0.3320	0.5275±0.3302	0.8580±0.3019	0.8930±0.3164	0.4856±0.2637
SwinUNETR	×	0.5528±0.3089*	0.5683±0.3123*	0.8803±0.2482	0.9145±0.3216	0.3967±0.2621*
	✓	0.6064±0.3408	0.6226±0.3356	0.8820±0.3190	0.9156±0.2682	0.4807±0.2375
MedNext	×	0.6055±0.3476	0.6211±0.3329	0.8871±0.2398	0.9212±0.3182	0.5613±0.2573
	✓	0.6104±0.3528	0.6263±0.3427	0.8901±0.3821	0.9223±0.3742	0.5746±0.2469
Mamba_Bot	×	0.6540±0.3008*	0.6692±0.3050*	0.8889±0.3471	0.9173±0.3284	0.5389±0.2817*
	✓	0.6733±0.3217	0.6887±0.3054	0.8892±0.3328	0.9182±0.3165	0.6101±0.2465

DSC技术在网络应用中的优势在细胞重叠且边界模糊的区域尤为显著。在内窥镜器械分割示例（底部行）中，DSC模块在复杂组织背景下的手术器械轮廓识别方面表现出卓越性能。其自适应核选择机制能有效应对从尖端精细抓持器到宽幅手术桨板等不同尺寸器械的多样化需求；而 TTT 模块则可实时适应内窥镜操作中常见的各种光照条件与组织形态变化。实验结果表明，DSC模块在各类二维分割任务中均能保持稳定的性能提升，在涉及复杂形态结构的高难度场景下尤其

展现出显著改进效果。

5.3.2. 3D数据集结果

对于三维任务，我们采用交叉验证方法报告Dice分数和 NSD 分数，具体遵循主干网络的实验流程。表5展示了DSC模块集成在腹部CT与MRI数据集上的三维器官分割性能。结果显示，DSC模块相较于大多数评估方法均展现出性能提升。在腹部CT分割任务中，结合DSC的 nnU-Net取得了显著效果。




图3: CT(a)与MRI(b)中腹部器官分割的可视化示例。

表5

3D分割任务结果总结。“*”和“†”表示实验结果源自现有研究：[34]中的结果用“*”表示，[18]中的结果用“†”表示。

方法	DSC模块	腹部器官CT		腹部器官MRI	
		骰子	NSD	骰子	NSD
TTT-UNet_Bot	—	$0.8709 \pm 0.1011^\dagger$	$0.8995 \pm 0.0721^\dagger$	$0.8677 \pm 0.0482^\dagger$	$0.9247 \pm 0.0631^\dagger$
nnU-Net	×	$0.8615 \pm 0.0790^*$	$0.8972 \pm 0.0824^*$	$0.8309 \pm 0.0769^*$	$0.8996 \pm 0.0729^*$
	✓	0.8718 ± 0.1177	0.9093 ± 0.0317	0.8461 ± 0.1062	0.9133 ± 0.0401
SegResNet	×	$0.7927 \pm 0.1162^*$	$0.8257 \pm 0.1194^*$	$0.8146 \pm 0.0959^*$	$0.8841 \pm 0.0917^*$
	✓	0.8054 ± 0.1700	0.8439 ± 0.0147	0.8136 ± 0.0963	0.8795 ± 0.0928
UNETR	×	$0.6824 \pm 0.1506^*$	$0.7004 \pm 0.1577^*$	$0.6867 \pm 0.1488^*$	$0.7440 \pm 0.1627^*$
	✓	0.6972 ± 0.2410	0.7265 ± 0.0865	0.6971 ± 0.0591	0.7576 ± 0.0453
SwinUNETR	×	$0.7594 \pm 0.1095^*$	$0.7663 \pm 0.1190^*$	$0.7565 \pm 0.1394^*$	$0.8218 \pm 0.1409^*$
	✓	0.7847 ± 0.2005	0.8179 ± 0.0411	0.7469 ± 0.0655	0.8091 ± 0.0467
MedNext	×	0.8427 ± 0.1137	0.8706 ± 0.1538	0.8270 ± 0.0625	0.8951 ± 0.0428
	✓	0.8642 ± 0.0786	0.8920 ± 0.0412	0.8421 ± 0.1098	0.9065 ± 0.0667
Mamba_Bot	×	$0.8683 \pm 0.0808^*$	0.9049 ± 0.0821	$0.8453 \pm 0.0673^*$	$0.9121 \pm 0.0634^*$
	✓	0.8712 ± 0.0973	0.9037 ± 0.0321	0.8535 ± 0.0597	0.9172 ± 0.0340

与基线值 0.8615 ± 0.0790 相比，最终结果为 0.8718 ± 0.1177 。采用 DSC 的 U-Mamba_Bot 达到 0.8712 ± 0.0973 ，而基线值为 0.8683 ± 0.0808 ；采用 DSC 的 MedNext 达到 0.8642 ± 0.0786 （基线值为 0.8427 ± 0.1137 ）；SegResNet 从 0.7927 ± 0.1162 显著提升至 0.8054 ± 0.1700 ，UNETR 则从 0.6824 ± 0.1506 改善至 0.6972 ± 0.2410 ；SwinUNETR 从 0.7594 ± 0.1095 提升至 0.7847 ± 0.2005 。所有架构的持续改进表明，DSC 模块在三维分割场景中能为不同架构范式提供普适性优势。在腹部 MRI 分割任务中，采用 DSC 的 U-Mamba_Bot 达到 0.8535 ± 0.0597 （基线值 0.8453 ± 0.0673 ）；采用 DSC 的 nnU-Net 达到 0.8461 ± 0.1062 （基线值 $0.8309 \pm$

0.0769 ）；MedNext 从 0.8270 ± 0.0625 提升至 0.8421 ± 0.1098 ，UNETR 则从 0.6867 ± 0.1488 进步至 0.6971 ± 0.0591 。尽管 SwinUNETR 从 0.7565 ± 0.1394 略有下降至 0.7469 ± 0.0655 ，但 DSC 模块在不同 MRI 对比度模式和成像协议下均保持稳定且具有竞争力的性能。图 3 展示了腹部 CT 和 MRI 数据的定性分割结果。该系统性比较同时呈现了真实标注数据、基线网络输出结果及其对应的 DSC 增强版本，涵盖四种代表性架构：UNETR、MedNext、SwinUNETR 和 U-Mamba。可视化证据清晰表明，将 DSC 模块集成到现有框架中可带来持续改进效果。CT

表6

ISIC2017数据集上二维皮肤病变分割结果总结。

方法	mIoU	骰子	NSD
U-Net [1]	0.7102	0.8355	0.5298
U-Net++ [3]	0.7334	0.8461	0.6265
SwinUNet [13]	0.6693	0.7782	0.5778
UNet3+ [4]	0.7805	0.8767	0.6283
TransUNet [12]	0.7834	0.8665	0.6124
HiFormer [14]	0.7695	0.8524	0.6031
FuseUNet [5]	0.8058	0.8773	0.6420
U-Net + DSC	0.7980	0.8876	0.6423

分割结果表明，DSC整合技术能够更精确地界定器官边界，并提升解剖结构的一致性。

在所有经过评估的架构中，基于DSC增强的版本生成的分割结果更接近真实标注数据，在保持器官连接完整性及减少分割伪影方面均取得显著提升。MRI分割对比结果证明了DSC在不同成像模式下的性能优势：增强型网络通常能提供更优质的分割效果，并能更好地处理MRI成像特有的复杂组织对比度模式。研究结果表明，DSC的整合有效解决了边界模糊和强度差异等常见分割难题。这些改进的临床意义不仅体现在量化指标上，更在于其提升的分割精度为诊断工作流程中的自动化分析提供了更可靠的支撑。通过涵盖多种架构和成像技术的全面评估，DSC模块已被证实是一种有效的增强策略，能在多样化的医学影像场景中保持稳定性能表现。

5.4. 消融研究

5.4.1. 跳连接增强策略的影响

本实验基于ISIC2017数据集进行，旨在评估我们的DSC模块相较于现有跳跃连接增强方法的有效性。表6展示了不同跳跃连接增强策略的应用效果。我们的UNet+DSC模型表现优异，mIoU值达0.7980，Dice分数为0.8876，不仅优于包含U-Net++ (mIoU: 0.7334, Dice: 0.8461) 和 UNet3+ (mIoU: 0.7805, Dice: 0.8767) 在内的直接改进方法，也优于TransUNet (mIoU: 0.7834, Dice: 0.8665) 和HiFormer (mIoU: 0.7695, Dice: 0.8524) 等间接增强方案。值得注意的是，这些改进在两项评估指标上均保持一致。结果表明，与现有的静态连接架构及基于编码器的间接改进方法相比，我们的DSC模块能提供更有有效的跳跃连接增强效果。

5.4.2. DSC阻塞放置策略的影响

为评估不同DSC块集成策略的性能与效率之间的权衡关系，我们在 ISIC 2017数据集上以 UNETR 作为基线架构进行了消融实验。我们比较了三种配置：

(1) 基线模型（未集成DSC）、(2) 仅瓶颈层设计（DSC仅整合于最深层跳跃连接）以及(3) 全层级集成（DSC在每个跳跃连接层级均被整合）。该设计使我们能够评估模块部署位置对参数、计算成本（GFLOPs）、推理时间及分割指标（Dice和 NSD）的影响。需注意：虽然DSC模块可作为通用组件应用于任意跳跃连接层级，但多层级集成虽可行且能带来轻微性能提升，却因跨层重复 TTT 更新而产生显著更高的计算开销。这验证了我们仅采用瓶颈层部署策略的合理性——该方案在效能与效率之间取得平衡，避免误导读者认为“动态跳跃连接”仅限于单一级；实际上多层级应用虽可行，但在推理时间至关重要的实际部署场景中并不推荐。如表7所示，仅瓶颈层配置实现了最优平衡：参数量（87.9M vs. 基线87.7M）与GFLOPs（26.5 vs. 26.4）增幅最小，推理时间适度延长（47.19 ms vs. 17.41 ms），同时Dice值提升至0.8580 $\pm$ 0.3019（对比基线）。基线值为0.8499 $\pm$ 0.3328，NSD 值升至0.8930 $\pm$ 0.3164（相较于基线值0.8850 $\pm$ 0.3198）。全层级配置进一步略微提升了精度：Dice值达到0.8625 $\pm$ 0.2950，NSD 值达到0.8975 $\pm$ 0.3100；但参数规模增至8810万，GFLOPs计算能力提升至27.5，推理时间显著缩短至641.55毫秒。这种性能提升并不足以抵消巨大的资源开销，这证实了在实时医学成像应用中，仅采用瓶颈级集成更为合适；而对于优先考虑最高精度而非效率的场景，多层级布局方案仍具有可行性。

5.4.3. 内核大小配置的影响

本实验基于ISIC2017数据集，旨在探究 DMSK 模块中不同核函数组合的效果。表8显示，小核与大核的组合能实现最佳性能（mIoU: 0.7980, Dice: 0.8876），显著优于仅使用小核（mIoU: 0.7629, Dice: 0.8638）或仅使用大核（mIoU: 0.7729, Dice: 0.8695）。结果表明，小核擅长捕捉精细的局部细节和精确的边界信息，而大核则能提供更优的全局上下文理解及长程空间依赖关系。单一尺度配置与组合方法之间的性能差距凸显了多尺度特征整合在医学图像分割任务中的重要性。这证明多尺度核函数整合能有效捕获互补信息：小核负责呈现精细节，大核则提供全局上下文信息。

表7

2017年 ISIC 上DSC块放置策略的性能与效率权衡分析。UNETR 架构被用作基准模型。仅关注瓶颈环节的集成方案在精度提升与计算开销之间实现了最优平衡。

配置	Attrs (M)	GFLOPs	推理时间 (毫秒)	骰子	NSD
基准	87.7	26.4	17.41	0.8499 ± 0.3328	0.8850 ± 0.3198
仅限瓶颈	87.9	26.5	47.19	0.8580 ± 0.3019	0.8930 ± 0.3164
所有级别	88.1	27.5	641.55	0.8625 ± 0.2950	0.8975 ± 0.3100

表8

基于UNet + DSC模型在ISIC2017数据集上的核尺寸消融研究。

配置	内核策略	mIoU	骰子	NSD
UNet + DSC	小粒与大粒；仅小	0.7980	0.8876	0.6423
		0.7629	0.8638	0.6418
	粒；仅大粒	0.7729	0.8695	0.6420

表9

针对伴有DSC阻滞的 UNETR 进行的组件消融研究。

数据集	DMSK	TTT	骰子	NSD
器官位于.....之中 腹部MRI	×	×	0.6867 ± 0.1488	0.7440 ± 0.1627
	✓	×	0.6943 ± 0.1408	0.7534 ± 0.1603
	×	✓	0.6965 ± 0.1538	0.7546 ± 0.1548
	✓	✓	0.6971 ± 0.1533	0.7576 ± 0.1653
仪器位于..... 内镜检查术	×	×	0.5017 ± 0.3201	0.5168 ± 0.3235
	✓	×	0.5038 ± 0.3148	0.5237 ± 0.2365
	×	✓	0.5042 ± 0.2785	0.5259 ± 0.2876
	✓	✓	0.5137 ± 0.3320	0.5275 ± 0.3302

5.4.4. 单个模块组件的影响

本实验评估了 DMSK 和 TTT 模块在腹部MRI (3D) 器官数据集及内镜检查 (2D) 器械数据集中的独立贡献。表9展示了各模块对分割性能的影响。在腹部MRI数据集上，基线 UNETR 模型获得 0.6867 ± 0.1488 (Dice) 和 0.7440 ± 0.1627 (NSD) 的分割指标；单独使用 DMSK 模块可提升至 0.6943 ± 0.1408 (Dice) 和 0.7534 ± 0.1603 (NSD)，而单独使用 TTT 模块则达到 0.6965 ± 0.1538 (Dice) 和 0.7546 ± 0.1548 (NSD)——其中 DMSK 通过自适应多尺度特征提取解决特征内部约束问题，TTT 则通过动态权重调整处理特征间约束。两模块联合使用时达到最优性能 (0.6971 ± 0.1533 Dice, 0.7576 ± 0.1653 NSD)。在内镜检查数据集上，各模块相较于基线模型均取得进步 (0.5017 ± 0.3201 Dice, 0.5168 ± 0.3235 NSD)：DMSK 实现 0.5038 ± 0.3148 (Dice) 和 0.5237 ± 0.2365 (NSD)，TTT 达到 0.5042 ± 0.2785 (Dice) 和 0.5259 ± 0.2876 (NSD)；两模块联合使用时表现最佳 (0.5137 ± 0.3320 Dice, 0.5275 ± 0.3302 NSD)。这些结果表明，两个模块均能提供互补性的增强效果，其整合后的性能在各种成像模式下均持续优于单一组件。

表10

基于 ISIC 2017数据集开展的消融研究，对比级联式与并行多尺度融合策略在 DMSK 中的表现。

方法	内核策略	mIoU	骰子	NSD
UNet + DSC	并行	0.7830	0.8827	0.6257
	级联 (我们的)	0.7980	0.8876	0.6423




图4：权重更新 ΔW_1 的奇异值谱，分别对应(a)具有挑战性的样本和(b)较简单的样本。在具有挑战性的样本中，较大的奇异值表明存在输入依赖性适应；而两种情况下的快速衰减则说明实现了针对性的低秩更新。

5.4.5. 多尺度融合策略的影响

为证明 DMSK 模块中核函数顺序 (级联) 应用的合理性，我们开展了一项消融研究，将其与并行多分支变体进行对比。在并行变体中，小尺度核 k_s 和大尺度核 k_b 会在输入特征拼接前独立处理。这种并行设计遵循了文献中常见的多尺度融合实践，但不同于我们在公式(8)中的递归聚合方法——后者通过先处理局部细节再整合更广泛上下文的方式实现层次化细化。实验在 ISIC 2017数据集上进行，采用UNet作为基线骨干网络并集成DSC机制。如表10所示，级联策略在所有评估指标上均优于并行变体。这些改进表明，顺序融合能促进更有效的多尺度交互，从而实现更精细的局部特征处理。

来自 k 的特征用于指导全局上下文提取

在 k b方法中, 该方法特别适用于处理医学图像中不同尺度的病灶及复杂的边界特征。相比之下, 平行处理方式可能引入冗余信息且自适应细化程度较低, 从而导致特征整合效果欠佳。

6. 结论

我们的DSC模块将静态跳跃连接转化为自适应机制, 能够在推理过程中根据图像的独特特征进行响应。作为即插即用组件, 它无需任何修改即可无缝集成到现有的U型网络结构中。TTT被应用于跳跃连接, 实现了针对性的特征适配(如图4所示)。我们的研究突破了传统经验式网络设计的局限, 通过识别并解决跳跃连接机制的根本性缺陷。DSC模块通过自适应机制显著提升了跨层连接性, 展现出卓越的特征表征能力。这一方法在处理医学影像数据中存在的显著异质性时尤为宝贵。然而, 所有基于TTT的方法普遍存在一个共同局限: 动态自适应机制会引入固有的计算开销。TTT模块在推理阶段需要额外处理资源, 可能增加时间敏感型临床应用中的延迟。这种计算负担体现了现有TTT方法在自适应性与效率之间持续存在的权衡关系。未来的研究应优先开发计算效率高的TTT实现方案及轻量级动态适应策略。这些进展对于将自适应机制应用于现实临床场景至关重要——在实际应用中, 准确性与计算效率均具有决定性意义。

致谢

本研究获得中国国家自然科学基金重大项目(项目编号: 62495064)和中国国家自然科学基金青年项目(项目编号: 62206189)的支持。

参考文献

- [1] 奥拉夫·罗内伯格、菲利普·菲舍尔与托马斯·布罗克斯。U-net: 用于生物医学图像分割的卷积网络。收录于*国际医学图像计算与计算机辅助干预会议*, 第234–241页, 2015年。
- [2] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y Hammerla, Bernhard Kainz, 等。Attention U-Net: 学习胰腺的定位区域。arXiv预印本 arXiv:1804.03999, 2018。
- [3] 周宗伟、Mahfuzur Rahman Siddiquee博士、Nima Tajbakhsh与梁建明。Unet++: 一种用于医学图像分割的嵌套式U-Net架构。收录于《*医学图像分析深度学习国际研讨会*》, 第3–11页, 2018年。
- [4] 黄慧敏、林兰芬、童若峰、胡洪杰、张巧伟、岩本裕太郎、韩先华、陈延伟和吴健。Unet 3+: 一款用于医学图像分割的全规模连接型UNET模型。收录于ICASSP 2020-2020 IEEE国际声学、语音与信号处理会议 (ICASSP), 第1055–1059页, 2020年。
- [5] 何全松、邢德民、王凯申和何涛。Fuseunet: 一种适用于U型网络的多尺度特征融合方法。ICML, 267:22669–22685, 2025。
- [6] Mohammad Hesam Hesamian, Wenjing Jia, Xiangjian He 与 Paul Kennedy。医学图像分割的深度学习技术: 成就与挑战。数字成像杂志, 32(4):582–596, 2019。
- [7] 陈冰志、黄晓林、刘一树、张正、卢光明、周正和潘佳辉。基于注意力机制且抗噪的鲁棒医学图像分割方法。IEEE仪器与测量汇刊, 73:1–13, 2024。
- [8] 罗海英、何涛和张毅。n模式的稳定映射。人工智能评论, 57(5):120, 2024。
- [9] Xiang Li、Wenhai Wang、Xiaolin Hu 和 Jian Yang 提出的选择性核网络。该研究成果发表于2019年IEEE/CVF 计算机视觉与模式识别会议 (CVPR), 第510–519页。
- [10] Su Ru, Zhang Deyun, Liu Jinhuai 和 Cheng Chuandong。Msu-net: 用于二维医学图像分割的多尺度U-Net。Frontiers in Genetics, 12:639930, 2021。
- [11] 孔凌杰、魏巧玲、徐成明、陈涵和傅艳薇。Efcnet: 每种特征对小型医学对象分割都至关重要。arXiv预印本 arXiv:2406.18201, 2024年。
- [12] 我哋系陈健宁、永毅路、曲航宇、罗向德、Ehsan Adeli、王燕、卢乐、Alan L Yuille 同 Zhou Yuyin。Transunet: Transformer 架构为医学图像分割提供强大编码器。arXiv预印本 arXiv:2102.04306, 2021年。
- [13] 胡曹、王月月、陈乔伊、江东生、张晓鹏、田琪和王曼宁。Swin-unet: 一种用于医学图像分割的类UNET纯变换器。收录于欧洲计算机视觉会议, 第205–218页, 2022年。
- [14] 莫因·海达里、阿米尔侯赛因·卡泽鲁尼、米拉德·索尔塔尼、雷扎·阿扎德、埃赫桑·霍达帕纳·阿格达姆、朱利安·科恩·阿达德和多丽特·梅尔霍夫。论文标题: 《基于Transformer的层次化多尺度医学图像分割表示方法》。收录于《IEEE/CVF 计算机视觉应用冬季会议论文集》, 第6202–6212页, 2023年。
- [15] 达米安·福鲁尔、雷米·埃莫内特、艾丽莎·弗罗蒙、达米安·穆塞莱、阿兰·特雷莫和克里斯蒂安·沃尔夫。用于语义分割的残差卷积-反卷积神经网络。arXiv预印本 arXiv:1707.07958, 2017年。
- [16] 孙宇、王晓龙、刘壮、John Miller、Alexei Efros 和 Moritz Hardt。基于分布变化下的泛化能力: 采用自监督机制的测试时训练。收录于国际机器学习会议, 第9229–9248页, 2020年。
- [17] 孙宇、李欣浩、卡兰·达拉尔、徐佳瑞、阿琼·维克拉姆、张庚汉、扬·杜布瓦、陈新雷、王晓龙、桑米·科耶乔等人。《学习在测试时学习: 具有表达性隐藏状态的RNN》。arXiv预印本 arXiv:2407.04620, 2024年。
- [18] 荣周、郑庆元、严志玲、孙伟祥、张凯、李一伟、叶彦芳、李翔、何丽芳和孙立超。Ttt-unet: 通过测试时训练层增强u-net用于生物医学图像分割。arXiv预印本 arXiv:2409.11299, 2024年。
- [19] 徐佳书。Med-ttt: 一种用于医学图像分割的实时视觉训练模型。arXiv预印本 arXiv:2410.02523, 2024年。
- [20] 赵奇·杨、王亚楠与葛勇。Ttt4rec: 一种用于序列推荐快速适应的测试时训练方法。arXiv预印本 arXiv:2409.19142, 2024。
- [21] 戴蒙、邢博浩、黄新雷、刘艳然、周一军、余子桐、郑旭斌等人。scfusionttt: 基于测试时训练层的单细胞转录组学与蛋白质组学融合方法。arXiv预印本 arXiv:2410.13257, 2024年。
- [22] Su Ru, Zhang Deyun, Liu Jinhuai 和 Cheng Chuandong。Msu-net: 用于二维医学图像分割的多尺度U-Net。Frontiers in Genetics, 12:639930, 2021。
- [23] 杨进、邱佩杰、张一驰、Daniel S. Marcus 和 Aristeidis Sotiras。D-net: 一种采用动态特征融合的动态大型核方法, 用于医学三维图像分割。arXiv预印本