

利用深度卷积技术加速视觉基础模型的训练速度

卡梅洛·斯克里巴诺^{1*}，穆罕默德·马赫迪²，内迪亚尔科·普里萨德尼科夫²，玉泉傅²、乔治娅·弗兰基尼¹、丹达·帕尼·保德尔²、马尔科·贝尔托尼亚¹、
卢克·范古尔²

¹ 摩德纳和雷焦艾米利亚大学，意大利摩德纳。

² INSAIT：索菲亚大学“圣克莱门特·奥赫里德斯基分校”，保加利亚索菲亚
{name.姓氏}@insait.ai

摘要。预训练视觉基础模型仅需少量微调即可在各类任务中展现出优异性能。然而，其基于Vision Transformer (ViT) 的骨干网络会带来较高的推理成本，限制了其在资源受限设备上的应用。本研究通过利用部分注意力头固有的卷积特性，在保持特征提取能力的同时实现了大规模预训练ViT模型的加速运行。

具体而言，我们提出了一种高效的基于深度卷积的神经网络层，可直接替代现有各类头部模块。同时，我们设计了简易策略以识别可替换的头部模块，并开发了能恢复下游任务性能的微调方案。在图像分类和分割任务中，我们的方法均实现了17%-20%的推理速度提升，且性能损失极小。通过详细的数学推导、大量实验及性能基准测试，我们验证了该方法的有效性。相关参考实现代码已公开发布¹。

关键词：高效注意力 · Edge Inference · 视觉变换器

1 引言

大规模预训练视觉Transformer (ViT) ([11]) 已成为现代机器学习领域的一种强大范式。仅需少量微调，它们就能在广泛的下游视觉任务中表现出色。主流范式包括DINO ([5,29])、MAE ([16]) 和CLIP ([31])。其显著缺点在于ViT架构的推理成本较高，尤其在针对低功耗边缘设备进行推理时更为明显。尽管已有多种方法被提出以降低ViT的推理成本，但仍存在若干挑战。主流方法通过减少令牌数量 ([2,27,12]) 来实现这一目标，但这会破坏特征的空间结构并限制其在密集预测场景中的适用性。

* 访问 INSAIT 期间完成的工作

¹ https://github.com/cscribano/DWConv_VFM

2 C. 斯克里巴诺等人。

任务（即分割）。另一种常见情况是依赖动态条件执行流程或动态形状张量，而这些特性很少被高性能推理框架支持。此外，对于微调基础模型而言，保留大规模预训练权重至关重要，而这在高效的Transformer骨干网络中通常难以实现 ([4,26,40])。




图1：所提出的即插即用近似的示意图。我们用深度卷积(b)替换了注意力机制(a)，这在保持预训练网络参数性能的同时提升了推理速度。

为应对这些挑战，本文提出了一种高效且可直接部署的*基础视觉Transformer (ViT) 加速方法*。基于先前研究 (2.2节)，我们假设多个多头自注意力 (MhSA) [38]头能够学习高度局部化、静态化的模式，其结构与卷积层极为相似。我们建议用针对重构后的价值张量（图1）实施更高效的深度卷积运算，来替换经过精心挑选的一组计算密集型自注意力操作单元。该方法作为即插即用式替代方案，在仅需少量微调的情况下即可恢复大规模预训练模型的性能表现，同时实现17%至20%以上的加速比且性能损失极小。本研究的主要贡献可总结如下。

- 我们推导出一种高效公式，可直接替代那些学习特定卷积结构的注意力头。随后我们证明，源自[15]的研究成果中的头部集成方法可以被明确化并推广至我们的应用场景，并能受益于这种更高效的公式化表达。
- 我们提出了一种简明的方法论，用于识别需通过卷积近似的头部特征。同时，我们针对为此情境重新构建的更复杂解决方案，验证了所提出的启发式方法的有效性。
- 我们明确研究了在预训练基础模型背景下进行性能优化的问题，针对实际部署场景，重点聚焦于一款主流边缘平台设备 (Nvidia Orin Nano) 及合适的推理框架 (TensorRT)。

我们认为，本研究提出的成果解决了文献中仅部分涉及的诸多挑战，并为从不同角度审视视觉基础模型的性能提升提供了新视角，这一视角未来或可融入更先进的剪枝框架之中。

采用深度卷积插值技术加速视觉基础模型的训练（版本3）

2 相关工作

2.1 变压器的修剪

通过消除次要参数、连接和层来降低神经网络复杂度的想法可追溯至深度学习早期 ([21,14])。类似技术虽适用于BERT[10]风格的Transformer模型 ([35,6,3])， 但会引入*非结构化*稀疏性，常因不规则内存访问导致额外开销。部分研究通过块稀疏性方法部分解决了这一问题 ([20,43])； 注意力头的结构化剪枝在[28]中得到探索，而[39]则提出了训练过程中采用随机门控选择注意力头的方法。在此基础上， [1] 该方法通过置信度评分早期识别可修剪节点， 而DSP[22] 则对剪枝比例引入了显式控制。针对ViT模型的多种剪枝方法都需要访问训练数据 ([30,23])， 其他方法则依赖蒸馏技术 ([47,44])。许多方法专注于利用预训练的DeiT模型 ([37]) 进行分类任务 ([48,47,15,23])。SPViT[15]在微调过程中将MhSA模块剪枝为基于[7]充分条件构建的学习卷积层，该假设实际上将该模块简化为单一卷积单元。相比之下，我们推导出适用于预训练基础模型的更通用公式，并进一步证明SPViT如何作为我们框架中的特例出现。Lambda-ViT ([23]) 则在转移熵度量的引导下，逐步将MhSA模块退化为恒等映射。这两种方法均适用于分类任务的DeiT骨干网络。

2.2 注意力建模作为卷积运算的一种形式

多项研究探讨了卷积神经网络与注意力机制所学习的空间关系之间的相似性。[32]指出两者学习到的模式存在显著差异， 尽管某些浅层注意力头主要关注局部特征。[18]进一步深入探讨了注意力机制捕捉局部模式的能力，并强调了位置编码在学习空间连接性中的作用。[7]我们从构造性角度证明：在严格假设条件下，若每个注意力头都能关注卷积核尺寸区域内特定位置，则MhSA模块即可实现卷积层的功能。正如作者所指出的，在实际应用中这仅是充分条件，我们将在3.2节进一步探讨这一观点。对本研究具有重要影响的文献[13]深入探讨了注意力机制（局部）与深度方向（DW）卷积之间的关系，并揭示了关键特性——这些特性将在3.3节中得到进一步阐述。

2.3 其他方法

令牌缩减方法 [33,46,25,2]的目的在于通过移除或聚合操作来减少Transformer处理的令牌数量。这些方法存在明显局限性：令牌缩减会破坏空间结构，因此不适用于分割或深度估计等高密度预测任务；此外，依赖聚类、聚集/分散操作或动态形状处理的技术往往难以有效应对此类挑战。

4 C. 斯科里巴诺等人。

这会给专用推理框架带来显著的开销。*高效注意力机制*研究提出了注意力层的替代性设计方案以降低计算复杂度 ([36,42,45])。这些方法通常并非旨在直接替代预训练视觉Transformer模型——在该场景下，保持预训练权重和模型行为特性至关重要，而从头重新训练则不切实际。其他研究方向则聚焦于对密集型运算进行算法与实现层面的优化，以充分发挥硬件性能优势，典型代表便是Flash-Attention ([9,8])。

3 研究方法

3.1 背景

视觉变换器与MhSA。ViT的输入定义为：将图像 $I \in \mathbb{R}^{H \times W \times 3}$ 分割为大小为 $p \times p$ 的非重叠块，将每个块展平为 $\mathbb{R}^{3p^2}$ 空间中的向量，并将其投影到 d 维嵌入空间。假设 $\frac{H}{p} = \frac{W}{p}$ 该模型由 n 个补丁嵌入向量组成的 $= \sqrt{n}$, this yields an input tensor $X \in \mathbb{R}^{n \times d}$ 矩阵，并附加位置编码。包括DinoV2在内的大多数实现方案均会在序列前添加[cls]标记，但本文暂不考虑该标记。整个序列通过交替使用多头自注意力（MhSA）和前馈层的Transformer模块进行处理。设 n_h 为注意力头的数量，MhSA由 W^Q 、 W^K 、 $W^V \in \mathbb{R}^{d_i \times (n_h * d_h)}$ 以及 $W^O \in \mathbb{R}^{(d_h * n_h) \times d_o}$ 参数化，其中通常 $d_i = d_o = d$ 且 $d_h * n_h = d$ （我们从现在起均以此假设）。将第 h 个注意力头的查询项、键值和数值定义为：

$$Q^h = XW_{[:,h,:]}^Q, K^h = XW_{[:,h,:]}^K, V^h = XW_{[:,h,:]}^V$$
 (1)

对于第 h 个头，注意力值计算公式如下：

$$Att(X)^h = E(X)^h V^h$$
 (2)

$$E(X)^h = softmax \left(\frac{Q^h K^{h\top}}{\sqrt{d_h}} \right)$$
 (3)

其中 $E(X)^h \in \mathbb{R}^{n \times n}$ 为注意力（能量）矩阵。将各头模块的输出连接起来即可得到完整的MhSA输出：

$$MhSA(X) = [Att^1(X) \parallel \dots \parallel Att^{n_h}(X)]W^O$$
 (4)

其中 $\parallel$ 表示沿嵌入维度进行拼接。

卷积层。一个具有核大小 k 的卷积层由权重 $W^C \in \mathbb{R}^{k \times k \times c_i \times c_o}$ 参数化。具体而言，其对称平移集合的尺寸为 $k \times k$ 。

采用深度卷积插值技术加速视觉基础模型的训练（第5篇）

由于 $\Delta_k = \{(s, r) \in \mathbb{Z}^2 : -k/2 \leq s, r \leq k/2\}$ （假设步长因子为1），输入 $X \in \mathbb{R}^{h \times w \times c_i}$ 在位置 (i, j) 处的输出定义为：

$$\text{Conv}(X, W^C)_{i,j} = \sum_{(r,s) \in \Delta_k} W_{r,s}^{C \top} X_{i+r,j+s} \quad (5)$$

因此，卷积运算可生成以点 (i, j) 为中心的、基于 $k \times k$ 邻域的加权局部聚合结果。类似地，深度卷积通过分别对每个通道独立应用不同的空间滤波器来实现局部聚合。利用 $W^D \in \mathbb{R}^{k \times k \times c_i}$ ，我们可表示为：

$$\text{Conv}_{DW}(X, W^D)_{i,j} = \sum_{(r,s) \in \Delta_k} W_{r,s}^D \odot X_{i+r,j+s} \quad (6)$$

其中 $\odot$ 表示逐元素乘法。

3.2 卷积近似

在本节中，我们系统阐述了如何通过卷积来近似注意力机制，并提出了构成我们方法核心的高效深度分解方案。随后我们将证明，SPViT[15]瓶颈模块正是我们该框架的一个特例，并通过头部集成技术进行了扩展。

直接深度公式化。考虑如公式（2）所示的单个注意力头。为清晰起见，我们对输入 $X \in \mathbb{R}^{n \times d}$ to $X \in \mathbb{R}^{m \times m \times d}$ with $m = \lceil n/h \rceil$ 进行重塑以恢复空间结构，因此 $E(X)^h \in \mathbb{R}^{n \times n}$ can be viewed as $E(X)^h \in \mathbb{R}^{(m \times m) \times (m \times m)}$ ，and the values as $V^h \in \mathbb{R}^{m \times m \times d_h}$ 。在书写二维索引时，我们始终指代这些未展平的张量。位置 (i, j) 处注意力函数的显式形式为：

$$\text{Att}(X)_{i,j}^h = \sum_{(r,s) \in \Delta_m} E^h(X)_{(i,j),(i+r,j+s)} V_{i+r,j+s}^h \quad (7)$$

其中 Δ_m 表示覆盖整个 $E(X)^h$ 的完整感受野。这类似于卷积运算，但存在关键差异：用于空间聚合的权重 $E^h(X)_{(i,j),(i+r,j+s)}$ 既取决于输入 X 也取决于查询位置 (i, j) ，而卷积核则是跨位置共享的固定参数。

我们通过假设某些头部可以被与输入无关的核函数所替代（这些核函数仅限于局部邻域 $\Delta_k \subset \Delta_m$ ）来近似注意力机制。形式上，对于头部 h ，我们表示为：

$$\text{Att}(X)_{i,j}^h \approx \sum_{(r,s) \in \Delta_k} K_{r,s}^h V_{i+r,j+s}^h \quad (8)$$

其中 $K^h \in \mathbb{R}^{k \times k}$ 为在微调过程中学习得到的可训练参数。

6 C. 斯克里巴诺等人。

全卷积表达式。直接实现公式（8）的方法是将 K^h 折叠到值投影 W^V 中，从而生成核函数 $W^{Vh} \in \mathbb{R}^{k \times k \times d_i \times d_h}$ ：

$$\tilde{\text{Att}}_C(X)^h = \text{卷积}(X, W^{Vh}) \quad (9)$$

$$W_s^h = K_{r,s}^h W_{[:,h,:]}^V, \quad (r, s) \in \Delta_k \quad (10)$$

尽管该表述是等式（8）的忠实对应形式，但从复杂性角度来看并不理想，如第4.2节所述。

深度分解。为降低计算成本，我们将逐点值投影与空间聚合过程分离。首先计算值 $V^h = XW_{[:,h,:]}^V$ ，随后使用针对头部特征的核函数 $K^h \in \mathbb{R}^{k \times k \times 1 \times d_h}$ 进行深度卷积：

$$\tilde{\text{Att}}_{DW}(X)^h = \text{Conv}_{DW}(V^h, K^h) \quad (11)$$

与全卷积相比，其复杂度从 $O(k^2 d_i d_h)$ 降低至 $O(d_i d_h + k^2 d_h)$ 。在完整公式（公式(9)）中，每个 K^h ， s 会在所有 d_h 通道中共享，从而强制采用单一空间模式；而深度方向核 K^h 则为每个通道提供一个 $k \times k$ 滤波器，实现不同的空间聚合效果。虽然通道级共享易于实现，但我们在此不作限制且不影响性能。该层可替代MhSA模块（4）中的任意注意力头子集，其实现方式如图1所示，并已在实验部分进行了全面评估。

头部集成。[15]中的表述基于[7]的充分条件，其中每个头部仅关注局部邻域内的特定空间位置。这一假设隐式地强制实现了退化的头部集成机制，导致MhSA模块坍缩为单一有效头部。相比之下，我们显式推导了集成方法，并证明其适用范围超越完整的卷积架构。具体而言，通过赋予可学习的组合权重 $\gamma \in \mathbb{R}^{n_h}$ 来控制各头部的贡献度，集成后的输出值与投影结果可表示为：

$$W^{Ve} = \sum_{h=1}^{n_h} \sigma(\gamma_h) W_{[:,h,:]}^V, \quad W^{Oe} = \sum_{h=1}^{n_h} \sigma(\gamma_h) W_{[:,h,:]}^O, \quad (12)$$

使用 $\sigma(\cdot)$ 对头部区域施加softmax函数。关键在于，这种显式的集成方法可自然地扩展到我们的深度方向建模框架中：

$$\tilde{\text{MhSA}}_{DW}^e(X) = \text{Conv}_{DW}(V^e, K^e) W^{Oe} \text{ s.t. } V^e = XW^{Ve} \quad (13)$$

且 K^e 表示如公式（11）所示的深度卷积核。从这一角度来看，[15]它作为我们框架的一个特例而出现。此后，我们将集合化表述（公式(13)）与非集合化表述（通过公式(11)直接进行头部替换）区分开来。

采用深度卷积插值技术加速视觉基础模型的训练（第7篇）

3.3 图层选择

给定一个需要通过卷积近似的 p_h 个头单元目标时，选择方式可以是分散式（在模型中随机替换任意头单元），或块状式（替换 p_b 个MhSA模块内的所有 n_h 个头单元）。如第4.3节所示，块状策略能带来更高的推理效率，因此我们将其作为默认方案。下文将介绍定义头集 $\mathbf{S}$ 的两个标准，这两个标准均适用于两种选择模式。

提出的标准。如前所述，在公式（8）中引入的 $E(X)^h$ 的近似表达式，在局部性（L）、平移不变性（TI）和输入不变性（II）条件下等价于真实注意力机制。对于感受野 Δ_k 及位移量 $(\mathbf{s}, \mathbf{r}) \in \Delta_k$ ，其表达式如下：

$$\left\{ \begin{array}{l} \text{(L)} : E(X)_{(i,j),(u,v)}^h \neq 0 \text{ only if } (u-i, v-j) \in \Delta_k \end{array} \right. \quad (14a)$$

$$\left\{ \begin{array}{l} \text{(TI)} : E(X)_{(i,j),(i+s,j+r)}^h = E(X)_{(l,t),(l+s,t+r)}^h \quad \forall (i,j), (l,t) \end{array} \right. \quad (14b)$$

$$\left\{ \begin{array}{l} \text{(II)} : E(X)^h = E(Y)^h \quad \forall X, Y \end{array} \right. \quad (14c)$$

标准定义 我们通过实证研究证明， $E(X)^h$ 的逐点标准差之和可作为识别类卷积头的一种简单有效替代指标。具体而言，对于每个头 $h \in \{1, \dots, N_h\}$ （其中 $N_h = n_h n_b$ 表示跨 n_b 个块的头部总数），我们计算 $E(X)^h$ 在 N_s 个输入样本上的逐点标准差 σ_{E^h} 。直接计算 σ_{E^h} 并不现实，因为对合理输入集（即 $N_s=1000$ ）累加 $E^h(\mathbf{x}_i)$ 需要超过500GB内存空间。我们采用Welford算法[41]在线单次计算 σ_{E^h} ，随后定义一个标量评分。

$$\Sigma_h = \sum \sigma_{E^h}, \quad (15)$$

对 E^h 的所有条目求和。我们选择具有最小 Σ_h 值的 p_h 个头组成的集合 $\mathcal{S}_h^{[p_h]}$ 作为候选头部。在块级设置中，我们在块级别采用相同的准则：对于每个块 $b \in \{1, \dots, n_b\}$ ，我们计算其 n_h 个头部的平均得分。

$$\Sigma_b = \frac{1}{n_h} \sum_{h \in [n_h]} \Sigma_h, \quad (16)$$

并选择具有最小 Σ_b 的 p_b 个块组成的集合 $\mathcal{S}_b^{[p_b]}$ 。

理论依据 根据构造， $\Sigma_h=0$ 是满足输入不变性性质（公式14c）的必要且充分条件。当 $\Sigma_h \rightarrow 0$ 时，核函数会收敛至其期望值 $E^h(X) \rightarrow \mu_{E^h}$ ，从而消除对输入的依赖性。我们的启发式方法基于以下观察：输入不变性是最严格的性质——一旦实现，它将迫使网络头部完全忽略输入变化，并退化为仅处理位置信息的操作器。在此状态下， $E^h(X)$ 仅由

8 C. 斯克里巴诺等人。

标准视觉Transformer（ViT）中各头单元共享的习得位置编码。位置注意力机制与空间连接模式（区域关联）存在关联。[18]），捕捉了卷积归纳偏置所蕴含的局部性及类翻译结构特征。因此，我们采用 Σ_h 作为启发式方法，其依据是输入不变性原理，但最终仍基于经验验证。

随机门控。作为现有标准的替代方案，我们提出将其与源自可微子集剪枝（DSP）[22]的选择方法进行比较。虽然DSP最初用于剪枝变换器头，但我们可轻松将其推广至本研究场景。为简化说明，我们在此以块处理方式阐述该机制，但其可轻松扩展至分散选择场景。我们定义一组可训练参数 $\mathbf{w}^b$ 和 n_b ，并利用 $\text{topk}(\cdot)$ 运算符提取 $\mathbf{w}^b$ 中最大的 p_b 个元素：

$$\text{topk}(\mathbf{w}^b, p_b)_i = \begin{cases} 1 & \text{if } i \in \mathcal{S}_b^{[p_b]} \\ 0 & \text{otherwise} \end{cases} \quad (17)$$

定义 $\overline{\mathbf{w}^b} = \text{topk}(\mathbf{w}^b, p_b)_i$ 后，我们可以在前向传播过程中实现一个简单的门控机制来选择所选操作：

$$\overline{MhSA^i}(X) = (1 - \overline{w_i^b}) MhSA(X)^i + \overline{w_i^b} \tilde{M} SA(X)^i \quad (18)$$

该公式仅需略微增加参数数量且不引入额外的损失项。由于 topk 算子不可微，在训练过程中学习 $\mathbf{w}^b$ 时，采用Gumbel top-k松弛方法[19]——这是Gumbel softmax技巧[17]的一种扩展形式，能够提供可微分的近似解。 $\tilde{w}^b$ 是硬选择参数 $\overline{\mathbf{w}^b}$ 的值，由温度 τ 控制。当 $\tau \rightarrow 0$ 时， $\tilde{w}^b$ 接近 $\overline{\mathbf{w}^b}$ ；我们遵循DSP作者提出的 τ 退火方案。

4 实验与比较

4.1 实验设置

除非另有说明，我们的分析均基于针对多种下游任务进行微调的Dino-V2（[29]）模型。这一选择有助于简化结果讨论。在4.2节中，我们证明使用其他视觉基础Transformer骨干网络时也能获得类似结果。

基准测试。为反映实际部署环境，我们主要在Nvidia Jetson Orin Nano平台上针对TensorRT进行测试，以评估其推理性能。与通用框架（如PyTorch）不同，TensorRT将模型编译为优化的GPU内核，从而突显现实场景中的性能限制。

任务性能。我们针对微调模型在语义分割（COCO[24]、ADE20K[49]）和分类（ImageNet-1K[34]）任务上进行评估。为支持插值卷积操作，我们从输入数据中移除了[cls]标记；对于分割任务此操作无影响；而对于分类任务，我们使用标记的均值作为解码器输入，且性能损失可忽略不计。所有任务中的卷积层均采用固定核尺寸 $k=3$ 以提升计算效率。

采用深度卷积插值技术加速视觉基础模型的训练（第9篇）

4.2 卷积注意力机制的应用效果

头部级性能分析。在表1中，我们对单个多头注意力模块进行了性能分析，为量化性能差异提供了直观的基准。无论是在非集成场景（第2-3行）还是集成场景（第4-5行）中，深度方向的计算方式均更具优势：相较于全卷积结构，其执行速度提升了×3倍。集成计算方式虽然运行速度显著更快，但如本章后续所述，会导致性能下降更为明显。内存使用模式则较难直观理解：可分离计算方式因中间结果的存在及缓冲区复用效率较低而需要更高的内存资源，这一劣势在集成计算方式中得到了缓解。

表1：MhSA模块不同配置方案的比较。所有结果均针对单个MhSA模块（ $n_h=16$ 个单元头，输入尺寸为24 × 24图像块；相当于Dino-V2模型的336 × 336图像分辨率）进行计算。批量大小设定为1。

注意；关心	浮点运算次数(G)	参数(M)	推理时间（毫秒)	内存占用（MB)
MhSA (Eq. (4))	6.19	4.2	3.2	47.2
凸 _[a11] (等式(9))	12.08	2.1	3.71	4.5
DW _[a11] (等式(11))	2.43	2.11	1.26	6.75
SPViT-风格 ([15])	0.75	2.1	0.641	4.5
Ens+DW (Eq. (13))	0.15	2.1	0.215	0.288

完整模型性能。除非另有说明，我们首先使用常规MhSA头对目标任务进行微调，随后将选定的头替换为卷积层，并对半数训练轮次进行新的微调。完整的实验设置详见附录。表2展示了采用不同MhSA模块配置方案所得结果的对比。所有实验均采用第3.3节提出的基于模块选择的标准差评估准则。尽管未追求最先进性能，但Dino-V2特征的强大表现使得我们的基线结果极具竞争力。延迟数据仅针对ViT主干网络报告，以避免受解码器设计选择的影响。

评估 首先我们确认深度方向公式化方法与全卷积网络（CL2–CL3）的性能一致，这与我们的分析推导结果相符，同时在推理速度上实现了显著提升。未采用头部集成时，全卷积基线模型比MhSA（CL1）慢7.5%，而深度方向变体则实现17.2%的速度提升。为与集成方案进行公平比较，我们将|S|的配置设置调整至具有相似观测加速效果的参数值。

10 C. 斯克里巴诺等人。

|S|：未集成情况下为12/24个块，集成情况下为10/24个块。在此设置下，深度方向非集成方法（CL3）相较于SPViT风格的全卷积集成模型准确率下降幅度更小（-0.08 vs. -0.98 mIoU），同时仍具备适度的速度提升优势。当与头部集成方法结合时（CL5），该深度方向方案可实现18.8%的速度提升，但代价是mIoU值下降幅度增大至-1.6。将|S|增加至16/24和12/24时（CL6–CL7），也观察到相同的权衡关系。在较小规模的ViT-B骨干网络（CB1–CB3）及ImageNet分类任务（IL1–IL5）中均获得可比结果，这证实了这些观察结果在不同模型规模和异构任务中具有一致性。关于ViT-B及ADE20K数据集的更多结果详见表3。

表2：不同参数设置下COCO和Imagenet数据集的实验结果。结果基于Dino-V2模型在输入分辨率336 × 336下的微调结果获得。推理性能数据采用批量大小为1的情况呈现。

身份证	任务	维持	注意；关心	S	我的爱	δ-mIoU	推断（毫秒)	加速率（%）
CL1	可可	大的	医学科学学士	-	66.03	(底线)	161.4	(底线)
CL2			转 换 为 [a11]	12/24	65.84	-0.19	173.5	-7.49
CL3			DW [a11]	12/24	65.95	-0.08	133.6	17.21
CL4			SPViT-样式	10/24	65.05	-0.98	133.3	17.40
CL5			Ens + DW	10/24	64.81	-1.61	131.1	18.79
CL6		基础	DW [a11] 本	16/24	64.64	-1.39	126.1	21.85
CL7			体 + DW	12/24	63.92	-2.11	124.5	22.87
CB1			MhSA DW [a	-	63.37	(底线)	49.9	(底线)
CB2			11] 基本值 +	6/12	62.22	-1.16	40.8	18.10
CB3			DW	6/12	60.55	-2.83	38.1	23.52
身份证	任务	维持	注意；关心	S	排名第一的账户。	δ-Acc	推断（毫秒)	加速率（%）
IL1	图像网络	大的	医学科学学士	-	86.22	(底线)	161.4	(底线)
IL2			DW [a11] 本	12/24	85.45	-0.77	133.6	17.21
IL3			体 + DW	10/24	84.96	-1.26	131.1	18.79
IL4			DW [a11] 本	16/24	84.88	-1.34	126.1	21.85
IL5			体 + DW	12/24	84.65	-1.57	124.5	22.87

泛化能力。我们通过评估CLIP ([31]) 和MAE ([16])，检验了我们的方法在超越Dino-V2框架时对骨干模型的泛化性能。尽管这两种模型的预训练目标不同，但均采用相同的ViT基础架构，因此无需修改即可复现相同的训练设置。针对每个模型，我们分别评估了ViT-Base和ViT-Large两种变体，其图像块尺寸分别为/16和/14。结果详见表4。我们采用未集成的块选择方案，并运用Σ_b准则确定块集合。通过对比未使用降维卷积（即|S|=一）的相同骨干网络，发现mIoU指标显著下降，这与Dino-V2实验结果一致，进一步验证了我们的降维方案在不同视觉基础模型中具有普适性。

表3：采用深度方向（Depthwise）公式化方法在不同任务中的实验结果。

任务	维特	注意：关心	$ S $	我的爱
图像网络	基础	医学科学学士	-	83.76
		DW[全部]	6/12	82.00
任务	维特	注意：关心	$ S $	我的爱
ADE20K	基础	MhSA	-	53.83
		DW [全部]	6/12	51.70
	大的	DW [全部]	12/24	56.05

表4：应用于MAE和CLIP模型并在COCO语义分割数据集上微调的深度建模方法评估。

模型主干 $ S $ mIoU 推断（毫秒）				
平均绝对误差	ViT-B/16	-	58.84	42.95
平均绝对误差	ViT-B/16	6/12	57.91	35.04
平均绝对误差	ViT-L/16	-	60.22	122.47
平均绝对误差	ViT-L/16	12/24	59.81	102.23
剪辑：片段	ViT-B/16	-	61.52	42.93
剪辑：片段	ViT-B/16	6/12	59.06	35.07
剪辑：片段	ViT-L/14	-	64.65	153.91
剪辑：片段	ViT-L/14	12/24	62.17	128.38

4.3 选择机制的结果

表5：筛选机制比较。

批评。				阶段	BW	$ S $ mIoU	批评。				BW分期	$ S $	我的爱
Σb [最低级]DSP-	2			12/24	65.95		$\Sigma \eta$ [最低级]DSP-	2			192/384	65.52	
端到端	2	是		12/24	64.15		端到端	2	不		192/384	62.32	
DSP - 2S	3			12/24	64.00		DSP - 2S	3			192/384	65.79	
Σb [最低级]DSP-	2			17/24	63.77		Σb [最高]	2			12/24	61.46	
端到端	2	是		17/24	58.25		Σb [最高] Σb [最	2	是		7/24	64.02	
DSP - 2S	3			17/24	64.20		低]	1			12/24	65.63	

(a) 块处理场景下 Σ_b 与DSP的比较

(b) （上图）散射场景中 Σ_h 与DSP的对比；（下图） Σ_b 的消融实验：选取最差候选项（ Σ_b [最高值]）并进行单阶段微调。

我们首先讨论分块选择与分散选择的影响。对于分块选择而言，精确子集 S_b 对观测到的加速效果没有影响；而在分散设置中， $S_h^{[p_h]}$ 的分布则具有重要影响。分散头部选择会导致加速效果随选定头部数量的增加呈非线性增长（这源于内存开销和多核执行带来的额外成本），从而抵消部分性能提升。这种对模型性能的影响在图2中清晰可见：分块选择始终表现更优，且仅导致轻微性能下降（表5）。

比较。在表5中，我们将提出的选择启发式方法（第3.3节）与可微分子集剪枝（DSP，第3.3节）进行了比较。对于后者，




图2：基于块式与分散式配置下加速比与替换头数量的关系。结果基于ViT-L模型（24个块，每块16个头，尺寸为336 × 336）。




图3：在块处理设置中使用DSP和 Σ_b 准则选择的区块。

我们同时评估了选择门的端到端训练方法（DSP-e2e，公式18）以及两阶段变体方法（DSP-2S）——后者将学习得到的参数集在固定选择条件下重新用于新的微调过程，并丢弃端到端权重。在块级设置（表5a）中，当 $|S|=12/24$ 时， Σ_b 准则的表现优于DSP；而DSP-2S仅略微缩小差距，仍落后近2个mIoU点。进一步分析（图3）表明，DSP常选择高方差头；当 $|S|=17/24$ 时，DSP-2S略优于 Σ_b ，而DSP-e2e则存在严重的训练不稳定性且性能下降。

消融实验。为进一步验证我们的评估标准，我们还评估了替换表5b中表现最差的头部单元（即 Σ_E 值最高者）的效果。仅替换7个块时，性能下降幅度已超过替换最佳12个块的情况；而替换全部12个最差块则会导致性能显著恶化。最后，我们对微调流程进行了消融测试（最后一行）：采用单阶段微调（直接应用卷积运算）即可获得接近双阶段设置的性能水平。

5 结论与未来研究方向

我们评估了针对大规模预训练视觉Transformer（ViT）中呈现卷积类行为的注意力头所采用的简易替换方案的有效性。该框架实现了17%的速度提升，且对下游性能影响极小，这表明许多预训练注意力头可通过高效的深度卷积运算进行近似处理，同时不会丧失其功能特性，从而充分保留预训练权重的优势。所研究的方法并非现有剪枝技术的替代方案，而是一种可与现有解决方案有效结合使用的组件。

致谢本研究部分由dAledge项目（项目编号：horizon-CL4-2022-human-02-02，资助协议号：101120726）及保加利亚教育与科学部（对 INSAIT 的支持，属于保加利亚国家科研基础设施发展路线图的一部分）资助。