


核心速览



论文题目: Accelerating Vision Foundation Models with Drop-in Depthwise Convolution

中文题目: 利用即插即用深度卷积加速视觉基础模型

论文链接:

<https://arxiv.org/pdf/2605.22132>

所属单位: 意大利摩德纳与雷焦艾米利亚大学, 保加利亚索非亚“圣克莱门特·奥赫里德斯基”大学

核心速览:

本文针对预训练视觉 Transformer (ViT) 推理成本高、难以部署在边缘设备的问题, 提出**即插即用的深度卷积替换层**, 将具备类卷积特性的多头自注意力头替换为**高效深度卷积**, 通过注意力矩阵标准差筛选可替换模块、**分块替换提升效率、轻量化微调恢复性能**, 在图像分类与语义分割任务中实现 17%–22.87%推理加速, 性能损失仅 0.08–2.11 mIoU/0.77–1.57% Top-1 准确率, 可通用适配 DINOv2、CLIP、MAE 等主流视觉基础模型, 在 NVIDIA Jetson Orin Nano+TensorRT 场景验证了落地可行性。

<https://mp.weixin.qq.com/s/BKFHero23Nz5T4Gw7Z828g>

```
DWConvAttention(  
    (qk_conv): Conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), groups=32, bias=False)  
    (v_proj): Linear(in_features=32, out_features=32, bias=False)  
    (attn_drop): Dropout(p=0.0, inplace=False)  
    (proj): Linear(in_features=32, out_features=32, bias=True)  
    (proj_drop): Dropout(p=0.0, inplace=False)  
)
```

维度验证:

输入形状: `torch.Size([2, 1024, 32])`

输出形状: `torch.Size([2, 1024, 32])`

哔哩哔哩/微信公众号: AI缝合术, 独家整理!