

愿景目标：基于科尔莫戈罗夫-阿诺德网络构建无注意力机制的视觉核心架构

杨卓琴^{1,2}、张建松¹、罗晓玲¹、吴旭¹、卢正²、沈琳琳³

¹深圳大学计算机科学与软件工程学院，中国深圳

²中国宁波诺丁汉大学计算机科学学院

³深圳大学人工智能学院，中国深圳

摘要

注意力机制因其能够建模长距离依赖关系，已成为现代视觉网络骨干架构中的关键组件。然而，其随序列长度增加而呈现的二次复杂度以及注意力权重的解释难度，限制了其可扩展性与清晰度。近期无注意力架构的研究表明，在不使用成对注意力机制的情况下仍能实现优异性能，这推动了寻找替代方案的需求。本文提出Vision KAN (ViK)——一种受Kolmogorov-Arnold网络启发的无注意力骨干架构。其核心在于MultiPatch-RBF-KAN模块：该统一标记混合器融合了(a)基于径向基函数的KAN网络实现的块级非线性变换；(b)支持高效局部传播的轴向可分离混合机制；以及(c)用于实现长距离交互的低秩全局映射。通过采用轻量级运算单元进行块级分组以重建跨块依赖关系，该架构可有效替代传统注意力模块，从而解决全KAN网络在高分辨率特征处理中面临的计算成本过高问题。ImageNet-1K上的实验表明，ViK在保持线性复杂度的同时实现了具有竞争力的准确率，证明了基于KAN的标记混合方法作为注意力机制的一种高效且理论基础扎实的替代方案所具有的潜力。代码：<https://github.com/SeriYann/ViK>

索引术语— 科尔莫戈罗夫-阿诺德网络、无注意力视觉骨干网络、标记混合。

1. 引言

近年来，视觉模型架构领域主要以注意力机制为基础。视觉Transformer (ViT) [1]通过将图像建模为具有自注意力机制的补丁序列，其性能已能与卷积神经网络相媲美甚至超越后者，从而确立了注意力机制作为通用视觉

建模工具的地位。后续研究进一步拓展了这一方向：数据高效图像Transformer (DeiT) [2]提升了训练效率与实用性；而金字塔视觉Transformer (PVT) [3]则引入了带有空间降维功能的分层特征图，实现了Transformer与多尺度表征之间的有效融合。

尽管自注意力机制取得了显著成功，但其仍存在两大主要局限：首先，其计算复杂度和内存消耗随标记数量的增加呈二次增长趋势，导致在高分辨率图像场景下扩展应用成本高昂[4]；其次，自注意力机制中的标记间亲和矩阵与语义或结构特征缺乏直接关联，限制了模型的可解释性[5]。这些局限性推动了无注意力骨干网络的研发——这类网络在保留Transformer架构的同时，用替代性的标记混合器取代了注意力机制。MLP-Mixer[6]证明通道层与标记层MLP均可实现媲美传统模型的性能；而MetaFormer[7]进一步证实：由归一化层、标记混合器及通道层MLP构成的骨干框架即使不使用注意力机制也能有效运行。这些研究共同表明，视觉处理领域的高性能并不必然依赖于二次注意力机制，这为开发基于函数原理且高效的替代方案提供了动力。

与此同时，柯尔莫哥洛夫-阿诺德表示定理 (K-A定理) [8]提供了深刻的理论洞见：任何多元连续函数都可以表示为单变量函数的复合形式。这一发现促使我们采用基于函数的视角来建模标记间的相互作用，而非依赖成对相似性或线性投影方法。近年来，柯尔莫哥洛夫-阿诺德网络 (KANs) [9, 10]及其在各领域中的应用 [11, 12, 13]展现出强大的逼近能力、局部可解释性以及跨领域的适应性，为设计新型骨干模块指明了极具前景的方向。

基于这些见解，我们提出了Vision KAN (ViK)——一种无需注意力机制的骨干网络架构，其采用受K-A定理启发的基于函数的令牌混合器来替代成对注意力机制。其核心组件MultiPatchRBFKAN融合了基于补丁的非线性建模、RBF基函数、轴可分离混合以及低秩特征表示。

*通讯作者

© 2026 IEEE. 允许个人使用本材料；对于所有其他用途（无论采用何种当前或未来的传播媒介），均须获得IEEE的书面许可，具体包括：为广告或宣传目的重新印刷/再发布本材料、创作新的集体作品、转售或向服务器及列表进行分发，以及将本作品中的任何受版权保护部分用于其他作品中。

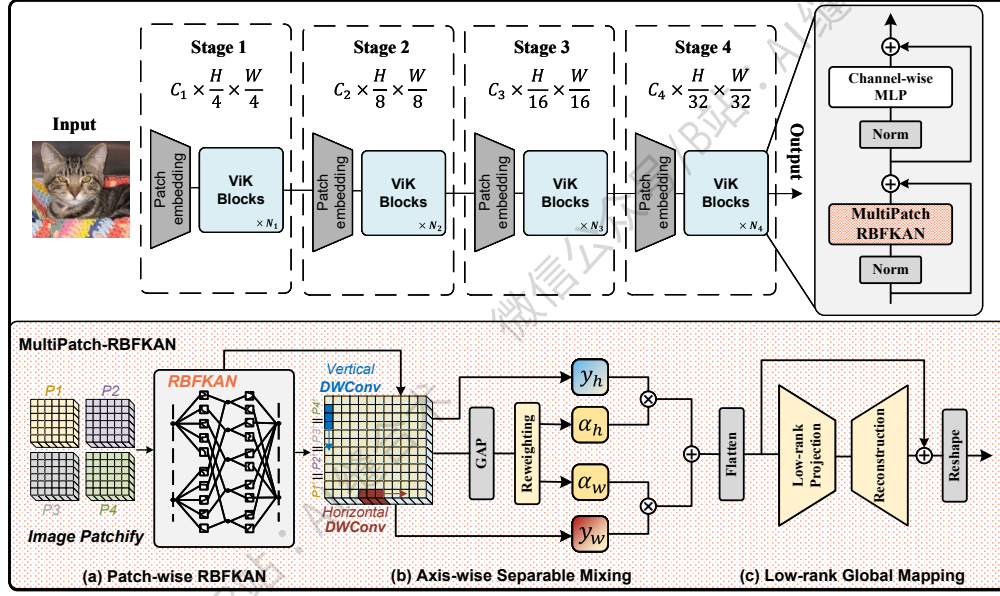


图 1. 所提出的 Vision KAN (ViK) 架构概述。其主干网络采用四阶段的层次化设计，特征图在各阶段均经过下采样并由 ViK 模块处理。每个 ViK 模块包含 MultiPatch- RBFKAN 模块，该模块整合了：(a) 基于 RBFKAN 的块级非线性建模；(b) 用于方向敏感局部混合的轴向可分离深度卷积；以及 (c) 用于高效建模长距离依赖关系的低秩全局路径。其中， $\oplus$ and $\otimes$ 表示元素级加法与乘法运算， $\parallel$ 表示拼接操作。

全局映射。一个关键挑战在于直接应用该方法时存在困难。将完整KAN层转换为高分辨率特征需要进行计算——这种做法在实际应用中存在明显局限性。为此，我们采用基于区域划分的分组策略，使KAN模型能够在大规模场景中实现有效运行。为弥补分组操作带来的区域间交互作用不足问题，可分离混合机制增强了局部信息传播能力，而全局映射则恢复了长距离依赖关系。这种统一设计实现了表达能力与计算效率之间的平衡。在ImageNet-1K数据集上的实验表明，ViK模型不仅具备优异的识别精度和线性复杂度，更拥有坚实的理论基础。

本研究的主要贡献如下：

- 我们提出**Vision KAN (ViK)**——一种无注意力机制的视觉骨干网络，它用受KAN启发的令牌混合器替代自注意力机制，为注意力模块提供了高效的替代方案。
- 我们设计了**MultiPatch- RBFKAN**这一统一模块，它融合了基于补丁的非线性 RBF 变换、轴向可分离混合以及低秩全局映射技术，旨在平衡表达能力与计算效率。
- ImageNet-1K上的实验表明，ViK在保持线性复杂度的同时实现了具有竞争力的准确率，验证了基于KAN的标记混合方法在大规模视觉任务中的有效性。

2. 方法

2.1. 预备知识：柯尔莫哥洛夫-阿诺德网络

柯尔莫哥洛夫-阿诺德表示定理指出，任何多元连续函数均可表示为单变量函数的复合形式，即 $f(x_1, \dots, x_n) = \sum_{q=1}^Q \varphi_q(\sum_{p=1}^P \phi_{pq}(x_p))$ ，其中 $\varphi(\cdot)$ 均为连续单变量函数。这表明与自注意力机制不同，复杂的映射关系无需显式建模成对交互作用即可得到近似表示。

柯尔莫戈罗夫-阿诺德网络 (KANs) 通过用参数化基展开替代固定激活函数来实现这一原理：

$$\phi(x) = \sum_{j=1}^M w_j \cdot B_j(x), \quad (1)$$

其中 $B_j(\cdot)$ 为基函数， w_j 为可训练权重， M 表示基函数的数量。与传统多层感知机 (MLP) 相比，KANs能提供更强的函数逼近能力和局部可解释性，因为每个基函数均可被显式可视化。本研究利用这一特性设计了一种**无注意力机制的视觉骨干网络**，该网络既避免了二次自注意力机制，又保持了强大的表征能力。

2.2. 整体架构

ViK是一种无注意力机制的视觉骨干网络，采用分层架构：包含卷积补丁嵌入层、四个阶段（空间分辨率递减、通道数递增）的 ViK 块，以及最终的归一化与分类头。每个 ViK 块均用我们的**MultiPatch- RBFKAN**替代自注意力机制——这是一种统一的标记混合器，能够在标记数量线性复杂度下实现局部到全局的交互作用，可作为二次注意力机制的直接替代方案。

2.3. 基于 KAN 的 Token 混合器

直接在整个标记上应用全局KAN在计算上难以实现。为此，ViK采用了结构化替换方案：**MultiPatch- RBFKAN**，该方案将三种互补运算器整合到单一标记混合模块中：(a) 用于非线性局部建模的块级KAN；(b) 支轴可分离混合机制，可在线性成本下实现跨块信息交换；(c) 低秩全局映射方法，无需二次计算开销即可捕捉长程依赖关系。

(a) 逐块 RBFKAN。给定一个输入特征图，我们首先将其划分为不重叠的 $p \times p$ 个块。根据等式1（其中 $B(x)$ 表示KAN中的基函数），我们使用径向基函数（RBFs）实现 $B(x)$ ，以建模每个块内的局部非线性相互作用。具体而言，每个块向量可转换为：

$$\phi(x) = \sum_{j=1}^M w_j \cdot \exp\left(-\frac{\|x - \mu_j\|^2}{2\sigma_j^2}\right), \quad (2)$$

其中 μ_j 和 σ_j 为可学习的中心点与宽度参数， w_j 为可训练的缩放权重。与KANs中常用的需要递归计算的B样条基函数不同，RBF能够并行计算所有基函数激活值，因此在大规模视觉任务中更具GPU友好性且效率更高[14]。

(b) 轴向可分离混合。尽管基于区域的KAN能够捕捉区域内依赖关系，但建模跨区域交互同样至关重要。为高效实现此目标，我们在水平轴和垂直轴上分别应用两次深度卷积（DW），随后进行全局平均池化（GAP）并采用基于 MLP 的重加权处理：

$$\begin{aligned} \hat{y} &= \alpha_h \cdot DW_h(y) + \alpha_w \cdot DW_w(y), \\ [\alpha_h, \alpha_w] &= \text{Softmax}(f_{\text{MLP}}(\text{GAP}(y))). \end{aligned} \quad (3)$$

该机制引入了方向敏感的局部混合特性，使模型能够根据图像结构自适应地强调水平或垂直依赖关系。

(c) 低秩全局映射。基于图像块的局部运算符不足以捕捉长距离依赖关系。为高效引入全局上下文，我们将

每个通道重塑为长度为 N 的标记向量（ $N=H \times W$ ），并应用低秩投影：

$$y_{\text{global}} = \mathbf{Q} \mathbf{P} y, \quad \mathbf{P} \in \mathbb{R}^{r \times N}, \mathbf{Q} \in \mathbb{R}^{N \times r}, r \ll N. \quad (4)$$

此处 $\mathbf{P}$ 将空间标记压缩至 r 维潜在空间，而 $\mathbf{Q}$ 则将其反向投影，从而实现高效的全局信息交换。

2.4. 复杂性分析

设 $N=H \times W$ 为空间分辨率， p 为图像块尺寸， C 为通道维度， M 为基函数数量， $r \ll N$ 为全局秩。MultiPatch-RBFKAN 中各组件的计算成本分别为：

- **Patch-wise RBFKAN**: $O(N \cdot C \cdot M \cdot F)$, where $F=p^2$ is the patch dimension;
- **轴向可分离混合**: $O(N \cdot C \cdot k)$, 其中核大小 k ;
- **低秩全局映射**: $O(N \cdot C \cdot r)$.

因此，每个区块的整体复杂度为 $O(N \cdot C \cdot (MF + k + r))$ 。

其计算复杂度随图像尺寸线性增长。与二次自注意力 $O(N^2 \cdot C)$ 相比，该方法在保持表达能力的同时，提供了更高效的无注意力机制替代方案。

3. 实验与结果

3.1. 实验设置

我们在 ImageNet-1K[15] 分类基准集（128 万张训练图像、5 万张验证图像、1000 个类别）上评估 ViK 模型。所有模型均从头开始使用 AdamW[16] 优化器进行 300 轮训练，权重衰减系数为 0.05，峰值学习率为 1×10^{-3} 。我们采用了现代视觉网络中常用的数据增强与优化策略，以确保公平比较[3]。实验结果包括在 224×224 输入分辨率下测得的 Top-1 准确率、参数量及 GFLOPs 计算量。所有实验均在 4 块 $\times$ NVIDIA RTX A6000 GPU 上完成。

3.2. 与代表性视觉架构的比较

表1将 ViK 与一系列广泛使用的视觉骨干网络模型进行了比较，包括 CNN（ResNet[17]）、Transformer（ViT[1]、DeiT[2]、PVT[3]）以及类 MLP 架构（ResMLP[18]）。我们的 ViK-Small 仅需 1.6 GFLOPs 计算资源即可实现 76.5% 的 Top-1 准确率，相较于早期 Transformer 模型（如 ViT-Ti 和 DeiT-Ti）显著提升性能，且计算成本仅略高。与

ResMLP-S12和PVT-Tiny相比，ViK-Small在所需FLOPs和参数数量更少的情况下仍能达到同等或更高的准确率。

在更大规模计算场景下，ViK-Base以3.2 GFLOPs的运算能力实现了80.3%的Top-1准确率，不仅超越了ResNet-50的表现，更与DeiT-Small、PVT-Small及ResMLP-S24相当甚至更优，同时保持显著更低的计算复杂度。这些结果表明ViK在准确性和效率之间实现了良好平衡，充分验证了其轻量级设计及无需依赖注意力机制即可实现高效标记混合的策略优势。

表 1. ImageNet-1K分类任务中不同架构的性能比较

Model	类型	参数(M)	GFLOPs	前 1 (%)
ResNet-18 [17]	中心体	11.7	1.8	70.6
ViT-Ti/16 [1]	注意; 关心	5.7	1.3	72.7
DeiT-Tiny [2]	注意; 关心	5.7	1.3	72.2
PVT-Tiny [3]	注意; 关心	13.2	1.9	75.1
ResMLP-S12 [18]	MLP	15	3.0	76.6
ViK-Small (我们的)	KAN	13.5	1.6	76.5
ResNet-50 [17]	中心体	25.6	4.1	79.2
ViT-S/16 [1]	注意; 关心	22.1	4.6	78.8
DeiT-Small [2]	注意; 关心	22.1	4.6	79.8
PVT-小型[3]	注意; 关心	24.5	3.8	79.8
ResMLP-S24 [18]	MLP	30	6.0	79.4
ViK-Base (我们的)	KAN	24.9	3.2	80.3

表2. ViK-Small的消融研究。“Activation”表示KAN中基函数的类型（RBF、B样条、小波或替换为MLP）；

活性值	#基础	可分离混合	全球地图	前 1 (%)
RBF	4	✓	✓	74.8
RBF	6	✓	✓	75.7
RBF	10	✓	✓	76.4
B样条	8	✓	✓	73.8
小波	8	✓	✓	75.2
MLP	-	✓	✓	72.1
RBF	8	✓	✗	74.6
RBF	8	✗	✓	73.9
RBF	8	✓	✓	76.5

3.3. 消融研究

我们在ViK-Small模型上开展消融实验，以探究激活函数、基函数数量以及MultiPatchRBFKAN结构组件的影响。表2汇总了实验结果。

基函数数量。增加RBF的数量能持续提升预测精度（从使用4个基函数时的74.8%提升至使用10个基函数时的76.4%）。性能在 $M=8$ 时达到峰值（76.5%），而在 $M=10$ 时略有下降（76.4%），表明系统已饱和并出现轻

微过拟合或优化噪声。鉴于计算成本随 M 呈线性增长，我们采用 $M=8$ 作为精度与效率之间的默认平衡值。

激活函数。用不同替代方案替换KAN中的基函数表明，RBF始终优于B样条和小波基函数。此外，使用规模相当的MLP替代KAN会导致性能显著下降（-4.4%）。这印证了我们的设计选择：径向基函数（RBF）更适配GPU计算，并能在视觉任务中提供更强的非线性逼近能力。

可分离混合与全局映射。若移除轴向可分离混合或低秩全局映射中的任一机制，性能均显著下降（分别从76.5%降至74.6%和73.9%）。结合MLP替换实验结果，这些发现证实：我们提出的技术通过将轴向混合与全局交互作用与局部非线性建模相结合，使KAN更适用于视觉任务。

3.4. 已学习的 RBF 映射可视化

为深入理解ViK的内部运作机制，我们可视化了RBF在不同阶段和模块中学习到的单变量函数 $\phi(x)$ 。每条曲线对应图像块中的特定输入维度。结果表明RBF能有效捕捉非线性变换：浅层阶段的函数呈现对局部变化更为敏感的振荡形态，而深层阶段的函数则收敛为更平滑的形式，表明模型逐步抽象出稳定且具有区分性的特征。这些单变量映射为局部可解释性提供了清晰的表达方式。




图2。展示了RBF在ViK不同阶段学习到的单变量函数 $\phi(x)$ 示例。浅层阶段呈现振荡性非线性特征，而深层阶段则收敛为更平滑的映射关系，表明抽象化程度逐步提升。

4. 结论

我们提出了ViK——一种无注意力机制的视觉骨干网络，其采用受柯尔莫哥洛夫-阿诺德表示定理启发的基于函数的标记混合器来替代二次成本自注意力机制。提出的MultiPatch-RBFKAN将块级非线性RBF展开、轴向

可分离混合以及低秩全局映射整合到统一模块中，实现了高效的局部与全局交互。在ImageNet-1K数据集上的实验表明，ViK在保持图像尺寸相关线性复杂度的同时，取得了与经典注意力模型相当的准确率。这些结果凸显了基于KAN的非线性变换作为视觉骨干网络原理性基础的潜力，为构建高效计算机视觉架构指明了新方向。

5. ACKNOWLEDGMENT

本研究获得以下资助：中国国家自然科学基金项目（项目编号：62576216、62502320）；广东省重点实验室项目（项目编号：2023B1212060076）；广东省自然科学基金项目（项目编号：2025A1515010184）；深圳市科技创新委员会项目（项目编号：JCYJ20240813141424032）；以及广东省普通高校青年创新人才培养基金项目（项目编号：2024KQNCX042）。

6. 参考文献

- [1] 阿列克谢·多索维茨基、卢卡斯·拜尔、亚历山大·科列斯尼科夫、迪尔克·魏森伯恩、翟晓华、托马斯·昂特辛纳、莫斯塔法·德赫加尼、马蒂亚斯·明德勒、格奥尔格·海戈尔德、西尔万·盖利等，《一张图像价值 16×16 个单词：大规模图像识别中的变换器》，*国际学习表征会议*，2021年。
- [2] 雨果·图夫龙、马蒂厄·科尔德、马蒂斯·杜泽、弗朗西斯科·马萨、亚历山大·萨布莱罗勒斯与埃尔韦·耶古，《基于注意力机制的高效训练图像变换器与蒸馏方法》，载于*国际机器学习会议*，PMLR，2021年，第10347–10357页。
- [3] 王文海、谢恩泽、李翔、范登平、宋凯涛、梁丁、陆彤、罗平和邵玲，《金字塔视觉变换器：一种无需卷积的密集预测通用骨干网络》，载于*IEEE/CVF 国际计算机视觉会议论文集*，2021年，第568–578页。
- [4] Albert Gu与Tri Dao，《Mamba：基于选择性状态空间的线性时间序列建模》，*arXiv预印本 arXiv:2312.00752*，2023年。
- [5] 贾斯敏·巴斯廷斯与卡佳·菲利波娃，《可解释性领域的“大象”：既然已有显著性方法，为何还要用注意力机制作为解释？》，载于*第三届黑盒NLP研讨会论文集——神经网络在自然语言处理中的分析与解释*，2020年，第149–155页。
- [6] 伊利亚·奥·托尔斯蒂欣、尼尔·霍尔比、亚历山大·科列斯尼科夫、卢卡斯·拜尔、翟晓华、托马斯·昂特辛纳、杰西卡·杨、安德烈亚斯·施泰纳、丹尼尔·凯瑟斯、雅各布·乌什科雷特等，《Mlp-mixer：一种用于视觉处理的全MLP架构》，*《神经信息处理系统进展》*，第34卷，第24261–24272页，2021年。
- [7] 于伟浩、罗米、周潘、司晨阳、周一辰、王新超、冯佳石和严水成，《Metaformer才是视觉领域的核心工具》，载于*IEEE/CVF 计算机视觉与模式识别会议论文集*，2022年，第10819–10829页。
- [8] 安德烈·I·尼古拉耶维奇·柯尔莫哥洛夫，《关于用较少变量的连续函数叠加表示多变量连续函数》，*美国数学学会*，1961年。
- [9] 刘子明、王一轩、萨钦·瓦伊迪亚、法比安·鲁勒、詹姆斯·哈尔弗森、马林·索尔贾奇、侯托马斯·Y·侯和马克斯·特格马克，《Kan：柯尔莫戈洛夫-阿诺德网络》，收录于*国际学习表征会议*，2025年。
- [10] 刘子明、马平川、王一轩、沃伊切赫·马图西克和马克斯·特格马克，《Kan 2.0：柯尔莫哥洛夫-瓦诺尔德网络与科学的交汇》，*arXiv预印本 arXiv:2408.10205*，2024年。
- [11] 杨卓琴、张建松、罗晓玲、卢正和沈林林，《可选激活空间的柯尔莫哥洛夫-阿诺德网络》，*arXiv预印本 arXiv:2408.08338*，2024年。
- [12] 余绍德、陈泽、杨志穆、顾佳城、冯碧珠和孙秋瑞，《基于柯尔莫哥洛夫-阿诺德网络的图像锐度真实评估研究》，收录于*ICASSP 2025-2025 IEEE 声学、语音与信号处理国际会议 (ICASSP)*，IEEE，2025年，第1–5页。
- [13] 杨卓琴、张建松、罗晓玲、卢正和沈林林，《Medkan：一种用于医学图像分类的先进柯尔莫哥洛夫-阿诺德网络》，*arXiv预印本 arXiv:2502.18416*，2025年。
- [14] 李子瑶：“柯尔莫哥洛夫-阿诺德网络是径向基函数网络”，*arXiv预印本 arXiv:2405.06721*，2024年。
- [15] Jia Deng、Wei Dong、Richard Socher、Li-Jia Li、Kai Li和Li Fei-Fei，《Imagenet：一个大规模分层图像数据库》，收录于*2009年IEEE 计算机视觉与模式识别会议*，IEEE，2009年，第248–255页。
- [16] 伊利亚·洛什奇洛夫与弗兰克·胡特，《解耦权重衰减正则化》，收录于*国际学习表示会议*，2019年。

- [17] 何开明、张向宇、任少清和孙健，《深度残差学习在图像识别中的应用》，载于《IEEE 计算机视觉与模式识别会议论文集》，2016年，第770–778页。
- [18] 雨果·图夫龙、皮奥特尔·博亚诺夫斯基、马蒂尔德·卡隆、马蒂厄·科尔德、阿拉埃尔丁·埃尔-努比、爱德华·格拉夫、戈蒂耶·伊扎卡尔、阿尔芒·朱兰、加布里埃尔·西纳耶夫、雅各布·维尔贝格等，《Resmlp：用于图像分类且具有数据高效训练特性的前馈网络》，《IEEE 模式分析与机器智能汇刊》，第45卷第4期，第5314–5321页，2022年。