

SA-Matching DETR: 一种具备增强型尺度自适应匹配功能的轻量级Transformer检测器

杨成山
哈尔滨工业大学

yangchengshan606@gmail.com

张鹏年, 大连理工大学

zhangpengnian1216@gmail.com

赵金静*悉尼大学

jzha0100@uni.sydney.edu.au

摘要

Transformer技术已在计算机视觉领域得到广泛应用，但基于Vision Transformer的检测器往往面临高昂的计算成本。此外，主流目标检测器在标签分配方面存在双重困境：DETR模型中采用的Hungarian匹配算法常产生假阴性结果（尤其针对大型目标），而R-CNN模型中基于交并比的匹配算法则容易对小型目标产生假阳性结果。为解决这些问题，我们提出SA-Matching DETR——一种轻量高效的检测框架。首先，我们引入Partial ViT作为骨干网络，通过通道分解技术对部分通道应用自注意力机制，在显著减少参数量和计算量的同时保持丰富的特征表示；其次，提出Scale Adaptive Matching算法，根据目标尺寸动态扩展真实框集合，该方法既能提升真例数量以降低假阴性率，又避免了其他策略常见的误分配风险。在ImageNet-1K数据集上，Partial ViT仅需6670万参数即可实现85.2%的Top-1准确率，性能超越现有大规模模型。在COCO数据集上，SA Matching DETR模型仅使用8400万个参数即可实现最先进的54.8%平均精度（mAP）；值得注意的是，我们的纯编码器版本同样达到53.5%的mAP值，超越了多项多阶段检测器，充分体现了该框架的高效性。

1. 引言

Transformer架构在自然语言处理（NLP）领域取得了显著成就[45]，并迅速成为现代计算机视觉的基石。在目标检测领域，DETR[4]通过引入端到端、无锚点的框架实现了范式转变。尽管后续研究如可变形DETR[57]解决了收敛速度慢、依赖单一尺度特征等关键初始




图1. 在ImageNet-1K数据集上，Top-1准确率与模型规模（以百万参数计）的对比结果。Partial ViT在准确率与效率之间实现了更优的平衡，始终优于其他主流Vision Transformer架构。

问题（这些问题限制了小目标检测能力），但这些现代框架的性能从根本上取决于其特征骨干网络。传统卷积骨干网络[5, 17, 20, 32, 41, 49]的自然继承者是视觉Transformer（ViTs）[13, 26, 31, 34, 35, 38, 42, 48]，但它们与检测流程的集成仍存在不无缝衔接的问题。

主要障碍在于ViT架构所面临的高昂计算成本与参数开销，尤其是在高分辨率场景下。这种开销直接源于全局自注意力机制——其计算成本随输入标记数量的增加呈二次方增长。现有解决方案通过多种策略试图缓解这一问题，但每种方法都存在固有的权衡。诸如局部窗口注意力[31]或标记剪枝[38]等方法通过减少注意力操作中的标记数量来直接应对二次项问题，但可能无法保留关键的长距离依赖关系或会丢失精细特

*通讯作者。




图2. 在COCO数据集上，不同目标检测器的平均精度（mAP）与参数数量的关系对比。我们的SA-Matching DETR模型曲线始终位于图表左上区域，表明其在检测准确率与模型复杂度之间实现了全新的最优平衡。

征；而量化[8, 50]和低秩分解[16]等其他方法虽能降低注意力模块中矩阵运算的成本，却可能导致特征失真从而削弱表征能力。

为缓解ViT骨干网络的效率局限性，我们提出了部分视觉变换器（Partial ViT）。这一轻量级架构采用了受部分卷积[5]启发的通道选择性注意力机制：具体而言，它将每个词元对应的特征通道进行划分，仅对其其中一部分子集应用计算密集型的自注意力操作，其余通道则保持原样传递。该策略在不改变原始词元序列的前提下，显著降低了参数数量和计算开销。通过保留完整的词元序列，Partial ViT避免了基于剪枝方法常见的信息丢失问题，从而保持了较高的特征完整性。这实现了模型效率与性能之间的最优平衡——如图1所示，在参数数量相当的情况下，我们的Partial ViT模型始终能取得比其他竞争架构更高的Top-1准确率。

除了骨干网络的效率之外，另一个更为微妙但同样关键的挑战在于训练过程中的**标签分配难题**。基于DETR的检测器[4, 6, 10, 30, 53, 57]通常采用匈牙利匹配[24]方法，在预测框与真实框之间建立全局最优的一一对应关系。然而这种严格约束会严重限制正样本数量，导致监督数据稀疏且假阴性率（FNs）较高，尤其对于大型目标而言。相反，传统的基于交并比（IoU）

的匹配策略[2, 3, 18, 33, 39, 40]容易对小目标产生假阳性（FPs），因为即使存在显著的几何错位仍可能获得较高的IoU值。这形成了一个持续存在的权衡问题，从根本上制约了检测器性能。

为解决这一难题，我们提出了尺度自适应匹配（SA-Matching）算法——一种旨在提升训练监督效果的动态分配策略。该算法并非修改匹配算法本身，而是根据物体尺寸自适应地扩展真实目标集合，再进行最优的一对一匹配。这种方案既能增强大尺寸物体的梯度信号以降低误报率，又能确保小尺寸物体仍能获得高精度匹配结果。

通过协同整合我们的轻量级骨干网络与先进的匹配算法，我们提出了SA-Matching DETR——一个高效且强大的目标检测框架。大量实验结果验证了该方法的有效性。如图2所示，该完整框架在COCO[28]目标检测基准上建立了新的最先进效率边界，在相近参数预算下始终优于现有方法。本研究的主要贡献总结如下：

- 我们提出**Partial ViT**——一种通过通道分解降低计算成本的轻量级视觉Transformer模型。该模型在图像分类任务中实现了卓越的精度与效率平衡，在ImageNet-1K数据集上仅使用6670万参数即可达到85.2%的Top-1准确率。
- 我们提出**SA-Matching**这一标签分配策略，有效解决了目标检测中的假阴性/假阳性难题。该策略可根据物体尺寸自适应地生成真实标注副本，显著提升了训练过程中正样本的密度与质量。
- 我们提出了集成化的**SA-Matching DETR**框架，该框架将Partial ViT与SA-Matching相结合，在高效目标检测领域实现了新的前沿水平。我们的模型在COCO基准数据集上使用8400万参数时达到54.8%的mAP值，性能优于参数规模相当的现有模型。

2. 相关工作

轻量级视觉Transformer。轻量级视觉Transformer旨在降低计算成本的同时保持强大的特征表示能力。常用策略包括架构融合、多尺度特征建模、标记压缩以及注意力机制简化。混合架构将CNN的局部特征提取与Transformer的全局建模相结合：例如MobileViT[34]通过轻量级卷积增强局部感知能力，非常适合资源受限场景；在多尺度特征建模方面，Swin Transformer[31]利用滑动窗口自注意力机制和分层金字塔结构提升物

体尺度感知精度；为缓解自注意力机制的高计算成本，研究人员开发了线性注意力方法，在保持竞争力的同时实现近线性复杂度[15, 16]；其他技术如Token Crop[1, 43]基于重要性评分减少冗余标记，有效降低计算量，但这些方法可能丢失部分关键信息，影响细粒度特征表征。

基于DETR的目标检测模型。DETR[4]提出了一种基于Transformer的端到端目标检测框架，无需人工设计锚点和非极大值抑制（NMS），但存在收敛速度慢的问题。可变形DETR[57]通过可变形注意力机制显著提升了收敛效率，被视为该领域的里程碑式成果。在此基础上，学界提出了多种扩展方案以提升性能：例如DINO[53]采用对比学习增强判别能力；Co-DETR[58]运用协作混合分配实现更高效精准的匹配；ViTDet[27]采用单尺度非层次化ViT骨干网络优化检测效果；DEYO[36]将一对多检测与端到端框架相结合。为进一步提升检测性能，多数检测器均集成特征精炼模块[7, 54, 56]，其中 HPR[56]通过多级处理精细增强区域特征，实现了显著性能提升。**基于DETR的检测器匹配策略。**大多数基于DETR的目标检测方法均采用匈牙利[24]算法进行严格的一一匹配。这种约束限制了正样本数量，并容易导致大尺寸目标产生假阴性结果。相比之下，基于IoU的匹配[3, 18]虽能生成正样本，但极易产生假阳性结果。为提升匹配质量，学界已提出一系列方法改进方案：DNDETR[25]通过引入噪声查询增加正样本密度以增强检测器鲁棒性；H-DETR[21]融合一一匹配与一多匹配机制以优化正样本利用；Group DETR[6]则通过结合组内一一匹配与组间一多匹配来加速收敛并提升检测性能。此外，部分研究通过优化匹配质量来提高检测精度[19, 37]。受现有进展启发，我们提出SA-Matching算法——该算法在不引入错误匹配的情况下增强了匈牙利匹配的监督效果。—分配了许多对一策略相关的风险。

3. 方法

在本节中，我们将详细阐述提出的SA-Matching DETR框架——这一高效且轻量级的目标检测框架旨在解决现有基于Transformer的检测器存在的关键局限性。我




图3. 部分视觉Transformer（Partial ViT）的架构结构，重点展示了部分注意力模块（右图）。通过分解特征并对仅部分通道应用多头注意力机制，该设计显著降低了计算开销。

们的方法基于两项核心创新：首先，在第3.1节中，我们提出了Partial ViT轻量级高效骨干网络，该网络通过采用通道分解策略显著降低了计算复杂度；其次，在第3.2节中，我们提出Scale Adaptive Matching（SA-Matching）算法——一种新型标签分配策略，旨在缓解基于IoU匹配与匈牙利匹配之间的权衡关系，从而提升训练监督效果；最后，在第3.3节中，我们详细阐述了完整的SA-Matching DETR框架架构，该架构通过协同整合Partial ViT骨干网络，在性能与效率之间实现了业界领先的平衡。

3.1. 部分视觉变换器

通道分解。模型剪枝是通过去除冗余组件来构建高效神经网络的一种常用技术。卷积领域近期的一个典型例子是部分卷积[5]——这是一种结构化剪枝方法，仅对输入通道的子集应用标准卷积运算，而其余通道保持不变。这种方法有效减少了冗余计算和内存访问量。受这种基于通道维度的方法启发，我们将该原理应用于视觉Transformer架构。如图3所示，我们的方法Partial ViT沿通道维度实现了高效的特征分解。与现有的ViT压缩方法不同




图4. 匹配算法对比（左）与我们提出的SA-Matching架构对比（右）。SA-Matching通过首先根据物体尺度扩充真值集，再进行一对一匹配分配，从而有效降低了IoU匹配中的假阳性率和匈牙利匹配中的假阴性率。

部分视觉Transformer（Partial ViT）通过沿空间维度剪枝或合并特征向量来降低计算量，同时保留所有特征向量。具体而言，它仅对每个特征向量对应的通道部分应用计算密集型的自注意力操作。这种设计既保持了Transformer模型全局语义建模的能力，又避免了特征向量剔除带来的细粒度信息损失，在模型效率与特征完整性之间实现了有效平衡。其核心创新在于通道选择性部分注意力模块：该机制能沿通道维度对输入特征矩阵进行策略性划分，从而显著降低计算负担。

给定一个输入特征矩阵 $Z \in \mathbb{R}^{N \times D}$ ，其中 N 表示标记数量， D 表示特征维度，我们首先定义一个部分通道比率 $r \in (0, 1]$ 。该比率决定了将参与自注意力操作的“活跃”通道数 D' 。随后，输入矩阵 Z 被划分为两个部分：包含活跃通道的活跃分区 $Z^{(D')}$ ，以及包含其余通道的“冻结”分区 $Z^{(D-D')}$ ，具体定义见等式（1）。

$$D' = \lceil rD \rceil, \quad Z = [Z^{(D')}, Z^{(D-D')}] \quad (1)$$

如结构示意图（图3）所示，这两个分区通过并行路径进行处理：

- 注意力路径：**活跃分区 $Z^{(D')}$ 由标准Transformer模块处理，从而使模型能够以较低的计算成本捕捉复杂的空间关系和长距离依赖性。
- 身份路径：**冻结分区 $Z^{(D-D')}$ 绕过了耗时的MHSA操作，并通过残余连接传递。这一简单而有效的步骤

确保了这些通道中的特征信息得以完整保留且不发生改变。

为完成运算，来自注意力路径（ $\hat{Z}^{(D')}$ ）和恒等路径（ $Z^{(D-D')}$ ）的特征表示均被重新整合。这一过程通过沿通道维度将二者拼接实现，从而生成网络中下一个模块所需的最终输出张量 $Z^{(l+1)}$ ：

$$Z^{(l+1)} = \text{Concat}(\hat{Z}^{(D')}, Z^{(D-D')}) \quad (2)$$

Partial ViT设计巧妙融合了高效性与高性能。通过仅对部分通道应用MHSA算法，计算成本和参数量均显著降低。实验结果验证了该设计的有效性：在ImageNet-1K数据集上，Partial ViT-B模型仅需6670万个参数即可实现85.2%的Top-1准确率。

3.2. 尺度自适应匹配

在现代目标检测系统中，标签分配策略（即将预测结果与真实标注框进行匹配的过程）是决定训练动态及模型最终性能的关键要素。目前主流的两种方法——基于交并比（IoU）的阈值判定法和匈牙利匹配法——各自存在根本性的权衡问题：基于IoU的方法虽能生成密集的正样本集但精度较低；而匈牙利匹配法则能实现最优的一对一匹配，但需要依赖稀疏监督数据。正如我们将要讨论的，这些局限性在处理不同尺度的目标时尤为明显。

基于IoU的匹配与假阳性问题。基于IoU的分配方法广泛应用于R-CNN类检测器[2, 18, 39]中，当预测结果与真实框的IoU值超过预设阈值时，即判定为正样本。虽然这种方法能生成大量正样本，但极易产生假阳性结果，尤其对于小尺寸目标而言。对于小型目标，预测结果可能在几何位置上显著偏离但仍满足IoU阈值要求，从而导致定位结果不准确。这一问题在我们的对比实验中得到直观展示（图4，上排）。**匈牙利匹配法与假阴性问题。**相比之下，作为DETR基模型核心的匈牙利算法[24]通过最小化成对成本矩阵来实现全局最优的一一对应匹配。这种精妙方案虽消除了重复匹配，却带来了显著副作用：会产生假阴性结果并导致监督效果稀疏（尤其针对大尺寸目标）。由于严格的一一对应约束，每个真实框仅能匹配一个预测结果。对于大型目标而言，这种情况往往会导致多个高质量且有效的预测结果无法被匹配，在训练过程中这些预测会被视为负样本。该机制在图4（中排）中以概念形式展示——由于遵循一对一规则，高质量预测结果会被舍弃。我们的定量结果进一步证实了这一点：与其它方法相比，标准匈牙利匹配算法对大型目标的平均精度（AP）较低（58.8 AP_L）（见表3）。

尺度自适应匹配。为解决这一难题，我们提出尺度自适应匹配（SA-Matching）算法——一种自适应算法，在不牺牲匈牙利匹配最优分配特性或避免多对一策略带来的错误分配风险的前提下，增强了该方法的监督能力。令初始真实对象集合定义为 $G=\{g_1, g_2, \dots, g_N\}$ 。我们引入了一个考虑尺度的增强函数 $\phi(ai)$ ，该函数根据每个真实框 g_i 的面积 a_i ，如等式(3)所示，确定需要生成的副本数量。

$$\phi(a_i) = s + (m-s) \cdot H(a_i - \eta_s) + (l-m) \cdot H(a_i - \eta_l). \quad (3)$$

此处， $H(\cdot)$ 表示海维赛德阶跃函数，其根据预设的面积阈值 η_s 和 η_l 充当开关作用。与尺度相关的增强因子 s 、 m 、 l 是超参数，分别定义了小尺寸、中尺寸和大尺寸物体对应的真值样本数量。如我们的消融实验（图5）所示，小尺寸物体的增强因子最佳设置为 $s=1$ 。这一选择能确保小目标之间保持一一对应关系，这对抑制假阳性结果的泛化至关重要。利用等式(3)，我们通过将每个真值框 g_i 复制总计 $\phi(ai)$ 次，构建出增强后的真值集 G' ：

$$G' = \bigcup_{i=1}^N \{g_i^{(1)}, g_i^{(2)}, \dots, g_i^{(\phi(a_i))}\}. \quad (4)$$

在训练过程中，随后会在这个扩展数据集 G' 上执行标准的一对一匈牙利匹配算法。这有效确保了中型和大型物体分别与 m 和 l 个预测结果相匹配。该过程显著提升了大型物体正样本的密度，这一点体现在相较于标准匈牙利匹配方法实现了高达6.3个百分点的AP值提升（表3）。

3.3. SA-Matching DETR框架

我们SA-Matching DETR框架的整体架构融合了轻量级的部分ViT骨干网络与先进的SA-Matching算法，共同构建出高效的物体检测领域的全新标杆。遵循ViTDet[27]的设计理念，我们用提出的Partial ViT替代传统层级化骨干网络，并直接从其最终单分辨率输出中提取多尺度特征金字塔，再将其输入标准Transformer编码器-解码器结构。在训练过程中，解码器预测结果与真实标注框之间的标签匹配完全由我们的SA-Matching算法负责处理。各组件间的协同作用至关重要：Partial ViT骨干网络提供了高效且强大的特征提取能力；特征金字塔有效为多尺度分析准备输出数据；而SA-Matching算法则确保生成密集且精准的监督信号，从而实现性能与效率之间的卓越平衡。

4. 实验

4.1. ImageNet-1K分类性能数据集及评估指标。模型表征能力的实验均在ImageNet-1K数据集上进行[11]。遵循标准做法，我们主要报告Top-1分类准确率，同时评估模型参数数量、FLOPs计算量及单GPU推理吞吐量以全面评估模型效率。**实现细节。**训练流程基于DeiT框架构建[42]，采用蒸馏后的DeiT模型进行硬蒸馏：具体而言，通过截取预训练DeiT模型的权重使其与Partial ViT架构的降维通道维度匹配来初始化模型；该预训练模型随后作为教师网络使用。我们采用DeiT的蒸馏策略，引入一个辅助蒸馏标记并对其进行训练以复现教师网络的预测结果。推理阶段则通过平均标准类别标记与该蒸馏标记的输出logit值来生成最终分类结果。输入图像在Partial ViT-B模型中被调整为 384×384 像素，而Small和Tiny变体则采用 224×224 像素。所有模型均使用AdamW优化器进行训练，初始学习率为 $1e_4$ ，最小学习率 $2e_6$ ，并采用余弦退火策略结合5轮线性学习率调整。

表1. 主流分类模型在ImageNet-1K数据集上的性能比较[11]。我们重点展示了最佳结果及第二佳结果。

模型	图像大小	参数(M)	GFLOPs	吞吐量 (图像/秒)	顶级 1 Acc
DeiT-T [42]	224	5.5	1.1	2219.1	72.2
DeiT-S [42]	224	21.6	4.2	875.5	79.8
DeiT-B [42]	384	85.7	49.4	90.7	83.1
双胞胎-SVT-S[9]	224	24.0	2.8	801.5	81.7
双胞胎-SVT-B[9]	224	56.0	8.4	367.6	83.2
双胞胎-SVT-L[9]	224	99.2	14.8	246.3	83.7
斯温-T[31]	224	29.0	4.4	617.2	81.3
斯温-S[31]	224	50.0	8.5	352.7	83.0
斯温-B[31]	384	88.0	44.6	74.9	84.5
PVTv2-B0 [46]	224	3.4	0.5	1835.5	70.5
PVTv2-B2 [46]	224	25.4	3.9	558.3	82.0
PVTv2-B5 [46]	224	82.0	11.4	233.3	83.8
MaxViT-T [44]	224	31.0	5.3	355.0	83.6
MaxViT-S [44]	224	69.0	11.3	219.9	84.5
内斯T-T[55]	224	17.0	5.2	449.5	81.5
内斯T-S[55]	224	38.0	9.4	272.7	83.3
内斯T-B[55]	224	68.0	16.7	186.2	83.8
达维特-T[12]	224	28.3	4.4	622.7	82.8
达维特-S[12]	224	49.7	8.6	364.4	84.2
达维特-B[12]	224	87.9	15.2	243.2	84.6
SHViT-S1 [52]	224	6.3	0.3	1952.3	72.8
SHViT-S3 [52]	224	14.2	0.6	1760.4	77.4
SHViT-S4 [52]	256	16.5	1.0	1394.7	79.4
RDNet-T [22]	224	24.0	5.0	540.4	82.8
RDNet-S [22]	224	50.0	8.7	346.5	83.7
RDNet-B [22]	224	87.0	15.4	216.3	84.4
MambaOut-T [51]	224	27.0	4.5	595.8	82.7
MambaOut-S [51]	224	48.0	8.9	336.0	84.1
MambaOut-B [51]	224	85.0	15.8	217.8	84.2
部分ViT-T	224	4.6	0.8	2283.5	72.6
部分ViT-S	224	17.1	3.3	1028.0	81.3
部分维生素B族	384	66.7	38.2	112.6	85.2

采用热身预训练阶段。训练共进行300个周期，批量大小为128。数据增强策略包括Mixup、CutMix、随机擦除以及多种增强组合。分类目标函数定义为标签平滑交叉熵，并与硬蒸馏损失函数取平均值以形成反向传播的总体损失函数。训练任务分布在8块 NVIDIA A 100 GPU上完成，而FLOPS计算量和推理吞吐量则在单块 NVIDIA 2080Ti GPU上持续测量。

ImageNet-1K上的主要结果。表1展示了Partial ViT在不同模型规模下的性能表现及其与主流架构的对比。Partial ViT-T在460万参数下达到72.6%的Top-1准确率；Partial ViTS达到81.3%；Partial ViT-B在384 × 384输入尺寸下实现85.2%的准确率。相较于DeiT-B[42]、Swin[31]、MaxViT[44]和MambaOut[51]，Partial ViT在保持准确率的同时展现出更高的效率：与DeiT-B相比，Top-1准确率提升2.1%，参数量减少22%，FLOPs消耗降低23%，吞吐量提高24%；与Swin-B相比，准确率提升0.7%，参数量与FLOPs分别减少24%和14%，吞吐量提升50%。

这些结果表明Partial ViT有效平衡了紧凑设计与高精度要求。

4.2. COCO目标检测性能

数据集与评估指标。物体检测性能实验均在COCO基准集[28]上进行。遵循标准做法，我们报告验证集上的AP值（包括AP₅₀，AP₇₅，AP_S，AP_M，AP_L），以实现全面评估。

COCO数据集上的实现细节。训练流程基于MMDetection[57]框架构建。检测器使用在ImageNet-1K[11]上预训练的权重进行初始化，并采用基于DETR的架构，包含900个目标查询用于预测生成。优化过程使用AdamW优化器[42]，总批次大小为16。输入图像被调整为1024 × 1024分辨率，学习率设置为2e₋₄，并采用250次迭代的线性热身阶段。在24轮训练方案中，第20轮（对于12轮方案则为第11轮）学习率衰减因子为0.1。采用了标准的DETR风格数据增强方法[21, 53]，并结合

表2. 主流目标检测模型在COCO数据集上的性能对比[28]。所有模型均在8 NVIDIA 上训练。
A100 (40GB) GPU。我们重点展示了**最佳**与**第二佳**的结果。

模型	脊梁骨	时代; 时期	mAP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L	参数(M)
单级探测器									
FoveaBox [23]	ResNet-101	12	40.8	61.4	44.0	24.1	45.3	53.2	55
FoveaBox [23]	ResNeXt-101	12	42.3	62.9	45.4	25.3	46.8	55.0	58
RetinaNet [29]	ScopeViT-T [35]	12	41.9	63.0	44.7	27.4	45.8	56.5	17
RetinaNet [29]	ScopeViT-S [35]	12	44.2	65.5	47.3	27.5	48.3	59.2	25
SOLOv2 [47]	ResNet-50	72	40.4	59.8	42.8	20.5	44.2	53.9	50
SOLOv2 [47]	ResNet-101	72	42.6	61.2	45.6	22.3	46.7	56.3	66
SOLOv2 [47]	ResNet-101 DCN	72	44.9	63.8	48.2	23.1	48.9	61.2	69
YOLOX-M [14]	ModifiedCSPv5	300	46.4	65.4	50.6	26.3	51.0	59.9	25
YOLOX-L [14]	ModifiedCSPv5	300	50.0	68.5	54.5	29.8	54.5	64.4	54
YOLOX-X [14]	ModifiedCSPv5	300	51.2	69.6	55.7	31.2	56.1	66.1	99
SA-匹配 DETR 编码器	部分ViT-T	12	44.7	61.8	49.1	25.4	48.6	61.7	15
SA-匹配 DETR 编码器	部分ViT-S	12	49.0	67.2	53.5	29.6	53.2	67.5	28
SA-匹配 DETR 编码器	部分维生素B族	12	52.5	71.7	57.2	32.2	57.3	70.8	78
SA-匹配 DETR 编码器	部分ViT-T	24	47.6	65.2	56.1	27.7	51.6	65.4	15
SA-匹配 DETR 编码器	部分ViT-S	24	51.3	69.7	52.1	32.0	55.9	69.1	28
SA-匹配 DETR 编码器	部分维生素B族	24	53.5	73.0	59.0	34.8	58.7	72.4	78
多级探测器									
DETR [4]	ResNet-50	500	42.0	62.4	44.2	20.5	45.8	61.1	41
DETR [4]	ResNet-101	500	43.5	63.8	46.4	21.9	48.0	61.8	60
DAB-DETR [30]	ResNet-50	50	42.2	63.1	44.7	21.5	45.7	60.3	44
DAB-DETR [30]	ResNet-101	50	43.5	63.9	46.6	23.6	47.3	61.5	63
稀疏R-CNN[40]	ResNet-50	36	42.8	61.2	45.7	26.7	44.6	57.6	106
稀疏R-CNN[40]	ResNet-101	36	44.1	62.1	47.2	26.1	46.3	59.7	125
变形。DETR[57]	ResNet-50	50	46.2	65.2	50.0	28.8	49.2	61.7	40
DN-DETR-DC5 [25]	ResNet-50	12	41.7	61.4	44.1	21.2	45.0	60.2	44
DN-DETR-DC5 [25]	ResNet-101	12	43.4	61.9	47.2	24.8	46.8	59.4	63
DN-变形。DETR[25]	ResNet-50	12	43.4	61.9	47.2	24.8	46.8	59.4	48
DN-变形。DETR[25]	ResNet-101	12	44.1	62.8	47.9	26.0	47.8	61.3	67
掩码R-CNN[18]	TrpViT-T [26]	36	48.7	71.0	53.5	—	—	—	47
掩码R-CNN[18]	TrpViT-S [26]	36	49.9	72.1	55.2	—	—	—	64
掩码R-CNN[18]	TrpViT-B [26]	36	50.5	72.4	55.1	—	—	—	99
DINO-4尺度[53]	ResNet-50	12	49.0	66.6	53.5	32.0	52.3	63.0	47
DINO-4尺度[53]	ResNet-50	24	50.4	68.3	54.8	33.3	53.7	64.8	47
Co-DETR [58]	ResNet-50	12	49.5	67.6	54.3	32.4	52.7	63.7	65
Co-DETR [58]	斯温- T	12	51.7	69.6	56.4	34.4	54.9	66.8	66
Co-DETR [58]	斯温- S	12	53.4	71.8	58.5	35.4	57.0	69.0	87
ViTDet口罩[27]	ViT-B	100	51.6	72.1	56.6	35.3	55.6	66.4	111
ViTDet级联[27]	ViT-B	100	54.0	—	—	—	—	—	141
SA匹配DETR	部分ViT-T	12	47.3	64.9	51.2	28.3	50.5	64.8	20
SA匹配DETR	部分ViT-S	12	51.1	69.5	55.7	31.4	55.0	68.8	33
SA匹配DETR	部分维生素B族	12	53.4	72.5	58.1	34.3	58.0	71.4	84
SA匹配DETR	部分ViT-T	24	50.7	69.0	55.1	31.6	54.0	68.0	20
SA匹配DETR	部分ViT-S	24	53.3	72.0	58.2	34.6	57.4	70.6	33
SA匹配DETR	部分维生素B族	24	54.8	73.8	59.5	36.4	59.3	72.3	84

重新调整[56]，以增强训练的鲁棒性。

COCO数据集的主要结果。表2展示了SA-Matching DETR在不同模型规模下的性能表现以及与主流架构的对比结果。SAMatching DETR框架展现出最先进的性能水平，为准确性和效率树立了新标准。我们仅使用编码器的轻量级模型具有极强竞争力；例如参数数量为2800万的Partial ViT-S版本实现了51.3%的mAP值，超越了规模远大的YOLOX-X[14]。通过集成三个解码器，我们的完整框架达到了新的前沿水平——参数数量为8400万的Partial ViT-B模型实现了54.8%的mAP值，这一成绩超过了Co-DETR[58]等当前主流强效模型的表现。这些结果充分证明我们的框架在高性能、轻量级目标检测领域具有卓越优势。

4.3. 消融研究

在本节中，我们开展了一系列消融实验，以验证关键设计选择并量化SA-Matching DETR框架中各组件的贡献度。除非另有说明，所有实验均使用**Partial ViT-S**骨干网络并训练12个周期。

尺度依赖性增强因子。我们通过消融实验确定了尺度依赖性增强因子 (s, m, l) 的最佳取值。这些初步实验采用ResNet-50主干网络进行，旨在在开发所提出的模型前建立一套稳健的超参数组合。如图5所示，mAP与小目标增强因子 s 呈负相关；当 $s=1$ 时性能达到最优，这符合我们降低假阳性率的目标。针对中大型目




图5. 关于小目标增强因子 s 的消融研究。性能在 $s=1$ 时达到峰值，表明一对一分配对小目标最为理想。

表3. SA匹配算法、匈牙利匹配算法及IoU匹配算法下的检测性能。

算法	AP _S	AP _M	AP _L	mAP
IOU 匈牙利	23.8	50.7	63.7	44.6
	25.0	46.0	58.8	42.7
语SA匹配	29.6	53.2	67.5	49.0

标，性能变化趋势如图6所示：实证结果清晰显示存在最佳参数区间，当增强因子设为 $m=7$ 、 $l=9$ 时mAP达到峰值。基于此分析，我们采用 $(s, m, l) = (1, 7, 9)$ 作为SA-Matching算法的默认配置。

SA匹配策略分析。SA匹配算法旨在融合匈牙利匹配法与基于IoU的匹配方法的优势，以提升训练过程中正样本分配的质量。如表3所示，我们的SA匹配算法在COCO基准测试中显著优于两种传统策略：相较于标准匈牙利算法实现了6.3个百分点的mAP提升，相较于基于IoU的匹配方法实现了4.4个百分点的mAP提升。这种优异性能在所有物体尺度下均保持一致，且在AP_S、AP_M和AP_L指标上的显著提升充分体现了我们方法的通用性。

组件分析。为全面评估各模块的贡献度，我们对ResNet-50及提出的ViT-S骨干网络均进行了消融实验（表4）。如表所示，在采用SA匹配技术的ResNet-50骨干网络中，数据重增强策略仅带来1.3%的mAP提升（44.7% → 46.0%）；而在我们的架构中，该策略对部




图6. 中等（ m ）与较大（ l ）物体增强因子下的性能分布情况。实证结果表明存在明显的最优区域，性能在 $(m, l) = (7, 9)$ 处达到峰值。

表4. ResNet-50及Partial ViT-S骨干网络上框架组件的消融研究。

骨干部分注意力机制数据重新增强SA匹配mAP				
ResNet-50	—	—	—	39.8
	—	✓	—	41.2
	—	—	✓	44.7
	—	✓	✓	46.0
ViT-S	✓	—	—	32.8
	✓	—	—	34.4
	✓	✓	—	42.7
	✓	✓	✓	42.8
				49.0

分ViT-S骨干网络结合SA匹配时效果显著，可实现高达6.2%的mAP提升（42.8% → 49.0%）。这种显著差异充分证明了所提出的骨干网络、匹配算法与增强技术之间存在强烈的协同效应。

5. 结论

在本研究中，我们提出了SA-Matching DETR模型，该模型通过协同整合轻量级Partial ViT骨干网络与先进的SA-Matching算法，实现了高效的物体检测。Partial ViT仅对部分通道应用多头自注意力机制，显著降低了计算成本和参数量；而SA-Matching则在保持匈牙利匹配监督机制最优分配特性的同时，避免了多对一策略存在的缺陷。实验表明：Partial ViT在ImageNet数据集上仅需6670万参数即可实现85.2%的Top-1准确率；而SA-Matching DETR在COCO数据集上仅需8400万参数即可达到54.8%的mAP值，展现出卓越的性能优势。