

基于上下文感知与语义引导的红外小目标检测自适应滤波网络

凌川孔、杨博、常瑞、罗军[✉]、朴华彦和皮阳军[✉]

摘要——红外小目标检测（ISTD）是从红外图像中识别微小目标的关键任务。尽管现有的卷积神经网络（CNN）-Transformer混合方法已实现优异的分割性能，但仍存在若干挑战：首先，自注意力机制对细微局部变化不敏感且计算成本高昂；其次，在特征融合过程中这些方法未能充分挖掘浅层特征所蕴含的关键信息，导致在目标与背景高度相似的场景中难以实现精准有效的区分。为解决这些问题，本文提出CSAFNet以提升目标与背景的区分能力。具体而言，我们引入了并行自感知注意力（PSAA），该机制利用物理先验知识捕捉全局上下文，并结合小波变换增强局部细节特征，从而实现局部与全局特征的精准融合。考虑到浅层特征对于精确定位和精细分割的重要性，我们在特征融合阶段设计了跨语义自适应过滤模块（CAFM），该模块深入挖掘浅层特征中的关键信息，并增强目标表示的相对显著性。此外，我们提出了动态多尺度空间金字塔（DMSSP）模块以提升边缘精度并提高分割准确性。在最常用的两个ISTD数据集NUAA-SIRST和IRSTD-1K上进行的大量实验表明，CSAFNet的表现优于其他最先进的方法。相关代码可访问<https://github.com/LingchuanK/CSAFNet>获取。

索引术语——自适应滤波、特征融合、红外小目标检测（ISTD）、跳跃连接。

I. 引言

红外小目标检测（ISTD）是一项关键技术，在军事安全、海上监视及预警系统中发挥着重要作用[1]。[2]，[3]，

收稿日期：2025年6月4日；修订日期：2025年10月14日及2025年12月2日；接受发表日期：2025年12月16日。出版日期：2025年12月19日；当前版本发布日期：2026年1月7日。本研究部分由国家自然科学基金（项目编号：T2421001）资助，部分由上海市教育委员会创新计划（项目编号：2021-01-07-00-09-E0013）支持。（通讯作者：Pi Yangjun。）

凌川孔、杨博、常瑞、罗军和皮阳军任职于重庆大学先进装备机械传动国家重点实验室，地址：重庆市重庆市重庆400044。（电子邮箱：chuan_cqu@163.com；cqyangbo@stu.cqu.edu.cn；1811213235@qq.com；luoj@cqu.edu.cn；cqpp@cqu.edu.cn）。

华彦普任职于中国重庆市重庆大学先进装备机械传动国家重点实验室（邮编：400044），同时兼任中国上海市上海大学机电一体化与自动化学院教授（邮编：200444）（电子邮箱：phygood 2001@shu.edu.cn）。

数字对象标识符：10.1109/TGRS.2025.3646255

电话：1558-0644 © 2025 IEEE。保留所有权利，包括文本与数据挖掘、人工智能及相关技术培训方面的权利。个人使用允许，但转载或重新分发需获得IEEE授权。

更多信息请参见<https://www.ieee.org/publications/rights/index.html>。

[4]然而，红外小目标具有固有特性，例如缺乏详细特征（如颜色和纹理）、尺寸较小以及信噪比低。这些特性使得现有检测方法普遍面临漏检和误报的难题。

在ISTD研究的早期阶段，传统方法主导了该领域[5]。[6]，[7]，[8]，[9]，[10]这些方法主要依赖预先设定的假设和人工设计的特征。然而，由于红外图像中的背景复杂多变，依赖手动调整参数的方法通常适应性较差。在实际应用中，传统算法难以区分真实目标与背景杂波，导致严重的漏检和误报现象。

随着深度学习技术的发展，基于卷积神经网络（CNN）的检测方法已取得显著成果[11]。[12]，[13]，[14]，[15]，[16] [17]。由于传统卷积运算符具有固有的平移不变性和局部感受野特性，这些方法主要关注图像的局部信息。然而，红外图像中常存在与红外目标局部特征高度相似的区域，仅依靠局部信息难以准确区分这些区域。因此，建模目标与背景之间的长程依赖关系显得尤为重要。

近年来，视觉Transformer（ViT）[18]在下游计算机视觉任务中取得了突破性进展，推动了遥感领域中将Transformer与CNN相结合的多种混合架构的发展[19]。[20]，[21]，[22]，[23]，[24]，[25]这类架构通常通过自注意力机制及其变体来建模全局信息。尽管这些方法通过改进特征提取提升了检测性能，但也带来了显著的计算开销。此外，在计算权重时，自注意力机制倾向于捕捉图像中的低频成分[26]。[27]在红外场景中，背景通常变化平缓，这些低频特征更容易被注意力机制捕捉，从而使模型更专注于大尺度结构，并insu伍准确地识别小目标的高频细节。然而，红外小目标与背景之间的差异往往体现在细微的梯度

波动上（此类波动属于高频信号），而自注意力机制捕捉此类变化的能力有限。现有方法[28][29] 研究人员已开始通过频域建模来缓解这一问题，在一定程度上提升了信号的可区分性。然而，其对这些关键高频信号的感知能力仍显不足，导致难以凸显目标的详细特征。

除了特征提取层面存在的不足外，特征融合层面也面临诸多挑战。与可见光图像不同，红外小目标信息极为匮乏，且有效的语义信息在前向传播过程中会明显衰减。为解决这一问题，现有研究普遍采用静态融合策略[19]。

[21], [27], [28], [30], [31]该方法利用跳跃连接将浅层信息直接引入深层网络，用于特征添加或通道拼接。然而，浅层特征与深层特征具有不同的语义特征，因此对检测结果的贡献程度不均。这种使用固定连接权重的方法缺乏灵活性，难以自适应地学习不同输入下各特征的相对重要性，可能导致特征冗余或表征能力不足。值得注意的是，已有研究已表明浅层特征对于红外小目标的定位和分割精度至关重要[15]。[17], [32]通过促进高层次语义信息与精细细节之间的深度交互，深度网络中红外小目标的细微特征能够得到更有效的保留和凸显[33]。然而，现有的改进方法尚未充分挖掘这些浅层信息，在特征融合过程中导致目标细节未能被有效突出。

为应对这些挑战，本文提出了CSAFNet模型：该模型能够高效建模局部与全局上下文信息，并结合动态特征融合策略，显著提升目标特征在背景中的可区分性。在特征提取方面，我们设计了双分支并行自感知注意力（PSAA）模块，实现局部细节与全局语义的高效协同表征；该模块包含利用频域信息增强局部细节的小波动态增强器（WDE）分支，以及融合物理先验以建模全局信息的上下文感知放大器（CAA）分支。在特征融合环节，我们引入跨语义自适应过滤模块（CAFM），该模块基于不同层间的空间相关性自适应滤除噪声，并将关键目标特征传递至深度解码器。此外，我们在网络瓶颈处引入了动态多尺度空间金字塔（DMSSP）模块，该模块通过结合动态空间注意力机制、扩张卷积层和全局池化操作，显著提升了边缘识别精度，从而更精细地区分目标与背景。所有这些模块均以U形架构有机融合[34]，大量实验表明所提出的CSAFNet能够有效应对ISTD中的各项挑战。

我们的贡献总结如下。

- 1) 本文开发了一种高效的CSAFNet模型，旨在应对ISTD中的挑战，并显著提升目标与背景之间的区分度。
- 2) 针对特征提取，我们提出了一种具有双分支结构的PSAA模块，能够高效地联合建模局部与全局特征。
- 3) 在特征融合方面，我们引入了CAFM算法，该算法能够自适应地突出目标特征并滤除噪声。
- 4) DMSSP模块被集成到瓶颈层中，以提升边缘精度并利用多尺度上下文信息来增强分割准确性。

II. 相关工作

A. ISTD 的传统方法

传统的基于模型的ISTD方法已被广泛研究，通常可分为三大类：基于滤波的方法、基于局部对比度的方法以及基于低秩分解的方法。基于滤波的方法（如TopHat[35]和Max-median[5]）通常利用多种滤波器来估计背景并从复杂场景中分离目标；虽然这些方法在均匀背景环境中效果显著，但在杂乱或噪声环境中表现较差。基于局部对比度的方法通过利用目标与其周围背景之间的强度差异来提升目标检测能力，例如WSLCM[6]、ILCM[36]和TLLCM[7]等方法。然而，这些方法往往难以处理亮度较低或信号较弱的目标。基于低秩分解的方法则假设背景具有低秩特性，从而能有效区分目标与背景——例如IPI[10]将输入图像建模为低秩背景与稀疏目标的组合，而IPT[37]则同时整合了局部与非局部先验信息进行分解。PSTNN[38]采用基于张量核范数的非凸优化策略实现特征分离。总体而言，尽管传统方法在理想条件下表现良好，但其对人工设计特征和固定参数配置的依赖限制了其在实际应用中的鲁棒性。

B. 面向ISTD的深度学习方法

随着深度学习的兴起，数据驱动方法受到越来越多的关注。基于卷积神经网络（CNN）的方法能够自动学习特征并实现端到端检测。Wang等人[11]采用生成对抗网络来平衡漏检与误报。为缓解背景抑制不足的问题，Zhang等人提出了相应改进方案。[17]提出的AGPCNet模型，实现了注意力机制与多尺度上下文融合的模块化设计。Li等人。[16]研究人员利用密集嵌套的多尺度特征交互及级联注意力机制开发了DNANet，以保留并充分利用小型目标特征。Wu等人。[39]引入了采用深度监督和交叉注意力机制的UIUNet模型，以增强目标与背景之间的对比度。Lin等人。[40] Hu等人设计的CSRNet在解码器中集成了中心差分卷积和大核卷积，用于重建并突出目标边缘。[41]提出的SMPISD-MTPNet模型通过整合专家预设特征，实

现了目标检测与场景感知的联合学习。然而，仅依赖局部提取的特征并不充分——红外目标常与其周围环境高度相似，且有限的感受野可能导致漏检和误报。

为解决这一问题，学界提出了多种混合方法，其中大多数将视觉 Transformer (ViT) 整合到基于卷积神经网络 (CNN) 的框架中，以弥补局部细节处理能力的局限。Qi 等人亦提出类似方案。[24] 提出的 FTC-Net 模型，该模型结合 Transformer 与 CNN 特征，将全局上下文与局部显著性相结合。Wu 等人。[20] 设计了 MTU-Net，这是一种多层混合结构，旨在实现从粗到细的特征提取以及自适应尺度融合。Zhang 等人。[19] 提出了 RKformer 模型，该模型将龙格-库塔方法与 Transformer 网络相结合以提升检测精度。Pan 等人[21] 研究人员构建了 ABC 模型，该模型融合了卷积神经网络 (CNN) 的深度特征与 Transformer 结构的优势，并提出了卷积线性融合 Transformer，更加注重目标信号的局部相关性。Chen 和 Ye[28] 将频域特征及神经常微分方程引入编码器，构建了 FreqODEs 模型。尽管这些方法能实现高质量检测，但仍存在两个问题：1) 均采用基于窗口的交互方式来建模全局信息，导致计算复杂度较高；2) 对某些关键局部高频信号的感知能力有限。

与现有方案不同，本研究引入图像先验知识，构建了一种高效的全局信息建模方法，显著降低了模型的计算复杂度。在局部信息处理方面，我们采用频域信息而非空间域信息来增强局部特征表示，有效地突出目标对象中微弱但关键的信号特征。

C. 优化 ISTD 中的跳跃连接

基于 U-Net 架构的方法通过跳跃连接将低级细节特征与高级语义特征融合，从而缓解了下采样导致的特征损失 [42]。然而，静态融合方法并未有效地解决红外小目标检测 (ISTD) 中的挑战 [19]。[21], [27], [28], [30], [31] 为克服这一局限性，Dai 等人.....[15] 提出了不对称上下文调制 (ACM) 网络，该网络通过非对称的自上而下与自下而上结构实现对高层语义和低层细节的双向调制，首次证明了改进跨层特征融合以保留目标特征的 effectiveness。多种方法已设计出复杂的注意力模块以提升检测性能 [16]。[39] 例如，Li 等人。[16] 提出了一种密集嵌套式交互模块，通过高低层级之间的逐步交互来增强目标特征。Wu 等人。[39] 引入了交互式交叉注意力 (IC-A) 模块，通过低级与高级语义特征的交叉交互来增强局部对比度。Xu 等人 [31] 研究人员尝试增加跳过连接中传输的编码器特征数量，但在融合阶段仍采用静态连接方法，这限制了其在复杂及变化场景下的性能表现。近期，Dai 等人提出了改进方案。[43] 提出了大型选择性特征融

合 (LSFF) 模块，该模块通过动态融合策略显著提升了网络的特征判别能力，并特别强调了全局上下文的重要性。

尽管上述方法在特征融合领域已取得显著进展，但大多数融合策略仍将浅层特征视为辅助信息，未能充分挖掘其丰富的空间细节。在深度神经网络中，这种做法往往会导致浅层细节信息被抑制，从而阻碍关键目标区域的捕捉。为解决这一问题，本文提出了一种自适应方法用于提取并迁移重要的浅层特征：具体而言，我们建立了浅层与深层之间的跨层交互以实现信息整合，并引入空间选择机制来有选择地传递浅层细节线索，有效地抑制背景干扰并增强目标特征的显著性。

三. 方法

A. 整体架构

本文旨在设计一种简洁高效的 CNN 模型，该模型能够有效建模局部与全局上下文信息，并通过引入动态特征融合策略显著提升目标特征与背景的区分度。如图 1 所示，CSAFNet 是一种改进版的 U-Net 架构：具体而言，PSAA 模块替换了编码器和解码器中的标准卷积运算，从而高效提取目标特征；DMSSP 模块用于增强边缘特征，通过多尺度信息实现对目标与背景 differences 关系的精细建模；CAFM 模块采用动态特征选择机制，自适应地突出目标特征并滤除噪声。整体流程中，输入的红外图像首先经过主干网络处理，随后依次通过编码器和 DMSSP 模块进行特征提取与边缘特征增强；CAFM 模块则融合浅层与深层特征，将关键目标信息传递至深度编码器。最终，由点卷积层组成的预测头可生成与输入尺寸相同的单通道输出图。

B. 并行自我意识注意力机制

在 ISTD 领域，现有方法 [21][22], [23], [30] 现有方法通常侧重于改进自我注意力机制以捕捉全局信息，但这些方法往往 suffer 高昂的计算成本以及对局部细节关注不足。因此，我们提出了如图 2 所示的 PSAA 模块，用于实现高效的局部与全局建模。该模块采用双分支结构：CAA 分支负责探索非局部信息，WDE 分支则专注于局部信息建模。

总之，给定输入特征 $I \in \mathbb{R}^{H \times W \times C}$ ，CAA 分支和 WDE 分支分别并行处理特征 I 以生成非局部特征 $X_g \in \mathbb{R}^{H \times W \times C}$ and local feature $X_l \in \mathbb{R}^{H \times W \times C}$ 。随后将这两个特征相加，并通过压缩-激励 (SE) 模块 [44]。




图1. 所提出的CSAFNet架构概述。PSAA 是编码器和解码器的核心组件；CFAM 被引入跳跃连接层以增强特征融合效果；在网络瓶颈层中，DMSSP 模块用于优化目标与背景信息的提取。




图2. 所提出 PSAA 的示意图。该模型包含一个用于增强局部细节的 WDE 分支和一个用于建模全局信息的CAA分支。

首先获取融合特征。随后，在融合特征与输入 I 之间建立残差连接，通过三个 3×3 convolution layer and 1×1 卷积层进行逐元素相加并提升特征维度，从而得到 $X_f \in \mathbb{R}^{H \times W \times C}$ 。The final output $Y \in \mathbb{R}^{H \times W \times 2C}$ 。该过程可表示为：

$$X_f = SE(X_g + X_l) + I$$

$$Y = \text{Conv}_1(X_f) + \text{Conv}_3(X_f)$$

其中 $SE(\cdot)$ denotes SE block, $\text{Conv}_1(\cdot)$ represents the 1×1 convolution layer and $\text{Conv}_3(\cdot)$ corresponds to the 3×3 个卷积层。

1) 情境感知放大器：红外图像的物理特性表明，目标区域通常呈现局部能量集中现象，而背景区域则表现为能量分布分散。基于这一物理特性，本文提出的CAA模块引入SimAM模型中的神经元能量理论[45]，通过优化能量函数来定量评估每个神经元的重要性。其理论基础在于：在

视觉处理过程中表现出强烈空间抑制效应的神经元通常携带更丰富的判别特征信息。在能量空间中，能量值较低的神经元对应具有更强空间抑制效应和更高局部对比度的区域，这些区域可被视为潜在的目标区域。

具体而言，CAA首先从输入特征 I 中提取低频分量 e^*_l 以捕捉全局结构信息；同时通过能量函数计算输入特征的最小能量映射 e^*_t ，从而表征像素级能量响应分布；最终通过整合全局结构信息与基于能量的响应信息，CAA建立全局特征关联关系，引导模型更聚焦于呈现显著空间抑制效应的神经元。具体流程定义如下：

$$I' = \text{Conv}_1(I) \quad (3)$$

$$e^*_l = \text{Up}_N(\varphi(\text{DWConv}_3(\text{AP}(I')))) \quad (4)$$

$$e^*_t = \text{SimAM}_E(I') \quad (5)$$

$$X_g = \left(e^*_l + \frac{1}{e^*_t}\right) \odot I' \quad (6)$$

其中 X_g 表示非局部特征图， $\text{AP}(\cdot)$ 代表平均池化操作。值得注意的是，随着网络深度增加，在编码器的池化操作中会分别应用8、4和2的缩放因子，以确保池化输出尺寸保持为 $[H_0/8 \times W_0/8]$ （其中 H_0 和 W_0 分别表示原始图像的高度和宽度）。类似地，在解码器中使用2、4和8的缩放因子以保持空间维度的一致性。 $\text{DWConv}_3(\cdot)$ denotes a 3×3 depthwise convolution layer, $\varphi(\cdot)$ 表示 GELU 激活函数， $\text{Up}_N(\cdot)$ 指最近上采样操作， $\odot$ 表示元素级乘法运算，而 $\text{SimAM}_E(\cdot)$ 代表神经元能量计算，其最小能量函数定义如下：

$$\hat{\mu} = \frac{1}{M} \sum_{i=1}^M x_i \quad (7)$$

$$\hat{\sigma}^2 = \frac{1}{M} \sum_{i=1}^M (x_i - \hat{\mu})^2 \quad (8)$$

$$e^*_t = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{\mu})^2 + 2\hat{\sigma}^2 + 2\lambda} \quad (9)$$

其中 $\hat{\mu}$ 和 $\hat{\sigma}^2$ 分别表示除神经元 t 外所有神经元的均值与方差。能量值 e^*_t 越低，神经元 t 的分化程度越高。因此，每个神经元的重要性可通过 $1/e^*_t$ 计算得出。

2) **小波动态增强器**：频域信息在捕捉高频信号（如局部微小变化）方面具有天然优势[28]。[46], [47], [48]因此，本文提出一种基于小波变换的注意力分支 WDE，该方法利用小波变换的多分辨率分析能力揭示频域特征，从而增强目标图像中局部细节的表征效果。具体而言，我们首先对输入特征应用深度可分离卷积运算，得到 $F_q \in \mathbb{R}^{H \times W \times C}$ 。




图3. 哈尔小波变换通过连续的滤波步骤对信号进行分解。首先对原始数据分别应用低通滤波器和高通滤波器，分别获得近似系数和细节系数；每次分解均使数据量减半。该过程分别记为 $A(x)$ 和 $D(x)$ 。本文对特征量进行两层迭代分解：先沿行方向进行滤波，再沿列方向进行滤波，最终得到四个分量：低频分量 A 、水平高频分量 H 、垂直高频分量 V 以及对角线高频分量 D 。

且 $F_s \in \mathbb{R}^{H \times W \times C}$ ，其中 F_q 用于生成注意力权重， F_s 则作为局部表示。该过程可表述为：

$$F_q, F_s = \text{DWConv}_3(\text{Conv}_1(I)) \quad (10)$$

随后，对特征图 F_q 进行小波变换，得到三个高频分量 $[F_qH, F_qV, F_qD] \in \mathbb{R}^{H/2 \times W/2 \times C}$ ，这些分量随后被聚合形成 $F_h \in \mathbb{R}^{H/2 \times W/2 \times C}$ 。小波变换的具体过程如图3所示。接着，通过上采样、卷积和非线性变换生成感知权重 $F_a \in \mathbb{R}^{H \times W \times C}$ 。最后，将该感知权重与局部特征相乘以增强细节信息。整个过程可表述如下：

$$F_h = F_qH + F_qV + F_qD \quad (11)$$

$$F'_h = \text{Up}_N(F_h) \quad (12)$$

$$F_a = \tanh(\text{Conv}_1(\phi(\text{Conv}_1(F'_h)))) \quad (13)$$

$$X_l = F_a \odot F_s \quad (14)$$

其中 X_l 表示局部特征图， $\text{Conv}_1(\cdot)$ is a 1×1 convolution layer and $\tanh(\cdot)$ 代表双曲正弦函数。

C. 跨语义自适应过滤模块

在U-Net架构中，该模型通过融合浅层与深层信息[42]来缓解信息丢失问题。由于红外小目标的特征较为稀疏，其信息可能已在更深层被背景淹没，而浅层特征通常包含更多目标相关信息。为充分利用浅层中的关键信息，我们提出了 CAFM 模块。如图4所示，该模块建立了动态特征选




图4. 所提 CAFM 的示意图。该模块包含四个组成部分：细节估计、全局估计、空间选择与交互，以及重建。

择机制，能够自适应地将关键目标信息从浅层传递至深层解码器，从而增强目标显著性并抑制背景噪声。CAFM 由四个组件构成：细节估计、全局估计、空间选择与交互以及重建。

该模块采用不同的处理方法，根据浅层与深层的不同特征来提取信息。对于浅层特征 $X_L \in \mathbb{R}^{H \times W \times C}$ ，细节估计使用多尺度深度卷积来提取局部细节 $X_D \in \mathbb{R}^{H \times W \times C}$ ；for the deep feature $X_H \in \mathbb{R}^{H \times W \times C}$ ，全局估计则应用全局池化来提取全局信息 $X_G \in \mathbb{R}^{H \times W \times 1}$ 。随后， X_D 与 X_G 通过广播机制下的元素级加法运算进行融合，最终得到 $X' \in \mathbb{R}^{H \times W \times C}$ 。该过程定义如下：

$$X_D = \text{卷积层1}(\text{卷积}[\text{DWConv}_3(X_L), \text{DWConv}_{r=2}(X_L)])$$

$$(15) X_G = \text{Conv}_1(\text{卷积}[\text{CAP}(X_H), \text{CMP}(X_H)]) \quad (16)$$

$$X' = X_D + X_G \quad (17)$$

其中 $\text{DWConv}_{r=2}(\cdot)$ 表示扩张率为2的深度卷积运算， $\text{Cat}[\cdot]$ 表示通道拼接操作， $\text{CAP}(\cdot)$ 为通道级平均池化， $\text{Conv}_1(\cdot)$ 是 1×1 convolution layer and $\text{CMP}(\cdot)$ 为通道级最大池化。在空间选择与交互阶段，融合特征 X' 会被压缩为两个通道，以生成针对深层与浅层特征的空间描述符。经过softmax激活函数后，可得到空间选择权重 $W_L, W_H \in \mathbb{R}^{H \times W \times 1}$ ；这些权重与特征向量相乘后得到加权输出 $X'_L \in \mathbb{R}^{H \times W \times C}$ and $X'_H \in \mathbb{R}^{H \times W \times C}$ ，具体表达式如下：

$$W_L, W_H = \text{软最大值}(\text{Conv}_1(X')) \quad (18)$$

$$X'_L = W_L \odot X_L, X'_H = W_H \odot X_H \quad (19)$$

其中 $\text{Softmax}(\cdot)$ 表示 Softmax 函数。 X_L 和 X_H 这两个特征被重新引入网络作为先验知识，主要出于两个目的：1)

指导并优化特征学习；2) 改善梯度流动。浅层与深层空间特征通过交叉调制相互作用，生成空间相关性描述符 $W_S \in \mathbb{R}^{H \times W \times C}$ 。该过程定义如下：

$$\sim X'_L = \text{卷积}1(\text{Ch}_s(\text{类别}[X'_L, X_L])) \quad (20)$$

$$\sim X'_H = \text{卷积}1(\text{Ch}_s(\text{Cat}[X'_H, X_H])) \quad (21)$$

$$W_S = \sim X'_L \odot \sigma(\sim X'_H) + \sim X'_H \odot \sigma(\sim X'_L) \quad (22)$$

在该方程中， $\text{Ch}_s(\cdot)$ is the channel shuffle operation and $\sigma(\cdot)$ 表示Sigmoid函数。空间相关性描述符 W_S 通过Sigmoid函数进行加权处理，得到最终表示 $W_f \in \mathbb{R}^{H \times W \times C}$ ；随后利用该表示通过元素级乘法过滤浅层特征，从而完成重建过程。具体表达式如下：

$$W_f = \sigma(\text{Conv}_1(W_S)) \quad (23)$$

$$Y = W_f \odot X_L \quad (24)$$

此处， $Y \in \mathbb{R}^{H \times W \times C}$ 表示 CAFM 的输出结果。

D. 动态多尺度空间金字塔

DMSSP 可提升边缘精度，使模型能更精细地呈现目标与背景信息，从而提高小目标分割的准确性。

如图5所示，该模块包含三个并行分支。第一个分支采用扩张卷积来有效捕捉目标边缘，并强化对目标与背景之间空间结构差异的建模。具体而言，输入特征 $X \in \mathbb{R}^{H \times W \times C}$ 被划分为三个部分 $F0a^{5}$ 、 $F0b^{25}$ 和 $F0c^{25}$ ，其通道比为 2:1:1。每个部分分别通过扩张率分别为6、12和18的扩张卷积进行处理。提取出的多尺度特征随后经过批量归一化，经ReLU激活函数激活后沿通道维度拼接，并通过一个 1×1 卷积层以获得最终特征图 $f_m \in \mathbb{R}^{H \times W \times C}$ 。具体流程如下：




图5. 所提出的 DMSSP 结构。该结构整合了多尺度图像信息，从而能够更精细地建模目标特征与背景特征。

$$F0a^{0.5}, F^{0.25}, F^{0.125} = \text{分割}(X) \quad (25)$$

$$\hat{F}_a^{0.5} = \delta(\text{BN}(\text{DConv}_3^{r=6}(F_a^{0.5}))) \quad (26)$$

$$\hat{F}_b^{0.25} = \delta(\text{BN}(\text{DConv}_3^{r=12}(F_b^{0.25}))) \quad (27)$$

$$\hat{F}_c^{0.125} = \delta(\text{BN}(\text{DConv}_3^{r=18}(F_c^{0.125}))) \quad (28)$$

$$f_m = \text{卷积}(\text{Cat}[\hat{F}_a^{0.5}, \hat{F}_b^{0.25}, \hat{F}_c^{0.125}]) \quad (29)$$

其中 Split \$(\cdot)\$ 表示通道分割操作，BN \$(\cdot)\$ represents batch normalization, \$\delta(\cdot)\$ is ReLU, and \$\text{DConv}_3^{r=0}(\cdot)\$ 则指扩张率为 \$r_0\$ 的扩张卷积。

接下来，第二分支采用全局池化操作来聚合全局语义信息，从而获得全局特征 \$f_g \in \mathbb{R}^{H \times W \times C}\$。该过程定义如下：

$$f_g = \text{Up}_B(\text{Conv}_1(\text{GAP}(X))) \quad (30)$$

其中 GAP \$(\cdot)\$ 表示全局平均池化，\$\text{Up}_B(\cdot)\$ 表示双线性插值上采样。

此外，我们设计了一个无需超参数的空间注意力（HFSA）分支，用于自适应地优化相关像素区域。该设计灵感来源于 HFAM 模块[49]：其空间分支通过计算每个像素的均值，并利用方差来衡量其与背景的偏差。然而，由于红外目标信号较弱且存在局部强干扰，沿通道维度计算均值往往会掩盖小目标的关键响应特征。为解决这一问题，我们在每个通道内独立计算均值，从而确保特定通道中小目标的响应特征得以保留并增强。具体而言，我们首先计算输入数据的均值和方差，其 \$\text{th_c}\$ 形状为 \$\mathbb{R}^{1 \times 1 \times C}\$。\$\bar{\mu}_{[c]}\$ 表示第 \$c\$ 个通道上的均值，\$S_{[c]}\$ 表示第 \$c\$ 个通道上的方差，而 \$X_{[c], i, j}\$ 表示第 \$c\$ 个通道上的元素。其计算公式如下：

$$\bar{\mu}_{[c]} = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W X_{[c], i, j} \quad (31)$$

$$S_{[c]} = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (X_{[c], i, j} - \bar{\mu}_{[c]})^2. \quad (32)$$

The center deviation of each element is computed using \$\mu'_{[c], i, j} = m\$ 且为第 \$c\$ 个通道中的最小值。represent the maximum

矩阵 \$Q, \in \mathbb{R}^{H \times W \times C}\$ 的计算方法如下：

$$q_{[c], i, j} = \frac{\mu'_{[c]}}{M_{[c]} - m_{[c]} + \lambda} S_{[c]} \quad (33)$$

其中 \$\lambda\$ 是一个小常数，用于避免除以零；\$q_{[c], i, j}\$ 表示 \$Q\$ 第 \$c\$ 个通道的值。最后，应用 S 形激活函数得到空间权重矩阵 \$Q \in \mathbb{R}^{H \times W \times C}\$，该矩阵随后与输入特征相乘以生成 \$f_s \in \mathbb{R}^{H \times W \times C}\$。具体流程如下：

$$f_s = Q \odot X. \quad (34)$$

最后，\$f_m, f_g\$ 和 \$f_s\$ 被相加后输入卷积层，生成 DMSSP 输出 \$Y \in \mathbb{R}^{H/2 \times W/2 \times 384}\$。具体流程如下：

$$Y = \text{卷积}_3^{=2}(f_m + f_g + f_s) \quad (35)$$

在该方程中，\$\text{Convs}_3^{=2}(\cdot)\$ denotes a \$3 \times 3\$ 个卷积层，步长为 2。

E. 损失函数

我们采用深度监督训练策略，如图1所示。通过点卷积层将各尺度特征转换为单通道图，并应用上采样处理以匹配真实标注的空间分辨率。我们使用 SoftIoU 函数作为损失度量指标，以增强模型对小目标的检测灵敏度。该损失函数定义如下：

$$L_i = \text{SoftIoU}(y_i, \hat{y}), \quad L = \sum_{i=0}^4 L_i \quad (36)$$

其中 \$L\$ 表示损失函数，\$L_i\$ 代表第 \$i\$ 个尺度上的损失值，\$y_i\$ 为第 \$i\$ 个尺度上的预测掩码，\$\hat{y}\$ 则是真实掩码。

四. 实验

A. 实验设置

1) 数据集：本研究采用两个具有代表性的真实世界数据集——NUAA - SIRST[15]和IRSTD -1K[12]，用于模型训练与性能评估。这些数据集因其多样化的场景和复杂的目标特征而在学术界被广泛采用；其中 NUAA - SIRST 数据集包含 341 个训练样本和 86 个测试样本，而 ISTD -1K 数据集则包含 800 个训练样本和 201 个测试样本。

2) 评估指标：本文从两个方面对提出的 CSAFNet 模型进行评估。在像素层面，采用交并比（IoU）和归一化 IoU（nIoU）作为评估指标，其定义如下：

$$\text{IoU} = \frac{TP}{T + P - TP} \quad (37)$$

$$\text{nIoU} = \frac{1}{N} \sum_{i=1}^N \frac{TP(i)}{T(i) + P(i) - TP(i)} \quad (38)$$

表 1

与IRSTD-1K和NUAA-SIRST领域的最先进方法进行比较。性能最佳的方法以粗体标示。

方法	类型	Param	失败	IRSTD-1K				NU AA-SIR: 此为编号 Pd.				F _a
				IoU	nIoU	P _d	F _a					
MDVSFA[11]ACM	中心体	3.92M	998.6G	47.45	49.78	81.59	79.11	60.14	58.45	72.08	50.39	
[15]FC3-NET[51]	中心体	0.387M	2.01G	62.76	56.20	89.57	17.46	72.19	69.61	96.22	11.31	
DNA NET[16]	中心体	6.896M	10.572G	64.98	63.59	92.93	15.73	74.42	73.14	98.76	6.57	
AGP CNET[17]	中心体	4.7M	56.08G	65.96	67.33	91.58	12.94	72.30	74.39	94.34	21.21	
UIUNET[39]RD	中心体	22.469M	327.54G	68.81	66.18	94.26	15.85	77.92	76.31	95.31	10.82	
Ian[52]MTU NET	CNN CNN	50.541M	217.85G	71.34	66.38	93.73	16.68	80.31	78.63	98.11	5.06	
[20]ABC[21]se		2.74M	14.76G	64.71	61.39	91.64	19.35	74.52	73.44	92.55	8.18	
Rank Det[43]SC	混合版	4.07M	24.43G	69.57	67.25	93.26	13.04	79.74	77.51	97.17	7.63	
Trans Net[22]	杂种	106.99M	332.551G	72.02	68.81	93.76	9.46	80.34	79.02	97.16	2.19	
MSHNET[13]	杂种	108.89M	568.74G	73.66	69.11	94.28	8.37	79.96	78.60	98.11	2.15	
DRP CAN ET[53]	混合	11.19M	67.4G	68.03	68.15	93.27	10.74	76.14	79.49	94.34	2.73	
		4.07M	24.43G	67.87	61.70	92.86	8.88	78.03	77.90	100.00	11.36	
	CNN CNN	1.169M	73.837G	62.38	60.73	91.76	16.44	74.81	72.64	98.86	4.28	
水泥网（或称U型钢钢筋网）	中心体	4.298M	32.146G	74.29	69.83	94.95	10.42	81.56	79.57	100.00	0.49	

其中 N 表示样本总数, 而 T 、 P 和 TP 分别代表真实像素数、预测阳性像素数及真阳性像素数。在目标级评估中, P_d 表示正确预测的目标像素 N_{pred} 占有所有目标像素 N_{all} 的比例; F_a 则表示误预测目标像素 N_{false} 与红外图像中所有像素 N_{all} 的比值。 P_d 和 F_a 的计算公式如下:

$$P_d = \frac{N_{pred}}{N_{all}}, \quad F_a = \frac{N_{false}}{N_{all}}. \quad (39)$$

3) 实现细节: 所提出的算法基于PyTorch框架实现, 采用SoftIoULoss[50]作为损失函数、AdamW优化器以及多项式学习率衰减策略, 并引入了深度监督机制进行训练。所有实验均在 NVIDIA GeForce RTX 4090 GPU上完成, 批量大小设为4, 输入维度默认为32。模型在IRSTD-1K数据集上训练500个周期, 在NUAA-SIRST数据集上训练1500个周期。

B. 与SOTA方法的比较

大量实验研究表明, 在性能方面, 深度学习方法显著优于基于模型的方法[14]。[15], [16], [17], [30], [31][32]。基于此, 我们的研究并未重复此类基线比较, 而是专注于在两个公开数据集上评估并分析所提出方法与现有深度学习最先进(SOTA)方法的性能。具体而言, 我们将本方法与代表性CNN基方法(包括MDvsFA[11]、ACM[15]、FC3-Net[51]、DNA Net[16]、AGPCNet[17]、UIUNet[39]、RDIAN[52]、MSHNet[13])、DRPCANet[53]以及混合架构方法(包括MTUNet[20]、ABC[21]、SeRankDet[43]和SCTransNet[22])进行对比。

1) 定量比较: 表1展示了多种方法在两个基准数据集上的性能对比。实验结果表明, 提出的CSAFNet在像素级指

标(IoU 和 $nIoU$)以及目标级指标(P_d 和 F_a)方面均表现出最佳整体性能。IRSTD-1K数据集包含具有显著多尺度目标特征的多样化复杂场景, 使其成为ISTD领域极具挑战性的基准数据集。得益于PSAA、CAFM和DMSSP模块的协同效应, CSAFNet在低信噪比条件下展现出更强的目标识别能力, 并实现最佳像素级性能。在目标级评估中, 在保持较低 F_a 的同时实现较高的 P_d 颇具难度。尽管CSAFNet在 P_d 指标上表现领先, 但其 F_a 值比SeRank-Det高出2.05%。然而SeRankDet的性能提升是以模型复杂度显著增加为代价的: 参数数量多出25.34倍, 计算量增加17.69倍。相比之下, MSHNet在参数更少的情况下实现了更低的 F_a 值, 但其 P_d 反而下降了2.09%。总体而言, CSAFNet在性能与计算效率之间取得了良好平衡, 取得了更优的结果。

在NUAA-SIRST数据集上, CSAFNet在所有评估指标中均取得最佳性能。具体而言, P_d 值达到100%, 表明所有目标均被成功检测且误报率极低, 较第二佳算法SeRank-Det提升了1.66%。这些结果充分证明CSAFNet在定位精度、特征提取和目标区分能力方面均具有显著优势。

2) 视觉对比: 图6展示了IRSTD-1K和NUAA-SIRST数据集代表性图像的视觉检测结果, 清晰呈现了各方法之间的性能差异。结果表明, 在目标尺寸较小且信噪比较低的场景中, 我们的方法能够实现高精度定位, 并显著降低漏检率与误报率。

具体而言, 在样本1和样本2中, 大多数对比方法均存在严重的漏检问题; 而仅CSAFNet能正确检测所有目标。在样本3中, 基于卷积的方法(如ACM和DNA Net)要么将连续目标分割成多个片段, 要么仅检测高强度区域; 即便是SCTransNet这类混合方法也只能.....




图6. 使用不同方法对 NUAAs - SIRST 和 IRSTD -1K数据集代表性图像检测结果的可视化对比。图中红色方框表示正确检测结果，绿色方框表示漏检结果，黄色方框表示误报结果。




图7. (a) IRSTD -1k与(b) NUAAs - SIRST 数据集上的ROC曲线。

该方法能够精准识别目标图像中的高亮区域，而我们的方法则能完整分割整个目标。对于样本4而言，尽管大多数方法都能检测较大目标，但其边缘分割的准确率仍显不足；在样本5中，则明显可见多数方法在区分真实目标与误报方面存在局限性，仅MSHNet和CSAFNet能准确识别真实目标。综上所述，本文提出的方法不仅能更精确地定位真实目标，还能在轮廓等细节特征的分割精度上表现更优。

3) **ROC曲线比较**：与定量比较不同，ROC曲线能更全面地评估不同阈值下的性能表现。图7展示了我们的方法与其他 SOTA 方法的ROC曲线对比结果。总体而言，

ROC曲线越靠近左上角，表示性能越好。可以观察到，我们的方法在 IRSTD -1K和 NUAAs - SIRST 数据集上均取得最佳性能，并且收敛速度最快。这表明我们的模型在准确性和效率之间实现了良好平衡，同时具备强大的鲁棒性，进一步验证了其优于现有 SOTA 方法的优势。

C. 消融研究

1) **各模块的消融研究**：表II展示了以标准U-Net为基准时的消融结果。我们逐步添加所提出的各个模块，系统评估其单独及组合对检测性能的贡献。除数值比较外，我们还提供了如图8所示的可视化结果。显而易见




图8展示了CSAFNet中特征图在分割模块之前的可视化效果，说明了单独或组合引入不同模块所产生的影响。图中标注(a)–(e)的字母代表不同的消融策略：红色矩形标示正确检测结果，紫色圆圈表示背景噪声。

表 II
IRSTD-1K上各模块的消融研究

Strategy	U-Net	PSAA	DMSSP	CAFM	IoU	$nIoU$	P_d	F_a	参数失败	
(a)	✓	×	×	×	68.37	66.71	90.58	17.06	32.085M	203.01G
(b)	✓	✓	×	×	71.73	68.68	93.06	14.39	3.786M	24.739G
(c)	✓	✓	✓	×	73.28	69.42	94.17	12.86	4.140M	25.919G
(d)	✓	✓	×	✓	73.46	69.44	94.29	11.55	3.945M	30.966G
(e)					74.29	69.83	94.95	10.42	4.298M	32.146G

每个模块均能提升检测性能。具体而言，PSAA 模块能有效捕捉局部细节与全局上下文信息，从而提高目标保留率，尽管仍存在部分背景噪声；CAFM 模块可成功抑制背景中的无关高频成分，精准凸显微小目标特征，有效缓解误检问题；DMSSP 模块则显著提升边缘分割质量并提高分割精度。综合来看，三个模块的协同作用实现了最佳性能，充分证明了各组件的有效性与互补性。

2) 缩放因子在CAA 中的影响：在编码器的不同阶段，CAA采用不同的缩放因子以保持空间维度的一致性，从而更好地保留图像的结构信息。在此过程中，缩放因子的组合表示为 $\{r_1, r_2, r_3\}$ 。实验中我们测试了多种缩放因子组合，以探索适用于红外小目标分割的最佳配置方案。如表

表 III

基于IRSTD-1K的CAA结垢系数消融研究

缩放因子	IoU	$nIoU$	P_d	F_a
$\{32, 16, 8\}$	73.43	69.01	93.26	12.63
$\{16, 8, 4\}$	73.91	69.39	93.93	11.35
$\{8, 4, 2\}$	74.29	69.83	94.95	10.42
$\{4, 2, 1\}$	73.40	69.16	93.94	11.87

III所示，我们比较了多种组合方案的分割性能，结果表明将缩放因子设为 $\{8, 4, 2\}$ 时可获得最佳的整体分割效果。

3) PSAA 模块的影响：表IV展示了PSAA 模块的消融实验结果，证实了双分支结构在全局-局部特征协同建模中的有效性。上下文感知增强器（CAA）分支与WDE分支分别负责提取全局信息和局部信息。通过移除各分支进行了对比实验：当移除CAA分支时

表 IV
PSAA 对IRSTD-1K的消融研究

方法	IoU	$nIoU$	P_d	F_a
PSAA (不含CAA)	73.42	69.21	93.72	12.83
PSAA(w/o WDE)	72.96	68.94	93.44	13.06
PSAA	74.29	69.83	94.95	10.42

表 V
IRSTD-1K上 CAFM 的消融研究

方法	IoU	$nIoU$	P_d	F_a
元素级加法: 通道级联	73.28、69.42、94.17、12.86			
CAFM	74.29	69.83	94.95	10.42




图9.三种特征融合方法在 ISTD -1K数据集上的特征可视化对比：I为元素级加法，II为通道拼接，III为 CAFM。红色方框表示正确检测结果，黄色圆圈表示误报。

移除相关特征后， IoU 、 $nIoU$ 和 P_d 均有所下降，而 F_a 则显著上升。这表明目标与背景之间的关系得以保持，验证了CAA所建模的全局信息在检测和识别隐藏目标中的关键作用。移除WDE分支会导致检测性能显著下降：由于缺乏局部细节信息，模型感知高频特征的能力受损，导致关键细节丢失，进而引发误报和漏检现象。究其原因，局部细节信息的缺失严重削弱了模型对高频特征的感知能力，致使关键细节信息丢失，从而引发误报和漏检。整合两个分支可实现最佳性能，充分体现了二者有效的特征互补性：CAA有效探索潜在目标区域，而WDE则专注于提取高频细节特征。

4) CAFM 的影响：表V中的定量结果及图9中的可视化结果通过与两种常见的静态跳跃连接策略对比，验证了CAFM在ISTD任务中的有效性。元素级加法策略在像素

表 VI
IRSTD-1K上 DMSSP 的消融研究

方法	IoU	$nIoU$	P_d	F_a
DMS SP (不含 OH FSA)	73.90、69.67、94.50、10.95			
DMSSP	74.29	69.83	94.95	10.42

级指标上表现优异，较高的 P_d 值表明其具有强大的目标发现能力；但该方法会无差别地添加所有特征，导致浅层产生的高频噪声传播至深层，这种噪声会干扰目标识别并显著提升 F_a 值。通道拼接策略仅简单堆叠不同层的特征，难以学习特征间的相对重要性，从而降低目标细节表征的质量；此外，缺乏特征选择机制也削弱了其判别能力。

相比之下，CAFM模块通过建立有效的空间交互关系和动态选择机制，实现了降噪与特征增强的双重效果。它不仅提升了细节精度，还实现了 P_d 与 F_a 之间的良好平衡。

5) DMSSP 模块的影响：表VI展示了DMSSP模块的消融实验结果。为验证HFSA在网络中的有效性，我们将完整模型与移除HFSA分支的变体模型进行对比。结果表明，移除HFSA会导致性能下降。这些结果说明，HFSA通过更有效地聚焦像素级细节，提升了模型定位边界和识别小型目标的能力。

V. 结论

本文中，我们提出CSAFNet模型以应对从复杂背景中分割红外小目标的挑战。该模型高效地建模了局部与全局上下文信息，并通过结合动态特征融合策略提升了目标与背景之间的区分度。我们设计了PSAA模块来同时建模局部与非局部信息，使网络能够有效保留关键目标特征；同时提出CAFM模块，其通过空间交互自适应地定位任务相关区域并筛选关键目标细节；最后，DMSSP模块整合多尺度信息以提升边缘精度，从而提高分割准确率。在NUAA-SIRST和IRSTD-1K数据集上的实验表明，CSAFNet在ISTD任务中表现卓越。

参考文献

- [1] X. Tong 等人, "ST-trans: 用于连续图像中红外小目标检测的空间-时间变换器", *IEEE 地球科学与遥感汇刊*, 第62卷, 2024年, 文章编号: 5001819.
- [2] 赵明、李伟、李磊、胡杰、马鹏和陶瑞, 《单帧红外小目标检测: 综述》, *IEEE 地球科学与遥感杂志*, 第10卷第2期, 第87-119页, 2022年6月.
- [3] B. 杨、X. 张、J. 张、J. 罗、M. 周和Y. 皮, "EFLNet: 增强红外小目标检测的特征学习网络", *IEEE 地球科学与遥感汇刊*, 第62卷, 2024年, 文章编号: 5906511.
- [4] F. 吴、S. 刘、H. 王、B. 涂、J. 罗和Z. 彭, "红外小目标检测中的神经空间-时间张量表示", *模式识别*, 第169卷, 2026年1月, 文章编号: 111929.