

条形R-CNN:用于遥感目标检测的大型条形卷积

袁新斌¹郑兆辉¹李玉轩¹刘夏雷¹刘丽³李翔^{1,2}霍启斌^{1,2*}Cheng Ming-Ming^{1,2*}

¹VCIP, 计算机科学学院, NKU ²NKIARI, 福田, 深圳, 中国

³中国湖南长沙先进技术研发学院

yxb@mail.nankai.edu.cn, {houqb, cmm}@nankai.edu.cn

项目页面: <https://github.com/HVision-NKU/Strip-R-CNN>

摘要

尽管遥感目标检测技术发展迅速, 但对于高长宽比目标的检测仍面临挑战。本文研究表明, 大条带卷积是遥感目标检测的理想特征表示学习器, 能够有效检测各种长宽比的目标。基于大条带卷积, 我们构建了一种名为Strip R-CNN的新型网络架构, 该架构简洁高效且性能强劲。与近期采用方形大核卷积的遥感目标检测器不同, 我们的Strip R-CNN通过主干网络StripNet采用顺序正交大条带卷积来捕捉空间信息。此外, 我们通过解耦检测头并在条带头中为定位分支配备条带卷积, 显著提升了遥感目标检测器的定位能力。在DOTA、FAIRIM、HRSC2016和DIOR等多个基准测试集上的大量实验表明, 我们的Strip R-CNN能大幅改进先前研究。特别是我们的30M模型在DOTA-v1.0数据集上取得了82.75%的平均精度, 创下新的最先进纪录。我们的代码将公开提供。

1. 介绍

遥感目标检测近年来因其在无人机和卫星拍摄的航拍图像中的应用而受到广泛关注[30, 31, 34, 35, 41, 44, 57, 78]。一种基于旋转框的流行流程被构建用于覆盖目标对象。由于边界不连续性和方块化问题[67, 71, 72]以及对长距离信息捕获的迫切需求[1, 32], 许多研究

*通讯作者




图1. DOTA 数据集[62]的统计结果及若干最新最先进检测器的检测性能。可见细长物体（长宽比>3）占比显著，且随着长宽比增大，先前最先进模型的检测性能逐渐下降。

在开发更强的旋转物体检测器方面已取得突破, 包括物体表示[29, 63, 64, 66]、IoU模拟损失函数[67, 71–73]以及基础模型[1, 32, 51]等。

尽管先前的工作取得了巨大进展, 但在遥感目标检测中普遍存在的高长宽比目标的成功检测仍是一个具有挑战性的问题。为证明这一点, 我们在图1中计算了广泛使用的DOTA数据集[62]的统计结果, 该数据集显示细长目标在遥感场景中相当常见且通常占据数据的很大比例。我们还通过实验发现, 现有的目标检测方法[1、19、32、64、71、72]往往难以处理细长目标, 其检测性能会随着目标长宽比的增加而下降。

我们认为, 检测这些目标的困难主要源于两个挑战。首先, 高长宽比




图2.多种遥感目标检测器在 DOTA 数据集上的检测性能综合对比。

物体在空间维度上具有丰富的特征信息，而在另一维度上则呈现相对稀疏的特征。基于卷积神经网络的传统检测器主要通过方形窗口提取输入特征图，这种设计极大限制了其有效捕捉遥感图像中常见的各向异性背景的能力，导致周围区域的无关信息被纳入检测结果。其次，高长宽比物体因其独特的几何特性，在回归任务中面临重大挑战。与常规物体检测不同，遥感物体检测需要额外进行角度回归。对于高长宽比物体，即使角度估计出现微小误差，也可能导致与真实值产生显著偏差。

迄今为止，关于如何处理具有挑战性的高长宽比物体的研究仍较少。先前方法中广泛采用的通用策略是通过大核卷积来扩大模型的感受野[3、11、12、37]。典型代表当属LSKNet[32]，该模型通过引入带有空间选择机制的大核卷积来捕捉长距离上下文信息。PKINet[1]进一步扩展了LSKNet，采用并行大方卷积结构以提升物体尺度变化范围的性能。然而，使用多个大核卷积的并行范式会加剧计算负担，复杂的模块设计也进一步限制了模型效率。对于物体长宽比的高变化范围，如何高效利用大核卷积仍是未解难题。

本文提出了一种名为Strip R-CNN的新型网络架构，该架构能高效融合方形卷积与条形卷积的优势，同时显著降低特征冗余。我们的设计遵循双重原则：首先，网络架构需保持简洁高效；其次，即使面对高分辨率的长宽比各异物体，仍能保持良好处理能力。针对遥感图像中物体的特殊属性，我们创新性地采用正交大条形卷积作为核心空间滤波器，这一设计构成了StripNet主干网络的核心组件。

我们将其称为条带模块。因此，我们的网络结构虽然简单，但能很好地泛化到高长宽比物体，如图1所示。此外，为应对前文提到的第二个挑战，我们在条带头中解耦了先前遥感目标检测中使用的检测头，并通过条带卷积强化了定位分支。研究发现，这种设计不仅能提升方法的定位能力，还能更精准地回归目标框角度。

据我们所知，Strip R-CNN是首个探索如何利用大型条带卷积进行遥感目标检测的研究。尽管结构简单且轻量级，我们的Strip R-CNN在标准DOTA基准测试中无需额外组件即可达到顶尖性能，如图2所示。值得注意的是，仅含3000万可学习参数的Strip R-CNN-S模型在DOTA排行榜上以82.75%的平均精度（mAP）取得最佳成绩。我们还在FAIR1M、HRSC2016和DIOR等多个遥感数据集上进行了大量实验，证明Strip R-CNN的优越性。我们希望这些设计原则能为遥感影像研究领域带来新的研究启示。

2. 相关工作

遥感目标检测。在遥感场景中，当目标具有任意方向时，通常采用旋转边界框进行目标表示。早期的旋转边界框表示使用五个参数 (x, y, w, h, θ) [10、39、69、77]。然而，由于角度的周期性，基于此表示训练的模型在回归中常面临边界不连续性问题[67、71、73]。为解决此问题，多种方法提出了改进的旋转边界框表示[15、29、59、63、64、66、70、74]。例如，Oriented R-CNN[64]用中点偏移量替代角度，得到六参数表示 $(x, y, w, h, \Delta\alpha, \Delta\beta)$ ，显著提升了检测器性能。COBB[63]提出了一种基于最小包围矩形长宽比与旋转边界框面积的九参数连续旋转框表示方法。此外，也有研究聚焦于通过损失函数缓解边界回归中的不连续性问题[7、24、52、71、72]。例如，GWD[71]和KLD[72]将旋转边界框转换为二维高斯分布，并采用高斯瓦瑟斯坦距离和库拉克-莱布勒散度作为损失函数。KFIoU[73]则运用高斯建模与卡尔曼滤波，提出了SKewIoU损失函数。

尽管先前研究已取得重大进展，但在遥感目标检测中普遍存在的高长宽比目标成功检测仍具挑战性。




图3. 我们提出的条带模块与其他采用大核卷积的代表性方法（包括LSKNet[32]和PKINet[1]）的结构对比。

伸展问题。我们的方法充分考虑了这些物体带来的困难，并利用大条带卷积使网络能够很好地泛化到具有挑战性的细长物体上，据我们所知，这在该研究领域尚未被探索过。

用于遥感目标检测的大核网络。大核卷积已成为遥感目标检测领域新兴且有前景的解决方案，其在图像分类和分割中的性能已得到验证，与基于Transformer的方法具有高度竞争力[3、11、12、16、17、25、26、37、75]。在遥感目标检测中，部分方法致力于利用大核卷积获取长距离上下文信息[1、33]。例如，LSKNet[33]采用大核卷积和选择机制来建模不同目标类别所需的上下文信息；PKINet[1]并行排列多个大核卷积以提取不同感受野间的密集纹理特征，并引入上下文锚点注意力机制来捕捉远距离像素间的关联。然而，采用多大核卷积的并行架构会显著增加计算负担，复杂的模块设计也导致模型效率低下。针对物体长宽比的高变异性，如何高效利用大核卷积仍是亟待解决的难题。据我们所知，Strip R-CNN是首个探索如何利用大核卷积进行遥感目标检测的研究工作。

3. 条形R-CNN

本节将详细阐述所提出的Strip R-CNN架构。我们的目标是通过引入大卷积条带结构来提升遥感目标检测性能，从而使模型能够有效处理不同长宽比的物体。这与既往研究采用的em-




图4. 我们StripNet主干的基本模块结构。

表1. StripNet骨干网的变体。 C_i : 特征通道数; D_i : 每个阶段 i 的条带块数。

模型	$\{C1, C2, C3, C4\}$	$\{D1, D2, D3, D4\}$	#P	FLOPs*StripNet-T
StripNet-T	{32,64,160,256}	{3,3,5,2}	3.8M	18.2G
StripNet-S	{64,128,320,512}	{2,2,4,2}	13.3M	52.3G

如图3所示，强调了使用大平方核卷积的重要性。

3.1. 总体体系结构

基于O-RCNN 框架[64]，我们的Strip R-CNN分别用StripNet骨干和strip头替换了骨干网络和检测头。具体而言，骨干网络主要由图4所示的基本模块构成，包含两个残差子模块：strip子模块和前馈网络子模块。strip子模块基于小核标准卷积和两个大条形核卷积构建，用于捕捉不同长宽比物体的鲁棒特征。前馈网络子模块直接沿用LSKNet[32]，用于促进通道混合和特征精炼。StripNet骨干不同变体的详细配置见表1。骨干层结构与LSKNet[32]保持一致。检测头方面，我们将定位分支与原始O-RCNN 头解耦，并通过提出的strip模块增强，最终形成strip头，具体将在第3.3节展示。

3.2. 条带模块

如第1节所述，大方形核卷积为遥感应用提供了关键的长距离上下文信息。PKINet[1]通过引入并行大方形核卷积和空间注意力机制来提取空间信息。然而，利用多个大核卷积的并行范式会加剧计算负担，复杂的模块设计也导致模型效率低下。我们的目标是高效提取不同长宽比物体的关键特征。最终成果是一种顺序范式，无需额外信息融合模块即可高效结合标准卷积与条带卷积的优势。下文将详细阐述去




图5. 有向R-CNN头部与条带头部的结构对比。在我们的条带头部中，分类头与角度预测头共享两个全连接层，而定位头则整合了我们的条带模块。

我们基本模块的核心描述：**条形模块**。

给定一个输入张量 $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ ，具有 C 个通道，首先应用一个方形核 $\mathbf{K} \in \mathbb{R}^{C \times k_H \times k_W}$ 的深度卷积来提取局部上下文特征，得到 $\mathbf{Z}$ ，其中 $H \times W$ 和 $k_H \times k_W$ 分别是特征尺寸和核尺寸。在实际应用中，我们将 $k_H \times k_W$ 设置为 5×5 。在初始深度卷积后，我们使用两个连续的大型条形核深度卷积来更好地捕捉高长宽比的物体。输出记为 $\hat{\mathbf{Z}}$ 。与标准卷积每次从方形区域提取特征不同，大型条形卷积允许网络更专注于沿水平或垂直轴的特征。水平和垂直大型条形卷积的联合使用使网络能够跨空间轴收集方向性特征，从而增强空间维度中细长或狭窄结构的表征。

为了进一步增强特征在通道维度上的交互作用，我们应用简单的逐点卷积将 $\hat{\mathbf{Z}}$ 转换为 $\mathbf{Y}$ 。通过这种方式，生成的特征图 $\mathbf{Y}$ 的每个位置都能编码宽广空间区域内的水平和垂直特征。最后，根据[17, 26]，我们将特征图 $\mathbf{Y}$ 视为注意力权重，用于重新加权输入 $\mathbf{X}$ ，其可表述为

$$\hat{\mathbf{Y}} = \mathbf{X} \cdot \mathbf{Y}, \quad (1)$$

其中 ‘ $\cdot$ ’ 表示逐元素乘法运算。图4展示了所提出的条带卷积模块的示意图。在实验中，我们将探讨如何选择条带卷积的核尺寸。

需要特别强调的是，我们的骨干网络StripNet比图3所示的采用大核卷积的早期遥感目标检测器要简单得多。在基础模块设计中，我们既未采用空间或通道注意力机制，也未使用不同类型大核卷积的复合融合操作。这种设计既保持了StripNet的简洁性，又使其在各类遥感检测基准测试中表现出色。




图6. 定向RCNN头与本条带的空间相关性图对比。本条带头在输出特征图中呈现显著更多的空间相关性。




图7. 输出特征图中分类、定位及角度预测的空间敏感性热图对比。

此外，我们发现应用水平条带卷积与垂直条带卷积之间不存在显著差异，反之亦然。两种方法均有效。

3.3. 带条形卷积的检测头

在定位任务中，模型应对变换敏感，因为定位的准确性取决于输入对象的位置。先前的强旋转对象检测器[1、32]采用了Oriented R-CNN框架[64]，其检测头共享用于分类和定位的相同线性层，如图5所示。然而，如图[61]所示，线性层的空间相关性有限，这使得它们对变换不敏感，不适合精确定位。

一个更优的解决方案可能是解耦分类与定位任务，并采用文献[61]中提出的定位分支小核卷积技术。然而，我们对空间相关图的分析表明，小核卷积仅能捕捉短程空间相关性（如图6左图所示）。这些短程相关性不足以准确定位细长物体，这类物体需要长程依赖关系。为有效定位不同长宽比的物体，我们认为定位头应能像主干网络处理的那样捕捉长程依赖关系。大条带卷积能同时捕捉广域空间的水平与垂直特征，为优化定位提供了必要的扩展空间相关性。因此，我们建议在定位分支中采用大条带卷积来增强检测器的定位能力。

定位功能

此外，同时预测参数 x 、 y 、 w 、 h 和 θ 可能会导致特征耦合问题[76]。为解决这一问题，我们将 θ 的预测与其他参数（ x 、 y 、 w 、 h ）解耦。基于这种解耦方法，我们研究了输出特征图中分类和角度预测的空间敏感区域。空间敏感热图如图7所示，第一列代表分类敏感度，第二列显示角度敏感度。我们的观察发现，分类的空间敏感度集中在物体中心区域，而角度敏感度主要集中在物体边缘附近。分类和角度预测的敏感区域存在部分重叠，并表现出互补特性。基于此，我们提出使用共享全连接层同时进行分类和角度预测。条带头的结构如图5底部所示。详细设置如下所述。

分类头：分类头仅使用两个全连接层，输出维度为1024。如双头 RCNN [61]所示，使用全连接层是分类头的优选方案，因此我们保持其不变。

定位头：定位头首先通过标准的 3×3 卷积层提取局部特征，随后添加条带模块，再通过全连接层捕捉长程空间依赖关系。

角度头：在角度预测中，我们采用三个全连接层来估计角度信息，实践证明该方案效果良好。需注意的是，前两个全连接层与分类头共享参数。

需要特别指出的是，我们的检测头采用了创新设计的条带模块。相较于原始的定向R-CNN头部，这一设计显著提升了检测性能。如图6所示，通过不同方法的空间敏感性可视化对比发现，定向R-CNN头部在输出特征图上呈现相似的空间关联模式。而我们的条带头部在输出特征图中展现出更强的空间关联性。我们将通过实验验证，这种设计使我们的方法能够更精准地定位高长宽比物体。

4. 实验

4.1. 实验设置

数据集。我们在五个主流的遥感目标检测数据集上进行了大量实验。

- **DOTA -v1.0**[62] 是一个用于遥感检测的大规模数据集，包含2,806张图像、188,282个实例和15个类别。

表2. 与不同骨干网络模型在DOTAv1.0上的对比。参数（Params）和浮点运算次数（FLOPs）仅针对骨干网络计算。所有骨干网络均在ImageNet上预训练300个周期。我们的StripNet-S模型达到的平均精度（mAP）高于先前流行的骨干网络。

模型（骨干）	#P↓	浮点运算数/	帧率	mAP（百分比）
ResNet-50 [21]	23.3M	86.1G	21.8	75.87
LSKNet-S [32]	14.4M	54.4G	20.7	77.49
PKINet-S [1]	13.7M	70.2G	12.0	78.39
*StripNet-S	13.3M	52.3G	17.7	80.06

- **DOTA -v1.5**[62] 是一个更具挑战性的数据集，包含403,318个实例和16个类别。
- **FAIR1M-v1.0**[56] 是一个遥感数据集，包含15,266张图像、100万实例和37个类别。
- **HRSC2016**[38] 是一个遥感数据集，包含1061张航拍图像和2976个实例。
- **DIOR-R**[5] 包含 23,463 张图像和 192,518 个实例。

实现细节。我们的训练过程分为两个阶段：在ImageNet[9]上进行预训练，以及在下游遥感数据集上进行微调。在消融实验中，我们训练所有模型100个周期。为获得更高性能，最终结果中模型训练周期为300个周期。DOTA、DOTAv1.5、HRSC2016、FAIR1M-v1.0和DIOR-R的训练周期数分别设置为12、12、36、12和12，遵循先前方法。学习率分别设置为0.0001、0.0001、0.0004、0.0001和0.0001。HRSC2016和DIOR-R的输入尺寸为 800×800 ，而DOTA -v1.0、DOTA -v1.5和FAIR1M-v1.0数据集的输入尺寸为 1024×1024 。训练期间采用AdamW[42]优化器，其 $\beta_1=0.9$ ， $\beta_2=0.999$ ，权重衰减为0.05。所有模型均在8 NVIDIA 3090显卡，批量大小为8，测试在单个NVIDIA 3090显卡上进行。

4.2. 主要结果

我们首先在DOTA v1.0数据集上，将我们的Strip R-CNN与采用Oriented R-CNN[64]框架实现的强骨干网络的最新前沿方法进行对比。如表2所示，Strip R-CNN-S在参数减少0.4%、计算量仅为PKINetS[1]所需74.3%的情况下，实现了1.67%的性能提升。此外，Strip R-CNN-S在参数减少1.1%、计算量减少2.2%的情况下，较LSKNet-S[32]展现出2.57%的性能增强。

DOTA -v1.0上的结果[62]。我们对不同模型进行了比较分析，并展示了DOTA数据集上各类别的平均精度（mAP）和平均精度（AP）的详细结果（更多模型结果参见补充材料）。如表3所示，我们的单尺度评估显示1.67%的提升-

表3.基于 DOTA -v1.0数据集的单尺度与多尺度训练测试方法与 SOTA 方法的对比。StripNet-S主干网络在ImageNet上经过300个epoch的预训练。†: 采用MoCAE[49]中的模型集成方法。

方法	前。	mAP↑	#P↓	浮点运算数/	PL	BD	BR	GTF	SV	左心室	SH	TC	BC	ST	SBF	RA	哈	SP	HC
单尺度																			
EMO2-DETR [27]	IN	70.91	74.3M	304G	87.99	79.46	45.74	66.64	78.90	73.90	73.30	90.40	80.55	85.89	55.19	63.62	51.83	70.15	60.04
CenterMap [60]	IN	71.59	41.1M	198G	89.02	80.56	49.41	61.98	77.99	74.19	83.74	89.44	78.01	83.52	47.64	65.93	63.68	67.07	61.59
AO2-DETR [8]	IN	72.15	74.3M	304G	86.01	75.92	46.02	66.65	79.70	79.93	89.17	90.44	81.19	76.00	56.91	62.45	64.22	65.80	58.96
SASM [23]	IN	74.92	36.6M	-	86.42	78.97	52.47	69.84	77.30	75.99	86.72	90.89	82.63	85.66	60.13	68.25	73.98	72.22	62.37
O-RCNN [64]	IN	75.87	41.1M	199G	89.46	82.12	54.78	70.86	78.93	83.00	88.20	90.90	87.50	84.68	63.97	67.69	74.94	68.84	52.28
R3Det-GWD [71]	IN	76.34	41.9M	336G	88.82	82.94	55.63	72.75	78.52	83.10	87.46	90.21	86.36	85.44	64.70	61.41	73.46	76.94	57.38
COBB [63]	IN	76.52	41.9M	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
R3Det-KLD [72]	IN	77.36	41.9M	336G	88.90	84.17	55.80	69.35	78.72	84.08	87.00	89.75	84.32	85.73	64.74	61.80	76.62	78.49	70.89
ARC [73]	IN	77.35	74.4M	217G	89.40	82.48	55.33	73.88	79.37	84.05	88.06	90.90	86.44	84.83	63.63	70.32	74.29	71.91	65.43
LSKNet-S [32]	IN	77.49	31.0M	161G	89.66	85.52	57.72	75.70	74.95	78.69	88.24	90.88	86.79	86.38	66.92	63.77	77.77	74.47	64.82
PKINet-S [1]	IN	78.39	30.8M	190G	89.72	84.20	55.81	77.63	80.25	84.45	88.12	90.88	87.57	86.07	66.86	70.23	77.47	73.62	62.94
RTMDet-R [43]	IN	78.85	52.3M	205G	89.43	84.21	55.20	75.06	80.81	84.53	88.97	90.90	87.38	87.25	63.09	67.87	78.09	80.78	69.13
★ 条纹R-CNN-S	IN	80.06	30.5M	159G	88.91	86.38	57.44	76.37	79.73	84.38	88.25	90.86	86.71	87.45	69.89	66.82	79.25	82.91	75.58
多尺度																			
CSL [67]	IN	76.17	37.4M	236G	90.25	85.53	54.64	75.31	70.44	73.51	77.62	90.84	86.15	86.69	69.60	68.04	73.83	71.10	68.93
DODet [6]	IN	80.62	-	-	89.96	85.52	58.01	81.22	78.71	85.46	88.59	90.89	87.12	87.80	70.50	71.54	82.06	77.43	74.47
AOPG [5]	IN	80.66	-	-	89.88	85.57	60.90	81.51	78.70	85.29	88.85	90.89	87.60	87.65	71.66	68.69	82.31	77.32	73.10
KFIoU [73]	IN	80.93	58.8M	206G	89.44	84.41	62.22	82.51	80.10	86.07	88.68	90.90	87.32	88.38	72.80	71.95	78.96	74.95	75.27
PKINet-S [1]	IN	81.06	30.8M	190G	89.02	86.73	58.95	81.20	80.41	84.94	88.10	90.88	86.60	87.28	67.10	74.81	78.18	81.91	70.62
RTMDet-R [43]	马	81.33	52.3M	205G	88.01	86.17	58.54	82.44	81.30	84.82	88.71	90.89	88.77	87.37	71.96	71.18	81.23	81.40	77.13
RVSA [58]	马	81.24	114.4M	414G	88.97	85.76	61.46	81.27	79.98	85.31	88.30	90.84	85.06	87.50	66.77	73.11	84.75	81.88	77.58
LSKNet-S [32]	IN	81.64	31.0M	161G	89.57	86.34	63.13	83.67	82.20	86.10	88.66	90.89	88.41	87.42	71.72	69.58	78.88	81.77	76.52
★ 条带状R-CNN-T	IN	81.40	20.5M	123G	89.14	84.90	61.78	83.50	81.54	85.87	88.64	90.89	88.02	87.31	71.55	70.74	78.66	79.81	78.16
★ 条纹R-CNN-S	IN	82.28	30.5M	159G												71	79.2	82.4	82.82
★ 条带状R-CNN-S†	IN	82.75	30.5M	159G	88.99	86.56	61.35	83.94	81.70	85.16	88.57	90.88	88.62	87.36	75.13	74.34	84.58	81.49	82.56

表4.基于 DOTA -v1.5数据集的单尺度训练与测试方法与 SOTA 方法的对比。StripNet-S主干网络在ImageNet上经过300个epoch的预训练。

方法	RetinaNet-O [36]	FR-O [53]	Mask RCNN [22]	HTC [4]	ReDet [20]	DCFL [65]	LSKNet-S [32]	PKINet-S [1]	条纹R-CNN-S
mAP (百分比)	59.16	62.00	62.67	63.40	66.86	67.37	70.26	71.47	72.27

在PKINet-S上的表现。此外，通过多尺度训练和测试，我们单个模型的平均准确率（mAP）达到82.28%。通过集成RTMDet和Strip R-CNN的结果，并遵循MoCAE[49]中的模型集成策略，我们实现了82.75%的mAP，创下新的最先进纪录。

DOTA -v1.5上的结果[62]。如表4所示，在这个实例极少的数据集中，我们的方法取得了优异的性能，证明了其对小物体的有效性和泛化能力。我们的Strip R-CNN优于之前的最先进方法，提高了0.8%。

FAIR1M-v1.0上的结果[56]。表5中的结果表明，我们的Strip R-CNN达到了48.26%的高竞争力mAP分数。我们的方法可将LSKNet[32]的mAP提升0.39%，并以显著优势超越所有其他方法。

DIOR-R上的结果[5]。如表7所示，我们观察到相较于LSKNet[32]提高了2.80%，相较于PKINet[1]提高了1.67%。

HRSC2016上的结果[38]。我们在VOC2012[14]指标下达到98.70%的mAP，这是当前最先进的性能，较PKINet[1]提升0.16%的mAP，较LSKNet[32]提升0.24%的mAP。结果如表6所示。

在多个数据集上，我们的方法始终超越先前的最先进方法，证明了其泛化能力和有效性。

4.3. 消融研究

条带卷积的核尺寸。条带卷积中的核尺寸对我们的条带模块至关重要。我们从11开始，以4为增量逐步增大核尺寸进行实验。较小的核尺寸无法有效捕捉提高长宽比物体的特征，而15的核尺寸已能获得满意效果，19的核尺寸则进一步提升了性能。为更直观展示大核条带卷积的优势，我们通过可视化分析不同核尺寸下的特征表示。图8表明，采用较大核尺寸的条带卷积能够学习到

表5.与 SOTA 方法在FAIR1M-v1.0数据集上的对比。StripNet-S主干网络在ImageNet上预训练300个周期。*：结果引自FAIR1M论文[56]。


方法	G. V.* [66]	RetinaNet* [36]	C-RCNN* [2]	F-RCNN* [53]	RoI Trans.* [10]	O-RCNN [64]	LSKNet-S [32]	条纹R-CNN-S
mAP (百分比)	29.92	30.67	31.18	32.12	35.29	45.60	47.87	48.26

表6. HRSC2016数据集上与 SOTA 方法的对比。mAP (07/12)：VOC 2007[13]/2012[14]指标。StripNet-S主干网络在ImageNet上预训练300个周期。

方法	前。	mAP (07) ↑	mAP (12) ↑	#P ↓	浮点运算数 /
DRN [50]	IN	-	92.70	-	-
DAL [45]	IN	89.77	-	36.4M	216G
GWD [71]	IN	89.85	97.37	47.4M	456G
AOPG [5]	IN	90.34	96.22	-	-
O-RCNN [64]	IN	90.50	97.60	41.1M	199G
RTMDet [43]	哥伦比亚	90.60	97.10	52.3M	205G
LSKNet-S [32]	IN	90.65	98.46	31.0M	161G
PKINet-S [1]	IN	90.65	98.54	30.8M	190G
★ 条纹R-CNN-S	IN	90.60	98.70	30.5M	159G

表7. DIOR-R与 SOTA 方法的对比。StripNet-S主干网络在ImageNet上经过300个epoch的预训练。

方法	前。	#P ↓	浮点运算数 /	mAP (百分比)
RetinaNet-O [36]	IN	-	-	57.55
更快的 RCNN -O [53]	IN	41.1M	198G	59.54
TIOE-Det [47]	IN	41.1M	198G	61.98
O-RCNN [64]	IN	41.1M	199G	64.30
ARS-DETR [79]	IN	41.1M	198G	66.12
O-RepPoints [29]	IN	36.6M	-	66.71
DCFL [65]	IN	-	-	66.80
LSKNet-S [32]	IN	31M	161G	65.90
PKINet-S [1]	IN	30.8M	190G	67.03
★ 条纹R-CNN-S	IN	30.5M	159G	68.70



输入图像内核尺寸：11 内核尺寸：15 内核尺寸：19图8. 不同内核尺寸的特征图可视化。内核尺寸19能更准确地捕捉高长宽比物体的特征。

该方法能更精准地定位细长物体特征，并有效锐化物体边界。我们在StripNet主干网络的四个阶段测试了不同核尺寸，同时探索了递增与递减策略。浅层采用较大核尺寸与深层使用较小核尺寸相结合时效果显著，而浅层使用较小核尺寸会导致性能大幅下降，这表明浅层更适合采用较大感受野。因此，我们最终确定19作为StripNet主干网络各阶段条带模块的最佳核尺寸。

表8. 我们提出的条带模块在StripNet主干网络四个阶段的核尺寸消融研究。我们采用在ImageNet上预训练100个周期的StripNet-S主干网络。在所有阶段使用核尺寸19时获得最佳结果。

内核大小	#P ↓	浮点运算数 /	mAP (百分比)
(19,19,19,19)	13.30M	52.34G	81.75
(15,15,15,15)	13.28M	52.19G	81.64
(11,11,11,11)	13.26M	52.03G	81.22
(15,17,19,21)	13.31M	52.26G	81.37
(21,19,17,15)	13.29M	52.34G	81.72

表9. 我们提出的条带模块设计的消融研究。我们采用在ImageNet上预训练100个周期的StripNet-S主干网络。d：膨胀率。

5 × 5 方凸	大条纹卷积		#P ↓	浮点运算数 /	mAP (百分比)
	顺序的	并行			
✗	✓	✗	13.23M	51.84G	81.38
✓	✓	✗	13.30M	52.34G	81.75
✓	✗	✓	13.33M	52.52G	81.54
✓	19 × 19 方凸		14.17M	58.41G	81.44
✓	7 × 7 方形凸面d=3		13.30M	52.34G	81.55

条带模块设计的消融实验。我们通过消融实验分析条带模块的设计选择，如表9所示。首先评估深度方向方形卷积的作用，移除该组件会导致性能大幅下降，这凸显了方形卷积在捕捉方形物体特征方面的重要性。接着考察水平与垂直大条带卷积的整合方式，对比并行与顺序排列方案。顺序配置优于并行方案，因为后者缺乏有效的二维建模，仅简单组合两个条带卷积而未能捕捉整体物体结构。此外，将顺序排列的大条带卷积替换为19 × 19大核卷积或7 × 7扩张卷积（扩张率3）时，均出现显著性能下降，这进一步验证了大条带卷积的有效性。

StripNet骨干网络的有效性。为验证我们提出的StripNet骨干网络的通用性和有效性，我们使用多种遥感检测框架进行了实验。如表17所示，我们的方法将RoI Transformer[10]的性能提升了7.11%。它还

表10. StripNet-S主干网络在其他遥感目标检测框架中的有效性。
StripNet-S主干网络在ImageNet[9]上进行了100个周期的预训练。

方法	脊梁骨	#P↓	浮点运算数↓	mAP (百分比)
RoI 转录[10]	ResNet-50 [21]	41.1M	211.4G	74.61
	StripNet-S	13.3M	52.3G	81.72
S ² ANet [19]	ResNet-50 [21]	41.1M	211.4G	79.42
	StripNet-S	13.3M	52.3G	80.52
R3Det [68]	ResNet-50 [21]	41.1M	211.4G	76.47
	StripNet-S	13.3M	52.3G	79.01
YOLO [43]	CSPNeXt-l [21]	52.3M	80.2G	78.02
	StripNet-S	13.3M	52.3G	78.50
ARS-DETR [79]	ResNet-50 [21]	41.1M	211.4G	72.08
	StripNet-S	13.3M	52.3G	75.07

该方法分别将S²ANet和R3Det的性能提升0.9%和2.54%。当集成到YOLO和DETR框架时，我们的方法持续提升性能，充分证明其在增强各类检测器方面的广泛兼容性和有效性。

条带头设计的消融。在设计条带头时，我们首先将头部解耦为 (x, y) 、 (w, h) 和 θ 分支，并将条带模块应用于 (x, y) 或 (w, h) 分支。这种方法显示出中等程度的改进。将 (x, y) 和 (w, h) 分支结合使用会获得稍好的结果，这可能是由于物体位置和形状信息具有互补且相似的特征。对于 θ 分支，我们发现全连接层的表现略优于卷积层。因此，我们在 θ 分支中采用两个全连接层，并与分类分支共享这些层，因为分类和角度预测的敏感区域存在部分重叠并具有互补特性，如第3.3节所述。简单地将条带模块应用于定位分支即可产生显著改进。我们认为，针对不同回归参数定制的更专业结构可进一步提升性能。结果见表11。

条带头的效能验证。如表12所示，我们对比了两种不同检测器在引入条带头前后的性能表现。实验结果表明，我们的条带头能持续提升其他检测器的性能，充分验证了其有效性和普适性。以ROI Transformer为例，我们的方法实现了5.0 mAP的显著提升，这一进步堪称亮眼。同样，其他检测器Rotated Faster R-CNN也获得了性能优化，进一步证明我们的方法可广泛应用于各类检测器，并能有效提升其检测性能。

表11. 条带头设计的消融研究。 fc 指使用两个全连接层。 $conv$ 指使用两个 3×3 卷积层。 $strip$ 指用我们设计的条带模块替换后者的 3×3 卷积层。我们采用在ImageNet上预训练100个周期的StripNet-S主干网络。

不同头结构	mAP (百分比)
$(x, y, w, h, cls, \theta)_{fc}$	81.75
$(x, y)_{conv}, (w, h)_{conv}, (cls)_{fc}, (\theta)_{fc}$	81.76
$(x, y)_{conv}, (w, h)_{conv}, (cls)_{fc}, (\theta)_{conv}$	81.72
$(x, y)_{strip}, (w, h)_{conv}, (cls)_{fc}, (\theta)_{fc}$	81.88
$(x, y)_{conv}, (w, h)_{strip}, (cls)_{fc}, (\theta)_{fc}$	81.77
$(x, y)_{conv}, (w, h)_{conv}, (cls)_{fc}, (\theta)_{strip}$	81.81
$(x, y, w, h)_{strip}, (cls)_{fc}, (\theta)_{fc}$	81.86
$(x, y, w, h)_{strip}, (cls, \theta)_{fc}$	81.96
$(x, y, w, h)_{strip}, (cls)_{fc}, (\theta)_{strip}$	81.93

表12. 条形头在其他旋转探测器上的有效性

方法	头	mAP (百分比)
更快的 RCNN -O [53]	原头	76.17
	带状头	77.88
RoI 转录[10]	原头	74.61
	带状头	79.37

4.4. 视觉分析

我们在图9中还展示了检测结果和Eigen-CAM[48]可视化效果。可以看出，对于高长宽比物体，Oriented-RCNN 和LSKNet等传统方法存在漏检和定位误差过大的问题。相比之下，我们的方法能成功检测这类高长宽比物体。Eigen-CAM可视化结果也显示，我们的方法对这些物体具有显著激活，验证了该方法的有效性。

此外，为了进一步验证我们的方法在检测高长宽比物体方面的优越性，我们在DOTA数据集上进行了额外实验。模型在DOTA训练集上进行训练，并按照[80]中采用的评估方法在验证集上进行测试。我们评估了不同长宽比物体的检测性能。如图1所示，结果表明在1-5的长宽比范围内，我们的方法与先前方法表现相当，仅存在细微差异。然而对于长宽比较大的物体，我们的方法展现出明显优势。

5. 结论

本文针对遥感场景中细长物体检测的挑战，提出基于大条带卷积的创新方案，通过优化特征提取与定位精度提升。我们设计的Strip R-CNN模型结构简洁却效果显著，大量实验表明该方法不仅具备强大的泛化能力，更在多个遥感基准测试中取得业界领先水平。




图9.上图：检测结果。我们的Strip R-CNN方法能够成功捕获高长宽比物体。下图：EigenCAM可视化。本方法的EigenCAM可视化显示高长宽比物体具有强激活，进一步验证了我们方法的有效性。

希望本研究能促进遥感领域中目标检测技术的发展。

参考文献

- [1] 蔡欣豪、赖秋霞、王宇伟、王文官、孙泽仁和姚亚舟。用于遥感检测的多核感知网络。发表于*CVPR*，第27706–27716页，2024。[1](#)、[2](#)、[3](#)、[4](#)、[5](#)、[6](#)、[7](#)
- [2] 蔡昭伟与努诺·瓦斯康塞洛斯。Cascade R-CNN：深入探索高质量目标检测。在*CVPR*，2018。[7](#)，[2](#)
- [3] 陈洪浩、楚香香、任永健、赵欣和黄凯奇。Pelk：具有外围卷积的参数高效大核卷积网络。在*CVPR*，第5557–5567页，2024。[2](#)，[3](#)
- [4] 陈凯、庞江淼、王佳琪、熊宇、李晓晓、孙书阳、冯万森、刘子伟、石建平、欧阳万里、陈变洛伊、林大华。实例分割的混合任务级联。在*CVPR*，2019。[6](#)，[3](#)
- [5] 龚程、王佳宝、李珂、谢星星、郎春波、姚艳青、韩俊伟。面向无锚点的物体检测提案生成器。*IEEE TGRS*，60:1–11,2022。[5](#)、[6](#)、[7](#)、[1](#)、[3](#)
- [6] 龚程、严庆瑶、李胜阳、李科、谢兴兴、王佳宝、姚希文、韩俊伟。双对齐定向检测器。*IEEE TGRS*，2022。[6](#)，[3](#)
- [7] 龚程、严庆瑶、李胜阳、李科、谢兴兴、王佳宝、姚希文、韩俊伟。双对齐定向检测器。*IEEE TGRS*，2022。[2](#)
- [8] Linhui Dai、Hong Liu、Hao Tang、Zhiwei Wu 和 Pinhao Song。AO2-DETR：任意方向目标检测变换器。*IEEE TCSVT*，2022。[2](#)，[6](#)，[3](#)
- [9] 贾登、魏东、Richard Socher、李丽佳、李凯和李飞飞。ImageNet：一个大规模分层图像数据库。在*CVPR*，2009。[5](#)，[8](#)，[4](#)
- [10] 建鼎、南雪、杨龙、夏贵松和陆启凯。用于航拍图像中方向性目标检测的学习RoI变换器。在*CVPR*，2019。[2](#)，[7](#)，[8](#)，[3](#)，[4](#)
- [11] 丁晓涵、张向宇、韩俊功和丁贵光。将卷积核扩展至 31×31 ：重访CNN中的大核设计。在*CVPR*，2022。[2](#)，[3](#)
- [12] 丁晓涵、张一元、葛一晓、赵思杰、宋林、岳向宇、沈颖。Unireplknet：一种用于音视频点云时间序列和图像识别的通用感知大核卷积网络。在*CVPR*，第5513–5524页，2024。[2](#)，[3](#)
- [13] M. Everingham、L. Van Gool、C. K. I. Williams、J. Winn 和 A. Zisserman。2007年帕斯卡视觉对象分类挑战赛（VOC2007）结果，2007年。[7](#)
- [14] M. Everingham、L. Van Gool、C. K. I. Williams、Winn 和 A. Zisserman。2012年帕斯卡视觉对象分类挑战赛（VOC2012）结果，2012年。[6](#)，[7](#)
- [15] 孔福、钟汉昌、张跃、孙贤。空中图像任意方向目标检测的点估计器。*IEEE TGRS*，59(5):4370–4387,2020。[2](#)
- [16] 郭梦浩、陆成柔、刘正宁、程明明和胡世勇。视觉注意力网络。*计算视觉媒体*，2022。[3](#)，[1](#)，[2](#)
- [17] 郭梦浩、卢成泽、侯启斌、刘正宁、程明明和胡世敏。SegNeXt：重新思考卷积注意力设计在语义分割中的应用。在*NeurIPS*，2022。[3](#)，[4](#)，[1](#)，[2](#)
- [18] 郭宗浩、刘长、张晓松、焦建斌、季向阳、叶启祥。超越边界框：面向密集密集物体检测的凸包特征适应。在*CVPR*，2021。[3](#)
- [19] Jiaming Han、Jian Ding、Jie Li 和 Gui-Song Xia。对齐深度特征以实现定向目标检测。*IEEE TGRS*，2020。[1](#)，[2](#)，[8](#)，[3](#)，[4](#)
- [20] 韩佳明、丁健、薛楠和夏贵松。ReDet：一种用于空中目标检测的旋转等变检测器。在*CVPR*，2021。[6](#)，[3](#)
- [21] 何凯明、张向宇、任少青和孙健。深度残差学习用于图像识别。在*CVPR*，2016。[5](#)，[8](#)，[4](#)
- [22] Kaiming He, Georgia Gkioxari, Piotr Dollár, 以及 Ross Girshick。Mask R-CNN。In *ICCV*，2017年。[6](#)，[3](#)
- [23] 侯立平、陆珂、薛健、李玉秋。有向对象检测的形状自适应选择与测量。在*AAAI*，2022。[6](#)，[3](#)
- [24] 侯立平、陆科、杨雪、李玉秋、薛健。Grep：面向任意方向物体检测的高斯表示。*遥感*，15(3):757,2023。[2](#)
- [25] 侯启斌、周大泉和冯佳石。协调注意力以实现高效的移动网络设计。在*CVPR*，第13713–13722页，2021。[3](#)
- [26] 侯启斌、卢成泽、程明明和冯佳石。Conv2former：一种用于视觉识别的简单Transformer式卷积网络。*IEEE TPAMI*，2024。[3](#)，[4](#)
- [27] 胡子波、高坤、张晓端、王俊伟、王红、杨志佳、李晨睿和李伟。Emo2-detr：基于Transformer的高效匹配导向目标检测。*IEEE TGRS*，2023。[6](#)，[3](#)
- [28] Steven Lang、Fabrizio Ventola 和 Kristian Kersting。DAFNe：一种用于定向物体检测的单阶段无锚深度模型。*CoRR*，2021。[3](#)
- [29] 李文通、陈一杰、胡凯轩和朱建科。航拍目标检测的定向重点。见*CVPR*，第1829–1838页，2022。[1](#)，[2](#)，[7](#)

- [30] 李伟杰、杨伟、侯元安、刘力、刘永祥和李翔. Saratr-x: 构建SAR目标识别基础模型. *arXiv预印本*, 2024. 1
- [31] 李伟杰、杨伟、刘天鹏、侯元南、李玉轩、刘振、刘永祥和刘丽. 预测梯度更优: 探索联合嵌入预测架构的自监督学习用于sar atr. *ISPRS 摄影测量与遥感杂志*, 218:326–338,2024. 1
- [32] 李宇轩、侯启斌、郑昭辉、程明明、杨健和李翔. 用于遥感目标检测的大型选择性核网络. 在 *ICCV*, 2023. 1, 2, 3, 4, 5, 6, 7
- [33] 李宇轩、李翔、戴义曼、侯启斌、刘力、刘永祥、程明明和杨健. Lsknet: 一种用于遥感的轻量级骨干网络. *IJCV*, 2024. 3
- [34] 李宇轩、李翔、李伟杰、侯启斌、刘力、程明明、杨健. Sardet-100k: 迈向大规模SAR目标检测的开源基准与工具包. *NeurIPS*, 2024. 1
- [35] 李宇轩、李翔、李云恒、张一诚、戴一民、侯启斌、程明明和杨健. Sm3det: 一种统一的多模态遥感目标检测模型. *arXiv预印本 arXiv:2412.20665*, 2024. 1
- [36] 林宗义、普里亚·戈亚尔、罗斯·吉尔希克、何凯明和皮奥特·多尔ár. 密集目标检测的焦点损失. 在 *ICCV 2017* 中 6, 7, 2, 3
- [37] 刘世伟、陈天龙、陈晓汉、陈旭熙、肖乔、吴伯谦、Mykola Pechenizkiy、Decebal Mocanu 和 王章阳. 2020年代更多卷积网络: 利用稀疏性将内核扩展至51x51以上. *ArXiv*, 2022. 2, 3
- [38] 刘子坤、王洪振、翁鲁斌、杨一平. 基于船舶旋转边界框空间的复杂背景高分辨率光学卫星图像船舶提取. *TGRS 快报*, 2016. 5, 6, 1
- [39] 刘子坤、王洪珍、翁鲁斌、杨一平. 基于船舶旋转边界框空间的复杂背景高分辨率光学卫星图像船舶提取方法. *IEEE TGRS*, 13(8):1074–1078,2016. 2
- [40] Zhuang Liu、Hanzi Mao、Chao- Yuan Wu、Christoph Feichtenhofer、Trevor Darrell 和 Saining Xie. 一个面向2020年代的卷积网络. 在 *CVPR*, 2022. 1
- [41] 杨龙、易平功、肖志峰、刘庆. 基于卷积神经网络的遥感图像精确目标定位. *IEEE TGRS*, 55(5):2486–2498,2017. 1
- [42] Ilya Loshchilov 和 Frank Hutter. 解耦权重衰减正则化. *ArXiv*, 2017. 5
- [43] 刘成奇、张文伟、黄海安、周跃、王玉东、刘燕怡、张世龙、陈凯. RTMDet: 实时目标检测器设计的实证研究. *CoRR*, 2022. 2, 6, 7, 8, 3
- [44] 杰梅、郑一博和程明明. D2ANet: 用于卫星影像多级变化检测的差异感知注意力网络. *计算视觉媒体*, 2023. 1
- [45] 戚明、周志强、苗玲娟、张洪伟、李林豪. 任意方向目标检测的动态锚点学习. *CoRR*, 2020. 7
- [46] 齐明、宋俊杰和周志强. 高分辨率卫星影像中细粒度目标识别的定向特征对齐. *ArXiv*, 2021. 2
- [47] 戚明、苗玲娟、周志强、宋俊杰、董云鹏、薛阳. 航拍图像中高精度定向目标检测的任务交错与方向估计. *ISPRS 摄影测量与遥感杂志*, 196:241–255,2023. 7
- [48] Mohammed Bany Muhammad 和 Mohammed Yeasin. Eigen-CAM: 基于主成分的分类激活图. *CoRR*, 2020. 8
- [49] Kemal Oksuz、Selim Kuzucu、Tom Joy 和 Puneet K Dokania. Mocae: 校准专家的混合显著提升目标检测能力. *ArXiv*, 2023. 6, 3
- [50] 潘兴佳、任宇强、盛克凯、董伟明、袁浩雷、郭晓伟、马重阳、徐长生. 面向密集密集物体检测的动态精炼网络. 在 *CVPR*, 2020. 7
- [51] 付一凡、王一儒、夏卓凡、韩一增、王玉林、甘伟豪、王子东、宋世基和黄高. 自适应旋转卷积用于旋转物体检测. 发表于 *ICCV*, 第6589–6600页, 2023. 1, 2
- [52] 温倩、薛阳、彭思龙、严俊驰和郭跃. 学习调制损失用于旋转物体检测. 在 *AAAI*, 2021. 2
- [53] 邵庆仁、何凯明、Ross Girshick 和孙健. 更快的 R-CNN: 基于区域提议网络的实时目标检测. 在 *NeurIPS*, 2015. 6, 7, 8, 2, 3
- [54] 宋俊杰、苗玲娟、齐明、周志强和董云鹏. 通过自适应标签分配和精炼平衡特征金字塔网络实现遥感图像的细粒度目标检测. *IEEE应用地球观测与遥感精选专题期刊*, 16:71–82,2022. 2
- [55] Xian Sun, Peijin Wang, Wanxuan Lu, Zicong Zhu, Xiaonan Lu, Qibin He, Junxi Li, Xue Rong, Zhujun Yang, Hao Chang, et al. Ringmo: 一种具有掩码图像建模的遥感基础模型. *IEEE TGRS*, 61:1–22,2022. 2
- [56] 孙贤、王培金、严志远、徐峰、王瑞平、刁文辉、陈金、李继豪、冯英超、徐涛、Martin Weinmann、Stefan Hinz、王程、傅坤. FAIR1M: 高分辨率遥感影像细粒度目标识别基准数据集. *ISPRS 摄影测量与遥感杂志*, 2022. 5, 6, 7, 1
- [57] 孙贤、田宇、陆万宣、王培金、牛瑞刚、余洪峰、傅坤. 从单模态到多模态遥感影像解释: 一项调查与分类. *中国科学信息*, 2023. 1
- [58] 王迪、张启明、徐玉飞、张静、杜波、陶大成、张良培. 推进平面视觉变换器向遥感基础模型发展. *IEEE TGRS*, 2022. 6, 3

- [59] 金王王、建鼎、郭浩文、程文生、潘婷、杨文。Mask obb: 一种基于语义注意力的掩码导向边界框表示方法, 用于航空图像中的多类别目标检测。《遥感》, 11 (24):2930,2019。2
- [60] 王金旺、杨文、李恒超、张海建、夏贵松。用于检测航拍图像中物体的学习中心概率图。《IEEE TGRS》, 2021。6, 3
- [61] 岳武、陈银鹏、卢源、刘子诚、王丽娟、李洪志和付云。重新思考目标检测的分类与定位。在《CVPR》, 第10186–10195页, 2020。4, 5
- [62] 夏桂松、白翔、丁健、朱振、Serge Belongie、罗杰波、达特库米海、Marcello Pelillo和张亮培。DOTA: 航空图像中大规模目标检测数据集。在《CVPR》, 2018。1, 5, 6
- [63] 肖子凯、杨国业、杨雪、穆太江、严俊驰、胡世民。理论实现定向边界框的连续表示。在《CVPR》, 第16912–16922页, 2024。1、2、6、3
- [64] Xingxing Xie、Gong Cheng、Jiabao Wang、Xiwen Yao 和 Junwei Han。Oriented R-CNN 用于目标检测。In《ICCV》, 2021。1, 2, 3, 4, 5, 6, 7
- [65] 张旭、丁健、王金旺、杨文、余怀、余磊和夏贵松。面向微型目标检测的动态粗到细学习。在《CVPR》, 第7318–7328页, 2023。6, 7
- [66] 徐永超、傅明涛、王启萌、王玉康、陈凯、夏贵松、白翔。多方向目标检测中的水平边界框滑动顶点。《IEEE TPAMI》, 2021。1, 2, 7, 3
- [67] Xue Yang 与 Junchi Yan。基于圆形平滑标签的任意方向目标检测。In《ECCV》, 2020。1, 2, 6, 3
- [68] 薛阳、刘清清、严俊驰、李安。R3Det: 面向旋转物体的特征精炼单阶段检测器。《CoRR》, 2019。8, 2, 3, 4
- [69] 薛阳、杨继瑞、严俊驰、张跃、张腾飞、郭志、孙贤和傅坤。SCRDet: 面向小型、杂乱及旋转物体的更稳健检测。在《ICCV 2019》中。2, 3
- [70] 薛阳、侯丽萍、周跃、王文涛、严俊驰。边界不连续性无旋转检测的密集标签编码。在《CVPR》, 第15819–15829页, 2021。2
- [71] 薛阳、严俊驰、齐明、王文涛、张晓鹏和田琦。基于高斯 Wasserstein 距离损失的旋转物体检测重新思考。在《ICML》, 2021。1, 2, 6, 7, 3
- [72] 薛阳、肖江阳、杨继瑞、齐明、王文涛、齐天和严俊驰。通过 Kullback-Leibler 散度学习高精度边界框用于旋转物体检测。《NeurIPS》, 2021。1, 2, 6, 3
- [73] 薛阳、周越、张格凡、杨继瑞、王文涛、严俊驰、张晓鹏和田琦。旋转物体检测的 KFIOU 损失。发表于《ICLR》, 2022。1、2、6、3
- [74] 景如毅、彭向武、刘波、黄巧英、曲辉和迪米特里斯·梅塔克萨斯。基于边界感知向量的航拍图像定向目标检测。载于《WACV》, 第2150–2159页, 2021年。2
- [75] Bowen Yin、Xuying Zhang、Zhongyu Li、Li Liu、Ming-Ming Cheng 和 Qibin Hou。Dformer: 重新思考 rgb-d 表示学习在语义分割中的应用。《ICLR》, 2024。3
- [76] 洪天宇、田云杰、叶启祥、刘云帆。面向对象检测的空间变换解耦。收录于《AAAI》, 第6782–6790页, 2024。5
- [77] 易宇和戴飞鹏。相移编码器: 在定向物体检测中预测精确方向。见《CVPR》, 第13354–13363页, 2023。2
- [78] Syed Sahil Abbas Zaidi、Mohammad Samar Ansari、Asra Aslam、Nadia Kanwal、Mamoona Asghar 和 Brian Lee。现代基于深度学习的目标检测模型综述。《数字信号处理》, 2022。1
- [79] 曾颖、陈宇石、杨雪、李庆云、严俊驰。Ars-detr: 面向空中目标检测的长宽比敏感检测变换器。《IEEE TGRS》, 62:1–15,2024。7, 8
- [80] 郑昭辉、陈宇明、侯启斌、李翔、王平和程明明。区域评估: 揭示物体检测中的空间偏差。《IEEE TPAMI》, 2024。8

条形R-CNN:用于遥感目标检测的大型条形卷积

补充材料

6. 数据集详情

DOTA -v1.0 [62] 是一个用于遥感检测的大规模数据集，包含2806张图像、188,282个实例和15个类别：飞机（PL）、棒球场（BD）、桥梁（BR）、地面运动场（GTF）、小型车辆（SV）、大型车辆（LV）、船舶（SH）、网球场（TC）、篮球场（BC）、储油罐（ST）、足球场（SBF）、环岛（RA）、港口（HA）、游泳池（SP）和直升机（HC）。每张图像的尺寸范围在 800×800 至 20000×20000 像素之间，包含呈现多种尺度、方向和形状的物体。DOTA -v1.0中训练集、验证集和测试集的比例分别为1/2、1/6和1/3。对于单尺度训练和测试，我们首先按照先前方法[1, 32, 51]将图像裁剪为 1024×1024 的块，重叠度为200，同时使用训练集和验证集进行训练，并使用测试集进行测试。

DOTA -v1.5[62]是一个更具挑战性的数据集，使用与DOTA -v1.0相同的图像，但极小实例（小于10像素）也进行了标注。该版本引入了新类别“集装箱起重机”（CC），小实例数量显著增加，数据集总实例数达到403,318个。图像数量和数据集分割与DOTA -v1.0保持一致。

FAIR1M-v1.0 [56] 是一个近期发布的遥感数据集，包含15,266张高分辨率图像和超过100万实例。该数据集的所有对象均通过定向边界框标注了5个类别和37个子类别。每张图像的尺寸范围为 1000×1000 至 $10,000 \times 10,000$ 像素，包含呈现多种尺度、方向和形状的物体。FAIR1M-1.0的训练集和测试集图像数量分别为16,488和8,137。在训练过程中，我们采用了与DOTA -v1.0数据集相同的预处理方法，从而生成多尺度的训练集和测试集。

HRSC2016 [38] 是一个用于船舶检测的遥感数据集，包含1061张航拍图像，尺寸范围从 300×300 到 1500×900 。所有图像均来自Google Earth，数据集分为训练集、验证集和测试集，其中训练集包含436张图像，验证集包含181张图像，测试集包含444张图像。

DIOR-R [5] 数据集通过提供定向边界框（OBB）标注扩展了DIOR遥感数据集。该数据集包含23,463张图像，每张图像的分辨率为

表13. 与基于大核方法在DOTA -v1.0[62]数据集上的对比。参数和浮点运算次数仅针对主干网络计算。StripNet-S主干网络在ImageNet上预训练300个周期。

方法	前。	#P ↓	浮点运算数 /	mAP (百分比)
VAN-B1 [16]	IN	13.4M	52.7G	81.15
SegNext [17]	IN	13.1M	45.0G	81.12
ConvNext V2-N [40]	IN	15.0M	51.2G	80.81
★ 条纹R-CNN-S	IN	13.3M	52.3G	82.28

800×800 像素，共计192,518条注释。

7. 实施细节

在本文中，我们采用先前研究[1, 32]中概述的方法，对DOTA、DOTAv1.5和FAIR1M数据集实施多尺度训练与测试。具体而言，我们将每张图像重新缩放至三个不同尺度（0.5、1.0、1.5），并裁剪为 1024×1024 的图像块，相邻图像块之间保留500像素的重叠区域。需要特别说明的是，在预训练和微调阶段，我们均未采用指数移动平均（EMA）技术。因此，主表中LSKNet的性能指标均基于未使用EMA技术的测试结果。

8. 公平1M基准测试结果

表14展示了在FAIR1M-v1.0数据集上与最先进方法进行的细粒度类别结果比较。

9. DOTA 基准结果

表16和表??展示了DOTA -v1.0与DOTA -v1.5数据集上细粒度类别结果与前沿方法的对比分析。

10. 更多关于条形头有效性的研究结果

表18展示了两种不同检测器在引入条带头前后的更多结果对比。这些结果是在DOTA -v1.0数据集上通过单尺度训练和测试获得的。如表18所示，我们比较了两种检测器在引入条带头前后的性能表现。结果表明，我们的条带头能持续提升其他检测器的性能，证实了其有效性和泛化能力。对于LSKNet[32]，我们的方法实现了

表14. 与FAIR1M-v1.0数据集上 SOTA 模型的对比。C1-C34与对象类别的对应关系

表格中按顺序排列的项目包括: C1: 波音737, C2: 波音747, C3: 波音777, C4: 波音787, C5: C919, C6: A220, C7: A321, C8: A330, C9: A350, C10: ARJ21, C11: 客船, C12: 机动船, C13: 渔船, C14: 拖船, C15: 工程船, C16: 液货船, C17: 干货船, C18: 军舰, C19: 小轿车, C20: 公交车, C21: 货运卡车, C22: 自卸卡车, C23: 厢式货车, C24: 拖车, C25: 拖拉机, C26: 挖掘机, C27: 牵引车, C28: 篮球场, C29: 网球场, C30: 足球场, C31: 棒球场, C32: 交叉口, C33: 环岛, C34: 桥梁。

方法	C1 C18	C2 C19	C3 C20	C4 C21	C5 C22	C6 C23	C7 C24	C8 C25	C9 C26	C10 C27	C11 C28	C12 C29	C13 C30	C14 C31	C15 C32	C16 C33	C17 C34	精度提升 (%)
滑动顶点[66]	35.43	47.88	15.67	48.32	0.01	40.11	39.31	16.54	16.56	0.01	9.12	23.34	1.23	15.67	15.43	15.32	25.43	29.92
	13.56	66.23	23.43	46.78	36.56	53.78	14.32	16.39	16.92	28.91	48.41	80.31	53.46	66.93	59.41	16.25	10.39	
RetinaNet [36]	38.46	55.36	24.57	51.84	0.81	40.5	41.06	18.02	19.94	1.7	9.57	22.54	1.33	16.37	19.11	14.26	24.7	30.67
	15.37	65.2	22.42	44.17	35.57	52.44	19.17	1.28	17.03	28.98	50.58	81.09	52.5	66.76	60.13	17.41	12.58	
级联 RCNN [2]	40.42	52.86	29.07	52.47	0	44.37	38.35	26.55	17.54	0	12.1	28.84	0.71	15.35	18.53	14.63	25.15	31.18
	14.53	68.19	28.25	48.62	40.4	58	13.66	0.91	16.45	30.27	38.81	80.29	48.21	67.9	55.67	20.35	12.62	
Faster-RCNN [53]	36.43	50.68	22.5	51.86	0.01	47.81	43.83	17.66	19.95	0.13	9.81	28.78	1.77	17.65	16.47	16.19	27.06	32.12
	13.16	68.42	28.37	51.24	43.6	57.51	15.03	3.04	17.99	29.36	58.26	82.67	54.5	71.71	59.86	16.92	11.87	
滚筒变压器[10]	39.58	73.56	18.32	56.43	0	47.67	49.91	27.64	31.79	0	14.31	28.07	1.03	14.32	15.97	18.04	26.02	35.29
	12.97	68.8	37.41	53.96	45.68	58.39	16.22	5.13	22.17	46.71	54.84	80.35	56.68	69.07	58.44	18.58	31.81	
OFA-Net [46]	43.20	87.58	23.58	57.78	30.71	54.31	67.83	73.65	73.56	29.25	9.90	68.15	11.70	30.37	11.83	26.80	38.68	43.73
	35.42	69.62	33.67	44.69	49.23	71.61	13.45	6.06	17.36	5.35	49.20	83.75	61.29	88.77	57.97	24.68	35.82	
O-RCNN [64]	38.65	84.96	20.05	55.57	25.55	48.58	68.75	71.18	74.43	32.85	20.46	67.63	11.13	32.89	16.22	26.45	39.03	44.30
	34.27	70.88	45.01	48.98	52.45	70.19	14.50	4.42	19.81	7.51	56.30	80.41	68.13	89.06	57.92	21.87	30.11	
CHODNet [54]	40.23	53.39	29.65	54.04	0.02	46.26	43.12	27.61	20.89	0.01	12.34	29.34	1.71	17.77	17.72	16.78	27.51	32.46
	13.68	70.12	28.38	49.11	44.02	60.78	14.48	4.96	17.60	30.09	47.91	82.11	54.10	69.97	19.57	59.91	14.38	
OBB-ISP [55]	43.97	88.77	38.97	58.29	50.88	54.09	65.14	59.19	65.94	35.00	19.78	56.77	26.84	26.31	21.41	44.97	47.39	45.91
	34.30	61.16	34.10	50.04	52.31	56.24	15.99	7.43	17.03	37.14	54.99	81.43	53.56	87.66	54.25	24.20	35.46	
LSKNet-S [32]	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	47.87
	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	
我们的																		
★条纹R-CNN-S	42.17	89.07	21.52	55.24	23.03	50.97	73.58	72.96	78.29	40.81	20.78	71.52	16.12	42.86	17.70	28.55	40.11	48.26
	39.56	76.14	49.44	55.37	60.55	76.18	20.32	8.12	25.96	7.23	58.94	86.59	72.73	89.43	62.89	25.57	40.58	

性能提升0.56%。类似地, Oriented R-CNN[64]也获得了0.3%的性能增益,这进一步验证了我们的方法与多种检测器兼容,并能可靠地提升检测性能。

11. StripNet骨干网的有效性

为验证我们提出的StripNet主干网络的通用性和有效性,我们使用多种遥感检测框架进行实验。这些框架包括两阶段框架如O- RCNN [64]和RoI Transformer [10],以及单阶段框架如S²ANet[19]和R3Det[68]。表17展示了两种不同检测器在整合StripNet-S前后的对比结果。实验结果基于DOTA -v1.0数据集进行多尺度训练和测试。如表17所示,我们比较了两种检测器在整合StripNet-S主干网络前后的性能。结果表明,我们的StripNet-S主干网络持续提升其他检测器的性能,证实了其有效性与泛化能力。对于RoI Transformer[10],我们的方法

实现了7.11%的性能提升。类似地, Oriented RCNN [64]也获得了0.88%的性能增益, S²ANet和R3Det分别提升了0.9%和2.54%,进一步验证了我们的方法兼容多种检测器,并能可靠地提升检测性能。

12. 与其他大型核网的比较

工厂

我们还将Strip R-CNN-S与表13中采用大卷积核的几种主流高性能骨干模型进行对比。在讨论的三个模型中,所有模型均采用了大卷积核。具体而言,VAN [16]通过扩张卷积来扩大感受野,虽然该技术能有效扩展模型的感受野,但也可能导致某些关键信息被忽略,这对遥感场景中密集分布的物体尤其不利。Seg-Next[17]引入了多分支大卷积核结构,旨在通过多路径捕捉更丰富的特征信息。然而,该

表15.基于 DOTA -v1.0数据集的单尺度与多尺度训练测试方法与 SOTA 方法的对比。StripNetS主干网络在ImageNet上经过300个epoch的预训练。†: 采用MoCAE[49]中的模型集成方法。

方法	前。	mAP↑	#P↓	浮点运算数/	PL	BD	BR	GTF	SV	左心室	SH	TC	BC	ST	SBF	RA	哈	SP	HC
单尺度																			
EMO2-DETR [27]	IN	70.91	74.3M	304G	87.99	79.46	45.74	66.64	78.90	73.90	73.30	90.40	80.55	85.89	55.19	63.62	51.83	70.15	60.04
CenterMap [60]	IN	71.59	41.1M	198G	89.02	80.56	49.41	61.98	77.99	74.19	83.74	89.44	78.01	83.52	47.64	65.93	63.68	67.07	61.59
AO2-DETR [8]	IN	72.15	74.3M	304G	86.01	75.92	46.02	66.65	79.70	79.93	89.17	90.44	81.19	76.00	56.91	62.45	64.22	65.80	58.96
SCRDet [69]	IN	72.61	41.9M	-	89.98	80.65	52.09	68.36	68.36	60.32	72.41	90.85	87.94	86.86	65.02	66.68	66.25	68.24	65.21
R3Det [68]	IN	73.70	41.9M	336G	89.5	81.2	50.5	66.1	70.9	78.7	78.2	90.8	85.3	84.2	61.8	63.8	68.2	69.8	67.2
转录体[10]	IN	74.05	55.1M	200G	89.01	77.48	51.64	72.07	74.43	77.55	87.76	90.81	79.71	85.27	58.36	64.11	76.50	71.99	54.06
S ² ANet [19]	IN	74.12	38.5M	-	89.11	82.84	48.37	71.11	78.11	78.39	87.25	90.83	84.90	85.64	60.36	62.60	65.26	69.13	57.94
SASM [23]	IN	74.92	36.6M	-	86.42	78.97	52.47	69.84	77.30	75.99	86.72	90.89	82.63	85.66	60.13	68.25	73.98	72.22	62.37
G.V. [66]	IN	75.02	41.1M	198G	89.64	85.00	52.26	77.34	73.01	73.14	86.82	90.74	79.02	86.81	59.55	70.91	72.94	70.86	57.32
O-RCNN [64]	IN	75.87	41.1M	199G	89.46	82.12	54.78	70.86	78.93	83.00	88.20	90.90	87.50	84.68	63.97	67.69	74.94	68.84	52.28
ReDet [20]	IN	76.25	31.6M	-	88.79	82.64	53.97	74.00	78.13	84.06	88.04	90.89	87.78	85.75	61.76	60.39	75.96	68.07	63.59
R3Det-GWD [71]	IN	76.34	41.9M	336G	88.82	82.94	55.63	72.75	78.52	83.10	87.46	90.21	86.36	85.44	64.70	61.41	73.46	76.94	57.38
COBB [63]	IN	76.52	41.9M	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
R3Det-KLD [72]	IN	77.36	41.9M	336G	88.90	84.17	55.80	69.35	78.72	84.08	87.00	89.75	84.32	85.73	64.74	61.80	76.62	78.49	70.89
ARC [73]	IN	77.35	74.4M	217G	89.40	82.48	55.33	73.88	79.37	84.05	88.06	90.90	86.44	84.83	63.63	70.32	74.29	71.91	65.43
LSKNet-S [32]	IN	77.49	31.0M	161G	89.66	85.52	57.72	75.70	74.95	78.69	88.24	90.88	86.79	86.38	66.92	63.77	77.77	74.47	64.82
PKINet-S [1]	IN	78.39	30.8M	190G	89.72	84.20	55.81	77.63	80.25	84.45	88.12	90.88	87.57	86.07	66.86	70.23	77.47	73.62	62.94
RTMDet-R [43]	IN	78.85	52.3M	205G	89.43	84.21	55.20	75.06	80.81	84.53	88.97	90.90	87.38	87.25	63.09	67.87	78.09	80.78	69.13
★ 条纹R-CNN-S	IN	80.06	30.5M	159G	88.91	86.38	57.44	76.37	79.73	84.38	88.25	90.86	86.71	87.45	69.89	66.82	79.25	82.91	75.58
多尺度																			
G.V. [66]	IN	75.02	41.1M	198G	89.64	85.00	52.26	77.34	73.01	73.14	86.82	90.74	79.02	86.81	59.55	70.91	72.94	70.86	57.32
R3Det [68]	IN	76.47	41.9M	336G	89.80	83.77	48.11	66.77	78.76	83.27	87.84	90.82	85.38	85.51	65.57	62.68	67.53	78.56	72.62
CSL [67]	IN	76.17	37.4M	236G	90.25	85.53	54.64	75.31	70.44	73.51	77.62	90.84	86.15	86.69	69.60	68.04	73.83	71.10	68.93
CFA [18]	IN	76.67	-	-	89.08	83.20	54.37	66.87	81.23	80.96	87.17	90.21	84.32	86.09	52.34	69.94	75.52	80.76	67.96
DAFNet [28]	IN	76.95	-	-	89.40	86.27	53.70	60.51	82.04	81.17	88.66	90.37	83.81	87.27	53.93	69.38	75.61	81.26	70.86
S ² ANet [19]	IN	79.42	-	-	88.89	83.60	57.74	81.95	79.94	83.19	89.11	90.78	84.87	87.81	70.30	68.25	78.30	77.01	69.58
R3Det-GWD [71]	IN	80.23	41.9M	336G	89.66	84.99	59.26	82.19	78.97	84.83	87.70	90.21	86.54	86.85	73.47	67.77	76.92	79.22	74.92
DODet [6]	IN	80.62	-	-	89.96	85.52	58.01	81.22	78.71	85.46	88.59	90.89	87.12	87.80	70.50	71.54	82.06	77.43	74.47
AOPG [5]	IN	80.66	-	-	89.88	85.57	60.90	81.51	78.70	85.29	88.85	90.89	87.60	87.65	71.66	68.69	82.31	77.32	73.10
R3Det-KLD [72]	IN	80.63	41.9M	336G	89.92	85.13	59.19	81.33	78.82	84.38	87.50	89.80	87.33	87.00	72.57	71.35	77.12	79.34	78.68
KFloU [73]	IN	80.93	58.8M	206G	89.44	84.41	62.22	82.51	80.10	86.07	88.68	90.90	87.32	88.38	72.80	71.95	78.96	74.95	75.27
PKINet-S [1]	IN	81.06	30.8M	190G	89.02	86.73	58.95	81.20	80.41	84.94	88.10	90.88	86.60	87.28	67.10	74.81	78.18	81.91	70.62
RTMDet-R [43]	IN	81.33	52.3M	205G	88.01	86.17	58.54	82.44	81.30	84.82	88.71	90.89	88.77	87.37	71.96	71.18	81.23	81.40	77.13
RVSA [58]	IN	81.24	114.4M	414G	88.97	85.76	61.46	81.27	79.98	85.31	88.30	90.84	85.06	87.50	66.77	73.11	84.75	81.88	77.58
LSKNet-S [32]	IN	81.64	31.0M	161G	89.57	86.34	63.13	83.67	82.20	86.10	88.66	90.89	88.41	87.42	71.72	69.58	78.88	81.77	76.52
★ 条带状R-CNN-T	IN	81.40	20.5M	123G	89.14	84.90	61.78	83.50	81.54	85.87	88.64	90.89	88.02	87.31	71.55	70.74	78.66	79.81	78.16
★ 条纹R-CNN-S	IN	82.28	30.5M	159G	89.17	85.57	62.40	83.71	81.93	86.58	88.84	90.86	87.97	87.91	72.07	71.88	79.25	82.45	82.82
★ 条带状R-CNN-S†	IN	82.75	30.5M	159G	88.99	86.56	61.35	83.94	81.70	85.16	88.57	90.88	88.62	87.36	75.13	74.34	84.58	81.49	82.56

表16.基于DOTA -v1.5数据集的单尺度训练与测试方法与 SOTA 方法的对比分析。

方法	前。	PL	BD	BR	GTF	SV	左心室	SH	TC	BC	ST	SBF	RA	哈	SP	HC	CC	mAP (%)	†
RetinaNet-O [36]	IN	71.43	77.64	42.12	64.65	44.53	56.79	73.31	90.84	76.02	59.96	46.95	69.24	59.65	64.52	48.06	0.83	59.16	
FR-O [53]	IN	71.89	74.47	44.45	59.87	51.28	68.98	79.37	90.78	77.38	67.50	47.75	69.72	61.22	65.28	60.47	1.54	62.00	
Mask R-CNN [22]	IN	76.84	73.51	49.90	57.80	51.31	71.34	79.75	90.46	74.21	66.07	46.21	70.61	63.07	64.46	57.81	9.42	62.67	
HTC [4]	IN	77.80	73.67	51.40	63.99	51.54	73.31	80.31	90.48	75.12	67.34	48.51	70.63	64.84	64.48	55.87	5.15	63.40	
ReDet [20]	IN	79.20	82.81	51.92	71.41	52.38	75.73	80.92	90.83	75.81	68.64	49.29	72.03	73.36	70.55	63.33	11.53	66.86	
LSKNet-S [32]	IN	72.05	84.94	55.41	74.93	52.42	77.45	81.17	90.85	79.44	69.00	62.10	73.72	77.49	75.29	55.81	42.19	70.26	
PKINet-S [1]	IN	80.31	85.00	55.61	74.38	52.41	76.85	88.38	90.87	79.04	68.78	67.47	72.45	76.24	74.53	64.07	37.13	71.47	
★ 条纹R-CNN-S	IN	80.04	83.26	54.40	75.38	52.46	81.44	88.53	90.83	84.80	69.65	65.93	73.28	74.61	74.04	69.70	38.98	72.27	

该架构存在特征混淆与冗余问题，可能影响模型性能。尽管这三种方法验证了有效性。

由于大型卷积核的局限性，它们无法充分应对遥感场景中数据特有的独特特征。这一局限性限制了其泛化能力。




图10. 检测结果。我们的方法Strip R-CNN-S能够成功捕获高长宽比物体，验证了本方法的有效性。

表17. StripNet-S主干网络在其他遥感目标检测框架中的有效性。StripNet-S主干网络在ImageNet[9]上进行了100个周期的预训练。

方法	脊梁骨	PL	BD	BR	GTF	SV	左心室	SH	TC	BC	ST	SBF	RA	哈	SP	HC	mAP (百分比)
RoI 转录[10]	ResNet-50 [21]	88.65	82.60	52.53	70.87	77.93	76.67	86.87	90.71	83.83	82.51	53.95	67.61	74.67	68.75	61.03	74.61
	StripNet-S	89.10	85.45	63.61	82.84	80.95	85.84	88.68	90.84	88.35	87.92	72.12	71.37	79.73	83.32	75.77	81.72
O-RCNN [64]	ResNet-50 [21]	89.84	85.43	61.09	79.82	79.71	85.35	88.82	90.88	86.68	87.73	72.21	70.80	82.42	78.18	74.11	80.87
	StripNet-S	89.46	84.40	63.04	82.89	81.84	86.16	88.66	90.88	88.12	86.97	74.27	73.69	79.05	81.14	76.44	81.75
S ² ANet [19]	ResNet-50 [21]	88.89	83.60	57.74	81.95	79.94	83.19	89.11	90.78	84.87	87.81	70.30	68.25	78.30	77.01	69.58	79.42
	StripNet-S	89.31	84.94	61.01	81.87	81.34	85.10	88.69	90.76	86.89	87.49	67.94	68.74	77.96	78.82	73.90	80.32
R3Det [68]	ResNet-50 [21]	89.80	83.77	48.11	66.77	78.76	83.27	87.84	90.82	85.38	85.51	65.57	62.68	67.53	78.56	72.62	76.47
	StripNet-S	89.56	83.47	56.71	81.28	79.80	83.87	88.63	90.87	86.16	86.93	66.82	69.16	75.64	74.42	71.88	79.01

针对这一挑战，我们提出的方法不仅全面分析遥感数据特征，还专门针对高长宽比目标进行优化。因此，该方案在遥感应用中展现出卓越性能，为解决该领域挑战提供了新思路 and 方向。

13. 更多检测结果

我们在图10中展示了额外的检测结果。如图10所示，包括Oriented R-CNN、LSKNet和PKINet在内的先前方法在检测高长宽比物体时常常遇到困难，导致漏检或误检。相比之下，我们的Strip RCNN方法能有效检测这类具有挑战性的物体。

表18. 条带头对其他遥感目标检测器的有效性

方法	头	PL	BD	BR	GTF	SV	左心室	SH	TC	BC	ST	SBF	RA	哈	SP	HC	mAP (百分比)
LSKNet-S [32]	原头	89.66	85.52	57.72	75.70	74.95	78.69	88.24	90.88	86.79	86.38	66.92	63.77	77.77	74.47	64.82	77.49
	带状头	89.71	83.50	56.18	78.86	79.83	84.66	88.16	90.86	88.30	86.11	67.02	66.27	76.19	71.79	63.39	78.05
O-RCNN [64]	原头	89.46	82.12	54.78	70.86	78.93	83.00	88.20	90.90	87.50	84.68	63.97	67.69	74.94	68.84	52.28	75.81
	带状头	89.48	82.33	53.95	72.83	78.60	77.97	88.12	90.89	85.84	84.76	64.42	67.55	74.57	70.31	60.05	76.11