

MFmamba:一种基于状态空间模型的全色图像分辨率复原多功能网络

钱江¹、王倩倩¹、金欣^{1*}
Michal Wozniak²、姚少文¹、周伟^{3*}

¹云南大学软件学院，中国云南省昆明市

²波兰弗罗茨瓦夫科技大学信息与通信技术学院

³云南大学工程学院，植被结构、功能与构建国家重点实验室（VegLab），中国云南省昆明市

jiangqian_1221@163.com, qianqianwang1325@163.com, xinxinjin@163.com, michal.wozniak@pwr.edu.pl,
yaosw@ynu.edu.cn, zwei@ynu.edu.cn

摘要

遥感影像正日益成为在军事和地球资源勘探领域应用广泛。由于单一传感器的局限性，我们能够获取高空间分辨率的灰度全色（PAN）图像和低空间分辨率的彩色多光谱（MS）图像。因此，当输入仅包含PAN图像时，如何获取高空间分辨率的彩色图像成为关键问题。现有方法通过超分辨率（SR）技术提升空间分辨率，或采用着色技术进行光谱恢复。然而，SR技术无法改善光谱分辨率，着色技术也无法提升空间分辨率。此外，全色校正方法需要两个配准输入且无法实现SR。因此，亟需一种集成方法。为解决上述问题，我们设计了一种新型多功能模型（MFmamba），通过三种不同输入实现SR、光谱恢复、联合SR及光谱恢复任务。首先，MFmamba以UNet++作为主干网络，并将Mamba上采样模块（MUB）与UNet++结合。其次，设计了双池注意力机制（DPA）以替代UNet++中的跳跃连接。最后，我们提出了一种多尺度混合交叉块（MHCB）用于初始特征提取。大量实验表明，MFmamba在评估指标和视觉效果上表现优异，且在仅使用输入PAN图像时，其在三项任务中均表现出色。

代码 -<https://github.com/QianqianWang1325/MFmamba.git>

介绍

遥感影像在物体检测（Ma等，2024）、城市规划（Park、Soh与Cho，2025）、环境监测（Zhang等，2024）等领域应用广泛，其重要性与日俱增。PAN（光谱成像）与MS（多光谱成像）是两种不同类型的遥感影像，均采集同一区域不同波长的信息（Feng等，2022）。PAN影像具有高空间分辨率，但由于其以灰度形式呈现，光谱分辨率较低（Jin等，2024）。光谱分辨率*通讯作者。

本文已被接受发表于AAAI-2026。

多光谱图像的空间分辨率更高，但由于物理限制，其空间分辨率较低。单个传感器无法同时获取具有高空间分辨率和高光谱分辨率的遥感图像。然而，高分辨率（HR）彩色遥感图像在遥感场景解释中更具优势，例如图像融合（Li等，2022b）、语义分割（An等，2024）。因此，在仅使用PAN图像作为输入的情况下，提升遥感图像的空间分辨率和光谱分辨率成为值得深入研究的课题。

现有研究采用超分辨率（SR）技术提升低分辨率（LR）图像的空间分辨率，并通过色彩化技术恢复灰度图像的光谱分辨率。因此，PAN图像的空间分辨率可通过SR技术实现恢复。随着卷积神经网络（CNN）在图像处理中的潜力被发现，后续研究引入了更多基于CNN的SR方法，例如（Li等人，2023）。此外，通过不同模型结构优化图像SR性能的方法也层出不穷，如基于生成对抗网络（GAN）的lgcgdan（Li等人，2024）、基于Transformer的MAT（Xie等人，2025）、基于扩散模型的StableSR（Wang等人，2024）。图像色彩化技术被用于恢复PAN图像的光谱分辨率。基于深度学习（DL）的自动图像色彩化模型也逐步设计完成，例如基于GAN的CycleGAN-Color（Huang等人，2021）、基于Transformer的Kumar、Weissenborn等人（2021），以及基于扩散模型的Control Color（Liang等人，2024）。

PAN图像联合空间分辨率重建与色彩化技术旨在同步提升图像的空间分辨率和光谱分辨率。现有方法中，这两项任务往往被割裂处理。为此，我们设计了多功能网络（MFmamba）来解决这一问题。通过采用不同输入数据，该网络可实现三项任务：PAN图像空间分辨率重建、光谱恢复、联合空间分辨率重建与光谱恢复。本研究的主要贡献如下：

- 我们设计了一个高效的PAN图像分辨率恢复网络（MFmamba），用于生成彩色高分辨率图像，从而实现联合的超分辨率与光谱恢复。该网络采用Mamba上采样模块（MUB）

采用状态空间模型进行分辨率恢复。

- 我们设计了一种多尺度混合交叉块（MHCB）用于浅层特征提取，该方法能有效检测局部和多尺度特征，从而提升细节特征提取能力。
- 我们提出一种新型双池注意力机制（Dual Pool Attention，简称DPA），通过动态调整通道权重来优化特征表示，使模型能够聚焦于更重要的特征通道。

相关工作

图像超分辨率

近年来，得益于深度学习强大的学习能力，图像超分辨率取得了突破性进展。李等人（Li et al. 2020）设计了MDCN超分辨率模型，该模型通过采用密集连接和残差策略提升性能，同时减少了参数量。李等人（Li, Yuan, and Wang 2023）提出了一种基于多尺度因子的高光谱图像联合学习算法（MulSR），该算法利用对称引导编码器和方向感知空间上下文聚合模块实现多尺度信息交互。李等人（Li et al. 2025）揭示了深度图像先验在高光谱图像超分辨率中的潜力，实现了高质量的重建效果。朱等人（Zhu et al. 2023）通过在生成器中引入残差块和注意力机制进行特征融合，改进了生成对抗网络。他们在判别器中引入RaGAN以增强边缘和纹理学习。陈等人（Chen et al. 2023）提出了一种新型混合注意力变压器（HAT），该模型受Swin Transformer启发，提出了基于窗口的自注意力机制和用于优化跨窗口交互的重叠交叉注意力模块。谢等人（Xie et al. 2025）提出了一种用于超分辨率任务的多范围注意力变换器（MAT），该模型利用了膨胀操作的计算效率，并通过自注意力机制将多范围注意力（MA）与稀疏多范围注意力（SMA）相结合以捕获特征。

李等人（Li et al. 2022a）首次提出基于扩散的单图像超分辨率模型SRDiff，该模型通过马尔可夫链将高斯噪声转化为超分辨率图像，并利用残差预测加速收敛。王等人（Wang et al. 2024）引入可控特征包裹模块StableSR，通过标量值和渐进聚合采样策略平衡质量与保真度，使预训练扩散模型能适配任意分辨率。郭等人（Guo et al. 2024）提出的MambaIR模型引入残差状态空间块和通道注意力机制，显著提升了特征重建能力。但现有方法仍存在不足：例如难以完整提取并保留所有纹理细节，导致复杂细节区域会产生错误纹理信息，且提取的细节特征仍显不足。

图像着色

传统图像着色方法依赖于用户指导。随着深度学习（DL）的发展，自动着色方法逐渐被设计出来。Feng等人（Feng et al.

2021b）提出了一种端到端的CNN网络用于遥感图像着色，该网络采用多尺度残差感受野进行特征提取，并融合了残差块、注意力机制和像素洗牌模块。Saeed等人（Anwar等人，2025）综述了基于深度学习的图像着色技术，指出了现有数据集的局限性，并引入了一个新的图像着色数据集。Shafiq等人（Shafiq和Lee，2024）设计了一种基于Transformer和GANs的混合架构图像着色网络，他们改进了编码器以生成颜色特征，随后采用自注意力机制捕捉长距离依赖关系。GAN也被应用于图像着色任务。Wu等人（Wu等人，2021）提出了一种基于DCGAN的PAN图像着色新模型，该模型结合了基于自动编码器的生成器和残差网络判别器。Zhao等人（Zhao等人，2021）提出了SCGAN框架。该全自动框架利用显著图和两个分层判别器，通过预训练的VGG-16-Gray网络提取全局特征，以最少数据实现感知准确的图像着色。

蒋等人（Jiang et al. 2025）设计了一种基于Transformer和CNN混合架构的多尺度着色网络，通过注意力机制和掩码机制增强图像特征。梁等人（Liang et al. 2024）开发了名为CtrlColor的框架，该框架利用预训练的Stable Diffusion模型处理无条件条件和条件性着色任务，包含用户提供的笔画编码、颜色分布控制等方法。然而这些方法存在明显缺陷：例如无法解决颜色失真问题，且依赖颜色分布导致着色效果不合理（赵等，2021）。因此，灰度图像着色方法仍需深入探索。

建议方法

为实现PAN图像的超分辨率（SR）与光谱恢复任务，我们提出了一种基于UNet++（Zhou等，2018）和Mamba的多功能模型（MFmamba），该模型可同时完成PAN图像的SR、光谱恢复及联合SR与光谱恢复任务。图1展示了本方案的整体架构。我们整合了基于状态空间模型构建的Mamba上采样模块（MUB），并采用创新的双池注意力机制（DPA）替代UNet++中的原始跳跃连接，以实现同层级特征图间的信息传递。此外，多尺度混合交叉块（MHCB）通过不同卷积核尺寸的卷积操作，实现了多尺度特征的提取。

多尺度混合交叉区块（MHCB）

我们设计了一种多尺度混合交叉块（MHCB），通过不同核尺寸的并行卷积路径提取多尺度特征信息，然后采用密集残差分组的跳跃连接来保持梯度流动，并在整个网络层次中强化关键特征的持久性。图2展示了MHCB的概念。我们使用 5×5 的卷积块，比其他方法更注重全局特征提取。




图1：所提解决方案（MFmamba）的总体结构。




图2：多尺度混合交叉块（MHCB）的结构。

小卷积核。我们采用 3×3 的核函数，参数较少，以获取局部特征并充分利用PAN图像中的细节信息。同时在模块末端使用 1×1 的核函数来融合特征并整合各层特征。MHCB可表示如下：

$$\begin{cases} X_1 = \text{ReLU}(3 \times 3 \text{Conv}(X)) \oplus X, \\ X_2 = \text{ReLU}(5 \times 5 \text{Conv}(X)) \oplus X, \end{cases} \quad (1)$$

$$X_3 = 1 \times 1 \text{Conv}(\text{Concat}(X_1, X_2, X)), \quad (2)$$

$$\begin{cases} X_4 = \text{ReLU}(3 \times 3 \text{Conv}(X_3)), \\ X_5 = \text{ReLU}(5 \times 5 \text{Conv}(X_3)), \end{cases} \quad (3)$$

$$\text{MHCB}_{out} = 1 \times 1 \text{Conv}(\text{Concat}(X_3, X_4, X_5)) \oplus X, \quad (4)$$

其中 X 表示MHCB的输入特征。 X_1, X_2, X_3, X_4 和 X_5 表示中间输出特征。 Concat 表示连接操作。

双池注意力（Dual Pool Attention, DPA）

在超分辨率（SR）和PAN图像的光谱恢复中，注意力机制对于模型有效捕捉相关性和语义信息至关重要。因此，我们提出了一种新型的双池注意力机制（DualPoolAttention, DPA），如图3所示。




图3：双池注意力机制（Dual Pool Attention, 简称DPA）的结构。

DPA 采用双流架构实现全面的通道级特征校准。DPA 同时利用了自适应-采用全局平均池化（等式5）和最大池化将全局空间信息压缩为通道描述符。随后，使用Sigmoid函数完全获取通道依赖关系，并生成尺寸为 $1 \times 1 \times C$ 的权重特征图（参见等式6）。这些图被应用于输入以评估通道重要性，然后进行求和（等式7）。DPA 引入最大池化以捕捉显著特征，通过聚焦细节和重要信息来增强模型性能，实现更全面的特征提取。结合两种池化操作有助于模型聚焦关键细节和相关信息，从而更好地保留输入图像的特征。

$$\begin{cases} A_{sq1} = \text{AP}_c(i, j) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_{i,j,c}, \\ A_{sq2} = \text{MP}_c(i, j) = \max_{p,q \in \{1, \dots, k\}} X_{p,q,c}, \end{cases} \quad (5)$$

$$\begin{cases} A_{ex1} = \text{sigmoid}(A_{sq1}), \\ A_{ex2} = \text{sigmoid}(A_{sq2}), \end{cases} \quad (6)$$

$$\text{DPA}_{out} = (X \odot A_{ex1}) \oplus (X \odot A_{ex2}), \quad (7)$$

其中 $X_{i,j,c}$ 是通道 c 上特征图位置 (i, j) 的值。 $\text{MP}_c(i, j)$ 表示位置的值




图4: Mamba上采样模块结构 (MUB)。

(i, j) 在池化输出特征图的通道 c 上。 $X_{p,q,c}$ 是池化窗口 $k \times k$ 中的像素值。

Mamba上采样模块 (MUB)

结构化状态空间序列模型近期取得突破，该模型通过潜在状态 $h(t) \in \mathbb{R}^M$ 将一维序列 $x(t) \in \mathbb{R} \rightarrow y(t) \in \mathbb{R}$ 进行映射。基于此，mamba模型被提出以解决Transformer在长序列上计算效率低的问题。

具体而言，状态空间序列模型由五个参数 (Δ 、 A 、 B 、 C 、 D) 定义，其序列到序列的转换被定义为两阶段过程。形式上，该系统可表示为线性常微分方程 (ODE) (Guo等, 2024)：

$$h'(t) = Ah(t) + Bx(t), \quad y(t) = Ch(t) + Dx(t), \quad (8)$$

其中 M 表示状态大小， $A \in \mathbb{R}^{M \times M}$ ， $B \in \mathbb{R}^{M \times 1}$ ， $C \in \mathbb{R}^{1 \times M}$ ，且 $D \in \mathbb{R}$ 。

然后使用离散化过程来积分等式8转化为实际的DL模型。参数 Δ 控制时间尺度，将连续参数 A 和 B 转换为其离散对应物 $\bar{A}$ 和 $\bar{B}$ 。广泛使用的离散化方法是零阶保持 (ZOH)，其定义如下：

$$\bar{A} = \exp(\Delta A), \quad \bar{B} = (\Delta A)^{-1} (\exp(\Delta A) - I) \cdot \Delta B. \quad (9)$$

在以时间步长 Δ 进行离散化后，等式8可重新表述如下：

$$h_\tau = \bar{A}h_{\tau-1} + \bar{B}x_\tau, \quad y_\tau = Ch_\tau + Dx_\tau, \quad (10)$$

其中 τ 表示离散时间步长，原始连续时间步长 t 被转换为离散时间步长 τ 。

公式10描述了一个线性时不变 (LTI) 系统，该系统在不同输入参数下保持静态，且其状态方程不会随输入变化。然而，这种静态系统存在某些局限性。为解决这一问题，近期研究 (YueLiu2024) 提出了一种

表1: 波茨坦消融实验，黑色加粗字体标记最佳性能。

	MHCB	DPA	MUB	PSNR↑	SSIM↑	MSE↓	MAE↓
w/o DPA	✓	✗	✓	39.980	0.965	7.457	76.791
w/o MUB	✓	✓	✗	39.794	0.965	7.679	68.398
w/o MHCB	✗	✓	✓	40.061	0.966	7.202	71.327
w/ MHCB-1	✓	✓	✓	40.072	0.966	7.210	75.845
w/ MHCB-2 (熊)	✓	✓	✓	40.148	0.967	7.096	73.499
w/ MHCB-3	✓	✓	✓	40.080	0.966	7.204	72.915

表2: 波茨坦不同UNet++深度对比

UNet++深度	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓
2	39.548	0.965	7.926	77.036	0.039	0.038
3	39.986	0.965	7.382	75.545	0.030	0.039
4 (小时)	40.148	0.967	7.096	73.499	0.029	0.036

选择性扫描机制能够根据输入数据动态调整矩阵 B 、 C 和 Δ ，从而提升性能。受此选择性扫描机制良好性能的启发，我们采用二维选择性扫描机制 (2D-SSM)

(Yue Liu 2024)，以增强对输入中嵌入上下文信息的感知 (Guo et al. 2024)。最后，基于上述理论，我们设计了Mamba上采样模块 (MUB)。MUB 结构图如图4所示。我们将原始二维图像特征扫描方向从四个不同水平方向增加到六个扫描方向，并添加两个对角线扫描方向以更全面地捕获数据信息。随后，我们将二维特征图整合并展平为一维序列，并通过等式10计算每个序列的长程依赖关系。最终，将结果组合成二维特征图作为 MUB 模块的最终输出 (Guo et al. 2024)。如图4中红色方框所示。通过利用互补的一维遍历路径，2D-SSM 框架使每个像素能够高效地从多个方向收集其他像素的信息。因此，建立二维空间中的全局感受野较为便捷 (Yue Liu 2024)。

损失函数

我们采用 L_1 损失函数优化网络，该函数通过计算预测图像与真实图像之间的绝对差值总和来实现优化，具体计算方式如下：

$$L_1(y, \hat{y}) = \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (11)$$

其中 n 表示批量训练样本的数量， y_i 代表对应的标签图像， $\hat{y}_i$ 表示由MFmamba生成的输出图像。

实验与分析数据集与设置

我们对MFmamba模型在五个遥感数据集 (NWPU、Pot-sdam、QuickBird、GF2和RSSCN7) 上的表现进行了评估。选择 MSE、PSNR、SSIM、MAE、SAM和 LPIPS 作为模型性能指标。MFmamba的 d UNet++ 网络深度 (Zhou等人, 2018) 设为4， g 的增长率为32。所有实验中，批量大小设为1，训练轮数为32。随机种子设为

表3：波茨坦地区不同扫描方法与贴片

配置	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓
3 × 3片	39.266	0.966	7.828	75.391	0.039
w/o MUB	39.794	0.965	7.679	68.398	0.034
w/ MUB (H_5 扫描)	40.071	0.966	7.185	73.53	0.031
w/ MUB (H_6 扫描)	40.007	0.966	7.34	74.477	0.032
2 × 2 MUB (我们的)	40.148	0.967	7.096	73.499	0.029

到10。我们使用Adam优化器对提出的MFmamba模型进行优化，学习率为 1×10^{-4} ，并采用StepLR每10次迭代调整一次学习率。此外，选择 $\sigma_1=0.9$ 和 $\sigma_2=0.99$ 。所有实验基于PyTorch，所有模型均在80GB内存的GPU上训练。对于SR x2任务，我们将原始PAN图像下采样为 128×128 作为输入。对于SR x4任务，我们将原始PAN图像下采样为 64×64 作为输入。在联合SR与着色任务中，我们将原始PAN图像下采样为 128×128 作为输入。

消融研究

为验证所提出的模块（MHCB、DPA 和 MUB）的性能，我们在波茨坦数据集上设计了一个消融实验，用于遥感图像的联合SR与光谱恢复任务。SR比例因子设置为x2，所有实验均采用相同配置。MHCB、DPA 和 MUB 彼此独立。首先，我们测试了 DPA 模块和 MUB 模块的性能。如表1所示，不使用 DPA 模块和 MUB 模块会导致性能下降。这表明 DPA 和 MUB 模块有助于模型聚焦关键信息，保留图像关键特征，优化上采样过程，并提升整体性能。其次，我们评估了 MHCB 模块的影响。我们的模型采用两个MHCB进行初始特征提取。为确定最佳数量，我们进行了使用1、2和3个MHCB的消融研究，最终发现使用两个MHCB能带来最佳性能，如表1第三至第六行所示。

我们还在本研究中评估了不同UNet++（Zhou等人，2018）深度的性能。我们测试了常用的两层、三层和四层UNet++架构。表2显示我们采用的四层网络表现出更优性能，在特征提取和恢复方面表现突出。此外，我们使用4块和9块 MUB 的输入来验证不同块数对模型性能的影响。我们还在 MUB 的2D-SSM 模块中设计了两个扫描方向（称为 H_5 和 H_6 ），并进行了消融实验，除了传统的四个水平扫描方向。所有结果均显示在表3中。可以观察到，我们模型中使用的4块配置比9块配置取得了更好的性能。此外，当仅使用 H_5 或 H_6 扫描方向时，MUB 模型无法达到最优性能。当同时纳入两种扫描方向时，模型性能得到显著提升，这证明了我们提出的双方向扫描方案的有效性。

扫描方向

实验对比与讨论

我们进行了三种实验以验证本方法的性能。

联合空间分辨率与光谱恢复我们的主要目标是实现遥感图像的联合空间分辨率与光谱恢复。我们使用x2比例因子进行空间分辨率任务，将本模型与现有联合空间分辨率与色彩化模型进行对比，包括RSI（Feng等人，2022）、CSRDN（Feng 等人，2021a）、CASR（Liu 等人，2022）和 MBPRR（Jin 等人，2024）。HAT（Chen 等人，2023）+CIR（Feng等人，2021b）表示先使用HAT进行空间分辨率操作，再使用CIR进行色彩化；CIR（Feng等人，2021b）+HAT（Chen等人，2023）表示先使用CIR色彩化模型，再使用HAT空间分辨率模型；SwinIR（Liang 等人，2021）+CIR（Feng 等人，2021b）和 CIR（Feng等人，2021b）+SwinIR（Liang等人，2021）的含义同上。我们在两个数据集上进行了对比实验与分析，以全面评估MFmamba在不同数据集上的泛化能力和性能。Potsdam和NWPU数据集的实验结果见表4，QuickBird、GF2和RSSCN数据集的实验结果详见附录。如表所示，尽管MFmamba在部分指标上略逊一筹，但其整体表现最为出色。这充分证明了MFmamba在同步完成超分辨率（SR）与光谱恢复任务方面的卓越优势。同时表明，MFmamba在遥感图像细节与关键信息提取方面表现突出，显著提升了特征恢复性能。

如图6所示，展示了所提出的MFmamba方法在五个数据集上损失函数值随迭代次数变化的收敛曲线。为更直观地呈现实验结果，我们从每个数据集中选取一张图像，将现有多种方法与我们提出的MFmamba进行性能对比，如图5所示。最后一列的“误差强度”表示模型生成结果与标注标签之间的误差程度，颜色从蓝色渐变至红色。其中蓝色代表误差较小的区域，黄色和红色则对应误差较大的区域。

超分辨率在图像超分辨率任务中，我们将MFmamba与双三次插值作为基线方法，并与RSI（冯等人，2022）、MDCN（李等人，2020）、HAT（陈等人，2023）、SwinIR（梁等人，2021）及MulSR（李、袁和王，2023）等方法进行对比。所有实验分析均在波茨坦数据集上进行，针对超分辨率任务分别采用x2和x4放大因子。结果详见表5。为直观展示对比效果，我们选取波茨坦数据集中的两幅图像，如图7所示，呈现了不同放大因子下各方法与MFmamba的对比结果。实验表明，MFmamba在超分辨率与光谱恢复的联合处理方面表现卓越，取得了优异的性能表现。

表4: 波茨坦与 NWPU 对比实验结果，黑色加粗字体标注最佳性能。

方法	波茨坦数据集						NWPU 数据集					
	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓
MBPRR (Jin等, 2024年)	34.953	0.943	28.653	103.165	0.023	0.064	28.504	0.913	101.887	128.501	0.077	0.096
CASR (Liu等, 2022年)	32.685	0.946	51.054	105.339	0.029	0.079	28.200	0.906	109.594	120.439	0.049	0.105
相对强弱指数 (RSI) (Feng等, 2022年)	34.857	0.910	25.760	99.911	0.054	0.052	32.354	0.913	59.534	104.111	0.074	0.068
CSRDDNN (Feng等, 2021a)	31.461	0.954	56.084	96.923	0.081	0.049	31.478	0.905	62.645	127.096	0.087	0.070
HAT (陈等人, 2023年)+CIR (冯等人, 2021b年)	32.853	0.958	34.774	103.314	0.062	0.039	22.760	0.533	393.884	125.429	0.299	0.279
CIR (Feng等, 2021b)+HAT (Chen等, 2023)	27.777	0.720	375.405	113.637	0.147	0.082	24.519	0.672	257.197	126.742	0.163	0.467
SwinIR (梁等人, 2021年)+CIR (冯等人, 2021b年)	32.838	0.957	34.907	103.308	0.062	0.038	22.789	0.536	390.958	125.484	0.198	0.270
CIR (Feng等, 2021b)+SwinIR (Liang等, 2021)	27.777	0.720	375.272	113.547	0.147	0.082	24.518	0.672	257.232	126.674	0.163	0.469
我们的	40.148	0.966	7.096	73.499	0.029	0.036	33.183	0.927	46.606	106.451	0.066	0.074

表5: SR在不同放大倍数下的实验结果（以波茨坦为基准，黑色加粗字体标记最佳性能）

方法	x2						x4					
	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓
双立方的	35.591	0.908	21.307	112.893	0.049	0.130	31.145	0.788	59.929	117.396	0.082	0.410
相对强弱指数 (RSI) (Feng等, 2022年)	37.525	0.936	13.626	66.786	0.038	0.055	31.886	0.810	49.420	68.907	0.072	0.189
MDCN (Li等, 2020)	34.718	0.859	313.392	99.817	0.096	0.0706	26.187	0.668	314.211	101.733	0.091	0.071
HAT (陈等人, 2023年)	34.963	0.861	311.239	106.593	0.095	0.0705	30.209	0.752	328.867	113.026	0.121	0.073
SwinIR (梁等人, 2021年)	34.921	0.861	311.239	106.423	0.095	0.0704	30.006	0.746	331.536	110.928	0.122	0.073
MulSR (李、袁和王, 2023年)	25.593	0.903	343.201	144.138	0.089	0.075	23.975	0.885	393.033	102.323	0.130	0.116
我们的	38.458	0.954	10.129	77.288	0.035	0.033	32.257	0.809	46.230	95.163	0.072	0.019




图5: MFmamba与基准方法在五个不同数据集上的可视化结果。




图6：五个数据集中损失函数随迭代次数变化的曲线。

表6：波茨坦地区着色实验结果

方法	PSNR↑	SSIM↑	MSE↓	MAE↓	SAM↓	LPIPS↓
相对熵指数 (RSI) (Feng等, 2022年)	33.135	0.983	47.805	103.962	0.068	0.052
CIR (Feng等, 2021b)	31.990	0.957	42.428	95.134	0.069	0.077
SEGAN (Wu等, 2019)	32.513	0.632	396.840	122.054	0.083	0.640
吴 (Wu等, 2019年)	31.558	0.537	458.715	127.489	0.085	0.634
Iizukas (Iizuka, Simo-Serra和Ishikawa, 2016年)	11.072	0.190	507.459	125.625	0.465	0.110
黄 (Huang等, 2021年)	32.025	0.968	72.866	105.335	0.066	0.175
我们的	35.569	0.984	28.477	88.036	0.052	0.048

当仅聚焦于超分辨率 (SR) 任务时, MFmamba在树木、屋顶、建筑物等图像的超分辨率处理中表现更优 (参见图7中的红色方框)。图7最后一行展示了SRx4图像与标注图像的超分辨率结果误差强度热图, 直观呈现了不同方法的误差分布及细节差异。

光谱恢复本研究提出的图像着色方法在波茨坦数据集上与RSI (冯等人, 2022)、CIR (冯等人, 2021b)、SEGAN (吴等人, 2019)、Wu (吴等人, 2019)、Iizukas (Iizuka, Simo-Serra 和 Ishikawa, 2016) 以及Huang (Huang等人, 2021) 等最先进算法进行了对比。结果如表6所示。尽管图像着色是MFmamba模型的附加功能, 但其表现仍优于其他方法, 生成结果具有更显著的视觉优势。我们选取波茨坦数据集中的五张图像展示所采用的多种对比方法及MFmamba的成果, 如图8所示。MFmamba在图像着色任务中表现最佳, 生成的图像色彩更真实自然、细节更丰富, 与真实标注图像高度接近。颜色过渡与边缘细节均得到有效还原, 展现出卓越的光谱恢复能力与出色的视觉效果。

Mamba与Transformer的对比我们通过将MUB模型中的Mamba模块替换为Transformer模块进行实验, 对比分析了Mamba与Transformer在运行时间、参数数量及内存占用方面的差异 (基于波茨坦数据集)。实验结果如图9所示, 可见我们设计的Mamba模型不仅运行速度更快, 参数数量也更少, 充分证明了Mamba的优越性。




图7：MFmamba与对比方法在波茨坦数据集上的视觉SR结果。



图8：MFmamba与基准方法在波茨坦数据集上的可视化着色结果。

Mamba的诸多优势。




图9：Potsdam数据集上Mamba与Transformer的对比条形图。

结论

我们提出了一种名为MFmamba的多功能分辨率恢复模型, 用于提升遥感图像的空间分辨率和光谱分辨率。该模型采用状态空间模型开发MUB模块, 从而增强模型的上下文建模能力。所提出的MHCB能提取多尺度特征, 有效传递图像细节信息。我们引入了新型注意力机制DPA, 使模型能够聚焦于最重要的特征通道。大量实验和可视化结果表明, MFmamba结合这些模块在空间分辨率恢复、光谱分辨率恢复以及PAN图像联合恢复方面均取得显著成效。此外, 我们的方法在超分辨率和着色领域表现优于现有大多数模型。大量实验也验证了在单一框架内整合多项任务的有效性。

致谢

本研究由美国国立卫生研究院 (National Institutes of Health) 资助。中国国家自然科学基金 (项目编号: 62261060)