

用于多变量时间序列预测的谱算子神经网络

徐玉轩、瓦西里奥斯·拉姆波斯

伦敦大学学院计算机科学系人工智能中心 {yuxuan.shu.22, v.lampos}@ucl.ac.uk

摘要

多变量时间序列预测方法能够整合外生变量信息，从而显著提升预测精度。由于能够捕捉长程序列依赖关系，Transformer架构已被广泛应用于各类时间序列预测模型中。然而，Transformer的直接应用往往难以有效建模变量间随时间变化的复杂关系。为解决这一问题，我们提出一种新型架构——**谱算子神经网络 (Sonnet)**。Sonnet对输入数据应用可学习的小波变换，并结合Koopman算子进行谱分析。其预测能力依赖于**多变量相干注意力 (MVCA)**，该操作通过利用谱相干性来建模变量依赖关系。实证分析表明，Sonnet在47项预测任务中表现最佳，其中34项任务的平均绝对误差 (MAE) 较最具竞争力的基线模型降低2.2%。我们进一步证明 MVCA 能有效弥补直接应用Transformer的不足。在多种深度学习模型中均受到关注，在最具挑战性的预测任务中平均将MAE降低了10.7%。¹

代码和数据——<https://github.com/ClaudiaShu/Sonnet>

1 引言

多变量时间序列 (MTS) 预测方法通过分析多个输入变量来预测单一目标变量 (Hidalgo和Goodman, 2013)。这类模型已广泛应用于金融建模 (Niemira和Saaty, 2004; Antunes等, 2018; Taylor和Buizza, 2003; Witt和Witt, 1995)、数值天气预报 (Fildes和Kourentzes, 2011; Young, 2018; Dalton和Bekker, 2022) 以及计算流行病学 (Dugas等, 2013; Shaman和Karspeck, 2012; da Silva等, 2020; Morris等, 2023) 等领域。近年来，时间序列预测的机器学习模型普遍采用多变量建模方法 (Nie等, 2023; Zeng等, 2023; Liu等, 2023; Ansari等, 2024; Das等, 2024)。这些模型不仅为传统时间序列预测与深度学习技术的融合提供了重要参考，例如捕捉季节性特征 (Lin等, 2024)、频域分析方法 (Zhou等, 2022a, b) 以及自回归模型 (Zeng等, 2023; Nie等)

¹经美国心脏病学会 (AAAI) 2026年年会口头报告接受。本版本为会议论文的扩展版。

(et al. 2023)，他们常常忽视通过外生指标利用外部信息所带来的益处。

事实上，实证研究表明，从外部变量中捕获依赖关系会增加复杂模型的过拟合风险 (Nie等, 2023)。此外，现有捕获变量间依赖关系的方法 (Zhang和Yan, 2023; Wang等, 2024a) 在某些预测任务中，其表现反而被不捕获依赖关系的模型超越 (Lin等, 2024; Luo和Wang, 2024a)。不过，这可能归因于预测基准的选择——这些基准往往具有明显的季节性特征 (Lin等, 2024; 另见附录E.5)，而这些特征可以通过更简单的自回归方法有效建模 (Zeng等, 2023; Lin等, 2024)。此外，不捕获变量间依赖关系的模型通过延长回溯窗口进行学习，既不会显著增加建模复杂度和计算成本 (Han、Ye和Zhan, 2023)，又能有效降低过拟合风险。但需要指出的是，这些实证结论未必适用于多变量预测场景，特别是在外生变量具有强预测能力的任务中。在此类情况下，明确建模变量间的相互作用有助于提升性能 (Wang等, 2024b; Shu和Lampos, 2025)。

现有研究已探索多种方法来捕捉多变量或多时间序列 (MTS) 预测任务中的变量间依赖关系。采用注意力机制的方法 (Vaswani等人, 2017; Liu等人, 2024; Ilbert等人, 2024) 虽能捕捉非线性依赖关系，但通过沿时间维度嵌入序列会破坏时间信息。Crossformer (Zhang和Yan, 2023) 试图通过改进Transformer结构来解决这一问题，将输入分割为时间序列片段，从而在子序列层面同时捕捉时间和变量维度的依赖关系。而ModernTCN (Luo和Wang, 2024b) 则采用卷积核同时处理变量和时间维度，以联合捕捉变量间及变量内的依赖关系。然而，随着外生变量数量或输入时间序列长度的增加，Crossformer和ModernTCN均面临GPU计算开销问题 (Shu和Lampos, 2025; Zhou等人, 2024)。TimeXer (Wang等人, 2024b) 通过分别建模外生变量与目标变量间的依赖关系，再将学习到的嵌入向量与交叉注意力模块结合。DeformTime (Shu和Lampos 2025) 可生成su-

通过采用可变形注意力机制整合不同时间步长的外生变量信息来提升模型性能。然而，该方法仅能捕捉卷积核接收域内的变量间依赖关系，从而限制了对更广泛外生变量的探索范围。

基于频率的分析技术（包括傅里叶变换法（Bochner 1953; Sorensen等 1987）和小波变换法（Varanini等 1997; Zhang等 2003; Arneodo、Grasseau和Holschneider 1988; Farge等 1992; Yu、Guo和Sano 2024））已被广泛应用于统计学领域，用于识别周期性模式（Priestley 2018），同时也被应用于机器学习方法的预测分析（Lange、Brunton和Kutz 2021; Zhou等 2022a, b; Piao等 2024）。这些方法通过傅里叶变换压缩时间信息，而部分方法则专注于捕捉变量间的内部依赖关系（Zhou等 2022a, b）。小波变换虽依赖于所选母小波（De Moortel、Munday和Hood 2004; Ngui等 2013），但仍能同时保留时间和频率信息。在频域中，谱相干性（White和Boashash 1990）是捕捉不同频率下变量间相关性的有力工具（Stein、French和Holden 1972; Mima和Hallett 1999）。为优化频域输入投影，Lange、Brunton和Kutz（2021）采用了Koopman算子（Mezić 2005年; Rowley等，2009年; Avila和Mezić 2020年; Liu等人2023年），即一种能够对非线性变化进行线性建模的谱函数，从而更好地处理非线性问题。最近，AdaWaveNet（Yu、Guo和Sano 2024年）将输入序列分解为季节性和长期成分，并利用小波变换捕捉周期性信息。该方法仅考虑季节性成分之间的变量依赖关系。

基于上述研究发现，我们提出了一种名为**谱算子神经网络**（Sonnet）的模型，该模型通过可学习的小波变换在频域捕捉多时间序列（MTS）的依赖关系。Sonnet创新性地采用频域**多变量相干注意力**（MVCA）层，同时捕捉变量内部及变量间的依赖关系。此外，该模型还部署了可学习的Koopman算子来实现时间状态的线性化转换（Li等人，2020）。MVCA在集成到现有架构时展现出独立有效性，其性能超越了“ive注意力”及其他改进型注意力机制。我们的核心贡献包括：

1. 我们提出**Sonnet**，一种新型的MTS预测神经网络架构，通过自适应时频谱算子捕捉变量间依赖关系，同时借助可学习的Koopman动力学确保系统稳定性。
2. 我们提出**MVCA**，这是一种通过利用变量间频域依赖性的频谱相干性来建模变量间交互作用的注意力机制。与传统自注意力机制通过点积计算成对相似度不同，MVCA通过包含所有变量的频域信息，利用交叉频谱密度捕捉时间关系，从而增强多时间序列任务的变量依赖建模能力。
3. 我们在经过严格筛选的MTS数据集上评估预测准确性，包括已建立的基准数据集。

由天气预报、流感流行率、电力消耗和能源价格等任务所涵盖。天气预报和流感流行率任务支持更全面的评估，因为它们包含大量外生变量、多年（ ≥ 10 ）的训练数据以及多个测试周期（ ≥ 3 ）。

4. 与性能最优的基准模型相比，Sonnet平均将平均绝对误差（MAE）降低了2.2%（统计显著性， $p < 10^{-3}$ ）。在更具挑战性的流感和天气建模任务中，MAE分别降低了3.5%和2%。随着预测时间范围的延长，性能提升持续存在，这证明了Sonnet在长期预测中的有效性。

2 MTS预测任务定义

我们专注于多变量时间序列（MTS）预测，即使用多个输入变量来预测单一目标变量。需要说明的是，虽然某些基线模型可能存在多个输出变量（多变量预测），但我们的评估仅限于对单一特定输出的预测。所有模型均采用滚动窗口设置进行训练和评估，回溯窗口和预测时域分别为 L 和 H 个时间步。在每个时间步 t ，目标（内生）变量的自回归信号表示为 $\mathbf{y}_{t-\delta} \in \mathbb{R}^L$ ；该信号包含 L 个过去时间步 $\{t-L+1, \dots, t\}$ 的 C 外生变量观测值，这些观测值被捕获在输入矩阵 $\mathbf{X}_t \in \mathbb{R}^{L \times C}$ 中。目标变量的自回归信号包含时间步 $\{t-\delta-L+1, \dots, t-\delta\}$ ，其中 $\delta \in \mathbb{N}_0$ 表示当目标变量存在时间滞后观测时可选的延迟项。我们将外生和内生输入变量表示为 $\mathbf{Z}_t = [\mathbf{X}_t, \mathbf{y}_{t-\delta}] \in \mathbb{R}^{L \times (C+1)}$ 。目标是在时间步 $t+H$ 预测目标变量，其中 H 表示预测时长。因此，预测模型的输出记为 $\mathbf{y}_{t+H} \in \mathbb{R}^H$ ，并包含时间步 $\{t+1, \dots, t+H-1, t+H\}$ 的预测。对于进行多元预测的模型，输出包含所有协变量的预测，因此记为 $\mathbf{Y}_{t+H} = [\mathbf{X}_{t+H}, \mathbf{y}_{t+H}] \in \mathbb{R}^{H \times (C+1)}$ 。预测任务是学习 $f: \mathbf{Z}_t \rightarrow \mathbf{y}_{t+H}$ 或 $\mathbf{Y}_{t+H}$ 。性能基于时间步 $t+H$ 的内生预测进行衡量，即 $\mathbf{y}_{t+H}$ 的最后一个（时间）元素， $y_{t+H} \in \mathbb{R}$ 。为简化符号，我们省略时间下标，并用 $\mathbf{Z}$ 表示 $\mathbf{Z}_t$ ， $\mathbf{y}$ 表示 $\mathbf{y}_{t-\delta}$ ， $\mathbf{x}$ 表示 $\mathbf{X}_t$ 。

3 光谱相干性与声子

在本节中，我们详细描述了提出的模型Sonnet。该模型通过可学习的小波变换在频域中运行，并引入**多变量相干注意力**（MVCA）模块来捕捉变量间的相互依赖和变量内部的依赖。我们进一步使用Koopman投影层，通过学习的线性算子实现稳定的时间演化。

3.1 输入变量的联合嵌入

给定一个输入矩阵 $\mathbf{Z} \in \mathbb{R}^{L \times (C+1)}$ ，它由外生变量 $\mathbf{x} \in \mathbb{R}^{L \times C}$ 和内生变量 $\mathbf{y} \in \mathbb{R}^L$ 组成，我们首先独立地获取 $\mathbf{x}$ 和 $\mathbf{y}$ 的嵌入向量。这些向量分别记为 $\mathbf{E}_x \in \mathbb{R}^{L \times \alpha d}$ 和 $\mathbf{E}_y \in \mathbb{R}^{L \times (1-\alpha)d}$ 。

它们通过可学习的权重矩阵 $\mathbf{W}_x \in \mathbb{R}^{C \times \alpha d}$ 和 $\mathbf{W}_y \in \mathbb{R}^{1 \times (1-\alpha)d}$ 推导得出，如 $\mathbf{E}_x = \mathbf{XW}_x$ 所示，其中 d 是嵌入维度， $\alpha \in [0,1]$ 是控制最终嵌入中 $\mathbf{x}$ 和 $\mathbf{y}$ 投影维度的超参数。² 通过沿特征维度拼接，我们得到最终嵌入 $\mathbf{E} = [\mathbf{E}_x, \mathbf{E}_y] \in \mathbb{R}^{L \times d}$ 。

3.2 可学习小波变换

随后我们将时间序列嵌入转换到包含时域和频域信息的小波空间中，以捕捉不同时间分辨率下的精细细节与整体趋势 (Mallat 1989; Daubechies 1990)。具体而言，在获得输入时间序列嵌入 $\mathbf{E}$ 后，我们首先定义一组 K 个可学习小波变换（亦称原子），其中第 k 个原子由矩阵 $\mathbf{M}_k \in \mathbb{R}^{d \times L}$ 表示，该矩阵通过

$$\mathbf{M}_k = \exp(-\mathbf{w}_\alpha \mathbf{t}^2) \times \cos(\mathbf{w}_\beta \mathbf{t} + \mathbf{w}_\gamma \mathbf{t}^2), \quad (1)$$

其中 $\mathbf{t} \in \mathbb{R}^L$ 是一个行向量，用于捕获归一化时间步长，其中 $t_i = i/(L-1)$ 对于 $i=0, \dots, L-1$ ，而 $\mathbf{w}_\alpha$ 、 $\mathbf{w}_\beta$ 以及 $\mathbf{w}_\gamma \in \mathbb{R}^d$ 是可学习的权重向量，用于控制小波的形状，每个权重向量均从正态分布中随机初始化。具体而言， $\mathbf{w}_\alpha$ 控制高斯包络的宽度，而 $\mathbf{w}_\beta$ 、 $\mathbf{w}_\gamma$ 分别决定生成余弦波形的线性或二次频率调制。该公式使原子能够适应数据中的局部时频结构。时间序列嵌入 $\mathbf{E} \in \mathbb{R}^{L \times d}$ 随后通过投影到每个小波原子 $\mathbf{M}_k \in \mathbb{R}^{d \times L}$ 上转换到小波空间，使用 $\mathbf{P}_k = \mathbf{E} \odot \mathbf{M}_k$ ，其中 $\mathbf{P}_k \in \mathbb{R}^{L \times d}$ 表示第 k 个原子的嵌入投影， $\odot$ 为逐元素乘法。所有 K 个原子的转换小波表示为 $\mathbf{P} \in \mathbb{R}^{K \times L \times d}$ 。上述步骤通过自适应小波变换将输入分解为多分辨率时频分量，同时保留时间结构，该变换能捕捉数据中的短期和长期模式。

3.3 多变量一致性注意力 (Multivariable Coherence Attention, MVCA)

在MTS预测中，输入变量既可能自相关（与自身历史值相关），也可能互相关（彼此相关）。为提升对这些相关性的学习能力，我们提出 MVCA 模块，该模块可增强标准注意力机制。MVCA 通过频域中的谱密度相干性捕捉变量间的相互依赖与内部依赖关系。其核心原理是：谱相干性越高的变量，对注意力输出的贡献度越高。MVCA 可替代任何神经网络中的注意力机制。ive attention module 用于预测方法中。

给定小波空间中获得的输入嵌入矩阵 $\mathbf{P} \in \mathbb{R}^{K \times L \times d}$ （其中 L 和 d 分别为时间维度和变量维度， K 表示变换后的波let数量），我们首先将其线性投影到查询、键和值的嵌入向量上。

²我们确保两个产品 αd 和 $(1-\alpha)d \in \mathbb{N}$ 以避免因舍入导致的维度不匹配。对于 $\alpha=0$ ，预测仅基于目标变量的历史值，简化为自回归设置。对于 $\alpha=1$ ，预测完全依赖于外生变量。

记为 $\mathbf{Q}$ 、 $\mathbf{K}$ 和 $\mathbf{V} \in \mathbb{R}^{K \times L \times d}$ ，分别使用权重矩阵 $\mathbf{W}_q$ 、 $\mathbf{W}_k$ 和 $\mathbf{W}_v \in \mathbb{R}^{d \times d}$ ，如 $\mathbf{Q} = \mathbf{PW}_q$ 。随后我们将不同小波变换（由 k 索引）的嵌入视为独立的注意力头。具体而言，对于每个注意力头，我们获取 $\mathbf{Q}$ 、 $\mathbf{K}$ 和 $\mathbf{V}$ 的子张量，记为 $\mathbf{Q}_h$ 、 $\mathbf{K}_h$ 和 $\mathbf{V}_h \in \mathbb{R}^{L \times d}$ ，分别作为查询、键和值的嵌入。因此，每个头捕获原始嵌入的不同子空间，其中子空间对应输入的不同小波变换。引入多头结构使模型能够并行学习多样化的依赖关系 (Vaswani 等, 2017)。

随后我们沿每个变压器头的变量维度应用快速傅里叶变换 (FFT) (Dudgeon 和 Mersereau 1984)，将查询和键的嵌入向量转移到频域，即 $\mathbf{Q}_f = \text{FFT}(\mathbf{Q}_h)$ 和 $\mathbf{K}_f = \text{FFT}(\mathbf{K}_h)$ ，其中 $\mathbf{Q}_f$ 和 $\mathbf{K}_f \in \mathbb{C}^{L \times \ell}$ ，且 $\ell = \frac{d}{2} + 1$ 。变换数据中的每个频段 ($\mathbf{Q}_f$, $\mathbf{K}_f$) 包含来自 FFT 所有原始输入的信息 (Lee-Thorp 等人, 2022)，既捕捉了精细（高频）模式，也捕捉了全局（低频）模式。互谱密度 $\mathbf{P}_{qk} \in \mathbb{C}^{L \times \ell}$ 与功率谱密度 $\mathbf{P}_{qq}$, $\mathbf{P}_{kk} \in \mathbb{R}^{L \times \ell}$ 的计算方法如下：

$$\mathbf{P}_{qk} = \mathbf{Q}_f \mathbf{K}_f^*, \mathbf{P}_{qq} = \mathbf{Q}_f \mathbf{Q}_f^*, \mathbf{P}_{kk} = \mathbf{K}_f \mathbf{K}_f^*, \quad (2)$$

其中 $*$ 表示复共轭。我们沿第二维平均得到 $\mathbf{P}_{qk} \in \mathbb{C}^L$ 、 $\mathbf{P}_{qq}$ 和 $\mathbf{P}_{kk} \in \mathbb{R}^L$ （另见附录B）。归一化谱相干性 $\mathbf{C}_{qk} \in \mathbb{R}^L$ 通过以下方式计算

$$\mathbf{C}_{qk} = |\bar{\mathbf{P}}_{qk}|^2 / (\bar{\mathbf{P}}_{qq} \cdot \bar{\mathbf{P}}_{kk} + \epsilon), \quad (3)$$

其中 $h=10^{-6}$ 可避免除以0的情况。 $\mathbf{C}_{qk}$ 反映了不同频段序列间的线性依赖关系。因此，该相干性指标会优先考虑查询值与键值在多个频段上平均值更为接近的时间步。

遵循注意力层的通用设计 (Vaswani 等人, 2017)，我们对 $\mathbf{C}_{qk}$ 进行缩放、归一化和正则化，即 $\mathbf{A}_h = \text{Dropout}(\text{Softmax}(\mathbf{C}_{qk}/\sqrt{d}))$ 。每个头的注意力权重 $\mathbf{A}_h \in \mathbb{R}^L$ 首先沿特征维度广播形成 $\mathbf{A} \in \mathbb{R}^{L \times d}$ ，随后与值表示 $\mathbf{V}_h$ （逐元素）相乘以生成头部特定输出 $\mathbf{O}_h \in \mathbb{R}^{L \times d} = \mathbf{A} \odot \mathbf{V}_h$ 。我们将这些输出在所有头之间拼接得到 $\mathbf{O}_r \in \mathbb{R}^{K \times L \times d}$ 。接着使用具有高斯误差线性单元 (GELU) 激活的2层感知机 (MLP, d 维层) 以进一步捕捉非线性特征。该感知机与残差层连接形成输出 $\mathbf{O}_m \in \mathbb{R}^{K \times L \times d} = \mathbf{O}_r + \text{MLP}(\mathbf{O}_r)$ 。然后我们将 $\mathbf{O}_m$ 与权重矩阵 $\mathbf{W}_{\text{out}} \in \mathbb{R}^{d \times d}$ 相乘，得到 MVCA 的输出 $\mathbf{O} \in \mathbb{R}^{K \times L \times d} = \mathbf{O}_m \mathbf{W}_{\text{out}}$ 。

3.4 库普曼引导的光谱演化

受Koopman算子理论的启发 (Mezić 2005年; Rowley等, 2009年; Avila和Mezić 2020年)，该方法为非线性动力学建模提供了一个框架，我们引入了一层来捕捉小波空间中时频模式的时间演化。我们的目标是学习一个具有 K 的Koopman算子。

变换空间中的维度。为获得算子 $\mathbf{K} \in \mathbb{C}^{K \times K}$ ，我们首先初始化一个可学习的复数值矩阵 $\mathbf{S} \in \mathbb{C}^{K \times K}$ 。在每次前向传播时，我们对 $\mathbf{S}$ 进行 QR 分解，并仅保留所得酉矩阵 $\mathbf{U} \in \mathbb{C}^{K \times K}$ ，即 $\mathbf{U} \leftarrow \text{QR}(\mathbf{S})$ ，满足 $\mathbf{U}^\dagger \mathbf{U} = \mathbf{I}$ ，其中 $\mathbf{U}^\dagger$ 是 $\mathbf{U}$ 的共轭转置。因此乘以 $\mathbf{U}$ 可防止数据放大或失真。

我们随后初始化一个可学习向量 $\mathbf{p} \in \mathbb{R}^K$ ，其中第 k 个元素 p_k 控制第 k 个变换的时间演化（相位转换角）。该向量的所有元素随后被映射为复数，得到 $\mathbf{v} \in \mathbb{C}^K$ ，其中 $v_k = e^{ip_k}$ 。我们利用 $\mathbf{v}$ 构建对角矩阵 $\mathbf{D} \in \mathbb{C}^{K \times K} = \text{diag}(\mathbf{v})$ 。Koopman 算子 $\mathbf{K}$ 由 $\mathbf{K} = \mathbf{U} \mathbf{D} \mathbf{U}^\dagger$ 给出。我们使用 $\mathbf{K}$ 来建模 MVCA 嵌入 $\mathbf{O}$ 在转换为复数形式 $\mathbf{O}_c \in \mathbb{C}^{K \times L \times d}$ （虚部设为 $i0$ 以执行复数值变换而不改变原始嵌入）后的时序演化，其表达式为 $\mathbf{O}_l = \mathbf{K} \times \mathbf{O}_c$ ，其中 $\mathbf{O}_l \in \mathbb{C}^{K \times L \times d}$ 是乘以 $\mathbf{K}$ 后的演化嵌入。传统的 Koopman 框架在每个时间步递归建模时序演化（Lusch、Kutz 和 Brunton 2018; Avila 和 Mezić 2020 年）。我们选择在频域中应用 Koopman 变换，仅需一次前向传播，这相当于从输入到输出学习一个直接变换。这种全局投影方法在保持训练鲁棒性的同时，减少了顺序误差的累积。

3.5 小波序列重构

逆变换通过聚合每个小波原子的权重来重构原始序列。给定演化状态 $\mathbf{O}_l$ ，我们首先获取其实部，记为 $\mathbf{O}_r \in \mathbb{R}^{K \times L \times d}$ 。对于每个由 k 索引的小波原子，令 $\mathbf{O}_k \in \mathbb{R}^{L \times d}$ 表示 $\mathbf{O}_r$ 的对应切片。然后将其与小波原子 $\mathbf{M}_k \in \mathbb{R}^{d \times L}$ 相乘，即 $\mathbf{R}_k = \mathbf{O}_k \odot \mathbf{M}_k^\top$ 。 $\mathbf{R}_k \in \mathbb{R}^{L \times d}$ 表示从第 k 个原子重构的序列。该操作在所有 K 个原子上进行。将所有重构序列拼接形成 $K \times L \times d$ 矩阵。对其第一维求和得到重构嵌入，记为 $\mathbf{R} \in \mathbb{R}^{L \times d}$ 。

3.6 卷积解码器

最后，一个三层卷积解码器对学习到的表示进行转换。它包含 3 个一维卷积层，每两层之间使用 GELU 激活函数。各层分别采用核大小 [5, 3, 3] 和填充 [2, 1, 1]，最后接一个自适应平均池化层。各层的维度分别为 $[H \times 4, H \times 2, H]$ ，生成最终序列表示 $\mathbf{Z}_{\text{out}} \in \mathbb{R}^{H \times H}$ ，与目标预测时域的时间步长对应。结果随后通过权重向量 $\mathbf{W}_z \in \mathbb{R}^H$ 进行线性投影，生成最终输出，如 $\hat{\mathbf{y}} \in \mathbb{R}^H = \mathbf{Z}_{\text{out}} \mathbf{W}_z$ ，与目标变量的维度相匹配。

4 结果

我们通过扩展数据集和任务集来评估预测准确性，以克服潜在的偏差。

当前文献。我们首先将 Sonnet 与其他竞争性基线模型进行比较。随后通过移除或替换注意力机制，探究其在时间序列预测模型中的作用。以及更先进的变体，包括提议的 MVCA 模块。我们还在附录 E 中提供了 Sonnet 关键组件和种子控制的消融研究。

4.1 实验设置

我们在 12 个真实数据集上开展实验。其中包括 Zhou 等人（2021）和 Zeng 等人（2023）提出的两个经典基准数据集——ETTh1 和 ETTh2，这两个数据集包含每小时电力变压器温度预测。油温作为目标变量，其余指标均按 Wang 等人（2024b）的方法作为外生变量处理。我们还使用 Darts 库中的两个数据集（Herzen 等人，2022），分别预测每小时能源价格（ENER）和电力（低压）消耗量（ELEC）。此外，我们从 WeatherBench 数据库（Rasp 等人，2020）中提取了五个不同地理位置城市的天气数据集，包括伦敦（WEA-LD）、纽约（WEA-NY）、香港（WEA-HK）、开普敦（WEA-CT）和新加坡（WEA-SG），以支持更全面的分析。针对每个城市，我们从其最近的电网节点采样数据，获取 5 个气候指标。通过纳入周边 8 个电网节点（ 3×3 网格）的数据作为附加外生变量，我们提供了空间上下文信息。基于全球气候预测领域的前期研究成果（Verma、Heinonen 与 Garg 2024），我们对数据进行了 6 小时时间分辨率的重采样。预测目标为 850 百帕（T850）温度，这是气候建模的关键指标（Scherrer 等 2004; Hamill 与 Whitaker 2007）。最后，我们在三个地区纳入流感样疾病（ILI）发病率预测任务（如 Shu 和 Lampos 2025 所述）：英格兰地区（ILI-ENG）、美国卫生与公众服务部（HHS）第 2 区（ILI-US2）和第 9 区（ILI-US9）。在 ILI 任务中，网络搜索频率时间序列被作为外生预测因子纳入。更多数据集信息详见附录 A。

对于 ETT 任务，我们将预测时间范围（ H ）设置为 {96, 192, 336, 720} 个时间步，并采用先前研究（Nie 等人 2023; Liu 等人 2024）中的评估设置，使用单个连续未见过的测试集。对于 ENER，我们将 H 设为 {24, 48, 72, 168} 小时，并使用 1 年（2018 年）进行测试。对于 ELEC，我们使用最后 2 年（2020 年、'21 年）作为 2 个独立测试季节，并将 H 设为 {12, 24, 36} 小时。对于 WEA 任务，我们构建 3 个测试集（2016 年、'17 年、'18 年），并将 H 设为 {4, 12, 28, 120} 个时间步，对应 {1, 3, 7, 30} 天。遵循与（Shu 和 Lampos 2025）相同的设置，对于 ILI 预测任务，我们在连续 4 个流感季节（2015/16 至 2018/19），每次均使用前几个季节的数据训练新模型。我们设定 $H = \{7, 14, 21, 28\}$ 天（更多细节见附录 D）。

我们将 Sonnet 与 8 种竞争性预测模型进行对比，据我们所知，这些模型构成了当前 SOTA 方法：DLinear（曾等人，2023）、Crossformer（张和严，2023）、iTransformer（刘等人，2024）、PatchTST（聂等人，2023）、TimeXer（王等人，2024b）、Samformer（伊尔伯特等人，2024）、ModernTCN（罗和王，2024b）以及

任务 Sonnet 变形时间 现代TCN Samformer 时间Xer 补丁TST iTransformer 交叉变换器 DLinear																			
	H	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%
ELEC	12	0.1040	24.95	0.1162	26.68	0.1596	36.81	0.2336	53.84	0.1287	28.45	0.1359	30.11	0.1419	30.76	0.1468	31.91	0.1513	30.35
	24	0.1203	27.70			0.1806	39.70	0.2520	56.39	0.1586	33.20			0.1588	35.40	0.1873	35.60	0.3369	73.23
	36	0.1389	30.21			0.1729	35.81	0.2065	43.79	0.2866	62.40	0.1785	35.33		0.1659	33.85	0.1791	38.18	0.2273
	48	0.1621	35.67	0.3717	66.92	0.3752	66.53	0.3703	66.01	0.3733	69.59	0.3717	65.89	0.3838	68.36	0.3716	67.44	0.4307	76.49
能量	0.4154	71.74	0.4294	72.34	0.4404	77.61	0.4467	75.60	0.4386	75.63	0.4647	81.79	0.5138	89.79	72	0.4036	70.52	0.4217	74.50
	0.4246	74.70	0.4303	73.90	0.4276	74.19	0.4473	78.62	0.5124	89.26						0.4089	70.84	0.4353	73.40
	168	0.3980	68.63	0.4399	78.98	0.4497	74.86	0.4243	72.28	0.4493	76.76	0.4872	81.34	0.4352	74.11	0.4168	76.76	0.5070	87.87
	96	0.2145	16.01	0.1941	14.96	0.2047	15.66	0.2047	15.73	0.2135	16.03	0.2017	15.41	0.2052	15.46	192	0.2330	17.61	0.2126
乙醇-乙醚	0.2116	16.08	0.2417	18.32	0.2307	17.64	0.2322	16.96	0.2409	18.29	0.2429	18.13	336	0.2392	18.91	0.2158	16.27	0.2415	0.2820
	18.52	0.2523	18.94	0.2414	17.34	0.2559	19.29	0.2593	19.11							22.65	0.6328	58.34	0.2599
	720	0.2768	19.73	0.2862	21.81	0.2785	20.44	0.3026	23.21	0.2617	18.58	0.3087	23.89	0.2886	22.05		0.3350	24.84	0.2599
	96	0.3098	33.04	0.3121	40.07	0.3199	40.68	0.3312	40.16	0.3346	41.04	0.3145	39.25	0.3420	192	0.3742	39.58	42.41	0.3486
IL-ENG	0.3281	37.90	0.3887	47.08	0.3874	45.37	0.4154	47.07	0.3839	45.45	0.4233	336	0.3689	39.48	0.3450	37.00	0.4035	43.16	0.4084
	0.3904	50.54	0.4083	46.41	0.4041	42.26	0.4018	46.77	0.4332							49.44	0.4710	55.53	0.4487
	720	0.4335	51.62	0.3640	34.99	0.5728	63.04	0.5198	58.44	0.5135	56.17	0.4960	55.27	0.4565		45.40	0.5832	61.45	0.7981
	7	1.4791	21.84	1.6417	28.60	1.9489	14	28.27	2.3475	28.31	2.8084	33.66	2.3115	27.61	2.3084	26.38	36.01	3.0290	1.8698
伊利-美国2号	1.9225	25.77	2.2308	33.98	2.7050	21	2.5101	36.63	3.4937	41.88	3.2547	37.76	3.2301	36.67	40.02	4.4980	54.41	4.3337	2.6543
	36.53	2.6500	32.70	3.0400								51.57	4.3192	51.11	4.2347	48.93			3.0014
	28	2.7481	36.95	2.7228	40.44	3.3611		5.1	60.	4.9013	61.60	4.9964	59.60	4.8125	55.35		3.1983	46.15	5.0347
	7	0.3806	14.89	0.4122	16.01	0.4398	16.55	0.6495	24.21	0.6083	14	0.4491	23.38	0.7097	24.51	0.6507	23.24	29.07	0.4400
伊利-美国2号	18.38	0.4752	17.73	0.5279	20.22	0.7696	30.16	0.7725	21	0.5326	20.64	0.5425	0.8635	30.11	0.7896	28.17	31.46	1.0286	0.5852
	22.12	0.5781	23.85	0.8374	31.42	0.8243						36.70	0.8042	30.03			0.6245	22.29	0.9124
	28	0.5788	21.15	0.5538	22.25	0.5710	23.66	0.9389	36.80	0.9074			34.72	1.1525	42.61	0.9619	36.75	0.6512	23.47
	7	0.2668	12.98	0.2622	12.26	0.2899	14.17	0.4025	19.39	0.3813	18.21	0.4116	19.34	0.4057	18.57	0.3149	14.44	14	0.2806
伊利-美国2号	13.80	0.3417	15.29	0.5257	24.50	0.4665	22.14	0.5020	24.09	0.4702	22.44	0.3571	17.23	21	0.3179	14.11	0.3179	14.23	0.3710
	24.22	0.5715	27.43	0.5935	29.40	0.5106	24.11	0.3418	15.90										0.6001
	28	0.3675	16.53	0.3532	15.75	0.3940	17.19	0.6050	27.95	0.6555	31.32	0.6665	33.35	0.6498	31.05	0.3747	16.44		0.6564
	4	1.6240	9.63	1.7600	10.41	1.8752	11.05	2.2265	13.09	2.2376	13.14	3.5004	20.17	2.1906	12	3.5432	20.38	12.83	1.6382
伊利-美国2号	3.5681	20.46	3.7761	21.67	4.0444	23.14	3.7241	21.31	4.1910	23.99	3.9741	28	3.7277	21.32	3.7601	21.49	3.5932	20.62	4.0265
	3.9399	22.36	3.9239	22.37	3.8325	21.87	3.9405	22.48	3.9584							21.72	3.9254	22.37	22.60
	120	3.7373	21.35	3.8040	21.67	4.0889	23.54	3.9018	22.30	3.8412	21.88	4.0547	23.02	3.9473		22.49	3.7659	21.49	4.0570
	4	0.6389	4.05	0.6804	4.32	0.7004	4.42	0.8097	5.10	0.8648	5.52	1.1488	7.15	0.8048	5.08	0.6488	4.11	0.9898	6.21
WEA-HK	7.99	1.3555	8.43	1.4006	8.70	1.3027	8.13	1.5825	9.77	1.4225	8.86	1.2896	8.08	1.5464	9.62	28	1.4135	8.83	1.4746
	10.05	1.5115	9.39	1.6441	10.16	1.6356	10.08	1.5282	9.45	1.6232	10.06					12	1.2355	7.74	1.2786
	120	1.5469	9.58	1.5399	9.45	1.6326	10.22	1.8843	12.06	1.7092	10.55	2.0084	12.84	1.6745	10.45	1.5931	9.73	1.8329	11.49
	4	1.7231	15.16	1.8753	16.31	1.9456	16.88	2.1537	18.53	2.2628	19.25	2.7602	22.93	2.1509	12	2.9589	23.88	18.55	1.7447
韦氏细胞染色	3.0214	24.15	3.2056	25.58	3.3070	26.61	3.1625	25.25	3.5406	28.33	3.3622	28	3.2161	25.49	3.2724	25.84	3.0492	24.35	3.3927
	3.5067	27.48	3.5841	27.97	3.4672	27.23	3.7365	29.42	3.6884							25.88	3.6073	28.16	26.70
	120	3.2464	25.82	3.2973	26.17	3.8434	29.92	3.8420	30.32	3.6557	28.52	4.2344	32.40	3.8518		30.36	3.3935	26.75	3.9640
	4	1.2716	11.94	1.4028	13.03	1.4154	12.95	1.6003	14.44	1.7290	15.57	2.1644	19.24	1.6066	12	2.4476	21.23	14.40	1.2935
西格玛-艾维	2.4453	21.04	2.6221	22.93	2.7069	23.57	2.6537	22.85	2.8592	24.81	2.6609	28	2.6744	23.10	2.7450	23.20	2.9336	2.4494	21.11
	25.37	3.0347	26.18	2.8775	24.48	3.0956	27.01	3.0204								23.66	3.2099	27.07	25.29
	120	2.7135	23.15	2.8224	23.86	3.3000	28.05	3.5289	33.01	3.1501	26.55	3.4086	28.78	3.1029		27.74	2.9615	24.69	3.6129
	4	0.3444	1.25	0.3557	1.30	0.3624	1.32	0.3925	1.43	0.3801	1.38	0.4238	1.54	0.3868	1.41	0.3532	1.29	0.4048	1.47
西格玛-艾维	12	0.4160	1.51	0.4256	1.55	0.4493	1.64	0.4784	1.74	0.4447	1.62	0.4992	1.82	0.4662	1.70	0.4359	1.59	0.4764	1.73
	28	0.4653	1.69	0.4875	1.77	0.5196	1.89	0.5421	1.97	0.4974	1.81	0.5542	2.02	0.5307	1.93	0.5003	1.82	0.5284	1.92
	120	0.4830	1.76	0.5050	1.83	0.5321	1.94	0.5221	1.90	0.5215	1.90	0.5357	1.95	0.5233	1.90	0.5212	1.89	0.5328	1.94

表1：所有任务、方法及预测时域（H）的预测准确性结果。针对ELEC/ILI/WEA任务，我们分别报告2、4和3个测试集的平均性能（详细分解见附录E.1）。ε%表示sMAPE。最佳结果为加粗，次优结果为下划线。灰色背景表示模型未超越持久性。

DeformTime（Shu 和 Lamos 2025）与 TimeXer、DeformTime 专为多变量预测设计。我们还包含一个 naive 基线，该基线可采用季节性模型或标准持久性模型，具体取决于是否存在显著季节性。除 ETT 外，我们对所有模型进行超参数调优。对于 ETT 任务，我们采用方法官方代码库中的设置。

（Crossformer 除外，其未提供该信息）。附录 C 中有关于基线模型的进一步详细说明。

4.2 “十四行诗” 预测精度研究

所有任务的预测准确率均列于表 1 中，主要采用平均绝对误差（MAE）和对称平均绝对百分比误差（sMAPE 或 ε%）作为评估指标。

	注意	H=7天			H=14天			H=21天			H=28天		
		ENG	US2	US9	ENG	US2	US9	ENG	US2	US9	ENG	US2	US9
iTransformer	—	2.3084	0.6507	0.4057	3.2301	0.7896	0.4702	4.2347	0.8042	0.5106	4.8125	0.9619	0.6498
	↖ 请致	2.3011	0.7242	0.4475	3.2557	0.8696	0.5344	4.4729	1.0105	0.6207	5.1864	1.1667	0.7179
	函 FNet	2.5534	0.7665	0.4741	3.5337	0.8746	0.5550	4.6970	1.0006	0.6066	5.3153	1.1118	0.7139
	FED	3.6150	0.9286	0.5613	4.3098	1.0750	0.6527	5.8596	1.4140	0.8669	6.4196	1.5167	0.9397
	VDAB	2.4287	0.6772	0.4126	3.3093	0.8274	0.4982	3.9406	0.8485	0.4992	4.4975	0.9068	0.5790
安装验证控制区		2.2707	0.5483	0.3581	3.1233	0.7267	0.4454	4.1780	0.7578	0.4880	4.8705	0.8885	0.5409
山姆·福尔摩斯	—	2.3475	0.6495	0.4025	3.0290	0.7696	0.5257	4.4980	0.8374	0.5415	5.1598	0.9389	0.6050
	↖ Attn	2.5010	0.8245	0.5131	3.3015	0.9679	0.6047	4.1830	1.1396	0.7389	5.0136	1.2391	0.8347
	F网	2.4812	0.7765	0.4699	3.2054	0.9202	0.5865	4.3909	0.9266	0.6443	5.0592	1.0983	0.7149
	联邦储备	3.5217	0.9140	0.5599	4.2109	1.0519	0.6508	5.7800	1.3439	0.8519	5.9809	1.4348	0.9190
	VDAB	2.0406	0.5755	0.3651	2.9525	0.7281	0.4505	4.1080	0.7883	0.4861	4.9015	0.8617	0.5605
安装验证控制区		2.1365	0.5514	0.3609	3.2046	0.6935	0.4379	3.8033	0.7294	0.4975	4.7438	0.8159	0.5345
贴片TST	—	2.3115	0.7097	0.4116	3.2547	0.8635	0.5020	4.3192	1.0286	0.5935	4.9964	1.1525	0.6665
	↖ Attn	2.4723	0.7702	0.4585	3.6415	0.9017	0.5551	4.2998	1.0657	0.6472	4.8538	1.1704	0.7313
	F网	2.8097	0.8033	0.4591	4.0342	0.9322	0.5327	4.7975	1.0341	0.5430	4.9718	1.1087	0.6279
	联邦储备	3.6158	0.9292	0.5614	4.6572	1.0765	0.6542	5.8725	1.4043	0.8671	6.3728	1.4953	0.9306
	VDAB	2.0799	0.5925	0.3820	3.0211	0.7722	0.4413	3.8164	0.8009	0.5159	4.6044	0.8518	0.5801
安装验证控制区		2.0054	0.5824	0.3705	3.0411	0.7406	0.4291	3.8627	0.7871	0.4746	4.5712	0.8765	0.5491

表2: iTransformer、Samformer和PatchTST在ILI预测任务（ILI-ENG/US2/US9）中对不同修改的na ive 注意力机制的性能表现（4个测试季节的平均MAE）。‘↖ Attn’表示移除残差注意力模块，FNet / FED / VDAB 分别指使用FNet（2025）、FEDformer（2022a）和DeformTime（2025）中提出的注意力模块。最佳结果以**粗体**显示，次优结果以下划线标注。

指标。对于WEA任务，sMAPE经过调整以避免因开尔文温度单位导致的数值过小（参见附录D.6）。对于ETT和ENER任务，结果基于单个预测季节（即每个预测周期采用一次训练/测试分割），而其他任务则取多个季节的平均值。

在所有测试的MTS预测任务中，Sonnet均展现出最佳整体表现。与各任务及预测周期中表现最优的基线模型相比，Sonnet的平均MAE指标降低了1.1%。在47项预测任务中，Sonnet在34项任务中表现最佳，在9项任务中位列第二。Sonnet在ETT任务中的表现相对逊色，但该ETT数据集仅包含6个外生变量且训练时间跨度有限（2年），这限制了变量依赖关系的探索空间，同时也缺乏足够的历史背景数据——而这些正是Sonnet所利用的优势。除ETT任务外，Sonnet平均MAE指标降低了3.3%。因此，Sonnet在处理更多协变量和更长训练时间跨度时效果更佳。相较于特定预测模型，Sonnet持续提升准确率，将MAE从表现最优的基线模型（变形时间模型）的2.2%降至表现最差的模型（DLinear）的31.1%。我们注意到，基于所有47个预测任务的配对t检验（ $p=5e-4$ ），MAE性能相对于DeformTime的提升具有统计学显著性。这进一步凸显了该模型在广泛应用场景中的预测能力。

在更具挑战性的预测任务（ILI和WEA）中，Sonnet分别基于sMAPE或MAE指标，在32个任务中优于基线模型25或26。在ILI任务中，MAE平均降低3.5%，在WEA任务中降低2%。在这些任务中，我们还观察到基线模型表现出一致的比较性能模式。未能捕捉变量间依赖关系的模型

线性模型和PatchTST通常预测能力较弱（Sonnet将其平均绝对误差降低了28.8%和29.8%），在大多数流感样疾病（ILI）任务中，其表现无法超越持久性模型。相比之下，能够捕捉变量间依赖关系的基线模型往往表现更优。其中，将协变量沿时间维度嵌入的模型——Samformer、TimeXer和iTransformer——表现欠佳（Sonnet将其MAE分别降低了23.9%、22.1%和22.9%），而保留时间顺序的模型——DeformTime、ModernTCN和Crossformer——则取得更佳效果（Sonnet将其MAE分别降低了3.4%、11.1%和8%）。因此，在涉及信息量较大的协变量任务中，建模变量间依赖关系的同时保留时间结构是理想特性。我们在附录E.3中提供了消融研究结果，量化了不同模块对Sonnet整体预测准确度的贡献。关于整个输出序列的额外性能评估结果详见附录E.8。

4.3 不同注意力模块在MTS预测中的有效性

我们通过将注意力驱动模块MVCA集成到现有预测模型（我们称之为基础模型）中来评估其有效性，这些模型最初采用ive变换器注意力机制。实验在ILI任务上进行，因为这些任务最能代表我们正在探索的MTS类别：它们不仅包含大量外生预测因子，还涉及当 $H=21$ 或28天时框架内实际流行病学建模难题。我们采用Samformer（Ilbert等人，2024）、iTransformer（Liu等人，2024）和PatchTST（Nie等人，2023）作为基础模型。针对每个模型，我们评估了5种注意力配置：完全移除注意力模块（↖ Attn）、采用FNet提出的傅里叶变换器注意力机制（Lee-Thorp

十四行诗 VDAB FED FNet Naïve													
	H	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%	MAE	ε%
IL-ENG	7	1.479	21.8	1.433	20.3	5.991	77.7	1.591	27.7	1.717	25.3	14	1.923
		25.8	1.973	29.4	6.031	78.1	2.084	32.8	2.068	31.4	21	2.510	36.5
		35.2	6.045	78.2	<u>2.765</u>	39.3	2.781	37.2					
	28	2.748	37.0	<u>3.060</u>	<u>44.3</u>	<u>6.051</u>	78.4	3.240	44.5	3.078	50.0		
伊利-美国2号	7	0.381	14.9	0.429	16.6	1.168	45.0	0.415	18.5	0.436	17.5	14	0.449
		18.4	<u>0.500</u>	<u>19.1</u>	1.179	45.5	0.558	23.2	0.532	20.4	21	0.533	<u>20.6</u>
		20.5	1.195	46.2	0.659	25.3	0.613	23.5					
	28	0.579	21.1	0.643	24.3	1.193	46.1	0.705	29.1	0.651	26.1		
PDRPRA-300W5.08	7	0.267	13.0	0.277	13.4	0.856	41.0	0.286	14.4	0.301	13.9	14	0.281
		13.1	<u>0.324</u>	15.8	0.856	41.0	0.351	16.1	0.340	<u>14.9</u>	21	0.318	<u>14.1</u>
		14.5	0.857	41.0	0.379	17.8	0.404	19.2					
	28	0.367	16.5	0.375	16.8	0.857	41.0	0.379	18.2	0.411	19.1		
PDRPRA-300W5.08	4	1.624	9.6	1.714	10.1	4.359	24.6	<u>1.629</u>	<u>9.6</u>	1.726	10.2	12	3.543
		20.4	3.563	20.5	4.359	24.7	3.588	20.6	<u>3.558</u>	<u>20.5</u>	28	3.728	21.3
		21.5	4.359	24.6	3.916	22.3	<u>3.758</u>	<u>21.5</u>					
	120	3.737	21.4	3.734	21.3	4.356	24.6	3.815	21.7	3.763	21.5		
PDRPRA-300W5.08	4	0.639	4.1	0.645	4.1	2.801	17.7	<u>0.639</u>	<u>4.1</u>	0.676	4.3		
		12	1.235	7.7	<u>1.279</u>	<u>8.0</u>	2.801	17.7	1.325	<u>8.3</u>	1.281	8.1	
		28	1.413	8.8	<u>1.463</u>	<u>9.1</u>	2.808	17.8	1.494	<u>9.3</u>	1.475	9.2	
	120	1.547	9.6	1.547	9.6	2.810	17.8	1.639	<u>10.1</u>	1.621	10.0		
PDRPRA-300W5.08	4	1.723	15.2	1.814	15.8	4.668	34.9	1.740	<u>15.3</u>	1.811	16.0	12	2.959
		23.9	2.986	24.1	4.661	34.9	3.008	24.1	<u>2.973</u>	<u>24.0</u>	28	3.216	25.5
		25.8	4.659	34.9	3.378	26.5	<u>3.268</u>	<u>25.8</u>					
	120	3.246	25.8	3.319	26.2	4.668	34.9	3.667	28.5	3.407	26.7		
PDRPRA-300W5.08	4	1.272	11.9	1.331	12.4	5.386	40.9	1.268	11.8	1.366	12.9	12	<u>2.448</u>
		21.2	2.474	21.6	5.384	40.9	2.510	21.8	2.438	<u>21.5</u>	28	2.674	23.1
		23.4	5.387	40.9	2.797	23.8	<u>2.724</u>	<u>23.1</u>					
	120	2.713	23.2	2.788	<u>23.5</u>	<u>5.389</u>	40.9	3.063	25.6	2.911	24.6		
PDRPRA-300W5.08	4	0.344	1.3	<u>0.346</u>	<u>1.3</u>	0.700	2.5	0.341	1.2	0.346	1.3		
		12	0.416	1.5	<u>0.421</u>	<u>1.5</u>	0.698	2.5	0.424	1.5	0.425	1.5	
		28	0.465	1.7	0.473	1.7	0.698	2.5	0.495	1.8	<u>0.471</u>	<u>1.7</u>	
	120	0.483	1.8	0.496	1.8	0.697	2.5	0.512	1.9	<u>0.485</u>	<u>1.8</u>		

表3: Sonnet在ILI和WEA任务中使用不同注意力模块的表现。最佳结果**加粗**，次优结果下划线。MAE值四舍五入到小数点后3位，sMAPE值四舍五入到1位。

等（2022年）、FEDformer（Zhou等，2022a）提出的频率增强分解（FED）注意力机制、DeformTime（Shu和Lampos，2025）提出的可变可变形注意力（VDAB）以及我们的方法（MVCA）。更多细节详见附录C.3和D.8。

表2列出了所有预测时域在4个测试季中的平均MAE（附录E.2中的sMAPE，表S9）。值得注意的是，对于基础模型，移除注意力模块并未导致显著性能下降，某些情况下甚至显示出改进效果，例如在 ILIENG 任务中某些时域的准确率有所提升。这表明基础模型中的注意力模块并非总能捕捉有效信息。

通过用提出的 MVCA 模块替代naïve 注意力机制，我们在所有ILI任务中均获得显著性能提升，所有基础模型的平均MAE降低10.7%。PatchTST的平均MAE降幅（15.1%）高于其他基础模型（Samformer为10.4%，iTransformer为6.7%），表明 MVCA 的应用带来了更显著的性能提升。

对于未能捕捉变量间依赖关系的模型，MVCA 与其他改进型注意力模块相比展现出竞争力，平均将MAE降低2.8%。相较于表现最佳的基线模型（DeformTime的VDAB），其MAE和sMAPE分别降低3.5%和3%。虽然ENG区域的提升幅度较小，但 MVCA 在所有美国区域均保持最优表现，VDAB 位列次优；这两种方法均能捕捉变量间依赖关系，而其他方法则无法做到。类似地，替换naïve attention with theFEDformer和FNet中的傅里叶注意力模块导致性能下降。

4.4 不同关注变体的十四行诗

为探究不同注意力机制对Sonnet预测精度的影响，我们采用前述改进型注意力机制替代 MVCA 模块（参见第4.3节）。实验在所有地点、预测时域及测试周期下，针对ILI和WEA两项预测任务展开。针对每种注意力机制变体，均采用相同验证流程重新调参。详见附录C.3。

表3列出了实验结果。总体而言，与其他注意力模块相比，MVCA 模块在32项任务中表现最佳，其中26项任务的平均绝对误差（MAE）优于其他模块。该模块平均可使MAE和sMAPE指标分别降低2.9%和2%。最具竞争力的基线模块是变形时间（DeformTime）的VDAB 模块，MVCA 模块在MAE和sMAPE指标上分别优于其3.6%和3%。表现最差的注意力模块是FED（前馈变形器）的FEDformer模块，MVCA 模块使其MAE指标降低51.5%。FED模块通过频率变换捕捉季节性信息，但未考虑变量间的依赖关系。这表明仅建模季节性信息不足以支持多时间序列（MTS）预测，特别是在关键预测信息来源于外生变量时。使用 naïve attention or FNet is similarMVCA 分别将平均绝对误差（MAE）降低了7%和6.6%。这符合预期，因为FNet并未向神经网络引入可学习参数。ive attention.

5 结论

本文提出了一种新型多变量时间序列预测模型Sonnet。该模型通过频谱维度运用可学习的小波变换，基于频率相干性捕捉变量间的依赖关系，进而采用Koopman算子预测未来时序动态。实验在12个跨领域数据集上展开，其中9个数据集包含多个测试季节以确保分析全面性。Sonnet在47项任务中取得34项最佳表现，与整体最优基线（DeformTime）相比平均降低均方误差（MAE）2.2%，与单项任务最优基线（可变）相比平均降低1.1%。实验还表明，用提出的 MVCA 模块替代现有预测模型中的标准注意力机制，可显著提升预测精度。