

透过噪声：从噪声抑制视角提升红外小目标检测与分割性能

毛迅元¹杜安妮孟¹子腾xi¹田毅赵¹史吉赵¹伊面戴²星星魏¹

¹北京航空航天大学²南开大学

{yuanmaoxun, mengduanni, xxwei}@buaa.edu.cn, yimian.dai@gmail.com

摘要

红外小目标检测与分割 (IRSTDS) 在国防及民用领域是一项关键而具有挑战性的任务，这源于目标呈现的微弱无形状特征以及严重的背景杂波干扰。近期基于卷积神经网络 (CNN) 的方法虽取得显著目标感知成果，但其仅通过增强特征表示来抵消噪声影响，导致误报警率上升问题。本文通过频域分析问题本质，创新性地从噪声抑制角度提升性能，提出新型噪声抑制特征金字塔网络 (NS-FPN)。该网络在原有 FPN 架构中集成低频引导特征净化 (LFP) 模块与螺旋感知特征采样 (SFS) 模块：LFP 模块通过净化高频成分实现无噪声干扰的特征增强，SFS 模块则采用螺旋采样技术在特征融合过程中整合目标相关特征。NS-FPN 设计兼具轻量化与高效性优势，可无缝集成至现有 IRSTDS 框架中。在 IRSTD-1k 和 NUAA-SIRST 数据集上进行的大量实验表明，我们的方法能显著降低误报率，并在 IRSTDS 任务中取得优异性能。相关代码可在 <https://github.com/mengduann/NS-FPN> 获取。

1. 引言

红外小目标检测与分割 (IRSTDS) 在国防及民用领域具有关键应用价值，涵盖鸟类预警系统[5]、海上救援行动[27, 28]以及空中监视系统[29, 32]等场景。由于成像距离远且缺乏足够的纹理或结构信息，红外小目标 (IRST) 常呈现为亮度微弱、形状模糊的斑点状特征，其信噪比 (SNR) 与信杂比 (SCR) 均处于极低水平[7, 30]。这些特性严重制约了精准检测能力，尤




图1.本方法与其他方法在 IRSTD-1k 和 NUAA-SIRST 数据集上的性能对比。外围区域表示性能更优。

其在动态环境中——当目标被密集背景杂波掩埋且热辐射特征微弱时，问题更为突出。因此，如何在多样化且真实的红外场景中开发出能够精准定位小目标的鲁棒高效 IRSTDS 方法，仍是亟待解决的技术难题。

近年来，IRSTDS 研究的重点已转向基于 CNN 的方法，用于检测[7, 15, 36]和分割[6, 13, 18, 31]，这些方法专注于设计特征融合结构以整合高层次特征与低层次细节。例如，DNANet[13]被用于缓解池化层导致的深度信息丢失问题，Liu 等人也对此进行了研究。[18] 为普通 U-Net 设计一种简易多尺度头部网络 (MSHNet) 以实现更精准的目标定位。此外，为捕捉小型目标的关键结构特征，IRPruneDet[35]提出小波通道剪枝方法，该方法认为高频分量能够有效区分特征对目标 IRSTDS 的重要性。近期，IRSAM[34]通过小波变换改进 Perona-Malik 扩散方程[20]以实现图像去噪与边缘保留，进一步提升了检测性能。尽管这些方法




图2. 离散Haar小波变换（DWT）用于将原始图像分解为低频与高频分量。红色与蓝色曲线之间存在交叉区域。

通过设计复杂网络结构已取得令人满意的性能提升效果，但这些方法主要聚焦于增强特征表示能力，却忽视了由此产生的误报问题——这主要是由于过度强调高频成分所致。如图1所示，尽管上述方法在交并比（IoU）和 P_d 指标上展现出良好的目标定位性能，但在IRSTDS任务中却同时伴随着较高的误报率（ F_a ）。

为解决这一问题，我们从频域角度探究了误报率上升的可能原因。由于不同频率成分在图像结构中具有不同功能，高频与低频成分在IRSTDS任务中可能发挥不同作用。因此，我们将原始图像如图2所示进行分解，并观察到以下特征：**高频成分对IRSTDS任务至关重要，但同时也导致误报率上升。**相较于低频成分，两种方法的 P_d 与IoU指标在原始图像上均表现出优异性能，这表明低频成分中丢失的图像细节（高频成分）对目标定位至关重要。然而这些高频成分也包含噪声干扰，导致误报率上升。**低频成分会降低目标定位性能，但也可作为减少误报的有效线索。**如图2所示，原始图像上的性能表现优于低频成分研究者发现， F_a 指标显示低频分量在虚假警报抑制性能上表现最佳。这一优异性能凸显了低频分量作为有效特征在抑制高频分量噪声方面的潜力。

基于上述研究思路，我们在特征融合噪声抑制领域开创性地提出新方法，旨在提升目标定位性能的同时降低误报警率。为此，我们首先提出一种**低频引导特**

征净化模块（LFP），通过净化高频成分来抑制噪声特征。具体实现 LFP 首先采用二维离散小波变换（DWT）将特征分解至频域，随后利用低频特征预测潜在目标位置的响应值。该预测结果作为加权映射用于优化高频特征，继而通过门控高斯滤波进一步抑制置信度较低的特征。最终通过逆DWT变换获得降噪特征，同时保留高频增强效果。此外，为避免周围背景噪声干扰，我们设计了具有**螺旋感知能力**的**特征采样模块（SFS）**，在特征融合过程中执行螺旋采样操作。具体而言，SFS 采用基于强度分布特征（螺旋形态）的动态采样方法，并通过计算相似度来获取目标相关特征，从而进一步降低噪声干扰的影响。

与以往侧重设计复杂网络结构的方法不同，本文旨在提出一种轻量级但高效的性能提升方案。为此，我们将 LFP 和 SFS 模块整合到特征金字塔网络（FPN）中，构建了一个名为**NS-FPN**的**噪声抑制 FPN**。通过这种方式，LFP 模块可替代 FPN 中的 1×1 卷积层，从而实现无噪声特征增强。

干扰处理方面，SFS 模块通过替代上采样操作实现目标相关特征的结构化采样与融合。这些高效设计使我们的NS-FPN 能够轻松集成到现有 IRSTDS 框架中。图1表明，NS-FPN 可有效降低误报率并实现卓越的目标定位性能。综上所述，本文的主要贡献如下：

- ① 我们从频域角度揭示了当前基于CNN的 IRSTDS 方法面临的误报率上升问题，并率先从噪声抑制角度提升检测与分割性能。
- ② 我们提出了一种新型特征金字塔网络（NSFPN），该网络通过低频引导特征净化模块和螺旋感知特征采样模块，在抑制噪声干扰的同时增强目标特征。
- ③ 在公共 IRSTDS 数据集上开展的大量实验表明，我们的NS-FPN 能有效降低误报率，从而进一步提升检测性能。

2. 相关工作

2.1. IRST 检测与分割网络

随着深度学习技术的进步，基于卷积神经网络（CNN）的方法已成为主流范式，能够为 IRSTDS 实现自动多层特征学习。在基于CNN的检测领域，Dai 等人的研究表明...[7] 被提议的

一种采用高级头部结果来调节低级头部预测结果的一级级联精炼网络（OSCAR），该网络从粗到细完成目标检测，以及Yang等人的研究。[25] 该研究引入动态头部机制，能够自适应地调整特征响应以适应不同空间和通道，从而提升网络对微小目标的聚焦能力。在基于卷积神经网络的分割方法中，ISNet[33]通过引入边缘重建机制提高了目标形状预测的准确性，而DNANet[13]则通过同层与异层特征间的密集交互，在深层网络中保留了小目标的信息特征。近期，刘等人[18]采用了一种新颖的尺度敏感与位置敏感（SLS）损失函数来校正多尺度预测结果，从而可进一步提升现有方法的检测性能。与此同时，IRPruneDet[35]提出了一种小波结构正则化软通道剪枝策略以提高网络推理效率。

本文未聚焦于复杂结构设计，而是实现了无噪声干扰的特征增强，从而有效降低误报率，进一步提升检测与分割性能。

2.2. 特征金字塔网络

特征金字塔网络（FPN）[16]作为通用目标检测的基础架构应运而生，其通过自上而下的连接方式能够将高层次特征与低层次细节相结合。然而，其线性求和机制可能并非最有效的特征融合方法。基于此，路径聚合网络（PANet）[19]通过引入自下而上的路径增强机制改进了FPN，既促进了低层次特征的复用，又缩短了信息流路径。此外，双向特征金字塔网络（BiFPN）[22]摒弃了PANet中的单输入节点结构，并采用自适应加权特征融合机制以提升检测性能。与依赖人工设计的上述FPNs不同，NASFPN[11]通过神经架构搜索技术自动探索特征融合网络的拓扑空间，发现最优连接策略。近期，HS-FPN[21]专为可见图像中的微小目标检测而设计。然而，该方法过度依赖预设频谱范围确定的高频特征，而忽视了低频特征的重要性，导致其在IRST任务中效果不佳。与上述方法不同，我们的研究充分利用低频成分来自适应引导高频成分，从而在特征融合过程中主动抑制噪声，这是该IRSTDS的特定设计。

3. 方法

在本节中，我们介绍噪声抑制特征金字塔网络（NS-FPN）及其组件。如图3所示，NS-FPN采用与传统

FPN相似的架构设计，从主干网络中提取分层特征图，并通过 1×1 卷积操作将其通道维度缩减至64。这些经通道降维处理的特征（记为 $\{X_1, X_2, X_3, X_4\}$ ）对应于原始输入分辨率下 $\{2, 4, 8, 16\}$ 像素的特征步长。随后通过NS-FPN中的自上而下路径构建多尺度特征金字塔 $\{Y_1, Y_2, Y_3, Y_4\}$ 。NS-FPN中的每个横向连接整合了双重专用噪声抑制模块：低频引导特征净化（LFP）模块与螺旋感知特征采样（SFS）模块。LFP通过净化 X_i 中的高频成分来抑制噪声特征，同时SFS以 $\{X'_i, Y_{i+1}\}$ 作为输入，动态以螺旋形状采样特征，并通过计算相似度进一步消除噪声干扰的影响。最后，通过特征加法获得的增强特征 $\{Y_1, Y_2, Y_3, Y_4\}$ 被用于后续的IRSTDS任务。需要注意的是，NS-FPN的所有侧向层均包含LFP模块，而仅 $\{Y_1, Y_2, Y_3\}$ 层包含SFS模块。

3.1. 低频引导特征净化

正如引言部分所述，低频成分可作为有效线索用于抑制高频表征中的噪声干扰。为此，我们提出LFP模块以减少高频特征中噪声干扰引发的误报现象。为实现这一目标，我们设计了如图3所示的两阶段净化机制：第一阶段利用低频特征构建潜在目标位置的加权分布图，该图谱可指导目标相关特征的增强过程，同时抑制高频噪声特征；第二阶段通过门控高斯滤波对高频特征进行精细化处理，从而更有效地消除噪声成分。

具体来说，在第一阶段，给定输入特征 $X_i \in \mathbb{R}^{B \times C \times H_i \times W_i}$ ，我们首先执行单层二维离散小波变换（DWT）将其分解为低频和高频特征：

$$[F_l, F_h] = \text{DWT}(X), \quad (1)$$

其中 F_l 和 F_h 分别表示低频和高频分量。随后我们通过空间注意力机制从 F_l 中获取加权图，具体步骤如下：

$$A_s = \text{Sigmoid}(\text{Conv}(\text{APool}(F_l) \oplus \text{MPool}(F_l))), \quad (2)$$

其中APool和MPool分别表示平均池化和最大池化。高频特征随后通过逐元素乘法进行调制：

$$F_h = A_s \odot F_h. \quad (3)$$




图3. 我们NS-FPN的整体结构及其组件细节。对于每个尺度，特征首先输入LFP模块，该模块基于低频成分生成目标相关空间注意力图，以指导高频特征的两阶段特征净化过程。随后，净化后的特征通过SFS模块与上层特征融合，根据红外小目标的空间分布先验实现语义互补。需注意，为便于可视化分析，图中省略了卷积层，且 Y_4 模型未包含SFS模块。

在第二阶段，为进一步纯化经调控的高 $\hat{F}_h$ ，对于频率分量 F_h ，我们引入门控高斯滤波 $G(\cdot)$ ，以自适应地对置信度较低的特征施加更强的抑制。具体而言，我们仅对绝对值低于经验设定阈值 τ 的高频分量应用高斯平滑处理：

$$\hat{F}_h = G(\hat{F}_h) \cdot \mathbb{I}_{|\hat{F}_h| < \tau} + \hat{F}_h \cdot \mathbb{I}_{|\hat{F}_h| \geq \tau}, \quad (4)$$

其中 $\mathbb{I}(\cdot)$ 表示用于施加门控约束的指示函数， $G(\cdot)$ 定义如下：

$$G(i, j; \sigma) = \frac{1}{Z} \exp\left(-\frac{(i-c)^2 + (j-c)^2}{2\sigma^2}\right), \quad (5)$$

其中 σ 为可学习标准差， (i, j) 表示核函数中的空间坐标， $c = k/2$ 为核中心， Z 为归一化因子。最后，通过逆离散小波变换对纯化特征进行重构：

$$X' = \text{IDWT}(F_l, \hat{F}_h). \quad (6)$$

3.2. 螺旋感知特征采样

在对每个尺度特征进行纯化处理后，我们设计了一种螺旋感知特征采样（SFS）方法，能够自适应地从上层特征向下层特征获取目标相关特征，从而进一步降低融合

过程中的噪声干扰。为确保特征尺度的一致性，特征采样成为必然选择。为此，我们整合了IRST的强度分布特性，并在SFS模块中设计了螺旋采样模式以获取目标相关特征。

具体而言，对于每个LFP纯化特征图 $X'_i \in \mathbb{R}^{B \times C \times H_i \times W_i}$ ，我们旨在从NS-FPN的深层注入更高层次的语义特征 $Y_{i+1} \in \mathbb{R}^{B \times C \times H_{i+1} \times W_{i+1}}$ 。一种直接方法是使用DAT[37]随机采样 Y_{i+1} 特征以获取尺度一致的特征。然而，由于IRST维度低且规模小，随机采样无法有效捕捉目标区域与周围区域之间的差异。因此，我们引入初始化模式来约束采样过程。首先为 Y_{i+1} 生成参考点均匀网格 $p \in \mathbb{R}^{H_G \times W_G \times 2}$ ，其中 $H_G \times W_G$ 控制采样的空间稀疏性。随后，偏移量 $\hat{p}$ 通过结合基础螺旋分布 s 与一组可学习偏置 h 生成：

$$Y'_{i+1} = \phi(Y_{i+1}; p + \hat{p}), \quad \hat{p} = s + h, \quad (7)$$

其中 $\hat{p}$ 表示双线性插值， Y'_{i+1} 为采样特征。特别地，设计了螺旋模式以




图4. DAT与 SFS 采样过程可视化展示

表1. 使用 SFS 与其他方法在分割性能和计算成本方面的比较。

方法	交互次数 (IoU)	钹	衰减	浮点运算次数(G)
上样	68.82	94.56	9.79	6.80
DAT [37]	68.52	93.54	10.40	+1.24G
SFS (我方)	69.29	95.24	8.58	+1.16G

构造 s ，如图4所示。该模式针对极坐标系中的每个注意力头 $h \in [1, H]$ 进行如下公式化：

$$S(h, k) = l_s [\cos(\theta_{h,k}) \sin(\frac{\delta}{l} h, k)],$$

$$\theta_{h,k} = \frac{2\pi k}{P} + \frac{2\pi h}{H}, \quad l_s = l_0 + k \cdot \Delta l, \quad (8)$$

其中 $k \in [1, P]$ 表示采样点索引， l_0 为初始半径， δl 为相邻采样点之间的径向步长。

基于生成的参考点 p ，我们可以执行多头注意力机制来计算相似度并获取融合特征。通常，我们使用 LFP 净化后的特征 X_i' 作为查询向量，上层特征 Y_{i+1}' 作为键值对，其表示形式可为：

$$F_s = \text{Attn}(LN(X_i'), LN(Y_{i+1}')), \quad (9)$$

其中 $\text{Attn}(\cdot)$ 是交叉注意力[3]， $LN(\cdot)$ 是层归一化[1]。

最后，通过残差加法将 F_s 作用于 X_i' ，得到输出特征 Y_i ：

$$Y_i = X_i' + F_s. \quad (10)$$

3.3. SFS 模块为何有效？

由于原始 FPN 中采用上采样和逐像素相加的方式缺乏对 IRST 周围空间感知能力的处理能力，一种直接可行的方法是采用可变形注意力机制（DAT）[37]来增强

空间感知能力，同时确保计算效率。然而如表1所示，直接使用DAT并不能有效提升性能，反而会增加计算复杂度。主要原因在于IRST通常体积较小且占据紧凑且形状一致的区域，这使得稀疏注意力机制中的随机采样方法不适用。因此，我们提出螺旋感知特征采样方法，从两个维度有效缓解上述局限性：

① **螺旋状空间感知**。由于IRST强度具有高斯分布特征，我们明确限制采样位置以满足螺旋分布要求，如图4所示。这种结构设计确保网络能够感知IRST周围的精细特征，从而在与LFP协同抑制背景噪声干扰时获得更清晰的目标轮廓，具体效果如表1所示。

② **共享可学习偏移量**。如上文分析所示，IRST通常具有稳定的形态特征。因此，与传统方法为每个查询单独使用可学习偏移量不同，SFS模块采用跨查询共享的可学习偏移量集合。这种设计不仅提升了采样过程的稳定性，同时降低了计算复杂度，具体数据详见表1。

4. 实验

4.1. 数据集与评估指标

数据集。为评估NS-FPN的有效性，我们选择IRSTD-1k[33]和NUAA-SIRST[6]作为实验数据集。IRSTD-1k包含512 × 512尺寸的1000张真实红外图像，NUAA-SIRST则包含427张不同尺寸的红外图像。每个数据集均将80%的红外图像用于训练集，剩余20%作为测试集。

分割任务评估指标。在分割任务中，采用交并比（IoU）作为像素级指标来评估形状描述能力，并通过检测概率（ P_d ）和误报率（ F_a ）来评估定位性能。

检测任务评估指标。在检测任务中，平均精度（mAP）被用作主要评估指标，用于基于分类准确率和定位精度来衡量检测性能。具体而言， mAP_{50} 和 mAP_{75} 分别表示在固定IoU阈值0.50和0.75时的mAP，而mAP则是通过以0.05为步长从0.50到0.95的IoU阈值范围内计算mAP值的平均值。

4.2. 实施细节

所有实验均在NVIDIA GeForce RTX 4090显卡上进行。我们将NS-FPN集成到MSHNet[18]中用于分割任务，并采用YOLOv8n-p2进行目标检测。Adagrad

表2.基于 IRSTD -1k和 NUAA - SIRST 数据集的分割指标分析: LFP 与 SFS 模块消融效果

模块		IRSTD-1k			NUAA-SIRST		
LFP	SFS	相互交款 (IoU)	钹	衰减	相互交款 (IoU)	钹	衰减
✓	✓	67.04	91.16	13.06	76.04	99.08	12.42
		68.82	94.56	9.79	76.99	100.0	12.07
✓	✓	67.81	93.88	13.66	78.07	100.0	4.61
		69.29	95.24	8.58	78.75	100.0	1.60

表3. 在 IRSTD -1k数据集上进行不同尺度层级的 LFP。最佳结果以**粗体**标出。

不同尺度层 LFP				IRSTD-1k		
X_1	X_2	X_3	X_4	相互交款 (IoU)	钹	衰减
✓ ✓ ✓ ✓ ✓	✓ ✓ ✓ ✓ ✓	✓ ✓ ✓ ✓ ✓	✓ ✓ ✓ ✓ ✓	67.81	93.88	13.66
				67.72	94.56	6.15
				67.66	94.22	8.35
				68.45	94.22	12.98
				69.29	95.24	8.58

表4.基于 IRSTD -1k数据集的不同FPNs对比分析, 包含参数及计算成本。

方法	分割			检测		复杂性	
	语义分割 每日	全分辨率 每日	全分辨率 每日	mAP_{50}	mAP	$P(M)$	$F(G)$
FPN[16]	67.0	91.2	13.1	85.9	41.8	3.91	6.80
PANet[19]	68.9	93.5	6.7	85.0	41.5	+0.41	+1.41
BiFPN[22]	66.9	93.5	12.1	85.8	41.6	+0.39	+1.33
HSFPN[21]	66.7	94.9	18.1	85.1	41.0	+0.17	+0.98
我们的	69.2	95.2	8.5	86.3	42.1	+0.26	+1.16

优化器[9]采用初始学习率0.05进行训练。模型训练周期为500个epoch, 批量大小为16。在分割任务中, 输入图像首先被调整至256像素尺寸, 随后在训练过程中随机裁剪至224像素; 而在检测任务中, 输入图像则统一调整为640像素尺寸。

4.3. 消融研究

各组件消融实验。为评估NS- FPN 的有效性, 我们对 LFP 和 SFS 模块进行了消融实验。基线模型采用 MSHNet和YOLOv8n-p2结合 FPN, 结果如表2所示。单独应用 LFP 或 SFS 模块均可提升分割性能。具体而言, 将 FPN 中的 1×1 卷积层替换为 LFP 模块后, 各项指标均显著提升。在 IRSTD -1k数据集上, IoU 提升1.78%, P_d 提升3.40%, 而 F_a 下降3.27。同时使用 LFP 和 SFS 模块时效果最佳, 两个数据集上的 F_a 均实现显




图5. NS- FPN 中逐步添加 LFP 和 SFS 后 X_2 水平特征的可视化呈现。




图6. SFS 模块中 H (行)与 P (列)的消融结果热图(IoU 、 P_d 、 F_a)。

著提升。如图5所示, LFP 与 SFS 的组合能有效抑制背景噪声并增强目标特征。

不同尺度层的 LFP。我们采用所提出的 LFP 来替换 FPN 中不同尺度层的 1×1 卷积层。表3展示了在不同层(从 X_1 到 X_4)应用 LFP 模块的结果。我们观察到, 将 LFP 应用于大尺度层(X_1 , X_2)可显著降低 F_a 至6.15。相比之下, 小尺度层(X_3 , X_4)能捕捉更多语义上下文, 提升了 IoU 但伴随更高的 F_a 。当 LFP 应用于所有尺度层时, 可实现分割指标的最佳整体平衡。

超参数消融实验 H 与 P 在 SFS 中的应用。为确定 SFS 模块中 H 与 P 的最佳超参数组合, 我们在 IRSTD -1k数据集上通过改变头数 $H \{1, 2, 4, 8, 16, 32\}$ 和点数 $P \{3, 4, 5, 6\}$ 进行消融研究, 其中64的FPN通道维度应能被 H 整除。如图6所示, 适度增加 H 可适度提升性能, 但过高的 H 会导致每头部信息不足而性能下降。类似地, 适度增加 P 可改善 P_d , 而过大的 P 则会降低

表5. 与 IRSTD -1k和 NUA - SIRST 数据集上其他最先进方法的比较。分割结果通过 IoU (%)、 P_d (%)和 F_a (10^{-6}) 进行评估。检测结果通过 mAP_{50} (%), mAP_{75} (%)和 mAP (%) 进行评估。最佳结果以**加粗**标示, 第二名结果以下划线标示。

分割							
方法	类型	IRSTD-1k			NUAA-SIRST		
		$IoU \uparrow$	$P_d \uparrow$	衰减	$IoU \uparrow$	$P_d \uparrow$	$F_a \downarrow$
Top-Hat (2010) [2]最大值-中位数 (1999) [8]	过滤	10.06 7.00	75.11 65.21	1432 59.73	7.14 4.17	79.84 69.20	1012 55.33
WSLCM (2020) [12] TLLCM (2020) [12]	局部对比度	3.45 3.31	72.44 77.39	6619 6738	1.16 79.09	77.95 5899	5446 1.03
IPI (2013) [10] RIPT (2017) [4]	低秩	27.92 14.11	81.37 77.55	16.18 28.31	25.67 11.05	85.55 79.08	11.47 22.61
ACMNet (WACV 21) [6]ISNet (CVPR 22) [33]DNANet (TIP 22) [13]UIUNet (TIP 22) [23] HCFNet (ICME 24) [24]IRPruneDet (AAAI 24) [35]IRSAM (ECCV 24) [34]SCTransNet (TGRS 24) [31]SFCANet (TAES 25) [17]PConv (AAAI 25) [26]MSHNet (CVPR 24) [18]MSHNet + NS- FPN (本研究)	深度学习	59.23 62.88 65.71 65.06 64.26 64.54 64.65 68.64 66.68 67.08 67.16 69.29	93.27 92.59 91.84 91.16 92.86 91.74 90.57 91.84 92.89 92.18 93.88 95.24	65.28 27.92 17.61 12.68 23.91 16.04 16.61 11.92 12.69 11.92 15.03 8.58	70.77 74.16 74.31 72.69 72.74 75.12 71.44 77.09 78.46 76.25 74.60 78.75	93.08 97.99 98.17 <u>99.08</u> 98.17 98.61 92.66 98.17 97.24 <u>99.08</u> <u>99.08</u> 100.0	3.70 8.35 15.97 26.61 6.21 2.96 7.53 15.26 8.02 6.74 17.21 1.60
检测							
方法	IRSTD-1k			NUAA-SIRST			
	mAP_{50}	mAP_{75}	mAP	mAP_{50}	mAP_{75}	mAP	
EFLNet (TGRS 24) [25] DFLMF - ISTD (IPT 25) [14] PConv (AAAI 25) [26]YOLOv8n (2024) YOLOv8n + NS- FPN (我们的)	86.1 82.7 86.1 85.0 86.3	29.5 — 34.5 31.9 36.9	38.0 38.6 40.8 41.5 42.1	98.1 94.2 96.4 95.6 97.5	37.9 — 49.9 40.3 61.6	47.1 51.1 54.9 49.0 58.0	

引入更多计算量和误报。最后, 我们为 SFS 模块选择最优配置 $H=8$ 和 $P=4$, 所有指标均达到最佳性能。不同FPNs的消融实验。为证明NS- FPN 的优越性, 我们将其与代表性替代方案进行对比, 包括 FPN[16]、PANet [19]、BiFPN[22]和HS- FPN[21], 如表4所示。在分割任务中, 我们的方法获得最高 IoU (69.29%) 和 P_d (95.24%), 同时保持可接受的 F_a 。在检测任务中, NS- FPN 同样取得最佳 mAP_{50} (86.3%) 和 mAP (42.1%)。这些结果表明NS- FPN 是专为 IRSTDs 任务设计的有效插件。

4.4. 与 SOTA 方法的比较

定量比较。在分割任务中, 我们选取了六种经典方法和十一种最先进的深度学习方法 (包括若干基于频域模型), 在 IRSTD -1k和 NUA - SIRST 数据集上进行对比。如表5所示, Top-Hat[2]和 WSLCM[12]等传统方法因依赖手工构建的先验知识而表现有限。在基于

深度学习的方法中, 我们的方法在两个数据集上均取得最优评估指标: IRSTD -1k数据集上达到69.29% IoU 、95.24% P_d 和8.58 F_a ; NUA - SIRST 数据集上达到78.75% IoU 、100.0% P_d 和1.60 F_a , 在像素级精度和对象级可靠性方面展现出卓越性能。在检测任务中, 我们进一步在 IRSTD -1k和 NUA - SIRST 数据集上与四种最新 IRSTD 方法进行对比。表5显示, 我们的方法在 mAP_{50} , mAP_{75} 和 mAP 指标上优于既往方法。具体而言, 我们的方法在两个数据集上均取得最佳结果, 达到86.在 IRSTD -1k数据集上, mAP_{50} 为3%, mAP_{75} 为36.9%, mAP 为42.1%; 在 NUA - SIRST 数据集上, mAP_{50} 为97.5%, mAP_{75} 为61.6%, mAP 为58.0%。上述结果表明, 我们的NS- FPN 在红外场景下的小目标分割与检测任务中具有高效性, 能够在抑制背景噪声干扰的同时实现精准的目标定位。




图7.不同 SOTA 方法的可视化结果。红色、蓝色和黄色方框分别代表正确检测、漏检和误检。底部角落显示放大视图。

表6. NS- FPN 组件的分割性能、浮点运算次数（FLOPs）及参数对比。

LFP	SFS	相互欠款 (IoU)	钹	衰减	参数	浮点运算次数
		67.04	91.16	13.06	3.91M	6.80G
✓		68.82	94.56	9.79	+0.01M	+0.01G
	✓	67.81	93.88	13.66	+0.25M	+1.15G
✓	✓	69.29	95.24	8.58	+0.26M	+1.16G

视觉对比分析。图7展示了不同方法的局部视图对比结果。通过采用 NSFPN 技术，我们的方法显著降低了误报率（第一行），实现了更精准的目标形状分割效果（第三行），并能有效区分目标与复杂背景干扰（第四行），同时未遗漏微弱目标（第二行）。相比之下，传统方法常存在误报率高、漏检率大的问题，而其他基于深度学习的方法则容易产生模糊预测结果。上述实验结果充分证明，我们提出的NS- FPN 在增强判别特征和抑制干扰方面具有显著优势，即使在复杂背景干扰环境下仍能实现精准分割。

4.5. 模型复杂性分析

本文旨在通过引入一种轻量级但高效的 FPN 来抑制特征融合过程中的噪声干扰。如表4所示，NS- FPN 在保持较低计算复杂度的同时，展现出优于其他FPNs的分

割与检测性能，这验证了NS- FPN 的高效性。此外，我们还对NS- FPN 各组件的参数配置及计算复杂度进行了分析（见表6）。LFP 模块的参数配置与浮点运算量主要来源于少量卷积操作，其计算成本与原始 FPN 基本持平。尽管 SFS 模块采用的交叉注意力机制会增加浮点运算量，但相较于原始 FPN，NS- FPN 整体框架在可接受的计算成本下实现了显著性能提升。

5. 结论

本文提出了一种噪声抑制特征金字塔网络（NS- FPN）以提升IRSTDS性能。针对噪声干扰导致误报问题，我们引入了低频引导特征净化模块（LFP），通过滤除高频成分来抑制噪声特征。同时设计了螺旋感知特征采样模块（SFS），采用螺旋采样方式对多尺度特征进行融合处理。这两个模块在 FPN 框架中紧密耦合，有效提升了检测与分割性能。大量实验表明，我们的方法在客观指标和主观评价中均优于 SOTA 方法。我们相信NS- FPN 为现实应用中更稳健、实用的IRSTDS方法开辟了新路径。