

DCMM 变换器：医学影像中基于度数校正的混合隶属度注意力机制

程会民^{1*}、余晓伟^{2*}、吴淑珊³、方路阳³、曹超⁴、张静⁴、刘天明⁵、朱大江⁴、钟文轩³、马平³

¹波士顿大学生物统计学系

²密苏里科技大学计算机科学系

³乔治亚大学统计系

⁴美国德克萨斯大学阿灵顿分校计算机科学与工程系

⁵美国佐治亚大学计算机学院

摘要

医学影像中存在潜在的解剖学分组结构（如器官、组织及病理区域），而标准视觉变换器（ViTs）难以有效利用这些特征。尽管近期研究如SBM-Transformer试图通过随机二值掩码技术整合此类结构，但其存在不可微性、训练稳定性差以及无法建模复杂社区结构等局限。本文提出 DCMM-Transformer——一种新型医学影像分析视觉变换器架构，通过在自注意力机制中引入度数校正混合隶属度（DCMM）模型作为附加偏置项。与依赖乘法掩码和二值采样的传统方法不同，本方法以完全可微且可解释的方式引入社区结构和度数异质性。基于脑部、胸部、乳腺及眼部等多样化医学影像数据集的全面实验表明，该方法具有卓越的性能表现与泛化能力。此外，通过学习到的群体结构与结构化注意力调制机制，生成的注意力图谱不仅具有解剖学意义，还展现出语义一致性，显著提升了模型的可解释性。

引言

医学图像分析对疾病诊断、预后评估及临床决策具有关键作用（Varoquaux与Cheplygina 2022; Yu等 2023 c, 2024a, b）。视觉Transformer（ViTs）及其变体模型——如TransUNet（Chen等 2024）和Swin Transformer（Liu等 2021）——已取得业界领先水平。这些模型通过将图像分割为固定尺寸的小块（标记），并运用自注意力机制来建模不同解剖结构间的复杂长距离关联。通过捕捉此类依赖关系，ViTs在图像分类、分割及目标检测等任务中均展现出卓越性能（Hatamizadeh等 2022; Yu等 2023a）。

医学影像面临的挑战。尽管技术发展迅速，医学图像分析仍具有挑战性且尚未完全成熟

*这些作者的贡献度相同。

版权所有 © 2026, 人工智能促进协会（www.aaii.org）。保留所有权利。

这要求建筑设计必须针对医学数据的独特特性进行定制化设计（Huang等, 2025; 2024; Yu等, 2022a; Li-tjens 等, 2017; Yu 等, 2022b; Zhang 等, 2025; Yu 等, 2025）。医学影像在空间上被划分为不同的解剖区域，如肿瘤区域、健康组织和血管结构，这些区域在图像中形成具有意义的聚类（Esteve等, 2021; Yu 等, 2021; Chavoshnejad等, 2021）。来自相同解剖或病理区域的图像块往往具有相关性，共享对临床任务特别具有信息价值的特征。相反，不同区域的图像块（如肿瘤与健康组织对比，或跨器官对比）通常表现出差异化的潜在生物学特性，导致二者间的关联性较弱。

社区感知注意力机制的理论基础。这种社区特征驱动了社区感知注意力机制的研发，该机制促使模型聚焦解剖学或病理学上具有连贯性的区域内的交互关系（Wang等, 2019）。此类方法在检测细微模式方面具有显著优势：以肿瘤检测为例，单个肿瘤区域内的信号可能较弱或存在模糊性。通过整合同一社区内多个区域的信息，模型能够增强这些微弱信号，从而实现更连贯且精准的诊断评估（Ilse、Tomczak与Welling, 2018; Yu等, 2023b）。

标准视觉 Transformer 的局限性。然而，传统的基于Transformer的注意力机制并未考虑这种潜在的社区结构。传统注意力方法对所有标记进行统一处理，仅基于学习到的特征相似性计算权重，而忽略了解剖学上的分组特征（Vaswani等人, 2017; Dosovitskiy等人, 2021）。因此，模型有时会因特征空间中的表面相似性，而将注意力集中在临床意义上相距较远或无关联的区域。这种缺乏解剖学感知的缺陷可能导致模型遗漏临床重要区域、更容易受到噪声或伪影干扰，并使预测结果更难解读（Li等人, 2023b）。这些局限性凸显了开发能显式整合社区结构的Transformer模型的必要性（Li等人, 2023a）。

SBM-Transformer的局限性。近期研究探索了将显式社区结构融入注意力机制的方法。典型代表是SBM-Transformer（Cho等人，2022年），该模型通过在每个注意力头中集成混合隶属度随机块模型（SBM），实现对图像块间潜在社区的建模。为降低计算成本，SBM-Transformer采用基于SBM学习概率随机采样标记连接的二值注意力掩码。仅被掩码选中的标记对才能相互关注，从而形成稀疏注意力分布。然而这种二值掩码机制引入了不可微性问题，需要采用直通估计器等替代梯度方法，导致优化偏差和收敛不稳定（Cho等人，2022年）。此外，将概率连接强度简化为硬性二值决策会丢失标记间关系强度的有用信息，导致训练和推理过程中的方差增大。另一个局限性在于SBM-Transformer忽略了节点度数异质性特征。实践中，图像块在连接性与重要性方面表现出显著差异。例如，肿瘤核心区域常通过与众多其他区域相互作用而发挥局部枢纽作用，这种效应在均匀连接性假设下无法被捕捉。

提出的方法。为克服这些局限性，我们提出DCMM-Transformer方法，该方法将度校正混合隶属度（DCMM）模型整合至视觉图卷积网络（ViTs）中。DCMM-Transformer的架构如图1所示。具体而言，我们采用DCMM框架建模图像块间的潜在社区结构，该框架既能捕捉社区成员间的重叠关系，又能反映度分布的异质性。DCMM模块生成学习概率矩阵，其中每个元素反映图像块对之间交互的可能性，该概率基于其共享的社区隶属度及个体连接性特征。本方法将学习概率矩阵直接作为加性偏置项叠加到注意力logits上，从而规避随机采样与二值离散化过程。这种基于社区特征的偏置机制有助于模型整合相关图像块（如同一肿瘤区域内的图像块）的微弱或分布式信号，从而提升对临床重要模式的检测能力——若对所有图像块采用统一处理方式，这些模式可能被忽略。

优势。DCMM-Transformer具有三大核心优势：(1)无失真的结构引导：与采用乘法掩码来实现稀疏性并可能因过度抑制弱连接或不均衡放大其他连接而扭曲语义关系的SBM-Transformer（Cho等人，2022）不同，我们的加性偏置在保持数据驱动洞察力的同时实现了结构引导。

(2) 训练稳定性：添加机制能保持梯度稳定性和归一化处理，有效避免梯度消失问题。(3) 建模能力增强：DCMM模型同时捕捉度数异质性和混合隶属关系，这是标准自编码器模型（SBMs）所不具备的能力。我们在五个医学图像分类任务中进行了全面评估，结果显示其性能较标准视觉Transformer（ViT）及其变体平均提升3.7%，同时提升了临床应用的可解释性。消融实验进一步表明，排除度数异质性会导致性能下降2.3%。




图1: DCMM-Transformer模型概述。该DCMM模型在图像块之间建立潜在社区结构，将其分组为若干区块（如蓝色、红色和绿色区块1-3），并为这些区块内部及区块间的交互关系分配概率权重。随后将这种基于社区的偏置信息叠加到标准注意力logits上。

相关工作

本节中，我们介绍了两个相关研究领域：自编码器模型（SBMs）与视觉变换器（Vision Transformers）。

SBM相关研究进展

SBM.随机块模型（Holland、Laskey和Leinhardt 1983；Cheng等人2018；Liu、Cheng和Zhang 2019）是具有社区结构网络的基础概率模型。在SBM中，每个节点被分配到 L 个潜在社区（或块）之一，任意两个节点之间边的概率仅取决于它们的社区归属。设 $A \in (0,1)^{n \times n}$ 表示网络邻接矩阵， $z_i \in 1, \dots, L$ 表示节点 i 的社区标签。块矩阵 $B \in (0,1)^{L \times L}$ 用于指定社区间连接概率，使得边的采样遵循独立分布

$$\Pr(A_{ij} = 1) = B_{z_i z_j}, \quad (1)$$

其中 $B_{z_i z_j}$ 表示节点 i 与节点 j 之间存在边的概率。虽然SBM为社区结构建模提供了简单有效的框架，但它假设同一区块内所有节点的期望度数相同，而现实网络中往往存在度分布异质性，这一假设常被打破。

度数 Corrected SBM。为解决SBM中同质度假设的局限性，度数 Corrected Stochastic Block Model（DC-SBM）（Karrer和Newman 2011）引入了节点特定度参数。在DC-SBM框架下，节点 i 与 j 之间边的概率不仅取决于它们的社区归属，还取决于控制预期节点度的个体倾向参数 $\theta_i > 0$ 和 $\theta_j > 0$ ，从而能够对具有异质度的网络进行更现实的建模：

$$\text{概率}(A_{ij}=1) = \theta_i \theta_j B_{z_i z_j}. \quad (2)$$

混合成员结构SBM。混合成员结构SBM（MMSBM）（Airoldi等人，2008年）通过替换原有模型中的参数，将经典SBM扩展至处理重叠社区问题。

具有软隶属向量的硬社区分配。每个节点 i 具有一个概率隶属向量： $\pi_i = (\pi_i(1), \dots, \pi_i(L))^T \in [0, 1]^L$ ，其中 $\sum_{\ell=1}^L \pi_i(\ell) = 1$ 。节点 i 与 j 之间存在边的概率为

$$\Pr(A_{ij}=1) = \sum_{\ell=1}^L \sum_{\ell'=1}^L \pi_i(\ell) \pi_j(\ell') B_{\ell\ell'} = \pi_i^T B \pi_j. \quad (3)$$

当每个 π_i 均为标准基向量（即节点仅属于一个社区）时，方程(3)可简化为经典SBM中的方程(1)。

度数校正混合隶属度SBM模型（DCMM）。该最通用模型融合了混合隶属度与度数异质性特征（Jin、Ke和Luo，2024年）：

$$\Pr(A_{ij}=1) = \theta_i \theta_j \pi_i^T B \pi_j. \quad (4)$$

先前模型是DCMM的特例：将 $\theta_i=1$ 可恢复MMSBM，而同时取 $\theta_i=1$ 和one-hot π_i 则得到经典SBM。

变压器相关研究进展

视觉Transformer与注意力机制。ViTs通过将图像视为序列标记进行处理，类似于语言模型处理文本的方式。首先，输入图像被分割为 n 个非重叠的二维扁平化块（标记），形成矩阵 $X \in \mathbb{R}^{n \times d}$ ，其中 d 表示每个块嵌入的维度。ViT的核心是自注意力机制，使模型能够捕捉所有块对之间的依赖关系与交互作用。其次，在每个注意力头内部，模型通过可学习权重矩阵 $Q=XW^Q$ 、 $K=XW^K$ 、 $V=XW^V$ ，将标记投影到查询（ Q ）、键（ K ）和值（ V ）表示中，计算标记间的成对关系，其中 $W^Q, W^K, W^V \in \mathbb{R}^{d \times d_h}$ ，且 d_h 为注意力头维度。注意力分数随后通过标准化点积计算得出 $\frac{QK^T}{\sqrt{d_h}}$ ，随后进行行级softmax归一化以获得权重 $\sigma\left(\frac{QK^T}{\sqrt{d_h}}\right)$ ，通过softmax函数处理。最终输出结果为各数值的加权和：

$$\text{Attn}(Q, K, V) = \sigma\left(\frac{QK^T}{\sqrt{d_h}}\right) V.$$

该过程使每个图像块能够根据其学习到的相似性关注所有其他图像块，从而使模型能够捕捉整个图像中的长程依赖关系。

SBM-Transformer。SBM-Transformer（Cho等人，2022）直接用由MMSBM引导的稀疏可学习替代方案取代了密集注意力机制，主要目的是降低Transformer的计算负担。具体而言，标记 i 与 j 之间的连接probability p_{ij} 由公式(3)给出，其中 π 和 B 是从神经网络中学习得到的参数。随后通过伯努利分布 $M_{ij} \sim \text{Bernoulli}(p_{ij})$ 采样生成二元注意力掩码 M_{ij} 。该掩码通过掩码注意力机制应用于注意力机制：

$$\text{Attn}_{\text{mask}}(Q, K, V, M) = \sigma_M\left(M \odot \frac{QK^T}{\sqrt{d_h}}\right) V,$$

其中 $\odot$ 表示逐元素乘法， $\sigma_M(\cdot)$ 是掩码softmax函数，仅对 M 每一行中的非零元素进行归一化处理。

尽管SBM-Transformer降低了计算成本，但仍存在以下局限性：(1)非-

可微性与优化不稳定性：二值采样具有不可微性，因为采样函数相对于 p_{ij} 缺乏连续导数。这破坏了梯度流特性，需要采用直通估计器等替代方法，但该替代方法会引入偏差和高方差。(2)硬阈值化导致的信息损失：二值化会丢弃 p_{ij} 中的概率信息，而这些信息可编码细微关联。例如， $p_{ij}=0.99$ 与 $p_{ij}=0.1$ 可能均导致 $M_{ij}=1$ ，但其连接强度存在显著差异。

(3)MMSBM中缺乏度异质性：MMSBM未能捕捉到度异质性这一真实网络的特征，包括图像块图中枢纽块（如肿瘤核心区域）具有广泛连接性，而外围区域则缺乏这种连接性的典型特征。

带有加性偏置的Transformer。另一类相关研究通过显式偏置项增强注意力机制，这些偏置项用于编码空间或结构关系。例如，ACC-ViT（Ibtehaz等人，2024）引入了多扩张率无孔注意力机制： $\text{Attn}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}} + b\right)V$ ，其中 b 表示分支特异性相对位置偏置，输出结果通过门控聚合进行融合。Swin Transformer（Liu等人，2021）通过限制注意力机制仅作用于局部块并引入可学习的相对位置偏置，从而获得显著性能提升。类似地，MaxViT（Tu等人，2022）采用多轴自注意力机制超越传统方法。然而这些方法均未考虑社区结构特征。

综上所述，尽管先前研究已证实社区感知注意力机制与加性偏置方法具有应用潜力，但其局限性依然存在：例如基于SBM的掩码方法不具备可微分性，而标准偏置项则未考虑潜在的社区结构特征。

DCMM 变换器

为解决这些局限性，DCMM-Transformer在DCMM下通过连接概率矩阵对标准Transformer注意力logits进行增强，使模型能够以完全可微的方式同时学习软社区分配和节点特异性中心性。

DCMM 变换器概述

DCMM-Transformer的核心创新在于采用了一种新颖的自注意力logits机制，通过添加一个学习到的社区结构矩阵 $P \in \mathbb{R}^{n \times n}$ 来实现，该矩阵是在DCMM下生成的：

$$\text{Attn}_{\text{DCMM}}(Q, K, V, P) = \sigma\left(\frac{QK^T}{\sqrt{d_h}} + \lambda P\right)V, \quad (5)$$

其中 λ 是一个可调超参数，用于控制社区结构的贡献度。当 $\lambda=0$ 时，模型退化为标准Transformer模型；随着 λ 的增大，社区结构逐渐占据主导地位。




图2：集成于Vision Transformers自注意力模块中的DCMM-Transformer机制示意图。针对每个标记，从查询表示中构建软分组隶属向量和度量标量，基于可学习的组间亲和力构建结构化注意力偏置。该偏置被叠加到标准注意力分数上，用于在softmax激活前对其进行调节。

图2展示了DCMM-Transformer模型。DCMM偏置 P 通过一系列专门网络和操作构建于图示左侧，这些操作主要作用于 Q 。具体而言，每个标记（图像块） i 由两个并行神经网络处理：隶属度网络模块为每个块计算软社区隶属向量 π_i ，表示其与各潜在社区的关联度；度校正网络模块生成节点特定度参数 θ_i ，捕捉各块的相对中心性或重要性；混合块网络模块引入 L 个可训练的潜在社区聚类嵌入向量。

加性偏差的理论依据。我们在公式(5)中选择加性偏差而非乘性偏差，原因如下：**(1)温和增强 vs. 指数缩放。**当DCMM偏差 P 被加到logits上时，经过softmax后的效果相当于乘以 $\exp(\lambda P_{ij})$ ，其中 P_{ij} 始终介于0到1之间。这意味着社区先验最多只能将对对应注意力权重温和和提升 e^λ 倍（当 $P_{ij}=1$ 时），或使其基本保持不变（当 P_{ij} 接近0时），且不会抹除原始特征相似性中的信息。相比之下，乘性偏差会在指数化前直接对logits进行 P_{ij} 缩放，导致任何小于1的 P_{ij} 值都会大幅压缩有效logit值，从而产生近乎均匀或无信息量的注意力模式，致使模型忽略有意义的关系。

(2) 训练稳定性。设 $l = \frac{QK^T}{\sqrt{d_h}}$ 对于加性偏差，softmax梯度为： $\frac{\partial \sigma(l + \lambda P)}{\partial l} = \text{diag}(\sigma(l + \lambda P)) - \sigma(l + \lambda P)\sigma(l + \lambda P)^T$ 。这种标准softmax雅可比矩阵无论偏置值 λP 如何都保持良好条件性，因为梯度结构保持不变——仅softmax输出发生偏移。然而对于乘性偏置 $P \odot l$ ，梯度变为： $\frac{\partial \sigma(P \odot l)}{\partial l} = \text{diag}(P) \cdot [\text{diag}(\sigma(P \odot l)) - \sigma(P \odot l)\sigma(P \odot l)^T]$ 由于 $\text{diag}(P)$ 通过相应的 $P_{ij} \in [0, 1]$ 对每个梯度分量进行缩放，这可能导致低 P_{ij} 时出现梯度消失问题，这种情况在稀疏网络中非常常见。

DCMM 变换器操作规程

下文将详细说明DCMM-Transformer如何在模型流程中构建并更新社区结构矩阵 P 。

(1) 聚类嵌入初始化：为表征潜在社区，我们引入 L 可训练聚类嵌入 $C \in \mathbb{R}^{L \times d_l}$ 。这些聚类嵌入在注意力头的表征空间中参数化了每个社区的特征。

(2) 区块连接概率。为建模社区间交互概率，我们构建了一个非负区块连接概率矩阵 $B \in (0, 1)^{L \times L}$ 。每个元素 B_{ij} 表示社区 i 与社区 j 之间的连接概率。矩阵 B 的对角线元素表示社区内连接概率，非对角线元素则代表社区间连接概率。我们通过对内积 CC^T 应用行向softmax函数来获得 B ，其中 C 为社区嵌入向量。

(3) 软性社区隶属度：对于每个标记 i ，我们构建其软性社区隶属度向量 $\pi_i \in [0, 1]^L$ ，其中每个元素 π_{ij} 表示标记 i 归属于社区 j 的强度。具体而言， π_i 通过以下方式获得：

$$q \sim i = \text{MLP}(qi), \pi_i = \text{Sigmoid}(q \sim i C^T), \quad (6)$$

其中MLP是采用ReLU激活函数的双层多层感知器（MLP），用于将查询映射至社区空间。

(4) 节点特异性度数校正：为应对标记符度数分布的异质性，我们为每个标记符引入了节点特异性度参数，

$$\theta_i = \text{Sigmoid}(W_\theta qi)$$

其中 $W_\theta \in \mathbb{R}^{1 \times d}$ 为学习参数。

(5) 构建连接概率。将所有学习到的组件相结合后，社区结构矩阵的每个条目为：

$$p_{ij} = \theta_i \theta_j \pi_i^T B \pi_j \quad (7)$$

表1: 我们的 DCMM -Transformer与基线VisionTransformer变体在五个医学影像数据集上的分类准确率对比 (%)。加粗数值表示各数据集的最高准确率。

方法	胸部X线摄影	SIIMACR	乳房内	海军情报局长助理	眼病	平均值
维生素T	92.3	86.9	79.7	66.7	92.5	83.6
SBM-变压器	95.8	85.8	78.4	64.2	91.3	83.1
脱铁素	95.8	86.8	83.8	65.4	91.7	84.5
ConViT	93.6	79.6	81.1	71.6	92.4	83.7
斯温变压器	95.0	87.6	84.8	65.4	92.9	85.1
马克斯维特	94.5	86.4	83.3	71.7	93.2	85.8
DCMM 变换器	96.0	88.2	85.1	74.1	93.3	87.3

当 P 构建完成后, DCMMM 多头自注意力机制 (MSA_{DCMM}) 如下所示:

$MSA_{DCMM}(Q, K, V, P) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$, 其中每个注意力头定义为 $\text{head}_i = \text{Attn}_{DCMM}(QW_i^Q, KW_i^K, VW_i^V, P)$ 。可学习参数矩阵 W_i^Q, W_i^K, W_i^V 是各子空间 (头) 中的投影, 而 W^O 是所有子空间的投影。

多头注意力机制有助于模型在不同位置联合聚合来自不同表征子空间的信息。

学习目标与损失函数。为提升模型的可解释性并促使模型为每个标记学习独特且具有意义的社区归属分配, 我们在软社区隶属向量上引入了熵正则化项。具体而言, 熵损失 $\mathcal{L}_{\text{entro}}$ 会对均匀分布 (高熵) 的隶属关系进行惩罚, 从而促进更精确、更具置信度的分配结果——即每个标记明确归属于特定社区集合。从数学角度而言, 社区分配损失的熵值计算公式为:

$$\mathcal{L}_{\text{entro}} = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^L \pi_{ij} \log(\max(\pi_{ij}, \epsilon))$$

1], (8) 其中 ϵ 是一个用于防止对零取对数的小常数。

总损失为:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{task}} + \alpha \mathcal{L}_{\text{entro}}, \quad (9)$$

其中 $\mathcal{L}_{\text{task}}$ 表示主要任务损失函数 (例如医学图像分类中的交叉熵), α 是用于平衡熵正则化的超参数。所有模型参数 (包括聚类嵌入向量、隶属度投影、度校正项及 Transformer 权重) 均采用随机梯度下降法进行端到端联合优化。

实验实验设置

数据集。我们采用所提出的 DCMM -Transformer 模型进行图像分类任务评估, 选取了以下五个多样化且具有代表性的医学影像数据集: 胸部X光片 (ChestX-ray)、SIIM -ACR、INbreast、ADNI 和 EyeDisease, 这些数据集分别涵盖不同解剖结构和成像模态。

(1) **胸部X光片:** 胸部X光片数据集 (Wang 等人, 2017) 包含大规模胸部X光图像。本研究重点关注两大类图像 (总计5,856张): 肺炎与正常影像。(2) **SIIM -ACR:** siimacr数据集 (Stephens, 2019) 包含1,250张标注放射影像, 分类为正常肺或塌陷肺。(3) **INbreast:** INbreast数据库 (Moreira 等人, 2012) 由葡萄牙波尔图某乳腺中心采集的6,154张乳腺X线摄影图像组成, 每张图像标注有恶性、良性及正常三种分类标签之一。(4) **ADNI:** 采用公开可用的阿尔茨海默病神经影像学计划 (ADNI) 数据集 (Yu 等人, 2023c) 中基于MRI扫描提取的结构连接性 (SC) 矩阵。最终数据集包含282名认知正常 (CN) 受试者和149名轻度认知障碍 (MCI) 受试者。(5) **眼病:** 眼病数据集 (Zanlorensi 等人, 2022) 包含约4,000张高分辨率视网膜 (眼底) 图像, 数据整合自多个公开来源。每张图像均标注为以下四类之一: 正常、糖尿病视网膜病变 (DR)、白内障及青光眼, 每类图像数量约为1,000张。

基线模型。我们与六种最先进的视觉Transformer (ViT) 基线模型进行对比: ViT (Dosovitskiy 等人, 2021)、DeiT (Touvron 等人, 2021)、Swin Transformer (Liu 等人, 2021)、MaxViT (Tu 等人, 2022)、ConViT (d'Ascoli 等人, 2021) 以及SBMTransformer (Cho 等人, 2022)。这些模型涵盖了广泛的设计理念, 包括标准Transformer架构 (ViT、DeiT)、分层式与局部感知注意力机制 (Swin、MaxViT、ConViT), 以及显式社区结构建模方法 (SBM-Transformer)。这种模型选择确保了评估结果的全面性。

训练细节。由于数据集规模介于中等至较小级别, 我们在ViT-Small (ViT-S) 上构建 DCMM -Transformer 模型, 并使用预训练权重进行初始化 (Dosovitskiy 等人, 2021)。为确保公平比较, 所有基线模型均采用预训练权重的小型变体。我们使用AdamW优化器, 训练批次大小为16, 总训练轮次为100轮。学习率从0线性递增至0.0005后采用余弦衰减方案。其他训练超参数 (如丢弃率) 在所有实验和方法中保持一致以确保可比性。我们的 DCMM -Transformer 引入三个特定超参数: 熵正则化权重 α 、社区偏置强度 λ 以及社区数量 L 。在

在网格搜索中，我们将超参数设置为 $\alpha=0.1$ 、 $\lambda=10$ 和 $K=100$ 。这些数值作为 DCMM -Transformer的默认值，但所有三个超参数均可通过交叉验证进一步优化。所有实验均在 NVIDIA H100 GPU上进行。

实验结果

表1展示了五个数据集上的分类准确率。DCMM -Transformer在所有数据集上均持续优于所有基线模型，平均准确率达到87.3%，以显著优势超越次优方法（MaxViT，85.8%）。值得注意的是，DCMM 在ADNI数据集上展现出最强的性能提升（74.1%），这凸显了其捕捉脑连接图中细微结构变化的能力——这一标准视觉Transformer表现欠佳的挑战性任务。该模型在胸部X光（96.0%）和 SIIM -ACR（88.2%）数据集上同样达到前沿水平，证明其对具有多样化病理特征的二维放射影像具有高效处理能力。这些结果验证了所提出的度数校正混合隶属注意力机制在医学图像分类任务中提升表征学习能力的有效性。

需要指出的是，在此场景下SBM-Transformer的表现相对标准基线模型有所逊色。这可能是因为SBM-Transformer最初设计时旨在促进稀疏性并降低自然语言处理任务中的计算成本，而非用于建模医学图像中存在的细微空间结构与解剖学特征。相比之下，DCMM -Transformer则专门针对医学图像块的空间一致性及类社区组织结构进行设计。此外，在临床实践中，模型性能与可解释性通常优先于计算成本，这进一步凸显了我们方法的实际价值。这些结果验证了所提出的度数校正混合隶属注意力机制在提升医学图像分类表征学习效果方面的有效性。

可解释性

除了提升分类准确率外，提出的 DCMM -Transformer机制还显著增强了视觉Transformer（ViT）在医学影像任务中的可解释性。为评估可解释性，我们可视化了DCMM -Transformer生成的注意力图谱以及标准注意力机制在这些数据集上的表现。图3展示了五个医学数据集上的代表性结果。图中每行对应特定诊断类别（如INbreast数据集上的恶性、良性或正常）。每个类别展示两个代表性图像样本：首列呈现原始输入图像，随后是标准ViT生成的注意力热图，最后是 DCMM -Transformer生成的注意力图谱。以下观察示例充分证明 DCMM -Transformer在临床可解释性方面具有显著优势。

(1) 乳腺X线摄影检查：在恶性病例中，DCMM -Transformer注意力图呈现高度集中分布




图3：标准Transformer与所提出的 DCMM -Transformer（图中缩写为 DCMM -TF）在五个数据集上的注意力图可视化结果。左列显示原始输入图像，中列展示标准Transformer的注意力图，右列呈现 DCMM -Transformer的注意力图。每个类别均随机选取两名受试者进行展示。

围绕致密、带刺状肿块进行处理，这些肿块是恶性肿瘤的经典放射学指征，可实现精确定位，同时将对邻近非恶性组织的辐射外渗降至最低。

表2: 基于五个医学影像数据集的 DCMM -Transformer关键组件消融效果研究。无 $\mathcal{L}_{\text{entro}}$: 未使用结构约束损失; w/o DC: 未使用度校正模块; w/o MM: 未使用混合隶属度模块。

方法	胸部X线摄影	SIIMARC	乳房内	海军总医院局长助理	眼病	平均值
DCMM 变换器	96.0	88.2	85.1	74.1	93.3	87.3
无 $\mathcal{L}_{\text{entro}}$	95.2	84.2	83.8	66.7	92.3	84.4
w/o DC	94.9	86.9	83.8	66.7	92.9	85.0
w/o MM	95.6	87.5	81.8	65.4	93.0	84.7




图4: 社区数量对五个医学图像数据集分类性能的影响。报告了每种设置下三次独立运行的平均分类准确率及标准差。

病理组织。相比之下，ViT的注意力分布较为分散，常覆盖乳房的广泛区域，包括正常纤维腺体组织甚至胸肌，这降低了临床诊断的清晰度。对于良性及正常INbreast病例，DCMM -Transformer仍能生成与腺体组织结构高度吻合的注意力图，充分尊重自然解剖学边界。

(2) SIIM -ACR胸部X光检查：对于肺萎陷（气胸）病例，DCMM -Transformer模型会将注意力集中于肺外侧区和肺尖区——这些区域正是放射科医师寻找胸膜线及周边肺纹理缺失的关键部位，而后者正是气胸的重要诊断标志。特别值得注意的是，该模型的注意力分布与可见胸膜边缘及相邻透亮区域高度吻合，这对精准诊断至关重要。相比之下，ViT模型的注意力分布则呈现模糊云状覆盖整个肺野，对病灶定位缺乏具体指引。在常规胸部X光检查中，DCMM -Transformer通常将关注范围限定于肺野内区域，同时避免涉及膈肌和胸壁等无关解剖结构。

消融术与敏感性分析

消融实验。我们通过全面消融研究评估了DCMM -Transformer核心组件及熵惩罚项对五个医学影像数据集模型性能的影响。通过逐一移除各组件以隔离其单独效应，结果汇总于表2。具体而言，剔除熵损失项导致平均性能下降幅度最大（从87.3%降至84.4%），这凸显了其在促进可靠且可解释的社区划分中的关键作用。移除度数校正或混合隶属度项同样会降低准确率（分别降至85.0%和84.7%），这进一步证明了同时建模节点连接异质性与社区结构重叠性的价值。

敏感性分析。我们的敏感性分析表明，DCMM -

Transformer模型在多种超参数设置下均展现出卓越的稳定性。其中，社区数量具有关键影响，因其会直接或间接导致DCMM偏差。为此，我们进一步探究了不同社区数量下的模型性能表现。如图4所示，当 L 参数在80至180范围内变化时，分类准确率始终保持稳定，尤其在INbreast、EyeDisease和ChestXray数据集上表现突出。这表明该模型无需对参数进行精细调校，其广泛适用性在实际医疗应用中具有显著优势。

结论

在本研究中，我们提出了一种名为DCMM -Transformer的新型视觉Transformer架构，该架构将DCMM社区结构整合至注意力机制中。通过直接从查询表征中学习软群体隶属度和度量标量，并通过加权偏置将其融入注意力机制，DCMMTransformer使模型能够聚焦于医学图像中语义连贯且具有临床相关性的区域。该方法不仅提升了分类准确率，还增强了模型的可解释性。基于多样化医学影像数据集的大量实验表明，DCMM -Transformer始终优于强Transformer基线模型，而消融实验则验证了度量校正模块、混合隶属度模块及熵正则化模块的独立贡献。

致谢

本研究部分由美国国家自然科学基金会（NSF）资助，项目编号包括DMS -1903226、DMS -1925066、DMS -2124493、DMS -2311297、DMS -2319279、DMS -2318809；同时获得美国国立卫生研究院（NIH）资助，项目编号为R01GM152814。本文中表达的所有观点、研究结果、结论或建议均属作者个人立场，未必反映NSF或NIH的官方观点。