

ORSIFlow: 基于显著性引导的校正流用于光学遥感显著目标检测

陈浩静^{1*}、李宇通^{2*}、刘志航¹、谭涛¹、边浩宇¹、马秋菊^{3✉}

¹中国电子科技大学, 成都, 中国

²中国海口海南大学

³中国矿业大学(北京), 中国北京

ch3n.512@gmail.com, liyutong@hainanu.edu.cn,

27269087111zh@gmail.com, 2025091202018@std.uestc.edu.cn

haoyubian04@gmail.com, ma200609@126.com

摘要——光学遥感图像显著目标检测 (ORSI-SOD) 仍面临诸多挑战, 主要源于复杂背景、低对比度、不规则物体形状及尺度差异显著等问题。现有判别方法直接回归显著性图, 而近期基于扩散的生成方法则存在随机采样和高计算成本的缺陷。本文提出ORSIFlow框架, 这是一种基于显著性引导的校正流方法, 将 ORSI-SOD问题重构为确定性潜在流生成任务。ORSIFlow通过冻结变分自编码器构建的紧凑潜在空间实现显著性掩码生成, 仅需少量步骤即可完成高效推理。为增强显著性感知能力, 我们设计了用于全局语义判别的显著特征判别器和用于边界精化的显著特征校准器。多项公开基准实验表明, ORSIFlow在显著提升效率的同时实现了业界领先性能。代码库地址:

<https://github.com/Ch3nSir/ORSIFlow>。

索引词——显著目标检测、光学遥感图像、流匹配

1. 引言

显著目标检测 (SOD) 旨在识别场景中最显著的视觉目标, 已在多个领域得到广泛应用[1]–[3]。随着光学遥感影像 (ORSIs) 在地理、农业及安防监控等领域的日益普及, 光学遥感影像显著目标检测 (ORSI-SOD) 正引发越来越多的研究关注。

目标区域分割 (ORSIs) 通常通过高空传感器获取, 其背景往往复杂且杂乱无章——在纹理、色彩或结构模式方面, 显著目标与周围环境具有高度视觉相似性[4]–[6]。这些挑战因物体拓扑结构不规则 (如蜿蜒河流与崎岖海岸线)、目标与背景对比度低、尺度变化极端以及车辆等密集小型结构而进一步加剧。现有大多数 ORSI 目标分割方法采用判别式学习范式, 直接从输入图像预测显著性图。例如, 李等人 [7] 提出的LVNet采用嵌套架构和双流金字塔结构以实现多层次整合




图1。左图展示了三种数据集上 $S\alpha$ 的性能表现, 右图则将我们的方法与先前最先进的方法进行对比。红色方框表示分割误差。

特征。Li等人 [8] 将 ORSI-SOD的全局上下文信息整合到Transformer模型中。为提升Transformer模型的性能, Zhou等人 [9] 整合了边缘感知注意力机制及Li等的研究成果 [10] 协调相邻特征层级之间的上下文信息。此外, Gu等人 [11] 引入特征学习技术以高效聚合细粒度特征与语义特征, 而Di等人 [12] 采用自适应加权策略进行多尺度特征聚合。

近期研究探索了将显著性检测视为掩码生成问题的生成式模型。例如, Han等人 [13] 该研究将扩散模型引入Orsisod框架, 并通过迭代优化噪声掩膜取得了令人鼓舞的成果。然而, 扩散模型通常依赖像素空间中的随机化与曲面去噪轨迹, 需要大量采样步骤, 这限制了推理效率。如图1所示, 此类随机生成方法仍难以保留精细结构和小型显著目标, 导致边界断裂或背景干扰问题。此外, 显著性掩膜呈现相对结构化且低熵的分布特征, 表明采用更具可控性和确定性的生成过程可能更为合适。这一发现促使我们从流场理论视角重新审视Orsisod框架。

本文提出ORSIFlow算法, 将 ORSI-SOD问题重新表述为显著性引导的潜在流匹配问题。该算法不直接在像素空间进行生成, 而是通过变分自编码器构建的紧凑潜在空间来生成掩码, 从而显著提升效率。

* 等额供款。

✉ 通讯作者。




图2.所提方法的整体架构。SFCN 通过 SFD 和SFC模块提取多尺度条件特征，而 LSFN 学习确定性速度场，将高斯分布转换为 VAE 潜在空间中的显著性图。

降低计算复杂度。基于这种潜在表征，修正流模型通过学习噪声与显著性掩码之间的确定性近似线性转换关系，仅需少量推理步骤即可实现高质量预测。此外，我们通过显著特征判别器（SFD）和显著特征校准器（SFC）引入显式显著性引导机制。该 SFD 通过通道级推理构建动态图拓扑结构以表征全局语义依赖关系，同时SFC采用双分支门控机制，通过自适应特征调制动态整合局部与上下文信息。在多个公开 ORSI -SOD基准集上的大量实验表明，ORSIFlow在显著降低计算成本的同时实现卓越性能表现，充分验证了所提方法的有效性。

我们的贡献总结如下：

- 我们提出ORSIFlow，一种基于显著性引导的校正流框架，其通过显著性掩码生成而非直接判别性预测来实现目标检测。
- 我们在由冻结变分自编码器构建的紧凑潜在空间中生成显著性掩膜，并采用校正流将噪声映射至掩膜，从而实现稳定训练及高效推理（仅需少量步骤）。
- 我们设计了两个专用引导模块以提升生成质量：显著特征判别器（SFD）能有效消除语义歧义以保持全局

一致性，显著特征校准器（SFC）则可确保对尺度变化极端的物体进行精确边界划分。

- 针对多个公开 ORSI -SOD基准集开展的大量实验验证了ORSIFlow的有效性。

II.相关工作

ORSI -SOD. 早期 ORSI -SOD方法主要依赖卷积神经网络（CNN），通过多尺度特征聚合和嵌套架构实现进展[7]。随着自注意力机制的兴起，研究者引入了Transformer和Mamba架构模块以捕捉长距离依赖关系和全局上下文[8] [4]。

[14]近期，诸如扩散模型等生成式方法应运而生，能够通过迭代过程从噪声中优化掩码[15]

[13]然而，这些方法要么缺乏明确的渐进式优化机制，要么存在像素空间扩散算法计算成本过高且稳定性差的缺陷，在复杂遥感场景中往往难以在边界保留与高效推理之间取得平衡。

基于流的生成学习。该方法利用连续归一化流（CNFs）从简单先验分布建模概率流至目标数据分布。Lipman等人 [16] 针对条件神经网络（CNFs）引入了流动匹配机制，通过沿固定条件概率路径学习向量场，实现了无需模拟训练即可泛化扩散路径的能力。与依赖随机过程的扩散模型相比

像素空间去噪会带来高昂的采样成本，而Rectified Flow [17]通过沿直线轨迹学习速度场，简化了推理过程并实现了少步采样。ORSI，这种确定性建模方法能更好地保持显著物体的结构一致性[18]。[19]。

III. METHODOLOGY

A. 总体体系结构

如图2所示，我们的整体架构由显著特征条件网络和潜在空间流网络构成。显著特征条件网络首先采用四阶段PVTv2-b4层级结构，通过整合RGB特征与掩码表示，逐步提取多尺度融合特征。基于这些融合特征，显著特征判别器进行全局语义关系建模，而显著特征校准器则通过修正局部细节来优化精细结构和边界质量，最终生成显著特征。随后，潜在空间流网络以显著特征作为条件输入，在由VAE压缩的低维潜在空间中进行迭代更新，最终生成预测显著性图。

B. 显著特征条件网络

我们设计了显著特征条件网络（SFCN），如图2(A)所示，基于四阶段金字塔Transformer主干结构来提取层次化条件特征。每个阶段遵循PVT风格架构，其中空间分辨率逐步降低，而语义抽象层次逐渐提升。给定输入RGB图像 I 和带噪声的显著性掩码 X_t ，分阶段嵌入向量构建方式如下：

$$OP_n = \begin{cases} \text{Conv}(\mathcal{R}(\text{Conv}(I) + \text{Conv}(X_t))) & n = 1, \\ \text{Conv}(\mathcal{R}(\text{Conv}(OP_{n-1}))) & n = 2, 3, 4. \end{cases} \quad (1)$$

其中 OP_n 表示第 n 阶段的分阶段嵌入向量，通过卷积投影和补丁重塑从RGB图像 I 与含噪显著性掩码 X_t 构建而成。

为使条件特征适应不同的时间步长，连续时间变量 $t \in [0, 1]$ 采用正弦位置嵌入进行编码。

$$T = \text{SPE}(t), \quad t \sim \mathcal{U}(0, 1), \quad (2)$$

其中 $\text{SPE}(\cdot)$ 表示正弦位置嵌入。时间嵌入在每个阶段被注入Transformer模块，从而生成具有时间感知能力的多尺度特征 $\{F_n\}_{n=1}^4$ ，其中 F_n 表示第 n 个Transformer阶段的输出特征。

考虑到多尺度条件特征 $\{F_n\}_{n=1}^4$ ，我们采用分阶段方式依次应用显著特征判别器（SFD）和显著特征校准器（SFC），以逐步优化不同语义层级的特征。该设计灵感源自遥感显著性检测领域：显著目标通常体积较小、分布稀疏，且被对比度较弱的主导背景区域所包围，因此需要

同时实现全局杂波抑制与局部边界细化的双重目标。

SFD旨在提升目标与背景的可分离性。我们基于两个投影通道描述符之间的差异生成重要性图：

$$z_1, \approx_2 = \text{GAP}(\text{Conv}_{1 \times 1}(\mathbf{F})), \quad (3)$$

$$\mathbf{A} = \sigma(\text{Conv}_{1 \times 1}(\tanh(\approx_1 - \approx_2))), \quad (4)$$

其中 $\cdot$ 表示逐对减法运算。与此同时，原始特征 $\mathbf{F}$ 通过第三个 1×1 卷积层映射为节点特征表示。随后我们在 $\mathbf{G}$ 上执行图卷积运算，以在通道节点间传播关系上下文。通过引入单位矩阵 $\mathbf{I}$ 以保留自循环，图推理过程可表述为：

$$\mathbf{F}_{\text{SFD}} = (\mathbf{A} + \mathbf{I}) \otimes \text{Conv}_{1 \times 1}(\mathbf{F}) \quad (5)$$

其中 $\otimes$ 表示矩阵乘法。

基于 $\mathbf{F}_{\text{SFD}}$ ，SFC采用双分支投影与双门控融合技术以提升遥感影像的结构保真度。具体而言， $\mathbf{F}_{\text{SFD}}$ 通过两个独立的 1×1 卷积层（ $\mathbf{F}_1 = \text{Conv}_{1 \times 1}(\mathbf{F}_{\text{SFD}})$ ）被投影到两个特征分支中， $\mathbf{F}_2$ 通过类似方式获取。随后将两个分支拼接形成融合特征：

$$\mathbf{F}_c = \text{Concat}(\mathbf{F}_1, \mathbf{F}_2). \quad (6)$$

随后我们利用来自 $\mathbf{F}_c$ 的互补全局统计特征：平均池化能够捕捉整体响应分布，而最大池化则突显了小物体和细边界特征中典型的稀疏但强激活信号。

$$g_{\text{avg}} = \text{GAP}(\mathbf{F}_c), \quad g_{\text{max}} = \text{GMP}(\mathbf{F}_c). \quad (7)$$

这些统计数据被融合以生成双校准门

$$\text{两个分支}, \mathbf{W}_1, \mathbf{W}_2 = \text{Split}(\mathcal{Z}(\text{Conv}_{1 \times 1}(\text{Concat}(g_{\text{avg}}, g_{\text{max}})))) \odot (8)$$

通道注意力分支生成双通道尺度因子：

$$s_1, s_2 = \text{Split}(\text{FC}(\text{GAP}(\mathbf{F}_c))). \quad (9)$$

最后，SFC采用残差公式实现双门控融合：

$$\mathbf{F}_{\text{cond}} = \mathbf{W}_1 \cdot s_1 + \mathbf{W}_2 \cdot s_2 + \mathbf{F}_{\text{SFD}}. \quad (10)$$

在遥感影像中，显著目标常以不同尺度呈现且边界模糊。通过联合利用平均响应与极端响应并采用双分支门控机制，SFC算法能够增强小尺度但信息丰富的区域，从而提升显著性定位精度。

表I
定量比较结果 (F值) β^{max} , E_{ξ}^{max} Sq 与MAE评分在三个基准数据集上呈现。在
表格中, $\uparrow$ 和 $\downarrow$ 分别表示较高和较低的数值更受青睐。每列中排名前三的结果分别以红色、蓝色和绿色高亮显示。

方法	公共	ORSSD				EORSSD				ORSI-4199			
		$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效距离 (MAE) $\downarrow$	$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效距离 (MAE) $\downarrow$	$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效距离 (MAE) $\downarrow$
GeleNet [20]	TIP-23	0.9328	0.9109	0.9760	0.0099	0.9324	0.8796	0.9735	0.0063	0.8730	0.8663	0.9397	0.0318
ACCoNet [21]	TCYB-23	0.9437	0.9149	0.9796	0.0080	0.9290	0.8837	0.9727	0.0074	0.8817	0.8740	0.9478	0.0294
ERPNet [9]	TCYB-23	0.9352	0.9036	0.9738	0.0114	0.9252	0.8743	0.9665	0.0082	0.8684	0.8610	0.9384	0.0327
WeightNet [22]	TGRS-24	0.9512	0.9278	0.9864	0.0075	0.9417	0.8908	0.9809	0.0060	0.8868	0.8821	0.9496	0.0290
PRNet [11]	TGRS-24	0.9425	0.9153	0.9866	0.0068	0.9296	0.8707	0.9809	0.0053	0.8795	0.8734	0.9491	0.0280
RAGRNet [15]	TGRS-24	0.9507	0.9242	0.9861	0.0066	0.9361	0.8852	0.9788	0.0057	0.8859	0.8803	0.9490	0.0281
CamoDiff [23]	TPAMI-25	0.9410	0.9116	0.9779	0.0096	0.9298	0.8809	0.9685	0.0075	0.8772	0.8710	0.9432	0.0312
MRBINet [5]	TGRS-25	0.9474	0.9199	0.9851	0.0069	0.9351	0.8852	0.9766	0.0056	0.8845	0.8787	0.9489	0.0287
SAANet [4]	EAAI-25	0.9487	0.9226	0.9840	0.0078	0.9399	0.8918	0.9801	0.0057	0.8806	0.8773	0.9455	0.0302
PDNet [14]	EAAI-25	0.9444	0.9161	0.9668	0.0080	0.9346	0.8813	0.9524	0.0063	0.8880	0.8755	0.9554	0.0270
ORSIDiff [13]	TGRS-25	0.9570	0.9255	0.9880	0.0054	0.9423	0.8890	0.9830	0.0046	0.8860	0.8812	0.9510	0.0275
我们的	—	0.9586	0.9262	0.9883	0.0050	0.9437	0.9010	0.9840	0.0041	0.8935	0.8870	0.9545	0.0262




图3. ORSIFlow与其他前沿方法的定性比较

C. 潜在空间流网络

如图2(B)所示, 潜在空间流网络 (LSFN) 在变分自编码器 (VAE) 提供的紧凑潜在空间中执行显著性条件建模。具体而言, 我们通过编码器将时间步 t 处的噪声显著性图 x_t 映射为潜在表示:

$$z_t = E(x_t), \quad (11)$$

其中 $E(\cdot)$ 表示VAE编码器, z_t 代表对应于噪声状态的潜在变量。

在显著性感知嵌入 F_{cond} 的条件下, LSFN 采用修正流来学习确定性速度场 v_{θ} 。该速度场驱动潜在变量 z_t 从噪声分布向数据分布迁移:

$$\frac{dz_t}{dt} = v_{\theta}(z_t, t, F_{\text{cond}}). \quad (12)$$

在训练过程中, 我们通过线性插值法在干净的潜在变量 z_0 (其中 $z_0 = E(x_0)$) 与高斯噪声样本 $\epsilon \sim N(0, I)$ 之间构建

流轨迹。时间 $t \in [0, 1]$ 处的噪声状态可解析定义为:

$$z_t = (1 - t)z_0 + t\epsilon. \quad (13)$$

网络参数通过最小化预测速度与目标方向 ($\epsilon - z_0$) 之间的均方误差进行优化:

$$\mathcal{L}_{\text{RF}} = \mathbb{E}_{z_0, \epsilon, t} \|v_{\theta}(z_t, t, F_{\text{cond}}) - (\epsilon - z_0)\|_2^2. \quad (14)$$

最后, 将经过优化的潜在表示 $\hat{z}_0$ (通过求解流场常微分方程获得) 进行重构, 以生成预测结果:

$$\hat{x} = D(\hat{z}_0), \quad (15)$$

其中 $D(\cdot)$ 表示解码器, $\hat{x}$ 为最终预测的显著性图。在推理阶段, 我们会在解码前对潜在变量进行若干步更新, 如图2所示。

表 II
基于 ORSSD, EORSSD 和 ORSI-4199 数据集的不同模块消融参数对比分析。各列中最佳结果以粗体标出。

不	模块消融术			ORSSD (200张测试图像)				EORSSD (600张测试图像)				ORSI -4199 (2199张测试图像)			
	VAE	SFD	SFC	$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效剂量 (MAE) ↓	$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效剂量 (MAE) ↓	$S_{\alpha} \uparrow$	$F_{\beta}^{max} \uparrow$	$E_{\xi}^{max} \uparrow$	平均有效剂量 (MAE) ↓
(a)	✓			0.9453	0.9003	0.9841	0.0063	0.9303	0.8846	0.9787	0.0051	0.8696	0.8593	0.9437	0.0302
(b)				0.9479	0.9067	0.9847	0.0061	0.9326	0.8882	0.9794	0.0050	0.8740	0.8651	0.9461	0.0297
(c)		✓		0.9548	0.9189	0.9863	0.0056	0.9398	0.8970	0.9821	0.0046	0.8866	0.8789	0.9515	0.0274
(d)			✓	0.9516	0.9128	0.9856	0.0059	0.9362	0.8923	0.9811	0.0048	0.8801	0.8724	0.9492	0.0287
(e)	✓	✓		0.9567	0.9217	0.9875	0.0052	0.9415	0.8989	0.9831	0.0044	0.8894	0.8826	0.9530	0.0271
(f)	✓		✓	0.9534	0.9150	0.9860	0.0057	0.9377	0.8941	0.9817	0.0047	0.8832	0.8752	0.9504	0.0281
(g)		✓	✓	0.9578	0.9246	0.9874	0.0052	0.9426	0.9002	0.9831	0.0043	0.8917	0.8846	0.9534	0.0268
(h)	✓	✓	✓	0.9586	0.9262	0.9883	0.0050	0.9437	0.9010	0.9840	0.0041	0.8935	0.8870	0.9545	0.0262




图4. 我们模块有效性评估的可视化结果。

IV. EXPERIMENT

A. 实验设置

实现细节。所提出的模型采用开源PyTorch框架及单 NVIDIA GeForceH100GPU进行实现。在训练和测试过程中, 所有输入图像均被调整为352×352分辨率。我们使用AdamW优化器进行150轮训练, 批量大小设为32, 初始学习率为1e-4。

数据集。我们针对 ORSI -SOD领域的三个常用数据集进行实验: ORSSD[7]、EORSSD[6]和 ORSI -4199[24]。The ORSSD 数据集包含800组图像对, 其中600组用于训练, 剩余200组用于测试。EORSSD 数据集是 ORSSD 的扩展版本, 包含2000组图像对, 其中1400组用于训练, 600组用于测试。ORSI -4199数据集由2000个训练样本和2199个测试样本组成, 因其场景多样且复杂, 被公认为 ORSI -SOD领域最具挑战性的基准数据集。

评估指标。我们采用四种广泛使用的指标对所有方法的性能进行定量评估, 包括S值 (S_{α}) [25]、平均绝对误差 (MAE)、最大E值 (E_{ξ}^{max}) [26]以及最大F值 (F_{β}^{max})。

B. 性能比较

我们将所提出的方法与包括 GeleNet[20]、ACCoNet [21]、ERPNet[9]、WeightNet[22]、PRNet[11]、RAGRNet [15]、CamoDiff[23]、MRBNet[5]、SAANet[4]、PDNet [14]及ORSIDiff[13]在内的十一种其他前沿 (SOTA) 方法进行对比。为确保评估公平性, 所有竞争模型的预测结果

均基于其官方发布的开源代码及推荐参数设置生成。

定量比较。如表I所示, 我们的方法在四个评估指标下于三个数据集上持续优于现有 SOTA 方法。在 ORSSD 数据集上, 我们的方法实现了最高的 F_{β}^{max} 、 S_{α} 和 E_{ξ}^{max} , 同时具有最低的MAE, 反映出准确且结构一致的预测结果。在 EORSSD 数据集上也能观察到类似趋势, 我们的方法在所有指标上均排名第一, 彰显了其强大的泛化能力。尽管 ORSI -4199数据集因复杂背景和多样化的物体尺度更具挑战性, 但我们的方法仍与现有方法保持高度竞争力。

定性对比分析。图3展示了本方法与若干代表性前沿方法的定性对比结果。首行数据表明, 多数竞品方法在检测小型物体时存在漏检或部分物体缺失现象, 而本方法实现了更完整的检测效果。第二、三行数据集中呈现细长结构特征时, 部分方法会产生碎片化预测或边界失真, 本方法则能更好地保持物体整体结构完整性。最后一行数据中, 背景杂乱与低对比度环境带来额外挑战时, 现有方法会产生明显误检结果, 而本方法生成的分割结果更为清晰整洁。

C. 消融研究

我们对 ORSSD、EORSSD 和 ORSI -4199进行消融研究以评估各模块的有效性。如表II所示, 引入单个组件在 F_{β}^{max} 、 S_{α} 、 E_{ξ}^{max} 和MAE方面持续提升性能, 而将它们组合使用则能带来更进一步的

模型增益。完整模型在所有数据集上均展现出最佳整体性能。图3提供了定性对比结果：移除特定模块会导致预测结果不完整或碎片化，而完整模型则能生成更精确且连贯的分割结果。

D. 效率分析

表 III
基于ORSI-4199数据集采用不同时间步长的生成式ORSI-SOD方法效率比较。各列中最佳结果以粗体标出。

方法	时间步	浮点运算次数(G)	帧率	$S_{\alpha} \uparrow$	$F_{\beta}^{\max} \uparrow$	$E_{\xi}^{\max} \uparrow$	平均绝对误差 (MAE) ↓
卡莫替尼	10	60.29	0.3	0.8772	0.8710	0.9432	0.0312
ORSI差值	10	15.25	8	0.8860	0.8812	0.9510	0.0275
我们的	3	5.68	19	0.8935	0.8870	0.9545	0.0262

表III对比了不同生成式 ORSI -SOD方法在 ORSI -4199数据集上的效率与性能表现。我们的方法通过显著减少扩散步骤和浮点运算次数，在GPU上实现了最优的推理速度，同时在效率与精度之间取得了卓越平衡。该方法在 S_{α} 、 $F_{\max}\beta$ 和 $E_{\max}\xi$ 指标上均表现最佳，且具有最低的MAE值，充分展现了其高效性与计算优势。

V. 结论

ORSIFlow是一种基于显著性引导的校正流框架，专为光学遥感显著目标检测设计。该框架通过在紧凑的潜在空间中生成显著性掩码，并采用确定性校正流算法，实现了高效精准的预测效果。其显著特征判别器与校准器有效提升了全局语义区分能力和边界精度。公开基准测试实验表明，ORSIFlow在更少推理步骤下即可超越现有最先进方法，充分展现了基于流的生成建模技术在遥感显著性检测领域实现鲁棒高效检测的潜力。

参考文献

[1] Bo Yu与Fang Chen, 《基于图像显著性的大规模滑坡检测实用方法》, *应用遥感杂志*, 第10卷第4期, 第045013页, 2016年。

[2] 任梦宇、李宇通、李华、王楚红与丛润民, 《超越全局扫描：光学遥感图像中显著目标检测的自适应视觉状态空间建模》, 2026年。

[3] 李润廷、连世杰、李华、李宇通、吴文辉与Sam Kwong, 《水流：基于显式物理先验的水下显著性掩模生成校正流场》, 2026年。

[4] 葛彦亮、梁太川、任俊超、何敏、毕洪波、张乔, 《遥感图像中显著目标检测的语义感知聚合》, *人工智能工程应用*, 第160卷, 第111837页, 2025年。

[5] 云佳、赵杰、马林和于立丹, 《光学遥感图像中显著目标检测的多策略区域与边界交互网络》, *IEEE地球科学与遥感汇刊*, 第63卷, 第1-16页, 2025年。

[6] 张启建、丛润民、李崇义、程明明、方宇明、曹晓春、赵耀和Kwong Sam, 《光学遥感图像中显著目标检测的密集注意力流网络》, *IEEE图像处理汇刊*, 第30卷, 第1305-1317页, 2021年。

[7] 李崇毅、丛润民、侯俊辉、张三义、钱跃及Sam Kwong, 《基于双流金字塔结构的嵌套网络用于光学遥感图像中显著目标检测》, *IEEE地球科学与遥感汇刊*, 第57卷第11期, 第9156-9166页, 2019年。

[8] 李国阳、白振、刘志、张新鹏和凌海斌, 《基于变换器驱动的光学遥感图像显著目标检测》, *IEEE图像处理汇刊*, 第32卷, 第5257-5269页, 2023年。

[9] 周晓飞、沈坤业、翁立、丛润民、郑伯伦、张继勇、严成刚 Clarence, “基于边缘引导的循环定位网络用于光学遥感图像中显著目标检测”, *IEEE控制论汇刊*, 第53卷, 第539-552页, 2022年。

[10] G. Li、Z. Liu、D. Zeng、W. Lin和H. Ling, 《光学遥感图像中显著目标检测的邻近上下文协调网络》, *IEEE控制论汇刊*, 第53卷第1期, 第526-538页, 2022年。

[11] 顾胜宇、宋勇、周亚、白亚硕、杨欣和何玉欣, 《Prnet: 基于群体特征学习的并行细化网络用于光学遥感图像中显著目标检测》, *IEEE地球科学与遥感快报*, 第21卷, 第1-5页, 2024年。

[12] L. Di、B. Zhang与Y. Wang合著的《光学遥感图像中显著目标检测的多尺度多维加权网络》, 发表于*IEEE地球科学与遥感汇刊*第62卷第1-16页, 2024年。

[13] 韩金字、孙静、王发胜、孙福明与李浩杰, 《Orsidiff: 光学遥感图像中显著目标检测的扩散模型》, *IEEE地球科学与遥感汇刊*, 第63卷, 第1-15页, 2025年。

[14] 陈超军、李飞、李振波与王云, 《基于并行双解码器网络的显著目标检测方法》, *人工智能工程应用*, 第139卷, 第109638页, 2025年。

[15] 赵杰、贾云、马林和于立丹, 《基于区域与边界交互的循环自适应图推理网络用于光学遥感图像中显著目标检测》, *IEEE地球科学与遥感汇刊*, 第62卷, 第1-20页, 2024年。

[16] Yaron Lipman、Ricky TQ Chen、Heli Ben-Hamu、Maximilian Nickel和Matt Le, 《生成建模中的流匹配》, *arXiv预印本 arXiv:2210.02747*, 2022年。

[17] 刘兴超、龚成跃和刘强, 《流速直快：学习利用校正流生成并迁移数据》, *arXiv预印本 arXiv:2209.03003*, 2022年。

[18] Bharath Irigireddy与Varaprasad Bandaru, 《Satflow: 基于生成模型的高分辨率无空白遥感影像生成框架》, *arXiv预印本 arXiv:2502.01098*, 2025年。

[19] Georges Le Bellier与Nicolas Audebert, 《Floweo: 面向地球观测的生成式无监督领域适应方法》, *arXiv预印本 arXiv:2512.05140*, 2025年。

[20] 李国阳、白振、刘志、张新鹏和凌海斌, 《基于变换器驱动的光学遥感图像显著目标检测》, *IEEE图像处理汇刊*, 第32卷, 第5257-5269页, 2023年。

[21] 李国阳、刘志、曾丹、林伟西和凌海斌, 《光学遥感图像中显著目标检测的邻近上下文协调网络》, *IEEE控制论汇刊*, 第53卷第1期, 第526-538页, 2023年。

[22] Lamei Di、Bin Zhang与Yiming Wang合著的《光学遥感图像中显著目标检测的多尺度多维加权网络》, 发表于*IEEE地球科学与遥感汇刊*第62卷第1-14页, 2024年。

[23] 顾森、陈忠熙、林贤明、孙晓帅、刘红、纪荣荣, 《伪装与显著目标检测的条件扩散模型》, *IEEE模式分析与机器学习汇刊*, 第47卷第4期, 第2833-2848页, 2025年。

[24] 涂正正、王超、李成龙、范明浩、赵海峰和罗斌, 《基于多尺度联合区域与边界模型的Orsi显著目标检测》, *IEEE地球科学与遥感汇刊*, 第60卷, 第1-13页, 2022年。

[25] 邓平范、程明明、刘云、李涛与阿里·博尔吉, 《结构-度量：评估前景地图的新方法》, 载于《*IEEE国际计算机视觉会议 (ICCV) 论文集*》, 2017年, 第4548-4557页。

[26] 邓平范、程功、杨曹、任波、程明明与阿里·博尔吉, 《二值前景图评估中的增强对齐度量》, 载于《*第二十七届国际人工智能联合会 (IJCAI) 论文集*》, 2018年, 第698-704页。