

RMAE · ProGress: 在非结构化环境中推进语义分割技术的发展

马尼什·布尔特尔, 霍
华德大学, 华盛顿特
区, 美国

manish.bhurtel@bison.howard.edu

丹达·B·拉瓦特, 霍华
德大学, 华盛顿特区,
美国

danda.rawat@howard.edu

摘要

在非结构化环境中进行语义分割面临独特挑战，这主要源于地形复杂、遮挡现象以及空间布局的多样性。虽然结构化场景（如城市景观）已得到广泛研究，但非结构化环境下的语义分割在标准化评估和架构设计方面仍相对缺乏探索。本研究提出一种基于编码器-解码器的语义分割架构，该架构整合了作为编码器的降维掩码自编码器（RMAE）、特征到金字塔（F2P）颈部网络以及名为ProGress的新型解码器。ProGress解码器引入了用于非连续特征图自上而下多尺度融合的渐进式跳跃融合（PLF）、带有残差项的轻量级通道注意力门（LCAR）模块，以及用于紧凑型优化的瓶颈特征融合（BFF）模块。我们通过在RELLIS-3D、其粗粒度版本及RUGD等具有挑战性的非结构化数据集上对比测试最先进的CNN和Transformer模型，建立了全面的基准性能指标。该架构在RELLIS-3D数据集上取得57.41%的平均交并比（mIoU），在RUGD数据集上达到45.63%的mIoU，整体性能位居行业前沿水平。在RELLIS-3DC数据集上实现95%的mIoU精度，同时保持具有竞争力的参数数量和显存使用率。代码可获取于<https://gitlab.com/coeaiml/rmae-progress>。

1. 引言

语义分割已成为计算机视觉领域的一项关键任务，它能够实现像素级场景理解，这对自主导航、机器人技术和环境感知至关重要。尽管在城市驾驶场景（如Cityscapes[8]、ADE20K[47]）等结构化环境中，通过采用强大的编码器-解码器架构已取得显著进展，但非结构化环境中的语义分割研究仍十分匮乏。非结构化环




图1. RELLIS-3D数据集中mIoU与参数数量的对比。我们提出的RMAE-ProGress模型在参数数量均衡的情况下实现了业界领先性能。

境以越野地形、复杂地貌、边界模糊及几何一致性缺失为特征，给设计精准高效的分割模型带来了独特挑战。尽管这类环境对战场场景、搜救任务、防御机器人及行星探测等关键领域具有重要意义，但在模型设计和标准化评估方面却鲜受关注。此外，非结构化环境往往存在空间冲突且资源受限，因此所需的模型不仅需要具备高性能特性，还需实现计算资源的均衡分配。因此，本研究的动机源于两个核心研究空白：(1) 在非结构化场景下缺乏标准化的语义分割基准和比较评估方法；(2) 亟需兼具高性能与合理计算效率的架构方案。我们通过重新审视非结构化环境数据集（RUGD[34]、RELLIS-3D[20]及其粗粒度版本RELLIS-3DC[14]），并提出一种能在准确率、计算效率与设计模块性之间取得平衡的语义分割框架来解决这些问题。

为弥补现有不足，我们首先对一系列优秀的基于CNN和Transformer的分割模型进行了全面基准测试，从而为RELLIS-3D和RUGD数据集建立了稳健且可复现的基线模型。随后，我们设计了**Reduced MAE (RMAE)**——一种轻量级基于ViT的[9]编码器，在保持准确性的前提下显著提升了计算效率。该架构在实现高效特征表示学习的同时大幅降低了计算成本。接着，我们采用标准的**Feature-to-Pyramid (F2P)**颈部网络构建层次化空间特征。最后，我们开发了创新的**ProGracc解码器**——一种由3.3节所述三个核心组件构成的轻量化模块化架构。完整的**RMAEProGracc**流程在RELLIS-3D、RELLIS-3DC和RUGD数据集上均实现了业界领先性能，同时保持了均衡的计算效率。

我们的贡献总结如下：

- **降维MAE编码器 (RMAE)**：我们通过减少ViT-MAEBase模型的深度，并采用掩码自编码器(MAE)预训练权重，设计出紧凑型编码器，同时显著降低参数量。实验表明，在RELLIS-3D数据集上，即使是结构简单的变体模型也优于复杂模型。
- **一种轻量级分割解码器**：我们提出**ProGracc**——一种模块化解码器，融合了**渐进式跳跃融合 (PLF)**、采用**门控与残差连接**的轻量级通道注意力机制(LCAR)以及**瓶颈特征融合 (BFF)**，旨在实现非结构化环境下的精准语义分割。
- **RELLIS-3D与RUGD数据集的全面基准测试**：除文献中的性能报告外，我们针对RELLIS-3D和RUGD数据集对基于CNN和Transformer的模型进行了训练并提供了系统性评估，为未来越野场景分割研究建立了标准化基线。
- **具备均衡计算能力的顶尖性能**：我们的RMAE-ProGracc模型在原始RELLIS-3D数据集上达到57.41%的mIoU值，在其粗粒度版本RELLIS-3DC上达到78.95%，在RUGD数据集上达到45.63%的mIoU值，均创下行业领先水平。其参数量、显存占用量及浮点运算量均与通用分割基线模型相当。

2. 相关工作

2.1. 非结构化环境中的语义分割

尽管诸如Cityscapes[8]和ADE20K[47]等数据集包含少量越野类别（如土壤、植被、河流），但这些类别分布稀疏，无法反映真实越野场景中存在的复杂性、变异性或边界模糊性。为弥补这一不足，美国陆军研究实验室(ARL)推出了RUGD[34]和RELLIS-3D[20]数据集，这些数据集通过自主平台在越野环境中采集。

已有诸多研究利用这些数据集，应用范围涵盖从基于组注意力机制的导航能力分析[14]到用于光照变化的记忆模块[21]、主动学习[12]以及边界增强分割[26]等领域。尽管如此，从模型设计与基准测试的角度来看，非结构化语义分割领域仍缺乏充分研究。为填补这一空白，我们针对这些数据集对基于CNN和Transformer的架构进行了全面评估，在保持计算成本平衡的同时优先考虑准确率。

2.2. 轻量级视觉变压器编码器

虽然基于CNN的骨干网络如ResNet[15]轻量且应用广泛，但视觉Transformer (ViTs) 在各类视觉任务中展现出更优性能[9]。这推动了适用于资源受限场景的轻量化Transformer架构设计。诸如MobileViT[25]等混合模型将MobileNet的高效性与Transformer的表达力相结合；而ViT-Tiny和MAETiny[13, 16]则降低了嵌入维度和模型宽度。然而这些方法即使在紧凑版本中仍保留ViT-Base模型的完整深度(12层)。相比之下，我们提出了一种**深度缩减版**的ViTMAE-Base模型，在保持原始嵌入维度的同时减少了Transformer层数。

2.3. 用于语义分割的编码器网络

编码器设计在语义分割中起着至关重要的作用，尤其是在聚合多尺度特征以及从深度编码器输出中恢复空间精度方面。传统的编码器-解码器框架（如U-Net[29]和SegNet[1]）采用带有跳跃连接的对称解码机制，将高分辨率空间特征与富含语义信息的编码器输出相结合。DeepLabV3+[5]通过整合空洞式空间金字塔池化(ASPP)及简化版解码器，进一步提升了多尺度上下文捕捉能力。类似地，UPerNet[37]通过结合横向连接与金字塔池化机制扩展了特征金字塔网络(FPN)[23]，实现了自上而下的语义细化。其他方法如OCRNet[42]和GCNet[3]则引入全局上下文模块以实现对象级理解。尽管这些解码器设计在结构化基准测试中表现优异，但在非结构化环境中仍缺乏充分验证。本研究中，我们针对采用不同编码器主干结构的各类解码器架构进行了全面评估，并将其与我们提出的RMAE-ProGracc模型进行直接对比。

3. 研究方法

我们的完整架构概述如图2所示。该系统包含三个主要组件：轻量级RMAE编码器，可生成非连续的粗粒度




图2. 提出的 RMAE-ProGress 架构概述。该架构包含：RMAE 编码器（图中为 RMAE-8L），可生成4个非连续特征图；特征到金字塔颈部网络，用于将特征图转换为多个空间维度；以及ProGress解码器，用于解码层次化特征图。通道维度 C 在整个架构中保持一致。

与细粒度语义特征；特征到金字塔颈部模块，负责在不同空间尺度上调整特征图尺寸并实现对齐；以及我们提出的ProGRecc解码器，负责执行渐进式融合、基于注意力机制的细化处理以及最终分割任务。

3.1. RMAE：简化编码器设计

为在保持强大表征能力的同时降低计算开销，我们采用截断版 ViT-Base 编码器并结合掩码自编码器（MAE）[16]预训练权重。标准 ViT-Base 编码器使用12个Transformer层；我们将层数分别减少至8层、6层和4层，从而构建出我们的简化MAE（RMAE）编码器。

表1. 不同 RMAE 变体及标准 ViTMAE-Base 编码器。Out Index 指所选特征层级的索引值。

模型	图层	正面朝上的	参数(M)	输出索引
ViTMAE数据库	12	12	86.0	{3, 5, 7, 11}
RMAE-8L	8	12	58.5	{1, 3, 5, 7}
RMAE-6L	6	12	44.2	{1, 2, 4, 5}
RMAE-4L	4	12	29.9	{0, 1, 2, 3}

在基于Transformer的编码器（如ViTMAE）中，由于增量标记混合机制[9, 16]，相邻层通常会生成高度相关的特征。从每一层采样都会引入冗余信息、增加内存占用，并使特征融合过程复杂化，而表征质量并未显著提升。受先前研究[2, 33, 38]的启发，我们采用固定间隔提取特征，从而捕捉早期结构特征、中层模式以及深层语义信息。如表1所示，我们的 RMAE 变体相较于原始ViTMAE-Base模型显著降低了参数量。

将一组形状为 (C', H, W) 的输入图像（记为 $I \in \mathbb{R}^{B \times C' \times H \times W}$ ）输入 RMAE 编码器后，输出特征图即为 $f_i = \{f_1, f_2, f_3, f_4\}$ ，其中 $f_i \in \mathbb{R}^{B \times C \times \frac{H}{16} \times \frac{W}{16}}$ ； B 表示批次大小， C 为通道维度。需注意，每个输出特征图均对应表1中所选 RMAE 编码器变体对应的索引。随后，特征图集合 f_i 被送入特征到金字塔（F2P）模块。我们

3.2. 特征到金字塔（F2P）

采用标准F2P颈部网络将这4个特征图重缩放为多尺度金字塔结构，使解码器能够处理不同空间分辨率的特征，从而同时捕捉宏观上下文与精细细节。在F2P中，特征图 f_i 通过相应缩放因子 $r_i \in \{4, 2, 1, 0.5\}$ 进行缩放，生成金字塔输出 $F_i = \mathcal{R}_{r_i}(f_i)$ ，其中 $\mathcal{R}_{r_i}(\cdot)$ 为定义如下的缩放运算符：

$$F_i = \mathcal{R}_{r_i}(f_i) = \begin{cases} C^T(\phi(\text{BN}(C^T(f_i)))) & \text{if } r_i = 4 \\ C^T(f_i) & \text{if } r_i = 2 \\ f_i & \text{if } r_i = 1 \\ \text{MaxPool}(f_i) & \text{if } r_i = 0.5 \end{cases}$$

其中 C^T 表示转置卷积函数， ϕ 为 GELU $(\cdot)$ 激活函数，BN 代表批量归一化。在此模型中，MaxPool 的池化尺寸为 2， C^T 的步长为 2，且每次重缩放操作中的权重均相互独立。最终，F2P 输出经过重缩放的特征： $F_i = \{F_1, F_2, F_3, F_4\}$ ，其空间尺度分别为： $\frac{H}{4} \times \frac{W}{4}$ ， $\frac{H}{8} \times \frac{W}{8}$ ， $\frac{H}{16} \times \frac{W}{16}$ ，和 $\frac{H}{32} \times \frac{W}{32}$ 各自地。

F2P模块将早期层特征（例如 RMAE-8L 中索引1和3的输出）上采样至更高分辨率以捕捉精细的空间细节，保持中间层特征（索引5）的原始分辨率，并对深层特征（索引7）下采样以突出高层次语义，从而在保留原始通道维度 C 的同时构建出平衡的金字塔结构。

3.3. ProGRecc解码器

我们提出了一种轻量级且模块化的ProGress解码器，该解码器能够逐步聚合并优化多尺度特征。ProGress解码器由三个核心模块组成：(i) 渐进式跳跃融合（PLF）；(ii) 带残差的轻量级通道注意力机制（LCAR）；(iii) 瓶颈特征融合（BFF）。

3.3.1. 渐进式阶梯融合（PLF）

金字塔特征集 $F_i = \{F_1, F_2, F_3, F_4\}$ 作为 PLF 模块的输入。每个金字塔特征对应来自编码器四个非连续索引

（例如 RMAE -8L模型中的索引1、3、5和7）生成的特征图。为融合这些跳跃式特征，PLF对这些非连续特征图进行自上而下处理：逐步将语义深层但空间分辨率较低的特征与空间分辨率较高但深度较浅的特征相结合，从而实现全局上下文信息与局部细节特征的整合。

在F2P模块之后，我们在整个解码器中保持通道维度 C 。PLF通过依次对深层特征进行上采样并与高分辨率特征融合来实现特征融合；由于 F_i 代表跳跃式特征图，这种融合过程形成了级联结构。此外，我们还对 F_4 应用自融合机制，以增强深层特征图中的语义表征。

$$\langle F_4 = \text{Fuse}(F_4, F_4) \text{ (自融合)} \rangle \quad (1)$$

$$\langle F_3 = \text{Fuse}(F_3, \langle F_4 \rangle) \rangle \quad (2)$$

$$\langle F_2 = \text{Fuse}(F_2, \langle F_3 \rangle) \rangle \quad (3)$$

$$\langle F_1 = \text{Fuse}(F_1, \langle F_2 \rangle) \rangle \quad (4)$$

在哪里，

$$\text{Fuse}(F_i, F_j) = \phi(\text{BN}(\mathbf{W}_{ij} \otimes [F_i \parallel \mathcal{U}(F_j, \text{size of } F_i)])) \quad (5)$$

其中 $\mathcal{U}(a, b)$ 的尺寸是插值运算（通过消融研究选择的最近邻），用于将特征图 a 上采样至空间维度 b ； $\parallel$ 表示拼接运算；且 $\mathbf{W}_{ij} \in \mathbb{R}^{C \times (C_i + C_j) \times 1 \times 1}$ 。

该模型采用可学习的 1×1 卷积核，将拼接后的特征映射至 C 个通道，并为每对融合特征（ F_i, F_j ）设置独立参数。

多尺度特征融合面临的一个关键挑战在于确保信息在金字塔各层级间有效流动。尽管PLF与FPN式方法存在某些相似性[23, 37]，但其递归融合设计具有独特性，相关详细讨论见补充材料（第12节）。我们通过PLF递归公式的一个基本性质（命题1）阐明了其信息流动机制。

命题 1（信息保留）。该PLF机制通过递归融合方式保留所有金字塔层级的信息。

*证明。*我们通过构造证明：每个 $\sim F_i$ 都包含了所有层级 $j \geq i$ 的信息。

基本情况： $\sim F_4$ 仅包含来自 F_4 的信息（自融合）。

归纳步骤：假设 $\sim F_{k+1}$ 包含来自 $\{F_{k+1}, F_{k+2}, \dots, F_4\}$ 的信息。那么：

$$\tilde{F}_k = \phi(\text{BN}(\mathbf{W}_k * [F_k \parallel \mathcal{U}(\tilde{F}_{k+1})])) \quad (6)$$

通过连接操作， $\sim F_k$ 明确包含 F_k 和 $\sim F_{k+1}$ 。根据归纳假设， $\sim F_{k+1}$ 包含 $\{F_{k+1}, \dots, F_4\}$ 。因此， $\sim F_k$ 包含了来自 $\{F_k, F_{k+1}, \dots, F_4\}$ 的信息。□

3.3.2. 基于残差的轻量级通道注意力机制

鉴于非结构化场景中视觉线索的异质性（如植被、碎屑、阴影等），简单的融合方法可能无法充分凸显相关的空间结构。LCAR通过采用基于像素级、通道级的门控机制来解决这一问题，该机制可根据局部重要性对各通道进行增强或抑制。与传统的通道注意力机制[18]（其通过全局平均池化和全连接层压缩空间信息）不同，我们采用一种轻量级且无需池化的 $1 \times$ 卷积运算来生成像素级、通道级的注意力图，从而在保持空间细节的同时将计算开销降至最低。

轻量级通道注意力（LCA）。对于输入 X ，LCA计算：

$$\text{LCA}(X) = X \odot \sigma(\mathbf{W}_c * X) \quad (7)$$

其中 $\mathbf{W}_c \in \mathbb{R}^{C \times C \times 1 \times 1}$ 是一个 1×1 卷积核，用于在固定维度 C 下混合通道； $\sigma(\cdot)$ 表示Sigmoid函数； $\odot$ 表示元素级乘法运算。

采用残差连接的注意力机制。此时LCAR模块定义如下：

$$\text{LCAR}(X) = \text{LCA}(X) + \alpha X = X \odot \sigma(\mathbf{W}_c * X) + \alpha X \quad (8)$$

其中 $\alpha \in \{0, 1\}$ 是表示每个层级残差连接的二元指示变量。 α 的取值通过经验验证确定。将等式8应用于所有特征层级 F_i （其中 $i \in \{1, 2, 3, 4\}$ ）后，可得：

$$\tilde{F}_i = \text{LCAR}(\tilde{F}_i) = \tilde{F}_i \odot \sigma(\mathbf{W}_i * \tilde{F}_i) + \alpha_i \tilde{F}_i \quad (9)$$

经验表明，当 $\alpha_1 = \alpha_2 = \alpha_3$ 且 $\alpha_4 = 1$ 时性能最佳，即残差连接仅应用于最深层（ $\uparrow F_4$ ）。已知残差连接能够稳定优化过程，并改善深层网络中的梯度流动——在这些层中，虽然表征具有更丰富的语义信息，但由于分辨率降低，其稳定性较差[15]。因此，LCAR中的残差路径有助于维持稳定的训练动态。

3.3.3. 瓶颈特征融合（BFF）

空间对齐。BFF是一个结构紧凑且功能强大的最终聚合模块。所有LCAR特征均被上采样至目标分辨率。 $\frac{H}{4} \times \frac{W}{4}$ ：

$$\text{曲率 } \tilde{F}_i = \mathcal{U}(\tilde{F}_i, \text{尺寸为 } \frac{H}{4} \times \frac{W}{4}), i \in \{1, 2, 3, 4\} \quad (10)$$

多尺度聚合。BFF模块通过以下方式在所有尺度上聚合特征：

$\mathbf{Z} = \phi(\text{BN}(\mathbf{W}_{bff} \otimes [\tilde{F}_1 \parallel \tilde{F}_2 \parallel \tilde{F}_3 \parallel \tilde{F}_4]))$ ，其中 $\mathbf{W}_{bff} \in \mathbb{R}^{C \times 4C \times 1 \times 1}$ 是一个 1×1 卷积核，可将通道维度从 $4C$ 降低至 C 。

3.3.4. 最终预测

分割结果可通过以下方式获取：

$$Y = \text{softmax}(W_{cls} * Z) \quad (11)$$

其中 $W_{cls} \in \mathbb{R}^{N \times C \times I \times I}$ 是一个 1×1 卷积核，用于将生成的通道 C 转换为类别数 N 。softmax 函数可生成每个像素的类别概率，最终标签通过 arg max 运算确定。

4. 实验

4.1. 数据集与评估指标

我们针对所提出的模型及其各种变体，在多个越野数据集上进行了全面评估，以检验其细粒度语义理解能力与跨域泛化能力，具体结果如表2所示。需注意的是，在基准测试与评估过程中，我们将验证集纳入了训练集。

表 2. 所有数据集的汇总

数据集名称	训练	试验	班级
雷利斯-3D	4562	1672	18
瑞利斯-3D	4562	1672	6
RUGD	5512	1924	22
地毯清洁通用套装	-	1924	14

RELLIS -3D。这是广受欢迎的越野语义分割数据集[20]。遵循原始数据集协议[20]，我们在18个类别上进行评估（排除空旷区域和污垢区域两类，因其标注数据稀疏）。

RELLIS -3DC。这是[14]提出的 RELLIS -3D的粗粒度变体，我们将其称为 RELLIS -3DC。该数据集将细粒度的 RELLIS -3D类别归为6个更广泛的类别，即：光滑、粗糙、凹凸、禁用、障碍物和背景类别。

RUGD。我们将评估范围扩展至 RUGD 数据集[34]。尽管 RUGD 定义了25个类别，但我们仅报告其中22个类别的结果（排除空洞、自行车和桥梁类别，因这些类别在训练集或测试集中均存在标注缺失）。

RUG-REL-Common。为实现零样本域泛化（从 RELLIS -3D到RUGD），我们构建了包含 RELLIS -3D中所有14个共同类别的 RUGD 测试集子集，记为 RUG-REL-Common。对于 RELLIS -3D中不存在的类别对应的像素点，则被标记为空白（赋值为0）。这种设置可直接评估跨域迁移性能——即仅在 RELLIS -3D上训练的模型无需微调即可直接在 RUGD 上进行测试。

评估指标。根据[14, 38]的研究，我们采用四种标准语义分割评估指标：每类交并比（IoU）、平均交并比（mIoU）、平均像素精度（mAcc）以及平均像素精度（aAcc）。

表3. 与现有 RUGD 及 REllis -3D测试集文献的对比。

数据集	方法	编码器	mIoU ↑
RUGD	UperNet [37]	ResNet50	31.95
	PSPNet [44]	ResNet-50	32.07
	DeepLabv3 [4]	ResNet50	32.81
	TrSeg [22]	ResNet50	33.91
	Memory-based Deeplabv3 [21]	ResNet50	37.71
	ProGRess (Ours)	ViTMAE数据库	45.63
雷利斯-3D	PSPNet [44]	ResNet18	38.52
	DeepLabv3 [4]	MobileNetV2	38.67
	DeepLabv3 [4]	ResNet50	43.97
	DeepLabv3 with memory [21]	ResNet50	45.61
	GSCNN [32]	-	52.92
	ProGRess (Ours)	ViTMAE数据库	57.41

4.2. 与现有文献的比较

表3展示了我们提出的方法与现有文献中关于 RUGD 和 REllis -3D数据集的研究结果对比。RUGD 上的性能数据引自[21, 22, 34]，而 REllis -3D上的性能数据则来自[20, 21]。虽然文献中还存在其他针对这些数据集性能评估的研究，但由于其评估指标不够明确，故未纳入比较范围。在 RUGD 数据集上，采用 ResNet-50骨干网络的先前研究取得了31.95%至37.71%不等的mIoU分数，其中基于Memory架构的DeepLabv3 [21]曾创下历史最佳成绩；我们的ViTMAE-ProGRess模型则实现了显著提升，达到45.63%的mIoU。在 REllis -3D数据集上，现有文献中 GSCNN 模型[20, 32]以52.92%的mIoU表现最佳；而我们的ViTMAE-ProGRess方法同样在此数据集上树立了新标杆，以57.41%的mIoU超越所有现有方法。尽管这些结果均较现有文献有明显改进，但既往研究范围有限且评估标准不一，因此亟需建立全面的基准测试体系。因此，我们对16种最先进的语义分割方法进行了全面评估，具体细节详见4.3小节。

4.3. 与国家艺术标准进行全面的基准测试和比较。

我们在 REllis -3D和 RUGD 数据集上对最先进的语义分割模型进行了全面的训练与性能基准测试。针对每种方法，我们均调整超参数，以确保在非结构化的户外场景中，无论是CNN还是Transformer架构都能获得稳健且可复现的基线性能。所有实验均使用MMSegmentation框架[7]实现，模型训练迭代次数为16万次，并报告训练过程中达到的最佳mIoU值；同时我们评估了MMSegmentation库中16种常用方法的表现。完整训练流程详见原文。

表4. 在 RELLIS -3D和 RUGD 测试集上，所提出方法与所有基准模型的性能比较。加粗数值表示我们的模型优于其他模型的情况；下划线表示与其他模型相比具有竞争力的表现；*表示基于Transformer的模型。

方法	backbone	Aux. 头	参数 / (M)	vRAM ↓ (MB)	RELLIS-3D [512 × 512]			RUGD [512 × 512]		
					失败次数(G) ↓	mIoU ↑	mAcc ↑	失败次数(G) ↓	mIoU ↑	mAcc ↑
ISANet [19]	ResNetV1c-101	FCN	56.7	227.4	227.8	40.65	49.86	455.6	21.63	32.50
FCN [30]	ResNetV1c-101	FCN	68.49	270.8	275.7	41.23	50.94	551.4	23.53	34.04
EncNet [43]	ResNetV1c-101	FCN	54.88	219.4	218.8	42.88	53.03	437.5	24.61	36.37
ANN [48]	ResNetV1c-101	FCN	65.22	257.8	263.3	43.21	51.56	526.6	25.81	36.11
分割器*[31]	ViT-B16	-	102.4	401.0	126.5	44.19	52.72	253.1	41.08	52.99
PSANet [45]	ResNetV1c-101	FCN	72.96	290.0	273.6	44.48	52.03	-	-	-
DeepLabV3 [4]	ResNetV1c-101	FCN	87.21	343.9	347.9	45.85	52.60	-	-	-
GCNet [3]	ResNetV1c-101	FCN	68.62	273.7	275.7	46.11	54.65	551.4	22.10	32.98
OCRNet + FCN [42]	HRNetV2-W48	-	70.37	282.1	162.8	46.55	54.58	325.9	27.16	37.56
DeepLabV3+ [5]	ResNetV1c-101	FCN	62.58	249.7	254.4	46.98	56.12	508.9	29.97	44.78
DPT* [28]	ViT-B16	-	109.67	441.4	217.4	47.95	57.32	-	-	-
ViT-UPerNet* [9]	ViT-B16	FCN	144.07	564.3	442.6	48.03	56.17	885.3	41.21	53.39
SETR-PUP* [46]	ViT-L16	SETRUP	317.15	1255.5	417.0	51.12	59.27	-	-	-
Segformer* [38]	MiT-B5	-	81.97	331.4	74.6	51.51	60.66	149.3	43.69	56.45
双胞胎-UPerNet*[6]	双胞胎——SVT	FCN	132.68	524.2	296.1	51.62	62.77	592.3	31.59	45.10
Swin-UPerNet* [24]	斯温-B-W7	FCN	121.18	473.8	298.3	53.86	63.33	596.7	41.76	55.19
ProGRecc (我们的)*	RMAE-4L	-	46.47	221.9	128.1	53.23	63.04	256.3	37.30	50.31
ProGRecc (我们的)*	RMAE-6L	-	<u>60.74</u>	296.0	145.9	55.46	66.02	291.8	37.67	50.81
ProGRecc (我们的)*	RMAE-8L	-	75.02	365.0	163.6	57.14	68.53	327.3	41.34	53.73
ProGRecc (我们的)*	ViTMAE数据库	-	103.56	509.4	199.1	57.41	69.21	398.3	45.63	57.80

具体实现细节详见补充材料（第7节）。我们还提供了与实时分割模型的对比结果，详细信息见补充材料（第10节）。

表4将我们的模型与基准模型进行了对比。在 RELLIS -3D数据集上，所有ProGRecc变体均位列榜首，其中ViTMAE-Base模型实现了57.41%的mIoU值和69.21%的mAcc值，显著优于最强基线模型 Swin-UPerNet（53.86% mIoU，63.33% mAcc）。值得注意的是，轻量级 RMAE -4L变体（参数量46.47百万）以128.1 GFLOPs的计算效率实现了53.23%的mIoU值，超越了几乎所有基线模型。我们将在补充材料（第9节）中详细阐述各项指标的具体分解及计算分析结果。在 RUGD数据集上，采用我们ProGRecc解码器的ViTMAEBase模型再次取得45.63%的mIoU值和57.80%的mAcc值，超越SegFormer模型（43.69% mIoU，56.45% mAcc）。这种跨数据集的一致性提升与优异的计算性能相结合，充分证明了我们的方法在非结构化语义分割任务中的有效性。图1展示了精度与参数之间的权衡关系；我们在补充材料（第8节）中报告了各类别的IoU结果，表明模型在处理稀有类别、几何形状不规则或边界模糊的图像时均表现出显著提升。定性结果亦包含于补充材料（第11节）中。

表5展示了我们的ProGRecc解码器与 RMAE -8L编码器相较于[14]中报道的最先进模型的性能对比。采用 RMAE -8L编码器的ProGRecc模型在表5中显著优于先前方法。与 RELLIS-3

DC数据集-上-现有-最先进模型的对比结果。各类别数值均为-类别间IoU值。粗体表示最佳性能，*表示基于Transformer-模型的结果。

方法	光滑	禁止的，非光滑	障碍物	背景	mIoU↑	aAcc↑
分割器[31]	51.67	78.4	19.38	42.61	66.04	92.05
PSANet [45]	64.06	75.29	17.08	47.45	61.74	94.31
CGNet [36]	62.84	74.17	49.57	45.41	68.88	94.31
PSPNet [44]	69.21	80.99	8.89	53.7	60.7	94.67
DeepLabv3+ [5]	65.76	79.84	19.72	47.52	64.88	95.92
BiseNetv2 [41]	65.56	73.24	39.35	48.17	71.91	93.78
SETR* [46]	65.37	78.64	40.89	52.59	63.8	91.87
丹网[11]	72.93	85.18	13.10	60.60	70.53	95.95
OCRNet [42]	74.67	83.04	27.76	60.44	70.22	92.58
DPT* [28]	5.42	76.65	47.13	54.87	62.74	85.5
FastFCN [35]	70.51	79.15	49.72	51.37	63.9	94.82
Segformer* [38]	60.28	79.78	53.35	53.78	66.82	85.37
FastSCNN [27]	67.06	77.6	56.49	49.76	70.31	94.43
GA-Nav-r32* [14]	76.73	86.86	23.49	71.58	71.24	94.65
GA-Nav-r16* [14]	78.37	85.58	28.63	67.55	73.82	95.73
GA-Nav-r8* [14]	78.5	88.25	37.28	72.34	74.75	96.07
进展 RMAE -8L	85.41	86.67	46.65	74.41	83.48	97.09

显著超过4%的mIoU提升幅度。此外，我们的方法在平滑、禁行区、障碍物和背景类别上均实现了最佳的每类别IoU性能，并在粗糙和颠簸类别上表现优异。可参阅补充材料中的可重复性说明。

4.4. 消融研究

4.4.1. 解码器在多种编码器环境下的有效性

为明确ProGRecc解码器的具体贡献并验证其有效性，我们开展了全面的消融实验，将其与其他最先进的解码器架构（均搭配多种基于CNN或Transformer的编码器骨干网络）进行对比，具体结果如表6所示。在所有四种基于Transformer的骨干网络中，ProGRecc均实现了最高的mIoU和mAcc值；在ResNet101-V1c编码器骨干网络上也

展现出竞争力。采用ViT-B16模型时，ProGRecc的mIoU达到55.68%，而基于FPN的UPerNet解码器仅为48.03%，性能提升达7.65%。同样，在使用我们提出的RMAE-4L编码器时，ProGRecc的mIoU为53.23%，mAcc为63.04%，在mIoU指标上分别超越DeeplabV3+（4.93%）和UPerNet（4.74%）。这种在不同编码器架构下的一致性性能提升充分证明了ProGRecc解码器的有效性。

表6.在RELLIS-3D数据集中针对多个编码器的解码器有效性进行的消融实验。加粗数值表示最佳性能。需注意，所报告的参数数量仅适用于解码器，并且会因各编码器生成的输入特征维度不同而有所差异。

编码器	解码器	参数(M)↓	mIoU↑	mAcc↑
ResNet101-V1c	ISANet	11.81	40.65	49.86
	EncNet	10.0	42.88	53.03
	DeeplabV3+	17.7	46.98	56.12
	进步：进展	5.91	42.39	51.39
斯温变压器	UPerNet	33.25	51.01	61.23
	进步：进展	4.41	52.16	62.34
MiT-B5	SegFormer	0.53	51.51	60.66
	进步：进展	1.12	54.11	62.99
ViT-B16	DPT	23.87	47.95	57.32
	UPerNet	32.27	48.03	56.17
	进步：进展	4.86	55.68	67.68
RMAE-4L	UPerNet	67.86	48.03	56.17
	DeepLabV3+	14.4	49.30	58.30
	进步：进展	9.46	53.23	63.04

除了精度优势外，ProGRecc在大多数配置下都展现出优异的参数效率。以ViT-B16为例，其仅使用486万个参数（比UPerNet的3227万个参数减少85%），同时仍能实现更高的精度。解码器的参数数量因编码器特征维度的不同而有所差异：唯一在参数效率方面存在差距的是采用SegFormer架构的MiT-B5（仅需530万个参数）；但ProGRecc仅用112万个参数就实现了更高的精度（mIoU值分别为54.11%和51.51%）。这种在ResNet、Swin、MiT及ViT等不同骨干网络架构上的持续性能提升，充分彰显了ProGRecc的架构优势。总体而言，实验结果表明所提出的解码器不仅能有效捕捉多尺度上下文信息，还能在多种编码器设计中保持高度灵活性与高效性。

4.4.2. 各解码器组件的影响

为分析ProGRecc解码器中各组件的贡献度，我们在RELLIS-3D测试集上使用RMAE-8L编码器，在冻结训练和微调两种设置下进行了系统的消融实验。实验采用补充材料（第7节）中讨论的相同实现参数，并进行两项关键调整：首先，将最近点插值替换为双三次

插值，以减少可能产生的混叠伪影并提升移除解码器模块时特征过渡的平滑性；其次，采用ViTMAE层间学习率配置中前8层的学习率参数应用于RMAE-8L编码器（具体方案详见补充材料第7节）。这些调整旨在保持梯度稳定性，并确保部分剪枝架构的安全优化。

表7.关于ProGRecc解码器各组件影响的消融实验研究。我们在RELLIS-3D测试集上分别训练并比较了冻结式与微调式RMAE-8L编码器的性能表现。需注意这些层均添加于分割头之上。

BFF	PLF	自融合	LCAR	冷冻 RMAE-8L		经过精细调校的 RMAE-8L	
				mIoU↑	mAcc↑	mIoU↑	mAcc↑
×	×	×	×	49.02	59.20	52.52	60.55
✓	×	×	×	49.01	58.82	54.56	66.68
✓	✓	×	×	52.60	62.09	56.15	66.35
✓	✓	✓	×	52.81	62.15	56.56	67.01
✓	✓	✓	✓	53.18	62.36	56.90	68.25
×	✓	✓	×	51.51	61.46	56.78	66.85
×	×	×	✓	51.03	60.69	54.51	63.15

表7展示了我们在分割头基础上逐步添加组件时获得的结果。不包含任何解码器组件的基线模型在冻结设置下达到49.02%的mIoU值，在微调后提升至52.52%。添加BFF模块在冻结设置下仅带来小幅提升（49.01%），但在微调后显著提升了+2.04个百分点的mIoU值（54.56%）。在BFF基础上进一步加入PLF模块则实现显著改进，冻结设置下达到52.60%，微调后提升至56.15%；继续整合Self Fusion模块则持续带来性能提升，分别达到52.81%和56.56%的mIoU值。完整的ProGRecc解码器（包含BFF、PLF、Self Fusion及LCAR模块）表现最佳：冻结设置下mIoU为53.18%、mAcc为62.36%；微调后则达到56.90%的mIoU和68.25%的mAcc。如最后两行所示，单独使用PLF或LCAR模块会导致性能明显下降。总体而言，这些结果充分体现了各模块的优势，并验证了整体ProGRecc解码器设计的有效性。

4.4.3. 插值方法的选择

插值处理会影响特征上采样过程，我们的解码器在两个关键阶段均采用上采样（公式5和10）。因此，我们使用RMAE8LProGRecc模型比较了三种插值方法——双三次插值、双线性插值及最近邻插值，结果如表8所示。

所有方法均得出几乎一致的结果，差异值均低于0.42（mIoU）和0.38（mAcc），表明ProGRecc对插值方式的选择基本不敏感。然而，最近邻插值法实现了最高的mIoU值（57.14%），但其一致性指标显著较低。

表8. 使用RMAE8L-ProGRess进行插值与精度对比。

插值	mIoU↑	mAcc↑
双三次的	57.10	68.42
双线性性的	56.72	68.80
最近的：最接近的	57.14	68.53

与双线性及双三次插值相比，其计算成本更低，因为仅需进行索引映射而无需其他数学运算。这一结果表明，在我们的框架中，最近邻插值能够有效替代双线性或双三次插值方法，既提供了计算效率更高的替代方案，又不牺牲精度。

4.5. 零样本领域泛化

表9展示了我们提出的ProGRess模型（使用 RMAE -8L编码器）在RUG-REL-Common数据集上的零样本领域泛化性能结果。为便于比较，我们从表4中选取了性能最优的基于CNN和Transformer的模型，并与我们的方法进行对比评估。所有模型均仅在 RELLIS -3D数据集上训练，并直接在RUG-REL-Common数据集上测试**未进行任何微调**，从而确保本次评估属于严格的零样本评估。

表9. 在RUG-REL-Common数据集上的零样本领域泛化性能。这些方法均采用表4中讨论的相同编码器，我们则使用配备ProGRess解码器的 RMAE -8L变体模型。

方法	草	树	柱子	水	天	车辆	目标	树干	建筑	记录	人	栅栏	灌木	混凝土	mIoU↑
DeepLabV3+	10.57	56.07	2.25	0.0	64.22	9.51	0.2	0.01	4.93	0.03	0.0	6.58	2.21	21.8	12.31
OCNet	13.7	58.79	7.02	0.0	66.1	13.51	0.04	0.0	10.26	0.06	0.0	0.01	2.43	14.09	13.29
Segformer	45.51	39.93	6.0	0.11	60.28	9.72	1.1	0.72	1.63	3.07	0.0	0.01	4.4	63.55	16.86
Segmenter	53.99	62.07	0.05	0.0	74.36	3.49	0.5	5.75	3.61	3.24	0.0	0.0	7.78	45.19	18.57
商品A-Pro400s	48.23	61.19	7.22	0.0	73.75	13.29	0.16	0.16	3.09	8.96	0.01	0.01	4.8	49.97	19.35
进阶：进展	62.13	51.08	11.93	0.0	61.75	20.27	0.74	4.79	1.26	11.73	0.0	0.15	13.09	55.28	21.01

RELLIS -3D与 RUGD 在视觉外观、地形结构及物体分布方面存在显著差异，导致直接迁移面临挑战。因此，在这种严格的零样本场景下，所有方法的mIoU值均相对较低（表9）。尽管如此，ProGRess仍优于所有基线模型，展现出更强的领域迁移鲁棒性。尤其在多个关键类别中表现最佳：**草丛**（62.13%）、**杆柱**（11.93%）、**车辆**（20.27%）、**沥青路面**（4.79%）、**树干**（11.73%）以及**灌木丛**（13.09%）。总体而言，我们的模型实现了最高的mIoU值21.01%，在这一具有挑战性的跨领域场景中超越了所有基线模型。这些结果充分证明了ProGRess无需目标域监督即可在视觉特征和结构特征迥异的领域间实现有效泛化的能力。

5. 局限性、未来发展方向及伦理考量

局限性与未来方向。虽然我们提出的模型在计算效率方面仍优于现有基线模型，但其参数数量和浮点运算量均高于PIDNet[39]、BiseNetV1[40]、STDC[10]及

DDRNet[17]等实时模型（详见补充材料第10节）。此外，我们已对模型中各模块的浮点运算量进行了细分分析，并提出了在保证精度的前提下降低计算成本的优化方案（详见补充材料第9节），供后续研究参考。未来工作计划包括针对结构化场景中的非结构化类别开展模型评估——这一方向的探索源于我们在城市景观数据集上取得的良好性能（参见补充材料第13节）。**伦理考量。**本研究提出的语义分割模型适用于非结构化环境，可广泛应用于自动驾驶导航、灾害响应、农业监测及生态监测等领域。我们强调该模型应遵循伦理原则使用，反对任何可能带来风险或侵犯人权的行为。尽管我们的方法能提升复杂地形环境中的态势感知能力，但仅应在透明、可问责且受监督的框架内应用。所有模型均基于不含敏感内容的公开数据集进行训练，并将公开全部代码、配置参数及预训练权重，以确保可复现性并促进负责任使用。

6. 结论

本文提出 RMAE -ProGRess——一个专为非结构化环境下的语义分割设计的轻量级编码器-解码器框架，这一场景在现有研究中尚未得到充分探索。我们通过从经过MAE预训练的ViT-Base模型中剪枝层，提出了改进型MAE（RMAE）编码器；同时开发了由PLF、LCAR和BFF模块组成的新型ProGRess解码器。我们的方法在RELLIS -3D、RELLIS -3DC和 RUGD 数据集上均取得业界领先性能，在保持参数量竞争力的同时超越了强大的CNN及基于Transformer的基线模型。我们在零样本领域迁移任务中也展现出优异表现，充分证明了所提架构的鲁棒性。总体而言，研究结果表明：精心的架构设计能够为非结构化场景下的语义分割提供精准解决方案。通过ProGRess，我们致力于推动非结构化场景下的模型设计与基准测试发展，为**该领域进步**作出贡献，并激励超越传统结构化基准的研究方向。

致谢

本研究由霍华德大学人工智能/机器学习卓越中心（CoE- AIML）根据与美国陆军研究实验室签订的W 911NF-20-2-0277号合同资助。但本文中表达的所有观点、发现、结论或建议均仅代表作者个人立场，不应被视为代表资助机构的官方政策（无论是明示还是暗示）。