


核心速览



论文题目: MHLA: Restoring Expressivity of Linear Attention via Token-Level Multi-Head

中文题目: MHLA : 通过标记级多头恢复线性注意力的表达性

论文链接: <https://arxiv.org/pdf/2601.07832>

所属单位: 北京大学, 英伟达

核心速览: 本文提出了多头线性注意力 (MHLA), 通过在令牌维度划分头部计算注意力, 解决线性注意力的全局上下文坍塌问题, 在保持线性复杂度的同时恢复软注意力的表达能力, 并在多个领域验证了其有效性。

论文内容详细解读:

<https://mp.weixin.qq.com/s/DyO1oxQ4vHP1jkS0X1CTkQ>

```
MHLA(  
  (norm): LayerNorm((32,), eps=1e-05, elementwise_affine=True)  
  (to_qkv): Linear(in_features=32, out_features=96, bias=False)  
  (q_norm): Identity()  
  (k_norm): Identity()  
  (lepe): Conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), groups=32)  
  (piece_attn): BlockDistanceConv(  
    (conv): Conv2d(4, 4, kernel_size=(1, 1), stride=(1, 1), bias=False)  
  )  
  (to_out): Sequential(  
    (0): Linear(in_features=32, out_features=32, bias=True)  
    (1): Dropout(p=0.1, inplace=False)  
  )  
)
```

Input shape: torch.Size([2, 4, 49, 32])
Output shape: torch.Size([2, 4, 49, 32])

哔哩哔哩/微信公众号：AI缝合术，独家整理！