

SEMC：结构增强的专家混合对比学习用于超声标准平面识别

蔡庆¹、严贵豪¹、张帆^{2*}、张成^{1*}、刘志³

¹中国海洋大学信息科学与工程学院

²香港理工大学卫生技术及资讯学系

³山东大学信息科学与工程学院

cq@ouc.edu.cn, {yanguihao, zhangcheng}@stu.ouc.edu.cn, fan-hti.zhang@polyu.edu.hk, liuzhi@sdu.edu.cn

摘要

超声标准平面识别对于疾病筛查、器官评估和生物特征测量等临床任务至关重要。然而现有方法难以有效利用浅层结构信息，且难以通过图像增强生成的对比样本捕捉细粒度语义差异，最终导致对超声标准平面中结构特征和判别细节的识别效果欠佳。为解决这些问题，我们提出 SEMC——一种创新的结构增强混合专家对比学习框架，该框架将结构感知特征融合与专家引导对比学习相结合。具体而言，我们首先引入新型语义-结构融合模块（SSFM），通过有效对齐浅层与深层特征，充分利用多尺度结构信息，从而显著提升模型感知细粒度结构细节的能力。随后，我们设计了一种新型专家混合对比识别模块（MCRM），该模块通过专家混合（MoE）机制实现多层次特征的分层对比学习与分类，从而进一步提升类别可分性与识别性能。更重要的是，我们还精心整理了一个包含六个标准平面的大规模肝脏超声数据集。在内部数据集和两个公开数据集上的大量实验结果表明，SEMC 在各项指标上均优于近期最先进的方法。

代码 -<https://github.com/YanGuihao/SEMC>

数据集——<https://github.com/YanGuihao/SEMC>

引言

超声成像凭借其无创性、实时性、高效性和低成本等优势（斯宾塞和阿德勒，2008），已成为临床实践中应用最广泛的医学影像技术之一。该技术在人体器官和软组织成像方面表现尤为突出，因此在产前检查中应用广泛。在临床诊疗流程中，获取标准平面（SP）对实现精准诊断和定量评估至关重要。这些平面不仅为临床医生提供了可靠的结构可视化图像，还建立了统一的解剖学参考基准用于测量（王等，2022）。

*通讯作者

版权归2026年人工智能促进协会所有（www.aaai.org）。保留所有权利。




图1: (a)超声标准平面呈现显著的组内方差（同一平面的图像可能差异明显），而组间方差较小（不同平面的图像通常具有高度相似的视觉特征）。(b)现有方法主要依赖深层语义特征，而忽视浅层结构线索。(c)相比之下，我们的 SEMC 框架通过语义-结构融合整合浅层结构，并采用门控编码器（MoE）进行分层对比学习，从而生成更具判别力且结构感知更强的表征。

（Di Cosmo等，2022年）。例如，在产前超声检查中，常采用股骨标准平面、丘脑标准平面和腹部标准平面来测量胎儿

分别测量胎儿的身长、头围和腹围。这些生物测量指标是评估胎儿生长的关键参数（Salomon等，2006；Guo等，2022）。然而，所获标准平面的质量可能因操作者经验及扫描技术的不同而存在显著差异，这可能影响生长评估的准确性及后续临床决策（Salomon等，2011；Maraci等，2014）。

近期研究探索了基于深度学习的标准平面（SP）识别方法，并取得了令人鼓舞的成果（Pu等，2021；Migliorelli等，2024）。然而，SP识别仍面临若干关键挑战。由于散斑噪声、低对比度及解剖结构边界模糊，超声图像质量存在显著差异，这使得结构区域检测本质上具有难度。如图1(a)所示，同一解剖平面的图像因采集角度不一致、探头压力差异及操作者经验不同而呈现显著外观差异（Lin等，2019；Xie等，2020；Yu等，2024；Krishna与Kokil，2024），而不同平面的图像则常因低对比度和边界模糊而表现出细微视觉差异，需要精细的判别能力（Baumgartner等，2016，2017）。现有方法大多聚焦于深度语义表征，而忽视浅层结构线索（Cai等，2018a；Zhang等，2024b；Yan等，2025），从而限制了模型在语义判别和结构感知方面的表现（Men等，2023；Li等，2025年；刘、叶和杜2024年；张等人2024a年）。此外，尽管对比学习已被纳入辅助策略，通过构建增强的正负样本对来实现，但这些技术往往难以捕捉超声图像固有的细微语义差异，如图1(b)所示。

针对这些不足，我们提出了一种新型结构增强型专家混合对比学习框架——SEMC。该框架通过有效整合结构感知特征融合与专家引导对比学习，成功攻克了超声标准平面识别中的固有挑战。具体而言，我们设计了新型语义-结构融合模块（SSFM），该模块能显式对齐并整合浅层结构线索与深层语义表征，显著提升了模型对精细结构细节的感知能力。为增强模型的判别能力，我们创新性地设计了专家混合对比识别模块（MCRM），其中多个专家分支专门针对特征空间的不同维度进行专业处理，并协同执行分层对比学习（如图1(c)所示）。通过在多特征层级强制对比学习目标，该框架有效提升了表征空间中的类间可分性，并实现了更紧凑的类内聚类。此外，我们构建了一个高质量的肝脏超声数据集LP2025，包含六个标准平面，以解决公开可用数据中标准平面识别的稀缺性问题。在该数据集及两个公开标准平面基准数据集上的评估表明，SEMC在多项指标上优于现有最先进方法，显示出强大的临床应用潜力。综上所述，我们的主要贡

献如下：

- 我们提出一种新型结构增强型混合专家对比学习框架 SEMC，该框架整合语义-结构融合与混合专家对比识别模块，以提升超声平面识别的细粒度结构感知能力与判别性特征表征。
- 我们构建了LP2025高质量肝脏超声数据集，该数据集包含六个标准平面，旨在解决公开可用基准数据的稀缺性问题，并支持标准平面识别领域的进一步研究。
- 在两个公开数据集和我们内部肝脏超声数据集上进行的大量实验表明，SEMC框架在标准平面识别任务中始终优于现有最先进的方法。

相关工作

超声平面识别

标准平面识别是医学图像理解中的基础任务，具有疾病筛查、器官功能评估和生物特征测量等广泛临床应用。早期方法依赖人工特征与传统分类器（例如SVM和KNN）结合，但由于特征表示薄弱和超声质量低，其泛化能力受限（Christodoulou等，2003；Latha、Samiappan和Kumar，2020；Huang等，2020；Liao、Cheng和Chan，2024）。近年来，卷积神经网络（CNNs）已成为主流解决方案。例如，基于VGG架构的SonoNet系列（Baumgartner等，2017）在胎儿标准平面识别中取得了显著性能。后续研究通过引入多任务学习、注意力机制（Cai等，2021；Zhang等，2024c）和结构先验，增强了模型识别关键区域和捕捉精细变异的能力（Cai等，2018b；Zhu、Salcudean和Rohling，2022；Yu等，2024；Ciobanu等，2025）。然而，这些方法主要依赖于高层次特征，往往忽视浅层结构线索和空间上下文，导致在细微的类别差异或复杂的成像条件下性能下降。为克服这一问题，我们引入了一个语义-结构融合模块，该模块整合浅层和深层特征以增强结构表征和区分能力。

对比学习与专家混合

对比学习在提升表征学习方面展现出巨大潜力，尤其在数据有限且类别边界模糊的医学影像任务中效果显著。诸如MoCo（何等人，2020）和SimCLR（陈等人，2020）等方法通过构建正负样本对优化表征空间，有效提升类别内部紧凑性和类别间可区分性。监督对比学习（Khosla等人，2021；Lin等人，2024）则通过在配对过程中利用标签信息，进一步增强了判别能力和语义一致性。




图2：所提出的 SEMC 框架架构。该框架首先采用基于多专家（MoE）的特征提取器，从输入的超声图像中生成多层次专家特征。这些特征随后通过语义-结构融合模块（SSFm）进行对齐和增强。最终生成的特征表示被输入到专家混合对比识别模块（MCRM），该模块包含两个分支：作为主要任务的多分类分类头，以及作为辅助任务的基于 MoE 的对比学习分支，通过优化已学习的特征表示来进一步提升主要任务的性能。

与此同时，模块化增强（MoE）范式因其动态建模能力和参数效率而备受关注（Shazeer等，2017；Riquelme等，2021；Zoph，2022）。例如，条件性 MoE（Zhu 等，2022）和开关式 Transformer（Fedus、Zoph 和 Shazeer，2022）在自然语言处理和计算机视觉领域均取得重大突破。然而，在解剖结构复杂且边界模糊的超声图像分析中，MoE 与对比学习的融合仍待深入探索。现有方法缺乏有效机制来利用结构线索引导专家协作。为此，我们提出一个框架，将结构增强特征融合与对比式专家建模相结合，显著提升了模型在标准平面分类任务中识别细微差异的能力。

方法学

工作流程概述

我们提出了一种新型结构增强型专家混合对比学习（SEMC）框架，用于超声标准平面识别。如图2所示，我们的核心贡献包含两个主要组件：(1) 语义-结构融合模块，该模块通过显式对齐和整合多层次特征来增强结构感知能力；(2) 基于 MoE 的对比识别模块，该模块利用专家特定特征同时进行对比学习和分类。通

过联合优化监督学习与自监督学习的特征空间，该模块显著提升了模型的类别可分性和识别性能。在后续章节中，我们将详细阐述这两个模块的具体实现以及我们自主研发的数据集。

LP2025数据集构建

数据采集。为推进超声成像中标准平面识别的研究，我们推出 LP2025 数据集——这是一个专为基于深度学习的解剖学理解与分类而精心构建的高质量综合数据集。该数据集由一家顶尖三级医疗中心的资深放射科医师和认证超声技师在临床监督下开发完成。所有超声扫描均采用高分辨率诊断系统采集，确保图像质量卓越且结构清晰可见。通过严格遵循标准化成像方案，统一不同患者及扫描批次的操作流程，从而保证解剖结构覆盖范围、空间分辨率及诊断相关性的统一性。

所有受试者均接受系统性腹部超声检查，在此过程中精确采集了六个具有临床意义的肝脏标准平面图像。

平面	缩写	数量
第一肝门平面	FHP1	979
第二肝门平面	FHP2	324
左叶平面	低层次结构规程	1038
右叶平面		490
左门静脉矢状面	LPV-S	840
肝肾平面	HRP	1072
非标准平面	NSP	4626
共计	-	9369

表1: LP2025数据集在六个肝脏标准平面及非标准（NSP）类别的图像分布。

选择的平面基于其在肝胆系统评估中的诊断相关性及其在常规临床工作流程中的高频使用。LP2025中的六个标准平面如下：

- 第一肝门平面（FHP1）：捕捉门静脉分叉处，作为肝分割的关键解剖标志。
- 第二肝门平面（FHP2）：显示门静脉与肝动脉的延续，便于血管评估。
- 左叶平面（LLP）：显示左肝叶的形态学特征及实质结构模式。
- 右叶平面（RLP）：显示右肝叶的纹理和大小，常用于评估肝肿大和肝脏病变。
- 左门静脉矢状面（LPV-S）：可清晰显示左门静脉分支的矢状面影像，有助于血管诊断。
- 肝肾平面（HRP）：显示肝脏与右肾的交界区域，常用于检测腹水或占位性病变。

除六个标准平面外，LP2025还包含非标准平面（NSP）类别，该类别包含不符合上述诊断视图但在常规超声检查中常见的图像。这一类别的引入增加了实际可变性与分类模糊性，从而增强模型稳健性，更真实地反映临床实际应用场景。

数据集组成与注释质量

为确保标签的准确性、一致性及临床有效性，LP2025数据集中的每幅图像均由一组资深超声技师独立标注，所有标注人员均具有超过五年肝脏超声成像的实践经验。标注过程重点关注两个关键方面：标准平面分类及可清晰识别的解剖结构存在情况。

为维持高标准的注释质量，实施了严格的多阶段质量控制流程：

- 初步审核：每项标注均由两名超声技师独立交叉核对，以发现潜在不一致或错误。

- 共识验证：对于存在分歧的病例，至少由三位资深超声医师参与共识讨论，以确保临床标签的可靠性。
- 最终验证：进行最后一轮检查以评估每张图像的临床相关性，并排除可能对模型训练或评估产生负面影响的低质量或模糊样本。

这一全面的多专家评审流程确保了LP2025的可靠性和可信度，为算法开发和临床导向研究奠定了坚实基础。

表1汇总了LP2025数据集，该数据集包含9,369幅高质量、经临床验证的肝脏超声图像，覆盖六个标准平面。所有患者数据均经过彻底匿名化处理，在采集、处理或发布过程中均未保留任何可识别信息。

专家混合特征提取模块

为捕捉超声图像中的精细变化与复杂解剖结构，我们设计了一个模块化特征提取模块。前三个模块（即第1层至第3层）在所有分支中共享，作为提取低级和中级特征的通用编码器。在第3层之后，我们引入三个并行的、结构相同但参数独立的第四阶段模块（分别标记为第4-1层、第4-2层和第4-3层），形成三条专业化的深度专家路径：

$$F_1, F_2, F_3 = \text{ResNet}_{1\sim 3}(\mathbf{x}), \quad (1)$$

$$D_1 = \text{ResNet}_{4-1}(F_3), \quad (2)$$

$$D_2 = \text{ResNet}_{4-2}(F_3), \quad (3)$$

$$D_3 = \text{ResNet}_{4-3}(F_3), \quad (4)$$

其中 F_3 表示共享主干网络的输出特征， $\{D_1, D_2, D_3\}$ 则代表各专家路径提取的高层次语义特征。该设计通过解耦的专家参数引入多样化特征表征，使得后续融合模块能够对不同语义视角进行建模与选择。

语义结构融合模块（SSFM）

现有方法大多聚焦于深度特征，却忽视了浅层特征的互补价值，尤其在解剖结构对比度较弱或边界模糊的情况下。为解决这一局限，我们提出了一种新型结构-语义融合模块（SSFM），通过自适应压缩扩展（ACE）模块和结构感知多上下文（SAMC）模块两大组件，实现浅层与深度特征的深度融合。该设计在提升特征区分度的同时，也增强了结构表征能力。

自适应压缩-扩张块（ACE）。为解决浅层特征与深层特征之间的空间和通道不匹配问题，我们提出了一种轻量级ACE模块。该模块通过渐进式下采样和通道自适应，将浅层特征 $\{F_1, F_2, F_3\}$ 与深层专家特征进行对齐。每个ACE模块处理输入 $\mathbf{X}_0 = F_i$

通过 L 个连续阶段:

$$x_{i+1} = \text{BN}(\text{Conv}_{1 \times 1}(\text{ReLU}(\text{BN} \cdot \text{DW会话}_{\times 3}(\text{sp_2} > x_i))))), \quad (5)$$

$i = 0, 1, \dots, L - 1$, 其中通道尺寸在每一步翻倍, 遵循 $C_i = C_{in} \times 2^i$ 。经过 L 个阶段后, 通过 1×1 卷积, 再经过BN和ReLU映射 $\mathbf{X}_L$, 最终达到目标通道维度 C_{out} :

$$\mathbf{F} \hat{=} \text{ReLU}(\text{BN}(\text{Conv}_{1 \times 1}(\mathbf{X}_L))), \quad (6)$$

生成对齐特征 $\mathbf{F} \hat{=} \mathbf{F} \in \mathbb{R}^{C_{out} \times H_L \times W_L}$ 。

ACE首先通过步长深度卷积降低空间分辨率, 随后通过逐点卷积调整通道维度, 在保持结构信息的同时提升计算效率。经过对齐的浅层特征随后通过元素级加法与深度专家特征 $\{D_1, D_2, D_3\}$ 融合:

$$\mathbf{M}_i = \mathbf{F} \hat{+} D_i, \quad i = 1, 2, 3. \quad (7)$$

与特征拼接相比, 这种融合策略能避免通道冗余、减少参数量, 并促进共享判别模式的学习。**结构感知多上下文块 (SAMC)**。为增强融合特征的判别能力和结构表征, 我们提出了一种新型 SAMC 模块, 该模块通过一组并行多尺度卷积在多个感受野间重建特征模式。此外, 协同的通道-空间注意力机制可自适应地突出信息性响应。通过联合建模语义线索与空间结构, SAMC 使模型能够在抑制无关背景变化的同时捕捉精细解剖细节。对于每个融合分支 $\mathcal{M}_i$, 其处理流程如下:

$$\begin{aligned} \mathbf{C}_i = & \sigma \left(\text{FC}_2 \left(\delta \left(\text{FC}_1 \left(\text{AvgPool}(\mathcal{M}_i) \right) \right) \right) \right. \\ & \left. + \text{FC}_2 \left(\delta \left(\text{FC}_1 \left(\text{MaxPool}(\mathcal{M}_i) \right) \right) \right) \right), \quad (8) \end{aligned} \quad i = 1, 2, 3,$$

其中 $\mathbf{C}_i \in \mathbb{R}^C$ 是自适应通道注意力。全局池化捕捉上下文信息, 而共享的全连接层通过激活函数 $\delta(\cdot)$ 捕捉通道间依赖关系。Sigmoid $\sigma(\cdot)$ 生成归一化注意力权重。

$$\mathbf{S}_i = \sigma(\text{Conv}([\text{Mean}(\mathbf{C}_i \odot \mathcal{M}_i, \text{dim} = 1), \text{Max}(\mathbf{C}_i \odot \mathcal{M}_i, \text{dim} = 1)])), \quad i = 1, 2, 3, \quad (9)$$

其中 $\mathbf{S}_i \in \mathbb{R}^{1 \times H \times W}$ 表示由通道精炼特征生成的空间注意力图。卷积层聚合空间线索, 引导网络聚焦解剖学相关区域。

$$\mathbf{O}_i = \text{Conv}(\text{Shuffle}(\text{Concat}(\{\mathbf{F}_k^{(i)}\}_{k=1}^K))), \quad (10) \quad i = 1, 2, 3,$$

其中 $\{\mathbf{F}_k^{(i)}\}_{k=1}^K$ 表示从空间增强输入 $\mathbf{S}_i \odot \mathbf{C}_i \odot \mathcal{M}_i$ 中提取的多尺度特征。这些特征被拼接、通道混洗以促进跨通道交互, 并通过逐点卷积压缩以生成融合输出 $\mathbf{O}_i$ 。

MoE对比识别模块(MCRM)

现有方法通过在训练过程中构建增强的正负样本对, 将对比学习作为辅助识别策略引入。然而, 这些方法往往难以有效捕捉超声图像中固有的细粒度语义变化。为解决这一问题, 我们设计了一种新型MoE对比识别模块, 该模块包含两个协同分支: (1)MoE对比分支: 多个专家子网络聚焦于特征空间的不同区域, 协同执行分层对比学习, 从而增强学习表征中的类间可分性和类内紧凑性; (2)MoE识别分支: 专家子网络从多样化的语义视角和空间尺度中提取互补的判别线索, 从而提升模型准确识别各类标准平面的能力。

MoE对比分支。为充分利用多层级语义与空间信息进行超声平面识别, 我们提出一种MoE增强对比分支, 该分支包含三个共享同一主干网络但由不同融合视角监督的专家分支。第一个专家输出 $\mathbf{O}_1$ 作为对比锚点(查询), 而 $\mathbf{O}_2$ 和 $\mathbf{O}_3$ 作为动态队列的正向键用于支持负采样更新。所有专家的分类logit被拼接, 真实标签被复制用于语义监督。当前专家特征进一步与动量记忆队列 $\mathbf{Q}$ 集成, 该队列存储历史表征以促进结构对比学习:

$$\mathbf{O}_{con} = \text{连接}(\mathbf{O}_1, \mathbf{O}_2, \mathbf{O}_3, \mathbf{Q}), \quad (11)$$

$$\mathbf{Y}_{con} = \text{连接}(\mathbf{y}, \mathbf{y}, \mathbf{y}, \mathbf{y}_Q), \quad (12)$$

其中 $\mathbf{O}_i$ 表示专家输出, $\mathbf{y}$ 和 $\mathbf{y}_Q$ 分别表示当前批次和队列的标签。沿批次维度拼接特征可扩大正负样本对的池, 从而提升对比学习效果。

我们定义了两种互补的损失函数: 监督对比损失利用标签信息将语义相似的样本拉近, 而自监督对比损失则通过从当前批次和队列中挖掘类别一致的样本来识别正样本对, 无需依赖显式标签。

$$\mathcal{L}_{sup} = \text{SupCon}(\mathbf{O}_{con}, \mathbf{Y}_{con}), \quad (13)$$

$$\mathcal{L}_{self} = \text{SelfCon}(\mathbf{O}_{con}). \quad (14)$$

最终目标被定义为两个损失的加权总和, 由平衡因子 λ 控制:

$$\mathcal{L}_{mc} = \mathcal{L}_{sup} + \lambda \mathcal{L}_{self}, \quad (15)$$

其中 λ 控制自监督信号的相对强度。该统一对比框架通过联合优化显式语义判别与隐式结构对齐, 显著提升了超声标准平面识别中的表征鲁棒性与泛化能力。

MoE识别分支在标准平面识别中, 专家子网络能捕捉多样化特征模式, 但简单平均法可能忽略样本特异性差异。

方法	FPUS23				加缪			
	准确率↑	精确度↑	召回↑	F1分数↑	准确率↑	精确度↑	召回↑	F1分数↑
双歧杆菌 (Yang等, 2023)	95.29	80.63	81.58	81.08	80.91	80.25	79.20	79.69
面积 (Chen等, 2023年)	95.20	93.37	95.71	94.40	81.59	80.17	82.53	80.88
Shike (Jin等, 2023年)	95.15	93.80	94.93	94.31	80.48	79.58	79.79	79.52
Metaformer (Yu等, 2023年)	95.52	94.19	94.48	94.53	81.52	81.58	79.69	80.49
铸件 (Ke、Mo和Yu, 2024年)	95.24	94.23	93.99	94.43	81.34	80.85	79.88	80.31
Supmin (Mildenberger等, 2025年)	95.28	94.03	94.68	94.34	81.13	80.88	78.84	79.71
SEMC (我们的)	95.78	94.38	95.81	95.06	82.13	82.03	80.08	80.93

表2: 不同模型在FPUS23和camus数据集上的定量比较

为解决这一问题, 我们提出了一种新型的MoE分类分支, 该分支配备了一个可学习的稀疏门控机制。通过利用Gumbel-Softmax (Lin等人, 2017), 该门控机制能够自适应地选择最具信息量的专家, 同时保持完全可微分性, 从而提高了对解剖学模糊性和影像变异性的鲁棒性。

令语义-结构特征为 $\mathbf{O} \in \mathbb{R}^{B \times C \times H \times W}$, 将其输入轻量级门控网络以生成专家logits $\mathbf{l} \in \mathbb{R}^{B \times N}$ 。该门控网络执行自适应平均池化后接线性层。随后通过Gumbel-Softmax函数获得门控权重 $\mathbf{w}$:

$$\mathbf{w} = \text{GumbelSoftmax}(\mathbf{l}, \tau), \quad (16)$$

其中 τ 控制分布的稀疏性。给定专家预测 $\mathbf{z}_n \in \mathbb{R}^{B \times C}$, 我们将它们堆叠成 $\mathbf{Z} \in \mathbb{R}^{B \times N \times C}$, 并计算融合输出为:

$$\mathbf{z}_{\text{fused}} = \sum_{n=1}^N w_n \cdot \mathbf{z}_n. \quad (17)$$

融合预测 $\mathbf{z}_{\text{fused}}$ 采用标准交叉熵损失进行监督:

$$\mathcal{L}_{\text{moe}} = \text{CE}(\mathbf{z}_{\text{fused}}, \mathbf{y}). \quad (18)$$

该设计提升了语义分类的灵活性并减少了冗余的专家交互, 从而增强了模型的泛化能力。为平衡主分类损失 $\mathcal{L}_{\text{moe}}$ 与对比损失 $\mathcal{L}_{\text{mc}}$, 我们采用了一个轻量级自适应网络。给定输入特征 $\mathbf{O} \in \mathbb{R}^{B \times C \times H \times W}$, 该网络预测样本特定权重 $\alpha = g(\mathbf{O}) \in (0, 1)$ 。总体而言, 总损失通过两个损失的加权组合计算得出:

$$\mathcal{L}_{\text{total}} = \alpha \cdot \mathcal{L}_{\text{moe}} + (1 - \alpha) \cdot \mathcal{L}_{\text{mc}}. \quad (19)$$

平衡因子 α 会根据样本难度和训练过程动态调整。该机制无需手动调整超参数, 即可实现最优权重的端到端学习, 从而显著提升多任务协同训练的稳定性和效果。

实验结果

数据集与评估指标

FPUS23 (Prabakaran等人, 2023) 是一个公开的胎儿超声数据集, 用于标准平面识别, 涵盖头部、腹部、股骨和胸腔等关键解剖视图, 并配有适用于监督学习

的专家标注。**camus** (Leclerc等人, 2019) 是最初为分割设计的心脏超声数据集。我们选取了心尖双腔和四腔视图并进行标注以进行分类。其跨受试者的多样性使其非常适合评估模型泛化能力。此外, 我们使用了内部开发的**LP2025**数据集, 该数据集包含临床定义的腹部超声标准肝脏平面。为公平评估和比较我们的方法与现有方法, 我们采用了包括准确率、精确率、召回率和F1分数在内的四种常用指标。

实施细节

我们的方法基于PyTorch框架实现, 所有实验均在配备NVIDIA RTX 3090 GPU的服务器上运行Python 3.8环境完成。数据预处理阶段, 将所有数据集图像调整为512 × 512分辨率, 并采用随机旋转、水平/垂直翻转及亮度调节等数据增强技术。模型优化使用随机梯度下降 (SGD) 算法, 动量设置为0.9, 权重衰减率为 1×10^{-4} 。初始学习率设为 1×10^{-3} , 并采用余弦退火策略进行衰减。批量大小为16, 训练最多进行200个周期。

与前沿方法的比较

为评估模型的性能, 我们与近期最先进的方法进行了对比分析。这些方法包括在医学图像分析中表现优异的Diffmic (Yang等人, 2023年); 基于CNN并取得显著改进的Area (Chen等人, 2023年) 和Shike (Jin等人, 2023年); 基于Transformer并取得良好效果的MetaFormer (Yu等人, 2023年) 和Cast (Ke、Mo和Yu, 2024年); 以及采用改进监督对比学习的SupMin (Mildenberger等人, 2025年)。为确保公平比较, 所有模型均采用统一参数设置训练, 并在相同实验条件下进行评估。**FPUS23数据集结果**。表2显示, 在FPUS23胎儿标准平面数据集上, 我们的方法在所有指标上均表现最优。具体而言, 我们获得了95.78%的准确率, 比第二名的MetaFormer (95.52%) 高出0.26%。我们的方法还取得了最高的F1分数, 达到95.06%, 优于Area (94.40%) 和SupMin (94.34%)。这些改进

方法	LP2025			
	准确率 $\uparrow$	精确度 $\uparrow$	召回 $\uparrow$	F1分数 $\uparrow$
双歧杆菌	80.07	75.35	77.81	76.27
区域	80.39	75.43	76.21	75.04
石克	80.26	75.76	77.63	76.19
与前任	80.13	77.10	77.00	76.44
铸造	80.86	74.87	79.59	77.00
补肾明胆	80.92	75.95	78.12	76.77
我们的	82.30	78.11	80.92	79.32

表3：不同模型在内部LP2025数据集上的定量比较

源自提出的语义-结构融合模块，该模块能有效捕捉浅层结构线索与深层语义特征。此外，跨专家协同分类分支通过自适应融合多位专家的预测结果，从而提升分类系统的鲁棒性与整体准确率。

camus数据集上的实验结果。表2显示，我们的 SEMC 框架在camus心脏标准平面数据集上持续优于现有方法。SEMC 达到了82.13%的最高准确率，超越了MetaFormer（81.52%）和Area（81.59%）。同时，其F1分数达到80.93%，优于CAST（80.31%）和SupMin（79.71%）。这表明 SEMC 有效解决了超声成像中类内变异大、类间相似度高的特征。

ACE	沈阳飞机制造公司	LMC	准确率 $\uparrow$	F1分数 $\uparrow$
$\times$	$\times$	$\times$	80.26	76.98
$\checkmark$	$\times$	$\times$	81.38	77.82
$\checkmark$	$\checkmark$	$\times$	81.51	77.91
$\checkmark$	$\times$	$\checkmark$	81.78	78.65
$\checkmark$	$\checkmark$	$\checkmark$	82.30	79.32

表4：LP2025数据集中拟议ACE、SAMC 和 L_{mc} 的消融研究。

LP2025数据集实验结果。表3展示了我们在LP2025数据集上的实验结果，其中我们的方法取得了最先进的性能表现。具体而言，模型准确率达到82.30%，比Diffmic（80.07%）高出2.23个百分点；F1分数达到79.32%，比SupMin（76.77%）提升2.55个百分点。这些改进凸显了我们模型在捕捉不同肝脏视图间判别性结构差异和关键语义区域方面的强大泛化能力，从而实现了更优的分类性能。

消融研究

各组件的消融研究。我们基于LP2025数据集开展消融研究，以评估框架中各模块的贡献。如表4所示，我们逐步将 SSFM 和 MCRM 整合到基线模型中。SSFM 包含ACE和 SAMC 子模块，而 MCRM 引入了对比损失。




图3：在LP2025数据集上，不同超参数 α 值的性能对比。

即， L_{mc} ，以鼓励专家分支学习互补表征。基线模型达到80.26%的准确率和76.98%的F1分数。添加ACE将准确率提升至81.38%，F1分数提升至77.82%，证明其在捕捉浅层结构线索方面的有效性。此外，在ACE基础上添加 SAMC 进一步增强了对空间区域的注意力。或者，将ACE与 L_{mc} 结合可将准确率提升至81.78%，F1分数提升至78.65%，证明了专家引导对比学习的优势。启用所有模块后，模型达到最佳性能，证实这三个组件具有互补性，并共同增强特征表征和泛化能力。**自适应参数消融研究。**图3展示了方程(19)中定义的超参数 α 的敏感性分析。我们在LP2025数据集上进行系统性消融实验，测试固定值 α 0.01、0.05、0.1、0.2和0.5，以及我们提出的自适应系数。结果表明，该自适应策略优于所有固定设置，在显著提高分类准确率的同时，大幅提升了训练稳定性和模型整体鲁棒性。

结论

本文提出了一种新型结构增强型混合专家对比学习框架——SEMC，用于超声标准平面识别。具体而言，所提出的语义-结构融合模块将浅层结构特征与深层语义表征进行对齐整合。此外，混合专家对比识别模块被设计为在特征空间的不同维度进行专业化处理，并协同执行分层对比学习，从而捕捉精细的判别表征。更重要的是，我们建立了包含六个标准平面的高质量超声数据集，解决了公开基准数据的稀缺性问题。在该内部数据集及两个公开基准上的大量实验表明，SEMC 在性能上持续超越近期最先进的方法。